



Universitat
de les Illes Balears

TRABAJO DE FIN DE GRADO

SEGMENTACIÓN DE IMÁGENES PUNTIFORMES HIPERTENSAS EN SUSTANCIA BLANCA

Aina Maria Tur Serrano

Grado en Ingeniería Informática

Escola Politècnica Superior

Año académico 2023-24

SEGMENTACIÓN DE IMÁGENES PUNTIFORMES HIPERTENSAS EN SUSTANCIA BLANCA

Aina Maria Tur Serrano

Trabajo de Fin de Grado

Escola Politècnica Superior

Universitat de les Illes Balears

Año académico 2023-24

Paraules clau del treball: IPHSB, FLAIR, T1, T2, Segmentación, IA, U-NET

Tutor: Francisco José Perales López, Gabriel Moyà Alcover

Autoritz la Universitat a incloure aquest treball en el repositori institucional per consultar-lo en accés obert i difondre'l en línia, amb finalitats exclusivament acadèmiques i d'investigació

Autor/a		Tutor/a	
Sí	No	Sí	No
☒	☐	☒	☐

A mi madre, porque siempre creyó en mí
y a mi padre, que me enseñó el valor del esfuerzo

ÍNDICE GENERAL

Índice general	iii
Índice de figuras	v
Índice de cuadros	vii
Acrónimos	ix
Resumen	xi
1 Introducción	1
1.1 Contexto	1
1.1.1 Imágenes de Resonancia Magnética	2
1.1.2 Problemática	5
1.2 Objetivos	6
1.3 Estructura de la memoria	7
2 Materiales y Métodos	9
2.1 Métodos	9
2.2 Bases de Datos	15
2.2.1 Origen de los datos	15
2.2.2 Las imágenes	16
2.2.3 Características de los datos	18
2.3 Tecnologías	21
2.3.1 Lenguaje de programación	21
2.3.2 Librerías	21
2.3.3 Entorno	22
2.4 Métricas	23
2.5 Conclusión	24
3 Experimentación con U-NET	27
3.1 Estructura de las pruebas	27
3.2 Segmentador de lesiones WMH Segmentation Challenge MICCAI 2017	28
3.2.1 Primeras pruebas y eliminación de rebanadas sin tejido cerebral	29
3.2.2 Tamaño de las imágenes	31
3.2.3 Normalización	35
3.2.4 Concatenación de secuencias	37
3.2.5 Aumento de datos	38

3.3	Segmentador MSLesSeg del ICPR 2024	40
3.4	Discusión	43
3.5	Conclusión	47
4	Otras aproximaciones	49
4.1	3D-UNET	49
4.2	Segment Anything Model	52
4.3	MedSAM	55
4.3.1	Conclusiones	59
5	Conclusiones	61
5.1	Resultados	61
5.1.1	Experimentos con U-NET	61
5.1.2	Otras aproximaciones	62
5.2	Cumplimiento de objetivos	62
5.3	A futuro	63
A	Validación MICCAI 2017 WMH Segmentation Challenge	65
B	Entrenamiento ICPR 2024 MSLesSeg	69
	Bibliografía	71

ÍNDICE DE FIGURAS

1.1	Cuadro resumen de características y patologías producidas por las lesiones [1].	2
1.2	Relajación T1 y T2 [2].	4
1.3	Secuencia FLAIR, máscara y T1.	5
1.4	Secuencia T2 y máscara.	6
2.1	Multipliación matricial del filtro y la imagen [3].	10
2.2	Arquitectura de U-NET [4].	12
2.3	Arquitectura de la 3D U-NET [5].	12
2.4	Estructura de SAM [6].	14
2.5	Secuencias originales y preprocesadas con SPM12 r6685.	19
2.6	Ejemplo de normalización con MNI-152 [7].	19
2.7	Secuencias registradas con MNI-152 y skull-stripping.	20
2.8	Representación gráfica del cálculo de DICE [8].	23
2.9	Representación gráfica de IOU [8].	24
3.1	Muestra de datos que indica el problema de desbalance de clases. La mayoría de píxeles pertenecen al fondo, en lugar de las lesiones.	30
3.2	Rebanadas sin tejido cerebral.	30
3.3	Unión máscaras FLAIR y T1.	31
3.4	Redimensionamiento de las imágenes.	32
3.5	Recorte o padding a las imágenes.	33
3.6	Entrenamiento redimensionamiento 128x128, podemos observar el sobreajuste a partir de la época 5.	34
3.7	Unión máscaras segmentadores tamaño 240x240 de imagen.	35
3.8	Entrenamiento tamaño 240x240.	35
3.9	Proceso de aplicación de máscaras a las imágenes.	36
3.10	Transformaciones aplicadas a las imágenes.	39
3.11	Comparación entre los diferentes conjuntos de datos. A la izquierda, secuencia FLAIR del WMH Segmentation Challenge. A la derecha, secuencia FLAIR del MSLesSeg, podemos apreciar la eliminación del cráneo.	40
3.12	Segmentación de lesiones muy pequeñas.	45
3.13	Segmentación secuencia FLAIR de otro escáner.	45
3.14	Segmentación lesiones pequeñas y grandes.	45
3.15	Segmentación sin lesiones.	46
3.16	Contador de contornos.	46
3.17	Segmentaciones del ICPR 2024.	48

4.1	Visualización en 3D del cerebro, lesiones de patrón perivascular y de origen vascular. Las lesiones del patrón perivascular proceden de una secuencia del ICPR 2024 MSLesSeg y las de origen vascular proceden del MICCAI 2017 WMH Segmentation Challenge.	50
4.2	Entrenamiento 3D U-NET para MICCAI 2017 WMH Segmentation Challenge. Se puede observar como se produce un sobreajuste del modelo. Se empleó una tasa de aprendizaje de 5×10^{-5}	51
4.3	Entrenamiento 3D U-NET para patrón perivascular del ICPR 2024 MSLesSeg. Se puede observar como se produce un sobreajuste del modelo en la época 5. Se empleó una tasa de aprendizaje de 5×10^{-5}	52
4.4	<i>Bounding box</i> que enmarca las lesiones de una imagen.	53
4.5	Segmentación obtenida por SAM. No ha conseguido segmentar lesiones.	54
4.6	Segmentación obtenida por SAM. Ha segmentado el cerebro.	54
4.7	Segmentación obtenida por SAM. Ha segmentado una parte del cerebro.	54
4.8	Segmentación realizada con MedSAM. Ha segmentado el cerebro.	55
4.9	Segmentación realizada con MedSAM. Comienza a segmentar la lesión.	55
4.10	Entrenamiento de MedSAM.	56
4.11	<i>Fine-tuning</i> de MedSam. No ha segmentado del todo la lesión, pero muestra resultados prometedores.	57
4.12	Patrón perivascular segmentado con MedSAM preentrenada.	58
B.1	Entrenamiento secuencias T1 con relleno de 200x200 píxeles.	69
B.2	Entrenamiento secuencias T2 con relleno de 200x200 píxeles. Muestra un entrenamiento similar al de la secuencia T1.	69
B.3	Entrenamiento secuencias FLAIR con la aplicación de normalización gaussiana.	70
B.4	Entrenamiento con concatenación de las secuencias FLAIR, T1 y T2. La curva de pérdida del entrenamiento desciende de forma constante, mientras que la validación no.	70
B.5	Entrenamiento secuencias FLAIR con aumento de datos de 4000 imágenes.	70

ÍNDICE DE CUADROS

1.1	Cuadro resumen de Secuencias de Resonancia Magnética	5
2.1	Escáneres y Instituciones.	16
2.2	Cantidad de imágenes por lugar de origen y escáner.	17
2.3	Cantidad de imágenes entrenamiento y test.	18
2.4	Tamaño de las imágenes del MICCAI 2017 WMH Segmentation Challenge.	20
2.5	Tamaño de las imágenes del ICPR 2024 MSLesSeg.	20
2.6	Versión de las librerías empeladas.	22
2.7	Tabla de Confusión	24
3.1	Primera aproximación. DC es el coeficiente de DICE, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	29
3.2	Experimentos realizados sin el 20%.DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	30
3.3	Experimentos realizados con diferentes tamaños.DC es el coeficiente de DICE, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	32
3.4	Experimentos realizados con recorte/ <i>padding</i> . DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	34
3.5	Experimentos realizados con normalización gaussiana/ <i>padding</i> . DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	36
3.6	Experimentos realizados con normalización MinMax/ <i>padding</i> . DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	37
3.7	Experimentos realizados con la concatenación de secuencias. DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	38
3.8	Experimentos realizados con el incremento de datos.Caract. significa la cantidad de características iniciales, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	39
3.9	Experimentos realizados con tamaño de 200x200. pre. significa <i>precision</i> , rec. significa <i>recall</i> , DC significa coeficiente de DICE.	41
3.10	Experimentos realizados con normalización gaussiana de 200x200. pre. sig- nifica <i>precision</i> , rec. significa <i>recall</i>	42
3.11	Experimentos realizados con concatenación de 200x200. pre. significa <i>preci- sion</i> , rec. significa <i>recall</i>	42
3.12	Experimentos realizados con aumento de datos (generación de 4000 imáge- nes). pre. significa <i>precision</i> , rec. significa <i>recall</i>	43
3.13	Lesiones detectadas, no detectadas y su área.	44
3.14	Área media detectadas, no detectadas en píxeles.	44

3.15	Lesiones detectadas, no detectadas y su área.	47
3.16	Área media detectadas, no detectadas en píxeles.	47
A.1	Primera aproximación. DC es el coeficiente de DICE, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	65
A.2	Experimentos realizados sin el 20 % de las rebanadas. DC es el Dice coeffi- cient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	65
A.3	Experimentos realizados con diferentes tamaños de redimensionamien- to. DC es el coeficiente de DICE, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	66
A.4	Experimentos realizados con recorte/ <i>padding</i> . DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	66
A.5	Experimentos realizados con normalización gaussiana/ <i>padding</i> . DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	67
A.6	Experimentos realizados con normalización MinMax/ <i>padding</i> . DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	67
A.7	Experimentos realizados con la concatenación de secuencias. DC es el Dice coefficient, pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	67
A.8	Experimentos realizados con el incremento de datos. pre. significa <i>precision</i> , rec. significa <i>recall</i> y acc. <i>accuracy</i>	67

ACRÓNIMOS

CNN Convolutional Neural Network

IA Inteligencia Artificial

ICPR International Conference of Pattern Recognition

IAPR International Association of Pattern Recognition

IPHSB Imágenes Puntiformes Hipertensas en la Sustancia Blanca

FLAIR Fluid Attenuated Inversion Recovery

RM Resonancia magnética

SAM Segment Anything Model

SPM Statistical Parametric Mapping

TFG Trabajo Final de Grado

UMC University Medical Center

WMH White Matter Hiperintensities

RESUMEN

La detección de Imágenes Puntiformes Hipertensas en la Sustancia Blanca (IPHSB) es una tarea habitual y frecuente de los neuroradiólogos, ya que están asociadas con diversas patologías médicas. Presentan una gran variabilidad en forma, tamaño y ubicación, lo que complica su diagnóstico y clasificación. Existen 3 tipos de patrones: el patrón vascular (PV), el patrón perivascular (PpV), y el patrón inespecífico (PI).

En este TFG se realiza un estudio de aquellas técnicas de Inteligencia Artificial (IA) más adecuadas para segmentar IPHSB y se han creado modelos capaces de realizar la segmentación automática de estas. Se analiza en detalle el modelo de aprendizaje profundo U-NET para el desarrollo del segmentador para lesiones de origen vascular del concurso WMH Segmentation Challenge MICCAI 2017, y posteriormente, se aplican los conocimientos adquiridos para crear un segmentador de lesiones de patrón perivascular, para el concurso MSLesSeg ICPR 2024. Además, se realiza un análisis detallado de la cantidad y el área de las lesiones que detectan nuestros modelos.

Finalmente, se detallan diversas aproximaciones que existen para la creación de modelos para estas lesiones, aunque no se han implementado de forma exhaustiva, pero muestran perspectivas para trabajos futuros. Estos son los modelos 3D U-NET, SAM y MedSAM. Esta última muestra resultados prometedores tras realizar *fine-tuning* con nuestro conjunto de datos.

INTRODUCCIÓN

En el presente Trabajo Final de Grado (TFG) se mostrará el estudio realizado de las técnicas de Inteligencia Artificial (IA) más adecuadas para la segmentación de Imágenes Puntiformes Hipertensas en la Sustancia Blanca (IPHSB) (en inglés, *White Matter Hyperintensities (WMH)*) en imágenes de resonancia magnética, y la obtención de los modelos que permitan la segmentación automática de estas lesiones.

En este capítulo, se presentará un breve contexto del marco en el que se sitúa el TFG, una descripción del tipo de imágenes empleadas y la problemática que presentan. Además, se detallarán los objetivos que pretendo conseguir en este TFG y la estructura de la memoria.

1.1 Contexto

La detección de IPHSB en resonancias magnéticas es una tarea habitual y frecuente de los neurorradiólogos debido a la asociación de estas lesiones con diversas patologías médicas. A pesar de ser una tarea muy común, su diagnóstico y clasificación pueden ser complejos debidos a la gran variabilidad tanto en forma, tamaño y ubicación de estas lesiones.

Estas lesiones pueden presentar tres patrones: **el patrón vascular (PV)**, que está relacionado con lesiones y enfermedades microvasculares, es decir, lesiones producidas en pequeños vasos sanguíneos del cerebro; **el patrón perivascular (PpV)**, que se asocia a una inflamación de los vasos sanguíneos del cerebro, como en el caso de la esclerosis múltiple; y **el patrón inespecífico (PI)**, que no tiene una causa clara y se debe a problemas microvasculares. Por lo tanto, su correcta detección permitirá aportar un diagnóstico preciso y tratamiento efectivo para afecciones como cefaleas, vasculitis, enfermedades metabólicas y esclerosis múltiple atípica, entre otras [1]. En la Figura 1.1 podemos observar un cuadro resumen de cada tipo, sus características y las patologías que los producen, además de una muestra de cada uno de los patrones que pueden tener las lesiones.

Debido a la complejidad de esta tarea de detección, se entiende la necesidad de crear




Figura 1.1: Cuadro resumen de características y patologías producidas por las lesiones [1].

herramientas precisas que faciliten el trabajo de los neurorradiólogos. Por ello, se propone la creación de dos segmentadores automáticos: uno para la segmentación de lesiones de origen vascular y otro para segmentar lesiones de tipo perivascular.

Mediante la creación de estos segmentadores automáticos de IPHSB se espera contribuir a la detección temprana y a un diagnóstico preciso, además de permitir a los radiólogos aumentar la eficiencia y orientar a jóvenes profesionales.

1.1.1 Imágenes de Resonancia Magnética

La neuroimagen, o formación de imágenes cerebrales, consiste en el uso de diversas técnicas para obtener una imagen directa o indirecta de la estructura y/o funcionalidad del sistema nervioso. Es una disciplina relativamente nueva ¹ dentro de la medicina, la neurociencia y la psicología. Dentro de este campo podemos encontrar las imágenes de Resonancia magnética (RM) (en inglés, MRI), que son las que utilizaremos en este trabajo [10].

La RM se ha convertido en una herramienta muy útil en el campo médico, tanto para el diagnóstico como para la investigación, debido a su gran capacidad para pro-

¹ Desde su introducción en la práctica clínica en la década de 1970-80, el TAC y la RM han avanzado considerablemente, mejorando la atención al paciente [9].

porcionar una visualización y diferenciación de los tejidos blandos de diferentes partes del cuerpo [11].

Las imágenes de RM nos permiten observar imágenes detalladas del interior del cerebro, su estructura anatómica y detectar posibles irregularidades como tumores, malformaciones y, en el caso que se centra el TFG, diferentes tipos de lesiones [12].

Estas imágenes se obtienen a partir de señales emitidas por los protones en nuestro cuerpo. En nuestro organismo, el hidrógeno es el elemento más abundante. La RM se aprovecha de una característica presente en este elemento: como todos los elementos que presentan un número impar de protones, puede emitir señales detectables. El hidrógeno se encuentra principalmente en el agua (unido al oxígeno) y en la grasa (unido al carbono), y su protón puede realizar dos tipos de movimientos: **momento magnético o Spin**, donde el protón gira sobre su propio eje, y **momento de precesión**, donde el protón gira alrededor del eje del campo magnético externo. La precesión es específica para cada elemento y proporcional al campo magnético externo. Al ser expuestos al campo magnético, los protones se alinean en dos direcciones : **a favor del campo** (paralelo y baja energía) y **en contra de este** (antiparalelo y alta energía) [2].

Las resonancias se obtienen tras la aplicación de una onda electromagnética cuya frecuencia debe coincidir con la frecuencia de precesión del protón. Cuando se aplica una onda en la frecuencia correcta, los protones absorben energía, cambian su orientación y se sincronizan girando a la vez (o en fase). Es decir, antes de excitarse, los protones están alineados en paralelo en el eje z; al excitarse, se orientan hacia el eje xy, formando un ángulo de 90 grados. Tras la excitación de los protones, estos vuelven a su posición original y liberan la energía que habían absorbido en forma de ondas. Estas ondas tienen características variadas y proporcionan información sobre el tejido en el que se encuentran. Este proceso se conoce como relajación y existen de dos tipos: **relajación longitudinal o T1**, que tiene una duración mayor, depende de las interacciones de los protones con su entorno y se mide desde un estado de baja señal (negro) y aumenta de intensidad (blanco); y **relajación transversal o T2**, que es más breve, depende de las interacciones entre los propios protones y se mide desde un estado inicial con señal alta (blanca) y decrece (negro) [2].

En la Figura 1.2 podemos observar el proceso de relajación T1 y T2, junto con el eje en el que se sitúan los protones. Como se puede ver, la relajación T1 comienza con un estado de baja señal y va aumentando, mientras que en la relajación T2 ocurre lo contrario.

Existen varios tipos de secuencias de resonancia magnética que nos permiten identificar estas lesiones, pero cabe destacar las siguientes:

1. **Secuencias spin echo**: Se aplica un impulso de radiofrecuencia de 90 grados a los protones. Después de un tiempo, se aplica un segundo impulso de 180 grados que invierte la dirección de giro de los protones. Estas secuencias poseen dos tiempos: **el tiempo de eco**, que es el intervalo entre el primer impulso de 90 grados y el momento en que se mide la señal emitida por los protones, y **el tiempo de repetición**, que consiste en el tiempo entre dos impulsos de 90 grados consecutivos [2]. Según si estos tiempos son largos o cortos podemos encontrar las siguientes secuencias:
 - a) **Secuencia spin echo potenciada en T1**: Posee un tiempo de eco y repetición cortos. Este tipo de resonancia muestra la sustancia blanca del cerebro con




Figura 1.2: Relajación T1 y T2 [2].

mayor señal (hipertensa) debido a su alto contenido en grasa, que tiene una rápida relajación. La sustancia gris tiene una baja señal debido a su alto contenido en agua, y los líquidos se muestran con menor intensidad. Estas imágenes son muy útiles para mostrar los detalles anatómicos del cerebro, y las lesiones aparecerán en un tono más oscuro [11].

- b) **Secuencia *spin echo* potenciada en T2:** Posee tiempos de eco y repetición largos. En estas secuencias la grasa se muestra con una señal de baja intensidad, mientras que el líquido se muestra como una señal de alta intensidad. La sustancia blanca del cerebro se ve con menor intensidad en comparación con la sustancia gris [11]. Estas resonancias nos permiten detectar una gran variedad de problemas como sangrado, hinchazón, tumores o tejido muerto. Las lesiones se verán con menor intensidad respecto al resto del tejido [13].

2. **Secuencias Inversión-Recuperación:** Estas secuencias modifican el contraste entre tejidos al aplicar un primer impulso de 180 grados antes del impulso de 90 grados. Esto aumenta la duración de la secuencia pero también la potencia de la señal obtenida. Además, algunos tejidos son anulados, lo que incrementa el contraste. El tiempo de inversión es el intervalo entre el impulso de 180 grados y el primer impulso de 90 grados, y dependiendo de su duración, se determinará qué tejido se anula [2]. Cabe destacar la siguiente secuencia Inversión-Recuperación por su valor para el estudio de lesiones en sustancia blanca:

FLAIR (*Fluid Attenuated Inversion Recovery*): Tiene un tiempo de inversión largo. Esta secuencia es una secuencia potenciada en T2 en la que se anula la señal del líquido cefalorraquídeo. La eliminación de esta señal no afecta a la señal que proviene de las lesiones patológicas. Es decir, el líquido cefalorraquídeo aparecerá oscuro y no habrá mucho contraste entre la sustancia blanca y la sustancia gris, pero las lesiones hipertensas se observarán con mayor intensidad.

Esta secuencia proporciona información importante sobre los tejidos [11]. En estas imágenes, las lesiones aparecen de forma más clara y son distinguibles del resto del tejido.

Secuencia	Características	Aplicaciones Clínicas
Secuencia <i>spin echo</i> potenciada en T1	Tiempo eco y repetición cortos. Sustancia blanca brillante, sustancia gris oscura.	útiles para detalles anatómicos. Lesiones aparecen oscuras.
Secuencia <i>spin echo</i> potenciada en T2	Tiempo eco y repetición largos. Sustancia blanca oscura, sustancia gris brillante.	Detecta sangrado, hinchazón, tumores y tejido muerto.
Inversión recuperación FLAIR	Tiempo inversión largo. Anula la señal líquido cefalorraquídeo, lesiones brillantes.	Útiles estudio de lesiones en sustancia blanca.

Cuadro 1.1: Cuadro resumen de Secuencias de Resonancia Magnética

En el Cuadro 1.1 se muestra un resumen de las principales secuencias, características y sus aplicaciones clínicas.

1.1.2 Problemática

Como ya se ha mencionado, la principal característica de estas lesiones es la variabilidad que presentan. Por ello, es necesario contar con imágenes correctamente etiquetadas por profesionales médicos para garantizar la fiabilidad de los resultados obtenidos.

Sin embargo, la falta de bases de datos de imágenes de RM que presenten lesiones de IPHSB representa un desafío en este trabajo. Como respuesta a esta limitación, se ha decidido centrarse en el empleo de imágenes tipo **FLAIR**, **T1** y **T2**.

Las características de las secuencias **FLAIR** permiten una correcta visualización de las lesiones, debido al contraste entre el líquido cefalorraquídeo y las lesiones hipertenensas. Por otro lado, las secuencias **T1** no permiten destacar las lesiones de la misma forma. En la Figura 1.3, podemos observar una muestra de las secuencias, junto con la máscara.



Figura 1.3: Secuencia FLAIR, máscara y T1.

También se puede observar una muestra de una secuencia T2, en la que las lesiones aparecen en un tono grisáceo, mientras que el resto del tejido en un tono más oscuro. Como se puede ver en la Figura 1.4, las lesiones son difíciles de observar. Por lo tanto, las secuencias FLAIR son las mejores para observar este tipo de lesiones, pero también se deben tener en cuenta las secuencias T1 y T2, ya que detectan diversas características útiles para la segmentación.




Figura 1.4: Secuencia T2 y máscara.

En conclusión, el uso de este tipo de imágenes requerirá la aplicación de técnicas de preprocesamiento para mejorar su calidad y la claridad de las lesiones. Además, debido al limitado número de imágenes originales, se deberán crear nuevas imágenes sintéticas mediante técnicas de aumento de datos, que consisten en aplicar diversas transformaciones. Las imágenes generadas serán representaciones plausibles y no invalidarán ni sesgarán el estudio, cuyo propósito será aumentar la variedad del conjunto de datos. Las deformaciones aplicadas son mínimas y no alteran significativamente la forma geométrica de la imagen.

1.2 Objetivos

Los principales objetivos de este trabajo son los siguientes:

- **Segmentación automática de Imágenes Puntiformes Hipertensas en la Sustancia Blanca (IPHSB):**

El principal objetivo de este trabajo es desarrollar modelos automatizados capaces de segmentar lesiones con diversos patrones geométricos significativos de la patología sujeta a estudio. Este modelo implicará la detección y delimitación de las lesiones mostradas en las imágenes y se implementaría empleando técnicas de IA.

- **Estudiar y comparar el uso de diferentes técnicas y modelos de IA:**

Se pretende evaluar la eficiencia, precisión y robustez de diversos modelos profundos de IA en la tarea de segmentación de IPHSB e identificar cuál es el más adecuado para realizar una segmentación precisa y eficiente de las lesiones de cada tipo. Mediante la comparación de diversos modelos, se logrará una com-

prensión más profunda de las técnicas más adecuadas para la segmentación de imágenes médicas, en concreto de imágenes de resonancia magnética cerebrales.

- **Optimización y creación de un modelo eficiente:**

Otro objetivo es obtener modelos óptimos y precisos. A través de la selección de un modelo eficiente, se pretende modificar y optimizar un conjunto de hiperparámetros para maximizar la eficiencia manteniendo la precisión de la segmentación. Por ejemplo, se modificará el tamaño de los lotes, que es el número de muestras que se procesan antes de que se actualicen los parámetros del modelo, o el número de épocas, que son la cantidad de veces que una red procesará el conjunto de datos de entrenamiento.

- **Mejorar la detección temprana de lesiones cerebrales:**

Mediante la creación del modelo de segmentación automática, se mejorará la detección temprana de las lesiones en las resonancias magnéticas. Esta detección permitirá una clasificación temprana que orientará al radiólogo para un diagnóstico y tratamiento de posibles enfermedades producidas por las lesiones.

- **Contribución a la investigación científica:**

El trabajo realizado proporciona herramientas útiles basadas en algoritmos de aprendizaje profundo (en inglés, *deep learning*) dentro del campo de la neuroimagen médica, en particular la RM. Su uso para la detección de lesiones supondrá el primer paso de un proceso final de un posible diagnóstico de enfermedades producidas por estas lesiones. La obtención de modelos correctamente evaluados y validados puede proporcionar datos que ayuden a la comprensión de diversas enfermedades cerebrales.

1.3 Estructura de la memoria

En el siguiente capítulo 2 se explicarán los diferentes conceptos, teorías y modelos empleados en este trabajo. Además, se describirán las bases de datos de imágenes médicas RM empleadas, su origen, las características presentes en las imágenes y las tecnologías y entorno utilizado para realizar los experimentos, además de las métricas para evaluarlos. El capítulo 3 estará dedicado a una explicación detallada de cada uno de los experimentos realizados mediante el modelo de aprendizaje profundo U-NET, además de una discusión de los resultados obtenidos. En el capítulo 4 se describirán otras aproximaciones contempladas para la creación de los segmentadores automáticos. Por último, se presentarán las conclusiones del proyecto donde se evaluarán todos los objetivos cumplidos y se discutirán posibles proyectos futuros.

MATERIALES Y MÉTODOS

En el presente capítulo, se realizará una explicación y comprensión en detalle de los algoritmos, técnicas y modelos más recientes y que han sido empleados para la realización de este trabajo. Posteriormente, se abordarán las bases de datos empleadas para el desarrollo de nuestro modelo y, por último, todas aquellas tecnologías, librerías y entornos necesarios para poder implementar nuestros segmentadores.

2.1 Métodos

La IA es una rama de la informática que se centra en la creación de máquinas capaces de imitar la inteligencia humana y algunas funciones cognitivas como aprender o resolver problemas. El aprendizaje automático es un subconjunto de la IA que engloba aquellos algoritmos y técnicas que permiten a las máquinas realizar predicciones, aprender, identificar patrones o tomar decisiones basándose en un conjunto de datos [14]. El aprendizaje profundo es considerado un gran avance dentro del campo del aprendizaje automático y contiene una amplia gama de aplicaciones, desde procesamiento de texto hasta análisis de imágenes. En esta sección, detallaremos en qué consiste el aprendizaje profundo, algunas de sus aplicaciones y las técnicas y modelos del estado del arte.

Deep Learning o Aprendizaje Profundo

El *deep learning* o aprendizaje profundo consiste en una red neuronal con tres o más capas que puede aprender de grandes cantidades de datos, como texto e imágenes, mediante la automatización de la extracción de características, es decir, los algoritmos de aprendizaje profundo determinan qué características serán más importantes para la tarea que deben realizar. Los modelos de *deep learning* consisten en varias capas interconectadas, donde la primera (la entrada, que recibe los datos a procesar) y la última capa (la salida, realiza la predicción o clasificación de los datos de entrada) son las capas visibles. Mientras, las capas interiores, llamadas invisibles, realizan una progresión de cálculos que propagan a las capas siguientes llamada propagación hacia

adelante. Otro proceso conocido como propagación inversa o *backpropagation* calcula los errores utilizando algoritmos (como descenso de gradiente) y ajusta los pesos y sesgos de la función desplazándose hacia atrás a través de las capas durante el entrenamiento. De esta forma, se permite al modelo aumentar su capacidad para resolver el problema [15].

Cabe destacar un modelo de aprendizaje profundo llamado *Convolutional Neural Network (CNN)*. Este modelo se emplea principalmente en tareas de visión por computador como clasificación de imágenes, detección de objetos y segmentación de imágenes. Este realiza un proceso llamado convolución, que se realiza desplazando un filtro o *kernel* (básicamente es un detector de características). El filtro es una matriz que puede tener cualquier tamaño y que calcula el producto escalar entre una región de la imagen y el filtro, los resultados se introducen en una matriz de salida. Este proceso continua hasta que se ha recorrido toda la imagen, obteniendo como resultado una matriz llamada mapa de características [16]. El desplazamiento del filtro se establece en el *stride*. Podemos observar en la Figura 2.1, como se realiza este movimiento y los resultados se almacenan en una matriz resultante. En la imagen, se introduce el concepto de *padding*, que es un proceso que consiste en añadir un relleno de píxeles negros a los bordes de las imagen y así controlar el tamaño del mapa de características resultantes.




Figura 2.1: Multiplicación matricial del filtro y la imagen [3].

Cabe destacar que las primeras CNNs se han convertido en la base para la creación de otros modelos de deep learning como AlexNet [17], Mask R-CNN [18], Fast R-CNN [19], U-NET [4], SAM [6] y muchos más.

Detección de objetos y segmentación de imágenes

Existen múltiples aplicaciones dentro del aprendizaje profundo, de las cuales cabe destacar la detección de objetos y la segmentación de imágenes.

La detección de objetos es un término empleado en el campo de la visión por computador y es una tarea que nos permite identificar objetos en imágenes. Esta tarea consiste en la localización de uno o más objetos en una imagen y la realización de una predicción de la clase a la que pertenecen. Algunos modelos dedicados a la detección de objetos son MASK R-CNN, YOLO [20], Fast R-CNN.

Por otro lado, la segmentación de imágenes es una tarea del campo de la visión por computador que consiste en la clasificación de cada píxel de una imagen dada en una o más clases. Existen dos tipos de segmentaciones: la segmentación semántica, donde todos los píxeles de una misma clase se les asigna el mismo valor de píxel y la segmentación por instancia, donde se asigna una etiqueta única a cada píxel de una imagen, y todos los píxeles de un mismo objeto de la misma clase se les asigna valores únicos de píxel. Cada objeto de la imagen se representa por separado y con una identificación única para poder distinguirlo de los objetos de la misma clase.

En este TFG nos centraremos principalmente en la tarea de segmentación semántica para las lesiones cerebrales. Algunos modelos útiles para esta tarea son U-Net, 3D U-NET [5] y SAM (Segment Anything Model).

U-NET

U-Net es una red neuronal diseñada para la segmentación de imágenes médicas. Se encuentra estructurada en dos partes. La primera parte es conocida como codificador o *encoder* y consiste en la repetición de dos convoluciones de tamaño 3x3 sin *padding*. Cada una de ellas se encuentra seguida de una capa de activación ReLU (Rectified Linear Unit) seguida de una capa de *maxpooling* 2x2 con *stride* 2. Una capa de activación ReLU realiza la Fórmula 2.1:

$$ReLU(x) = \max(0, x), \quad (2.1)$$

es decir la salida será el valor de x si este es positivo, y 0 en caso contrario. Mientras una capa de *maxpooling* tiene la función de reducir la dimensión de la entrada manteniendo las características más importantes; al tener un tamaño de 2x2 las dimensiones se reducen a la mitad.

La segunda parte de la red, conocida como decodificador o *decoder*, consiste en una serie de capas de *upsampling* seguida de una convolución 2x2 que divide a la mitad el número de características, además de una concatenación con el correspondiente mapa de características del codificador y dos convoluciones 3x3, cada una de estas seguida de una función de activación ReLU. Una capa de *upsampling* tiene la función de incrementar el tamaño del mapa de características, interpolando los valores existentes para crear uno mayor. Finalmente, la última capa es una convolución 1x1 que reduce la profundidad del mapa de características a la profundidad que se desea para la segmentación final, es decir, el número de clases que se quieren segmentar. En total este modelo posee 23 capas convolucionales.

Una característica principal de este modelo son las *skip connections* o conexiones de salto. Se tratan de conexiones de salto entre el codificador y el decodificador que permiten la transferencia de información, las características de las capas correspondientes del *encoder* se concatenan con las del *decoder* permitiendo una segmentación más precisa. En la Figura 2.2 se puede observar la arquitectura de esta red.

3D U-NET

Otra red empleada y similar a U-Net es el modelo 3D U-Net. Se trata de una red neuronal especializada en la segmentación de volúmenes. Por lo tanto, esta red nos puede ser útil ya que los datos que tenemos son en 3D. Al igual que U-Net posee dos partes,

2. MATERIALES Y MÉTODOS




Figura 2.2: Arquitectura de U-NET [4].

el codificador y el decodificador. Cada capa del codificador realiza 2 convoluciones de tamaño 3x3x3, seguidas de una ReLU, y una capa de *maxpooling* de tamaño 2x2x2 con *stride* 2. Para cada capa del decodificador, hay una capa de upsampling de tamaño 2x2x2, seguido de dos convoluciones de 3x3x3, cada una seguida de una ReLU. Al igual que U-NET, también hay *skip-connections* entre el codificador y el decodificador. Introducen *batch normalization* antes de cada ReLU, que es un proceso que consiste en normalizar durante el entrenamiento de la red cada conjunto de imágenes que es enviado a la red o *batch* con su media y desviación típica [5]. En la Figura 2.3 podemos observar la arquitectura de este modelo.




Figura 2.3: Arquitectura de la 3D U-NET [5].

Segment Anything Model (SAM)

Un modelo que se destaca por su gran capacidad de segmentación de cualquier objeto en una imagen es Segment Anything Model (SAM) [6]. SAM es un proyecto de META y se inspira en los modelos de inteligencia artificial del lenguaje natural (NLP). Su tarea principal es traducir los *prompts* de NLP que el usuario realiza a segmentación. Un *prompt* es una entrada o indicación que se le proporciona al modelo para guiar el proceso de segmentación y consiste en una serie de puntos, una *bounding box*, se trata de un recuadro que se establece alrededor del objeto que se quiere segmentar; o una máscara, que consiste en una representación binaria que cubre un área de la imagen y proporciona información específica sobre qué partes de la imagen deben ser segmentadas. Como resultado, se devuelven 3 segmentaciones válidas al *prompt*.

El modelo SAM tiene los siguientes componentes [6]:

- **Image Encoder:** se trata de un Vision Transformer (ViT) que está adaptado para procesar imágenes de alta resolución. Está basado en la idea de una MAE (Masked Autoencoder) [21], que reconstruye la imagen original después de haberla procesado a través de la aplicación de transformaciones. Se ejecuta una vez por imagen y captura las características importantes de la imagen. Por lo tanto, el codificador tiene la función de devolver los vectores numéricos que representan las características visuales de la imagen, también llamados *embeddings*.
- **Prompt encoder:** Se consideran dos tipos de *prompts*:
 - **Puntos, *bounding boxes* y texto;** este tipo se llaman *sparse*. Los puntos y las *bounding boxes* se emplean para indicar la ubicación o región de interés dentro de una imagen. Para representar estos datos se emplean codificadores posicionales que ayudan al modelo a entender la posición de los puntos o *bounding boxes*. Además, el modelo realiza un aprendizaje específico a cada tipo de *prompt*, es decir, el modelo puede aprender las características y patrones asociados a cada tipo de *prompt* adaptándose a las diferentes tipos de entrada. Para procesar texto de forma libre se emplea un codificador de texto llamado CLIP, puede analizar y entender descripciones o instrucciones en lenguaje natural sin restricciones de formato o estructura [22].
 - **Máscaras.** Se llaman *dense*. Se incorporan empleando convoluciones y se concatenan con la codificación obtenida en el image encoder.
- **Mask decoder:** se trata de un decodificador que recibe como entrada los *embeddings* de una imagen y un *prompt*. Genera 3 máscaras.

En la Figura 2.4 podemos ver la estructura de SAM y cómo los componentes se conectan entre sí. Además posee las siguientes características [6]:

- **Resuelve la ambigüedad:** Con una sola salida, el modelo hace un promedio de diversas máscaras si se ha dado un *prompt* ambigüo.
- **Eficiencia:** El diseño del modelo se centra en la eficiencia. Si se emplean *embeddings* de imágenes precalculadas, el codificador y el *mask decoder* funcionan




Figura 2.4: Estructura de SAM [6].

rápidamente en un navegador web, en CPU, en 50 ms. Pudiendo operar el modelo sin problemas, rápidamente y en tiempo real.

- **Pérdidas y entrenamiento:** La predicción de máscaras utiliza una combinación de dos funciones de pérdida: la pérdida focal y la pérdida de DICE. La pérdida focal se diseñó para abordar el problema de desbalance de clases, donde ciertas clases pueden estar subrepresentadas en comparación con otras. Por ejemplo, el caso en que hay más instancias de fondo que objetos, lo que lleva a un entrenamiento sesgado, ya que el modelo se centra en las clases más abundantes. La Fórmula 2.2 define la pérdida focal:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t), \quad (2.2)$$

donde p_t es la probabilidad predicha del modelo de ser de la clase verdadera, α_t es un factor de ponderación que ajusta la pérdida para cada clase, dando importancia a clases menos frecuentes o difíciles de clasificar, y γ es un parámetro que reduce la pérdida en los casos bien clasificados (p_t alto) y aumenta la pérdida en los mal clasificados (p_t bajo). La función de pérdida focal penaliza más fuerte los errores en datos difíciles, donde p_t es bajo y la clase verdadera. De esta forma se ayuda al modelo a que se enfoque en clasificar correctamente los ejemplos más difíciles [23].

La pérdida de DICE es una métrica de similitud que mide la superposición entre dos imágenes. La Fórmula 2.3 indica como se calcula la pérdida:

$$DL = 1 - \frac{\sum_{n=1}^N (p_n + r_n) + \epsilon}{\sum_{n=1}^N (p_n r_n) + \epsilon} - \frac{\sum_{n=1}^N (2 - p_n - r_n) + \epsilon}{\sum_{n=1}^N (1 - p_n)(1 - r_n) + \epsilon}, \quad (2.3)$$

donde p_n es la predicción del modelo en el píxel n , r_n es el valor real para el píxel n , N el número total de píxeles y ϵ se emplea para que la función no divida entre cero en el caso de que no haya superposición entre las dos imágenes [24].

Mediante la combinación de estas dos pérdidas, se crea un método interactivo que se repite en 11 rondas, donde el modelo recibe de forma aleatoria diferentes *prompts* que ayudan a ajustar y mejorar las máscaras predichas.

Tras el éxito de SAM, la comunidad científica trabajó en la adaptación de este modelo a dominios nuevos más específicos. Con lo que se crearon múltiples variantes de este, de los cuales cabe destacar MedSAM [25]. Este tiene como objetivo ser un

modelo para la segmentación de imágenes médicas basándose en SAM. Se entrenó con más de un millón de imágenes médicas que abarcan una gran variedad de patologías, cánceres y condiciones médicas. Además, se emplearon diferentes modalidades de imágenes para entrenarla como Tomografías Computarizadas(CT), endoscopias y RM (la modalidad de nuestros conjuntos de datos).

En los próximos capítulos, se detallarán los experimentos realizados con estos modelos y se compararán. Además, se comprobará la eficiencia de cada uno de estos en la tarea de segmentación. En la siguiente sección se definen las bases de datos utilizadas para la creación de los modelos segmentadores de lesiones, las imágenes obtenidas y las características que poseen.

2.2 Bases de Datos

Uno de los principales desafíos de este trabajo era la obtención de un conjunto de imágenes de resonancia magnéticas cerebrales que presentaran lesiones de materia blanca. Nos hemos enfrentado a dos principales problemas en la búsqueda de imágenes:

- **Calidad de imágenes:** Debíamos encontrar imágenes de resonancia magnética cuya calidad nos permitiera identificar o distinguir las lesiones de materia blanca. La búsqueda de imágenes de calidad para no dificultar el entrenamiento de nuestros modelos era un aspecto importante del TFG.
- **Disponibilidad de datos anotados:** Además de la calidad de las imágenes, debíamos encontrar un conjunto de datos que estuviera correctamente anotado, es decir, las imágenes debían incluir las máscaras de las lesiones de materia blanca anotadas de forma precisa y correcta. Esta anotación debía de estar realizada por profesionales médicos para asegurarse que estaban debidamente anotadas.

Finalmente, tras una búsqueda exhaustiva se encontraron dos bases de datos que encajaban con el problema planteado en el TFG y que cumplían con los requisitos de una calidad óptima de imagen y una correcta anotación de los datos.

2.2.1 Origen de los datos

El primer conjunto de datos empleado proviene del concurso **White Matter Hyperintensity (WMH) Segmentation Challenge** que estuvo activo desde 2017 hasta 2022. El propósito del concurso era la comparación de diferentes métodos para crear un segmentador automático que permitiera la segmentación de WMH de origen vascular [26].

El concurso fue organizado por la *University Medical Center (UMC)* de Utrecht en asociación con la MICCAI 2017. La *MICCAI* (cuyas siglas en inglés significan *Medical Image Computing and Computer Assisted Intervention*) es una sociedad sin ánimo de lucro que se encarga de difundir, promocionar y al avance de la investigación en la informática médica. Se fundó en 2004 y cada año organiza una conferencia que reúne a médicos, ingenieros y investigadores de todo el mundo [27]. En la conferencia del 2017, organizada en Quebec (Canadá), fue presentado este concurso, sus datos se han usado para la creación del segmentador automático de lesiones de origen vascular.

2. MATERIALES Y MÉTODOS

Los datos fueron obtenidos de diversos escáneres de diferentes hospitales de Singapur y Países Bajos (en concreto, de Utrecht y Amsterdam). En el Cuadro 2.1, se muestran los escáneres y la instituciones que las han proporcionado además de la región de la que proceden.

Cuadro 2.1: Escáneres y Instituciones.

Escáner	Institución	Origen
3T Philips Achieva	University Medical Center(UMC)	Utrecht
3T Siemens TrioTim	National University Health System(NUHS)	Singapur
3T GE Signa HDxt	Vrije Universiteit(VU)	Amsterdam
3T Philips Ingenuity	Vrije Universiteit(VU)	Amsterdam
1.5T GE Signa HDxt	Vrije Universiteit(VU)	Amsterdam

Por otro lado, el segundo conjunto de datos fue obtenido a través del concurso **ICPR 2024 Competition on Multiple Sclerosis Lesion Segmentation (MSLesSeg)**, como su nombre indica se realiza en conjunto con el 2024 International Conference of Pattern Recognition (ICPR) y los principales organizadores del concurso provienen de la Universidad de Catania (Italia) y la unidad de radiología del hospital público Azienda Ospedaliera Garibaldi, también situado en Catania.

El ICPR es una conferencia internacional organizada cada año por la International Association of Pattern Recognition (IAPR), que es una asociación sin ánimo de lucro de científicos y otros profesionales interesados en el reconocimiento de patrones, visión por computador y procesamiento de imágenes [28].

Los datos fueron recogidos de diversos centros hospitalarios y fueron obtenidos por diferentes escáneres 1.5 Tesla.

En conclusión, los conjuntos de datos no solo difieren en los escáneres empleados para la obtención de las RM, sino que dentro de cada uno de los conjuntos de datos se emplearon diversos escáneres. Este hecho puede afectar a la calidad y la homogeneidad de los mismos. Cada uno de los escáneres poseen sus propias características técnicas y configuración del color, haciendo que produzcan imágenes con distintas resoluciones o que introduzcan más ruido en ellas, afectando a la claridad y la precisión de los detalles.

2.2.2 Las imágenes

En el siguiente apartado se explicará la estructura de los conjuntos de datos obtenidos y las imágenes que incluyen. En el primer conjunto de datos, del MICCAI 2017 WMH Segmentation Challenge, contiene lesiones de origen vascular y se proporcionan tres directorios principales:

- **Training:** Contiene el conjunto de imágenes que se emplearán para entrenar el modelo. Esta carpeta a su vez divide los datos en tres carpetas según su origen: Utrecht, Singapur y Amsterdam. Cabe destacar que en la carpeta de Amsterdam solo hay imágenes del escáner 3T GE Signa HDxt.
- **Test:** Contiene el conjunto de datos con el que será evaluado el modelo. Sigue la misma estructura que la carpeta anterior dividiendo los datos según el origen. Cabe destacar que el directorio de test de Amsterdam también separa los datos en tres carpetas diferentes según el escáner con el cual fueron realizados.

- **Additional Annotations:** Contiene anotaciones manuales de los datos. Este directorio no será utilizado, ya que se proporcionan las máscaras manualmente segmentadas para cada imagen del conjunto de datos.

Para cada dato, se proporcionan 3 tipos de resonancias magnéticas: FLAIR, secuencias *spin echo* potenciadas en T1 y 3D T1. Está última no será empleada ya que no va alineada con la máscara proporcionada para las secuencias FLAIR y T1. Para el conjunto de entrenamiento, el concurso proporcionó los datos de 60 pacientes mientras que para el conjunto de test proporcionó 110. Cabe destacar que en el conjunto de entrenamiento no hay datos de dos escáneres de Amsterdam. Por lo tanto, el modelo será evaluado con datos nunca vistos durante el entrenamiento. En el Cuadro 2.2 podemos ver la distribución de datos según el origen y escáner.

Cuadro 2.2: Cantidad de imágenes por lugar de origen y escáner.

Origen	Escáner	Cantidad Entrenamiento	Cantidad Test
Utrecht	3T Philips Achieva	20	30
Singapur	3T Siemens TrioTim	20	30
Amsterdam	3T GE Signa HDxt	20	30
Amsterdam	3T Philips Ingenuity	-	10
Amsterdam	1.5T GE Signa HDxt	-	10

Podemos observar que hay un desbalance de datos entre el conjunto de entrenamiento y test, donde este último contiene casi el doble de datos, lo que puede provocar algunos problemas como falta de datos en el entrenamiento y la obtención de modelos con una generalización escasa. Estos problemas no nos permitirán obtener un modelo robusto y que sea capaz de capturar la complejidad de las imágenes de forma correcta, lo que conlleva a un rendimiento no eficiente y que no generaliza ante datos nunca vistos.

Para poder solucionar este desbalance de datos se aplicarán técnicas de aumento de datos. Se aplicarán algunas transformaciones como rotaciones, cambios de escala o la aplicación de una pequeña distorsión sobre un alguno de los ejes de la imagen. Estas transformaciones generarán imágenes que serán plausibles y que puedan encontrarse en el mundo real.

Para el segundo conjunto de datos, proveniente del concurso MSLesSeg ICPR 2024 y que muestra las lesiones de patrón perivascular, se proporcionan datos de 115 pacientes, los cuales se realizaron diferentes RM y en total puede haber entre 1 a 5 RM para cada uno de ellos. La estructura del conjunto de datos es la siguiente:

- **Training:** Al igual que el primero, son las imágenes para entrenar el modelo. Esta carpeta divide los datos en carpetas individuales para cada paciente. En su interior se encontrarán diferentes subcarpetas que son diferentes momentos en los que se realizaron RM. En cada subcarpeta están las correspondiente RM.
- **Test:** Al igual que el primero, son las imágenes con el que será evaluado el modelo. Se diferencia del conjunto de entrenamiento en que simplemente encontramos carpetas individuales para cada paciente y en su interior las radiografías. Al ser un concurso en activo, las máscaras anotadas no se han proporcionado, lo que

2. MATERIALES Y MÉTODOS

nos impedirá la evaluación mediante las métricas seleccionadas del segmentador final.

Para cada dato del conjunto de datos se proporcionan tres tipos de radiografías: FLAIR, secuencias *spin echo* potenciada en T1 y T2. Para el conjunto de entrenamiento, el concurso proporcionó los datos de 93 pacientes mientras que para el conjunto de test proporcionaron datos de 22 pacientes. Como hemos mencionado anteriormente, por cada paciente se ofrecen varias RM. En el Cuadro 2.3 podemos observar las cantidades correspondientes al entrenamiento y al test:

Cuadro 2.3: Cantidad de imágenes entrenamiento y test.

Cantidad Entrenamiento	Cantidad Test
93	22

2.2.3 Características de los datos

Para cada observación del primer conjunto de datos (MICCAI 2017 WMH Segmentation Challenge), se proporciona un directorio con las imágenes originales y otro con las imágenes preprocesadas empleando el programa SPM12 r6685. Statistical Parametric Mapping (SPM) es un programa diseñado para el análisis de neuroimágenes, en concreto el análisis de imágenes de resonancia magnética. Este software permite la realización de análisis estadísticos y el preprocesamiento de imágenes [29]. Para nuestro modelo emplearemos las imágenes preprocesadas porque el software habrá permitido corregir algunas distorsiones y la normalización de las imágenes.

En la Figura 2.5 podemos observar una serie de secuencias FLAIR, T1 y 3DT1. Estas secuencias son una porción transversal en 2D de las imágenes 3D proporcionadas en el conjunto de datos. También podemos observar significativamente el efecto del preprocesamiento con este software en la imagen T1. Si observamos la imagen original tiene un contraste muy elevado que tras el preprocesamiento disminuye. Por otro lado, el efecto del preprocesamiento sobre las secuencias FLAIR es apenas perceptible.

El segundo conjunto de datos aplicó un procesamiento a las imágenes de RM. En primer lugar, se registraron las imágenes en la plantilla estándar MNI-152. Esta plantilla es un cerebro humano promedio generado a partir de las imágenes de RM de 152 individuos sanos. Se emplea como una referencia estándar en neuroimagen para comparar y analizar los datos de diferentes sujetos de forma uniforme [30]. En la Figura 2.6 se muestra un ejemplo del proceso de normalización mediante la plantilla MNI-152. En la primera fila se pueden observar una serie de vistas del cerebro, mientras que en la segunda fila se muestran las mismas vistas tras haber sido transformados al espacio MNI. Finalmente, la tercera fila muestra mediante líneas amarillas la plantilla MNI sobre el cerebro [7]. En segundo lugar, se realizó una extracción del cráneo (llamada *skull-stripping en inglés*), de forma que las imágenes solo contuvieran tejido del cerebro. En la Figura 3.11 podemos observar una muestra transversal en la que solo aparece el tejido cerebral.

Una de las principales características a tener en cuenta es la forma de las imágenes, ya que dependiendo de su formato se deberán aplicar transformaciones de redimensionamiento o recorte.




Figura 2.5: Secuencias originales y preprocesadas con SPM12 r6685.




Figura 2.6: Ejemplo de normalización con MNI-152 [7].

2. MATERIALES Y MÉTODOS




Figura 2.7: Secuencias registradas con MNI-152 y skull-stripping.

En el Cuadro 2.4 podemos encontrar las dimensiones de las imágenes según el escáner y su origen del MICCAI 2017 WMH Segmentation Challenge. Las dos primeras dimensiones indican el tamaño de la imagen, mientras que la tercera dimensión indica la profundidad. En el contexto de las imágenes médicas, esta profundidad se refiere a la cantidad de rebanadas que componen la imagen. Como podemos observar tenemos

Cuadro 2.4: Tamaño de las imágenes del MICCAI 2017 WMH Segmentation Challenge.

Origen	Escáner	Dimensión
Utrecht	3T Philips Achieva	240 x 240 x 48
Singapur	3T Siemens TrioTim	256 x 232 x 48
Amsterdam	3T GE Signa HDxt	132 x 256 x 83
Amsterdam	3T Philips Ingenuity	321 x 240 x 83
Amsterdam	1.5T GE Signa HDxt	128 x 256 x 103

tamaños muy dispares entre ellas. Por lo tanto, se deberá determinar un tamaño estándar para todas las imágenes del conjunto. En el siguiente capítulo, se mostrará como se ha resuelto este problema.

En el Cuadro 2.5 podemos observar el tamaño de las imágenes del conjunto de datos procedente de la competición del ICPR 2024 MSLesSeg. Todas las imágenes tienen la misma dimensión, así que no supone un problema.

Cuadro 2.5: Tamaño de las imágenes del ICPR 2024 MSLesSeg.

Conjunto	Dimensión
Entrenamiento	182 x 218 x 182
Test	182 x 218 x 182

Finalmente, para cada observación se proporciona una máscara con la segmentación realizada manualmente por profesionales neurólogos y radiólogos. Esta máscara tiene el mismo tamaño que la correspondiente resonancia que segmenta. Las máscaras del primer conjunto de datos contienen 3 etiquetas: 0, que es el fondo; 1, las lesiones y 2, otras patologías. Para el entrenamiento, las etiquetas 0 y 2 se fusionarán, ya que solo es necesario el entrenamiento para la segmentación de las IPHSB. Las máscaras del segundo conjunto de datos, solo tienen las dos etiquetas: 0: fondo y 1: lesiones.

2.3 Tecnologías

En esta sección se explicará el lenguaje de programación empleado para realizar el desarrollo de los modelos, además del conjunto de las librerías más empleadas y el entorno utilizado para el entrenamiento y la validación de los modelos.

2.3.1 Lenguaje de programación

La selección del lenguaje de programación con el que se desarrollará el proyecto es importante porque nos permite proporcionar las herramientas y infraestructuras necesarias para implementar algoritmos de segmentación automáticos, manejar los datos y evaluar el rendimiento de los correspondientes modelos creados.

Para este proyecto se ha seleccionado el lenguaje de programación Python. A pesar de que no es uno de los lenguajes más eficientes, se ha seleccionado este lenguaje debido a la gran facilidad de uso que posee, ya que nos permitirá implementar los modelos empleando poco código y utilizando una sintaxis simple. Además, Python posee una gran variedad de bibliotecas especializadas en el procesamiento de datos y el aprendizaje automático que nos facilitarán el desarrollo del proyecto.

2.3.2 Librerías

El uso de bibliotecas es importante para el desarrollo del proyecto, ya que proporcionan funciones y herramientas predefinidas que nos permiten poder implementar funcionalidades más complejas sin emplear mucho código y esfuerzo. A continuación, se explican brevemente algunas de las librerías empleadas para el desarrollo del proyecto:

OpenCV

OpenCV(Open Source Computer Vision Library) es una biblioteca de código abierto utilizada en el área de la visión por computador y el procesamiento de imágenes. Está compuesta por una gran variedad de funciones y cuenta con más de 2500 algoritmos, además de ser eficiente y fácil de usar [31]. La emplearemos en nuestro proyecto para añadir procesamientos a las imágenes o la extracción de características.

Nibabel

Nibabel es una librería diseñada exclusivamente para el manejo de datos de imágenes biomédicas. Posee un conjunto de herramientas para leer imágenes en formato NIfTI(el formato que poseen las imágenes de nuestros conjuntos de datos), entre otros formatos [32]. Además, de tener otras funciones para poder manipular y escribir datos, lo que hace que sea una librería muy útil a la hora de manejar datos de resonancias magnéticas y nos permitirá manejar los datos en nuestro proyecto.

Scikit-Image

Scikit-image es una colección de algoritmos dedicados al procesamiento de imágenes. Algunos de estos algoritmos sirven para realizar transformaciones geométricas y análisis de características [33]. La emplearemos para obtener el "threshold_otsu" de

2. MATERIALES Y MÉTODOS

las imágenes, es decir, calcular el umbral óptimo para binarizar las imágenes. De esta forma, los píxeles que estén por encima serán 1 y los que estén por debajo, 0. Esta binarización separará el cerebro del fondo para poder aplicar diferentes procesamiento únicamente a esa parte de la imagen.

PyTorch

Pytorch es un *framework* de código abierto de aprendizaje profundo que nos permitirá crear las redes neuronales. Se encuentra combinada con la biblioteca Torch , que es una biblioteca de aprendizaje automática y una API basada en Python. Es muy flexible, sencilla de utilizar y los cálculos se realizan a través de tensores. Un tensor es una matriz multidimensional, similar a los *ndarrays* de Numpy y que permite cálculos sobre GPU [34].

Numpy

Numpy es una librería de código abierto que ofrece una variedad de funciones matemáticas con Python [35]. Nos permitirá hacer cálculos con matrices que facilitarán la aplicación de transformaciones a las imágenes.

Matplotlib

Matplotlib es una biblioteca para la creación de gráficos 2D [36]. Nos servirá para visualizar los resultados de los entrenamientos de los modelos y la segmentaciones realizadas.

En el Cuadro 2.6 se indican para cada una de las librerías, la versión utilizada.

Cuadro 2.6: Versión de las librerías empeladas.

Librería	Versión
OpenCV	4.9.0.80
Nibabel	5.2.0
Scikit-Image	0.24.0
PyTorch	2.2.2+cu118
Numpy	1.26.4
Matplotlib	3.9.0

2.3.3 Entorno

Todas las operaciones se han realizado en GPU porque los entrenamientos y cálculos tenían una alta demanda computacional. Las GPUs son muy eficientes en las tareas de procesamiento paralelo, por lo que son ideales para entrenar modelos que requieren del procesamiento de grandes cantidades de datos en cada iteración. Se empleó un ordenador que tenía una gráfica NVIDIA GeForce RTX 3060, además de tener una CPU Intel I5.

2.4 Métricas

Para poder evaluar cada uno de los modelos hemos empleado una serie de métricas que se describen en esta sección.

Coeficiente de DICE

El coeficiente de DICE se define de la siguiente forma:

$$DSC = \frac{2|A \cap B|}{|A| + |B|} \quad (2.4)$$

A y B representan la máscara y la salida generada por el modelo de segmentación, respectivamente. Las dos imágenes deben ser binarias con valores de 0 a 1. En la Figura 2.8 podemos ver una representación gráfica del cálculo de esta medida. Esta métrica se emplea para

$$\text{Dice} = \frac{2 \times \text{Area of overlap}}{\text{Total area}} = \frac{2 \times \text{Prediction} \cap \text{Ground truth}}{\text{Prediction} \cup \text{Ground truth}}$$

Figura 2.8: Representación gráfica del cálculo de DICE [8].

determinar la similitud entre los dos conjuntos de imágenes [37]. Cuánto más grande sea este coeficiente, mejor será el modelo.

IOU (Intersection Over Union)

Esta métrica nos permite cuantificar el ratio de superposición entre dos imágenes, es decir evalúa la superposición entre la máscara y la salida predicha por el modelo [38]. Se define de la siguiente forma:

$$IoU = \frac{|A \cap B|}{|A \cup B|} \quad (2.5)$$

En la Figura 2.9, podemos observar una representación gráfica del cálculo de esta métrica.

Precision, Accuracy y Recall

Para poder explicar las siguientes métricas debemos prestar atención a la matriz de confusión. La matriz de confusión es una matriz cuadrada, que tiene tantas filas y columnas como hay en el problema. En nuestro caso, al ser un problema binario, solo habrá dos clases, lesión o no [8]. En el Cuadro 2.7, se puede observar un ejemplo. Los términos de la matriz significan:

- TP, *True positive* o verdadero positivo: aparecerán el número de instancias del conjunto de datos que han sido predichos como lesión.


$$IoU = \frac{\text{Area of overlap}}{\text{Area of union}} =$$


Figura 2.9: Representación gráfica de IOU [8].

Cuadro 2.7: Tabla de Confusión

Real	Predicción	
	Positivo	Negativo
Positivo	TP (Verdadero Positivo)	FN (Falso Negativo)
Negativo	FP (Falso Positivo)	TN (Verdadero Negativo)

- TN, *True negative* o verdadero negativo: aparecerán el número de instancias que han sido predichos como NO lesión.
- FP, *False positive* o falsos positivos, cantidad de instancias predichas como lesión pero que no lo son.
- FN, *False negative* o falsos negativos, cantidad de instancias predichas como no lesión pero que si lo eran.

A partir de estas métricas de primer orden se pueden calcular otras métricas de segundo orden que nos permiten resumir más información en un solo dato:

- *Precision*. Indica la proporción de verdaderos positivos sobre todos las instancias de la clase lesiones [8].

$$Precision = \frac{TP}{TP + FP} \quad (2.6)$$

- *Accuracy*. Indica la proporción de predicciones correctas (tanto TP como TN) sobre todas las predicciones[8] .

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.7)$$

- Recall. Indica la proporción de verdaderos positivos sobre el total de instancias de lesiones [8].

$$Recall = \frac{TP}{TP + FN} \quad (2.8)$$

2.5 Conclusión

En el presente capítulo se ha realizado un análisis del estado del arte, lo que nos ha permitido la comprensión de los algoritmos y modelos más recientes. Además, se ha

explicado la base de datos que se utilizará para el desarrollo de nuestro segmentador, destacando su origen y principales características de las imágenes. Por último, se han establecido las tecnologías, librerías y entornos necesarios para la implementación del modelo, así como las métricas para evaluarlo.

Una vez establecida la base teórica y práctica para el desarrollo del proyecto, podremos explicar en el siguiente capítulo los experimentos y conjuntos de pruebas realizados para la implementación de un segmentador automático de las lesiones. Para cada uno de estos experimentos se establecerá el modelo, los datos utilizados y procesamientos aplicados, además de los parámetros configurados.

EXPERIMENTACIÓN CON U-NET

En el presente capítulo, se llevará a cabo un análisis detallado del comportamiento del modelo de aprendizaje profundo U-Net con el objetivo principal de desarrollar el segmentador de lesiones de origen vascular del concurso WMH Segmentation Challenge del MICCAI 2017. Por lo tanto, se realizarán una serie de experimentos de los cuales se variarán diversos parámetros y se aplicarán diversos procesamientos a las imágenes con el objetivo de evaluar como afectan al rendimiento del modelo. Posteriormente, una vez entendido el modelo, se creará el segmentador para lesiones de patrón perivas-
cular del concurso MSLesSeg ICPR 2024. Finalmente, se realizará una discusión de las observaciones y conclusiones obtenidas.

3.1 Estructura de las pruebas

Para poder realizar los diferentes experimentos se ha realizado la división de los conjuntos de datos de entrenamiento de cada uno de las bases de datos y se han obtenido los conjuntos siguientes:

- **Conjunto de entrenamiento.** Consiste en el 80 % de los datos del conjunto de entrenamiento. Son las imágenes que se emplearán para realizar el entrenamiento de cada uno de los modelos. Gracias a este conjunto el modelo se ajustará durante el aprendizaje y aprenderá los patrones y características más importantes.
- **Conjunto de validación** Representa el 20 % del conjunto de datos. Estas imágenes sirven para evaluar el rendimiento del modelo mientras se va entrenando.

El conjunto de test de cada uno de los conjuntos de datos no se emplea ni durante el entrenamiento ni la validación, sirve para dar la evaluación final del modelo y comprobar el rendimiento del modelo con datos nunca vistos durante el entrenamiento.

Durante el entrenamiento, se empleará la función de pérdida de DICE. Esta función se basa en el coeficiente de DICE, que mide la similitud entre dos conjuntos de datos y nuestro modelo deberá minimizarla durante el entrenamiento.

Para cada una de las pruebas se han ajustado una serie de parámetros que pueden influir en el rendimiento del modelo:

- **Número de épocas:** Las épocas representan la cantidad de veces que el algoritmo de aprendizaje profundo recorre todo el conjunto de entrenamiento. Durante cada una de estas épocas, el modelo ajusta los pesos al basarse en el error que haya realizado en las predicciones. Se ha decidido que el guardado del modelo se produce en la época en la que la pérdida de DICE para el conjunto de validación es mínima.
- **Tasa de aprendizaje:** Controla el tamaño de los pasos que da el algoritmo de optimización al actualizar los pesos del modelo. Según si esta es baja o alta, puede hacer que el modelo converja rápidamente o que el entrenamiento sea muy lento. Durante los entrenamientos se ha empleado el optimizador ADAM, que es una técnica de optimización muy eficiente y que permite una convergencia rápida. Este optimizador ajusta la tasa de aprendizaje de cada parámetro individualmente y converge más rápidamente que otros métodos de optimización [39].
- **Dimensión de la imagen:** Según el tamaño que establecemos de imagen podríamos afectar al entrenamiento del modelo, tanto en su eficacia como en su velocidad de entrenamiento.
- **Normalización de la imagen:** Consiste en el ajuste de los valores de los píxeles de la imagen a un rango determinado. Nos puede ayudar a que el modelo converja rápidamente y de forma estable.
- **Tamaño del *batch*:** Es el número de muestras que se procesan juntas antes de actualizar los pesos del modelo. Durante el desarrollo de los experimentos, se emplearán diversos tamaños teniendo en cuenta las posibles limitaciones de memoria de las GPUs.
- **Características iniciales del modelo:** El número de características que se generan en la primera capa convolucional. Al establecer las características iniciales de la primera capa, el siguiente contiene el doble y van creciendo exponencialmente por cada capa del modelo. Si ponemos un número grande de filtros se aumenta el número total de parámetros, y si es pequeño, este disminuye. Según que número establecemos puede afectar la capacidad del modelo de capturar características y reducir el rendimiento.

3.2 Segmentador de lesiones WMH Segmentation Challenge MICCAI 2017

A continuación, se muestran todos los experimentos realizados con U-NET, el objetivo de cada uno de ellos y una breve discusión de los resultados obtenidos.

3.2.1 Primeras pruebas y eliminación de rebanadas sin tejido cerebral

El conjunto de datos estaba compuesto por imágenes tridimensionales, para poder realizar el entrenamiento con el modelo U-Net se obtuvieron cada una de las rebanadas que componían las imágenes. En total, 48 datos de pacientes pertenecían al conjunto de entrenamiento y 12 al de validación y una vez obtenidas todas las rebanadas los conjuntos pasaron a tener 2934 y 646 imágenes respectivamente. El conjunto de datos de estas lesiones, de origen vascular, estaba compuesto por secuencias de tipo FLAIR y T1, por lo que una de las primeras ideas iniciales fue la creación de dos segmentadores individuales: uno únicamente compuesto de secuencias FLAIR y otro de secuencias T1. Como se explicó en el capítulo 1, las dos resonancias poseen características muy variadas. El objetivo de este primer experimento es una primera aproximación de los dos segmentadores. De esta forma, se pretende optimizar el modelo para capturar las características presentes en cada tipo de imagen y realizar una fusión de los resultados para obtener una segmentación más precisa y robusta.

En este experimento inicial se establecieron 65 épocas de entrenamiento; un tamaño de *batch* de 30 imágenes; una tasa de aprendizaje de 1×10^{-3} y una cantidad de características iniciales de 32. Las imágenes poseen tamaños muy variados, por lo que se redimensionaron a un tamaño inicial de 128x128 píxeles. En el Cuadro 3.1 podemos observar los resultados obtenidos de estos experimentos sobre el conjunto de test. Por cuestiones de espacio, se muestran los resultados sobre el conjunto de validación en el Anexo A.

Cuadro 3.1: Primera aproximación. DC es el coeficiente de DICE, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	DC	IOU	Pre.	Rec.	Acc.
FLAIR	37.06 %	27.60 %	44.06 %	38.71 %	99.90 %
T1	18.17 %	12.51 %	19.24 %	20.84 %	99.85 %
Unión	32 %	23 %	35 %	41.30 %	99.87 %

El Cuadro 3.1 muestra la evaluación del segmentador de secuencias FLAIR, el segmentador de las secuencias de T1 y la evaluación de la unión de las dos máscaras obtenidas de los dos segmentadores. Como podemos observar los resultados muestran que el segmentador basado en secuencias FLAIR tiene un rendimiento mayor que el segmentador basado únicamente en secuencias T1. Esto es debido a que las secuencias FLAIR muestran las lesiones de forma más clara y son distinguibles del resto de tejido. Cabe mencionar que la superposición de las dos máscaras reduce el coeficiente de DICE, el IOU, sin embargo aumenta ligeramente el *recall* lo que significa que se capturan más áreas de las lesiones, aunque incluyendo más falsos positivos (de ahí que el *precision* también disminuya). Finalmente, el *accuracy* es demasiado elevado en todas las evaluaciones, pero esto es debido al desbalance entre clases, ya que la mayoría de los píxeles no pertenecen a las lesiones. Por lo tanto, el resto de métricas son más relevantes para nuestra tarea.

Tras una evaluación más exhaustiva de las imágenes se comprobó que algunas de las rebanadas obtenidas no pertenecían al cerebro (eran parte de la nariz y los ojos, o la parte superior del cráneo que no posee tejido cerebral), es decir, contenían estructuras que no son de interés para nuestro problema y que pueden llegar a confundir el mo-

3. EXPERIMENTACIÓN CON U-NET




Figura 3.1: Muestra de datos que indica el problema de desbalance de clases. La mayoría de píxeles pertenecen al fondo, en lugar de las lesiones.

delo. Por ello, se decidió eliminar un 10 % de las secuencias iniciales y un 10 % de las secuencias finales, de esta forma nos aseguramos que el modelo aprenda de secuencias que contienen información útil para la segmentación de las lesiones. En la Figura 3.2 podemos observar un ejemplo de estas rebanadas.




Figura 3.2: Rebanadas sin tejido cerebral.

Una vez eliminadas estas rebanadas, los conjuntos de entrenamiento y validación pasaron a tener 2358 y 522 imágenes respectivamente.

Cuadro 3.2: Experimentos realizados sin el 20 %. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*

Tipo	DC	IOU	Pre.	Rec.	Acc.
FLAIR	46.80 %	35.90 %	53.40 %	49.79 %	99.88 %
T1	33.80 %	23.05 %	38.60 %	34.75 %	99.83 %
Unión	45 %	33.20 %	41.23 %	57.77 %	99.85 %

En el Cuadro 3.2 podemos observar los resultados del experimento con esta modalidad. Podemos observar que las métricas han mejorado bastante, en concreto el segmentador de secuencias FLAIR muestra un 40.62 % de *precision*, por lo que ha identificado una gran cantidad de predicciones correctas positivas, aunque el *recall* haya

aumentado levemente, podemos observar que aún necesita mejora en la identificación completa de las lesiones. En cuanto al segmentador de secuencias T1, a pesar de mejorar, sigue teniendo un rendimiento considerablemente inferior con respecto a FLAIR. Además, la superposición de las máscaras vuelve a aumentar el *recall*, aunque el *precision* obtenido es bastante bajo con respecto a FLAIR. Finalmente, reforzamos la idea de que el *accuracy* no es adecuado para evaluar los modelos debido a los resultados tan elevados. En conclusión, la eliminación de estas rebanadas ha producido una mejora en los resultados, pero aún debemos seguir intentando mejorar el modelo.

En la Figura 3.3 se muestra la máscara obtenida por el segmentador FLAIR, T1 y la superposición de las máscaras. Además, de la máscara real y la imagen que se ha segmentado. Como podemos observar, a pesar de tener mejores métricas, el segmentador FLAIR detecta una gran número de falsos positivos, mientras que el segmentador T1 apenas consigue detectar completamente las lesiones.




Figura 3.3: Unión máscaras FLAIR y T1.

3.2.2 Tamaño de las imágenes

Una vez eliminadas las rebanadas que no aportaban información importante, el siguiente paso fue buscar la mejor configuración para nuestros datos, definiendo el tamaño ideal de las imágenes para la U-Net. Debido a la gran variedad de tamaños en nuestro conjunto de datos es importante determinar un tamaño único, ya que puede impactar al entrenamiento y rendimiento del modelo. Imágenes muy grandes pueden necesitar mucho tiempo para ser procesadas y si son demasiado pequeñas, no se podrán identificar las características más importantes debido a la baja resolución.

Por ello, se realizaron una serie de experimentos en los que se redimensionó la imagen a diversos tamaños. En la Figura 3.4 se puede ver el efecto del redimensionamiento a un tamaño de 128x128. Al tener tamaños variados, este redimensionamiento puede provocar una deformación de la imagen. Se han realizado tres experimentos con redimensionamiento en las imágenes para comprobar que tamaño era mejor: 256x256, 384x384 y 200x200 píxeles. Se utilizó el tamaño 256x256 píxeles por ser un tamaño similar al que poseían los datos. 384x384 píxeles para comprobar si un tamaño más grande permite capturar más detalles de las imágenes. Por último, 200x200 píxeles se empleó para comprobar si un tamaño ligeramente inferior al tamaño de los datos, nos permitía obtener un mejor rendimiento. Este último tamaño presentó problemas con la red porque las operaciones de *downsampling* resultaban en divisiones no enteras. Posteriormente, en el *upsampling* las dimensiones no coincidían y impedían la concatenación de los mapas de características. Se han realizado dos experimentos para comprobar cuál de las dos modificaciones realizadas a la red funcionan mejor

3. EXPERIMENTACIÓN CON U-NET




Figura 3.4: Redimensionamiento de las imágenes.

con un tamaño 200x200. La primera modificación consistía en el recorte del mapa de características de las capas del codificador; se pretendía ajustar el tamaño de las imágenes intermedias durante el proceso de codificación y que las dimensiones de los mapas de características fueran compatibles con la concatenación de las salidas de las capas de *upsampling*. La segunda modificación consistía en añadir relleno o *padding* al resultado de una capa del decodificador. En el Cuadro 3.3 se muestran los resultados de los experimentos, también se han incluido los resultados del anterior experimento, ya que se redimensionaron las imágenes a 128x128.

Para este conjunto de experimentos se ha mantenido la misma configuración de hiperparámetros que en el conjunto de experimentos anteriores. Como podemos ob-

Cuadro 3.3: Experimentos realizados con diferentes tamaños. DC es el coeficiente de DICE, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	Tam img.	DC	IOU	Pre.	Rec
FLAIR	128	46.80 %	35.90 %	53.40 %	49.79 %
FLAIR	256	21.60 %	15.92 %	26.10 %	44.45 %
FLAIR	384	23 %	16.79 %	32.07 %	40.12 %
FLAIR	200 <i>padding</i>	25.70 %	18.85 %	30.56 %	38.74 %
FLAIR	200 recorte	26.27 %	18.87 %	37.50 %	34.33 %
T1	128	33.80 %	23.05 %	38.60 %	34.75 %
T1	256	12.4 %	8.14 %	17.75 %	11.63 %
T1	384	15.66 %	10 %	20.9 %	14.56 %
T1	200 <i>padding</i>	17.15 %	11.04 %	22.17 %	19.15 %
T1	200 recorte	19.14 %	12.90 %	22.50 %	21.73 %
Unión	128	45 %	33.20 %	41.23 %	57.77 %
Unión	256	21.40 %	15.27 %	24.33 %	47 %
Unión	384	21.38 %	15.09 %	24 %	42.63 %
Unión	200 <i>padding</i>	23.63 %	16.4 %	22.97 %	42.42 %
Unión	200 recorte	25.35 %	17.47 %	32 %	38.91 %

servar, el mejor modelo es aquel en el que se redimensionaron las imágenes a 128x128, mientras que los tamaños de 256x256 y 384x384 tienen unas métricas relativamente bajas. Esto podría deberse a que el aumento del tamaño de la imagen hace que se introduzca más ruido y se dificulta la segmentación. Con respecto a el tamaño de

200x200, las dos modificaciones han obtenido resultados similares, siendo el recorte del mapa de características ligeramente mejor. En conclusión, las métricas muestran que el mejor redimensionamiento de imágenes es de 128x128.

El redimensionamiento, como se ha observado en la Figura 3.4, introduce una deformación de las imágenes lo que puede estar perjudicando al modelo. Otra transformación que se puede aplicar a las imágenes sin introducir deformaciones es la del recorte a un tamaño deseado, o bien incrementar el tamaño añadiendo píxeles negros a los bordes de la imagen en un proceso llamado *padding*, en el caso de que queramos hacer la imagen más grande. En la Figura 3.5 podemos ver un ejemplo de estos efectos, en este caso esta transformación no deformará las imágenes.



Figura 3.5: Recorte o padding a las imágenes.

Se ajustaron las imágenes a los siguientes tamaños: 200x200, 240x240, 256x256, 384x384. Se utilizó 200x200 píxeles para tener en la imagen únicamente el cerebro. Mientras que 240x240 y 256x256, por las mismas razones que en el experimento anterior, son tamaños similares al conjunto de datos. Finalmente, 384x384 píxeles para comprobar si el efecto del relleno creando imágenes más grandes, obtiene resultados mejores. Para el tamaño de 200x200, se empleó el recorte del mapa de características al obtener unas métricas ligeramente superiores. Se mantuvo el tamaño del *batch* a 30 imágenes pero la configuración de hiperparámetros que se empleó es diferente: se establecieron 100 épocas de entrenamiento y una tasa de aprendizaje de 1×10^{-4} , se pretendió mejorar así el modelo, debido a la detección de un posible sobreajuste de los datos de entrenamiento durante el entrenamiento con el redimensionamiento de tamaño de imagen 128x128 píxeles. Como se puede observar en la Figura 3.6, en la que se muestra el proceso de entrenamiento con este tamaño, la pérdida del conjunto de entrenamiento sigue bajando, mientras que para el conjunto de validación se mantiene durante gran parte del tiempo en el mismo valor.

En el Cuadro 3.4 se muestran los resultados de los experimentos. Como podemos observar el tamaño de 200x200 ha mostrado mejores resultados que los experimentos con la transformación de redimensionamiento, pero el rendimiento está por debajo de lo observado con tamaños mayores. El tamaño de 240x240 ha mostrado mejoras significativas en todas las métricas, y el resto de tamaños obtiene métricas ligeramente mejores. A pesar de que el tamaño 256x256 muestra unos resultados superiores, se ha optado que el tamaño a utilizar gracias a que nos proporciona mejor rendimiento computacional (procesamiento y entrenamiento más rápidos y menos costosos) y mejor detalle de las imágenes.

3. EXPERIMENTACIÓN CON U-NET




Figura 3.6: Entrenamiento redimensionamiento 128x128. podemos observar el sobre-ajuste a partir de la época 5.

Cuadro 3.4: Experimentos realizados con recorte/*padding*. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	Tam img.	DC	IOU	Pre.	Rec.
FLAIR	200	38.50 %	29.82 %	52 %	42 %
FLAIR	240	55.31 %	44.88 %	66.55 %	53.42 %
FLAIR	256	56.36 %	45.78 %	64.69 %	57.89 %
FLAIR	384	52.60 %	41.21 %	64.78 %	54.96 %
T1	200	20.44 %	13.98 %	27.51 %	18.88 %
T1	240	23.88 %	16.65 %	31.78 %	21.12 %
T1	256	24 %	16.68 %	33.74 %	20.82 %
T1	384	24.17 %	16.54 %	31.76 %	21.63 %
Unión	200	37.48 %	27 %	45.6 %	44.75 %
Unión	240	51.11 %	40.16 %	58.42 %	54.11 %
Unión	256	52.43 %	41.60 %	57.78 %	57.31 %
Unión	384	48.90 %	37.13 %	53.67 %	56.23 %

En conclusión, el objetivo principal de este experimento era la obtención del tamaño ideal de imágenes que nos proporcionará un equilibrio entre costo computacional y mejor precisión en la segmentación. Se determinó que la mejor transformación era el recorte o relleno, ya que no se deforma la imagen y se obtuvo un incremento de las métricas en los experimentos de la segunda transformación. Finalmente, se determinó que de todos los tamaños probados, en los futuros experimentos se empleará el tamaño de imagen de 240x240 píxeles porque nos aporta un mejor rendimiento. En la Figura 3.7, se puede observar un ejemplo de la unión de las máscaras obtenidas con los segmentadores de 240x240.

Finalmente, en la Figura 3.8 podemos observar el entrenamiento del modelo de tamaño 240x240. Se puede observar como el ajuste de los hiperpárametros, además del procesamiento de imágenes mejora considerablemente la pérdida del conjunto de validación, aunque pensamos que aún es posible mejorar el modelo.




Figura 3.7: Unión máscaras segmentadores tamaño 240x240 de imagen.




Figura 3.8: Entrenamiento tamaño 240x240.

3.2.3 Normalización

La normalización de imágenes es una técnica de procesamiento de imágenes que nos permite ajustar los valores de los píxeles de una imagen para que se establezcan en un rango específico [40]. Mediante la aplicación de la normalización a las imágenes se pretende obtener una mejor calidad de estas, para que nuestro modelo tenga mejor rendimiento a la hora de capturar las características de las lesiones.

Se aplicó la normalización de tres formas. En la Figura 3.9 se muestran los tres procesos de normalización que se han aplicado. La primera imagen indica que la normalización se ha aplicado a toda la imagen. La segunda, se ha aplicado una máscara que selecciona el tejido cerebral y se ha realizado únicamente a los píxeles de dentro de la máscara, de esta forma podemos resaltar los detalles del tejido cerebral y ignorar los valores de los píxeles que se encuentran fuera de la máscara. La tercera, se ha aplicado una máscara a todo el cerebro y se han rellenado los huecos; de esta forma nos aseguramos que todos los píxeles de dentro del cerebro estén incluidos durante la normalización.

Para la obtención de las máscaras se ha utilizado el método de umbralización de Otsu, que consiste en determinar automáticamente el umbral de binarización óptimo basado en el histograma de la imagen[41], de esta forma se separa el cerebro del fondo. Para rellenar los huecos de la máscara, se ha utilizado el método `binary_fill_holes` de la librería `scipy` que cubre cualquier área discontinua en el área de una máscara.

Hemos decidido aplicar dos tipos de normalización: la normalización Gaussiana y la normalización MinMax.

3. EXPERIMENTACIÓN CON U-NET




Figura 3.9: Proceso de aplicación de máscaras a las imágenes.

Experimentos con normalización Gaussiana

La normalización gaussiana o estandarización consiste en ajustar los valores de los píxeles de una imagen para que tenga una distribución normal, es decir, una media de cero y una desviación de 1 [40]. La configuración de hiperpárametros empleada es la misma que en los experimentos de recorte. Se disminuyó el tamaño del *batch* a 15 para intentar mejorar el rendimiento del modelo. En el Cuadro 3.5 se pueden observar los resultados de los experimentos.

Cuadro 3.5: Experimentos realizados con normalización gaussiana/*padding*. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	Normalización	DC	IOU	Pre.	Rec.
FLAIR	Toda imagen	62 %	51.85 %	70 %	63 %
FLAIR	Tejido cerebral	60 %	49.65 %	73.21 %	56.78 %
FLAIR	Todo cerebro	59 %	48.30 %	70 %	57.40 %
T1	Toda imagen	31.56 %	22.24 %	46.31 %	28.14 %
T1	Tejido cerebral	33.70 %	24.58 %	43.3 %	33.30 %
T1	Todo cerebro	31.31 %	24.50 %	39 %	38.20 %
Unión	Toda imagen	57.66 %	45.53 %	56.80 %	63.88 %
Unión	Tejido cerebral	54.28 %	41.74 %	54 %	60 %
Unión	Todo cerebro	50.37 %	37.67 %	46.29 %	62.80 %

Como se puede observar la normalización de toda la imagen ha obtenido unas métricas altas tanto para el modelo de secuencias FLAIR como para la superposición. En el caso del modelo de secuencias FLAIR ha obtenido un coeficiente de DICE del 62 % y un IOU del 51.85 %, lo que nos indica buena superposición entre las predicciones y las áreas de referencia. Además, posee una precisión y *recall* bastante elevados, lo que indica que está capturando una gran cantidad de lesiones reales. Sin embargo, para el modelo de secuencias T1, el experimento que ha obtenido mejores resultados ha sido normalizando únicamente el tejido cerebral, es el experimento que ha sido ligeramente mejor en comparación con los otros métodos de normalización. Pero, en general son más bajas que en FLAIR.

Se ha podido comprobar que mediante la aplicación de este tipo de normalización se ha mejorado significativamente las métricas.

Experimentos con normalización MinMax

La normalización minmax consiste en el ajuste de los valores de los píxeles para que se encuentren entre un rango determinado, este suele ser entre 0 y 1. Este tipo de normalización nos permite preservar la relación original de los valores [40].

La configuración de los hiperpárametros es la misma que se utilizó en los experimentos de recorte y normalización Gaussiana.

Cuadro 3.6: Experimentos realizados con normalización MinMax/*padding*. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	Normalización	DC	IOU	Pre.	Rec.
FLAIR	Toda imagen	48.35 %	38.59 %	53.11 %	49.48 %
FLAIR	Tejido cerebral	47.94 %	38.40 %	55.50 %	46.52 %
FLAIR	Todo cerebro	47.80 %	38.04 %	52.75 %	48.78 %
T1	Toda imagen	24.97 %	17.69 %	33.32 %	23.13 %
T1	Tejido cerebral	25.10 %	17.55 %	37.69 %	22.21 %
T1	Todo cerebro	23.82 %	16.57 %	35.69 %	21 %
Unión	Toda imagen	44.90 %	34.92 %	44.45 %	51.55 %
Unión	Tejido cerebral	45.69 %	35.62 %	47.42 %	49.22 %
Unión	Todo cerebro	46.07 %	35.83 %	46.42 %	51.16 %

En el Cuadro 3.6 se pueden observar los resultados de los experimentos. Como se puede observar, los resultados obtenidos no son mejores que los obtenidos con la normalización Gaussiana. Al igual que en los experimentos de la normalización gaussiana, para las secuencias FLAIR y T1 se obtiene que la mejor normalización es de toda la imagen y del tejido cerebral. Sin embargo, para la superposición de las máscaras el mejor ha sido la normalización de todo el cerebro.

En conclusión, hemos demostrado que la aplicación de normalización en las imágenes, no solo mejora la calidad de estas, sino que también mejora el rendimiento de segmentación. Además, la normalización gaussiana ha obtenido una métricas considerablemente altas con respecto a la normalización minmax, que puede ser debido a que la normalización minmax es más sensible a los valores extremos, mientras que la estandarización de los datos no permite que estos valores altos dominen la escala.

3.2.4 Concatenación de secuencias

Como hemos podido observar, los modelos con únicamente secuencias T1 obtienen métricas muy bajas. Sus métricas demuestran una gran incapacidad para aprender las características de las lesiones. Las secuencias T1, por si solas no proporcionan suficiente información como para segmentar de forma precisa las lesiones.

Para abordar este problema y utilizar las secuencias T1, se decidió realizar una concatenación de las secuencias FLAIR y T1 como información de entrada de nuestro modelo. Consiste en construir imágenes de 2 canales: en el primer canal se situó una secuencia y en el segundo, otra. De esta forma, podemos aprovechar las características presentes en las secuencias T1 para poder mejorar la segmentación de las imágenes, y mejorar la capacidad del modelo para segmentar las lesiones.

3. EXPERIMENTACIÓN CON U-NET

Si bien las secuencias FLAIR resaltan mejor las lesiones, las secuencias T1 proporcionan otros detalles anatómicos que pueden proporcionar información complementaria para realizar una segmentación más robusta y precisa.

Además, hasta ahora los modelos se habían entrenado con las imágenes siguiendo un orden fijo, donde las secuencias estaban organizadas por rebanadas del cerebro. Esta aproximación hacía que nuestros modelos se sobreajustasen a las secuencias específicas de las imágenes. Al hacer la mezcla aleatoria, se ayuda al modelo a generalizar mejor y aprende los patrones de manera independiente del orden de las imágenes.

Cuadro 3.7: Experimentos realizados con la concatenación de secuencias. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

ID	Características	Tasa apren.	Épocas	DC	IOU	Pre.	Rec.
1	32	1×10^{-4}	100	55.64 %	47.90 %	68.32 %	56.58 %
2	32	5×10^{-5}	100	43.50 %	45.31 %	56.39 %	63.63 %
3	32	5×10^{-5}	150	55.30 %	48.26 %	63.33 %	60.23 %
4	32	1×10^{-4}	100	59 %	53 %	61.60 %	68.37 %
5	48	1×10^{-4}	30	59.70 %	52.37 %	60.62 %	70 %

En el Cuadro 3.7 se puede observar los resultados de los experimentos. La prueba nº1 consiste en la concatenación de las secuencias y la utilización de los mismos hiperpárametros que los experimentos anteriores. Se consiguieron unos resultados aceptables, por lo que se decidió continuar experimentando con la tasa de aprendizaje y el número de épocas del modelo. A pesar de que los experimentos 2 y 3, no han alcanzado métricas mejores en comparación al resto, podemos llegar a la conclusión de que si se usan tasas de aprendizaje bajas para el entrenamiento, el incremento del número de épocas (es decir, hacer el entrenamiento más largo), beneficia al rendimiento del modelo. Posteriormente, para el experimento nº4 se decidió mezclar las imágenes, y como indican los resultados, ayudó al modelo a generalizar. Finalmente, para el último experimento se decidió incrementar el número de características para permitir una mayor capacidad de aprendizaje durante el entrenamiento.

Las conclusiones obtenidas de estos experimentos es que la tasa de aprendizaje 1×10^{-4} y la mezcla aleatoria de las imágenes permite converger muy rápido y obtener unas métricas mejores. Además, si incrementamos el número de características del modelo podemos mejorar la capacidad de aprender y generalizar de este.

3.2.5 Aumento de datos

Una de las principales limitaciones es la limitada cantidad de imágenes disponibles en nuestro conjunto de entrenamiento. Por lo tanto, es necesario la aplicación de una serie de transformaciones a las imágenes para la creación de nuevas imágenes sintéticas. Este proceso se conoce como aumento de datos (en inglés, *data augmentation*) y, como su propio nombre indica, nos permite aumentar el tamaño del conjunto de datos. De esta forma, el modelo tiene más ejemplos de los que aprender. Además, se incrementa la variabilidad de los datos haciendo que el modelo sea más robusto y mejorar la generalización de este, haciendo que no memorice únicamente características del conjunto de entrenamiento y que tenga un mejor rendimiento ante datos nuevos.

3.2. Segmentador de lesiones WMH Segmentation Challenge MICCAI 2017

Las transformaciones aplicadas a las imágenes son las siguientes y se pueden observar su efecto en la Figura 3.10 :

- **Rotación:** las imágenes se han rotado un rango de 15 grados, tanto hacia la derecha o izquierda
- **Escalado:** se ha aplicado un *zoom in* y *zoom out* para variar el tamaño del cerebro entre 0.9 y 1.1 veces su tamaño original.
- **Cizallamiento:** Se desliza una parte de la imagen hacia una dirección específica, para poder estirar la imagen y deformarla en cierta medida. El cizallamiento aplicado ha sido de 18 grados.




Figura 3.10: Transformaciones aplicadas a las imágenes.

Se realizaron una serie de experimentos y en cada uno se incrementó de manera progresiva la cantidad de imágenes generadas. Todas las imágenes creadas se añadieron al conjunto de datos original.

Cuadro 3.8: Experimentos realizados con el incremento de datos. *Caract.* significa la cantidad de características iniciales, *pre.* significa *precision*, *rec.* significa *recall* y *acc.* *accuracy*.

Imágenes gen.	Caract.	Épocas	Tasa aprendizaje	DC	IOU	Pre.	Rec.
1000	48	50	1×10^{-4}	58.72 %	51.31 %	64.66 %	65.04 %
2000	58	50	5×10^{-5}	59 %	52.2 %	64.75 %	65.84 %
3000	58	60	5×10^{-5}	59 %	51.59 %	61.57 %	67.34 %
4000	62	60	1×10^{-4}	60.41 %	69.03 %	78.43 %	85.73 %
5000	62	60	1×10^{-4}	61.41 %	67.90 %	79.18 %	83.30 %

Se han realizado una serie de experimentos en los que se ha ido aumentando progresivamente la cantidad de datos y en el Cuadro 3.8 se muestran los resultados. Como podemos observar, si incrementamos 1000 imágenes se obtiene un rendimiento similar al mejor experimento de la sección anterior. En los siguientes experimentos, además de incrementarse el número de imágenes, se aumentó el número de características y se disminuyó la tasa de aprendizaje, lo que provocó que aumentarían ligeramente las métricas. Finalmente, con una cantidad de 4000 imágenes generadas y con una cantidad de características iniciales de 62, podemos observar los mejores resultados hasta ahora, esto indica que una mayor cantidad de datos y características mejoran la capacidad del modelo de segmentar y reconocer las lesiones de forma más precisa. Con 5000 imágenes se obtienen resultados ligeramente inferiores. En conclusión, podemos afirmar que el aumento de datos permite que el modelo mejore las métricas y que generalice mejor.

3.3 Segmentador MSLesSeg del ICPR 2024

En esta sección se describe el proceso de creación de un segmentador de lesiones de patrón perivascular. Para la creación de este modelo, se empleó el conocimiento adquirido durante la creación del segmentador de lesiones anterior. Se emplearon aquellos procesamientos y técnicas que han resultado efectivas para la segmentación de las lesiones y las adaptaremos para abordar las particularidades de las lesiones de patrón perivascular.

Las imágenes utilizadas para entrenar y validar se obtuvieron de un concurso que se encuentra en activo (MSLesSeg ICPR 2024) en el momento de la realización del TFG. Con lo cual, es importante destacar que las máscaras del conjunto de test no se han proporcionado. Estas máscaras son esenciales para la evaluación directa de la precisión del modelo. Debido a esto, la evaluación de los modelos se realizó sobre el conjunto de validación, así garantizamos que el rendimiento del modelo es medido utilizando las máscaras y imágenes aportadas en este conjunto.

Aparte de la diferencia en la tipología de las lesiones, nos encontramos con una serie de diferencias principales con el anterior conjunto de datos. En el conjunto de datos actual, se nos proporcionan secuencias T2. Además, las imágenes han sido sometidas a procesamientos y normalizaciones diferentes; a un proceso de *skull-stripping*, es decir, el cráneo ha sido eliminado y han sido normalizadas con un software diferente y proceden todas de escáneres similares. Por lo tanto, poseemos un conjunto de datos más uniforme que el anterior.




Figura 3.11: Comparación entre los diferentes conjuntos de datos. A la izquierda, secuencia FLAIR del WMH Segmentation Challenge. A la derecha, secuencia FLAIR del MSLesSeg, podemos apreciar la eliminación del cráneo.

En la Figura 3.11 podemos observar como el conjunto de imágenes de lesiones de origen vascular no se ha realizado la extracción del cráneo, y para el de patrón perivas-

cular si. Finalmente, en el Anexo B se muestran las gráficas de algunos entrenamientos realizados.

Primera aproximación: Redimensionamiento

El primer experimento en el desarrollo del segmentador de lesiones de patrón perivascul ar se enfocó en la creación de tres segmentadores, uno para cada secuencia: FLAIR, T1 y T2, para después unir las máscaras. A pesar de que todas las imágenes ya poseen el mismo tamaño, se decidió redimensionar a un tamaño de 200x200, aprovechando la modificación realizada para la U-NET. El redimensionamiento se ha realizando aplicando *padding* a las imágenes, ya que nos permite ajustar las dimensiones de las imágenes sin distorsionar las características de estas. Además, tras analizar más a fondo el conjunto de datos, se observó que había rebanadas que no tenían tejido cerebral y eran completamente negras, por lo que se optó por eliminarlas ya que no aportaban información útil para la segmentación de las imágenes. El entrenamiento tuvo una duración de 35 épocas, con unas características iniciales de 64 y una tasa de aprendizaje de 1×10^{-4} . Para todos los experimentos se estableció un tamaño de *batch* de 48 imágenes. Se ha utilizado un número elevado de características, ya que se tienen más imágenes, entonces nos enfrentamos a una tarea más compleja y se requiere capturar más características.

Cuadro 3.9: Experimentos realizados con tamaño de 200x200. pre. significa *precision*, rec. significa *recall*, DC significa coeficiente de DICE.

Tipo	DC	IOU	Pre.	Rec.
FLAIR	75 %	62 %	76.80 %	75.98 %
T1	44.38 %	30 %	56.65 %	38 %
T2	48.87 %	33.48 %	58.26 %	43.26 %
Unión	47.16 %	34.70 %	44.10 %	55 %

Como podemos ver en el Cuadro 3.9, FLAIR sigue siendo el modelo con métricas más altas. El coeficiente de DICE y el IOU muestran que hay una superposición significativa entre la salida y la máscara de referencia, con lo cual hay una precisión y *recall* altos. Los modelos con T1 y T2 muestran métricas significativamente más bajas, siendo T2 ligeramente mejor que T1. Por último, la superposición de las máscaras tampoco ha mejorado el modelo, sino que ha obtenido métricas similares a T1 y T2.

Normalización gaussiana

El segundo experimento se centró en la aplicación de la normalización Gaussiana a las imágenes. Esta técnica había sido efectiva en la mejora de rendimiento durante la creación del segmentador de lesiones de origen vascular, por lo que decidimos probar si mejoraría el rendimiento en estos modelos. Se ha realizado un entrenamiento de 35 épocas, se ha bajado la tasa de aprendizaje a 5×10^{-5} y se ha incrementado a 84 el número de características iniciales.

Como podemos ver en el Cuadro 3.10, las métricas para FLAIR y T2 han disminuido ligeramente, en comparación con el experimento anterior. Mientras que para el modelo de secuencias T1 se mantienen los valores similares. Aunque FLAIR sigue siendo

3. EXPERIMENTACIÓN CON U-NET

Cuadro 3.10: Experimentos realizados con normalización gaussiana de 200x200. pre. significa *precision*, rec. significa *recall*.

Tipo	DC	IOU	Pre.	Rec.
FLAIR	70.65 %	58 %	75.50 %	71.82 %
T1	44.46 %	31 %	61.48 %	37.55 %
T2	46.67 %	32.70 %	59.13 %	41.54 %
Unión	45.28 %	33.83 %	44.72 %	51.94 %

el modelo que aporta mejores resultados. La unión de las máscaras ha disminuido ligeramente también. A diferencia del segmentador de lesiones del MICCAI 2017 WMH Segmentation Challenge, la estandarización no aporta una mejora significativa, con lo que no lo emplearemos en futuros experimentos. Esto puede deberse a que los datos ya son bastante homogéneos entre si y fueron procesados previamente, con lo cual los efectos de la normalización son mínimos o, incluso, podemos estar añadiendo ruido a las imágenes.

Concatenación de secuencias

El tercer experimento consistió en la concatenación de las secuencias FLAIR, T1 y T2 para generar una imagen con tres canales. En los anteriores experimentos, se creó una imagen de dos canales. En nuestro caso, poseemos una secuencia extra, por lo que podemos observar el comportamiento que tiene en la creación del modelo. Se ha realizado un entrenamiento de 35 épocas, y las tasas de aprendizaje se han ido variando como vemos en el Cuadro 3.11. Como podemos observar en el Cuadro 3.11 la

Cuadro 3.11: Experimentos realizados con concatenación de 200x200. pre. significa *precision*, rec. significa *recall*.

ID	Tasa apren.	DC	IOU	Pre.	Rec.
1	5×10^{-5}	29.22 %	19.55 %	43.41 %	24.23 %
2	1×10^{-4}	26.65 %	17.74 %	41.27 %	21.93 %
3	5×10^{-4}	25.99 %	17.35 %	35.70 %	22.69 %

concatenación de las tres imágenes, ha disminuido significativamente los resultados de los modelos. Por lo tanto, no ha mejorado en comparación con el resto de experimentos. Puede ser que la combinación introduzca una complejidad adicional que afectó al rendimiento del modelo.

Aumento de datos

En este último experimento se crearán imágenes sintéticas aplicando las transformaciones definidas en el experimento de aumento de datos del segmentador del MICCAI 2017. En ese caso, el rendimiento mejoró considerablemente. Por lo que se intentó de esta forma mejorar el comportamiento de los segmentadores de secuencias T1 y T2.

A diferencia del segmentador del MICCAI 2017, se generaron 4000 datos sintéticos y se concatenaron las correspondientes secuencias, pero en este experimento no se realizó porque los resultados de la concatenación no mejoraron el rendimiento. Volvimos a

entrenar un segmentador para cada tipo de secuencia y se añadieron 4000 imágenes generadas.

Para el entrenamiento se establecieron 50 épocas, una tasa de aprendizaje de 5×10^{-5} y unas características iniciales de 64.

Cuadro 3.12: Experimentos realizados con aumento de datos (generación de 4000 imágenes). pre. significa *precision*, rec. significa *recall*.

Tipo	DC	IOU	Pre.	Rec.
FLAIR	75.67 %	61.94 %	82.10 %	70.89 %
T1	42.98 %	29 %	59.88 %	34.94 %
T2	47.41 %	32.22 %	57.75 %	41.16 %
Unión	47.41 %	35 %	46.5 %	54 %

Como podemos ver en el Cuadro 3.12, la creación de estas 4000 imágenes apenas mejoró el rendimiento. Esto puede deberse a que el aumento de datos no haya generado suficiente diversidad como para mejorar el rendimiento del modelo. Sin embargo, el segmentador de secuencias FLAIR demostró ser el mejor de todas las modalidades.

3.4 Discusión

Esta sección se realizará un análisis de los resultados y conclusiones obtenidas.

Segmentador de lesiones del MICCAI 2017 WMH Segmentation Challenge

Tras una experimentación exhaustiva, se han podido extraer las siguientes conclusiones sobre el modelo U-Net:

1. La eliminación de imágenes que no aportaban información de interés a nuestro problema supuso una gran mejora en el rendimiento. De esta forma, se redujo ruido en el conjunto de datos y que el modelo se enfocará en las características distintivas de las lesiones.
2. El tamaño que poseen las imágenes puede afectar a como el modelo captura los detalles. La forma de redimensionar las imágenes suponía un gran impacto en el modelo, obteniendo que el recorte o o relleno mejoraba sin dudas las métricas al no deformar la forma del cerebro. Además, el tamaño 240x240 se mostró como el indicado.
3. La normalización de las imágenes tiene un impacto importante en el modelo. En este caso, la aplicación de diferentes normalizaciones mostró que la mejor fue la normalización gaussiana.
4. La optimización de los hiperpárametros del modelo nos ha permitido ir ajustando el modelo en la tarea de segmentación.
5. La generación de imágenes sintéticas han supuesto una solución a nuestro limitado conjunto de datos. Además, nos ha permitido añadir una gran variabilidad que mejoró la generalización de nuestro modelo.

3. EXPERIMENTACIÓN CON U-NET

Con lo cual se ha obtenido un segmentador de lesiones de origen vascular que posee las siguientes características:

1. Se ha entrenado con un conjunto de datos en el que se eliminó el 20% de las rebanadas de cada cerebro.
2. Se realizó un procesamiento de imágenes en el que se hizo un recorte/relleno de 240x240 y se aplicó una normalización gaussiana.
3. El modelo posee 62 características iniciales y se entrenó con una tasa de aprendizaje 1×10^{-4} durante 60 épocas.
4. Se aplicó aumento de datos de 4000 imágenes al conjunto de entrenamiento.

Aunque las métricas de evaluación empleadas son muy útiles al la hora de evaluar el rendimiento del modelo, se quiso hacer un análisis más profundo del modelo para proporcionar información de aquellos aspectos más débiles.

Se decidió cuantificar la cantidad de lesiones de nuestro conjunto de datos y hacer un análisis de su área. De esta forma podremos averiguar que tipo de lesiones tiene más dificultades de detectar nuestro modelo. En el Cuadro 3.13 podemos observar la cantidad total de lesiones que posee el conjunto de test, la cantidad de lesiones detectadas por el modelo y las no detectadas. El modelo consiguió detectar correctamente la mitad de las lesiones. Si hacemos un análisis más exhaustivo podemos observar que la mayoría de las lesiones tienen una área inferior a 10 píxeles, mientras que las lesiones de una área entre 20 y 50 o superior son menos comunes. Podemos llegar a la conclusión de que nuestro modelo tiene una gran dificultad para detectar lesiones pequeñas en comparación con las lesiones de mayor tamaño. En el Cuadro 3.14 podemos observar el área media de las lesiones detectadas y no detectadas de cada rango. La diferencia entre el área media de las lesiones de la segunda categoría es apenas imperceptible, mientras que con el resto es bastante grande, esto puede deberse a como son las imágenes.

Cuadro 3.13: Lesiones detectadas, no detectadas y su área.

Lesiones	Área <10	20<Área <50	Área >50	Total
Detectadas	8471	214	480	9165
NO detectadas	5117	1315	2846	9278
Total	13588	1529	3326	18443

Cuadro 3.14: Área media detectadas, no detectadas en píxeles.

Lesiones	Área <10	20<Área <50	Área >50
Detectadas	1.33	31.65	49.80
NO detectadas	3.55	31.98	121.65

Vamos a observar algunas segmentaciones obtenidas para entender los resultados de este análisis. Una de las principales problemas es como son las imágenes. Contienen características muy diversas: provienen de escáneres y lugares diferentes, tienen tamaños variados y muchas de las segmentaciones se tratan de lesiones diminutas. En la

Figura 3.12 y la Figura 3.13, se puede observar claramente la diferencia entre secuencias que proceden de diferentes escáneres. Además, se pueden observar que las lesiones a veces tenían una área muy pequeña o formas variadas sin seguir ningún patrón, lo que dificultan el aprendizaje de nuestros modelos. En la Figura 3.14 se puede observar un




Figura 3.12: Segmentación de lesiones muy pequeñas.




Figura 3.13: Segmentación secuencia FLAIR de otro escáner.

ejemplo más de la gran cantidad y variedad de lesiones, y como las pequeñas son las más difíciles de detectar. También, cabe destacar el hecho de que no todas las rebana-




Figura 3.14: Segmentación lesiones pequeñas y grandes.

das tenían lesiones como se puede observar en la Figura 3.15, con lo que se permitía al modelo tener ejemplos de partes del cerebro que estuvieran sanas y poder aprender de sus características.

Finalmente, destacar que se ha implementado un algoritmo que cuenta los contornos de la segmentación obtenida por el modelo y la máscara etiquetada basada en la función `findContours` de la librería OpenCV. De esta manera, si se desea evaluar las

3. EXPERIMENTACIÓN CON U-NET




Figura 3.15: Segmentación sin lesiones.

imágenes de forma individual, se pueden comparar los contornos detectados con los contornos de la máscara detectada. En la Figura 3.16, se puede observar un ejemplo.




Figura 3.16: Contador de contornos.

Segmentador de lesiones del ICPR 2024 MSLesSeg

Para la creación de este segmentador, se aplicaron los conocimientos adquiridos durante el desarrollo del segmentador del MICCAI 2017 WMH Segmentation Challenge. Pero cada tarea presentaba problemáticas diferentes. En este caso, no se hizo una búsqueda exhaustiva del tamaño ideal, ya que todas las imágenes poseían el mismo tamaño. Se redimensionaron mediante *padding* y recorte a un tamaño de 200x200 píxeles. Además, la normalización y la concatenación de secuencias, que había mejorado considerablemente el rendimiento en el anterior segmentador, no lo hizo en este caso. La adición de imágenes sintéticas al conjunto de datos, mejoró ligeramente las métricas, pero aún habiendo espacio para mejorar.

En conclusión, el modelo de secuencias FLAIR es el que mejor segmenta, a diferencia del segmentador para secuencias T1 y T2. A continuación, se realizará un análisis cualitativo, al igual que con el anterior segmentador, del mejor modelo obtenido. Este modelo ha sido el segmentador de secuencias FLAIR entrenado con un aumento de datos de 4000 imágenes. Los resultados que se describirán se han obtenido del conjunto de validación.

En el Cuadro 3.15 podemos observar que no ha detectada la mayoría de las lesiones, teniendo dificultad para segmentar sobretodo las lesiones más pequeñas, al igual que

Cuadro 3.15: Lesiones detectadas, no detectadas y su área.

Lesiones	Área <10	20<Área <50	Área >50	Total
Detectadas	469	58	124	651
NO detectadas	1537	627	937	3101
Total	2006	685	1061	3752

el segmentador del MICCAI 2017.

Cuadro 3.16: Área media detectadas, no detectadas en píxeles.

Lesiones	Área <10	20<Área <50	Área >50
Detectadas	4.31	34.56	57.83
NO detectadas	4.735	31.32	55.49

En el Cuadro 3.16, se muestra que el área media de las lesiones detectadas y no detectadas es similar, pero el de las no detectadas tiende a ser un poco más pequeña.

Si se observan algunas segmentaciones obtenidas, se puede comprobar la similitud con las segmentaciones del segmentador del MICCAI 2017. En la Figura 3.17 podemos ver como tienen dificultad para detectar algunas lesiones, definirlas correctamente, o bien, segmentar las más pequeñas. También, se puede ver como algunas imágenes no tenían lesiones, lo que permitía al modelo aprender las características de rebanadas sanas.

En conclusión, a pesar de tratarse de tareas de segmentación similares, gran parte de los experimentos que funcionaron sobre un conjunto de datos no lo hicieron sobre el otro.

3.5 Conclusión

En este capítulo, se ha expuesto el análisis realizado del comportamiento de la U-Net, que tenía como objetivo la creación de un segmentador eficaz de lesiones de origen vascular para el MICCAI 2017 WMH Segmentation Challenge. Se exploraron diferentes combinaciones de parámetros y procesamientos para evaluar sus efectos en la eficacia del modelo. Basándose en ese entendimiento, se desarrolló un segmentador especializado en lesiones de patrón perivascular para el ICPR 2024 MSLesSeg. Finalmente, se realizó un análisis exhaustivo de la eficacia de los modelos obtenidos y la precisión en sus segmentaciones.

3. EXPERIMENTACIÓN CON U-NET




Figura 3.17: Segmentaciones del ICPR 2024.

OTRAS APROXIMACIONES

Aunque el modelo U-Net ha mostrado resultados muy buenos, la creación de un segmentador de este tipo de lesiones puede abordarse desde varias aproximaciones. Por tanto, la exploración de diferentes enfoques puede ofrecer otras perspectivas. En el presente capítulo, se abordarán las estrategias alternativas para la segmentación de lesiones, que a pesar de no haber sido implementados de forma exhaustiva en este proyecto, representan líneas prometedoras para trabajos futuros.

4.1 3D-UNET

Las RMs de nuestros conjuntos de datos son volumétricas, lo que presenta un desafío debido a la complejidad y dimensionalidad de los datos. Durante el entrenamiento con U-Net, los datos volumétricos se transformaron en datos bidimensionales, procesando cada rebanada del volumen de forma independiente. Sin embargo, este enfoque puede resultar insuficiente para capturar características tridimensionales de nuestros datos, ya que no se tiene en cuenta la continuidad de las lesiones entre las diferentes rebanadas del volumen. Es aquí donde el modelo 3D U-Net constituye una herramienta útil para la segmentación de datos volumétricos. Este modelo es una extensión de U-Net tradicional, en la que se adapta su arquitectura a un dominio tridimensional para permitir la segmentación de estructuras anatómicas en volúmenes de imágenes médicas.

Se nos plantean una serie de problemáticas para el modelo:

- **Variabilidad en profundidad:** Durante la experimentación con U-NET, se planteó esta problemática para las imágenes del MICCAI 2017 WMH Segmentation Challenge, debido a la diferencia de tamaños en sus imágenes. Pero este conjunto de datos no solo posee variaciones de tamaños, sino que también de profundidad. Con lo que se plantea la pregunta de cuál es el tamaño tridimensional más adecuado y cómo se deben transformar los datos para nuestro modelo.

- **Limitación de datos:** La cantidad limitada de datos tridimensionales puede que sea insuficiente para entrenar un modelo de aprendizaje profundo tan complejo como 3D U-Net. En el caso de las imágenes del MICCAI 2017, nuestro conjunto de entrenamiento y validación poseen 48 y 12 imágenes, mientras que el del ICPR 2024 posee 74 y 19 imágenes. Siendo unas cantidades de datos muy pequeñas.
- **Lesiones con formas y volúmenes muy variados:** Al igual que en el entrenamiento bidimensional, las formas y tamaños tan variados de estas lesiones dificulta el aprendizaje de patrones y las características. En el caso de los datos 3D, los diferentes volúmenes y múltiples objetos lo convierten en una tarea compleja. En la Figura 4.1, podemos observar tres imágenes 3D, una en la que podemos observar el cerebro, en la segunda, lesiones de patrón perivascular y, finalmente, lesiones de origen vascular.
- **Complejidad del modelo:** 3D U-Net es una extensión tridimensional de U-Net. Este hecho introduce una mayor complejidad al requerirse más recursos computacionales, tanto en memoria como en capacidad de cómputo para el procesamiento completo de volúmenes.




Figura 4.1: Visualización en 3D del cerebro, lesiones de patrón perivascular y de origen vascular. Las lesiones del patrón perivascular proceden de una secuencia del ICPR 2024 MSLesSeg y las de origen vascular proceden del MICCAI 2017 WMH Segmentation Challenge.

Se realizaron un conjunto de experimentos para el conjunto de datos del MICCAI 2017 WMH Segmentation Challenge y otros para el conjunto de datos del ICPR 2024 MSLesSeg. Para todos ellos se realizó un entrenamiento de 50 épocas y se establecieron unas tasas de aprendizaje de 5×10^{-5} y 5×10^{-6} . Se decidió emplear la función de pérdida *CrossEntropyLoss* para evaluar el rendimiento del modelo durante el entrenamiento. Al igual que en la experimentación con U-Net, se usó el optimizador ADAM. Esta función de pérdida mide las diferencias entre las predicciones del modelo y las etiquetas verdaderas. La función convierte en probabilidades las salidas del modelo en un rango entre 0 y 1, después calcula la diferencia entre las probabilidades predichas y las etiquetas verdaderas usando una función llamada entropía cruzada. La entropía cruzada mide la incertidumbre asociada a las predicciones del modelo, es decir, si se realiza una predicción de forma incorrecta, la pérdida será mayor [42]. Se ha empleado porque penaliza las predicciones incorrectas cuando el modelo realiza una predicción

incorrecta con una probabilidad muy elevada. De esta forma, ayudamos al modelo a aprender más rápido de sus errores.

Las imágenes se redimensionaron a un tamaño de 128x128x48. De esta forma, poder tener un tamaño uniforme con el que realizar una primera aproximación y que nos permita entrenar el modelo sin utilizar tantos recursos y memoria. Se optó para esta primera aproximación utilizar las secuencias FLAIR, ya que con la experimentación de la U-Net era el método que nos aportaba mejores resultados.

En el caso de los experimentos realizados sobre el conjunto del MICCAI 2017 WMH Segmentation Challenge, los entrenamientos realizados tuvieron comportamientos similares a la Figura 4.2. En ella podemos observar como la curva de entrenamiento descendiendo lentamente hasta estancarse. La pérdida de validación continua descendiendo, aunque de forma muy lenta.




Figura 4.2: Entrenamiento 3D U-NET para MICCAI 2017 WMH Segmentation Challenge. Se puede observar como se produce un sobreajuste del modelo. Se empleó una tasa de aprendizaje de 5×10^{-5} .

En el caso del conjunto de datos del patrón perivascular (del ICPR 2024 MSLesSeg), los entrenamientos también fueron muy similares como en la Figura 4.3. En ella podemos observar como la curva de la pérdida sobre el entrenamiento tiene una tendencia más suave, mientras que para la curva de la validación tiene una gran variación de las pérdidas. El modelo está sobreentrenando los datos del conjunto de entrenamiento, está aprendiendo las características específicas de los datos de entrenamiento y no generaliza los del conjunto de validación.

Tras la realización de estos experimentos se pueden obtener una serie de conclusiones. El modelo 3D U-Net es un modelo muy complejo, posee un total de 19.072.899 parámetros, a diferencia de los 7.800.000 aprox. de parámetros de U-NET. Por lo tanto, al tener conjuntos de datos tan pequeños, un modelo más simple permitiría generalizar mejor los datos, como se ha visto en el entrenamiento de U-Net. La gran cantidad de parámetros también produce un mayor riesgo de sobreajuste, como se puede ver en los experimentos del ICPR 2024 MSLesSeg en la Figura 4.3, porque se aprende los patrones específicos de los datos de entrenamiento. Llegamos a la conclusión de que la limitada cantidad de datos afecta considerablemente al rendimiento de nuestros segmentadores, siendo insuficientes para entrenar un modelo tan complejo. Una posible solución sería la creación de imágenes sintéticas en 3D para incrementar el tamaño de los conjuntos. En nuestros modelos bidimensionales, el aumento de datos se ha realizado mediante la

4. OTRAS APROXIMACIONES




Figura 4.3: Entrenamiento 3D U-NET para patrón perivascular del ICPR 2024 MSLesSeg. Se puede observar como se produce un sobreajuste del modelo en la época 5. Se empleó una tasa de aprendizaje de 5×10^{-5} .

aplicación de rotaciones, deformaciones elásticas y cambios en el escalado, por ello se deberían investigar la aplicación de estas técnicas para la generación de nuevos datos volumétricos.

También, se podría considerar el uso de un modelo 3D U-Net entrenado en conjuntos de datos más grandes de imágenes médicas y realizar *fine-tuning*, una técnica que consiste en el entrenamiento de las últimas capas de un modelo con datos más específicos [43].

En conclusión, el uso de modelos 3D como 3D U-Net puede ser una alternativa útil para la segmentación de datos volumétricos. Sin embargo, su implementación presenta diversos desafíos que van más allá del alcance de este proyecto. No obstante, se sitúa como una línea de trabajo a futuro prometedora.

4.2 Segment Anything Model

SAM es un modelo de segmentación de imágenes, cuya característica principal es la capacidad para segmentar cualquier objeto en una imagen sin necesidad de entrenamiento previo [6]. Por lo tanto, lo podría convertir en una herramienta valiosa para segmentar las lesiones, debido a la gran diversidad y variabilidad de estas, lo que dificulta el entrenamiento de modelos específicos.

Existen tres variantes de SAM, basadas en la arquitectura del *vision transformer*(ViT) que posee su *image encoder*. Nosotros hemos empleado ViT-B porque es la variante base y es el más pequeño, mientras los otros, ViT-L y ViT-H, tienen más parámetros y requieren más costos computacionales [6].

Para utilizar SAM en la segmentación de lesiones en IPHSB realizaremos un proceso de inferencia en el conjunto de datos del MICCAI 2017 WMH Segmentation Challenge. Este proceso de inferencia consiste en segmentar las imágenes usando el modelo ya entrenado. Previamente, debemos preparar las imágenes y los *prompts*.

En primer lugar, debemos obtener las imágenes bidimensionales del conjunto de datos. Se ha optado por utilizar únicamente las secuencias FLAIR, ya que muestran mejor las lesiones. Una vez extraídas cada una de las rebanadas del cerebro, debemos

preprocesar las imágenes. El tamaño de las imágenes que espera SAM es 1024x1024 píxeles con 3 canales (RGB) y el tamaño de las máscaras debe ser de 256x256 píxeles. Para incrementar el tamaño de nuestras imágenes al que acepta SAM, se añade un relleno de píxeles negros para ajustarlas. Además, hemos realizado otros procesamientos a las imágenes como escalar las intensidades de los píxeles a un rango de 0 a 255. Posteriormente, hemos convertido las imágenes que se encontraban en escala de grises a un formato de 3 canales, replicando la imagen en cada canal y así convertirla en RGB.

Una vez preparadas las imágenes, debemos preparar los *prompts* para nuestro modelo. Los *prompts* que utilizaremos serán *bounding boxes* que enmarcarán la región donde se encuentran las lesiones. Aunque SAM acepta múltiples *bounding boxes*, nosotros hemos decidido utilizar una sola para comprobar la capacidad que tiene el modelo de detectar las lesiones en una área en específico. En la Figura 4.4 podemos observar un ejemplo de la *bounding box* que utilizará el modelo, como podemos ver se marca toda la región donde se encuentran las lesiones. Finalmente, se prepara el procesador




Figura 4.4: *Bounding box* que enmarca las lesiones de una imagen.

y el modelo preentrenado. El procesador tiene la función de preparar las imágenes y *prompts* para que sean compatibles con nuestro modelo. Una vez preparadas, el modelo comienza a segmentar las imágenes. En la Figura 4.5 podemos ver una de las segmentaciones obtenidas, en la que en lugar de segmentar las lesiones ha segmentado una parte del cerebro. Mientras que en las Figuras 4.6 y 4.7, ha segmentado el cerebro o gran parte de él, ignorando las lesiones.

Tras observar algunas segmentaciones obtenidas, podemos llegar a la conclusión de que SAM tiene dificultad para segmentar las lesiones. Esto puede deberse a que el modelo no ha sido entrenado con imágenes de resonancia magnética, lo cual afecta a la capacidad del modelo para identificar y segmentar correctamente las áreas de interés. Para mejorar la segmentación se podrían considerar varios trabajos a futuro: el empleo de múltiples *bounding boxes*, ya que actualmente solo se está utilizando una para delinear la región de interés y se podría proporcionar información adicional que mejorara la segmentación; se podría considerar también el entreno del modelo sobre el conjunto de datos y mejorar la capacidad del modelo de capturar las características



Figura 4.5: Segmentación obtenida por SAM. No ha conseguido segmentar lesiones.



Figura 4.6: Segmentación obtenida por SAM. Ha segmentado el cerebro.



Figura 4.7: Segmentación obtenida por SAM. Ha segmentado una parte del cerebro.

de las lesiones; o el uso de un modelo ya preentrenado sobre imágenes médicas como MedSAM, lo que podría obtener mejores segmentaciones de las imágenes.

4.3 MedSAM

MedSAM es una variante preentrenada del modelo SAM para la segmentación de imágenes médicas. Al contrario que SAM, MedSAM ha sido entrenada con un gran conjunto de datos de imágenes médicas. Es capaz de segmentar estructuras anatómicas, lesiones y otras características de diversos tipos de imágenes como RMs, radiografías o tomografías [25]. Tiene un gran potencial para detectar las características más relevantes de las lesiones y segmentarlas con precisión y eficiencia.

Al igual que con SAM, realizaremos un proceso de inferencia sobre el conjunto de datos del MICCAI 2017. Aprovecharemos la preparación de las imágenes y la creación de *bounding boxes* empleadas en SAM. Modificaremos el procesador por el de MedSAM y observaremos algunas de las segmentaciones obtenidas. En las Figuras 4.8 y 4.9 se pueden observar algunos resultados obtenidos.



Figura 4.8: Segmentación realizada con MedSAM. Ha segmentado el cerebro.



Figura 4.9: Segmentación realizada con MedSAM. Comienza a segmentar la lesión.

Gran parte de las segmentaciones obtenidas son partes del cerebro o apenas consigue distinguir algunas lesiones. Al igual que con SAM, esta falta de precisión puede deberse a que, aunque la red haya sido entrenada en un amplio conjunto de imágenes médicas, las características específicas de nuestro conjunto de datos no están adecuadamente representadas. Vamos a realizar un *fine-tuning* de la red para comprobar si mejora la segmentación. El proceso de *fine-tuning* nos permite ajustar los pesos del modelo preentrenado y adaptarlo mejor a las características de las imágenes y lesiones que queremos segmentar. Es decir, realizaremos un entrenamiento de la última capa del modelo, empleando las imágenes de nuestro conjunto de datos [43]. La función de pérdida que se utilizará será la pérdida de DICE y se realizará un entrenamiento de 15 épocas con una tasa de aprendizaje de 1×10^{-5} . A pesar de que SAM emplea una combinación de la pérdida de DICE y la pérdida focal, se ha decidido emplear únicamente la pérdida de DICE para simplificar el problema y ser consistente con el resto de entrenamientos previos realizados con U-NET, de esta forma podremos realizar una comparación directa de los resultados. La pérdida de DICE relaciona la superposición entre la segmentación predicha y la máscara anotada, lo que nos facilita su interpretación en este problema. Finalmente, empleamos el optimizador ADAM para ir acorde con el resto de entrenamientos.




Figura 4.10: Entrenamiento de MedSAM.

Como podemos observar en la Figura 4.10, se muestra la gráfica de preentrenamiento. De la gráfica se destaca que se han necesitado muy pocas épocas para que el modelo converja rápidamente a diferencia de los entrenamientos realizados con U-Net. El modelo se ha evaluado utilizando el coeficiente de DICE y se ha obtenido un 52.43 % sobre el conjunto de test. Considerando las pocas épocas con las que se ha entrenado el modelo y los pocos datos que tenemos, se está logrando una segmentación aceptable.

Una muestra de las segmentaciones obtenidas son las mostradas en la Figura 4.11. En ella podemos observar algunos ejemplos de las segmentaciones obtenidas sobre el conjunto de test de nuestros datos.

Una vez vistos estos resultados, se nos plantea la siguiente pregunta: ¿puede este modelo preentrenado con datos de lesiones de origen vascular del MICCAI 2017, detectar de forma efectiva las lesiones de patrón perivascular del ICPR 2024 MSLesSeg? Se tratan de imágenes completamente diferentes y de lesiones de tipología distinta. Para comprobar la efectividad, hemos calculado el coeficiente de DICE para el conjunto de




Figura 4.11: *Fine-tuning* de MedSam. No ha segmentado del todo la lesión, pero muestra resultados prometedores.

validación de las lesiones del concurso del ICPR 2024 y se ha obtenido un 41.67 %. A pesar de no haber sido entrenado con imágenes de ese tipo de lesiones, muestra una capacidad razonable para segmentarlas. Entonces, si se realizarán entrenamientos más exhaustivos quizás podría llegar a obtener un buen resultado.

Podemos observar algunas segmentaciones en la Figura 4.12. El modelo tiene capacidad de generalización y parece detectar las lesiones, a pesar de no segmentarlas del todo, y puede que en algunos casos, se equivoque considerablemente.




Figura 4.12: Patrón perivascular segmentado con MedSAM preentrenada.

Como podemos observar, el preentrenamiento del modelo sobre nuestros datos ha obtenido mejores resultados. Estos muestran que es capaz de detectar gran parte de las lesiones, en comparación con el modelo SAM o MedSAM sin el preentrenamiento. Por

lo tanto, se destaca su potencial como una herramienta más en la segmentación de las lesiones. Aunque, se deberían realizar entrenamientos más exhaustivos y la evaluación de los errores en la segmentación y sus causas.

4.3.1 Conclusiones

En el presente capítulo, se han descrito otras aproximaciones para la segmentación de IPHSB. Estos métodos alternativos presentan sus propios desafíos pero también abren nuevas posibilidades para mejorar la precisión y la eficiencia en la segmentación.

Se ha planteado el uso de 3D U-Net para la segmentación de datos volumétricos, pero su gran complejidad y limitación de los datos existentes muestran la necesidad de una implementación y investigación más exhaustiva. Por otro lado, la inferencia utilizando el modelo SAM y MedSAM no ha mostrado capacidad adecuada para segmentar las lesiones porque no han sido entrenados con imágenes con características similares a las secuencias del conjunto de datos. Finalmente, el *fine-tuning* con MedSAM ha obtenido resultados y segmentaciones razonables, situándose como una herramienta potencial para la segmentación de estas lesiones.

CONCLUSIONES

En el presente capítulo se recopilan y analizan las conclusiones obtenidas del desarrollo del proyecto, centrado en el estudio de múltiples modelos de IA para la creación de un segmentador de IPHSB. También, se comprobará el cumplimiento de todos los objetivos propuestos y posibles trabajos a futuro.

Para el cumplimiento de esta tarea, se analizaron múltiples modelos y técnicas de IA, en concreto se analizó el comportamiento del modelo U-Net para la creación de un segmentador de lesiones de origen vascular, del concurso MICCAI 2017 WMH Segmentation Challenge. Posteriormente, las conclusiones obtenidas se aplicaron para la creación de un segmentador para lesiones del tipo perivascular, del concurso ICPR 2024 MSLesSeg. Por lo tanto, se obtuvo así dos herramientas para segmentar este tipo de lesiones: un segmentador de lesiones de origen vascular y otro de lesiones de tipo perivascular. Además, se examinaron otras aproximaciones, como los modelos SAM o 3D U-Net y sus resultados.

5.1 Resultados

En la presente sección se detallan los resultados obtenidos durante la experimentación con U-Net y del análisis de otras aproximaciones.

5.1.1 Experimentos con U-NET

La creación del segmentador de lesiones del MICCAI 2017 WMH Segmentation Challenge aportó una serie de conclusiones. En primer lugar, el preprocesamiento de los datos tiene un gran impacto en el rendimiento de los modelos. La técnica de redimensionamiento, así como la normalización aplicada, permite mejorar la efectividad del modelo. Además, la eliminación de imágenes irrelevantes de nuestro conjunto de datos permiten que el modelo se enfoque en las características de las lesiones.

Por otra parte, la generación de imágenes sintéticas cuando se posee conjuntos de datos pequeños demuestran que aumentan el rendimiento. Junto con la optimi-

5. CONCLUSIONES

zación de los hiperparámetros del modelo, se permite aumentar la efectividad en la segmentación.

Una de las primeras ideas fue la implementación de segmentadores para cada tipo de secuencia y la concatenación de sus máscaras. Sin embargo, la concatenación de las secuencia FLAIR y T1, mejoró el rendimiento del modelo. En cambio, para la creación del segmentador de lesiones de patrón perivascular, la concatenación de las tres secuencias, FLAIR, T1 y T2 no aportó mejoras en el rendimiento.

También, cabe mencionar las características de las lesiones. Gran parte de ellas son lesiones pequeñas, de menos de 10 píxeles, y los modelos presentan dificultad para detectarlas.

Muchos de los procesamientos y experimentos realizados para el primer segmentador, no obtuvieron los mismos resultados para el segmentador de concurso ICPR 2024. Esto es debido a las diferencias significativas en ambos conjuntos de datos, tanto en las características de las imágenes, como en la cantidad de ellas. A pesar de ser ambas tareas de segmentación, se destaca la importancia de adaptar los enfoques de preprocesamiento y los experimentos a las características de cada tipo de imágenes.

5.1.2 Otras aproximaciones

Para la creación de los segmentadores se han explorado diferentes enfoques. Nuestro datos al ser en 3D, se ha realizado una aproximación con 3D U-Net y se obtuvieron una serie de conclusiones. En general, el modelo tiene potencial para la segmentación de datos volumétricos, pero es importante tener en cuenta la gran complejidad de este con un número de parámetros mayor que U-Net. Esta gran cantidad y junto con la limitación de datos volumétricos, aumenta el riesgo de sobreajuste. El conjunto de datos pequeño ha sido un factor determinante en el rendimiento y por ello se sugiere la investigación de métodos para generar nuevas imágenes sintéticas en 3D.

Además, podríamos plantear el uso de un modelo 3D U-Net ya preentrenado en un conjunto más grande de imágenes médicas y realizar un preentrenamiento, similar al proceso realizado con MedSAM.

El preentrenamiento de MedSAM sobre el conjunto de datos del MICCAI 2017 WMH Segmentation Challenge se ha convertido en una herramienta muy eficaz para la segmentación de las lesiones, superando el rendimiento de los modelos SAM y MedSAM sin preentrenamiento. Aunque SAM ha sido entrenado con un conjunto de datos grande y variado, no está especializado en imágenes médicas como MedSAM, lo que ha dificultado la detección de las lesiones. Por otra parte, el modelo preentrenado también ha demostrado ser eficaz en la segmentación de lesiones de patrón perivascular del ICPR 2024, es decir, lesiones de otra tipología, a pesar de no haber sido entrenado con esas imágenes, lo que sitúa a este modelo como una técnica muy prometedora para la segmentación de estas lesiones.

5.2 Cumplimiento de objetivos

Uno de los principales objetivos de este proyecto era la creación de modelos automatizados que pudieran segmentar IPHSB. Este objetivo se ha cumplido mediante la obtención de dos segmentadores.

Además, otro de los objetivos trataba sobre el estudio y comparación de diversas técnicas de IA, por lo que se implementaron y compararon diversas técnicas de segmentación, realizándose un análisis del funcionamiento del modelo de aprendizaje profundo U-Net, y el uso de modelos como SAM y 3D U-NET. Todos los modelos fueron evaluados mediante métricas como el coeficiente de DICE, IOU, *precision* y el *recall*, de esta forma se seleccionaron aquellos modelos que mostraron buenos resultados.

Gracias a la modificación de diversos hiperpárametros y la aplicación de diversos procesamientos que mejoraron la precisión en la segmentación, se obtuvieron así modelos eficientes.

Finalmente, se espera que mediante la obtención de estas dos herramientas se consiga mejorar la caracterización de este tipo de lesiones y permitir su detección temprana, correspondiente diagnóstico y tratamiento temprano. Mediante el trabajo realizado en este proyecto, se pretende aportar unas herramientas dentro del campo de la neuroimagen médica y que además supongan la base para investigaciones futuras. Para contribuir a otros trabajos, el proyecto desarrollado se encuentra en el siguiente GitHub: <https://github.com/AinaT9/White-Matter-Hyperintensity-Segmentation>.

5.3 A futuro

Además de continuar explorando otros modelos o analizar de forma más exhaustiva los detallados en este proyecto, uno de los principales trabajos a futuro sería la implementación de modelos de IA capaces de clasificar cada una de las lesiones segmentadas en los diferentes patrones existentes. Para su desarrollo se podría contemplar la integración de datos clínicos, como la edad del paciente, sexo y otros biomarcadores importantes. Sin embargo, su implementación depende del acceso a una gran cantidad de datos correctamente clasificados y etiquetados.

La limitación de datos ha sido una de las principales problemáticas del proyecto. En la actualidad, los modelos generativos adversariales (GANs) están en auge. Estos modelos de aprendizaje profundo tienen como objetivo la generación de imágenes nuevas basándose en un conjunto de datos reales. De esta forma, se podría considerar su posible aplicación para generar imágenes sintéticas que simulan diferentes tipos y variaciones de lesiones IPHSB.

Finalmente, destacar la implementación de algoritmos o técnicas capaces de realizar análisis volumétricos a las lesiones detectadas o la determinación en centímetros del área de estas, ya que estos datos supondrían información adicional para los neurorradiólogos en la determinación de un diagnóstico o seguimiento de enfermedades.

VALIDACIÓN MICCAI 2017 WMH SEGMENTATION CHALLENGE

El siguiente anexo tiene como objetivo mostrar los resultados sobre el conjunto de validación de los entrenamientos realizados sobre el conjunto de datos MICCAI 2017 WMH Segmentation Challenge. Para cada uno de los experimentos se indica el mejor resultado.

Cuadro A.1: Primera aproximación. DC es el coeficiente de DICE, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	DC	IOU	Pre.	Rec.	Acc.
FLAIR	47.06 %	34.46 %	55.87 %	47 %	99.84 %
T1	26.47 %	18.82 %	28.66 %	28.40 %	99.78 %
Unión	31.60 %	22.55 %	34.60 %	38.04 %	99.81 %

Cuadro A.2: Experimentos realizados sin el 20% de las rebanadas. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	DC	IOU	Pre.	Rec.	Acc.
FLAIR	58.15 %	44.07 %	70.49 %	57.06 %	99.80 %
T1	42.80 %	30 %	52.62 %	39.15 %	99.77 %
Unión	47.55 %	34.90 %	47.53 %	55.17 %	99.78 %

Cuadro A.3: Experimentos realizados con diferentes tamaños de redimensionamiento. DC es el coeficiente de DICE, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	Tam img.	DC	IOU	Pre.	Rec
FLAIR	128	58.15 %	44.07 %	70.49 %	57.06 %
FLAIR	256	27.75 %	21.31 %	26.84 %	40 %
FLAIR	384	22.24 %	16.94 %	25.63 %	28 %
FLAIR	200 <i>padding</i>	28.80 %	21.49 %	34.24 %	32.06 %
FLAIR	200 recorte	28.9 %	21.52 %	43 %	30 %
T1	128	42.80 %	30 %	52.62 %	39.15 %
T1	256	22.23 %	14.96 %	30.18 %	18.56 %
T1	384	15.19 %	10.15 %	21.5 %	13.66 %
T1	200 <i>padding</i>	20.91 %	14.34 %	23.53 %	21.57 %
T1	200 recorte	20.24 %	13.96 %	27.13 %	19.45 %
Unión	128	47.55 %	34.90 %	47.53 %	55.17 %
Unión	256	24.60 %	18.47 %	21.80 %	38.80 %
Unión	384	20.10 %	14.88 %	19.86 %	25.51 %
Unión	200 <i>padding</i>	24.60 %	18.15 %	21 %	35 %
Unión	200 recorte	26.30 %	19 %	28.74 %	30.26 %

Cuadro A.4: Experimentos realizados con recorte/*padding*. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	Tam img.	DC	IOU	Pre.	Rec.
FLAIR	200	34.9 %	25.3 %	57.87 %	34.18 %
FLAIR	240	61.54 %	48.62 %	74.50 %	54.80 %
FLAIR	256	64.20 %	51.02 %	72.69 %	60.50 %
FLAIR	384	43.22 %	33.35 %	50.27 %	43.28 %
T1	200	22.89 %	15.93 %	30.18 %	19.94 %
T1	240	25.70 %	18.41 %	32.36 %	22.51 %
T1	256	26.23 %	18.53 %	34.25 %	22.70 %
T1	384	19.50 %	13.97 %	25.86 %	17.18 %
Unión	200	34.67 %	25.02 %	50.36 %	37.60 %
Unión	240	51.45 %	39.57 %	58.19 %	50.30 %
Unión	256	54.20 %	42.50 %	57.38 %	55.68 %
Unión	384	40.22 %	30.45 %	44.46 %	45.42 %

Cuadro A.5: Experimentos realizados con normalización gaussiana/*padding*. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	Normalización	DC	IOU	Pre.	Rec.
FLAIR	Toda imagen	64 %	52.52 %	73.16 %	58.57 %
FLAIR	Tejido cerebral	62 %	49.5 %	78.46 %	52.5 %
FLAIR	Todo cerebro	59.6 %	47 %	78.53 %	50.79 %
T1	Toda imagen	34.56 %	23.66 %	53.88 %	27.88 %
T1	Tejido cerebral	38.42 %	27.10 %	51.40 %	33.53 %
T1	Todo cerebro	36 %	26.65 %	50 %	37.86 %
Unión	Toda imagen	53.76 %	43.96 %	54.54 %	56.05 %
Unión	Tejido cerebral	52.52 %	41.75 %	54.28 %	53.97 %
Unión	Todo cerebro	48.54 %	37.55 %	49.45 %	53.42 %

Cuadro A.6: Experimentos realizados con normalización MinMax/*padding*. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Tipo	Normalización	DC	IOU	Pre.	Rec.
FLAIR	Toda imagen	56.22 %	45.53 %	62.55 %	53.83 %
FLAIR	Tejido cerebral	55.14 %	44.65 %	65 %	50.38 %
FLAIR	Todo cerebro	55 %	44.55 %	61.89 %	51.76 %
T1	Toda imagen	31 %	22 %	46 %	25.89 %
T1	Tejido cerebral	29.22 %	20.44 %	47.50 %	23.38 %
T1	Todo cerebro	30 %	21.37 %	47 %	25 %
Unión	Toda imagen	42.64 %	33.90 %	43.33 %	46.02 %
Unión	Tejido cerebral	42.44 %	33.87 %	45.96 %	43.82 %
Unión	Todo cerebro	42.25 %	33.49 %	42.44 %	45 %

Cuadro A.7: Experimentos realizados con la concatenación de secuencias. DC es el Dice coefficient, pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

ID	Características	Tasa apren.	Épocas	DC	IOU	Pre.	Rec.
1	32	1×10^{-4}	100	55.7 %	43.30 %	68.2 %	58 %
2	32	5×10^{-5}	100	43.31 %	40.23 %	58 %	47.33 %
3	32	5×10^{-5}	150	51.60 %	42.03 %	64.68 %	46.39 %
4	32	1×10^{-4}	100	84 %	74 %	85.32 %	83.45 %
5	48	1×10^{-4}	30	85.40 %	74.84 %	86.30 %	84.94 %

Cuadro A.8: Experimentos realizados con el incremento de datos. pre. significa *precision*, rec. significa *recall* y acc. *accuracy*.

Imágenes gen.	Features	Épocas	Tasa aprendizaje	DC	IOU	Pre.	Rec.
1000	48	50	1×10^{-4}	78.6 %	67.89 %	81.15 %	78.50 %
2000	58	50	5×10^{-5}	76.43 %	66.43 %	80.49 %	74.56 %
3000	58	60	5×10^{-5}	76.49 %	65.22 %	77.08 %	78.06 %
4000	62	60	1×10^{-4}	79.50 %	69.10 %	78.24 %	82.71 %
5000	62	60	1×10^{-4}	78.13 %	67.14 %	80.13 %	78.47 %

ENTRENAMIENTO ICPR 2024 MSLesSEG

El siguiente anexo muestra algunos resultados de los entrenamientos realizados para la creación del segmentador del ICPR 2024 MSLesSeg.




Figura B.1: Entrenamiento secuencias T1 con relleno de 200x200 píxeles.




Figura B.2: Entrenamiento secuencias T2 con relleno de 200x200 píxeles. Muestra un entrenamiento similar al de la secuencia T1.

B. ENTRENAMIENTO ICPR 2024 MSLESSEG




Figura B.3: Entrenamiento secuencias FLAIR con la aplicación de normalización gaussiana.




Figura B.4: Entrenamiento con concatenación de las secuencias FLAIR, T1 y T2. La curva de pérdida del entrenamiento descende de forma constante, mientras que la validación no.




Figura B.5: Entrenamiento secuencias FLAIR con aumento de datos de 4000 imágenes.

BIBLIOGRAFÍA

- [1] S. Medrano Martorell, M. Cuadrado Blázquez, D. García Figueredo, and J. González Ortiz, S. y Capellades Font, “Imágenes puntiformes hiperintensas en la sustancia blanca: una aproximación diagnóstica,” *Radiología*, vol. 54, no. 4, pp. 321–335, 2012. (document), 1.1, 1.1
- [2] S. Claret Loaiza and V. Cáceres Filippom, “Principios básicos de rm: Lo que todo radiólogo debe conocer para su práctica diaria,” *Seram*, 2018, Última visita: [1 de junio de 2024]. [Online]. Available: <https://www.piper.espacio-seram.com/index.php/seram/article/view/2659> (document), 1.1.1, 1, 1.2, 2
- [3] S. Tammina, “Transfer learning using vgg-16 with deep convolutional neural network for classifying images,” 2019, Última visita: [21 de mayo de 2024]. [Online]. Available: <http://dx.doi.org/10.29322/IJSRP.10.2019.p9420> (document), 2.1
- [4] O. Ronneberger, P. Fischer, and T. BroX, “U-net: Convolutional networks for biomedical image segmentation,” 2015, Última visita: [21 de mayo de 2024]. [Online]. Available: <https://arxiv.org/pdf/1505.04597> (document), 2.1, 2.2
- [5] Özgün Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, and O. Ronneberger, “3d u-net: Learning dense volumetric segmentation from sparse annotation,” 2016, Última visita: [14 de junio de 2024]. [Online]. Available: <https://arxiv.org/pdf/1505.04597> (document), 2.1, 2.1, 2.3
- [6] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, P. Dollár, and R. Girshick, “Segment anything,” 2023, Última visita: [21 de mayo de 2024]. [Online]. Available: <https://arxiv.org/pdf/2304.02643> (document), 2.1, 2.1, 2.1, 2.4, 4.2
- [7] “Mni normalization,” Última visita: [2 de Junio de 2024]. [Online]. Available: <https://www.brainvoyager.com/bv/doc/UsersGuide/BrainNormalization/MNINormalization.html> (document), 2.2.3, 2.6
- [8] “Understanding evaluation metrics in medical image segmentation,” Última visita: [7 de junio de 2024]. [Online]. Available: https://medium.com/@nghihuyinh_37300/understanding-evaluation-metrics-in-medical-image-segmentation-d289a373a3f (document), 2.8, 2.4, 2.9, 2.4, 2.4, 2.4
- [9] A. Calzado and J. Geleijns, “Tomografía computarizada. evolución, principios técnicos y aplicaciones,” *Revista de Física Médica*, vol. 11, no. 3, 2010, Última visita: [28 de abril de 2024]. 1

- [10] U.N.I.R, “Técnicas de neuroimagen: la clave para conocer el cerebro,” 2022, Última visita: [28 de abril de 2024]. [Online]. Available: <https://www.unir.net/salud/revista/tecnicas-neuroimagen/> 1.1.1
- [11] D. Rivera, S. Puentes, and L. Caballero, “Resonancia magnética cerebral: secuencias básicas e interpretación,” *Universitas Medica*, vol. 52, no. 3, p. 292–306, 2011. 1.1.1, 1a, 1b, 2
- [12] Children’s Minnesota, “Resonancia magnética: Cerebro,” Última visita: [28 de abril de 2024]. [Online]. Available: <https://www.childrensmn.org/educationmaterials/parents/article/12225/resonancia-magnetica-cerebro/> 1.1.1
- [13] HOSPITAL NACIONAL DE PARAPLÉJICOS, “El contraste en imagen de resonancia magnética,” 2021, Última visita: [27 de abril de 2024]. [Online]. Available: <https://saishnp.com/2021/04/20/el-contraste-en-imagen-de-resonancia-magnetica/> 1b
- [14] “¿ai versus machine learning versus deep learning versus neural networks: What’s the difference?” Última visita: [14 de junio de 2024]. [Online]. Available: <https://www.ibm.com/think/topics/ai-vs-machine-learning-vs-deep-learning-vs-neural-networks> 2.1
- [15] “¿qué es el deep learning?” Última visita: [14 de mayo de 2024]. [Online]. Available: <https://www.ibm.com/es-es/topics/deep-learning> 2.1
- [16] “¿qué son las redes convolucionales?” Última visita: [14 de mayo de 2024]. [Online]. Available: <https://www.ibm.com/es-es/topics/convolutional-neural-networks> 2.1
- [17] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” *Advances in Neural Information Processing Systems*, vol. 25, 2012, Última visita: [13 de junio de 2024]. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf 2.1
- [18] K. He, G. Gkioxari, P. Dollár, and R. Girshick, “Mask r-cnn,” 2018, Última visita: [21 de mayo de 2024]. [Online]. Available: <https://arxiv.org/pdf/1703.06870> 2.1
- [19] R. Girshick, “Fast r-cnn,” 2015, Última visita: [21 de mayo de 2024]. [Online]. Available: <https://arxiv.org/pdf/1504.08083> 2.1
- [20] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” 2016, Última visita: [21 de mayo de 2024]. [Online]. Available: <https://arxiv.org/pdf/1506.02640> 2.1
- [21] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, “Masked autoencoders are scalable vision learners,” 2021, Última visita: [2 de Junio de 2024]. [Online]. Available: <https://arxiv.org/pdf/2111.06377> 2.1
- [22] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning transferable visual models from natural language supervision,” 2021, Última visita: [2 de Junio de 2024]. [Online]. Available: <https://arxiv.org/pdf/2103.00020> 2.1

-
- [23] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” 2018, Última visita: [3 de Junio de 2024]. [Online]. Available: <https://arxiv.org/pdf/1708.02002> 2.1
- [24] C. H. Sudre, W. Li, T. Vercauteren, S. Ourselin, and M. Jorge Cardoso, “Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations,” pp. 240–248, 2017, Última visita: [3 de Junio de 2024]. [Online]. Available: <https://arxiv.org/pdf/1707.03237> 2.1
- [25] J. Ma, Y. He, F. Li, L. Han, C. You, and B. Wang, “Segment anything in medical images,” *Nature Communications*, vol. 15, no. 1, 2024, Última visita: [21 de mayo de 2024]. [Online]. Available: <https://arxiv.org/pdf/2304.12306> 2.1, 4.3
- [26] H. Kuijf, M. Biesbroek, J. de Bresser, R. Heinen, C. Chen, W. van der Flier, Barkhof, M. Viergever, and G. J. Biessels, “Data of the white matter hyperintensity (wmh) segmentation challenge,” 2022, Última visita: [11 de mayo de 2024]. [Online]. Available: <https://doi.org/10.34894/AECRSD> 2.2.1
- [27] The MICCAI Society, “About miccai,” Última visita: [11 de mayo de 2024]. [Online]. Available: <https://miccai.org/index.php/about-miccai/> 2.2.1
- [28] “About us,” Última visita: [21 de mayo de 2024]. [Online]. Available: <https://iapr.org/about-us/> 2.2.1
- [29] “Spm12: Statistical parametrical mapping,” Última visita: [13 de mayo de 2024]. [Online]. Available: <https://www.fil.ion.ucl.ac.uk/spm/software/spm12/> 2.2.3
- [30] P. Mandal, R. Mahajan, and I. Dinov, “Structural brain atlases: Design, rationale, and applications in normal and pathological cohorts,” *Universitas Medica*, vol. 31, no. 3, pp. 169–188, 2012. 2.2.3
- [31] “About opencv,” Última visita: [14 de mayo de 2024]. [Online]. Available: <https://opencv.org/about/> 2.3.2
- [32] “Nibabel,” Última visita: [14 de mayo de 2024]. [Online]. Available: <https://nipy.org/nibabel/index.html> 2.3.2
- [33] “Image processing in python,” Última visita: [21 de mayo de 2024]. [Online]. Available: <https://scikit-image.org/> 2.3.2
- [34] “¿qué es pytorch?” Última visita: [21 de mayo de 2024]. [Online]. Available: <https://www.ibm.com/es-es/topics/pytorch> 2.3.2
- [35] “Numpy,” Última visita: [21 de mayo de 2024]. [Online]. Available: <https://numpy.org/> 2.3.2
- [36] “Matplotlib:visualization with python,” Última visita: [21 de mayo de 2024]. [Online]. Available: <https://matplotlib.org/> 2.3.2
- [37] R. R. Shamir, Y. Duchin, J. Kim, G. Sapiro, and N. Harel, “Continuous dice coefficient: a method for evaluating probabilistic segmentations,” 2019, Última visita: [7 de junio de 2024]. [Online]. Available: <https://arxiv.org/pdf/1906.11031> 2.4

- [38] “Intersection over union (iou) in object detection segmentation,” Última visita: [7 de junio de 2024]. [Online]. Available: <https://learnopencv.com/intersection-over-union-iou-in-object-detection-and-segmentation/> 2.4
- [39] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” 2017, Última visita: [30 de junio de 2024]. [Online]. Available: <https://arxiv.org/abs/1412.6980> 3.1
- [40] “Preprocessing data,” Última visita: [18 de junio de 2024]. [Online]. Available: <https://scikit-learn.org/stable/modules/preprocessing.html> 3.2.3, 3.2.3, 3.2.3
- [41] N. Otsu, “A threshold selection method from gray-level histograms,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, 1979. 3.2.3
- [42] “Crossentropyloss,” Última visita: [23 de junio de 2024]. [Online]. Available: <https://pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html#crossentropyloss> 4.1
- [43] “Transfer learning fine-tuning,” Última visita: [27 de junio de 2024]. [Online]. Available: https://keras.io/guides/transfer_learning/ 4.1, 4.3