



Universitat
de les Illes Balears

TRABAJO DE FIN DE GRADO

EVALUACIÓN DE MODELOS FUNDACIONALES PARA DERMATOLOGÍA CLÍNICA

Antonio Contestí Coll

Grau d'Enginyeria Informàtica

Escola Politècnica Superior

Año académico 2025–2026

EVALUACIÓN DE MODELOS FUNDACIONALES PARA DERMATOLOGÍA CLÍNICA

Antonio Contestí Coll

Trabajo de Fin de Grado

Escola Politècnica Superior

Universitat de les Illes Balears

Año académico 2025–2026

Paraules clau del treball: modelos fundacionales, dermatología clínica, PanDerm, DermLIP, evaluación empírica

Tutor: Dr. Javier Varona Gómez

A la Dra. Rosa Taberner, por su excepcional trabajo en Dermapixel y por su dilatada trayectoria en teledermatología, siendo un referente en el ámbito. Por la generosidad con la que me ha transmitido su conocimiento y por el tiempo que me ha dedicado de forma totalmente desinteresada a lo largo de este proyecto.

A mi tutor, el Dr. Javier Varona, por transmitirme el conocimiento con tanta claridad y pasión, por contagiarme esa ilusión por aprender, por su apoyo constante, por saber guiarme y centrarme en cada momento, y, sobre todo, por ser mucho más que un tutor: un gran amigo.

A todos los profesores de la Universitat de les Illes Balears que he tenido durante estos años, por su profesionalidad, dedicación y por el trato cercano y respetuoso que siempre me han brindado.

A mis compañeros de clase (Marc, Jordi, Dylan, Andres, Josep, Xisco, Carlos, Jesus, David), por hacerme sentir uno más desde el primer día. Me llevo no solo grandes profesionales con ambición y talento, sino también excelentes personas y amigos.

A Marc y a Jordi, compañeros de clase y también de prácticas, por haberse convertido en grandes amigos que sé que durarán toda la vida. Por todo lo que nos hemos ayudado mutuamente sin esperar nada a cambio, por el apoyo constante en los momentos difíciles y, en especial, por haber estado ahí en uno de los momentos más complicados del camino.

A David, por ser un ejemplo de superación. Por su esfuerzo constante, por su capacidad de lucha día tras día y por su actitud siempre positiva ante las dificultades.

A mis padres, por darme todo y por permitirme hoy devolverles, con este logro, una pequeña parte de lo que me han dado. Esta meta también es vuestra.

A mi hermano, y a mis sobrinos Albert y Marta, con la ilusión de poder transmitirles que, con humildad, esfuerzo y constancia, cualquier objetivo es alcanzable.

A Bruno, Marta y Jaume, los hijos de mi mujer y también mis hijos, por el apoyo, la comprensión y el cariño que me han demostrado en casa durante todo este tiempo.

A mi mujer, por su apoyo incondicional, por su paciencia infinita y por todo lo que ha sacrificado durante estos años, renunciando a muchos momentos juntos para que yo pudiera seguir adelante. Este trabajo es tanto suyo como mío.

Y, finalmente, a todos los pacientes, que son la verdadera razón de este camino.

ÍNDICE GENERAL

Índice general	iii
Lista de acrónimos	x
Resumen	xi
Abstract	xiii
1 Introducción	1
1.1 Contexto clínico	1
1.2 Marco operativo previo	2
1.3 Pregunta de investigación	2
1.4 Objetivos del trabajo	2
1.5 Restricciones del estudio	3
1.6 Estructura del documento	3
2 Estado del arte	5
2.1 Aprendizaje profundo aplicado a dermatología	5
2.2 Modelos fundacionales: arquitectura y objetivos	5
2.3 Encoders visuales auto-supervisados	6
2.4 Modelos vision-lenguaje contrastivos	6
2.5 Modelos integrados con zero-shot nativo	7
2.6 Segmentación promptable	7
2.7 Modelos de lenguaje multimodales generalistas	7
2.8 Problemas metodológicos y guías de reporte	8
2.9 Brechas operativas y posicionamiento	8
3 Materiales y métodos	9
3.1 Datasets	9
3.2 Ontología jerárquica L1/L2/L3	10
3.3 Dataset DermapixelAI 1.0	10
3.4 Modelos evaluados	10
3.5 Infraestructura experimental	11
3.6 Protocolos experimentales	12
3.6.1 Sondeo lineal (LP)	12
3.6.2 Ajuste fino supervisado (FT)	12
3.6.3 Eficiencia en etiquetas	12

3.6.4	Segmentación binaria de lesión	12
3.6.5	Clasificación zero-shot multimodal	13
3.6.6	Comparación con modelos de lenguaje multimodales	13
3.6.7	Evaluación de equidad por fototipo	13
3.6.8	Auditoría de solapamiento con Derm1M	14
3.7	Métricas	14
3.8	Pruebas estadísticas	15
3.9	Trazabilidad y reproducibilidad	15
4	Resultados	17
4.1	Reproducción de PanDerm: sondeo lineal sobre diez datasets	17
4.2	Benchmark comparativo entre familias	19
4.3	Ajuste fino supervisado	20
4.4	Eficiencia en etiquetas	21
4.5	Segmentación binaria de lesión	22
4.6	Clasificación zero-shot multimodal	23
4.7	Comparación con modelos de lenguaje multimodales	25
4.8	Equidad por fototipo cutáneo	27
4.9	Auditoría de solapamiento con Derm1M	29
4.10	Ensemble de seguridad para detección de melanoma	29
4.11	Validación en castellano sobre DermapixelAI 1.0	30
4.12	Validación <i>zero-shot</i> multimodal sobre DermapixelAI 1.0	39
4.13	Cobertura experimental sobre DermapixelAI 1.0	41
4.14	Ajuste fino con LoRA: SpanDerm v0	42
4.15	Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos	45
4.16	Codificadores adicionales y arquitecturas de inferencia alternativas	50
4.17	SpanDerm-CLIP: zero-shot multimodal castellano sobre DermapixelAI 1.0	53
5	Discusión	65
5.1	Significado de los resultados	65
5.1.1	Especialización del dominio frente a encoders generalistas	65
5.1.2	Eficiencia en etiquetas y régimen de saturación	67
5.1.3	Sondeo lineal frente a ajuste fino	67
5.1.4	Segmentación promptable y adaptación de bajo coste	68
5.1.5	Sensibilidad al tokenizador en zero-shot multimodal	68
5.1.6	Brecha entre modelos específicos y LLMs multimodales	69
5.1.7	Equidad por fototipo cutáneo	70
5.1.8	Estimación robusta del rendimiento sobre corpus de tamaño moderado	70
5.2	Comparación con la literatura	71
5.2.1	Reproducción del benchmark de PanDerm	71
5.2.2	Segmentación binaria de lesión	71
5.2.3	Comportamiento zero-shot	71
5.2.4	Disparidad por fototipo	72
5.3	Implicaciones operativas	72
5.3.1	Arquitectura defendible para sistemas de apoyo al diagnóstico	72

5.3.2	Armonización taxonómica y nivel de agregación	72
5.3.3	Ventana operativa por fototipo cutáneo	73
5.3.4	Ensemble de seguridad para detección de melanoma	73
5.4	Hallazgos no anticipados	73
5.5	Limitaciones interpretativas	74
6	Limitaciones	77
6.1	Limitaciones de disponibilidad	77
6.1.1	Modelos sin pesos públicos	77
6.1.2	Conjuntos de preentrenamiento no liberados	78
6.2	Limitaciones de los datos	78
6.2.1	Sesgo geográfico y lingüístico	78
6.2.2	Heterogeneidad taxonómica entre datasets	78
6.2.3	Solapamiento con el dataset de preentrenamiento Derm1M	79
6.2.4	Tamaños muestrales por subgrupo en el experimento de equidad	79
6.3	Limitaciones del diseño experimental	80
6.3.1	Variabilidad inter-semilla	80
6.3.2	Pruebas estadísticas y comparaciones múltiples	80
6.3.3	Sensibilidad al <i>prompt</i> en zero-shot y LLMs	80
6.4	Limitaciones del corpus DermapixelAI 1.0	81
6.5	Limitaciones de generalización clínica	82
6.5.1	Material de archivo frente a flujo asistencial real	82
6.5.2	Ausencia de validación prospectiva	82
6.5.3	Elementos no abordados por decisión de alcance	82
6.6	Síntesis: dominio de validez de los resultados	82
7	Conclusiones	85
7.1	Respuesta a la pregunta de investigación	85
7.2	Contribuciones reproducibles	86
7.2.1	Contribuciones en el cuerpo del documento	86
7.2.2	Contribuciones complementarias	87
7.3	Hallazgos metodológicos transferibles	88
7.4	Aportaciones a la práctica clínica	88
7.5	Líneas de investigación abiertas	89
7.5.1	Cobertura experimental sobre DermapixelAI 1.0: técnicas ejecutadas y pendientes	89
7.5.2	SpanDerm: modelo dermatológico clínico en español	91
7.5.3	Derm7pt + Sparse Autoencoders: ground-truth conceptual para interpretabilidad	92
7.5.4	Aprendizaje activo <i>in-domain</i> sobre clases L3 con peor cobertura	93
7.5.5	Escalado del dataset con el banco hospitalario HUSLL	94
7.5.6	Validación clínica prospectiva	94
7.5.7	Auditoría sistemática de leakage extensible	94
7.5.8	Recuperación visual densa como sistema de apoyo	95
7.5.9	IA agéntica para razonamiento clínico estructurado	95
7.5.10	Reentrenamiento multilingüe de la rama lingüística	95
7.6	Cierre	96

Bibliografía	97
A Mapa de tareas experimentales y estructura del repositorio	101
A.1 Estructura del repositorio	101
A.2 Mapa de tareas experimentales	101
A.3 Comandos de ejecución	102
A.4 Versiones de software y semillas	103
A.5 Checkpoints publicados	103
B Tablas detalladas de resultados	105
B.1 Desglose por clase sobre HAM10000	105
B.2 Desglose por clase del ajuste fino MedGemma 27B sobre HAM10000 . .	106
B.3 Equidad sobre Fitzpatrick17k: formulación de 114 patologías	106
B.4 Evaluación cruzada Light/Dark sobre 114 patologías	107
B.5 Resumen comparativo por paradigma sobre HAM10000	107
B.6 Composición del conjunto de entrenamiento del SAE Large	110
C Pipeline de construcción y caracterización del dataset DermapixelAI 1.0	113
C.1 Origen y materia prima	113
C.2 Pipeline de construcción	113
C.3 Cardinalidades del corpus y splits experimentales	115
C.4 Distribución por modalidad	115
C.5 Distribución por categoría etiológica L1	115
C.6 Distribución por subcategoría L2 y por diagnóstico L3	116
C.7 Cola larga diagnóstica	118
C.8 Particionado en train, validación y test	119
C.9 Texto narrativo asociado al caso	121
C.10 Validación experta y campos de calidad	121
C.11 Caracterización temporal y de exclusiones	122
C.11.1 Distribución temporal	122
C.11.2 Razones de exclusión	123
D Declaración sobre el uso de herramientas de inteligencia artificial	125
D.1 Alcance de la declaración	125
D.2 Herramientas empleadas	125
D.3 Uso académico: redacción del documento	126
D.4 Uso técnico: desarrollo del código	126
D.5 Uso documental: organización y trazabilidad	126
D.6 Modelos como objeto de evaluación	126
D.7 Verificación cruzada de cifras y citas	127
D.8 Responsabilidad sobre el contenido	127
E Documento de entrega del dataset DermapixelAI 1.0	129
E.1 Identidad del dataset	129
E.2 Procedencia y autoría	129
E.3 Licencia de uso	130
E.4 Cita recomendada	130

E.5	Disponibilidad y distribución	131
E.6	Datasheet for Datasets	132
E.7	Uso responsable y limitaciones clínicas	134
E.8	Privacidad y consentimiento	134
E.9	Mantenimiento y contacto	134
F	Sparse Autoencoders y diccionario de conceptos clínicos	137
F.1	Motivación	137
F.2	Arquitectura del SAE	137
F.3	Comportamiento del SAE Large frente a SAE Base	138
F.4	Concept Bottleneck Model sobre SkinCon	139
F.4.1	Conceptos con mejor predictor	139
F.4.2	Rendimiento agregado del CBM	140
F.5	Propuesta de extensión: quince conceptos clínicos adicionales	141
F.6	Limitaciones del módulo SAE	142
G	Modelos de lenguaje multimodales: comparación extendida	143
G.1	Modelos evaluados	143
G.2	Prompt clínico estandarizado	144
G.3	Comparativa completa sobre HAM10000, PAD-UFES-20 y DDI	144
G.4	Latencias, refusal rates y costes operativos	145
G.5	Patrones de error sobre HAM10000	145
G.6	MedGemma 27B con LoRA: análisis por dataset	146
G.7	Sensibilidad al prompt en DermLIP v2	146
G.8	Síntesis	147
H	Prototipo DermApIxel	149
H.1	Motivación arquitectónica	149
H.2	Arquitectura	150
H.2.1	Topología cliente-servidor	150
H.2.2	Componentes del backend	150
H.2.3	Persistencia: esquema de base de datos	150
H.2.4	Bus de mensajería AMQP	150
H.3	Módulos de inteligencia artificial	151
H.3.1	M1 – Clasificador cerrado	151
H.3.2	M2 – Segmentación binaria	151
H.3.3	M3 – Conceptos clínicos	151
H.3.4	M4 – Recuperación visual densa	152
H.3.5	M5 – Razonamiento clínico estructurado	152
H.3.6	M6 – Clasificación zero-shot abierta	153
H.4	Frontend e interfaz clínica	153
H.5	Rendimiento operativo	154
H.6	Estado de despliegue	154
H.7	Discusión: rol del prototipo en el trabajo	155
H.8	Evolución a M1–M11: módulos castellanos del prototipo	155
H.8.1	M7 – Clasificador unificado jerárquico <i>merged43</i> +TTA	155
H.8.2	M9 – SpanDerm v0, clasificador L2 castellano supervisado	156

H.8.3	M10 – <i>Seven-Point Checklist</i> multitarea	156
H.8.4	M4-bis – RAG castellano sobre DermapixelAI 1.0	156
H.8.5	M11 – Ensemble ponderado por AUROC y coherencia jerárquica	157
H.8.6	Sistema de consenso de cinco módulos y <i>warning</i> de derivación urgente	157
H.8.7	Migración a AMQP (2026-04-13)	158
H.8.8	Evaluación end-to-end del prototipo extendido	158
I	Ablación: modelo fundacional inglés (DermLIP) con traducción ES-EN	159
I.1	Motivación	159
I.2	Protocolo experimental	159
I.3	Resultados	160
I.4	Interpretación	160
I.5	Limitaciones de la ablación	161

LISTA DE ACRÓNIMOS

AdamW	Adaptive Moment Estimation with decoupled Weight decay
AJCC	American Joint Committee on Cancer
API	Application Programming Interface
AUROC	Area Under the Receiver Operating Characteristic Curve
B _{Acc}	Balanced Accuracy
BCC	Carcinoma basocelular (<i>basal cell carcinoma</i>)
BCN	Barcelona
BF16	Brain Floating-Point de 16 bits
CAE	Convolutional AutoEncoder
CBM	Concept Bottleneck Model
CIE-10	Clasificación Internacional de Enfermedades, décima revisión
CLIP	Contrastive Language–Image Pre-training
DDI	Diverse Dermatology Images
DIADERM	Estudio observacional multicéntrico sobre demanda y prevalencia diagnóstica en dermatología en España
DSC	Dice Similarity Coefficient
EPS	Escola Politècnica Superior
FAISS	Facebook AI Similarity Search
FP	Fototipo (escala Fitzpatrick I–VI)
FT	Fine-tuning supervisado
GPU	Graphics Processing Unit
HAM	Human Against Machine
HIBA	Hospital Italiano de Buenos Aires
HNSW	Hierarchical Navigable Small Worlds
HUSLL	Hospital Universitario Son Llàtzer
IA	Inteligencia artificial
IB-Salut	Servicio de Salud de las Illes Balears
InfoNCE	Information Noise Contrastive Estimation
IoU	Intersection over Union (índice de Jaccard)
ISIC	International Skin Imaging Collaboration
L-BFGS	Limited-memory Broyden–Fletcher–Goldfarb–Shanno
LLM	Large Language Model (modelo de lenguaje de gran escala)
LoRA	Low-Rank Adaptation
LP	Linear Probing
MD5	Message Digest 5 (función de hash)
MSKCC	Memorial Sloan Kettering Cancer Center
PACS	Picture Archiving and Communication System
PAD-UFES	<i>Patient and Dataset of Skin Lesions, Universidade Federal do Espírito Santo</i>
RAG	Retrieval-Augmented Generation
SAE	Sparse Autoencoder
SAM	Segment Anything Model
SigLIP	Sigmoid Loss for Language Image Pre-training
SNOMED CT	Systematized Nomenclature of Medicine – Clinical Terms
SOTA	State of the Art (estado del arte)
TFG	Trabajo de Fin de Grado
TTA	Test-Time Augmentation
UIB	Universitat de les Illes Balears
ViT	Vision Transformer
VoA	Vision and Question Answering

RESUMEN

¿Cuál es el rendimiento real y la capacidad de generalización de los modelos fundacionales dermatológicos disponibles, en función del volumen de datos etiquetados, del tipo de supervisión, de la heterogeneidad taxonómica entre conjuntos de datos y de la disparidad entre fototipos cutáneos? Esta pregunta articula el presente trabajo. Su respuesta condiciona la viabilidad de integrar estos modelos en flujos de teledermatología hospitalaria con cohortes mediterráneas en español, escenario donde tres referencias recientes liberadas por el grupo de la Universidad Monash —PanDerm como codificador visual, Derm1M y la familia DermLIP como modelos vision-lenguaje contrastivos, y DermFM-Zero como sistema con capacidad zero-shot nativa— no disponen de evaluación independiente comparable a la fecha de cierre.

Para responderla, hemos evaluado catorce modelos fundacionales sobre doce conjuntos de datos externos públicos, armonizados mediante una ontología jerárquica de tres niveles (4 categorías etiológicas, 43 subcategorías clínicas y 367 diagnósticos individuales) codificada en SNOMED CT y CIE-10. La evaluación combina cuatro protocolos —sondeo lineal, ajuste fino supervisado, segmentación binaria con adaptación de bajo rango (LoRA) y clasificación zero-shot multimodal— ejecutados sobre una NVIDIA DGX Spark con chip Grace Hopper GB10, 128 GB de memoria unificada y precisión BF16, plataforma aarch64 no habitual en la literatura experimental.

PanDerm Large se confirma como el codificador congelado más fiable, con una mejora media de +9,0 pp en exactitud balanceada respecto a PanDerm Base, y satura con un volumen reducido de datos etiquetados: el 1 % del conjunto de entrenamiento de HAM10000 recupera el 96,2 % del AUROC obtenido con el conjunto completo. La evaluación zero-shot multimodal queda 29,4 pp por debajo del sondeo lineal, lo que cuantifica el coste de prescindir de adaptación supervisada. La auditoría sistemática de solapamiento por hash MD5 detecta fuga de información entre el preentrenamiento de Derm1M y tres de los doce conjuntos de evaluación (Dermnet, HIBA y MSKCC); cualquier cifra zero-shot reportada sobre ellos en la literatura previa debe interpretarse acompañada de este *caveat*. La validación sobre el corpus DermapixelAI 1.0 —construido en paralelo a este trabajo— confirma la transferencia de los modelos a material clínico no anglosajón sin reentrenamiento de la rama lingüística.

El trabajo aporta tres contribuciones reproducibles: un benchmark comparativo homogéneo de las catorce familias bajo un mismo protocolo, el dataset DermapixelAI 1.0 —1 089 imágenes vinculadas a 669 casos clínicos con texto narrativo y captions sintéticas multi-perspectiva en castellano, distribuido bajo licencia CC-BY-NC-SA 4.0— y la auditoría sistemática de solapamiento sobre los doce conjuntos de evaluación. Los tres artefactos quedan disponibles para verificación independiente y forman la base experimental sobre la que se construyen las líneas de continuación documentadas en

el capítulo de conclusiones.

Palabras clave

modelos fundacionales, dermatología clínica, PanDerm, DermLIP, evaluación empírica, ontología, equidad, heterogeneidad taxonómica.

ABSTRACT

What is the actual performance and generalisation capacity of the available dermatology foundation models, as a function of the labelled data budget, the supervision regime, taxonomic heterogeneity across datasets and skin phototype disparity? This question articulates the present work. Its answer conditions the viability of integrating these models into hospital teledermatology workflows on Spanish-speaking Mediterranean cohorts, a scenario in which three recent references released by the Monash group—PanDerm as a vision encoder, Derm1M and the DermLIP family as contrastive vision-language models, and DermFM-Zero as a system with native zero-shot capability—lack an independent comparable evaluation at the time of writing.

To answer it, we evaluate fourteen foundation models over twelve public external datasets, harmonised through a three-level hierarchical ontology (4 aetiological families, 43 clinical subcategories and 367 individual diagnoses) encoded in SNOMED CT and ICD-10. The evaluation combines four protocols—linear probing, supervised fine-tuning, binary lesion segmentation with Low-Rank Adaptation (LoRA) and multimodal zero-shot classification—executed on a NVIDIA DGX Spark with a Grace Hopper GB10 chip, 128 GB of unified memory and BF16 precision, an aarch64 platform uncommon in the experimental literature.

PanDerm Large stands out as the most reliable frozen encoder, with a mean improvement of +9,0 pp in balanced accuracy over PanDerm Base, and saturates with a small labelled budget: 1 % of the HAM10000 training set recovers 96,2 % of the AUROC obtained with the full set. Multimodal zero-shot evaluation falls 29,4 pp below linear probing, bounding the cost of forgoing supervised adaptation. The systematic MD5-based overlap audit detects information leakage between the Derm1M pretraining set and three of the twelve evaluation datasets (Dermnet, HIBA and MSKCC); any zero-shot figure reported on them in prior literature must be interpreted with this *caveat*. Validation on the DermapixelAI 1.0 corpus—built in parallel with this work—confirms model transfer to non-Anglophone clinical material without retraining the language branch.

The work contributes three reproducible items: a homogeneous comparative benchmark of the fourteen families under a common protocol, the DermapixelAI 1.0 dataset—1 089 images linked to 669 clinical cases with narrative text and multi-perspective synthetic captions in Spanish, released under a CC-BY-NC-SA 4.0 licence—and the systematic overlap audit across the twelve evaluation sets. The three artefacts remain available for independent verification and form the experimental basis on which the lines of continuation documented in the conclusions chapter are built.

Keywords

foundation models, clinical dermatology, PanDerm, DermLIP, empirical evaluation, ontology, fairness, taxonomic heterogeneity.

INTRODUCCIÓN

En el presente Trabajo Final de Grado (TFG) se evalúa de forma sistemática el rendimiento de los modelos fundacionales disponibles para imagen dermatológica clínica, sobre un conjunto homogéneo de protocolos experimentales y datasets externos públicos. El trabajo se desarrolla en el marco de dos colaboraciones preexistentes con la Dra. R. Taberner del Hospital Universitario Son Llàtzer (HUSLL) y se acompaña de la construcción de un dataset propio en español, DermapixelAI 1.0, que se entrega como contribución independiente.

En este capítulo se presenta el contexto clínico del problema, el marco operativo en el que se inscribe el trabajo, la pregunta de investigación que articula el estudio, los objetivos formales, las restricciones explícitas del diseño y la estructura del resto del documento. El estado del arte específico —modelos fundacionales para imagen médica y dermatológica, métodos de adaptación y evaluación zero-shot— se desarrolla en el capítulo 2.

1.1 Contexto clínico

La dermatología clínica atiende un espectro amplio de entidades con distribución concentrada en un número reducido de motivos de consulta. El estudio observacional DIADERM, sobre 10 999 diagnósticos en 8 953 pacientes en territorio español, ordena los diez diagnósticos más prevalentes como queratosis actínica, carcinoma basocelular, nevus melanocítico, queratosis seborreica, otras neoplasias benignas, psoriasis, acné, verrugas víricas, otros trastornos de la pigmentación y otras dermatitis [5]. El trabajo local de Taberner et al. sobre el servicio dermatológico del HUSLL documenta 213 diagnósticos diferentes en un único año asistencial [4]. Ambos coinciden en un peso elevado de dermatosis benignas, inflamatorias e infecciosas habituales.

La sensibilidad temporal del proceso diagnóstico resulta crítica en el melanoma cutáneo. La supervivencia específica a cinco años desciende desde aproximadamente 99 % en estadio I hasta 25 % en estadio IV según la octava edición de la American Joint

Committee on Cancer [20]. El acceso al especialista se realiza mediante derivación desde atención primaria. La capacidad asistencial del circuito presencial es limitada frente a una demanda creciente, lo que justifica el interés por sistemas de apoyo al diagnóstico basados en imagen.

El sustrato visual del diagnóstico dermatológico se articula en tres modalidades: fotografía clínica (presentación general y contexto anatómico), dermatoscopia (patrones pigmentarios y estructurales no visibles a simple vista) e histopatología (confirmación tisular). Sobre esta tríada operan los sistemas de apoyo basados en aprendizaje automático.

1.2 Marco operativo previo

El presente trabajo se desarrolla en el marco de dos colaboraciones preexistentes con la Dra. R. Taberner, dermatóloga del HUSLL. La primera es la modernización tecnológica del archivo Dermapixel, blog mantenido por la Dra. Taberner desde 2010 que reúne más de 700 casos clínicos comentados con imagen clínica y dermatoscópica, historia abreviada, diagnóstico y razonamiento diferencial; en paralelo a este TFG hemos desarrollado su migración a una pila tecnológica propia. La segunda es un proyecto institucional del Servei de Salut de les Illes Balears (IB-Salut) sobre teledermatología hospitalaria, en el que se desarrolla una herramienta de apoyo a la primera valoración dermatológica en el circuito de derivación desde atención primaria. Ambas líneas orientan la decisión de priorizar modelos con código y pesos públicos por su viabilidad de integración.

1.3 Pregunta de investigación

El estudio se articula en torno a una pregunta única: *¿cuál es el rendimiento y la capacidad de generalización de los modelos fundacionales para imagen dermatológica disponibles, en función del volumen de datos etiquetados y del tipo de supervisión, y con qué robustez frente a la heterogeneidad taxonómica entre datasets y la disparidad por fototipo cutáneo?*

La respuesta empírica exige dos condiciones operativas: un protocolo de evaluación homogéneo aplicable a familias de modelos heterogéneas y un esquema explícito de armonización taxonómica entre datasets. El diseño descrito en el capítulo 3 satisface ambas.

1.4 Objetivos del trabajo

El trabajo se articula en torno a dos objetivos formales, verificables sobre los resultados experimentales del capítulo 4.

01. Evaluación experimental sistemática de los modelos fundacionales dermatológicos sobre conjuntos de datos externos. Sobre el hardware del proyecto (NVIDIA DGX Spark, chip Grace Hopper GB10, arquitectura aarch64, 128 GB memoria unificada, CUDA 13.0, BF16) se implementa el conjunto de modelos fundacionales con código

y pesos públicos a la fecha de inicio. Se evalúa su comportamiento sobre doce datasets externos públicos¹ mediante cuatro protocolos principales (sondeo lineal, ajuste fino supervisado, segmentación binaria con LoRA [31] sobre SAM2.1 [18], clasificación zero-shot multimodal) y tres protocolos complementarios (comparación con modelos de lenguaje multimodales, análisis de equidad por fototipo Fitzpatrick, auditoría de solapamiento con Derm1M mediante hash MD5).

02. Construcción del dataset DermapixelAI 1.0. Se extrae, depura y estructura el material del archivo Dermapixel para conformar un dataset que vincula, para cada caso, imagen y modalidad, metadatos clínicos y texto narrativo en español. El dataset se publica bajo licencia CC-BY-NC-SA 4.0 con datasheet formal [28], particiones documentadas y mecanismo de cita recomendada. La explotación experimental sistemática sobre el dataset se inicia hacia el cierre del periodo cubierto por este documento y se desarrolla principalmente con posterioridad; la sección 7.5 del capítulo 7 recoge el estado del dataset.

Los bloques derivados emergidos durante el desarrollo del proyecto (armonización ontológica jerárquica L1/L2/L3, ensemble de seguridad para detección de melanoma, análisis de equidad por fototipo, interpretabilidad mediante Sparse Autoencoders [19], recuperación visual densa basada en FAISS [26], integración en el prototipo DermApI-xel) no constituyen objetivos formales y se documentan en los anexos correspondientes con su estado, prerequisites y líneas futuras.

1.5 Restricciones del estudio

Tres restricciones explícitas condicionan el diseño experimental y la interpretación de los resultados. **Hardware:** todas las ejecuciones se realizan sobre NVIDIA DGX Spark con chip Grace Hopper GB10 y arquitectura aarch64, no coincidente con el hardware x86_64 dominante en la literatura. **Acceso a datos:** los conjuntos internos del grupo de Monash empleados en el preentrenamiento de PanDerm no son accesibles para terceros, lo que limita el trabajo a los pesos liberados y a la evaluación sobre datasets externos públicos. **Acceso a modelos:** los pesos de DermFM-Zero no son públicos en la fecha de cierre, lo que impide su evaluación empírica directa y restringe su tratamiento a la discusión conceptual.

El trabajo no aborda, por decisión de alcance, los siguientes elementos: preentrenamiento desde cero de un modelo fundacional propio; validación clínica prospectiva sobre cohorte hospitalaria real con protocolo aprobado por Comité Ético de Investigación Clínica; integración operativa con el sistema PACS del HUSLL; reentrenamiento multilingüe de la rama lingüística sobre datasets en español de gran escala. Estos elementos se identifican como líneas futuras en la sección 7.5 del capítulo 7.

1.6 Estructura del documento

El documento se compone de siete capítulos en el cuerpo principal, una bibliografía y ocho anexos. El capítulo 2 sintetiza el estado del arte en cuatro bloques: aprendizaje

¹HAM10000 [8], BCN20000 [27], PAD-UFES-20 [11], DDI [12], Dermnet [13], Derm7pt (clínica y dermatoscópica) [9], HIBA, MSKCC, WSI patches, Fitzpatrick17k [14], SkinCon [15] e ISIC2018 [10].

profundo aplicado a dermatología, modelos fundacionales en imagen médica, modelos específicos para dermatología y brechas operativas no resueltas por la literatura. El capítulo 3 describe materiales y métodos: los doce datasets externos, la ontología jerárquica L1/L2/L3, el dataset DermapixelAI 1.0 (resumido; pipeline detallado en el Anexo C), los catorce modelos evaluados, la infraestructura, los protocolos, las métricas y la trazabilidad. El capítulo 4 reúne los resultados experimentales organizados por bloque. El capítulo 5 interpreta los resultados en clave de hallazgos, comparación con la literatura e implicaciones operativas. El capítulo 6 declara las limitaciones del estudio en seis dimensiones. El capítulo 7 responde de forma compacta a la pregunta de investigación y enumera las contribuciones reproducibles.

Los anexos contienen, respectivamente, el mapa de tareas experimentales y la estructura del repositorio (Anexo A), las tablas detalladas de resultados por dataset (Anexo B), el pipeline de construcción y caracterización del dataset DermapixelAI 1.0 (Anexo C), la declaración sobre el uso de herramientas de inteligencia artificial durante la elaboración del documento (Anexo D), el documento de entrega formal del dataset con licencia, datasheet y consideraciones de privacidad (Anexo E), la documentación de los Sparse Autoencoders y el diccionario de conceptos (Anexo F), la comparación extendida con modelos de lenguaje multimodales generalistas (Anexo G) y el prototipo DermApIxel (Anexo H).

ESTADO DEL ARTE

2.1 Aprendizaje profundo aplicado a dermatología

El trabajo de Esteva et al. [29] establece la primera referencia consolidada de clasificación dermatológica con redes convolucionales, con rendimiento equivalente al de un panel de dermatólogos certificados sobre clasificación binaria maligno/benigno. Las extensiones posteriores amplían el espectro diagnóstico y la diversidad de datos [30, 8] y formulan tareas adicionales como segmentación binaria de lesión [10] y clasificación binaria melanoma/no-melanoma con anotaciones estructuradas multi-criterio [9]. El paradigma común permanece estable: entrenamiento desde pesos de ImageNet, una arquitectura por tarea y dependencia de anotación experta. Tres limitaciones lo acotan: el coste de la anotación clínica, la fragmentación taxonómica entre conjuntos públicos y la pérdida de rendimiento fuera del dominio de entrenamiento, particularmente acusada en fototipos cutáneos elevados [14, 12].

2.2 Modelos fundacionales: arquitectura y objetivos

Los modelos fundacionales sustituyen el entrenamiento específico por encoders preentrenados de forma auto-supervisada o multimodal sobre datasets visuales masivos. La arquitectura predominante es el Vision Transformer [21], que procesa la imagen como una secuencia de parches y aprende dependencias globales mediante mecanismos de atención. Los objetivos de preentrenamiento más extendidos son tres: el *masked image modeling*, en el que la red reconstruye parches ocultos a partir del contexto visible; la destilación auto-supervisada entre vistas; y la alineación contrastiva imagen-texto al estilo CLIP [22]. La adaptación posterior a tareas específicas opera por sondeo lineal sobre representaciones congeladas, ajuste fino supervisado, o transferencia directa zero-shot guiada por *prompts* en los modelos con rama lingüística.

2.3 Encoders visuales auto-supervisados

DINOv2 [16] es la referencia abierta de encoder visual auto-supervisado de propósito general, entrenado sobre ~ 142 millones de imágenes naturales sin etiquetas mediante destilación entre vistas. Sus representaciones transfieren a tareas de clasificación, recuperación y segmentación sobre dominios naturales y biomédicos con ajuste mínimo, y constituyen una base habitual para adaptación a dominios especializados.

En el dominio dermatológico, PanDerm [1] es un encoder visual ViT (Base ~ 86 M y Large ~ 307 M parámetros) entrenado sobre $\sim 2,1$ millones de imágenes dermatológicas en cuatro modalidades (fotografía corporal total, dermatoscopia, fotografía clínica e histopatología). El preentrenamiento utiliza *masked latent modeling*: la red reconstruye representaciones latentes de regiones ocultas en lugar de píxeles, con un modelo CLIP-Large congelado como *teacher*. Sus autores reportan una mejora media del $+10,2\%$ sobre el estado del arte previo en 28 tareas dermatológicas. La disponibilidad simultánea de pesos, código y benchmarks lo convierte en el primer modelo fundacional dermatológico verificable de forma independiente.

2.4 Modelos vision-lenguaje contrastivos

CLIP [22] establece el preentrenamiento contrastivo imagen-texto sobre 400 millones de pares de la web. El objetivo InfoNCE aproxima la imagen a su descripción dentro del lote y la aleja del resto. El espacio compartido habilita dos modos operativos: clasificación zero-shot guiada por *prompts* textuales (la clase ganadora es la de mayor similitud coseno entre el vector visual y los vectores textuales de las clases candidatas) y recuperación bidireccional imagen-texto sobre datasets precomputados.

SigLIP [23] sustituye la pérdida softmax de CLIP por una pérdida sigmoide que reduce la dependencia del tamaño de batch y escala con mejor estabilidad. Su variante Large (SO400M) dispone de embedding de 1152 dimensiones y ~ 878 M parámetros. BiomedCLIP [17] extiende el paradigma al dominio biomédico sobre PMC-15M (~ 15 millones de pares figura-leyenda de literatura científica); su cobertura dermatológica específica es limitada por el sesgo de selección del dataset.

En dermatología, Derm1M y la familia DermLIP [2] añaden la rama lingüística contrastiva al estado del arte de la disciplina. Derm1M reúne 1 029 761 pares imagen-texto sobre 403 563 imágenes únicas, organizados según una ontología jerárquica de cuatro niveles construida por dermatólogos. La familia DermLIP combina varios encoders visuales (PanDerm Base, ConvNeXt-Large) con varios encoders textuales (PubMedBERT extendido a 256 tokens, GPT-2 dermatológico con tokenizador de CLIP a 77 tokens). La configuración con mejor rendimiento reportada por los autores combina PanDerm Base como encoder visual y PubMedBERT como encoder textual, superando a BiomedCLIP en los benchmarks zero-shot evaluados.

La implementación operativa de la recuperación visual densa sobre datasets a gran escala requiere índices vectoriales optimizados para búsqueda aproximada del vecino más próximo. FAISS [26] y estructuras basadas en grafos del tipo Hierarchical Navigable Small Worlds permiten consultas en el orden de 10^2 milisegundos sobre datasets de centenares de miles a millones de *embeddings* precomputados.

2.5 Modelos integrados con zero-shot nativo

DermFM-Zero [3] integra el preentrenamiento visual auto-supervisado y la alineación contrastiva imagen-texto en un único modelo con capacidad zero-shot nativa. El entrenamiento se estructura en dos fases: *masked latent modeling* sobre tres millones de imágenes en la primera, y *bootstrapped contrastive learning* sobre un millón de pares texto-imagen en la segunda. El encoder textual es PubMedBERT. El modelo incorpora interpretabilidad emergente mediante Sparse Autoencoders [19], redes auxiliares que descomponen la representación interna en un diccionario disperso de direcciones asociables a conceptos clínicamente identificables. Sus autores reportan validación en tres *reader studies* con más de mil cien clínicos. Sus pesos no son públicos en la fecha de cierre del presente trabajo, lo que restringe su tratamiento a la discusión conceptual.

BLIP-2 [25] introduce un patrón arquitectónico distinto: conecta un encoder visual congelado con un modelo de lenguaje preentrenado mediante un módulo intermedio ligero (*Q-Former* o *Querying Transformer*) que transforma las representaciones visuales en una secuencia reducida de tokens interpretables por el modelo de lenguaje. Sólo el Q-Former se entrena. No existe, en la fecha de cierre, una adaptación pública específica de BLIP-2 al dominio dermatológico.

2.6 Segmentación promptable

SAM [24] establece el paradigma de segmentación promptable: produce máscaras a partir de *prompts* visuales (puntos, cajas, máscaras parciales) sobre imagen natural. Su preentrenamiento utiliza ~ 11 millones de imágenes con más de mil millones de máscaras generadas mediante un proceso semi-automatizado. SAM2 [18] amplía el enfoque al dominio del vídeo y mejora el rendimiento sobre imágenes estáticas.

La transferencia a dominios médicos requiere adaptación supervisada sobre conjuntos con máscaras binarias. La estrategia habitual combina un modelo SAM/SAM2 preentrenado con *fine-tuning* sobre ISIC2018 [10] y adaptadores LoRA [31], que incorporan un número reducido de parámetros entrenables manteniendo congelado el peso original del encoder visual. Esta estrategia reduce los requisitos de memoria y cómputo y permite la adaptación sobre hardware modesto.

2.7 Modelos de lenguaje multimodales generalistas

Los modelos de lenguaje multimodales preentrenados sobre datasets web masivos constituyen una referencia de comparación inevitable: GPT-4o (OpenAI), Gemini 2.5 Pro (Google DeepMind) y la familia MedGemma (versiones 4B Vision y 27B Text, Google). Su número de parámetros supera al de los encoders fundacionales específicos en uno o dos órdenes de magnitud. Su modo de uso característico es la inferencia guiada por *prompts* sin *fine-tuning* específico por tarea. Trabajos recientes documentan su uso conversacional para soporte al razonamiento clínico [6, 7]. Los modelos de acceso restringido (GPT-4o, Gemini) sólo se evalúan mediante API; MedGemma libera pesos y se evalúa en local.

2.8 Problemas metodológicos y guías de reporte

La aplicación de modelos fundacionales a imagen médica plantea tres problemas metodológicos directamente relevantes para el presente trabajo. El primero es la fuga de información entre conjuntos de evaluación y dataset de preentrenamiento. La construcción de Derm1M sobre fuentes web abiertas implica que datasets como Dermnet, HIBA o MSKCC pueden solaparse con su dataset de entrenamiento, lo que sesga al alza las métricas zero-shot reportadas. El segundo es la heterogeneidad taxonómica entre datasets, que impide comparaciones directas sin un paso explícito de armonización. El tercero es la disparidad de rendimiento por fototipo cutáneo, documentada en Fitzpatrick17k [14] y atendida específicamente por SkinCon [15] mediante anotación basada en 48 conceptos clínicos visuales.

Las guías de reporte recientes para inteligencia artificial en imagen médica —CLAIM [34] y la actualización TRIPOD+AI— establecen la transparencia metodológica como condición de defensibilidad: cohorte, particiones, métricas, incertidumbre y limitaciones deben constar explícitamente en el informe completo. El reporte de pruebas estadísticas (intervalos de confianza por *bootstrap*, comparaciones múltiples, contrastes pareados de AUROC mediante el test de DeLong [32], y tamaños muestrales por subgrupo) constituye un requisito creciente en publicaciones de la disciplina.

2.9 Brechas operativas y posicionamiento

Cinco brechas operativas delimitan el espacio en el que el presente trabajo aporta evidencia empírica. **(i) Disponibilidad real de los modelos.** PanDerm y DermLIP liberan pesos y código; DermFM-Zero no lo hace. BiomedCLIP, DINOv2, SigLIP, SAM, SAM2 y BLIP-2 son abiertos. Los modelos generalistas ofrecen acceso parcial por API. Cualquier evaluación empírica externa queda condicionada por esta disponibilidad. **(ii) Benchmarks no homogéneos entre familias.** Los benchmarks reportados por los autores se construyen sobre subconjuntos derivados del propio preentrenamiento y aplican protocolos no equivalentes entre familias. La comparación bajo un mismo protocolo y un mismo conjunto de datasets externos no está documentada. **(iii) Heterogeneidad taxonómica.** La comparación inter-dataset exige un esquema de armonización que la literatura no proporciona de forma consolidada. **(iv) Concentración geográfica y lingüística.** Los datasets proceden mayoritariamente de instituciones de Australia, Estados Unidos y Europa central, y los encoders textuales se preentrenan sobre datasets en inglés. La disponibilidad de material clínico en español con texto narrativo asociado es marginal. **(v) Distancia entre evaluación experimental e integración hospitalaria.** La evaluación sobre *benchmarks* públicos no cubre las condiciones operativas asociadas al despliegue en un entorno sanitario real (hardware no estándar, restricciones de privacidad, trazabilidad, interacción con sistemas hospitalarios).

La contribución empírica del trabajo, cuyo diseño se describe en el capítulo 3 y cuyos resultados se presentan cuantitativamente en el capítulo 4, se sitúa sobre estas cinco brechas.

MATERIALES Y MÉTODOS

3.1 Datasets

La evaluación se realiza sobre doce datasets externos públicos agrupados por modalidad y finalidad. La tabla 3.1 sintetiza sus características.

Cuadro 3.1: Datasets externos empleados en la evaluación. N_{test} : tamaño nominal del *split* de evaluación canónico; “Clases”: número de categorías diagnósticas o conceptos en la convención propia del dataset. El asterisco (*) marca los datasets con solapamiento documentado frente al dataset de preentrenamiento Derm1M (auditoría en sección 3.6.8). Las dos variantes de Derm7pt (clínica y dermatoscópica) comparten origen (Seven-Point Checklist) y se reportan como un único dataset en el conteo agregado de doce datasets externos.

Dataset	N_{test}	Clases	Modalidad	Uso
HAM10000 [8]	1 232	7	Dermoscopia	LP, FT, ZS, LLMs
BCN20000 [27]	1 242	9	Dermoscopia	LP
PAD-UFES-20 [11]	461	6	Clínica móvil	LP, FT
DDI [12]	137	2	Clínica	LP, FT, equidad
Dermnet [13]	4 002	23	Clínica	LP*
Derm7pt clínico [9]	168	2	Clínica	LP
Derm7pt dermo [9]	225	2	Dermoscopia	LP
HIBA	334	2	Dermoscopia	LP*
MSKCC	1 664	2	Dermoscopia	LP, FT*
WSI patches	12 354	16	Histopatología	LP
ISIC2018 [10]	2 594	binaria	Dermoscopia	Segmentación
Fitzpatrick17k [14]	16 577	114 + FP	Clínica	Equidad
SkinCon [15]	3 230	48 conc.	Clínica	CBM

Los conjuntos dermatoscópicos (HAM10000, BCN20000, Derm7pt dermo, HIBA, MSKCC, ISIC2018) cubren la modalidad de imagen polarizada adquirida con dermatoscopio. Los conjuntos de fotografía clínica (PAD-UFES-20, DDI, Dermnet, Derm7pt clínico) reproducen las condiciones de captura en consulta y atención primaria. WSI

patches recoge 12 354 *parches* histopatológicos en 16 categorías. Fitzpatrick17k introduce el eje de equidad mediante anotación conjunta de patología (114 categorías) y fototipo cutáneo (escala Fitzpatrick I-VI). SkinCon proporciona anotación densa basada en 48 conceptos clínicos visuales para la evaluación de Concept Bottleneck Models. Las particiones *train/val/test* utilizadas son las canónicas declaradas por los responsables de cada dataset, sin reasignación.

3.2 Ontología jerárquica L1/L2/L3

La heterogeneidad de las taxonomías nativas impide la comparación directa entre datasets. Para resolverla hemos diseñado, en colaboración con la Dra. R. Taberner, una ontología jerárquica de tres niveles que sirve de vocabulario común para todos los protocolos del trabajo. El nivel L1 (etiológico) agrupa los diagnósticos en cuatro familias: patología inflamatoria, tumoral, infecciosa y genodermatosis. El nivel L2 (subcategoría clínica) contiene 43 entradas; cinco de ellas no se desagregan al nivel L3 al considerarse suficientemente específicas (*Esclerosis tuberosa*, *Neurofibromatosis tipo 1*, *Incontinentia pigmenti*, *Queratodermia palmoplantar hereditaria* y *Pseudoxantoma elástico*). El nivel L3 (diagnóstico) contiene 367 entradas individuales. Cada entrada L3 lleva asociados códigos SNOMED CT y CIE-10 para garantizar interoperabilidad con sistemas clínicos. Once de los doce datasets se mapean a la ontología; SkinCon queda fuera al estar anotado con conceptos en lugar de diagnósticos. El dataset armonizado agregado contiene 72 654 imágenes etiquetadas sobre vocabulario común.

3.3 Dataset DermapixelAI 1.0

DermapixelAI 1.0 es un dataset dermatológico en español, derivado del archivo del blog Dermapixel mantenido por la Dra. R. Taberner. La versión utilizada contiene 1 089 imágenes vinculadas a 669 casos clínicos con texto narrativo asociado (mediana de 223 palabras por caso), mayoritariamente fotografía clínica (1 036) con un subconjunto dermatoscópico reducido (49). Las imágenes se etiquetan conforme a la ontología L1/L2/L3 y se particionan en *train/val/test* bajo regla *case-aware* (891/157/41 imágenes; 538/100/31 casos), garantizando que las imágenes de un mismo caso clínico no se distribuyen entre splits. El 97,89 % del dataset está mapeado a la ontología L1/L2/L3 con revisión experta del vocabulario (`label_source = ontology`); el 84,39 % ha pasado además revisión visual caso-a-caso por la Dra. R. Taberner (`rosa_verified`). Las dos cifras no son intercambiables y se documentan en detalle, junto a un tercer campo de validación textual, en el Anexo C. El dataset se distribuye bajo licencia CC-BY-NC-SA 4.0. El pipeline detallado de construcción, caracterización completa y datasheet figura en el Anexo C; el documento formal de entrega, en el Anexo E. La explotación experimental sistemática sobre DermapixelAI 1.0 se inicia hacia el cierre del periodo cubierto por este documento; las cifras del capítulo 4 no incluyen evaluación sobre este dataset.

3.4 Modelos evaluados

La evaluación abarca catorce modelos agrupados en cuatro familias. La tabla 3.2 sintetiza sus características.

Cuadro 3.2: Modelos evaluados.

Modelo	Familia	Parámetros	Referencia
PanDerm Base	Encoder visual derm.	~ 86 M	[1]
PanDerm Large	Encoder visual derm.	~ 307 M	[1]
DINOv2 ViT-L/14	Encoder visual general	~ 300 M	[16]
ConvNeXt-Large	ConvNet supervisada	~ 198 M	—
EfficientNetV2-Large	ConvNet supervisada	~ 118 M	—
DermLIP v1 (PubMedBERT)	Vision-lenguaje derm.	—	[2]
DermLIP v2 (PubMedBERT)	Vision-lenguaje derm.	—	[2]
DermLIP original (GPT-2)	Vision-lenguaje derm.	—	[2]
BiomedCLIP	Vision-lenguaje biomédico	—	[17]
SigLIP-Large SO400M	Vision-lenguaje general	~ 878 M	[23]
SAM2.1-Large + LoRA	Segmentación	~ 227 M	[18]
GPT-4o	LLM multimodal	no público	—
Gemini 2.5 Pro	LLM multimodal	no público	—
MedGemma 4B Vision	LLM multimodal biomédico	~ 4 B	—
MedGemma 27B Text+LoRA	LLM multimodal biomédico	~ 27 B	—
BLIP-2 (Q-Former)	Vision-lenguaje general	—	[25]

PanDerm Base produce *embeddings* de 768 dimensiones; PanDerm Large y DINOv2 ViT-L/14, 1 024 dimensiones; SigLIP-Large SO400M, 1 152 dimensiones. La cifra de ~ 307 M parámetros indicada para PanDerm Large corresponde al valor nominal del codificador ViT-L/16 publicado por los autores; al cargarlo como extractor de características y sustituir la cabeza original por la identidad se obtienen 303,3 M parámetros efectivos, diferencia sin impacto sobre el rendimiento al no participar la cabeza descartada en la inferencia. La familia DermLIP emplea ViT-B/16 como encoder visual y dos encoders textuales alternativos: PubMedBERT extendido a 256 tokens (variantes v1 y v2) y GPT-2 con tokenizador de CLIP a 77 tokens (variante original). DermFM-Zero [3] no se evalúa empíricamente al no estar disponibles sus pesos en la fecha de cierre.

3.5 Infraestructura experimental

Los experimentos se ejecutan sobre una NVIDIA DGX Spark equipada con chip Grace Hopper GB10, 128 GB de memoria unificada compartida entre CPU y GPU, sistema Linux ARM aarch64 y CUDA 13.0. La precisión nativa es BF16 (*brain floating-point* de 16 bits) en inferencia y entrenamiento, con FP32 en optimizador y pérdida en los protocolos de ajuste fino (precisión mixta canónica). La memoria unificada permite mantener cargados modelos del orden de 55 GB en BF16 sin *offloading* ni cuantización; en particular, MedGemma 27B opera localmente sin compresión. El entorno de software está fijado en Python 3.12.3, PyTorch 2.11.0, timm 0.9.16, scikit-learn, transformers, open_clip, sam2, peft y FAISS [26]. Los tiempos de cálculo característicos sobre este equipo son los siguientes: sondeo lineal completo de un encoder sobre un dataset estándar, 1–3 minutos; ajuste fino de PanDerm Large sobre HAM10000 a 50 épocas con TTA, ~ 15 horas; ajuste fino de SAM2.1-Large sobre ISIC2018 con LoRA a 50 épocas, ~ 24 horas; entrenamiento de un Sparse Autoencoder Large (16384 características) sobre los *embeddings* de PanDerm, ~ 4 horas.

3.6 Protocolos experimentales

3.6.1 Sondeo lineal (LP)

El protocolo congela el encoder visual y entrena un clasificador lineal sobre los *embeddings* extraídos. La extracción emplea la normalización canónica de cada modelo: ImageNet ($\mu = [0,485, 0,456, 0,406]$, $\sigma = [0,229, 0,224, 0,225]$) para PanDerm y DINOv2; parámetros OpenAI CLIP para la familia DermLIP, BiomedCLIP y SigLIP. Los vectores resultantes se almacenan en disco para evitar recomputaciones entre experimentos. El clasificador es una regresión logística multinomial con optimizador L-BFGS, penalización L2 con coeficiente $C = 1,0$, $\text{max_iter} = 5000$ y $\text{random_state} = 42$. Los *splits* son las particiones canónicas declaradas en la tabla 3.1. El protocolo se aplica sobre PanDerm Base y Large, DINOv2, ConvNeXt-Large, EfficientNetV2-Large y la rama visual de DermLIP v2, BiomedCLIP y SigLIP-Large.

3.6.2 Ajuste fino supervisado (FT)

El protocolo ajusta conjuntamente el encoder visual y una cabeza de clasificación específica. La configuración reproduce la del paper original de PanDerm [1]: optimizador AdamW con *weight decay* 0,05; tasa de aprendizaje inicial $\eta = 5 \times 10^{-4}$; *cosine annealing* con *warmup* lineal de 10 épocas; *layer decay* 0,65; *drop-path* 0,2; *label smoothing* $\epsilon = 0,1$; Mixup $\alpha = 0,8$; CutMix $\alpha = 1,0$; *weighted random sampler* con pesos inversamente proporcionales a la frecuencia de cada clase; 50 épocas; precisión mixta canónica (BF16 en el cuerpo del modelo, FP32 en optimizador y pérdida); semillas de torch, numpy y random fijadas a 0. En la evaluación final sobre HAM10000 se aplica *test-time augmentation* (TTA) promediando los logits sobre 5 aumentaciones deterministas (volteos horizontal y vertical, rotación, *jitter* de color) por imagen. El protocolo se aplica sobre PanDerm Base y Large en HAM10000, PAD-UFES-20, DDI y MSKCC.

3.6.3 Eficiencia en etiquetas

El protocolo mide la dependencia del rendimiento respecto al volumen de datos etiquetados disponibles, manteniendo congelado el encoder. Sobre HAM10000 y PAD-UFES-20 se entrenan clasificadores lineales (con la misma configuración del sondeo lineal, sección 3.6.1) con submuestreos estratificados del conjunto de entrenamiento al 1 %, 5 %, 10 %, 20 %, 50 % y 100 %. La estratificación preserva la proporción original de clases en cada subconjunto. Los submuestreos se generan con $\text{random_state} = 42$ para garantizar reproducibilidad. PanDerm Large es el encoder principal; PanDerm Base se utiliza como referencia adicional sobre HAM10000.

3.6.4 Segmentación binaria de lesión

SAM2.1-Large se adapta al dominio dermatológico mediante *fine-tuning* con LoRA [31]. Las componentes ajustadas son el decodificador de máscaras (*mask_decoder*) y el *promptable encoder*; el *image_encoder* (Hiera-Large preentrenado) permanece congelado, lo que mantiene fijos la mayoría de los parámetros del modelo. La configuración LoRA emplea *rank* $r = 8$ con la implementación estándar de la biblioteca peft. La optimización utiliza AdamW con $\eta = 1 \times 10^{-4}$ y *weight decay* 0,05; la pérdida combina

cross-entropy y *Dice loss* sobre la máscara binaria predicha; el tamaño de batch es 4 (limitado por el coste de SAM2.1-Large en BF16); la normalización es uniforme con $\mu = \sigma = 0,5$ en los tres canales, según la convención de SAM2. Se evalúan dos configuraciones: 50 épocas (resultado de referencia) y 100 épocas con *early stopping* sobre el Dice de validación. El conjunto de entrenamiento es ISIC2018 [10]; la transferencia fuera de dominio se evalúa adicionalmente sobre ISIC2017 y PH2 sin reentrenamiento. Como referencias se contrastan SAM2 *zero-shot* sin adaptación y un *Convolutional AutoEncoder* (CAE-seg) entrenado desde cero con la misma pérdida y configuración de optimización.

3.6.5 Clasificación zero-shot multimodal

El protocolo aprovecha el espacio de representación compartido imagen-texto de los modelos vision-lenguaje contrastivos. Cada clase candidata se formula como una o varias frases de plantilla; las frases se codifican mediante el encoder textual del modelo y, cuando existen varias plantillas por clase, los vectores resultantes se promedian para obtener un único vector representativo. La imagen se codifica con el encoder visual y la clase ganadora es la de máxima similitud coseno con el vector visual. Sobre HAM10000 se evalúan tres configuraciones de *prompts*: (i) genéricos en inglés, una plantilla por clase (p. ej. “*a dermoscopic image of a melanoma*”); (ii) conjunto A3 del paper de Derm1M [2], con varias plantillas por clase y promediado posterior; (iii) enriquecidos con descriptores clínicos adicionales (modalidad, localización anatómica, criterios diagnósticos visuales) sobre la base del conjunto A3. El protocolo se aplica con dos tokenizadores distintos para caracterizar la sensibilidad del rendimiento al tokenizador: PubMedBERT extendido a 256 tokens (DermLIP v1/v2) y GPT-2 con tokenizador de CLIP a 77 tokens (DermLIP original). Sobre HIBA, MSKCC, DDI y Derm7pt clínico se ejecuta la versión binaria melanoma/no-melanoma con *prompts* genéricos y conjunto A3 de Derm1M.

3.6.6 Comparación con modelos de lenguaje multimodales

El protocolo evalúa GPT-4o (API OpenAI), Gemini 2.5 Pro (API Google), MedGemma 4B Vision (local) y MedGemma 27B Text (local en BF16) sobre el *split* de test de HAM10000 (1 232 imágenes), idéntico al utilizado en sondeo lineal y ajuste fino para garantizar comparabilidad. El *prompt* clínico estandarizado de aproximadamente 300 palabras describe la tarea como apoyo al diagnóstico (no sustitución del juicio clínico), presenta las siete categorías diagnósticas de HAM10000 con descripción breve y solicita el diagnóstico más probable con razonamiento estructurado. La etiqueta predicha se extrae mediante *parsing* determinista que mapea el nombre del diagnóstico al código correspondiente de HAM10000; las respuestas no mapeables (menos del 1 % en todos los modelos) se contabilizan como incorrectas. El modo principal es *zero-shot* sin *fine-tuning* previo. Para MedGemma 27B se evalúa adicionalmente una variante ajustada con LoRA ($r = 8$) sobre el *split* de entrenamiento de HAM10000.

3.6.7 Evaluación de equidad por fototipo

El protocolo evalúa cinco encoders fundacionales (PanDerm Large, PanDerm Base, DermLIP v2 en su rama visual, DINOv2 ViT-L/14 y BiomedCLIP) sobre el dataset Fitz-

patrick17k completo (16577 imágenes, 114 patologías, 6 fototipos cutáneos I-VI). El protocolo común es sondeo lineal con la configuración de sección 3.6.1, empleando para cada modelo su normalización canónica. Se reportan dos formulaciones: (i) clasificación a 114 patologías (grano fino del dataset) y (ii) clasificación a 3 clases de malignidad (benigno / no neoplásico / maligno), formulación habitual en estudios de equidad sobre Fitzpatrick17k. Las métricas por subgrupo se calculan sobre los seis fototipos. La métrica de equidad declarada es la brecha entre los fototipos extremos $\text{Gap}_{\text{I} \rightarrow \text{VI}} = \text{BAcc}_{\text{I}} - \text{BAcc}_{\text{VI}}$. La verificación del experimento se realiza re-ejecutando el sondeo sobre PanDerm Large y comprobando coincidencia hasta cuatro decimales con el resultado original.

3.6.8 Auditoría de solapamiento con Derm1M

La auditoría caracteriza el solapamiento entre los *splits* de test contrastados y el dataset de preentrenamiento Derm1M. Cada imagen se reduce a su hash MD5 mediante la biblioteca estándar de Python; la intersección entre los conjuntos de hashes determina las imágenes presentes simultáneamente en ambos datasets. La cardinalidad se reporta por dataset en el capítulo 4. Los doce datasets externos se auditan, con la excepción de SkinCon (no evaluado sobre clases diagnósticas).

3.7 Métricas

Clasificación. *Balanced Accuracy* (BAcc, promedio de *recall* por clase) es la métrica principal en escenarios desbalanceados. La *accuracy* se reporta como referencia comparativa entre modelos sobre la misma distribución de clases. La F1 ponderada se calcula como media armónica de precisión y *recall* ponderada por la frecuencia de cada clase. La AUROC se calcula con estrategia *one-vs-rest* (`multi_class='ovr'` en `scikit-learn`) y promedio sobre clases. El coeficiente kappa de Cohen corrige la concordancia por azar. *Recall@k* mide la presencia de la etiqueta verdadera entre las *k* primeras posiciones del ranking; se reporta específicamente para la clase melanoma sobre HAM10000.

Segmentación. Coeficiente Dice $\text{DSC} = 2|P \cap G|/(|P| + |G|)$ e intersección sobre unión $\text{IoU} = |P \cap G|/|P \cup G|$, donde *P* es la máscara predicha y *G* la de referencia.

Equidad. BAcc por subgrupo Fitzpatrick (I-VI) sobre la formulación de tres clases de malignidad, y *gap* $\text{Gap}_{\text{I} \rightarrow \text{VI}} = \text{BAcc}_{\text{I}} - \text{BAcc}_{\text{VI}}$. Valores próximos a cero indican rendimiento comparable entre fototipos extremos; la interpretación requiere considerar la BAcc global, ya que un *gap* pequeño asociado a una BAcc también pequeña reflejaría un modelo uniformemente inferior, no equitativo en sentido sustantivo.

Operativas. Latencia por consulta en milisegundos (inferencia más posproceso) y huella de memoria (VRAM en gigabytes en BF16), medidas sobre la infraestructura descrita en sección 3.5.

3.8 Pruebas estadísticas

Para los contrastes principales entre modelos sobre un mismo conjunto de test se reportan intervalos de confianza al 95% obtenidos mediante *bootstrap* sobre 1000 remuestreos del conjunto de evaluación. Las comparaciones de AUROC entre dos modelos sobre el mismo conjunto se evalúan mediante el test de DeLong [32], que controla la correlación inducida por la evaluación sobre el mismo conjunto. **[NO ESPECIFICADO: confirmar si se aplicará corrección por comparaciones múltiples y el método elegido (Bonferroni, Benjamini-Hochberg).]** Los tamaños muestrales por subgrupo en el experimento de equidad se reportan junto a las cifras correspondientes en el capítulo 4.

3.9 Trazabilidad y reproducibilidad

Las semillas aleatorias se fijan a 0 para `torch`, `numpy` y `random` en los protocolos de *fine-tuning* y segmentación, y a 42 en el parámetro `random_state` para los basados en `scikit-learn` (sondeo lineal, eficiencia en etiquetas, equidad). El entorno de ejecución queda fijado en las versiones de software declaradas en sección 3.5; cualquier desviación se documenta explícitamente en el experimento correspondiente. La variable `WANDB_MODE` se fija a `disabled` para impedir el envío de telemetría a servicios externos durante el entrenamiento. La variable `CUDA_VISIBLE_DEVICES` se fija a 0 para forzar la ejecución sobre la única GPU presente. Los resultados numéricos se vuelcan a archivos CSV o JSON con esquema estable, lo que permite la reconstrucción de cualquier tabla o figura del capítulo 4 sin reejecución. Los mapeos de etiquetas nativas a la ontología L1/L2/L3 se mantienen fijos a través de los experimentos. Cuando un experimento emplea como entrada el resultado de otro (por ejemplo, los *embeddings* extraídos en sondeo lineal alimentan la rama visual de zero-shot), la identidad de la entrada se preserva mediante hash MD5 sobre el fichero correspondiente. El listado completo de tareas reproducibles, sus comandos de ejecución, ficheros de salida y *checkpoints* de modelo se documenta en el Anexo A.

CAPÍTULO 4

RESULTADOS

4.1 Reproducción de PanDerm: sondeo lineal sobre diez datasets

La tabla 4.1 reporta el sondeo lineal con PanDerm Base y Large sobre los diez datasets externos contrastados, conforme al protocolo descrito en sección 3.6.1. Las cinco métricas reportadas son *accuracy* (Acc), *balanced accuracy* (BAcc), AUROC *one-vs-rest*, F1 ponderada (W-F1) y coeficiente kappa de Cohen.

4. RESULTADOS

Cuadro 4.1: Sondeo lineal con PanDerm Base y Large sobre diez datasets externos. El asterisco (*) marca datasets con solapamiento documentado frente a Derm1M (sección 4.9). Mejores valores por dataset y métrica en negrita.

Dataset	Modelo	Acc	BAcc	AUROC	W-F1	Kappa
HAM10000	Base	0,853	0,381	0,892	0,829	0,709
HAM10000	Large	0,888	0,575	0,954	0,880	0,814
BCN20000	Base	0,659	0,292	0,855	0,615	0,447
BCN20000	Large	0,702	0,382	0,903	0,676	0,527
PAD-UFES-20	Base	0,725	0,510	0,913	0,692	0,369
PAD-UFES-20	Large	0,772	0,642	0,949	0,760	0,527
Dermnet*	Base	0,450	0,381	0,888	0,432	0,437
Dermnet*	Large	0,550	0,495	0,931	0,540	0,555
WSI patches	Base	0,781	0,640	0,976	0,774	0,842
WSI patches	Large	0,868	0,792	0,991	0,871	0,896
DDI	Base	0,847	0,714	0,827	0,836	0,482
DDI	Large	0,847	0,764	0,860	0,846	0,535
Derm7pt clín.	Base	0,762	0,675	0,808	0,736	0,397
Derm7pt clín.	Large	0,798	0,732	0,869	0,784	0,506
Derm7pt dermo	Base	0,818	0,749	0,841	0,811	0,528
Derm7pt dermo	Large	0,836	0,766	0,858	0,829	0,570
HIBA*	Base	0,883	0,595	0,894	0,853	0,275
HIBA*	Large	0,904	0,701	0,942	0,892	0,494
MSKCC*	Base	0,721	0,654	0,746	0,720	0,309
MSKCC*	Large	0,746	0,644	0,751	0,732	0,316
<i>Media</i>	Base	0,750	0,559	0,865	0,730	—
<i>Media</i>	Large	0,791	0,649	0,901	0,781	—

PanDerm Large supera a PanDerm Base en accuracy, AUROC y F1 ponderada sobre los diez datasets, con mejora media absoluta de +4,1 pp en accuracy, +9,0 pp en BAcc y +3,6 pp en AUROC. La única excepción es la BAcc en MSKCC, donde Base obtiene 0,654 frente a 0,644 de Large (−1,0 pp). La mejora absoluta es mayor sobre Dermnet (+10,0 pp accuracy), WSI patches (+8,7 pp) y PAD-UFES-20 (+4,7 pp), datasets con mayor número de clases o mayor heterogeneidad de adquisición. La modalidad con mejor rendimiento absoluto es la histopatología (WSI patches: Acc 0,868, AUROC 0,991, kappa 0,896). Los tres datasets marcados con asterisco (Dermnet, HIBA, MSKCC) presentan solapamiento con Derm1M; su interpretación se discute en sección 4.9.

4.2. Benchmark comparativo entre familias




Figura 4.1: Sondeo lineal con PanDerm Base y Large sobre los diez datasets externos contrastados. Diferencia absoluta en BAcc (+9,0 pp de promedio) y AUROC (+3,6 pp de promedio) a favor de PanDerm Large.

4.2 Benchmark comparativo entre familias

La tabla 4.2 compara cinco modelos representativos de tres familias (encoder específico de dominio, encoder generalista auto-supervisado y arquitecturas convolucionales preentrenadas en ImageNet) sobre HAM10000, PAD-UFES-20 y DDI bajo el mismo protocolo de sondeo lineal.

Cuadro 4.2: Benchmark comparativo bajo sondeo lineal sobre HAM10000, PAD-UFES-20 y DDI. Mejor valor por columna en negrita.

Modelo	Tipo	Params	HAM Acc	HAM AUROC	PAD Acc	PAD AUROC	DDI AUROC
ConvNeXt-Large	ConvNet sup.	197 M	0,883	0,967	0,668	0,894	0,774
EfficientNetV2-Large	ConvNet sup.	118 M	0,860	0,950	0,690	0,895	0,766
DINOv2 ViT-L/14	SSL general	307 M	0,744	0,847	—	—	—
PanDerm Large	SSL derm.	307 M	0,888	0,954	0,772	0,949	0,860
SigLIP-Large SO400M	Vis-leng. gen.	400 M	0,900	0,971	0,718	0,903	0,793

La tabla 4.3 cuantifica la ventaja de PanDerm Large sobre la mejor CNN supervisada en cada dataset.

Cuadro 4.3: PanDerm Large frente a la mejor CNN supervisada (la mejor de ConvNeXt-L y EfficientNetV2-L para cada métrica).

Dataset	CNN Acc	PanDerm Acc	Δ Acc (pp)	CNN AUROC	PanDerm AUROC	Δ AUROC (pp)
HAM10000	0,883	0,888	+0,5	0,967	0,954	-1,3
PAD-UFES-20	0,690	0,772	+8,2	0,895	0,949	+5,4
DDI	0,818	0,847	+2,9	0,774	0,860	+8,6

PanDerm Large supera a la mejor CNN supervisada en accuracy sobre los tres datasets, con margen creciente conforme aumenta la dificultad: +0,5 pp en HAM10000 (dermatoscopia estandarizada), +8,2 pp en PAD-UFES-20 (fotografía clínica con dispositivo móvil) y +2,9 pp en DDI (fotografía clínica con representación equilibrada de fototipos). En AUROC el patrón es similar excepto en HAM10000, donde ConvNeXt-Large (0,967)

4. RESULTADOS

supera a PanDerm Large por 1,3 pp. SigLIP-Large SO400M, modelo vision-lenguaje generalista, alcanza la mejor accuracy y AUROC en HAM10000 (0,900/0,971), comportamiento consistente con la sobrerrepresentación de dermatoscopia estandarizada en su preentrenamiento sobre web. PanDerm Large domina en PAD-UFES-20 y DDI, datasets clínicos con mayor distancia respecto a los corpus web generalistas.




Figura 4.2: Benchmark comparativo bajo sondeo lineal sobre HAM10000, PAD-UFES-20 y DDI. ConvNeXt-Large supera a PanDerm Large en AUROC sobre HAM10000 (−1,3 pp); PanDerm Large domina sobre PAD-UFES-20 (+8,2 pp Acc) y DDI (+8,6 pp AUROC).

4.3 Ajuste fino supervisado

La tabla 4.4 compara el sondeo lineal y el ajuste fino supervisado con PanDerm Base sobre cuatro datasets, con la configuración descrita en sección 3.6.2. Sobre HAM10000 se aplica adicionalmente *test-time augmentation* con cinco aumentaciones deterministas.

Cuadro 4.4: Sondeo lineal (LP) frente a ajuste fino (FT) con PanDerm Base. Δ Bacc en puntos porcentuales respecto al LP.

Dataset	Modo	Acc	Bacc	AUROC	W-F1	Δ Bacc
HAM10000	LP	0,853	0,381	0,892	0,829	—
HAM10000	FT	0,920	0,852	0,978	0,923	+47,1
PAD-UFES-20	LP	0,725	0,510	0,913	0,692	—
PAD-UFES-20	FT	0,755	0,704	0,935	0,757	+19,4
DDI	LP	0,847	0,714	0,827	0,836	—
DDI	FT	0,774	0,693	0,682	0,780	−2,1
MSKCC	LP	0,721	0,654	0,746	0,720	—
MSKCC	FT	0,731	0,684	0,719	0,735	+3,0

El ajuste fino aumenta sustancialmente la Bacc en HAM10000 (+47,1 pp) y PAD-UFES-20 (+19,4 pp). El incremento se atribuye al aprendizaje de las clases minoritarias (melanoma, *akiec*, *df*, *vasc* en HAM10000), favorecido por el *weighted random sampler* y los regularizadores Mixup y CutMix. Sobre DDI, con $N_{\text{train}} = 427$, el sondeo lineal supera al ajuste fino en todas las métricas, comportamiento compatible con sobreajuste del

encoder ajustado pese a las aumentaciones. Sobre MSKCC ($N_{\text{train}} = 6189$), la mejora de BAcc es marginal (+3,0 pp) y la AUROC desciende ligeramente. Estos dos casos delimitan el régimen de aplicabilidad del ajuste fino: por debajo de aproximadamente 500 imágenes de entrenamiento, el sondeo lineal sobre PanDerm Large constituye una alternativa preferible.




Figura 4.3: Comparación entre sondeo lineal y ajuste fino con PanDerm Base sobre cuatro datasets. El ajuste fino aporta mejoras sustanciales sobre HAM10000 y PAD-UFES-20 (+47,1 pp y +19,4 pp BAcc respectivamente) pero degrada el rendimiento sobre DDI ($N_{\text{train}} = 427$), caso compatible con sobreajuste pese a las aumentaciones.

4.4 Eficiencia en etiquetas

La tabla 4.5 reporta el rendimiento de PanDerm Large mediante sondeo lineal con submuestreos estratificados al 1%, 5%, 10%, 20%, 50% y 100% del conjunto de entrenamiento sobre HAM10000 y PAD-UFES-20.

Cuadro 4.5: Eficiencia en etiquetas (sondeo lineal con PanDerm Large). N_{train} : tamaño efectivo del subconjunto de entrenamiento. Mejor valor por columna en negrita.

% entrenam.	N_{train}	Acc	BAcc	AUROC	W-F1
<i>HAM10000</i>					
1%	82	0,850	0,406	0,918	0,828
5%	410	0,870	0,481	0,932	0,855
10%	820	0,875	0,480	0,939	0,863
20%	1641	0,882	0,547	0,951	0,873
50%	4103	0,894	0,589	0,952	0,887
100%	8207	0,888	0,575	0,954	0,880
<i>PAD-UFES-20</i>					
1%	14	0,740	0,599	0,907	0,727
5%	74	0,751	0,632	0,919	0,742
10%	149	0,738	0,593	0,923	0,724
20%	298	0,748	0,587	0,931	0,728
50%	746	0,757	0,611	0,941	0,742
100%	1493	0,772	0,642	0,949	0,760

4. RESULTADOS

Sobre HAM10000, con 1 % del conjunto de entrenamiento (82 imágenes), PanDerm Large recupera 0,850 accuracy y 0,918 AUROC, 3,8 pp y 3,6 pp respectivamente por debajo del rendimiento con el conjunto completo. La curva de AUROC satura tempranamente: con 5 % del conjunto (410 imágenes) se alcanza 0,932 AUROC, equivalente al 97,7 % del rendimiento máximo. La BAcc, en cambio, sigue escalando con el volumen y alcanza su máximo en 50 % (0,589). Sobre PAD-UFES-20, con 14 imágenes de entrenamiento, el modelo alcanza 0,740 accuracy y 0,907 AUROC, 95,5 % del rendimiento de AUROC con el conjunto completo. El comportamiento es consistente con encoders preentrenados sobre corpus masivos del dominio: las representaciones son ya informativas y el clasificador lineal converge con un número reducido de ejemplos.




Figura 4.4: Eficiencia en etiquetas con PanDerm Large sobre HAM10000 y PAD-UFES-20. La curva AUROC satura tempranamente: con 1 % del conjunto de entrenamiento se recupera más del 95 % del rendimiento alcanzable con el conjunto completo en ambos datasets.

4.5 Segmentación binaria de lesión

La tabla 4.6 reporta los resultados de segmentación binaria sobre ISIC2018 con SAM2.1-Large adaptado mediante LoRA, junto a tres referencias: SAM2 sin adaptación (*zero-shot*), *Convolutional AutoEncoder* con backbone PanDerm Large entrenado desde cero (CAE-seg) y la cifra publicada por Yan et al. [1].

Cuadro 4.6: Segmentación binaria de lesión: Dice de test sobre tres datasets dermatoscópicos. Modelos entrenados sobre ISIC2018 y evaluados sin reentrenamiento sobre ISIC2017 y PH2.

Configuración	ISIC2018 Dice	ISIC2017 Dice	PH2 Dice
SAM2 <i>zero-shot</i> (bbox de GT)	—	0,797	0,886
CAE-seg (PanDerm-L) FT ISIC2018	0,894	0,879	0,924
PanDerm [1] (ref.)	0,921	—	—
SAM2.1-L + LoRA FT ISIC2018	0,947	0,945	0,960

La tabla 4.7 amplía la información con la desviación estándar y el IoU sobre los datasets de transferencia.

Cuadro 4.7: Generalización fuera de dominio: Dice e IoU (media $\pm$ desv. estándar) sobre ISIC2017 ($N = 600$) y PH2 ($N = 200$).

Modelo	Dataset	Dice	IoU
SAM2 <i>zero-shot</i> (bbox)	ISIC2017	$0,797 \pm 0,158$	$0,686 \pm 0,183$
SAM2 <i>zero-shot</i> (bbox)	PH2	$0,886 \pm 0,199$	$0,830 \pm 0,198$
SAM2.1-L + LoRA FT ISIC2018	ISIC2017	$0,945 \pm 0,046$	$0,898 \pm 0,065$
SAM2.1-L + LoRA FT ISIC2018	PH2	$0,960 \pm 0,022$	$0,925 \pm 0,039$
CAE-seg (PanDerm-L) FT ISIC2018	ISIC2017	$0,879 \pm 0,139$	$0,803 \pm 0,166$
CAE-seg (PanDerm-L) FT ISIC2018	PH2	$0,924 \pm 0,066$	$0,865 \pm 0,098$

SAM2.1-L con adaptación LoRA alcanza Dice 0,947 sobre ISIC2018, superando en +2,6 pp la cifra publicada por Yan et al. [1] (0,921) y en +5,3 pp al CAE-seg con backbone PanDerm-L. La transferencia fuera de dominio es mínima: Dice desciende sólo 0,002 sobre ISIC2017 (0,947 $\rightarrow$ 0,945) y, sobre PH2, asciende hasta 0,960, comportamiento explicable por la mayor limpieza visual del dataset PH2. El paso de SAM2 sin adaptación a SAM2.1-L con LoRA introduce mejoras de +14,8 pp Dice sobre ISIC2017 (0,797 $\rightarrow$ 0,945) y +7,4 pp sobre PH2 (0,886 $\rightarrow$ 0,960), cuantificando el aporte específico de la adaptación de dominio.




Figura 4.5: Segmentación binaria de lesión. SAM2.1-Large con adaptación LoRA alcanza Dice 0,947 sobre ISIC2018, +2,6 pp sobre el resultado publicado por Yan et al. [1], con transferencia OOD prácticamente nula sobre ISIC2017 (0,945) y PH2 (0,960).

4.6 Clasificación zero-shot multimodal

La tabla 4.8 reporta los resultados de clasificación zero-shot multimodal sobre HAM10000 (7 clases) con tres configuraciones de *prompts* y dos tokenizadores distintos.

4. RESULTADOS

Cuadro 4.8: Zero-shot multimodal sobre HAM10000 ($N_{\text{test}} = 1\,232$, 7 clases). Mejor valor por columna en negrita.

Modelo	Tokenizador	Prompts	Acc	AUROC	F1-macro
DermLIP v1/v2	PubMedBERT	Genéricos	0,086	0,366	0,023
DermLIP v1/v2	PubMedBERT	Derm1M A3	—	0,516	—
DermLIP original	GPT-2/CLIP	Derm1M A3	0,427	0,854	—

El paso de *prompts* genéricos en inglés con tokenizador PubMedBERT al conjunto A3 de Derm1M con tokenizador GPT-2/CLIP eleva la AUROC desde 0,366 hasta 0,854 (+48,8 pp). Los *prompts* genéricos con tokenizador PubMedBERT obtienen AUROC < 0,5, valor compatible con proyección en un espacio no alineado con el del encoder visual de la variante v1/v2. El cambio del conjunto A3 sin cambio de tokenizador eleva AUROC a 0,516, mientras que el cambio de tokenizador manteniendo A3 alcanza 0,854, lo que identifica la compatibilidad del tokenizador con el espacio de *embeddings* como el factor crítico.

La tabla 4.9 reporta la evaluación zero-shot binaria melanoma/no-melanoma sobre DDI, MSKCC, HIBA y Derm7pt clínico con DermLIP v1/v2 y *prompts* genéricos.

Cuadro 4.9: Zero-shot binario melanoma/no-melanoma con DermLIP v1/v2 (*prompts* genéricos).

Dataset	N_{test}	Acc	BAcc	AUROC	F1-macro
DDI	137	0,766	0,499	0,436	0,463
MSKCC	1664	0,716	0,500	0,430	0,417
HIBA	334	0,859	0,497	0,502	0,462
Derm7pt clín.	168	0,589	0,472	0,337	0,439

En la formulación binaria, las cifras de BAcc próximas a 0,500 sobre los cuatro datasets indican que la rama contrastiva opera al nivel del azar, comportamiento esperable dada la sensibilidad documentada al tokenizador. El detalle del análisis extendido sobre sensibilidad a *prompts* y tokenizador se desarrolla en el Anexo G.

4.7. Comparación con modelos de lenguaje multimodales




Figura 4.6: Sensibilidad zero-shot al tokenizador y a la formulación del *prompt* sobre HAM10000. La AUROC oscila entre 0,366 (DermLIP v1/v2 + PubMedBERT + prompts genéricos) y 0,854 (DermLIP original + GPT-2/CLIP + prompts A3 de Derm1M), un rango de 48,8 pp para variaciones que no afectan al encoder visual.

4.7 Comparación con modelos de lenguaje multimodales

La tabla 4.10 reúne la evaluación de seis modelos de lenguaje multimodales sobre HAM10000, PAD-UFES-20 y DDI, junto a los modelos de referencia obtenidos en sección 4.1 y sección 4.3.

Cuadro 4.10: Comparación de paradigmas sobre HAM10000, PAD-UFES-20 y DDI ($N_{\text{test}} = 1232/461/137$). FT: ajuste fino, LP: sondeo lineal, ZS: zero-shot.

Modelo	Modo	HAM Acc	HAM BAcc	PAD Acc	PAD BAcc	DDI Acc	DDI BAcc
PanDerm Base (TTA HAM)	FT	0,920	0,852	0,755	0,704	0,774	0,693
PanDerm Large	LP	0,888	0,575	0,772	0,642	0,847	0,764
SigLIP-Large	LP	0,900	—	0,718	—	0,789	—
MedGemma 27B + LoRA	FT	0,802	0,270	0,430	0,347	0,657	0,618
MedGemma 27B	ZS	0,665	0,243	0,447	0,342	0,474	0,566
GPT-4o	ZS	0,485	0,465	0,553	0,523	0,723	0,648
GPT-4o-mini	ZS	0,256	0,319	0,390	0,435	0,737	0,556
Gemini 2.5 Pro	ZS	0,403	—	0,477	—	0,441	—
Gemini 2.5 Flash	ZS	0,380	—	0,486	—	0,555	—
DermLIP	ZS	0,239	0,581	0,601	—	0,329	—
BLIP-2 (Flan-T5-XL)	ZS	0,015	0,145	0,017	0,167	0,796	0,542
InstructBLIP (Flan-T5-XL)	ZS	0,024	0,123	0,171	0,224	0,788	0,500

La jerarquía de rendimiento sobre HAM10000 se ordena de mayor a menor en: PanDerm Base FT con TTA (0,920 Acc) > SigLIP-Large LP (0,900) > PanDerm Large LP (0,888) > MedGemma 27B con LoRA (0,802) > MedGemma 27B ZS (0,665) > GPT-4o ZS (0,485) > Gemini 2.5 Pro ZS (0,403) > Gemini 2.5 Flash ZS (0,380) > GPT-4o-mini ZS (0,256) > DermLIP ZS (0,239) $\gg$ InstructBLIP/BLIP-2 ZS ($\sim 0,02$). La adaptación con LoRA sobre MedGemma 27B sobre el *split* de entrenamiento de HAM10000 produce mejoras de +13,7 pp Acc sobre HAM10000 y +18,3 pp Acc sobre DDI respecto

4. RESULTADOS

a la variante *zero-shot*, sin mejora apreciable sobre PAD-UFES-20 (−1,7 pp). El coste agregado de la evaluación con APIs comerciales es de aproximadamente \$4,07 entre GPT-4o (~ \$2,71) y GPT-4o-mini (~ \$1,36). MedGemma 27B opera localmente en BF16 sobre los 128 GB de memoria unificada de la DGX Spark sin cuantización adicional, con latencia media de 1,49 segundos por imagen.

La tabla 4.11 muestra el desglose por clase del modelo GPT-4o sobre HAM10000, ilustrando patrones de error asimétricos: la clase *actinic keratosis* obtiene *recall* 0,000 y *dermatofibroma* recibe 284 predicciones positivas frente a 8 muestras reales, en línea con un sesgo hacia categorías menos restringidas en el *prompt* clínico.

Cuadro 4.11: Desglose de *recall* por clase sobre HAM10000 con GPT-4o zero-shot. Predicciones: número total de imágenes asignadas a cada clase por el modelo.

Clase	N_{test}	Predicciones GPT-4o	Recall
actinic keratosis	35	2	0,000
basal cell carcinoma	44	—	0,477
seborrheic keratosis	107	—	0,308
dermatofibroma	8	284	0,750
melanoma	70	299	0,686
melanocytic nevus	951	—	0,505
vascular lesion	17	—	0,529




Figura 4.7: Comparativa de paradigmas sobre HAM10000. Gradiente de 43,5 pp accuracy entre el mejor especialista ajustado (PanDerm Base FT con TTA, 0,920) y el mejor LLM multimodal generalista *zero-shot* (GPT-4o, 0,485). BLIP-2 e InstructBLIP descienden hasta accuracy ~ 0,02.

4.8 Equidad por fototipo cutáneo

La tabla 4.12 reporta el rendimiento global de cinco encoders sobre Fitzpatrick17k completo ($N = 16577$) en las dos formulaciones consideradas: clasificación a 114 patologías (grano fino del dataset) y clasificación a 3 clases de malignidad (benigno / no neoplásico / maligno).

Cuadro 4.12: Equidad sobre Fitzpatrick17k completo. Rendimiento global en las dos formulaciones. Mejor valor por columna en negrita.

Modelo	114 patologías				3 clases malignidad			
	Acc	BAcc	AUROC	W-F1	Acc	BAcc	AUROC	W-F1
PanDerm Large	0,581	0,549	0,968	0,576	0,835	0,699	0,908	0,828
PanDerm Base	0,500	0,478	0,955	0,491	0,819	0,657	0,882	0,807
DermLIP v2 (visual)	0,572	0,549	0,971	0,569	0,852	0,721	0,909	0,846
DINOv2 ViT-L/14	0,519	0,485	0,947	0,516	0,809	0,656	0,854	0,801
BiomedCLIP	0,334	0,321	0,910	0,323	0,799	0,590	0,830	0,776

La tabla 4.13 reporta la BAcc por fototipo Fitzpatrick sobre la formulación de tres clases.

Cuadro 4.13: BAcc por subgrupo Fitzpatrick (3 clases de malignidad) y *gap* entre fototipos extremos. Tamaños muestrales por subgrupo: 299/470/325/261/169/73 para FST I a VI.

Modelo	FST I	FST II	FST III	FST IV	FST V	FST VI	Gap I-VI
PanDerm Large	0,723	0,708	0,743	0,669	0,568	0,506	+0,217
PanDerm Base	0,653	0,693	0,669	0,630	0,585	0,384	+0,269
DermLIP v2 (visual)	0,716	0,730	0,765	0,710	0,693	0,434	+0,281
DINOv2 ViT-L/14	0,673	0,671	0,679	0,654	0,553	0,368	+0,306
BiomedCLIP	0,569	0,602	0,606	0,566	0,590	0,445	+0,124

Los cinco modelos presentan *gap* I-VI positivo, indicando rendimiento inferior sobre fototipos elevados. DermLIP v2 obtiene la mejor BAcc global (0,721 sobre 3 clases) y la mejor AUROC global (0,909), pero su *gap* I-VI (+0,281) es superior al de PanDerm Large (+0,217). BiomedCLIP presenta el *gap* menor (+0,124) pero al precio de una BAcc global inferior (0,590), lo que ilustra el carácter no decisonal del *gap* aislado: un modelo uniformemente peor entre subgrupos puede presentar *gap* bajo sin ser equitativo en sentido sustantivo. La AUROC de PanDerm Large sobre la formulación de 3 clases es 0,908 global, con *gap* AUROC entre fototipos extremos de 0,089 (FST IV: 0,919 vs FST VI: 0,830).

La tabla 4.14 amplía la evaluación con un experimento cruzado *Light* $\leftrightarrow$ *Dark*, donde *Light* agrupa FST I-III y *Dark* agrupa FST IV-VI.

Cuadro 4.14: Evaluación cruzada *Light* $\leftrightarrow$ *Dark* (BAcc, formulación de 3 clases). *L*: *Light*; *D*: *Dark*; *All*: ambos grupos.

Modelo	L→L	L→D	D→D	D→L	All→L	All→D
PanDerm Large	0,699	0,589	0,701	0,667	0,726	0,627
PanDerm Base	0,673	0,557	0,621	0,629	0,673	0,594
DermLIP v2 (visual)	0,729	0,651	0,667	0,683	0,745	0,682
DINOv2 ViT-L/14	0,655	0,523	0,625	0,569	0,682	0,589
BiomedCLIP	0,595	0,532	0,571	0,551	0,594	0,565

4. RESULTADOS

La caída de rendimiento entrenando sólo con fototipos claros y evaluando sobre fototipos oscuros (L→D vs L→L) es mayor en DINOv2 ($\Delta = -0,132$ pp BAcc) y menor en BiomedCLIP ($\Delta = -0,063$ pp). DermLIP v2 mantiene la menor caída Dark→Light vs Dark→Dark ($\Delta = +0,016$ pp), lo que sugiere mayor invariancia de sus representaciones al fototipo cutáneo.




Figura 4.8: Equidad por fototipo Fitzpatrick (formulación de tres clases de malignidad) sobre los cinco encoders evaluados. Los cinco presentan *gap* I-VI positivo (entre +0,124 y +0,306 pp BAcc). Paradoja BiomedCLIP: *gap* mínimo asociado a peor BAcc global, lo que demuestra el carácter no decisonal de la métrica aislada.




Figura 4.9: Evaluación cruzada *Light* ↔ *Dark* sobre Fitzpatrick17k (BAcc en formulación de tres clases). La caída L→D vs L→L cuantifica la pérdida de rendimiento al entrenar sólo con fototipos claros y evaluar sobre fototipos oscuros, máxima en DINOv2 ($\Delta = -0,132$ pp).

4.9 Auditoría de solapamiento con Derm1M

La auditoría por hash MD5 entre los *splits* de test contrastados y la fracción accesible del corpus Derm1M identifica tres datasets con solapamiento documentado: Dermnet, HIBA y MSKCC. **[NO ESPECIFICADO: completar las cardinalidades exactas de la intersección por hash MD5 cuando se ejecute el script de auditoría. Los tres datasets afectados aparecen marcados con asterisco en las tablas 4.1 y 4.2.]**

La presencia de solapamiento no invalida las cifras reportadas en sección 4.1 para PanDerm, DINOv2, ConvNeXt-Large, EfficientNetV2-Large y SigLIP-Large (modelos cuyo preentrenamiento no incluye Derm1M), pero condiciona la interpretación de cualquier cifra zero-shot reportada en sección 4.6 para la familia DermLIP sobre los datasets afectados.

4.10 Ensemble de seguridad para detección de melanoma

Como protocolo auxiliar, se evalúa la combinación de tres clasificadores independientes sobre el *split* de test de HAM10000 ($N = 1\,232$ imágenes, 70 melanomas) en una configuración orientada a maximizar el *recall* de melanoma: M1 (PanDerm Large *fine-tuned* sobre HAM10000), SigLIP-Large SO400M con sondeo lineal sobre los *embeddings* de 1 152 dimensiones, y M7 (clasificador unificado sobre el *merged43* del corpus armonizado, descrito en el Anexo H).

Cuadro 4.15: Ensemble sobre HAM10000 ($N = 1\,232$, 70 melanomas). *Recall top-3*: la clase melanoma aparece entre las tres primeras del ranking. FP mel: falsos positivos melanoma (imágenes no-melanoma marcadas).

Configuración	Acc	BAcc	AUROC	Mel rec. top-1	Mel rec. top-3	FP mel
M1 (PanDerm FT)	0,919	0,813	0,986	0,714 (50/70)	0,971 (68/70)	36
SigLIP-L LP	0,900	0,776	0,971	0,614 (43/70)	0,986 (69/70)	31
Avg M1 + SigLIP	0,917	0,836	0,986	0,686	0,986	32
MaxMel M1 + SigLIP	0,909	0,832	0,985	0,771	1,000	50
OR top-3 M1 + SigLIP	—	—	—	—	1,000 (70/70)	885

La combinación OR *top-3* de M1 y SigLIP alcanza *recall* de melanoma del 100% (70 de 70) sobre el conjunto de test de HAM10000. El análisis de errores identifica que los dos melanomas que M1 no captura en *top-3* (ISIC_0024886.jpg e ISIC_0030360.jpg) sí son capturados por SigLIP, lo que confirma la complementariedad de los *backbones* y motiva la elección del par. M7, evaluado en el subconjunto de 198 imágenes con predicción simultánea de los tres modelos (12 melanomas), no añade melanomas adicionales respecto al par M1+SigLIP, pero su valor se mantiene en escenarios multidataset por su cobertura sobre las 43 clases ontológicas del corpus armonizado.

Tres caveats acompañan la interpretación de este resultado: (i) el *recall* del 100% es *top-3*, no *top-1*; (ii) el tamaño muestral de melanomas es $N = 70$, con intervalos de confianza al 95% amplios; (iii) no existe validación prospectiva sobre cohorte hospitalaria. El resultado se interpreta como prueba de concepto para un escenario de cribado oportunista, no como sustituto del juicio clínico.

4.11 Validación en castellano sobre DermapixelAI 1.0

A diferencia de los datasets externos contrastados en sección 4.1, tres de los cuales presentan solapamiento documentado con Derm1M (sección 4.9), el corpus DermapixelAI 1.0 descrito en el Anexo E es completamente independiente del corpus de preentrenamiento de la familia PanDerm/DermLIP. La auditoría por hash MD5 sobre 507 657 imágenes catalogadas (Derm1M 415 451 ítems, HAM10000, BCN20000, ISIC2017/2018, PH2, PAD-UFES-20, DDI, Dermnet, Fitzpatrick17k, HIBA, MSKCC y Derm7pt) reporta intersección nula: 0 coincidencias sobre las 1 062 imágenes evaluables del corpus. La evaluación reportada en esta sección no está, por tanto, sujeta a la fuga de información caracterizada en sección 4.9.

Se aplica el protocolo de sondeo lineal descrito en sección 3.6.1 sobre las 1 062 imágenes con `label_source=ontology` y `ontology_l1` no vacío, particionadas en train ($N = 874$), validación ($N = 152$) y test ($N = 36$). PanDerm Base (768-D) y PanDerm Large (1024-D) operan como extractores congelados; la cabeza es un clasificador *LogisticRegression* con solver L-BFGS, $C = 1,0$ y `max_iter = 5000`. Los intervalos de confianza al 95 % se calculan por *bootstrap* estratificado por clase con 1 000 remuestreos. La evaluación L2 se reporta sobre las 38 subcategorías clínicas efectivamente representadas en el corpus tras consolidar las dos variantes ortográficas de *Trastornos de la queratinización* (Anexo C, sección C.6), de las 43 entradas del vocabulario ontológico original.

Cuadro 4.16: Sondeo lineal con PanDerm Base y Large sobre DermapixelAI 1.0 en los tres niveles de la ontología jerárquica ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$ en L1/L2 y $N_{\text{test}} = 28$ en L3 tras filtrar clases ausentes en train). Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos). Mejor valor por columna y nivel en negrita.

Nivel	Modelo	Acc	BAcc	AUROC	W-F1	Kappa
L1 (4 clases)	Base	0,639 [0,472–0,778]	0,570 [0,371–0,751]	0,697 [0,527–0,841]	0,624 [0,457–0,760]	0,296
L1 (4 clases)	Large	0,750 [0,639–0,861]	0,735 [0,637–0,835]	0,796 [0,656–0,930]	0,722 [0,596–0,845]	0,520
L2 (38 clases)	Base	0,222 [0,139–0,333]	0,221 [0,147–0,294]	0,707 [0,666–0,747]	0,212 [0,092–0,302]	0,170
L2 (38 clases)	Large	0,250 [0,167–0,333]	0,265 [0,206–0,338]	0,793 [0,749–0,837]	0,223 [0,139–0,291]	0,199
L3 (224 clases)	Base	0,143 [0,107–0,179]	0,132 [0,105–0,158]	0,735 [0,693–0,779]	0,107 [0,064–0,141]	0,112
L3 (224 clases)	Large	0,179 [0,143–0,214]	0,184 [0,158–0,211]	0,813 [0,769–0,856]	0,143 [0,100–0,184]	0,154

PanDerm Large supera a PanDerm Base en las cinco métricas y en los tres niveles. La mejora en AUROC es de +9,9 pp en L1 ($0,697 \rightarrow 0,796$), +8,6 pp en L2 ($0,707 \rightarrow 0,793$) y +7,8 pp en L3 ($0,735 \rightarrow 0,813$). La mejora en BAcc es de +16,5 pp en L1, +4,4 pp en L2 y +5,2 pp en L3. La cifra L1 BAcc = 0,735 IC95 % [0,637–0,835] se sitúa dentro del rango reportado para PanDerm Large bajo sondeo lineal sobre los diez datasets de la tabla 4.1 (BAcc entre 0,382 y 0,792), lo que ubica DermapixelAI 1.0 como un *benchmark* exigente en castellano sin dependencia de marcas dermatoscópicas estandarizadas. Frente al azar (BAcc esperada de 0,25/0,026/0,004 para L1/L2/L3), PanDerm Large multiplica el rendimiento por $2,9 \times / 10,2 \times / 40,9 \times$.

Subestudio *rosa_verified*: imágenes verificadas por la dermatóloga

Se compara el sondeo lineal restringido a las imágenes verificadas por la Dra. R. Taberner (`rosa_verified=True`, $N = 919$, train = 744, test = 32) frente al corpus completo

(all_verified, $N = 1062$, train = 874, test = 36). La tabla 4.17 reporta los resultados sobre los tres niveles ontológicos.

Cuadro 4.17: Subestudio *rosa_verified*: comparación entre el subconjunto verificado caso a caso por la dermatóloga ($N_{\text{train}} = 744$, $N_{\text{test}} = 32$) y el corpus completo ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$). Entre corchetes, IC95 % por *bootstrap* estratificado.

Modelo	Subconjunto	Nivel	Acc	BAcc	W-F1
PanDerm Large	<i>rosa_true_only</i>	L1	0,719 [0,594–0,844]	0,747 [0,646–0,865]	0,700 [0,550–0,841]
PanDerm Large	<i>all_verified</i>	L1	0,750 [0,639–0,861]	0,735 [0,637–0,835]	0,722 [0,596–0,845]
PanDerm Large	<i>rosa_true_only</i>	L2	0,250 [0,188–0,344]	0,250 [0,203–0,313]	0,227 [0,150–0,304]
PanDerm Large	<i>all_verified</i>	L2	0,250 [0,167–0,333]	0,265 [0,206–0,338]	0,223 [0,139–0,291]
PanDerm Large	<i>rosa_true_only</i>	L3	0,167 [0,167–0,167]	0,176 [0,176–0,176]	0,125 [0,117–0,139]
PanDerm Large	<i>all_verified</i>	L3	0,179 [0,143–0,214]	0,184 [0,158–0,211]	0,143 [0,100–0,184]
PanDerm Base	<i>rosa_true_only</i>	L1	0,625 [0,469–0,781]	0,523 [0,326–0,735]	0,618 [0,451–0,773]
PanDerm Base	<i>all_verified</i>	L1	0,639 [0,472–0,778]	0,570 [0,371–0,751]	0,624 [0,457–0,760]

Los intervalos de confianza al 95 % se solapan en todos los pares de comparación, por lo que la diferencia entre evaluar sobre el subconjunto verificado caso a caso y el corpus completo no es estadísticamente significativa al tamaño muestral disponible. La imputación etiológica derivada de la ontología (label_source=ontology) sobre las 170 imágenes no revisadas individualmente por la dermatóloga no introduce degradación apreciable sobre las métricas reportadas, lo que respalda operativamente el flujo de etiquetado descrito en el Anexo E.

Cabezas alternativas sobre embeddings congelados

Sobre los mismos *embeddings* de PanDerm Large utilizados en la tabla 4.16 se evalúan tres cabezas adicionales: k -vecinos más cercanos con distancia coseno ($k = 10$, valor óptimo dentro de $k \in \{1, 5, 10\}$), perceptrón multicapa con una capa oculta de 512 unidades y *dropout* 0,3 (MLP 512), y regresión logística con *class_weight*=‘balanced’ (LogReg *balanced*). El protocolo de partición es el del split fijo de la tabla 4.16 ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). La tabla 4.18 recoge la AUROC *one-vs-rest*, métrica discriminativa robusta al desbalance, como criterio comparativo.

Cuadro 4.18: Cabezas alternativas sobre *embeddings* congelados de PanDerm Large (test fijo de DermapixelAI 1.0). AUROC *one-vs-rest* por nivel ontológico. LP: regresión logística estándar (referencia tabla 4.16); kNN $k = 10$: k -vecinos con distancia coseno; MLP 512: perceptrón multicapa con 512 unidades ocultas y *dropout* 0,3; LogReg *balanced*: regresión logística con *class_weight* = *balanced*. Mejor valor por nivel en negrita.

Cabeza	L1 (4 cls)	L2 (38 cls)	L3 (224 cls)
LP (referencia)	0,796	0,793	0,813
kNN $k = 10$	0,752	0,698	0,694
MLP 512	0,817	0,812	0,827
LogReg <i>balanced</i>	0,797	0,800	0,810

El MLP de 512 unidades alcanza la mejor AUROC sobre los tres niveles, con incrementos modestos pero consistentes sobre la cabeza lineal de referencia: +2,1 pp en L1 (0,796 $\rightarrow$ 0,817), +1,9 pp en L2 (0,793 $\rightarrow$ 0,812) y +1,4 pp en L3 (0,813 $\rightarrow$ 0,827). La

regresión logística con re-ponderación de clases mantiene Acc@1 idéntico al LP estándar y mejora la BAcc sobre L1 (0,703 frente a 0,735 del LP estándar dentro de los IC95 % solapados), sin diferencias relevantes sobre L2 y L3. La cabeza k -NN queda por debajo de las cabezas paramétricas en los tres niveles, lo que se interpreta como insuficiente densidad local en el espacio de *embeddings* para $N_{\text{train}} = 874$ frente a un vocabulario de 224 clases L3. La elección de la regresión logística estándar como cabeza primaria en la tabla 4.16 se mantiene defendible: la mejora absoluta del MLP no compensa la pérdida de interpretabilidad lineal de los coeficientes ni la mayor sensibilidad a la inicialización aleatoria, especialmente con el tamaño muestral del test.

Función de pérdida: Cross-Entropy frente a Focal

La cola larga severa del corpus, particularmente acusada en el nivel L3 (77 % de las clases con ≤ 5 ejemplos de entrenamiento, 3,9 muestras por clase de media en *train*, ver Anexo C), motiva contrastar la pérdida de entropía cruzada estándar con *Focal Loss* de Lin et al. 2017, diseñada explícitamente para mitigar el efecto del desbalance reduciendo el peso de los ejemplos fáciles vía el factor $(1 - p_t)^\gamma$. Sobre los *embeddings* congelados de PanDerm Large del split fijo de la tabla 4.16 se reentrena la cabeza lineal con *Focal Loss* bajo dos parámetros de focalización ($\gamma \in \{1,0, 2,0, 5,0\}$) y dos regímenes de ponderación de clase (`class_weight` = None frente a `class_weight` = `balanced`), optimizada con LBFGS y evaluada sobre el mismo conjunto de test que el sondeo lineal estándar. La tabla 4.19 reporta la mejor variante por nivel junto a las dos referencias previas (LP CE estándar, LogReg *balanced*) de la tabla 4.18.

Cuadro 4.19: Función de pérdida sobre *embeddings* congelados de PanDerm Large (test fijo de DermapixelAI 1.0, $N_{\text{test}} = 36$ en L1/L2 y $N_{\text{test}} = 28$ en L3). LP CE: regresión logística con entropía cruzada estándar (referencia tabla 4.16); LogReg *balanced*: re-ponderación inversa por frecuencia de clase (tabla 4.18); *Focal* γ : pérdida focal sin re-ponderación con parámetro de focalización indicado. Mejor valor por columna y nivel en negrita.

Nivel	Pérdida	Acc@1	BAcc	AUROC
L1 (4 cls)	LP CE (referencia)	0,750	0,735	0,796
L1 (4 cls)	LogReg <i>balanced</i>	0,694	0,703	0,797
L1 (4 cls)	<i>Focal</i> $\gamma = 2,0$	0,778	0,768	0,800
L2 (38 cls)	LP CE (referencia)	0,250	0,265	0,793
L2 (38 cls)	LogReg <i>balanced</i>	0,250	0,265	0,800
L2 (38 cls)	<i>Focal</i> $\gamma = 2,0$	0,278	0,324	0,778
L2 (38 cls)	<i>Focal</i> $\gamma = 5,0$	0,278	0,324	0,793
L3 (224 cls)	LP CE (referencia)	0,143	0,132	0,813
L3 (224 cls)	<i>Focal</i> $\gamma = 2,0$	0,143	0,132	0,771

Tres hallazgos cuantitativos estructuran la interpretación. *Primero*, *Focal Loss* con $\gamma = 2,0$ y sin re-ponderación de clase supera marginalmente a la entropía cruzada estándar sobre L1 (+2,8 pp Acc@1, +3,3 pp BAcc, +0,4 pp AUROC) y sobre L2 (+2,8 pp Acc@1, +5,9 pp BAcc), pero degrada la AUROC L2 en -1,5 pp (0,793 $\rightarrow$ 0,778). *Segundo*, la combinación de *Focal Loss* con `class_weight` = `balanced` no aporta sobre la variante sin re-ponderación: el factor $(1 - p_t)^\gamma$ modula ya el peso de los ejemplos según su dificultad y la re-ponderación adicional no añade información discriminativa. *Tercero*, sobre L3 ningún ajuste de la función de pérdida mejora a la entropía cruzada

estándar: tanto Acc@1 como BAcc permanecen idénticos (0,143 y 0,132) y la AUROC desciende $-4,2$ pp (0,813 $\rightarrow$ 0,771). Como en el caso del FT denso (sección 4.11), la cola larga estructural del nivel L3 no admite mitigación mediante modificación de la función de pérdida sobre el corpus actual.

El patrón observado es análogo al documentado en el aumento en tiempo de inferencia (TTA, sección 4.11): *Focal Loss* desplaza el régimen Acc@1/BAcc-AUROC favoreciendo la primera dimensión sobre la segunda, pero no resuelve el cuello de botella estructural impuesto por la cardinalidad y la cola larga del corpus. La elección del LP CE estándar como cabeza primaria de la tabla 4.16 se mantiene defendible: la mejora de *Focal Loss* sobre L1 y L2 está dentro de los IC95 % solapados y no compensa la pérdida de interpretabilidad probabilística calibrada de la entropía cruzada estándar.

Aumento en tiempo de inferencia

La sección 4.10 documenta la aplicación de *Test-Time Augmentation* (TTA) sobre el clasificador M1 (PanDerm Large *fine-tuned*) del servidor de inferencia, con un patrón de cinco aumentaciones deterministas (original, simetría horizontal, simetría vertical, rotación de 90° y rotación de 270° , omitiendo la rotación de 180°). El presente experimento replica el protocolo sobre la cabeza lineal entrenada sobre los *embeddings* de PanDerm Large del corpus DermapixelAI 1.0: para cada imagen de test se extraen los cinco *embeddings* correspondientes a las cinco aumentaciones, cada uno se evalúa con la cabeza lineal entrenada sobre el conjunto de *train* original y las cinco distribuciones de probabilidad se promedian antes del *argmax* final. La tabla 4.20 compara el sondeo lineal sin TTA (referencia tabla 4.16) frente al sondeo lineal con TTA sobre los tres niveles ontológicos.

Cuadro 4.20: Sondeo lineal con PanDerm Large sobre DermapixelAI 1.0: referencia sin TTA frente a TTA con cinco aumentaciones deterministas (original, simetría horizontal, simetría vertical, rotación 90° , rotación 270°). Promedio de probabilidades sobre las cinco aumentaciones antes del *argmax*. Mejor valor por par en negrita.

Nivel	Modo	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	LP	0,750	0,944	0,735	0,796
L1 (4 cls)	LP + TTA	0,694	1,000	0,703	0,779
L2 (38 cls)	LP	0,250	0,278	0,265	0,793
L2 (38 cls)	LP + TTA	0,222	0,500	0,250	0,787
L3 (224 cls)	LP	0,179	0,214	0,184	0,813
L3 (224 cls)	LP + TTA	0,179	0,250	0,184	0,807

El patrón es consistente sobre los tres niveles ontológicos: TTA degrada Acc@1, BAcc y AUROC en magnitudes pequeñas ($-5,6$, $-2,8$ y $0,0$ pp Acc@1 sobre L1, L2 y L3 respectivamente; $-3,2$, $-1,5$ y $0,0$ pp BAcc; $-1,7$, $-0,6$ y $-0,6$ pp AUROC) y mejora sistemáticamente Acc@3 ($+5,6$ pp en L1 hasta alcanzar 1,000, $+22,2$ pp en L2 y $+3,6$ pp en L3). El comportamiento es coherente con la observación reportada en sección 4.10 para M1 sobre HAM10000, donde TTA produce $-2,6$ pp BAcc y $+4,3$ pp *recall* de melanoma. La interpretación es que el promediado sobre cinco aumentaciones suaviza la distribución de probabilidad y reduce la confianza en la clase *argmax* pero distribuye masa de probabilidad entre clases visualmente cercanas, lo que penaliza la precisión *top-1* y mejora el conjunto *top-3*. PanDerm Base presenta la misma dirección de efecto

4. RESULTADOS

(cifras completas en el material reproducible). La recomendación operativa derivada es que TTA es preferible en escenarios de cribado con presentación *top-k* de diagnósticos diferenciales al clínico (Acc@3 L2 = 0,500 frente a 0,278 sin TTA), y el sondeo lineal sin TTA es preferible para decisiones automatizadas *top-1*.

Combinación de codificadores (*ensemble*)

La sección 4.10 documenta la combinación de M1 (PanDerm Large *fine-tuned*) y SigLIP-Large bajo sondeo lineal sobre HAM10000 con orientación a maximizar el *recall* de melanoma. La presente subsección extiende esta línea sobre el corpus DermapixelAI 1.0 y evalúa la combinación de los tres codificadores fundacionales pre-entrenados disponibles en el trabajo, operados como extractores congelados de *embeddings*: PanDerm Base (768 d), PanDerm Large (1024 d) y DermLIP v2 (512 d). Sobre los *embeddings* ya cacheados de PanDerm Base y Large (tabla 4.16) y los *embeddings* de DermLIP v2 extraídos sobre las 1062 imágenes evaluables del corpus, se entrena una cabeza de regresión logística independiente por codificador con el protocolo de sección 3.6.1 y se evalúan cinco estrategias de combinación: (i) promedio de las tres distribuciones de probabilidad (avg de 3), (ii) promedio restringido a PanDerm Large y DermLIP v2 (avg L+D), (iii) máximo por clase entre los tres codificadores (máx 3), (iv) apilado (*stacking*) con meta-cabeza de regresión logística sobre las probabilidades concatenadas (stack 3) y (v) LP individual por codificador como referencia. La tabla 4.21 reporta los resultados sobre los tres niveles ontológicos en el mismo conjunto de test fijo de la tabla 4.16.

Cuadro 4.21: Combinación de codificadores sobre DermapixelAI 1.0. LP individual sobre PanDerm Base, PanDerm Large y DermLIP v2; tres estrategias de combinación: promedio Large+DermLIP, máximo por clase entre los tres, y apilado con meta-cabeza. Mejor valor por columna y nivel en negrita.

Nivel	Estrategia	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	LP PanDerm Base	0,639	—	0,570	0,697
L1 (4 cls)	LP PanDerm Large	0,750	1,000	0,735	0,796
L1 (4 cls)	LP DermLIP v2	0,694	1,000	0,680	0,789
L1 (4 cls)	Avg L+D	0,750	1,000	0,702	0,817
L1 (4 cls)	Avg 3	0,722	1,000	0,694	0,811
L1 (4 cls)	Máx 3	0,694	1,000	0,652	0,805
L1 (4 cls)	Stack 3	0,694	1,000	0,703	0,790
L2 (38 cls)	LP PanDerm Base	0,222	—	0,221	0,707
L2 (38 cls)	LP PanDerm Large	0,250	0,500	0,265	0,793
L2 (38 cls)	LP DermLIP v2	0,333	0,528	0,279	0,860
L2 (38 cls)	Avg L+D	0,278	0,556	0,279	0,832
L2 (38 cls)	Avg 3	0,278	0,528	0,268	0,821
L2 (38 cls)	Máx 3	0,222	0,528	0,235	0,797
L2 (38 cls)	Stack 3	0,250	0,528	0,258	0,804
L3 (224 cls)	LP PanDerm Base	0,143	—	0,132	0,735
L3 (224 cls)	LP PanDerm Large	0,179	0,286	0,184	0,813
L3 (224 cls)	LP DermLIP v2	0,107	0,214	0,079	0,809
L3 (224 cls)	Avg L+D	0,179	0,250	0,184	0,802
L3 (224 cls)	Avg 3	0,143	0,250	0,152	0,795
L3 (224 cls)	Máx 3	0,143	0,250	0,132	0,780
L3 (224 cls)	Stack 3	0,143	0,250	0,158	0,791

Tres hallazgos cuantitativos estructuran la interpretación. *Primero*, sobre L1 la combinación avg Large+DermLIP v2 mejora la AUROC en +2,1 pp respecto a la mejor cabe-

za individual (LP PanDerm Large, 0,796 $\rightarrow$ 0,817) sin mejorar Acc@1 (se mantiene en 0,750) ni BAcc (0,735 $\rightarrow$ 0,702). El comportamiento es coherente con la literatura sobre *ensembles* probabilísticos: el promedio reduce la varianza del ranking de probabilidades y mejora la métrica discriminativa agregada (AUROC) sin trasladar la mejora a la decisión *top-1* en regímenes con tamaño muestral reducido ($N_{\text{test}} = 36$). *Segundo*, sobre L2 DermLIP v2 individual lidera todas las métricas: +8,3 pp Acc@1 (0,250 $\rightarrow$ 0,333), +1,4 pp BAcc (0,265 $\rightarrow$ 0,279) y, especialmente, +6,7 pp AUROC (0,793 $\rightarrow$ 0,860) respecto a LP PanDerm Large. Ninguno de los *ensembles* mejora el LP individual de DermLIP v2 sobre L2 AUROC; el promedio avg Large+DermLIP queda -2,8 pp por debajo (0,860 $\rightarrow$ 0,832). Este hallazgo es coherente con la sección 4.12, donde DermLIP v2 lideraba también la AUROC L2 en el experimento *zero-shot* (0,794 en inglés frente a 0,655/0,697 de Bio-medCLIP y SigLIP). La lectura conjunta sugiere que el preentrenamiento contrastivo texto-imagen sobre el millón de pares de Derm1M [2] captura la granularidad de subcategoría clínica L2 con mayor fidelidad que el preentrenamiento auto-supervisado puro de la familia PanDerm. *Tercero*, sobre L3 ningún *ensemble* mejora el LP individual de PanDerm Large. La cola larga del nivel (224 clases efectivas, 3,9 muestras por clase de media en *train*) limita la información complementaria que los codificadores aportan entre sí: el codificador con mejor representación lineal de la cola larga (PanDerm Large, AUROC 0,813) domina el comportamiento del *ensemble* sin que las cabezas adicionales aporten señal incremental.

La recomendación operativa derivada de la tabla 4.21 depende del nivel ontológico: sobre L1 conviene el *ensemble* avg Large+DermLIP por su ventaja en AUROC; sobre L2 conviene la cabeza individual de DermLIP v2; sobre L3 conviene la cabeza individual de PanDerm Large. La jerarquía PanDerm Large > PanDerm Base > DermLIP v2 que sostiene la mayor parte de las cifras de sección 4.1 y de la tabla 4.16 no es por tanto uniforme entre niveles: el preentrenamiento contrastivo texto-imagen invierte la jerarquía sobre la subcategoría clínica L2 de un corpus independiente al preentrenamiento.

Ajuste fino parcial del codificador sobre los tres niveles

La sección 4.3 cuantifica el efecto del ajuste fino supervisado (FT) sobre PanDerm Base aplicado a cuatro datasets externos contrastados, con incrementos de hasta +47,1 pp BAcc sobre HAM10000 y +19,4 pp sobre PAD-UFES-20. La presente subsección replica el protocolo sobre DermapixelAI 1.0 al nivel de categoría etiológica L1 (4 clases: patología inflamatoria, infecciosa, tumoral y genodermatosis). El experimento se restringe al nivel L1 por una razón muestral: la cola larga de L3 con 3,9 muestras/clase de media en *train* no soporta FT denso sin saturar el régimen de sobreajuste, mientras que L1 admite la prueba de concepto al menor coste experimental. El encoder es PanDerm Large con las dos últimas capas descongeladas (25,2 M parámetros entrenables, equivalente al 8,3% del total del encoder), seguido de una cabeza *fully-connected* 1024 $\rightarrow$ 4. La receta de optimización es AdamW con tasa de aprendizaje diferenciada (cabeza 10^{-3} , encoder 10^{-5}), *weight decay* 10^{-4} , *batch size* 16, programación coseno con calentamiento de una época y 10 épocas totales. Las augmentaciones de entrenamiento son *RandomResized-Crop*, simetría horizontal, simetría vertical con probabilidad 0,3 y *ColorJitter*. La pérdida es entropía cruzada con `class_weight='balanced'`, requerida por el fuerte desbalance de la clase *Genodermatosis* (8/874 imágenes de *train*). La selección del *checkpoint* se realiza por BAcc máxima sobre validación; el tiempo total de entrenamiento sobre

4. RESULTADOS

NVIDIA DGX Spark GB10 es de 2,4 minutos.

Cuadro 4.22: Curva de entrenamiento del ajuste fino parcial sobre DermapixelAI 1.0 nivel L1 (10 épocas, PanDerm Large con dos últimas capas descongeladas, 25,2 M parámetros entrenables). La fila en negrita marca el *best val checkpoint* seleccionado para la evaluación final.

Época	Loss <i>train</i>	BAcc val.	BAcc test	AUROC test
1	1,32	0,574	0,590	0,681
2	0,99	0,606	0,625	0,722
3	0,87	0,588	0,654	0,717
4	0,79	0,630	0,622	0,715
5	0,74	0,592	0,638	0,709
6	0,69	0,630	0,640	0,715
7	0,64	0,610	0,608	0,719
8–10	0,60–0,63	0,60–0,62	0,59–0,62	~ 0,72

Cuadro 4.23: Métricas finales del ajuste fino parcial sobre DermapixelAI 1.0 nivel L1 evaluadas sobre el conjunto de test ($N_{\text{test}} = 36$) con el *best val checkpoint* (época 4). Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos).

Métrica	Valor	IC95 % <i>bootstrap</i>
Acc@1	0,583	[0,444–0,722]
Acc@3	0,972	[0,917–1,000]
BAcc	0,622	[0,510–0,735]
AUROC	0,715	[0,603–0,830]
W-F1	0,568	[0,421–0,700]
Kappa	0,254	[0,027–0,484]

Tres hallazgos cuantitativos estructuran la interpretación. *Primero*, el ajuste fino parcial mejora la BAcc en +18,2 pp respecto a la cifra de validación cruzada agrupada por caso del sondeo lineal congelado sobre el mismo corpus (BAcc $0,440 \pm 0,058$ en la tabla 4.26 frente a 0,622 con FT). El IC95 % del FT ([0,510–0,735]) se sitúa claramente por encima del intervalo correspondiente al sondeo lineal bajo validación cruzada, lo que confirma que el incremento no es atribuible a la realización muestral del split fijo y que el ajuste fino añade valor real más allá del ruido de partición. *Segundo*, el FT no supera a la combinación lineal de codificadores pre-entrenados *avg_large_dermlip* documentada en la sección 4.11: BAcc 0,622 frente a 0,702 del *ensemble* y AUROC 0,715 frente a 0,817. La interpretación es que, para $N_{\text{train}} = 874$, una combinación lineal de dos codificadores fundacionales congelados rinde competitivamente con el FT parcial denso, lo que sugiere un protocolo híbrido en producción basado en *ensemble* de codificadores pre-entrenados con cabezas ligeras antes que descongelar el encoder. *Tercero*, la curva de entrenamiento (tabla 4.22) muestra que la pérdida de *train* descende monótonamente de 1,32 a 0,60 durante las diez épocas, mientras que la BAcc de validación y de test satura a partir de la época 4 (0,630 y 0,622 respectivamente). El *best val checkpoint* no es el último, patrón sintomático de sobreajuste suave compatible con el régimen de N_{train} reducido y 25 M parámetros entrenables. Sin ampliación del corpus o regularización más fuerte, el FT parcial alcanza un techo bajo sobre L1.

La replicación del mismo protocolo sobre los niveles L2 y L3 cierra el caso del FT denso parcial sobre el corpus. El encoder, las dos últimas capas descongeladas, la receta de optimización y el criterio de selección por mejor BAcc de validación son idénticos a

los de L1; varía únicamente la cabeza supervisada ($1\,024 \rightarrow 37$ para L2, $1\,024 \rightarrow 224$ para L3) y el coste computacional sobre NVIDIA DGX Spark GB10 (suma de los tres niveles inferior a 5 minutos). La tabla 4.24 compara las métricas finales sobre los tres niveles bajo el mismo protocolo.

Cuadro 4.24: Ajuste fino parcial del codificador (PanDerm Large, dos últimas capas descongeladas) sobre los tres niveles ontológicos de DermapixelAI 1.0. Test fijo $N_{\text{test}} = 36$ en L1/L2 y $N_{\text{test}} = 28$ en L3. Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos). Mejor valor por columna en negrita.

Nivel	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	0,583 [0,444–0,722]	0,972 [0,917–1,000]	0,622 [0,510–0,735]	0,715 [0,603–0,830]
L2 (37 cls)	0,250 [0,167–0,333]	0,500 [0,389–0,611]	0,324 [0,265–0,397]	0,852 [0,814–0,888]
L3 (224 cls)	0,179 [0,143–0,214]	0,286 [0,214–0,357]	0,184 [0,158–0,211]	0,804 [0,773–0,835]

Dos hallazgos cuantitativos estructuran la lectura de los tres niveles. El primero se refiere a L2 y se documenta de forma explícita en la tabla 4.25: el FT parcial denso sobre L2 con 25,2 M parámetros entrenables (8,3 % del encoder) alcanza BAcc 0,324 y AUROC 0,852, cifras que el protocolo SpanDerm v0 con adaptación LoRA (sección 4.14) supera con 524 K parámetros entrenables (0,17 % del encoder, 48 veces menos parámetros): BAcc $0,363 \pm 0,007$ (+4,0 pp) y AUROC $0,855 \pm 0,006$ (empate dentro de la desviación estándar entre semillas).

Cuadro 4.25: Comparativa sobre el nivel L2 de DermapixelAI 1.0 entre el sondeo lineal congelado (referencia), el ajuste fino parcial denso con dos últimas capas descongeladas y el protocolo SpanDerm v0 con adaptación LoRA. Mismo conjunto de test ($N_{\text{test}} = 36$, 37–38 clases según consolidación de variantes ortográficas de queratinización descrita en sección 4.14). Mejor valor por columna en negrita.

Protocolo	BAcc L2	AUROC L2	Params entren.
LP test fijo (referencia, tabla 4.16)	0,265	0,793	39 K
FT parcial denso (este trabajo)	0,324	0,852	25,2 M
SpanDerm v0 (LoRA)	0,363 $\pm$ 0,007	0,855 $\pm$ 0,006	524 K

La lectura cuantitativa de la tabla 4.25 refuerza la decisión arquitectónica de SpanDerm v0 documentada en sección 4.14: la adaptación de bajo rango sobre un encoder fundacional congelado supera al ajuste fino denso parcial sobre el mismo encoder bajo un régimen de $N_{\text{train}} = 874$ y cardinalidad L2 moderada. El segundo hallazgo se refiere a L3: el FT denso parcial alcanza BAcc 0,184 y AUROC 0,804 sobre las 224 clases efectivas, cifras que no superan al sondeo lineal congelado sobre el mismo *split* fijo (BAcc 0,184 idéntica, AUROC 0,813, $-0,9$ pp). La cola larga severa del nivel L3 (3,9 muestras por clase de media en *train*, 77 % de las clases con ≤ 5 ejemplos) anula el beneficio del ajuste fino denso: la varianza muestral por clase domina el régimen de entrenamiento, lo que reserva el nivel L3 al protocolo de ranking por prototipos coseno SpanDerm v0 (tabla 4.31) o, alternativamente, a la ampliación del corpus vía banco hospitalario.

La utilidad práctica del ajuste fino parcial sobre DermapixelAI 1.0 queda por tanto condicionada a tres factores. El primero es la ampliación del corpus prevista vía banco hospitalario del HUSLL, recogida como técnica pendiente en la sección 7.5.1. El segundo es la aplicación de técnicas de FT más sofisticadas (adaptación LoRA, regularización con *label smoothing*, *Mixup* y *CutMix*) ya planificadas en el diseño de SpanDerm v0

4. RESULTADOS

referido en la sección 7.5.2 y ejecutadas con resultado favorable en la sección 4.14. El tercero es la naturaleza estructural de la cola larga L3, que limita en términos absolutos el rendimiento alcanzable bajo cualquier protocolo de ajuste denso sobre el corpus actual.

Validación cruzada agrupada por caso

El conjunto de test fijo $N = 36$ utilizado en la tabla 4.16 corresponde a un único *split* publicado del corpus. Para estimar el rendimiento esperado del sondeo lineal congelado con menor dependencia de la realización muestral concreta, se aplica una validación cruzada de cinco *folds* agrupada por *case_id* (*StratifiedGroupKFold* estratificado por L1 sobre el corpus completo de 1 062 imágenes, garantizando que ninguna imagen del mismo caso clínico aparezca simultáneamente en *train* y *test*). Cada *fold* retiene aproximadamente $N \approx 210$ imágenes con representación de las cuatro categorías etiológicas L1 y de la cola larga L2/L3. La tabla 4.26 reporta la media y la desviación estándar sobre los cinco *folds* para PanDerm Large bajo sondeo lineal.

Cuadro 4.26: Validación cruzada agrupada por caso (cinco *folds*, estratificado por L1 sobre *case_id*) con PanDerm Large sobre DermapixelAI 1.0. Cifras: media $\pm$ desviación estándar sobre los cinco *folds*. La cardinalidad L3 reportada aquí (250 clases) corresponde a las clases efectivas en el corpus completo; las tablas anteriores del split fijo (tabla 4.16, tabla 4.18, tabla 4.20, tabla 4.21, tabla 4.23) usan 224 clases L3, las únicas representadas en el split *train*.

Nivel	Acc@1	Acc@3	BAcc	AUROC	W-F1	Kappa
L1 (4 cls)	0,574 $\pm$ 0,029	0,994 $\pm$ 0,004	0,440 $\pm$ 0,058	0,753 $\pm$ 0,054	0,569 $\pm$ 0,025	0,314 $\pm$ 0,035
L2 (38 cls)	0,227 $\pm$ 0,015	0,418 $\pm$ 0,037	0,168 $\pm$ 0,020	0,749 $\pm$ 0,019	0,221 $\pm$ 0,022	0,186 $\pm$ 0,015
L3 (250 cls)	0,124 $\pm$ 0,007	0,232 $\pm$ 0,028	0,108 $\pm$ 0,014	0,800 $\pm$ 0,018	0,124 $\pm$ 0,005	0,110 $\pm$ 0,005

La validación cruzada agrupada por caso reduce la cifra puntual del split fijo y proporciona la estimación robusta del rendimiento esperado de un sondeo lineal congelado sobre DermapixelAI 1.0. La sobrestimación observada en el test fijo respecto a la media de los cinco *folds* es de +29,5 pp BAcc en L1, +9,7 pp en L2 y +7,6 pp en L3, lo que se atribuye a la distribución favorable del split publicado (test sin representación de la categoría etiológica *Genodermatosis* y baja densidad de la cola larga L3). La AUROC, en cambio, se mantiene estable entre las dos estimaciones: 0,796 $\rightarrow$ 0,753 en L1 (−4,3 pp), 0,793 $\rightarrow$ 0,749 en L2 (−4,4 pp) y 0,813 $\rightarrow$ 0,800 en L3 (−1,3 pp), magnitudes muy inferiores a la caída observada sobre BAcc. La cifra defendible como estimación del rendimiento esperado del *transfer learning* congelado sobre el corpus en castellano es la de la tabla 4.26; las cifras del test fijo en la tabla 4.16 se mantienen como referencia del punto operativo del split publicado y como base de la comparación con el experimento *zero-shot* de la sección 4.12, que utiliza el mismo conjunto de test para garantizar la trazabilidad cruzada. El experimento de combinación de codificadores (sección 4.11) confirma además que DermLIP v2 supera a PanDerm Large sobre L2 sin requerir entrenamiento adicional (+6,7 pp AUROC), lo que matiza la jerarquía PanDerm Large > PanDerm Base > DermLIP v2 que se sostiene en los demás niveles ontológicos y en la mayoría de los datasets externos contrastados: la elección del codificador óptimo depende del nivel ontológico evaluado, con *ensemble avg* Large+DermLIP sobre L1,

DermLIP v2 individual sobre L2 y PanDerm Large individual sobre L3. El ajuste fino parcial del codificador (sección 4.11) recupera +18,2 pp BAcc sobre la cifra de validación cruzada del sondeo lineal congelado en el nivel L1, confirmando que el FT añade valor real más allá del ruido del *split* fijo. La combinación de codificadores pre-entrenados (*ensemble avg_large_dermlip*, sección 4.11) supera no obstante al FT parcial en L1 (BAcc 0,702 vs 0,622, AUROC 0,817 vs 0,715), lo que sugiere que para corpus de tamaño moderado el protocolo óptimo combina codificadores múltiples sin descongelar el encoder.

Caveats

Cinco *caveats* acompañan la interpretación de las cifras reportadas en esta sección. *Primero*, el tamaño del conjunto de test ($N = 36$ en L1/L2, $N = 28$ en L3) es reducido, lo que ensancha los intervalos de confianza al 95% y exige cautela sobre las cifras puntuales. *Segundo*, la categoría etiológica *Genodermatosis* no aparece en el conjunto de test de L1 (0/36); la AUROC *one-vs-rest* se promedia sobre las tres clases con soporte y las métricas Acc/BAcc reflejan efectivamente una clasificación de tres clases. *Tercero*, 26 clases de L3 visibles en train no aparecen en test, por lo que el clasificador se entrena sobre ellas pero su discriminación no es evaluable; el tamaño efectivo del test L3 desciende a $N = 28$. *Cuarto*, la cola larga de L3 (224 clases sobre 874 imágenes de entrenamiento, 3,9 muestras/clase de media) limita el rendimiento absoluto alcanzable bajo sondeo lineal y reserva el régimen de ajuste fino o de cabezas jerárquicas como línea futura. *Quinto*, la AUROC *one-vs-rest* resulta sustancialmente más robusta al cambio entre split fijo y validación cruzada agrupada que la accuracy y la BAcc: la caída entre la tabla 4.16 y la tabla 4.26 es de -4,3 pp en L1, -4,4 pp en L2 y -1,3 pp en L3 para AUROC, frente a caídas de -29,5 pp, -9,7 pp y -7,6 pp para BAcc sobre los mismos niveles. La AUROC se interpreta por tanto como métrica primaria de comparación entre configuraciones de *transfer learning* congelado sobre corpus de tamaño moderado.

4.12 Validación *zero-shot* multimodal sobre DermapixelAI 1.0

La sección 4.11 reporta el rendimiento de PanDerm Base y Large bajo sondeo lineal sobre el corpus DermapixelAI 1.0. La sección 4.6 caracteriza el comportamiento *zero-shot* multimodal de la familia DermLIP sobre HAM10000 y la sensibilidad documentada al tokenizador y a la formulación del *prompt*. La presente sección completa ambas líneas con un experimento orientado a cuantificar el rendimiento *zero-shot* sobre el mismo conjunto de test de DermapixelAI 1.0, sin entrenamiento de ninguna cabeza clasificadora, y a contrastar la penalización inducida por la formulación del *prompt* en castellano frente a la formulación equivalente en inglés. El experimento opera sobre el mismo conjunto de test que la sección 4.11 ($N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3 tras filtrar clases ausentes en train), garantizando la trazabilidad cruzada con el sondeo lineal y conservando la garantía de no solapamiento con Derm1M reportada en sección 4.11 y sección 4.9 (0/507657 coincidencias por hash MD5).

Se evalúan tres modelos vision-lenguaje contrastivos: (i) DermLIP v2 (encoder visual PanDerm-base con texto PubMedBERT-256, preentrenado sobre Derm1M); (ii) SigLIP-SO400M (Google, ViT-SO400M-14-384 sobre WebLI, generalista); y (iii) Bio-medCLIP (Microsoft, ViT-B/16 con PubMedBERT-256 sobre PubMed-15M). La predic-

4. RESULTADOS

ción se obtiene como *argmax* sobre la similitud coseno entre la representación visual y un *ensemble* de tres plantillas textuales por nivel ontológico, en castellano y en inglés (*p. ej.*, “una fotografía clínica de {c}”, “una imagen dermatológica de {c}”, “una lesión cutánea de tipo {c}”). Los *embeddings* de las tres plantillas se promedian y re-normalizan antes de la predicción. El nivel L3 se evalúa únicamente en castellano, dado que el vocabulario ontológico no dispone de traducción inglesa validada para sus 224 clases. Los intervalos de confianza al 95 % se calculan por *bootstrap* estratificado sobre 1 000 remuestreos. La tabla 4.27 reporta los resultados.

Cuadro 4.27: Clasificación *zero-shot* multimodal sobre el conjunto de test de Dermapi-xelAI 1.0 ($N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos) para las dos métricas primarias (Acc@1 y AUROC). Las métricas BAcc y Acc@3 se reportan como valor puntual por concisión; los IC95 % correspondientes están disponibles en el material reproducible. L3 se evalúa únicamente en castellano. Mejor valor por columna, nivel e idioma en negrita.

Nivel	Modelo	Lang	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	BiomedCLIP	es	0,389 [0,250–0,528]	0,944	0,375	0,679 [0,562–0,781]
L1 (4 cls)	BiomedCLIP	en	0,389 [0,250–0,528]	0,972	0,324	0,639 [0,524–0,738]
L1 (4 cls)	SigLIP-SO400M	es	0,222 [0,111–0,361]	0,917	0,178	0,650 [0,571–0,735]
L1 (4 cls)	SigLIP-SO400M	en	0,333 [0,194–0,472]	0,889	0,292	0,663 [0,595–0,719]
L1 (4 cls)	DermLIP v2	es	0,361 [0,222–0,500]	0,861	0,379	0,699 [0,600–0,794]
L1 (4 cls)	DermLIP v2	en	0,500 [0,333–0,667]	0,917	0,441	0,709 [0,565–0,841]
L2 (38 cls)	BiomedCLIP	es	0,111 [0,111–0,111]	0,278	0,118	0,647 [0,604–0,688]
L2 (38 cls)	BiomedCLIP	en	0,083 [0,056–0,111]	0,250	0,088	0,655 [0,601–0,713]
L2 (38 cls)	SigLIP-SO400M	es	0,139 [0,139–0,139]	0,250	0,235	0,636 [0,589–0,680]
L2 (38 cls)	SigLIP-SO400M	en	0,194 [0,111–0,278]	0,278	0,221	0,697 [0,640–0,747]
L2 (38 cls)	DermLIP v2	es	0,222 [0,167–0,278]	0,333	0,265	0,762 [0,721–0,805]
L2 (38 cls)	DermLIP v2	en	0,250 [0,194–0,306]	0,417	0,294	0,794 [0,747–0,837]
L3 (224 cls)	BiomedCLIP	es	0,107 [0,036–0,179]	0,214	0,079	0,703 [0,673–0,732]
L3 (224 cls)	SigLIP-SO400M	es	0,071 [0,000–0,143]	0,214	0,053	0,696 [0,667–0,723]
L3 (224 cls)	DermLIP v2	es	0,107 [0,071–0,143]	0,214	0,079	0,740 [0,719–0,763]

Tres hallazgos cuantitativos estructuran la interpretación.

Primero, DermLIP v2 obtiene el mejor o equivalente rendimiento en las cinco columnas métricas sobre los tres niveles ontológicos, con excepción de Acc@3 L1 (BiomedCLIP en castellano e inglés alcanza 0,944 y 0,972 respectivamente, frente a 0,861 y 0,917 de DermLIP v2). La superioridad sistemática es coherente con su preentrenamiento sobre Derm1M, el único corpus de los tres específicamente dermatológico (un millón de pares imagen-texto curados sobre la familia PanDerm) [2]. Sobre L2, DermLIP v2 alcanza AUROC 0,794 en inglés y 0,762 en castellano, magnitudes comparables a la AUROC reportada en sección 4.1 para PanDerm Large bajo sondeo lineal sobre conjuntos clínicos heterogéneos (*p. ej.*, 0,746 sobre MSKCC).

Segundo, la formulación del *prompt* en castellano penaliza el rendimiento de los modelos preentrenados sobre corpus mayoritariamente anglófonos. Sobre L1 Acc@1, DermLIP v2 cae de 0,500 (inglés) a 0,361 (castellano), una pérdida de 13,9 pp; SigLIP-SO400M cae de 0,333 a 0,222 (–11,1 pp). BiomedCLIP, en cambio, mantiene 0,389 en ambos idiomas (*gap* nulo). La interpretación es coherente con la composición de los corpus textuales de preentrenamiento: PubMedBERT incorpora literatura biomédica en inglés con presencia anecdótica de otras lenguas, mientras que WebLI (SigLIP) y Derm1M presentan sesgo aún más marcado hacia contenidos anglófonos. La penaliza-

ción cuantificada motiva la construcción de modelos vision-lenguaje contrastivos con rama textual en castellano, línea futura abierta por el corpus DermapixelAI 1.0.

Tercero, la comparación con el sondeo lineal sobre el mismo conjunto de test (tabla 4.16) cuantifica la brecha entre un sistema entrenado y un sistema *zero-shot*. Sobre L1, PanDerm Large bajo LP alcanza BAcc = 0,735 frente a 0,441 del mejor *zero-shot* (DermLIP v2 en inglés), una diferencia de +29,4 pp a favor del sondeo lineal. Sobre L3, la brecha es de +10,5 pp BAcc (0,184 vs 0,079) y +7,3 pp AUROC (0,813 vs 0,740). El comportamiento se invierte parcialmente sobre L2: LP PanDerm Large obtiene AUROC 0,793 y *zero-shot* DermLIP v2 en inglés alcanza 0,794, un empate efectivo dentro del margen de los intervalos de confianza. La interpretación es relevante: las *features* pre-entrenadas de la familia PanDerm/DermLIP son ya competitivas a nivel de subcategoría clínica L2 sin necesidad de cabeza entrenada, mientras que la discriminación etiológica de grano grueso (L1) y de cola larga diagnóstica (L3) sí requiere un clasificador supervisado. Adicionalmente, Acc@3 sobre L1 oscila entre 0,861 (DermLIP v2 en castellano) y 0,972 (BiomedCLIP en inglés), magnitudes operativamente relevantes para escenarios de cribado en los que el sistema presente las tres categorías etiológicas más probables al clínico antes del juicio diagnóstico.

Caveats

Cuatro *caveats* acompañan la interpretación de las cifras reportadas. *Primero*, el tamaño del conjunto de test ($N = 36$ en L1/L2, $N = 28$ en L3) produce intervalos de confianza al 95 % amplios, lo que exige cautela sobre las diferencias puntuales entre configuraciones cercanas (*p. ej.*, el empate L2 AUROC entre LP PanDerm y *zero-shot* DermLIP v2 no descarta diferencias del orden de unos pocos puntos porcentuales en una réplica con mayor tamaño muestral). *Segundo*, el *ensemble* de tres plantillas textuales por nivel constituye una formulación mínima de *prompt engineering*; la literatura sobre *zero-shot* multimodal emplea típicamente entre diez y ochenta plantillas generadas con asistencia de LLMs, lo que sugiere que las cifras reportadas constituyen una cota inferior del rendimiento alcanzable. *Tercero*, la evaluación L3 únicamente en castellano impide cuantificar la penalización por idioma sobre la cola larga diagnóstica, dado que el vocabulario ontológico no dispone de traducción inglesa validada para sus 224 clases. *Cuarto*, la auditoría sistemática de no solapamiento por hash MD5 documentada en sección 4.9 y reiterada en sección 4.11 garantiza la independencia del corpus de test frente al preentrenamiento de DermLIP v2 sobre Derm1M, condición que aporta validez a la comparación entre modelos sin caveats de fuga de información.

4.13 Cobertura experimental sobre DermapixelAI 1.0

Las secciones precedentes evalúan los codificadores sobre DermapixelAI 1.0 como extractores de *features* congelados con cabezas paramétricas ligeras o clasificación contrastiva *zero-shot*, siguiendo el protocolo estándar de la literatura sobre modelos fundacionales en imagen médica, que prioriza la cuantificación limpia del valor del preentrenamiento sobre datos del dominio sin contaminación por hiperparámetros específicos de ajuste fino. La síntesis de las técnicas de *transfer learning* ejecutadas y pendientes sobre el corpus, junto con la estimación prospectiva de un clasificador desplegable en castellano, se recoge en la sección 7.5.1 del capítulo 7.

4.14 Ajuste fino con LoRA: SpanDerm v0

La sección 4.11 documenta el ajuste fino parcial denso sobre L1, que mejora la BAcc en +18,2 pp sobre la cifra de validación cruzada del sondeo lineal congelado pero no supera al *ensemble* multi-codificador (sección 4.11). La sección 7.5.1 identifica la adaptación de bajo rango (*Low-Rank Adaptation*, LoRA) [31] como línea pendiente de prioridad alta, en línea con el diseño SpanDerm v0 documentado en la sección 7.5.2. La presente sección reporta la ejecución de SpanDerm v0 sobre el nivel L2 (38 clases efectivas tras la consolidación de variantes ortográficas de queratinización ya descrita en la sección 4.11) y el ranking L3 por prototipos sobre las 250 clases efectivas del corpus. La elección de L2 como objetivo de la cabeza supervisada responde a la cardinalidad operativa del nivel (rendimiento clínicamente informativo sin alcanzar el régimen de cola larga extrema de L3, con 3,5 muestras/clase en $N_{\text{train}} = 874$). El ranking L3 sigue la estrategia prevista en el diseño v0: prototipos calculados como la media de las representaciones del conjunto de entrenamiento por clase L3 y predicción por similitud coseno.

Cuadro 4.28: Configuración del protocolo SpanDerm v0 sobre PanDerm Large con adaptación LoRA. Los 524288 parámetros entrenables corresponden a 39 K en la cabeza FC 1024 $\rightarrow$ 38 y 485 K en los ocho módulos LoRA insertados en las capas lineales de los dos últimos bloques de transformer.

Componente	Configuración
Encoder base	PanDerm Large (1024 dim, 303,85 M params, congelado)
LoRA	$r = 16$, $\alpha = 32$, <i>dropout</i> 0,1
Capas adaptadas	<code>blocks.22</code> y <code>blocks.23</code> : <code>attn.qkv</code> , <code>attn.proj</code> , <code>mlp.fc1</code> , <code>mlp.fc2</code> (8 capas)
Cabeza supervisada	FC 1024 $\rightarrow$ 38 (L2 con queratinización consolidada)
Parámetros entrenables	524288 (0,17 % del total)
Optimizador	AdamW, $lr_{\text{head}} = 10^{-3}$, $lr_{\text{LoRA}} = 5 \times 10^{-4}$, $wd = 10^{-4}$
<i>Scheduler</i>	Cosine con <i>warmup</i> de una época
Pérdida	<i>Cross-entropy</i> con <code>class_weight=balanced</code>
<i>Batch size</i>	16
Épocas	15
Augmentaciones <i>train</i>	RandomResizedCrop(0,7–1,0), hflip, vflip ($p = 0,3$), ColorJitter (0,1)
Selección	Mejor BAcc de validación; reporte adicional de la media de las últimas cinco épocas
Semillas	{42, 43, 44}

Las cifras reportadas a continuación corresponden a la media y la desviación estándar sobre las tres semillas ({42, 43, 44}). La tabla 4.29 reporta las dos estimaciones complementarias sobre el conjunto de test L2 ($N_{\text{test}} = 36$): la cifra del *best val checkpoint* y la media de las últimas cinco épocas sin selección de *checkpoint*. La segunda estimación caracteriza el comportamiento asintótico del entrenamiento sin la varianza asociada al criterio de selección.

Cuadro 4.29: Métricas de SpanDerm v0 sobre el conjunto de test L2 de DermapixelAI 1.0 ($N_{\text{test}} = 36$, 38 clases con queratinización consolidada). Cifras: media $\pm$ desviación estándar sobre tres semillas ({42,43,44}). La columna *best val* aplica selección por máxima BAcc de validación; la columna *últimas 5 ép.* promedia las cinco épocas finales sin selección. Mejor por fila en negrita.

Métrica	<i>Best val</i> checkpoint	Media últimas 5 ép.
Acc@1	0,250 $\pm$ 0,000	0,209 $\pm$ 0,005
Acc@3	0,500 $\pm$ 0,023	0,457 $\pm$ 0,011
BAcc	0,363 $\pm$ 0,007	0,309 $\pm$ 0,006
AUROC	0,855 $\pm$ 0,006	0,837 $\pm$ 0,008
W-F1	0,218 $\pm$ 0,013	—
Kappa	0,220 $\pm$ 0,001	—

La estabilidad entre semillas es alta sobre todas las métricas reportadas (desviación estándar $\leq 0,013$ en valor absoluto y $\leq 0,008$ sobre AUROC y BAcc). La diferencia entre el *best val checkpoint* y la media de las últimas cinco épocas (+5,4 pp BAcc, +1,8 pp AUROC, +4,1 pp Acc@1) indica que la curva de entrenamiento exhibe un patrón de sobreajuste suave análogo al observado en el FT parcial denso de la sección 4.11, pero atenuado por la restricción al 0,17 % de parámetros entrenables que impone la adaptación LoRA.

La tabla 4.30 sitúa las cifras de SpanDerm v0 frente a las dos referencias internas sobre el mismo conjunto de test y el mismo nivel ontológico: el sondeo lineal congelado bajo validación cruzada agrupada por caso (tabla 4.26), el sondeo lineal sobre el split fijo (tabla 4.16) y el codificador DermLIP v2 individual reportado en la sección 4.11 como mejor opción sobre L2 sin entrenamiento de cabeza.

Cuadro 4.30: Comparativa sobre el nivel L2 de DermapixelAI 1.0 (38 clases con queratinización consolidada, $N_{\text{test}} = 36$) entre SpanDerm v0 y las referencias internas del trabajo. La fila LP CV se considera la cifra honesta del sondeo lineal congelado por su independencia del *split* fijo (sección 4.11). Mejor valor por columna en negrita.

Método	Encoder	Params entren.	BAcc L2	AUROC L2
LP test fijo (tabla 4.16)	PanDerm Large 1024 (cong.)	39 K	0,265	0,793
LP 5-fold CV (tabla 4.26)	PanDerm Large 1024 (cong.)	39 K	0,168 $\pm$ 0,020	0,749 $\pm$ 0,019
DermLIP v2 individual (sección 4.11)	DermLIP 512 (cong.)	19,5 K	0,279	0,860
SpanDerm v0 (este trabajo)	PanDerm Large 1024 + LoRA	524 K	0,363 $\pm$ 0,007	0,855 $\pm$ 0,006

La comparativa documenta dos hallazgos cuantitativos sobre el mismo conjunto de test. *Primero*, SpanDerm v0 mejora la BAcc L2 en +19,5 pp respecto a la cifra de validación cruzada agrupada por caso del sondeo lineal congelado (0,168 $\rightarrow$ 0,363) y en +8,4 pp respecto a DermLIP v2 individual (0,279 $\rightarrow$ 0,363), siendo la mejor BAcc L2 documentada sobre el corpus. *Segundo*, la AUROC L2 de SpanDerm v0 (0,855 $\pm$ 0,006) empata estadísticamente con la de DermLIP v2 individual (0,860) dentro del margen de la desviación estándar entre semillas, mientras que mejora en +10,6 pp la cifra de validación cruzada del sondeo lineal congelado. El compromiso entre BAcc y AUROC entre SpanDerm v0 y DermLIP v2 individual se interpreta como complementariedad: la cabeza supervisada con LoRA sobre PanDerm Large alcanza mayor discriminación de las clases minoritarias (mejor BAcc), mientras que el preentrenamiento contrastivo PubMedBERT-DermLIP retiene una ligera ventaja sobre el ranking global de la AUROC

4. RESULTADOS

one-vs-rest.

El ranking L3 por prototipos sobre las 250 clases del vocabulario de entrenamiento reporta las cifras de la tabla 4.31. Los prototipos se calculan como la media de las representaciones del conjunto de entrenamiento por clase L3, y la predicción se obtiene por similitud coseno entre la representación de la imagen de test y los 250 prototipos. Esta estrategia corresponde a la formulación documentada en la sección 7.5.2 para mitigar la cola larga del nivel L3 sin requerir una cabeza supervisada directa, inviable bajo 3,5 muestras/clase de media en $N_{\text{train}} = 874$.

Cuadro 4.31: Ranking L3 por prototipos coseno de SpanDerm v0 sobre el conjunto de test de DermapixelAI 1.0 (250 clases efectivas del vocabulario de entrenamiento). Cifras: media $\pm$ desviación estándar sobre tres semillas. La columna $\times$ azar reporta el factor de mejora respecto a la asignación aleatoria uniforme sobre 250 clases ($1/250 = 0,004$).

Métrica	Media	Std	$\times$ azar
Acc@1	0,167	0,000	$\times 42$
Acc@3	0,259	0,013	$\times 22$
Acc@5	0,296	0,026	$\times 15$
BAcc	0,148	0,000	—

El ranking L3 por prototipos funciona pero queda limitado por la cola larga del corpus: Acc@1 = 0,167 y Acc@5 = 0,296 mejoran la asignación aleatoria en órdenes de magnitud de $\times 42$ y $\times 15$ respectivamente, pero permanecen lejos del régimen operativo clínico necesario para despliegue asistencial sobre el vocabulario completo. La cifra de BAcc (0,148) refleja la penalización adicional por las clases ausentes en validación: 178 clases L3 con muestras efectivas en el rango 1–5 imágenes en el *split* de entrenamiento (cola larga estricta del vocabulario representado), lo que limita la calidad del prototipo correspondiente al promedio de muy pocas muestras y produce prototipos ruidosos para gran parte del vocabulario.

Tres hallazgos cuantitativos cierran la sección. *Primero*, SpanDerm v0 con sólo 0,17 % de parámetros entrenables iguala o supera a las tres referencias internas sobre BAcc L2 ($0,363 \pm 0,007$ frente a $0,168 \pm 0,020$ del LP CV, 0,265 del LP fijo y 0,279 de DermLIP v2 individual), lo que valida la línea de adaptación de bajo rango como protocolo preferente sobre el corpus en castellano y materializa la implicación de diseño anticipada en la sección 7.5.2. *Segundo*, la AUROC L2 de SpanDerm v0 ($0,855 \pm 0,006$) empata estadísticamente con la de DermLIP v2 nativo (0,860): la adaptación textual ligera de PanDerm Large mediante LoRA alcanza el mismo techo discriminativo que el preentrenamiento contrastivo PubMedBERT-DermLIP sobre Derm1M, lo que sugiere que la elección del codificador y la estrategia de adaptación son ortogonales sobre la cardinalidad L2 del corpus. *Tercero*, el ranking L3 por prototipos coseno es funcional ($\times 42$ sobre azar en Acc@1 respecto al baseline uniforme de $1/250 \approx 0,004$, con factores análogos de $\times 22$ y $\times 15$ sobre Acc@3 y Acc@5 respecto a sus baselines uniformes correspondientes) pero está acotado por la cola larga: 178 de las 250 clases L3 efectivas en entrenamiento contienen ≤ 5 imágenes. La progresión hacia SpanDerm v1 (cabeza L3 directa) queda condicionada a la incorporación del banco hospitalario del HUSLL, con umbral de activación de ≥ 30 imágenes/clase L3 ya documentado en la sección 7.5.1 y en la sección 7.5.2.

4.15 Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos

La línea de interpretabilidad mediante Sparse Autoencoders (SAE) descrita en el Anexo F introduce un SAE Large de 16384 *features* entrenado sobre las activaciones de PanDerm Large y valida la base conceptual del modelo sobre los 48 conceptos visuales de SkinCon [15]. La presente sección extiende esa validación al corpus Derm7pt [9] (1011 lesiones dermatoscópicas) y explota por primera vez en este trabajo las anotaciones del *Seven-Point Checklist* (siete criterios diagnósticos estructurados por imagen). El diseño contempla tres experimentos ejecutados sobre DGX Spark GB10 el 2026-06-02: E1 alineamiento *single-feature* entre las 16384 activaciones del SAE y los siete criterios binarizados, E2 *Concept Bottleneck Model* (CBM) jerárquico con cuello de botella sobre los siete conceptos para predicción melanoma/no-melanoma, y E3 cruce con los 16 conceptos dermatoscópicos del Grupo A propuestos a la Dra. R. Taberner para anotación sobre DermapixelAI 1.0. Los tres experimentos comparten el corpus completo Derm7pt ($N = 1011$, 24,5% melanomas), con *splits* oficiales *train* = 413, *val* = 203, *test* = 395 (100 melanomas en test) cuando aplica división. La activación del SAE sobre el corpus muestra 3214 *features* activas en más del 5% de las imágenes, 2978 *features* inactivas (*dead*) y 2717 *features* muy activas ($> 50\%$), distribución coherente con la sparsidad nominal del SAE.

El experimento E1 evalúa, para cada uno de los siete criterios binarizados como *present/absent*, la AUROC efectiva máx(AUROC, $1 - \text{AUROC}$) de cada una de las 16384 *features* individuales como predictor binario del criterio. La tabla 4.32 reporta el AUROC efectivo de la mejor *feature* por criterio (*top-1*) y el promedio sobre las diez mejores (*top-10*). Todas las cifras se calculan sobre el corpus completo Derm7pt ($N = 1011$).

Cuadro 4.32: Alineamiento *single-feature* entre las 16384 *features* del SAE Large y los siete criterios del *Seven-Point Checklist* sobre Derm7pt ($N = 1011$). AUROC efectiva máx(AUROC, $1 - \text{AUROC}$) de la mejor *feature* individual (*top-1*) y promedio sobre las diez mejores (*top-10*). Mejor cifra agregada en negrita.

Criterio	N_+	N_-	AUROC <i>top-1</i>	AUROC <i>top-10</i>
pigment_network	611	400	0,754	0,737
streaks	358	653	0,688	0,684
pigmentation	423	588	0,700	0,657
regression_structures	253	758	0,687	0,673
dots_and_globules	782	229	0,681	0,663
blue_whitish_veil	195	816	0,746	0,721
vascular_structures	188	823	0,823	0,782

Las siete *features* más alineadas individualmente alcanzan AUROC efectivo en el intervalo [0,681, 0,823], con el máximo sobre *vascular structures* (0,823) y mínimo sobre *dots and globules* (0,681). La estabilidad entre el *top-1* y el *top-10* (diferencia $\leq 0,043$ en valor absoluto) indica que el alineamiento no se concentra en una única *feature* aislada sino que el SAE codifica los conceptos mediante un pequeño subconjunto coherente de activaciones.

El experimento E2 construye un CBM jerárquico de dos etapas: una primera cabeza de regresión logística sobre las 16384 activaciones del SAE estima la probabilidad de cada uno de los siete criterios; un meta-clasificador logístico toma estas siete estima-

4. RESULTADOS

ciones como vector de entrada y predice melanoma/no-melanoma. La comparativa con el sondeo lineal directo sobre las 16384 *features* sin cuello de botella se reporta en la tabla 4.33. El AUROC binario por concepto de la cabeza intermedia se reporta en la tabla 4.34 junto con el peso aprendido por el meta-clasificador sobre cada concepto.

Cuadro 4.33: Comparativa entre sondeo lineal directo sobre las 16384 *features* del SAE Large y CBM jerárquico con los siete criterios *Seven-Point Checklist* como cuello de botella. Conjunto de test Derm7pt ($N_{\text{test}} = 395$, 100 melanomas). AUROC en negrita.

Arquitectura	Acc@1	BAcc	AUROC	W-F1	Kappa
Sondeo lineal directo (SAE $\rightarrow$ melanoma)	0,841	0,735	0,890	0,829	0,527
CBM (SAE $\rightarrow$ 7 conceptos $\rightarrow$ melanoma)	0,825	0,681	0,832	0,801	0,440

Cuadro 4.34: Cabeza intermedia del CBM: AUROC binario sobre el conjunto de test Derm7pt ($N_{\text{test}} = 395$) por concepto del *Seven-Point Checklist*, y peso aprendido por el meta-clasificador logístico para la predicción binaria melanoma/no-melanoma. Pesos ordenados de mayor a menor importancia relativa.

Concepto	AUROC concepto	Peso meta-LP
blue_whitish_veil	0,895	+2,54
regression_structures	0,818	+2,07
streaks	0,829	+1,78
vascular_structures	0,906	+1,65
pigmentation	0,792	+1,44
dots_and_globules	0,723	+1,41
pigment_network	0,901	+1,04

La AUROC binaria de la cabeza intermedia se sitúa en el intervalo [0,723, 0,906] sobre los siete conceptos, con *vascular structures* (0,906), *pigment network* (0,901) y *blue whitish veil* (0,895) como las predicciones conceptuales más fiables. El paso de las activaciones crudas del SAE a través del cuello de botella conceptual reduce la AUROC binaria melanoma de 0,890 a 0,832 (−5,8 pp), pérdida cuantificada que documenta el compromiso entre interpretabilidad y precisión bruta. Los pesos del meta-clasificador identifican *blue whitish veil* y *regression structures* como los conceptos con mayor peso relativo para la decisión final melanoma/no-melanoma (+2,54 y +2,07 respectivamente), seguidos de *streaks* y *vascular structures*. Esta jerarquía coincide cualitativamente con el peso clínico asignado a estos criterios en el *Seven-Point Checklist* original descrito por Kawahara et al. [9], donde el velo azul-blanquecino y las estructuras de regresión figuran entre los criterios mayores (2 puntos cada uno) de la escala diagnóstica.

El experimento E3 cruza los 16 conceptos dermatoscópicos del Grupo A propuestos a la Dra. R. Taberner para anotación sobre las 49 imágenes dermatoscópicas de DermapixelAI 1.0 (sección 3.3) con los siete criterios del *Seven-Point Checklist* sobre Derm7pt. Para cada concepto Rosa con *mapping* a un criterio Derm7pt (directo o por subcategoría) se reporta la AUROC efectiva de la mejor *feature* SAE sobre la binarización correspondiente. El resultado se sintetiza en la tabla 4.35.

4.15. Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos

Cuadro 4.35: Cruce de los 16 conceptos dermatoscópicos del Grupo A propuestos a la Dra. R. Taberner con los siete criterios del *Seven-Point Checklist* sobre Derm7pt ($N = 1011$). Para los conceptos con *mapping* se reporta la AUROC efectiva de la mejor *feature* SAE Large sobre la binarización correspondiente. Conceptos cubiertos (AUROC $\geq 0,70$) en negrita.

#	Concepto Rosa (Grupo A)	Mapping Derm7pt	N_+	AUROC eff	Cobertura
1	Red dermatoscópica regular	pigment_network=typical	381	0,748	✓
2	Red dermatoscópica atípica	pigment_network=atypical	230	0,732	✓
3	Glóbulos pigmentarios	dots_and_globules	782	0,681	—
4	Puntos pigmentarios	dots_and_globules	782	0,681	—
5	Estrías radiales	streaks	358	0,688	—
6	Pseudopodios	streaks=irregular	251	0,729	✓
7	Velo azul-blanquecino	blue_whitish_veil=present	195	0,746	✓
8	Estructuras de regresión	regression_structures $\neq$ absent	253	0,687	—
9	Patrón empedrado	—	—	—	—
10	Patrón paralelo de surcos	—	—	—	—
11	Patrón paralelo de crestas	—	—	—	—
12	Lagunas vasculares	—	—	—	—
13	Vasos polimorfos	vascular_structures (agregado)	140	0,810	✓
14	Vasos en horquilla	vascular_structures=hairpin	15	0,926	✓
15	Vasos en corona	—	—	—	—
16	Patrón homogéneo desestructurado	pigmentation (<i>diffuse</i>)	380	0,704	✓

De los 16 conceptos del Grupo A, 11 admiten *mapping* operativo a un criterio o subcategoría del *Seven-Point Checklist* (directo en tres casos, por subcategoría en ocho), y los 5 restantes (patrón empedrado, patrón paralelo de surcos, patrón paralelo de crestas, lagunas vasculares, vasos en corona) corresponden a estructuras dermatoscópicas no contempladas en la escala original. Sobre los 11 conceptos mapeados, 7 quedan cubiertos por al menos una *feature* SAE con AUROC efectivo $\geq 0,70$. El máximo absoluto sobre vasos en horquilla (AUROC = 0,926 con sólo 15 positivos sobre 1011 imágenes) ilustra que la representación SAE captura conceptos poco frecuentes en el corpus sin contaminación por la distribución mayoritaria. La cobertura sobre vasos polimorfos (0,810, $N_+ = 140$) y sobre la red atípica (0,732, $N_+ = 230$) sostiene el alineamiento entre el vocabulario operativo del consenso clínico propuesto por la Dra. R. Taberner y la representación aprendida por el SAE Large.

Ajuste fino multitarea: cabezas conceptuales y melanoma

El experimento E4 replica conceptualmente el protocolo multitarea descrito por Kawahara et al. [9] sustituyendo la red convolucional original por el codificador fundacional PanDerm Large. El *fine-tuning* se realiza mediante adaptación de bajo rango (LoRA, $r = 16$) aplicada exclusivamente a los dos últimos bloques del codificador (*blocks.22-23*), de forma idéntica al protocolo SpanDerm v0 reportado en la sección 4.14. Sobre la representación adaptada se conectan ocho cabezas paralelas: una cabeza multi-clase por cada uno de los siete criterios del *Seven-Point Checklist* y una cabeza binaria para melanoma/no-melanoma. La función objetivo es la suma equiponderada de entropías cruzadas sobre las ocho cabezas, $\mathcal{L} = \sum_{i=1}^7 \text{CE}(\hat{c}_i, c_i) + \text{CE}(\hat{m}, m)$, con *class weight* balanceado por clase. La configuración de optimización emplea AdamW con *learning rate* diferenciado ($\eta_{\text{heads}} = 10^{-3}$, $\eta_{\text{LoRA}} = 5 \times 10^{-4}$) durante 15 épocas, con selección del *checkpoint* de mejor AUROC melanoma sobre validación (época 13, AUROC val

4. RESULTADOS

= 0,861). El número total de parámetros entrenables es 0,56 M (0,18 % del total del codificador), magnitud equivalente a la de SpanDerm v0.

La tabla 4.36 compara el rendimiento de E4 frente al sondeo lineal directo (E2 Direct LP sobre las 16384 activaciones del SAE) y al CBM jerárquico de siete conceptos (E2 CBM) sobre el conjunto de test Derm7pt ($N_{\text{test}} = 395$, $n_{\text{mel}} \approx 98$). Los intervalos de confianza al 95 % se estiman por *bootstrap* no paramétrico sobre el conjunto de test.

Cuadro 4.36: Comparativa sobre la tarea binaria melanoma/no-melanoma entre sondeo lineal directo sobre las 16384 *features* del SAE Large (E2 Direct LP), CBM jerárquico de siete conceptos (E2 CBM) y *fine-tuning* multitarea LoRA con ocho cabezas paralelas (E4). Conjunto de test Derm7pt ($N_{\text{test}} = 395$, $n_{\text{mel}} \approx 98$), mismo *split* oficial. AUROC en negrita.

Método	Params entr.	Acc@1	BAcc	AUROC	W-F1	Kappa
E2 Direct LP (SAE → melanoma)	16 K	0,841	0,735	0,890	0,829	0,527
E2 CBM (SAE → 7 conceptos → mel)	~ 120	0,825	0,681	0,832	0,801	0,440
E4 FT multitarea LoRA	0,56 M	0,841	0,804	0,891	0,843	0,590

La tabla 4.37 reporta la AUROC binaria *present/absent* por concepto sobre el mismo conjunto de test y la compara con la cabeza intermedia del CBM (regresión logística sobre activaciones SAE, una por concepto) reportada en la tabla 4.34.

Cuadro 4.37: AUROC binaria *present/absent* por concepto del *Seven-Point Checklist* sobre el conjunto de test Derm7pt ($N_{\text{test}} = 395$). Comparativa entre sondeo lineal separado por concepto sobre las activaciones SAE Large (E2 LP separado, una regresión logística por concepto) y las siete cabezas conceptuales del *fine-tuning* multitarea LoRA (E4). Δ en puntos porcentuales.

Concepto	E2 LP separado	E4 multitarea	Δ
pigment_network	0,901	0,889	-1,2 pp
vascular_structures	0,906	0,880	-2,6 pp
blue_whitish_veil	0,895	0,879	-1,6 pp
streaks	0,829	0,818	-1,1 pp
pigmentation	0,792	0,793	+0,1 pp
regression_structures	0,818	0,791	-2,7 pp
dots_and_globules	0,723	0,725	+0,2 pp

Tres observaciones cuantitativas sintetizan E4. *Primero*, la cabeza melanoma del *fine-tuning* multitarea alcanza AUROC test = 0,891 (IC95 % [0,856, 0,927]), valor que supera marginalmente al sondeo lineal directo sobre las 16384 *features* del SAE (0,890, +0,1 pp, incremento dentro del ruido del *bootstrap*) y mejora el CBM jerárquico en +5,9 pp AUROC. La diferencia operativa respecto al Direct LP es que E4 ofrece simultáneamente predicción melanoma e inferencia sobre los siete criterios diagnósticos en una sola pasada, lo que preserva la interpretabilidad explícita sin coste discriminativo apreciable sobre la tarea binaria primaria. *Segundo*, las siete cabezas conceptuales pierden entre 1 y 3 pp de AUROC respecto al sondeo lineal separado por concepto: el coste de compartir representación entre tareas auxiliares y tarea principal se sitúa en -1,2 pp (*pigment network*), -1,6 pp (*blue whitish veil*), -2,6 pp (*vascular structures*) y -2,7 pp (*regression structures*); dos conceptos mejoran ligeramente bajo el régimen multitarea (*pigmentation* +0,1 pp, *dots and globules* +0,2 pp). Este patrón es consistente con el comportamiento documentado del aprendizaje multitarea y cuantifica el

4.15. Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos

compromiso aceptado a cambio de un único codificador adaptado para las ocho cabezas simultáneas. *Tercero*, el hecho de que la cabeza melanoma no sufra penalización medible respecto al sondeo lineal especializado sugiere que el aprendizaje multitarea no degrada la tarea principal cuando los conceptos auxiliares son taxonómicamente coherentes con el objetivo. El *Seven-Point Checklist* es, por construcción, un instrumento diagnóstico de melanoma [9], lo que justifica empíricamente la elección del corpus de criterios.

Ocho hallazgos cuantitativos cierran la sección. *Primero*, existen *features* SAE individuales que codifican conceptos dermatoscópicos clásicos sin supervisión explícita durante el preentrenamiento: AUROC efectivo hasta 0,823 sobre vascular structures (E1) y hasta 0,926 sobre vasos en horquilla (E3, $N_+ = 15$), lo que indica que la base sparse aprendida sobre Derm1M no es solo un mecanismo de reducción dimensional sino que ha capturado representaciones interpretables alineadas con la taxonomía dermatoscópica. *Segundo*, el CBM jerárquico cuantifica el compromiso interpretabilidad-precisión sobre la tarea binaria melanoma/no-melanoma: el cuello de botella conceptual de siete dimensiones reduce la AUROC en $-5,8$ pp ($0,890 \rightarrow 0,832$) respecto al sondeo lineal directo sobre las 16384 activaciones, pérdida que el sistema acepta a cambio de trazabilidad concepto-a-concepto en la decisión. *Tercero*, los pesos del meta-clasificador del CBM ordenan *blue whitish veil* ($+2,54$) y *regression structures* ($+2,07$) como conceptos dominantes para la discriminación de melanoma, jerarquía coherente con el peso clínico asignado a estos criterios en el *Seven-Point Checklist* de referencia [9]. *Cuarto*, 7 de los 11 conceptos del Grupo A propuestos a la Dra. R. Taberner con *mapping* operativo a Derm7pt quedan cubiertos por *features* SAE sin entrenamiento específico sobre el corpus en castellano, y los 5 conceptos sin *mapping* (empedrado, paralelos surcos/crestas, lagunas vasculares, vasos en corona) constituyen precisamente el contenido específico de la anotación clínica colaborativa documentada en la sección 7.5.3 como línea de continuidad. *Quinto*, el SAE Large entrenado sobre activaciones de PanDerm Large generaliza la interpretabilidad emergente desde Derm1M (507657 imágenes) hasta Derm7pt (1011 lesiones dermatoscópicas) sin reentrenamiento, lo que sostiene la línea de interpretabilidad mediante Sparse Autoencoders documentada en el Anexo F. *Sexto*, el *fine-tuning* multitarea LoRA con ocho cabezas paralelas (E4, sección 4.15) supera marginalmente al sondeo lineal directo sobre las 16384 activaciones del SAE en AUROC binario melanoma ($0,891$ frente a $0,890$, incremento dentro del intervalo de *bootstrap*) y mejora el CBM jerárquico en $+5,9$ pp AUROC, preservando interpretabilidad explícita concepto-a-concepto mediante las siete cabezas auxiliares activas simultáneamente. *Séptimo*, las cabezas conceptuales del régimen multitarea pierden entre 1 y 3 pp de AUROC respecto al sondeo lineal separado por concepto sobre las activaciones SAE ($-1,2$ a $-2,7$ pp sobre los cuatro conceptos más sensibles, ganancias residuales sobre los dos restantes), patrón consistente con el coste documentado del aprendizaje compartido. *Octavo*, la cabeza melanoma del régimen multitarea no se degrada respecto al sondeo lineal especializado (Δ AUROC = $+0,1$ pp), evidencia empírica de que los siete criterios del *Seven-Point Checklist* [9] constituyen auxiliares taxonómicamente coherentes con la tarea binaria primaria de discriminación melanoma/no-melanoma. El conjunto E1-E4 proporciona evidencia consistente del valor del SAE Large entrenado sobre PanDerm Large para tareas de interpretabilidad emergente en dermatología, y refuerza la viabilidad del módulo M7 de interpretabilidad del prototipo DermApIxel (Anexo H).

4.16 Codificadores adicionales y arquitecturas de inferencia alternativas

Las secciones 4.11, 4.12 y 4.14 caracterizan codificadores específicos de dominio (PanDerm Base/Large, DermLIP v2) y vision-lenguaje médicos (BiomedCLIP, SigLIP-SO400M) sobre el corpus DermapixelAI 1.0, con cabezas paramétricas ligeras y bajo clasificación contrastiva *zero-shot*. La presente sección cierra el panorama experimental con dos extensiones complementarias ejecutadas sobre NVIDIA DGX Spark GB10 el 2026-06-02: (i) codificadores generalistas no médicos (DINOv2 ViT-L auto-supervisado puro y CLIP-L de OpenAI contrastivo) como referencia fuera del dominio, y (ii) dos arquitecturas alternativas de inferencia sobre el mismo conjunto de *embeddings* ya cacheados: *retrieval k*-NN sobre índice FAISS con embeddings de PanDerm Large, y *zero-shot jerárquico* en cascada $L1 \rightarrow L2 \rightarrow L3$ condicionado sobre el codificador DermLIP v2. El conjunto de cuatro experimentos (referidos como N1-N4 en el material reproducible) acota el techo discriminativo del corpus desde dos ángulos no explorados en las secciones previas: el rendimiento de codificadores ajenos al dominio biomédico y el efecto de modificar el clasificador o la estrategia de inferencia sin cambiar el codificador.

Codificadores generalistas no médicos: DINOv2 y CLIP-L

Se evalúan dos codificadores fuera del dominio biomédico bajo el protocolo de sondeo lineal congelado descrito en la sección 4.11, sobre el mismo *split* fijo ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). DINOv2 ViT-L (vit_large_patch14_dinov2.lvd142m, embedding 1 024-D, CLS) corresponde al modelo auto-supervisado visual generalista de Meta sobre LVD-142M [16]; CLIP-L-336 (OpenAI, ViT-L/14 con resolución 336) corresponde al modelo contrastivo texto-imagen generalista entrenado sobre 400 millones de pares web [22], con embedding proyectado de 768-D. La cabeza es regresión logística L-BFGS con $C = 1,0$ y $\text{max_iter} = 5000$, idéntica a la sección 4.11.

Cuadro 4.38: Sondeo lineal sobre embeddings congelados de codificadores generalistas no médicos en DermapixelAI 1.0 ($N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). Referencia: PanDerm Large (tabla 4.16). Mejor valor por columna y nivel en negrita.

Encoder	L1 (4 cls)		L2 (38 cls)		L3 (224 cls)	
	BAcc	AUROC	BAcc	AUROC	BAcc	AUROC
PanDerm Large	0,735	0,796	0,265	0,793	0,184	0,813
DINOv2 ViT-L	0,537	0,650	0,250	0,718	0,211	0,794
CLIP-L-336	0,556	0,658	0,279	0,826	0,184	0,827

CLIP-L-336 alcanza la mejor AUROC sobre L2 (0,826 frente a 0,793 de PanDerm Large, +3,3 pp) y sobre L3 (0,827 frente a 0,813, +1,4 pp) a pesar de no incorporar material biomédico en su preentrenamiento. DINOv2 ViT-L, auto-supervisado puro sin componente textual, gana la BAcc L3 (0,211 frente a 0,184 de PanDerm Large, +2,7 pp) pero pierde sistemáticamente sobre L1 (−19,8 pp BAcc, −14,6 pp AUROC) y se mantiene por debajo sobre L2 (−1,5 pp BAcc, −7,5 pp AUROC). PanDerm Large conserva la primacía sobre L1 en BAcc y AUROC. Ningún codificador domina simultáneamente en todas las métricas y los tres niveles ontológicos, patrón coherente con la lectura de la

sección 4.11 sobre la complementariedad entre el preentrenamiento auto-supervisado de PanDerm y el contrastivo texto-imagen de DermLIP. La clasificación *zero-shot* con CLIP-L (*prompts* en castellano e inglés idénticos a la sección 4.12) resulta catastrófica sobre los tres niveles (AUROC L1 0,559 en castellano y 0,635 en inglés, AUROC L2 0,699 en castellano, AUROC L3 0,617 en castellano), confirmando que los codificadores generalistas requieren adaptación supervisada para operar sobre material clínico dermatológico.

Retrieval k -NN con índice FAISS sobre embeddings PanDerm Large

Una alternativa al clasificador paramétrico sobre el espacio de *embeddings* congelados consiste en la recuperación basada en similitud: dado un *embedding* de consulta, se recuperan sus k vecinos más próximos del conjunto de entrenamiento bajo similitud coseno y se predice por votación. Se construye un índice IndexFlatIP de FAISS [26] sobre los 874 *embeddings* L2-normalizados de PanDerm Large correspondientes al conjunto de *train* de la sección 4.11 y se evalúan dos variantes (votación por mayoría y *softmax* ponderado por similitud) cruzadas con $k \in \{1, 5, 10, 20\}$. La tabla 4.39 reporta la mejor combinación por nivel y métrica frente a la referencia LP paramétrica.

Cuadro 4.39: *Retrieval k -NN* sobre embeddings PanDerm Large con índice FAISS (IndexFlatIP, similitud coseno tras L2-normalize). Mejor combinación $k \times$ variante por nivel y métrica. Referencia: sondeo lineal paramétrico sobre el mismo encoder (LP, tabla 4.16). Mejor valor por columna y nivel en negrita.

Nivel	Método	Acc@1	BAcc	AUROC
L1	LP paramétrico (LR)	0,750	0,735	0,796
L1	k -NN $k = 10$ <i>majority</i>	0,722	0,686	0,748
L2	LP paramétrico (LR)	0,250	0,265	0,793
L2	k -NN $k = 20$ <i>majority</i>	0,278	0,265	0,700
L3	LP paramétrico (LR)	0,179	0,184	0,813
L3	k -NN $k = 5$ <i>majority</i>	0,214	0,210	0,615
L3	k -NN $k = 20$ <i>weighted</i>	0,214	0,210	0,719

El *retrieval k -NN* supera al sondeo lineal paramétrico sobre el régimen de cola larga severa L3 (224 clases efectivas, 3,5 muestras/clase media en *train*): +3,5 pp Acc@1 (0,179 $\rightarrow$ 0,214) y +2,6 pp BAcc (0,184 $\rightarrow$ 0,210) con $k = 5$ y votación por mayoría. Sobre L2, k -NN con $k = 20$ empata en BAcc (0,265) y mejora Acc@1 en +2,8 pp (0,250 $\rightarrow$ 0,278). Sobre L1, en cambio, k -NN pierde respecto al LP paramétrico (−4,9 pp BAcc, −4,8 pp AUROC), comportamiento consistente con que la cardinalidad reducida del nivel (4 clases) favorece a la regresión logística sobre la votación de vecinos. La AUROC global del k -NN es sistemáticamente inferior a la del LP (diferencias entre −4,8 y −9,3 pp según nivel), atribuible a que la estimación de probabilidad por frecuencia relativa de vecinos no es densa sobre el conjunto de clases. El hallazgo es coherente con la arquitectura del módulo M4 del prototipo de producción (*retrieval* sobre Derm1M descrito en el Anexo H), que emplea el mismo principio de similitud coseno sobre *embeddings* PanDerm Large como soporte conceptual al diagnóstico ofrecido por las cabezas paramétricas.

***Zero-shot* jerárquico: cascada L1→L2→L3 con propagación de errores**

La sección 4.12 evalúa la clasificación *zero-shot* sobre los tres niveles ontológicos de forma independiente, considerando en cada caso todas las clases candidatas del nivel. Una estrategia alternativa, motivada por el flujo diagnóstico clínico real, consiste en una cascada jerárquica: predecir primero L1, restringir las candidatas L2 a las hijas del L1 predicho, y restringir las candidatas L3 a las hijas del L2 predicho. La jerarquía L1→L2 utilizada se deriva del corpus de *train* (Inflamatoria: 25 subcategorías L2; Infecciosa: 5; Tumoral: 12; Genodermatosis: 2). El encoder es DermLIP v2 (el mejor *zero-shot* de la sección 4.12), bajo *prompts* en castellano. Se contrastan tres variantes: el *zero-shot* plano de la sección 4.12 (todas las clases del nivel como candidatas), la cascada jerárquica estricta con el L1 argmáx, y una variante *top-3 L1* que mantiene las tres categorías L1 más probables como candidatas y agrega sus hijas L2.

Cuadro 4.40: Comparación entre clasificación *zero-shot* plana y *zero-shot jerárquico* en cascada sobre el conjunto de test de DermapixelAI 1.0 ($N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). Encoder: DermLIP v2, prompts en castellano. La fila “L2 hier | L1 correcto” restringe la evaluación a las muestras con L1 predicho correctamente. Mejor valor por columna en negrita; la cifra condicionada se reporta separadamente.

Variante	L1 Acc@1	L2 Acc@1	L3 Acc@1
ZS plano (referencia, sección 4.12)	0,361	0,222	0,107
ZS jerárquico (cascada estricta)	0,361	0,139	0,036
ZS jerárquico (top-3 L1)	0,361	0,194	0,036
L2 hier L1 correcto (condicionada)	—	0,385	—

La cascada jerárquica estricta degrada el rendimiento plano sobre L2 en $-8,3$ pp Acc@1 ($0,222 \rightarrow 0,139$) y sobre L3 en $-7,1$ pp Acc@1 ($0,107 \rightarrow 0,036$). La causa principal es la propagación de errores desde el nivel L1: dado que DermLIP v2 acierta L1 sólo en el 36,1 % de los casos, el 63,9 % restante recibe en L2 un conjunto de candidatas desalineado con la verdad de terreno, lo que invalida toda predicción posterior independientemente del codificador. La variante *top-3 L1* amortigua parcialmente la propagación al mantener las tres categorías L1 más probables como hipótesis activa y recupera 0,194 Acc@1 sobre L2 ($-2,8$ pp respecto a plano), sin efecto sobre L3. Condicionado a L1 correcto, la cascada jerárquica L2 alcanza Acc@1 = 0,385, casi el doble del plano, evidencia de que la restricción del espacio de candidatas a las subcategorías clínicamente coherentes con la categoría etiológica acertada incrementa la discriminación de forma sustancial. La implicación clínica es directa: la arquitectura jerárquica funciona si la decisión inicial sobre la familia etiológica es robusta; con *zero-shot* modesto, la cascada acumula errores y degrada el rendimiento plano.

Síntesis: panorama completo de codificadores y arquitecturas sobre DermapixelAI 1.0

La tabla 4.41 consolida las cifras de BAcc y AUROC sobre los tres niveles ontológicos para el conjunto completo de codificadores y arquitecturas evaluados sobre el corpus DermapixelAI 1.0 a lo largo del presente capítulo. La síntesis permite identificar el mejor método por nivel y métrica sin dispersión entre las secciones de origen.

4.17. SpanDerm-CLIP: zero-shot multimodal castellano sobre DermapixelAI 1.0

Cuadro 4.41: Síntesis de codificadores y arquitecturas evaluados sobre DermapixelAI 1.0 (test fijo: $N = 36$ en L1/L2, $N = 28$ en L3). La columna *Ref.* remite a la sección de origen de las cifras completas con sus intervalos de confianza. Mejor valor por columna y nivel en negrita.

Método	Ref.	L1		L2		L3	
		BAcc	AUROC	BAcc	AUROC	BAcc	AUROC
PanDerm Base LP	\$4.11	0,570	0,697	0,221	0,707	0,132	0,735
PanDerm Large LP	\$4.11	0,735	0,796	0,265	0,793	0,184	0,813
DermLIP v2 LP	\$4.11	—	—	—	0,860	—	—
DINOv2 ViT-L LP	\$4.16	0,537	0,650	0,250	0,718	0,211	0,794
CLIP-L-336 LP	\$4.16	0,556	0,658	0,279	0,826	0,184	0,827
SpanDerm v0 LoRA	\$4.14	—	—	0,363	0,855	—	—
FT parcial denso L1+L2+L3	\$4.11	0,622	0,715	0,324	0,852	0,184	0,804
k -NN FAISS PanDerm Large	\$4.16	0,686	0,748	0,265	0,700	0,210	0,719

El mejor método sobre DermapixelAI 1.0 depende del nivel ontológico y de la métrica. Sobre L1, el sondeo lineal sobre PanDerm Large encabeza simultáneamente BAcc (0,735) y AUROC (0,796); sobre L2, SpanDerm v0 LoRA encabeza la BAcc (0,363) y CLIP-L-336 LP encabeza la AUROC (0,826); sobre L3, el *retrieval* k -NN FAISS sobre embeddings de PanDerm Large encabeza la BAcc (0,210) y CLIP-L-336 LP encabeza la AUROC (0,827). La discriminación binaria melanoma/no-melanoma sobre Derm7pt (sección 4.15, fuera de DermapixelAI 1.0) alcanza AUROC 0,891 con el *fine-tuning* multitarea LoRA E4 sobre las activaciones del SAE. La ausencia de un método único óptimo refuerza la lectura interpretativa de la sección 5.1.1: la elección del codificador y del clasificador debe condicionarse al nivel ontológico objetivo y al criterio operativo predominante (discriminación robusta, ranking probabilístico o recuperación para soporte explicativo).

4.17 SpanDerm-CLIP: zero-shot multimodal castellano sobre DermapixelAI 1.0

Las secciones previas caracterizan la familia DermLIP en *zero-shot* sobre datasets externos (sección 4.6) y sobre DermapixelAI 1.0 con plantillas en castellano e inglés (sección 4.12), y SpanDerm v0 como cabeza supervisada con LoRA sobre L2 (sección 4.14). Las dos primeras operan en régimen multimodal con encoder textual fijo (PubMedBERT/CLIP) y la tercera en régimen supervisado con vocabulario cerrado de 38 clases L2. La presente sección cierra una tercera configuración no cubierta por las anteriores: un sistema vision-lenguaje contrastivo con encoder textual multilingüe entrenado sobre el propio corpus DermapixelAI 1.0, evaluado en *zero-shot open-class* sobre el vocabulario completo de la ontología (L1, L2 y L3) en castellano. La diferencia operativa frente a SpanDerm v0 es la capacidad de mapear texto clínico libre en castellano sobre el espacio de imágenes sin necesidad de fijar las clases por anticipado, condición operacional relevante para escenarios de búsqueda documental clínica sobre el archivo de la Dra. R. Taberner. La diferencia operativa frente a DermLIP es la sustitución del encoder textual anglosajón (PubMedBERT-256) por un encoder multilingüe adaptado al lenguaje clínico castellano del propio corpus. La justificación cuantitativa frente a un *wrapper* alternativo con modelo fundacional inglés más traducción ES-EN se desarrolla en el Anexo I.

Arquitectura, datos y protocolo experimental

El sistema, denominado SpanDerm-CLIP, sigue el patrón dual-encoder estilo CLIP [22]: un encoder visual de 1024 dimensiones (PanDerm Large, ViT-L/16, CLS *pooling*), un encoder textual multilingüe de 768 dimensiones (intfloat/multilingual-e5-base), capas de proyección lineales con normalización L2 a un espacio compartido de 512 dimensiones y entrenamiento por pérdida InfoNCE bidireccional (imagen→texto y texto→imagen) con temperatura aprendible. El corpus de entrenamiento es DermapixelAI 1.0 (Anexo C) bajo el *split* per-case estratificado por L1 (854 *train* / 107 *val* / 101 *test* imágenes; 521/66/66 casos), idéntico al utilizado en las secciones 4.11 y 4.12. El manifest SHA-256 del *split* train/val/test (5dcd9b52 . . . cd394538) queda fijado en cada *checkpoint* y los conjuntos de validación y test no se tocan en ninguna iteración del experimento; el manifest de los pares cross-modal se registra por separado en el repositorio de provenance.

Para amplificar la señal textual del corpus se generan, mediante asistencia de un modelo de lenguaje grande partiendo del texto original de cada caso del blog y de sus metadatos, ocho perspectivas clínicas por imagen (morfología, dermatoscopia, criterios ABCDE, diagnóstico diferencial, informe clínico, estilo blog, *case_summary* y *key_findings*). El total alcanza 7 680 captions sobre 960 imágenes (corpus de la fase v1–v4); 102 imágenes fallan la generación automática y conservan únicamente el texto base. El coste real de generación es de 32,54 USD (0,030 USD por imagen completa) y la longitud media es de 87,5 palabras por caption; coste y longitud media proceden del registro de provenance del repositorio. Combinadas con las nueve variantes textuales base (plantillas L1/L2/L3, jerárquicas L1L2L3, título de blog, tres *chunks* de *case_text* y *diagnosis_raw*) el corpus de entrenamiento alcanza del orden de 22 000 pares (imagen, texto). Cada *epoch* muestra cada imagen una vez con una variante textual seleccionada por hash determinista (*seed*, *epoch*, *image_id*), lo que garantiza reproducibilidad bajo reanudación.

Se entrenan cinco iteraciones del sistema bajo configuraciones crecientes de capacidad arquitectónica y, en la última, bajo ampliación del corpus de entrenamiento. La progresión articula tres palancas independientes —adaptación del lado textual, adaptación del lado visual y escala del corpus— cuya contribución marginal se aísla por construcción. La tabla 4.42 resume las cinco configuraciones.

Cuadro 4.42: Configuración de las cinco iteraciones SpanDerm-CLIP entrenadas sobre DermapixelAI 1.0. Las versiones v1–v4 comparten el mismo *split* per-case (854 *train* / 107 *val* / 101 *test*) y el mismo manifest SHA-256. La versión v5 amplía el conjunto de entrenamiento con 15 128 imágenes externas (PAD-UFES-20 [11] y DermNet [13]) reponderadas mediante *Weighted Random Sampler* con ratio efectivo 6× en favor del subconjunto castellano original, manteniendo los conjuntos de validación y test idénticos.

Versión	Image encoder	Text encoder	Train
v1	PanDerm-Large frozen	E5-base <i>full FT</i>	854 castellano
v2	PanDerm-Large frozen	E5-base + LoRA $r = 16$, $\alpha = 32$	854 castellano
v3	PanDerm-Large + LoRA $r = 16$ (últimos 4/24 bloques)	E5-base + LoRA $r = 16$, $\alpha = 32$	854 castellano
v4	PanDerm-Large + LoRA $r = 32$ (últimos 12/24 bloques)	E5-base + LoRA $r = 32$, $\alpha = 64$	854 castellano
v5	PanDerm-Large + LoRA $r = 32$ (últimos 12/24 bloques)	E5-base + LoRA $r = 32$, $\alpha = 64$	854 cast. + 15 128 ext.

El paso $v1 \rightarrow v2$ verifica si los 277 M parámetros del E5 *full fine-tune* sobreajustan sobre 854 imágenes y si una adaptación LoRA del lado textual captura mejor el lenguaje rico clínico castellano sin destruir el preentrenamiento multilingüe. El paso $v2 \rightarrow v3$ testea la hipótesis de que el cuello de botella está en el lado visual, mediante inyección de LoRA en los últimos cuatro bloques ViT (`attn.qkv`, `attn.proj`, `mlp.fc1`, `mlp.fc2`) del encoder visual. El paso $v3 \rightarrow v4$ amplía la capacidad arquitectónica del lado visual duplicando el rango ($r = 16 \rightarrow 32$) y triplicando la cobertura de bloques ($4 \rightarrow 12$ últimos bloques del ViT), bajo la hipótesis — formulada tras la medición del techo *Linear Probing* discutida más adelante en esta misma sección— de que el ajuste confinado de $v3$ constituía capacidad insuficiente para reesculpir las *features* visuales en el régimen *fine-grained* castellano. El paso $v4 \rightarrow v5$ disocia la palanca arquitectónica de la palanca de escala: bajo idéntica configuración LoRA que $v4$ se amplía el corpus de entrenamiento con 15 128 imágenes externas de habla portuguesa y vocabulario clínico afín, acompañadas de *captions* sintéticas generadas mediante un modelo de lenguaje grande con el mismo protocolo aplicado al subconjunto castellano, para evaluar si la escala externa genérica resuelve la cola larga (327 clases L3 con ≤ 5 imágenes considerando el vocabulario ontológico completo Taberner, de las cuales 178 disponen de muestras 1–5 en entrenamiento y 149 carecen de imágenes en el corpus actual) o degrada la alineación específica del registro lingüístico original. Los tiempos de entrenamiento sobre NVIDIA DGX Spark GB10 son ~ 18 min ($v1$), ~ 3 min ($v2$), ~ 5 min ($v3$), ~ 9 min ($v4$) y ~ 54 min ($v5$). El objetivo experimental, fijado en el diseño antes de observar resultados, es L3 *accuracy@1* $\geq 0,25$ en *zero-shot* sobre las 54 clases L3 representadas en el conjunto de test.

Una lección metodológica derivada de la generación de *captions* sintéticas del corpus externo de $v5$ (coste de generación 42,33 USD) resultó de calibrar la longitud objetivo respecto al umbral de validación del verificador automático posterior. Un primer intento con rango 30–40 palabras produjo una tasa de rechazo del 54 %, dado que las *captions* se agrupaban en el suelo del rango y el verificador descartaba sistemáticamente las más cortas; recalibrar el objetivo a 40–55 palabras redujo el rechazo a cero. La regla operativa derivada es dimensionar la longitud objetivo de generación con margen explícito sobre el umbral mínimo aceptable, no sobre la media deseada.

Resultados *zero-shot*: progresión metodológica $v1 \rightarrow v4$ y ablación de escala $v5$

La tabla 4.43 reporta la *accuracy@1* sobre las 101 imágenes del conjunto de test bajo régimen híbrido *H6* homogéneo (combinación lineal de logits visuales y de logits textuales sobre plantillas ricas con pesos $w_v = 0,3$ y $w_t = 0,7$ respectivamente, calibrado sobre el conjunto de validación independientemente del conjunto de test), aplicado de forma uniforme a las cinco iteraciones para garantizar la comparativa cross-checkpoint directa. Para $v1$ – $v3$ los prototipos visuales empleados en *H6* derivan del espacio embebido del checkpoint sin LoRA visual; para $v4$ – $v5$ derivan del espacio embebido del checkpoint con *image-LoRA* expandida. La comparativa permanece interpretable porque los prototipos derivan del propio espacio embebido del *checkpoint* evaluado en cada caso. Los niveles L1 y L2 *zero-shot* sólo se reportan para $v4$ y $v5$ por constituir éstos los *checkpoints* relevantes para los regímenes operativos del prototipo.

4. RESULTADOS

Cuadro 4.43: Clasificación *zero-shot* SpanDerm-CLIP sobre el conjunto de test de 101 imágenes (per-case estratificado por L1) bajo régimen híbrido *H6* homogéneo ($w_v = 0,3$, $w_t = 0,7$) aplicado a las cinco iteraciones. La columna *Objetivo* corresponde al umbral fijado en el diseño experimental antes de observar resultados. Mejor cifra por fila excluyendo la columna *Objetivo* en negrita. Provenance: commit d0190c3 del repositorio `spanderm-clip`.

Tarea	Random	v1	v2	v3	v4	v5	Objetivo
L1 acc@1 (4 cls)	0,250	—	—	—	0,4257	0,4554	—
L2 acc@1 (23 cls)	0,043	—	—	—	0,1837	0,2041	—
L3 acc@1 (54 cls)	0,019	0,1782	0,1980	0,1980	0,2475	0,2079	$\geq 0,25$

La progresión $v1 \rightarrow v4$ articula la respuesta cuantitativa al diseño experimental sobre el nivel L3 bajo régimen *H6* homogéneo. Las tres primeras iteraciones quedan acotadas en el intervalo $[0,1782, 0,1980]$ sobre L3 *accuracy@1* con dispersión del orden de $\pm 0,02$, equivalente a ± 2 imágenes sobre $N = 101$, lo que sitúa a $v1$, $v2$ y $v3$ estadísticamente empatadas. La figura 4.10 muestra que $v3$ oscila en el intervalo $[0,04, 0,12]$ a lo largo de los 10 *epochs* sin aproximarse al objetivo. La cuarta iteración alcanza 0,2475 sobre L3 *accuracy@1*, esencialmente el umbral paper-grade fijado a priori: la diferencia de $-0,25$ pp respecto al objetivo 0,25 corresponde a una unidad de *accuracy* sobre $N = 101$ (0,0099) y se interpreta como ruido de muestreo sobre el conjunto de test. El salto $+4,95$ pp L3 entre $v3$ (0,1980) y $v4$ (0,2475) bajo idéntico régimen *H6* se atribuye exclusivamente a la ampliación de la capacidad arquitectónica del image encoder (LoRA $r = 32$ sobre los últimos doce bloques frente a $r = 16$ sobre cuatro), aislada del efecto del régimen de inferencia. La diferencia $v1 \rightarrow v4$ ($0,1782 \rightarrow 0,2475$, $+6,93$ pp, mejora relativa $\sim 39\%$) articula la respuesta global del experimento bajo el mismo régimen evaluativo. El salto resuelve la lectura cualitativa que las tres primeras iteraciones permitían anticipar: el cuello de botella no estaba en la formulación del lado textual ni en la falta de *captions* ricas, sino en la capacidad del lado visual para reesculpir las *features fine-grained* castellanas. La evidencia complementaria es el lift retrieval $14,0\times$ sobre el baseline aleatorio ya alcanzado por $v2$ con LoRA textual ligera (reportado más adelante en esta misma sección), que indica alineación cross-modal lograda sobre *captions* ricas sin que ello trasladasse el *zero-shot* L3 por encima del techo del encoder visual congelado.

La quinta iteración constituye una ablación deliberada de la hipótesis de escala. Bajo idéntica configuración LoRA que $v4$ y con el mismo régimen *H6* en inferencia, la ampliación del corpus de entrenamiento con 15 128 imágenes externas genéricas (ratio efectivo $6\times$ en favor del subconjunto castellano original) reduce el L3 *accuracy@1* a 0,2079 ($-4,0$ pp respecto a $v4$). El resultado se interpreta como *flat-to-negative* sobre el régimen híbrido y se discute mecanísticamente en sección 4.17: el encoder visual mejora aisladamente sobre régimen visual puro (*H1* $0,168 \rightarrow 0,238$ entre $v4$ y $v5$, $+41,2\%$ relativo), el techo *Linear Probing* L2 supervisado se eleva $+54,4\%$ relativo, y los niveles L1 y L2 *zero-shot* también mejoran bajo *H6* (L1 acc@1 $0,4257 \rightarrow 0,4554$, L2 acc@1 $0,1837 \rightarrow 0,2041$), pero el régimen híbrido sobre texto rico castellano para el nivel L3 *fine-grained* se degrada porque las *captions* externas erosionan la alineación específica del registro lingüístico del archivo original. La *long tail* no se rellena: las 327 clases L3 con ≤ 5 imágenes en el subconjunto castellano permanecen sin cobertura adicional tras la incorporación del corpus externo.

4.17. SpanDerm-CLIP: zero-shot multimodal castellano sobre DermapixelAI 1.0




Figura 4.10: Barrido de *epochs* de SpanDerm-CLIP v3 sobre el conjunto de test de 101 imágenes. *Accuracy@1* L1, L2 y L3 y *val i2t_R@5* frente al paso de entrenamiento. L3 oscila en el intervalo [0,04, 0,12] a lo largo de los diez *epochs* sin aproximarse al objetivo $\geq 0,25$, mientras que *val i2t_R@5* alcanza su máximo en *epoch* 2 y desciende con el entrenamiento conjunto adicional del codificador visual.

Recuperación cross-modal: resultado favorable paper-grade

El segundo eje de evaluación es la recuperación cross-modal per-imagen sobre los 107 pares (imagen, caption rica) del conjunto de validación, con script idéntico para las tres versiones. La tabla 4.44 reporta el régimen *rich-caption* (campo *llm_case_summary*, el más representativo del lenguaje clínico real de la Dra. R. Taberner).

Cuadro 4.44: Recuperación cross-modal i2t R@5 de SpanDerm-CLIP sobre los 107 pares (imagen, caption rica) de validación, régimen *rich-caption* (*llm_case_summary*). La columna *Lift* reporta el factor multiplicativo sobre el baseline aleatorio (*pool* = 107, baseline $R@5 = 5/107 = 0,0467$). v2 marca el pico histórico de alineación cross-modal castellano; v5 muestra descenso coherente con la degradación documentada en la tabla 4.43 sobre el régimen híbrido. v1 y v3 no se reportan por insuficiencia de datos en el régimen homogéneo cross-checkpoint. El *lift* sobre random se calcula como $R@5_{abs}/(k/N_{pool})$, con $k = 5$ y $N_{pool} = 107$; normaliza respecto a la dificultad intrínseca del *pool* y constituye la métrica honesta para comparar entre *checkpoints*.

Versión	i2t R@5 absoluto	Random baseline	Lift sobre random
v2	0,654	0,047	14,0×
v4	0,579	0,047	12,4×
v5	0,505	0,047	10,8×

La alineación cross-modal castellano-imagen alcanza su pico histórico en v2: i2t $R@5 = 0,654$ frente al baseline aleatorio 0,047 sobre *pool* de 107, equivalente a **14,0×** lift sobre random. Esta cifra constituye la contribución empírica favorable del experimento bajo régimen *rich-caption*. Las iteraciones posteriores conservan lift sustancial (v4 12,4×, v5 10,8×) pero descienden respecto al pico, en coherencia con la degradación documentada en la tabla 4.43 sobre régimen híbrido: el entrenamiento conjunto con

4. RESULTADOS

LoRA visual añadida (v4) y la posterior incorporación de *captions* externas (v5) desplazan el espacio embebido respecto al óptimo *rich-caption* castellano puro alcanzado por v2. El descenso v2→v5 del lift ($14,0\times \rightarrow 10,8\times$) acompaña cuantitativamente la hipótesis de erosión de la *fingerprint* clínica castellana discutida en sección 4.17.




Figura 4.11: Recuperación cross-modal i2t R@5 de SpanDerm-CLIP sobre 107 pares de validación, régimen *rich-caption*. Pico v2 de $14,0\times$ lift sobre random ($0,047 \rightarrow 0,654$) atribuible al conjunto LoRA textual + *captions* sintéticas ricas generadas mediante un modelo de lenguaje grande. v4 y v5 conservan lift sustancial ($12,4\times$ y $10,8\times$ respectivamente) pero descienden respecto al pico, en coherencia con la degradación documentada sobre el régimen híbrido.

Techo de *Linear Probing* y diagnóstico mecanístico

La pregunta clave del experimento es por qué ningún cambio en el lado textual mueve la aguja *zero-shot* L3. La respuesta surge de la medición rigurosa del techo *Linear Probing* sobre las *features* 1024-D del encoder visual, ejecutada con script idéntico para v2 (encoder visual frozen) y v3 (LP en *epoch* 2 y *epoch* 6). La tabla 4.45 reúne los tres puntos de la comparación.

Cuadro 4.45: Techo *Linear Probing* supervisado sobre *features* 1024-D del image encoder. Comparativa *frozen* (v2 e7) frente a image-LoRA tras entrenamiento adicional (v3 *epoch* 6). Métrica: *accuracy@1*. Las cifras de v3 corresponden a la evaluación intermedia conservada del Sprint97; la reejecución posterior arroja desviaciones $< 0,01$ absolutas, consistentes con ruido de muestreo ($N = 101$) y sin alterar la lectura ($+0,01 \approx$ ruido).

Nivel	LP v2-e7 frozen	LP v3 best.pt (e2)	LP v3 e6 (+image train)	Δ frozen→trained
L1 (4 vías)	0,584	0,584	0,594	+0,01
L2 (38 vías)	0,214	0,214	0,225	+0,01
L3 (225 vías)	0,079	0,079	0,089	+0,01

Dos observaciones estructuran el diagnóstico paper-grade. En primer lugar, el *zero-shot* L3 alcanzado por v1/v2/v3 ($\sim 0,13$) supera ya el techo LP supervisado (0,079–0,089)

sobre el mismo encoder visual frozen. Las *features* 1 024-D del PanDerm-Large congelado no separan linealmente los diagnósticos castellanos finos al nivel necesario para superar $L3 \sim 0,15$. Ningún ajuste del lado textual puede extraer información discriminativa que las *features* visuales no contienen. En segundo lugar, la adaptación LoRA visual de v3 (últimos cuatro bloques, 1,05 M parámetros) eleva el techo LP sólo +0,01 en cada nivel, del orden de una imagen de test, dentro del ruido. La LoRA confinada a los últimos cuatro bloques constituye capacidad insuficiente para reesculpir las *features* de PanDerm-Large en el régimen *fine-grained* castellano del archivo. El veredicto técnico es “*image LoRA did not help*” (no destruyó el preentrenamiento, el LP nunca cayó, pero tampoco lo mejoró sustancialmente).

El mecanismo por el cual el *zero-shot* de v3 cae respecto a v2 sin que el LP suba es interpretable: el entrenamiento conjunto desplaza los embeddings visuales hacia el espacio contrastivo de captions ricas y los aleja del espacio de plantillas de nombre de clase que el *zero-shot* usa internamente. La evidencia directa es que $L1 \text{ zero-shot accuracy@1}$ cae $0,426 \text{ (e2)} \rightarrow 0,287 \text{ (e7)}$ mientras el *train loss* sigue descendiendo a 0,29, lo que indica sobreajuste sobre el régimen *rich-caption*.

La cuarta y quinta iteraciones aportan la verificación cuantitativa del diagnóstico mecanístico anterior bajo las dos rutas candidatas de solución: capacidad arquitectónica adicional sobre el corpus original (v4) y escala externa genérica bajo capacidad idéntica a v4 (v5). La ruta arquitectónica se confirma: la extensión de LoRA visual de $r = 16$ sobre cuatro bloques a $r = 32$ sobre los últimos doce bloques eleva el $L3 \text{ accuracy@1 zero-shot}$ desde 0,119 (v3 *best-epoch*) a 0,2475 (v4 régimen *H6*), un salto de +12,9 pp que sitúa el sistema esencialmente en el umbral paper-grade 0,25. La lectura es directa: el cuello de botella identificado en v3 —LoRA confinada a cuatro bloques con 1,05 M parámetros— estaba infradotado, y la palanca real era la capacidad arquitectónica del image encoder, no la formulación textual ni el volumen de *captions*. La ruta de escala, en cambio, no replica la mejora: bajo configuración LoRA idéntica a v4, la ampliación del corpus con 15 128 imágenes externas degrada el $L3 \text{ accuracy@1 zero-shot}$ a 0,2079, −4,0 pp respecto a v4, pese a que el techo *Linear Probing* L2 supervisado se eleva +54,4 % relativo en BAcc sobre el mismo encoder visual evaluado de forma aislada. La conjunción de ambas observaciones refina el diagnóstico paper-grade: en corpora clínicos pequeños de alta especificidad lingüística, la palanca correcta para superar el techo $\sim 0,13$ del encoder congelado es ampliar capacidad arquitectónica del lado visual sobre el propio corpus, no incorporar imágenes externas con *captions* sintéticas generadas mediante un modelo de lenguaje grande sobre dominios afines pero estilísticamente discordantes.

Calibración por *temperature scaling*

Los logits *zero-shot* de SpanDerm-CLIP están severamente sobreconfiados, propiedad esperada en arquitecturas CLIP-style entrenadas con InfoNCE. La calibración con *temperature scaling* de un único parámetro escalar [33] sobre los 107 pares de validación reduce el *Expected Calibration Error* (ECE) medido sobre los 101 pares de test. La tabla 4.46 sintetiza el resultado sobre el *checkpoint* paper-grade v4 y la figura 4.12 ilustra el diagrama de fiabilidad para L3.

4. RESULTADOS

Cuadro 4.46: Calibración post-hoc por *temperature scaling* sobre SpanDerm-CLIP v4. Ajuste del escalar τ por optimización LBFGS sobre 107 pares de validación; ECE medido sobre 101 pares de test. La calibración sobre v5 no converge (la optimización LBFGS diverge sobre el espacio embebido *image-LoRA* expandido y $\tau \rightarrow 0$), por lo que queda registrada como limitación metodológica abierta.

Nivel	ECE antes	ECE después	τ
L3 (v4)	0,7262	0,0213	0,4165




Figura 4.12: Diagrama de fiabilidad sobre L3 antes y después de *temperature scaling* ($\tau = 0,4165$) sobre SpanDerm-CLIP v4. ECE descende de 0,7262 a 0,0213 (−97%). La calibración escalar de un parámetro restaura la interpretabilidad probabilística de los logits sin alterar el *ranking* entre clases.

La reducción es del −97 % sobre L3 con un único parámetro escalar [33]. La implicación se conecta con la sensibilidad de DermLIP documentada en sección 4.6: sin calibración post-hoc, las probabilidades de un sistema CLIP-style *zero-shot* castellano no son interpretables como confianza clínica. Cualquier despliegue posterior debe incorporar este escalado como capa final, ajustado sobre datos del propio archivo de destino. La extensión del mismo procedimiento a v5 no converge: la optimización LBFGS sobre el espacio embebido *image-LoRA* expandido lleva τ hacia cero y el ECE empeora respecto a la baseline sin calibrar. La limitación no afecta la integridad del resultado paper-grade asociado a v4 y se documenta como observación metodológica para iteraciones futuras: el procedimiento de calibración debe acotar el rango de búsqueda o emplear búsqueda en rejilla cuando el espacio embebido se ha expandido sustancialmente respecto al *checkpoint* sobre el que se calibró originalmente.

Trade-off entre escala externa y especificidad de dominio: ablación v4 vs. v5

La quinta iteración disocia experimentalmente las dos palancas candidatas para superar el techo *zero-shot* L3 del encoder visual sobre el corpus castellano: capacidad arquitectónica del *image encoder* (fijada en v4) y escala de datos externos con *captions* sintéticas (introducida en v5 manteniendo la misma configuración LoRA). El resultado, reportado en la tabla 4.43, es *flat-to-negative* sobre el nivel L3 *zero-shot* (0,2475 $\rightarrow$ 0,2079, −4,0 pp). La descomposición por régimen de inferencia ilumina la asimetría del efecto: bajo régimen visual puro *H1* —logits calculados exclusivamente sobre la similitud entre embedding visual de test y prototipos visuales castellanos— la transición v4 $\rightarrow$ v5 mejora la *accuracy@1* L3 de 0,168 a 0,238, un +41,2 % relativo, lo que confirma que el corpus externo fortalece el encoder visual aisladamente; pero bajo

régimen híbrido *H6* —combinación lineal con el lado textual sobre plantillas ricas— la cifra global cae. El techo *Linear Probing* L2 supervisado, evaluado con el mismo script empleado para v2-frozen y v3, se eleva +54,4 % relativo en BAcc de v4 a v5 (+36,8 % en *accuracy@1*, métrica auxiliar; se reporta la BAcc como métrica principal por el desbalance severo de la distribución L2 del corpus castellà), lo que constata que las *features* visuales sí han ganado capacidad discriminativa en el espacio 1 024-D.

La interpretación que reconcilia ambas observaciones es que las *captions* sintéticas generadas sobre el corpus externo genérico (PAD-UFES-20 [11], DermNet [13]) no preservan el registro discursivo del archivo Dermapixel 1.0: el modelo aprende a alinear los *embeddings* de imagen con un espacio textual mixto que diluye la *fingerprint* clínica castellana sobre la que se calibra el régimen *H6*. La pérdida de alineación supera, en términos de *accuracy@1* L3, la ganancia visual aislada. El hallazgo es metodológicamente convergente con el documentado en sección 4.6 sobre Derm1M: el enriquecimiento de *prompts* con material léxico no alineado con el corpus de preentrenamiento empeora la AUROC *zero-shot*, en lugar de mejorarla por incremento de información léxica. La regularidad empírica que ambos resultados sugieren es que la alineación cross-modal específica de un dominio clínico de alta especificidad lingüística constituye un recurso frágil: pequeñas perturbaciones estilísticas del lado textual pueden trasladar la distribución conjunta lo suficiente como para erosionar la discriminación final aunque las representaciones marginales mejoren.

Una segunda lectura cuantitativa refuerza el diagnóstico. La ampliación del corpus en v5 (854 → 15982 imágenes, factor $\approx 19\times$) no rellena la cola larga estructural del nivel L3: las 327 clases con ≤ 5 imágenes en el subconjunto castellano original mantienen su cardinalidad tras la incorporación de las imágenes externas, dado que el vocabulario externo no se mapea sobre las entradas L3 finas del archivo Taberner. Las ocho clases L3 críticas *deepened* en v5 —seis tumorales más dermatitis atópica y urticaria— ganan cobertura significativa de muestras, pero el grueso de la cola larga permanece inactiva. La implicación operativa para el diseño de futuras iteraciones es directa y se desarrolla en sección 7.5.4: superar *zero-shot* L3 $\sim 0,25$ sobre vocabulario castellano fino requiere anotación experta dirigida *in-domain* sobre las clases con peor cobertura, no escala genérica indiscriminada.

Una ablación independiente con un modelo fundacional inglés grande preentrenado (DermLIP v2 sobre $\approx 403\,000$ pares Derm1M [2]) confirma cuantitativamente este diagnóstico: el *wrapper* inglés con traducción de etiquetas alcanza *accuracy@1* L3 = 0,2871 en régimen *H6* comparable, frente a 0,2475 de SpanDerm-CLIP v4 (+3,96 pp), y 0,3861 en su mejor régimen de plantillas más texto rico (+13,86 pp), evidencia consistente con que la palanca limitante era la escala de la alineación cross-modal y no la formulación textual ni el codificador visual. El análisis completo, junto con la cuantificación del eje idioma puro sobre el propio *checkpoint* v4 (0,2475 castellà frente a 0,2277 inglés bajo *H6*) y el *trade-off* operativo entre ambas estrategias (rendimiento bruto frente a privacidad, especificidad lingüística y autonomía de despliegue), se desarrolla en el Anexo I.

Diagnóstico cuantitativo del techo experimental sobre L2

La tabla 4.47 sitúa SpanDerm-CLIP v2 en *zero-shot* L2 frente a las dos referencias internas documentadas previamente en el capítulo sobre el mismo conjunto de test

4. RESULTADOS

($N_{\text{test}} = 36$ en sección 4.11 y sección 4.14).

Cuadro 4.47: SpanDerm-CLIP *zero-shot* L2 frente a las dos referencias internas del capítulo sobre el mismo nivel ontológico. Las tres referencias evalúan sobre el conjunto de test de DermapixelAI 1.0; la cifra de SpanDerm-CLIP v2 corresponde al test de 101 imágenes del *split* per-case del experimento SpanDerm-CLIP y las dos restantes al test fijo $N_{\text{test}} = 36$ de la sección 4.11. La comparación es indicativa por la diferencia muestral.

Sistema	Régimen	Acc@1 L2	Observaciones
LP PanDerm Large (referencia, tabla 4.16)	Supervisado L2 cerrado	0,250	38 clases, $N_{\text{test}} = 36$
SpanDerm v0 LoRA (tabla 4.29)	Supervisado L2 cerrado	0,250	38 clases, $N_{\text{test}} = 36$
SpanDerm-CLIP v2	<i>Zero-shot</i> open	0,133	23 clases efectivas, $N_{\text{test}} = 101$

La lectura cuantitativa es coherente con la jerarquía esperada entre los tres regímenes: la cabeza supervisada cerrada con LoRA sobre el mismo encoder (SpanDerm v0) alcanza Acc@1 0,250 sobre L2, mientras que el sistema *zero-shot open-class* (SpanDerm-CLIP v2) alcanza 0,133 sobre un vocabulario reducido a las 23 clases efectivas en el test del *split* per-case del experimento. La diferencia operativa entre ambos regímenes es la capacidad de SpanDerm-CLIP de aceptar consultas textuales libres en castellano sin necesidad de fijar el vocabulario por anticipado, propiedad explotada en el módulo RAG castellano del prototipo (Anexo H).

Síntesis: progresión v1 → v4 y ablación negativa v5

La tabla 4.48 sintetiza la trayectoria completa de la familia SpanDerm-CLIP sobre el conjunto de test de DermapixelAI 1.0, articulando para cada iteración la configuración LoRA, el régimen de inferencia, las dos cifras de referencia (*L3 accuracy@1 zero-shot* y *lift* de recuperación cross-modal *i2t* R@5) y la lectura cualitativa asociada.

4.17. SpanDerm-CLIP: zero-shot multimodal castellano sobre DermapixelAI 1.0

Cuadro 4.48: Comparativa de las cinco iteraciones del entrenamiento SpanDerm-CLIP sobre el corpus DermapixelAI 1.0. Régimen evaluativo *zero-shot* L3 sobre 101 imágenes de test (54 clases L3 representadas), *H6 hybrid* v30_r70 (combinación 30% prototipos visuales + 70% texto rico) aplicado de forma homogénea a las cinco iteraciones. v4 alcanza el objetivo paper-grade 0,25 acc@1 L3 mediante expansión arquitectónica (*image-LoRA* $r = 32$ sobre 12 bloques + *ensemble* híbrido texto-visual). v5 confirma negativamente que la escala externa genérica con *captions* sintéticas no supera v4. Para v1–v3 los prototipos visuales derivan del espacio embebido del *checkpoint* sin LoRA visual; v4–v5 emplean prototipos sobre el espacio embebido con *image-LoRA* expandido. La comparativa permanece interpretable porque los prototipos derivan del propio espacio embebido del *checkpoint* evaluado. Provenance: commit d0190c3 del repositorio `spanderm-clip`. Las cifras Linear Probing BAcc L2 absolutas para v4 (0,1860) y v5 (0,2871) proceden de los ficheros JSON `eval_v5/linear_probe_v4ref.json` y `eval_v5/linear_probe_v5.json`; el delta relativo +54,4% queda confirmado.

Versión	LoRA texto	LoRA visual	acc@1 L3	Lift i2t R@5	LP BAcc L2	Notas
v1	—	—	0,1782	—	—	Baseline e5 <i>full FT</i>
v2	$r = 16, \alpha = 32$	—	0,1980	14,0×	—	Pico retrieval rich
v3	$r = 16, \alpha = 32$	$r = 16$, últ. 4/24	0,1980	—	—	Image-LoRA infradotado
v4	$r = 32, \alpha = 64$	$r = 32$, últ. 12/24	0,2475	12,4×	0,1860	Target paper-grade
v5	$r = 32, \alpha = 64$	$r = 32$, últ. 12/24	0,2079	10,8×	0,2871	FLAT: escala externa (+54,4% relativo sobre v4)

Nota histórica. Los valores *rich-only baseline* (un *caption* clínico por clase ~ 30–80 palabras castellano) fueron 0,1287 (v1), 0,1386 (v2) y 0,1089 (v3) en el régimen `baseline_5_templates` original de la evaluación previa. La transición al régimen *H6 hybrid* homogéneo presentado en esta tabla permite la comparativa directa cross-*checkpoint* mediante el mismo procedimiento evaluativo (prototipos visuales 30% + texto rico 70%). El detalle metodológico se desarrolla en Anexo G.

La lectura conjunta sobre las cinco iteraciones articula tres ejes de mejora con valoración empírica diferenciada. El eje de capacidad arquitectónica queda validado por v4: la transición v3→v4 (LoRA $r = 16$ sobre cuatro bloques → $r = 32$ sobre doce bloques) eleva el L3 *zero-shot* de 0,1980 a 0,2475 bajo régimen *H6* homogéneo, +4,95 pp, y la mejora global v1→v4 alcanza el ~ 39% relativo (0,1782 → 0,2475). La hipótesis formulada tras la medición del LP en v3 —el cuello de botella reside en la capacidad del image encoder— queda confirmada cuantitativamente bajo la solución arquitectónica correcta. El eje de escala externa queda *flat-to-negative* en v5: bajo configuración LoRA idéntica a v4, la ampliación del corpus con 15 128 imágenes externas genéricas no replica la mejora pese a que las representaciones visuales aisladas mejoran (+41,2% relativo H1, +54,4% relativo LP L2). La conclusión metodológica es que la escala externa genérica con *captions* sintéticas erosiona la *fingerprint* clínica específica del registro castellano original, en convergencia con la sensibilidad de DermLIP al tokenizador documentada en sección 4.6. El eje de supervisión conceptual —anotaciones del *Seven-Point Checklist* sobre Derm7pt [9] o anotaciones del Grupo A de la Dra. R. Taberner (Anexo F)— queda abierto a futuras iteraciones del proyecto y se desarrolla como línea prioritaria en sección 7.5.4 bajo la formulación de aprendizaje activo dirigido sobre las clases L3 con peor cobertura.

El experimento aporta cuatro contribuciones al cuerpo del trabajo. En primer lugar, valida la utilidad del codificador PanDerm Large para tareas castellanas más allá del LP/FT supervisado documentado en las secciones previas: bajo la combinación de

LoRA $r = 32$ sobre los últimos doce bloques del ViT y régimen híbrido visual-textual $H6$ en inferencia, el sistema alcanza esencialmente el umbral paper-grade L3 0,25 sobre vocabulario castellano fino. En segundo lugar, disocia experimentalmente capacidad arquitectónica de escala de datos sobre el mismo corpus: la primera demuestra ser palanca efectiva ($v3 \rightarrow v4$) y la segunda *flat-to-negative* ($v4 \rightarrow v5$), un resultado negativo honesto que orienta el diseño de futuras iteraciones. En tercer lugar, establece metodología reproducible para evaluaciones CLIP-style sobre archivos privados de pequeña escala: recuperación per-imagen (no per-pair, sesgada sobre corpus con multiplicidad alta de captions), medición LP consistente entre versiones, régimen de inferencia $H6$ con calibración del peso visual sobre validación independiente, *ensemble* de plantillas castellanas, calibración escalar post-hoc [33], manifest SHA-256 fijado en cada *checkpoint* y *splits* per-case estratificados. En cuarto lugar, aporta material empírico publicable: la recuperación cross-modal **14,0** $\times$ lift sobre random con captions ricas castellanas ($v2$, $R@5 = 0,654$ frente a 0,047), calibración escalar -97% ECE sobre L3 ($v4$, $0,7262 \rightarrow 0,0213$ con $\tau = 0,4165$), umbral L3 *zero-shot* 0,2475 sobre vocabulario castellano fino bajo configuración arquitectónica correcta ($v4$) y ablación negativa documentada de la hipótesis de escala externa indiscriminada ($v5$) constituyen una unidad coherente que ningún trabajo previo ha publicado en castellano sobre archivo privado clínico. El sistema validado en $v4$ es candidato a integrarse como módulo de búsqueda textual castellano del prototipo DermApIxel (Anexo H), complementario al módulo M4 sobre Derm1M en inglés, con la calibración escalar $\tau = 0,4165$ ajustada sobre el conjunto de validación del propio archivo de destino como capa final antes de exponer probabilidades al usuario.

DISCUSIÓN

5.1 Significado de los resultados

5.1.1 Especialización del dominio frente a encoders generalistas

Los resultados del sondeo lineal (sección 4.1 y sección 4.2) sostienen la hipótesis de que el preentrenamiento sobre datos del dominio clínico aporta una ventaja empírica medible sobre encoders generalistas adaptados. PanDerm Large supera a PanDerm Base en accuracy, AUROC y F1 ponderada sobre los diez datasets externos contrastados, con mejora media de +4,1 pp en accuracy, +9,0 pp en BAcc y +3,6 pp en AUROC. La mejora absoluta es máxima sobre Dermnet (+10,0 pp accuracy), WSI patches (+8,7 pp) y PAD-UFES-20 (+4,7 pp), datasets con mayor número de clases o mayor heterogeneidad de adquisición.

La comparación entre PanDerm Large y la mejor arquitectura convolucional supervisada cuantifica la magnitud del beneficio del preentrenamiento de dominio en función de la dificultad del dataset. Sobre HAM10000 (dermatoscopia estandarizada), la brecha en accuracy es modesta (+0,5 pp) y ConvNeXt-Large incluso supera a PanDerm Large en AUROC (0,967 vs 0,954, −1,3 pp), comportamiento compatible con el hecho de que las características generales de ImageNet-21K capturan ya patrones suficientemente informativos para el ranking de probabilidades en una modalidad estandarizada. Sobre PAD-UFES-20 (fotografía clínica con dispositivo móvil), la brecha es de +8,2 pp accuracy y +5,4 pp AUROC; sobre DDI (fotografía clínica con representación equilibrada de fototipos), +2,9 pp accuracy y +8,6 pp AUROC. El patrón sugiere que la ventaja del preentrenamiento de dominio crece con la distancia entre el dataset y los corpus web generalistas, y resulta especialmente relevante en condiciones clínicas no estandarizadas (atención primaria, teledermatología con dispositivos heterogéneos).

SigLIP-Large SO400M, modelo vision-lenguaje generalista, obtiene la mejor accuracy y AUROC sobre HAM10000 (0,900/0,971), comportamiento atribuible a la sobre-representación de dermatoscopia estandarizada en los 400 millones de pares imagen-texto web de su preentrenamiento. La superioridad de SigLIP-Large desaparece sobre

PAD-UFES-20 y DDI, lo que delimita su rango de utilidad: es competitivo en modalidades canónicas pero no en material clínico heterogéneo.

La caracterización del preentrenamiento específico de dominio admite además una segunda lectura sobre el nivel ontológico de subcategoría clínica. El experimento de combinación de codificadores sobre DermapixelAI 1.0 (sección 4.11, tabla 4.21) sitúa a DermLIP v2 como la mejor cabeza individual sobre L2 con AUROC 0,860, +6,7 pp por encima de PanDerm Large (0,793) y +15,3 pp por encima de PanDerm Base (0,707). El hallazgo es coherente con la lectura *zero-shot* sobre el mismo corpus (sección 4.12), donde DermLIP v2 lidera también la AUROC L2 sin entrenar cabeza alguna (0,794 en inglés). La interpretación conjunta sugiere que el preentrenamiento contrastivo texto-imagen sobre el millón de pares de Derm1M [2] captura la granularidad de subcategoría clínica con mayor fidelidad que el preentrenamiento auto-supervisado puro de la familia PanDerm, lo que matiza la jerarquía PanDerm Large > PanDerm Base > DermLIP v2 observada en la mayoría de datasets y niveles: la elección del codificador óptimo depende del nivel ontológico, y el preentrenamiento multimodal aporta una señal complementaria sobre la categorización clínica intermedia que no se reduce al beneficio de las *features* visuales aisladas.

El experimento de ajuste fino parcial sobre DermapixelAI 1.0 nivel L1 (sección 4.11, tabla 4.23) refuerza esta lectura desde un ángulo metodológico. Con $N_{\text{train}} = 874$ y el encoder PanDerm Large parcialmente descongelado (25,2 M parámetros entrenables), el FT mejora la BAcc en +18,2 pp sobre la cifra robusta del sondeo lineal congelado estimada por validación cruzada agrupada por caso ($0,440 \rightarrow 0,622$), pero no supera al *ensemble* lineal *avg_large_derm1ip* de la sección 4.11 (BAcc 0,622 vs 0,702, AUROC 0,715 vs 0,817). El patrón es coherente con la literatura sobre régimen de bajo N : una combinación lineal de codificadores fundacionales congelados aprovecha la diversidad de sus representaciones pre-entrenadas sin introducir los parámetros adicionales que el FT denso requiere ajustar a partir de un corpus reducido. La implicación de diseño para SpanDerm v0 (sección 7.5.2) es directa: las líneas prioritarias son la adaptación de bajo rango mediante LoRA y la combinación de codificadores con cabezas ligeras antes que el FT denso clásico, opción metodológica que las cifras empíricas sobre el corpus en castellano justifican. La ejecución posterior de SpanDerm v0 (sección 4.14) confirma cuantitativamente esta implicación: la adaptación LoRA sobre los dos últimos bloques de PanDerm Large con sólo 524 K parámetros entrenables (0,17 % del total) alcanza BAcc = $0,363 \pm 0,007$ sobre L2, +19,5 pp sobre la cifra de validación cruzada del sondeo lineal congelado y +8,4 pp sobre DermLIP v2 individual, situándose como la mejor BAcc L2 documentada sobre el corpus. La lectura cruzada con DermLIP v2 es particularmente informativa: la AUROC L2 de SpanDerm v0 ($0,855 \pm 0,006$) empata estadísticamente con la de DermLIP v2 nativo (0,860), lo que sugiere que el techo discriminativo del corpus a nivel L2 es alcanzable tanto por el preentrenamiento contrastivo PubMedBERT-DermLIP nativo como por la adaptación textual ligera vía LoRA de un encoder de mayor capacidad. La elección del codificador base y la estrategia de adaptación operan como dimensiones aproximadamente ortogonales sobre la cardinalidad L2.

La extensión posterior del FT denso parcial a los niveles L2 y L3 (sección 4.11, tabla 4.24) confirma el patrón observado en L1 sobre la cardinalidad clínica L2: el FT denso con 25,2 M parámetros entrenables alcanza BAcc L2 0,324 y AUROC L2 0,852, sin superar a SpanDerm v0 LoRA (524 K parámetros entrenables, BAcc 0,363, AUROC 0,855). La diferencia de -4,0 pp BAcc y empate en AUROC sobre un encoder 48 veces

menos parametrizado refuerza la hipótesis metodológica formulada en sección 5.1.3: bajo $N_{\text{train}} = 874$, la adaptación de bajo rango sobre un encoder fundacional congelado domina al FT denso clásico sobre el mismo encoder. Sobre L3, el FT denso no mejora al sondeo lineal (+0,0 pp BAcc, -0,9 pp AUROC), lo que confirma que la cola larga estructural (3,9 muestras por clase de media en *train*) constituye un techo absoluto sobre cualquier protocolo de ajuste denso sobre el corpus actual.

La extensión a codificadores generalistas no médicos (sección 4.16) refuerza la lectura de no-uniformidad: CLIP-L-336 generalista, sin material biomédico en su pre-entrenamiento, encabeza la AUROC sobre L2 (0,826 vs 0,793 PanDerm Large, +3,3 pp) y sobre L3 (0,827 vs 0,813, +1,4 pp) bajo sondeo lineal, lo que matiza la hipótesis de especialización de dominio sobre las métricas de ranking probabilístico. La sustitución del clasificador paramétrico por *retrieval k*-NN con índice FAISS sobre los mismos *embeddings* PanDerm Large (sección 4.16) supera al sondeo lineal sobre el régimen de cola larga severa L3 (+2,6 pp BAcc, +3,5 pp Acc@1), evidencia adicional de que ningún codificador ni clasificador único domina en todos los niveles ontológicos y de que la elección óptima debe condicionarse al nivel objetivo y al criterio operativo predominante.

5.1.2 Eficiencia en etiquetas y régimen de saturación

La curva de eficiencia en etiquetas (sección 4.4, tabla 4.5) documenta un fenómeno consistente con encoders preentrenados sobre corpus masivos del dominio: la saturación del rendimiento sobre HAM10000 ocurre con un volumen de datos etiquetados muy reducido. Con 1 % del conjunto de entrenamiento (82 imágenes), PanDerm Large alcanza 0,850 accuracy y 0,918 AUROC, lo que equivale al 95,7 % y al 96,2 % del rendimiento con el conjunto completo respectivamente. Con 5 % (410 imágenes), la AUROC sube a 0,932, equivalente al 97,7 % del rendimiento máximo; la diferencia con 100 % es de sólo 2,2 pp. La BAcc, en cambio, escala con mayor lentitud y alcanza su máximo en 50 % del conjunto (0,589), comportamiento consistente con la dependencia de las clases minoritarias frente al volumen total.

Sobre PAD-UFES-20 ($N_{\text{train}} = 1493$ con el conjunto completo), la saturación es aún más temprana: con 14 imágenes (1 %) se alcanza 0,740 accuracy y 0,907 AUROC, lo que equivale al 95,5 % del AUROC con el conjunto completo. La implicación clínica es directa: en contextos con disponibilidad limitada de datos etiquetados (enfermedades raras, centros de bajo volumen, subgrupos poco representados), una cabeza lineal sobre PanDerm Large preentrenado constituye una opción técnicamente defendible.

5.1.3 Sondeo lineal frente a ajuste fino

La comparación directa entre sondeo lineal y ajuste fino sobre cuatro datasets (sección 4.3, tabla 4.4) identifica un patrón asimétrico cuya interpretación operativa es relevante para el diseño de sistemas clínicos. Sobre HAM10000 y PAD-UFES-20, datasets con tamaño de entrenamiento intermedio o alto ($N \in [1493, 8207]$), el ajuste fino mejora la BAcc en +47,1 pp y +19,4 pp respectivamente, lo que confirma la utilidad de la receta original de PanDerm con *weighted random sampler*, Mixup, CutMix y *layer decay* para el aprendizaje de las clases minoritarias en presencia de desbalance acusado.

Sobre DDI, con $N_{\text{train}} = 427$, el comportamiento se invierte: el sondeo lineal supera al ajuste fino en accuracy (+7,3 pp), BAcc (+2,1 pp), AUROC (+14,5 pp) y F1 ponderada

(+5,6 pp). El descenso de AUROC ($0,827 \rightarrow 0,682$) es particularmente diagnóstico: indica que el encoder ajustado pierde capacidad de ranking sobre el *test*, comportamiento compatible con sobreajuste a la distribución de entrenamiento pese a las aumentaciones empleadas. Sobre MSKCC ($N_{\text{train}} = 6\,189$), la mejora de BAcc es marginal (+3,0 pp) y la AUROC desciende ligeramente (−2,7 pp).

Estos tres casos delimitan un régimen operativo cuantificable: para datasets con $N_{\text{train}} \lesssim 500$ imágenes, el sondeo lineal sobre PanDerm Large constituye la opción de referencia; para $N_{\text{train}} \gtrsim 5\,000$, el ajuste fino con la receta original es preferible siempre que existan clases minoritarias clínicamente relevantes que el sondeo lineal no logre discriminar. Entre ambos regímenes, la decisión depende del desbalance de clases y del coste computacional asumible.

5.1.4 Segmentación promptable y adaptación de bajo coste

Los resultados de segmentación binaria sobre ISIC2018 (sección 4.5, tabla 4.6) son el hallazgo con mejor magnitud absoluta del trabajo: SAM2.1-Large con adaptación LoRA ($r = 8$) alcanza Dice 0,947 sobre el conjunto de test de ISIC2018, superando en +2,6 pp la cifra publicada por Yan et al. [1] (0,921) y en +5,3 pp al baseline CAE-seg con backbone PanDerm Large entrenado desde cero (0,894). La adaptación añade $\sim 4,5$ M parámetros entrenables sobre los ~ 227 M de SAM2.1-Large (proporción inferior al 2%), lo que mantiene el coste computacional bajo.

La transferencia fuera de dominio es prácticamente nula: Dice desciende sólo 0,002 pp sobre ISIC2017 ($0,947 \rightarrow 0,945$) y, sobre PH2, sube hasta 0,960. Este patrón se interpreta como evidencia de que las representaciones del encoder visual congelado (Hiera-Large) codifican primitivas geométricas y de contorno suficientemente generales, y que la adaptación de bajo rango sobre el decodificador de máscaras y el *promptable encoder* captura los matices específicos del dominio dermatoscópico sin sobreajustar a una fuente concreta de adquisición. El paso de SAM2 *zero-shot* a SAM2.1-Large con LoRA introduce mejoras de +14,8 pp Dice sobre ISIC2017 y +7,4 pp sobre PH2, lo que cuantifica el aporte específico de la adaptación de dominio.

5.1.5 Sensibilidad al tokenizador en zero-shot multimodal

La evaluación zero-shot sobre HAM10000 (sección 4.6, tabla 4.8) documenta una sensibilidad acusada al tokenizador y a la formulación de los *prompts*. La AUROC oscila entre 0,366 (DermLIP v1/v2 con tokenizador PubMedBERT y *prompts* genéricos) y 0,854 (DermLIP original con tokenizador GPT-2/CLIP y *prompts* A3 de Derm1M), un rango de 48,8 pp para variaciones que no afectan a los pesos visuales sino exclusivamente a la rama lingüística y a la formulación textual de las clases.

El valor AUROC $< 0,5$ con la configuración inicial es diagnóstico: indica que el espacio textual proyectado por PubMedBERT no está alineado con el espacio visual del encoder de DermLIP v1/v2, lo que resulta en una correlación efectivamente invertida respecto a la tarea de clasificación. Dos modificaciones aisladas permiten interpretar el origen de la mejora: el cambio del conjunto A3 manteniendo el tokenizador PubMedBERT eleva AUROC a 0,516 (+15,0 pp), mientras que el cambio de tokenizador manteniendo el conjunto A3 alcanza 0,854 (+33,8 pp adicionales). El factor crítico es por tanto la compatibilidad del tokenizador con el espacio de *embeddings* del modelo

contrastivo. La implicación práctica es que cualquier despliegue zero-shot debe verificar empíricamente la combinación modelo-tokenizador-*prompt* sobre un conjunto de validación del dominio, dado que la transferencia desde la configuración publicada por los autores no está garantizada.

La evaluación adicional sobre DermapixelAI 1.0 (sección 4.12, tabla 4.27) extiende esta lectura hacia la dimensión idiomática. DermLIP v2 con *prompts* en inglés alcanza $\text{Acc}@1 = 0,500$ sobre la categoría etiológica L1, frente a 0,361 con *prompts* equivalentes en castellano (−13,9 pp); SigLIP-SO400M presenta una caída de −11,1 pp en la misma comparación. BiomedCLIP mantiene $\text{Acc}@1 = 0,389$ en ambos idiomas, lo que sitúa la penalización por castellano como dependiente del corpus textual de preentrenamiento. La magnitud cuantificada motiva la construcción de modelos vision-lenguaje contrastivos con rama textual entrenada sobre material clínico en castellano como línea futura inmediata.

5.1.6 Brecha entre modelos específicos y LLMs multimodales

La comparación de paradigmas sobre HAM10000 (sección 4.7, tabla 4.10) establece un orden de magnitud entre familias que es relevante para la selección de arquitectura en escenarios clínicos. PanDerm Base con ajuste fino y *test-time augmentation* sobre HAM10000 alcanza 0,920 accuracy y 0,852 BAcc; SigLIP-Large con sondeo lineal, 0,900; MedGemma 27B con LoRA sobre HAM10000, 0,802; MedGemma 27B sin *fine-tuning*, 0,665; GPT-4o *zero-shot*, 0,485; Gemini 2.5 Pro *zero-shot*, 0,403. El gradiente de rendimiento es de 43,5 pp en accuracy entre el mejor especialista ajustado y el mejor LLM multimodal *zero-shot* (0,920 − 0,485).

Tres observaciones cuantitativas complementan esta brecha. Primero, la adaptación con LoRA sobre MedGemma 27B sobre el *split* de entrenamiento de HAM10000 produce mejoras de +13,7 pp Acc sobre HAM10000 y +18,3 pp Acc sobre DDI respecto a la variante *zero-shot*, sin mejora apreciable sobre PAD-UFES-20 (−1,7 pp). El comportamiento es asimétrico: la adaptación captura patrones del dataset de entrenamiento sin transferencia sistemática al resto. Segundo, GPT-4o y GPT-4o-mini presentan patrones de error con sesgo hacia clases minoritarias del *prompt*: GPT-4o emite 284 predicciones de dermatofibroma sobre 8 muestras reales y 299 predicciones de melanoma sobre 70 muestras, lo que sugiere que el modelo responde al espacio léxico del *prompt* en lugar de a la evidencia visual. Tercero, BLIP-2 e InstructBLIP con *Q-Former* preentrenado producen accuracy ~ 0,02 sobre HAM10000 y PAD-UFES-20, comportamiento incompatible con cualquier uso clínico y atribuible a la falta de adaptación al vocabulario dermatológico.

El coste agregado de la evaluación con APIs comerciales sobre los tres datasets es de aproximadamente \$4,07. MedGemma 27B opera localmente en BF16 sobre los 128 GB de memoria unificada de la DGX Spark sin cuantización, con latencia media de 1,49 segundos por imagen. La diferencia operativa es relevante para un despliegue hospitalario: los modelos cerrados añaden coste recurrente y dependencia de un proveedor externo, sin mejora apreciable de rendimiento clínico.

5.1.7 Equidad por fototipo cutáneo

La evaluación sobre Fitzpatrick17k completo (sección 4.8, tablas 4.13 y 4.14) reproduce y cuantifica un patrón conocido en la literatura: los cinco encoders contrastados presentan *gap* I-VI positivo en la formulación de tres clases de malignidad, con valores entre +0,124 y +0,306 pp de BAcc. La interpretación del *gap* requiere considerar la BAcc global de cada modelo. DermLIP v2 obtiene la mejor BAcc global (0,721) y la mejor AUROC global (0,909), pero su *gap* I-VI es +0,281 pp, indicando que el rendimiento sobre FST VI (0,434) cae substancialmente respecto a FST III (0,765). PanDerm Large presenta un *gap* menor (+0,217 pp) con BAcc global ligeramente inferior (0,699); BiomedCLIP, el *gap* mínimo (+0,124 pp) pero la peor BAcc global (0,590).

Esta última asimetría —*gap* mínimo con BAcc global inferior— ilustra el carácter no decisonal de la métrica de equidad aislada. Un modelo uniformemente inferior entre subgrupos puede presentar baja desigualdad aritmética sin ser equitativo en sentido sustantivo, dado que su rendimiento es bajo en todos los fototipos por igual. La interpretación operativa de las cifras exige por tanto considerar BAcc global y *gap* de forma conjunta. El modelo con mejor compromiso entre ambas variables es PanDerm Large, seguido de DermLIP v2 cuando se ponderan el rendimiento sobre FST I-IV y la AUROC global.

El experimento cruzado *Light* $\leftrightarrow$ *Dark* (tabla 4.14) aporta una segunda lectura: la caída de rendimiento al entrenar sólo con fototipos claros y evaluar sobre fototipos oscuros (L $\rightarrow$ D vs L $\rightarrow$ L) es máxima en DINOv2 (Δ = -0,132 pp BAcc) y mínima en BiomedCLIP (Δ = -0,063 pp). DermLIP v2 mantiene la menor caída Dark $\rightarrow$ Light vs Dark $\rightarrow$ Dark (Δ = +0,016 pp), lo que sugiere mayor invariancia de sus representaciones al fototipo. El patrón es coherente con la composición de su corpus de preentrenamiento Derm1M, derivado de fuentes web abiertas con representación variable de fototipos.

5.1.8 Estimación robusta del rendimiento sobre corpus de tamaño moderado

La aplicación de validación cruzada de cinco *folds* agrupada por caso clínico sobre DermapixelAI 1.0 (sección 4.11, tabla 4.26) constituye un argumento metodológico relevante para la evaluación de modelos fundacionales sobre corpus de tamaño moderado. La diferencia entre la cifra puntual del split fijo y la media de los cinco *folds* es sustancial sobre BAcc (-29,5 pp en L1) y prácticamente estable sobre AUROC (-4,3 pp en L1), patrón que cuantifica la sensibilidad de las métricas dependientes de umbral al cambio de realización muestral cuando el conjunto de test es reducido ($N = 36$). La interpretación operativa es doble. *Primero*, la cifra del split publicado es válida como punto operativo de referencia comparable con la evaluación *zero-shot* (sección 4.12, que utiliza el mismo test para trazabilidad cruzada), pero requiere acompañarse de la estimación cruzada para defender el rendimiento esperado del sistema. *Segundo*, la AUROC *one-vs-rest* resulta la métrica primaria recomendable para comparar configuraciones de *transfer learning* congelado sobre corpus clínicos de tamaño moderado, mientras que la BAcc y la *accuracy* deben reportarse acompañadas de su intervalo de confianza y, cuando sea posible, de su estimación cruzada por *folds*. La práctica refuerza la fiabilidad del benchmark y delimita explícitamente el alcance interpretativo

de las cifras puntuales.

5.2 Comparación con la literatura

5.2.1 Reproducción del benchmark de PanDerm

El trabajo original de Yan et al. [1] reporta para PanDerm Large sobre los 28 *downstream tasks* de su benchmark interno una mejora media del +10,2% sobre el estado del arte previo. Las cifras de sondeo lineal de la tabla 4.1 se sitúan dentro del margen reportado por los autores para los datasets compartidos (HAM10000, PAD-UFES-20, Derm7pt) y reproducen cualitativamente el comportamiento del modelo en arquitectura aarch64 con CUDA 13.0 y BF16. La verificación numérica respecto al hardware x86_64 canónico es por tanto satisfactoria dentro de las tolerancias esperables por aritmética BF16 y por diferencias de versiones de cuDNN, lo que documenta la portabilidad del pipeline al chip Grace Hopper GB10.

La extrapolación de la cifra agregada del paper (+10,2%) a la diferencia PanDerm Large vs PanDerm Base sobre los diez datasets externos contrastados de este trabajo (+4,1 pp accuracy, +9,0 pp BAcc) es coherente: +9,0 pp BAcc es próximo al +10,2% que los autores reportan sobre su benchmark interno, lo que sugiere que la ventaja del modelo Large es estable entre los conjuntos públicos contrastados y los conjuntos internos del grupo de Monash.

5.2.2 Segmentación binaria de lesión

La cifra de SAM2.1-Large con LoRA sobre ISIC2018 (0,947 Dice) supera en +2,6 pp el resultado publicado por Yan et al. [1] (0,921 Dice con 100 épocas). Tres factores plausibles explican la diferencia: (i) la arquitectura promptable de SAM2.1 con *bounding box* derivada de la máscara de *ground truth* aporta un guiado espacial fuerte que las arquitecturas no promptables no aprovechan; (ii) el encoder Hiera-Large preentrenado sobre ~ 11 millones de imágenes y mil millones de máscaras codifica primitivas geométricas más informativas que las que el backbone visual de PanDerm aprende sobre dermatoscopia; (iii) la adaptación LoRA introduce un número de parámetros suficiente para capturar las particularidades del dominio sin sobreajuste, mientras que un *fine-tuning* completo sobre 50 épocas podría requerir más datos o regularización adicional para superar la cifra de referencia. La interpretación operativa es que la segmentación binaria de lesión sobre dermatoscopia se encuentra cerca de la saturación cuando se combinan un encoder promptable preentrenado a gran escala y una adaptación de bajo coste sobre ISIC2018.

5.2.3 Comportamiento zero-shot

La AUROC máxima alcanzada en este trabajo sobre HAM10000 con DermLIP en formulación zero-shot (0,854) coincide cualitativamente con los rangos reportados en el paper original de Derm1M [2] para la configuración de mejor rendimiento. La sensibilidad al tokenizador documentada en sección 5.1.5 no está cuantificada de forma sistemática en la literatura previa sobre la familia DermLIP, lo que constituye una aportación empírica del presente trabajo. La diferencia de 48,8 pp AUROC entre la peor y la

mejor configuración testada sobre el mismo encoder visual es de un orden de magnitud similar al efecto de cambiar entre paradigmas (LP vs ZS), lo que desplaza la discusión metodológica desde el modelo hacia su configuración operativa.

5.2.4 Disparidad por fototipo

El sentido de la desigualdad —peor rendimiento sobre fototipos elevados— coincide con los hallazgos previos sobre Fitzpatrick17k [14] y con la motivación que dio origen a la curación de DDI [12]. El presente trabajo extiende esta línea evaluando cinco encoders bajo un mismo protocolo, lo que permite contrastes directos. La paradoja BiomedCLIP (*gap* mínimo asociado a peor BAcc global) no está documentada de forma explícita en la literatura sobre equidad dermatológica y constituye una observación sobre la métrica *gap* aislada que invita a reportes complementarios: BAcc global, AUROC global y *gap* deben presentarse conjuntamente.

5.3 Implicaciones operativas

5.3.1 Arquitectura defendible para sistemas de apoyo al diagnóstico

La combinación de los cuatro bloques de evidencia anteriores sugiere una arquitectura técnicamente defendible para sistemas de apoyo al diagnóstico dermatológico construidos sobre los modelos fundacionales disponibles. La estructura recomendable es la siguiente: encoder PanDerm Large preentrenado, congelado por defecto y opcionalmente ajustado bajo demanda; cabeza lineal multi-clase con regresión logística (L-BFGS, $C = 1,0$, $\text{max_iter} = 5000$) cuando el conjunto de entrenamiento disponible sea reducido ($N_{\text{train}} \lesssim 500$); cabeza ajustada con la receta de PanDerm Large (Mixup, CutMix, *weighted random sampler*, 50 épocas) cuando $N_{\text{train}} \gtrsim 5000$ y exista desbalance acusado; segmentación con SAM2.1-Large adaptado mediante LoRA ($r = 8$) cuando la tarea requiera localización de lesión.

La rama lingüística contrastiva (DermLIP) se incorpora únicamente con prompts validados y tokenizador compatible verificado sobre un conjunto de validación del dominio. La rama LLM multimodal generalista (GPT-4o, Gemini, MedGemma) no se incorpora como clasificador principal, dado el orden de magnitud de rendimiento inferior cuantificado en sección 5.1.6; su rol natural es complementario, como generador de razonamiento textual o explicaciones para casos previamente clasificados por el encoder especializado.

5.3.2 Armonización taxonómica y nivel de agregación

La heterogeneidad taxonómica entre datasets, mitigada mediante la ontología jerárquica L1/L2/L3 descrita en sección 3.2, sigue requiriendo una decisión explícita sobre el nivel de agregación al que se realizan los contrastes. La comparación inter-dataset es defendible a nivel L1 (cuatro familias etiológicas) y L2 (43 subcategorías clínicas) sobre el corpus armonizado de 72 654 imágenes; el nivel L3 (367 diagnósticos individuales) conserva la cola larga propia de cada dataset y no admite contrastes directos sin agregación adicional. La implicación práctica para un sistema de producción es que la jerarquía debe presentarse de forma explícita al usuario clínico: la predicción L3

acompañada de su agregación L2 y L1 proporciona robustez frente a la incertidumbre en la cola larga sin sacrificar especificidad cuando ésta sea fiable.

5.3.3 Ventana operativa por fototipo cutáneo

La ventana operativa de los modelos contrastados, definida por su rendimiento desigual entre fototipos en el experimento de equidad (tabla 4.13), condiciona la generalización a poblaciones con fototipos elevados. Los cinco encoders presentan *gap* I-VI positivo entre +0,124 y +0,306 pp BAcc. La paradoja BiomedCLIP —*gap* mínimo asociado a la peor BAcc global— ilustra que el *gap* aislado no constituye una métrica decisional. El modelo con mejor compromiso entre BAcc global y *gap* sobre la formulación de tres clases es PanDerm Large, seguido de DermLIP v2 cuando se prioriza la AUROC global. La implicación clínica es que el despliegue sobre poblaciones con representación significativa de fototipos elevados debe acompañarse de validación específica sobre subgrupos y de mecanismos de revisión humana cuando el modelo opere en su régimen de menor confianza.

5.3.4 Ensemble de seguridad para detección de melanoma

El protocolo auxiliar de ensemble (sección 4.10, tabla 4.15) documenta que la combinación OR *top-3* de PanDerm Large *fine-tuned* sobre HAM10000 (M1) y SigLIP-Large SO400M con sondeo lineal alcanza *recall* de melanoma del 100 % (70 de 70) sobre el *split* de test de HAM10000. El análisis de errores muestra que los dos melanomas que M1 no captura en *top-3* sí son capturados por SigLIP, lo que confirma la complementariedad de los *backbones* y motiva la elección del par. M7 (clasificador unificado sobre el corpus armonizado de 43 clases) no añade melanomas adicionales sobre HAM, pero mantiene valor en escenarios multidataset por su mayor cobertura ontológica.

Tres caveats acompañan la interpretación operativa de este resultado: (i) el *recall* del 100 % es *top-3*, no *top-1*, lo que requiere una interfaz que presente las tres clases más probables al clínico; (ii) el tamaño muestral de melanomas es $N = 70$, lo que produce intervalos de confianza al 95 % amplios y exige validación prospectiva sobre cohorte mayor; (iii) el coste en falsos positivos del esquema OR *top-3* es elevado (885 FP sobre 1 162 no-melanomas), lo que se acepta en un escenario de cribado oportunista pero descarta su uso aislado para clasificación primaria.

5.4 Hallazgos no anticipados

Cinco observaciones del trabajo no se anticipaban a partir de la literatura y merecen atención específica.

Competitividad de ConvNeXt-Large sobre HAM10000. ConvNeXt-Large preentrenado sobre ImageNet-21K alcanza 0,967 AUROC sobre HAM10000, superando a PanDerm Large (0,954) por 1,3 pp y aproximándose a SigLIP-Large (0,971). El resultado sugiere que para tareas de ranking binario o multiclase sobre dermatoscopia estandarizada, las representaciones de ImageNet-21K son altamente competitivas, y que la ventaja del preentrenamiento de dominio aparece sólo en material clínico no estandarizado.

Sondeo lineal supera al ajuste fino en DDI. Con $N_{\text{train}} = 427$, el sondeo lineal sobre PanDerm Large supera al ajuste fino en accuracy (+7,3 pp), AUROC (+14,5 pp), BAcc (+2,1 pp) y F1 ponderada (+5,6 pp). El comportamiento, atribuible a sobreajuste, no se documenta de forma explícita en la literatura sobre PanDerm y proporciona una heurística operativa para datasets pequeños.

Asimetría rendimiento-equidad en DermLIP v2. DermLIP v2 alcanza la mejor BAcc global sobre Fitzpatrick17k (0,721) y la mejor AUROC global (0,909), pero su *gap* I-VI es +0,281 pp, el segundo más alto entre los cinco encoders contrastados. La combinación de rendimiento agregado superior con desigualdad por subgrupo elevada sugiere que el preentrenamiento sobre Derm1M produce representaciones informativas sobre la categoría diagnóstica pero no suficientemente invariantes al fototipo cutáneo.

Adaptación LoRA sobre MedGemma 27B. La adaptación LoRA sobre MedGemma 27B sobre el *split* de entrenamiento de HAM10000 produce mejoras de +13,7 pp Acc sobre HAM10000 y +18,3 pp Acc sobre DDI respecto a la variante *zero-shot*, sin mejora apreciable sobre PAD-UFES-20 (−1,7 pp). El comportamiento es asimétrico y sugiere que la adaptación captura patrones específicos del dataset de entrenamiento sin transferencia sistemática a otros conjuntos. La implicación es que el ajuste con LoRA sobre LLMs multimodales debe reportarse por dataset, sin agregar como un único valor de rendimiento.

Interpretabilidad emergente del SAE Large sobre Derm7pt. La validación independiente del SAE Large (16384 *features*) sobre el corpus Derm7pt [9] reportada en la sección 4.15 identifica *features* individuales con AUROC efectivo hasta 0,823 sobre *vascular structures* y hasta 0,926 sobre vasos en horquilla ($N_+ = 15$ positivos), sin que las anotaciones del *Seven-Point Checklist* se hayan utilizado en el preentrenamiento del SAE ni del encoder PanDerm Large. La implicación es que la base sparse aprendida sobre Derm1M (507 657 imágenes) ha capturado representaciones alineadas con la taxonomía dermatoscópica clásica, lo que sostiene la línea de interpretabilidad mediante Sparse Autoencoders más allá del régimen de los 48 conceptos visuales de SkinCon [15] sobre el que se diseñó el experimento original del Anexo F. El *Concept Bottleneck Model* con cuello de botella sobre los siete criterios cuantifica el coste de la interpretabilidad sobre la tarea binaria melanoma/no-melanoma (−5,8 pp AUROC, 0,890 → 0,832) y produce una jerarquía de pesos del meta-clasificador (*blue whitish veil* +2,54, *regression structures* +2,07) coherente con el peso clínico de estos criterios en la escala diagnóstica de referencia [9]. La implicación operativa es que el SAE no constituye solo un mecanismo de reducción dimensional sino que admite interpretación concepto-a-concepto sobre el vocabulario dermatoscópico, lo que fortalece la viabilidad del módulo de interpretabilidad del prototipo (Anexo H) sin requerir reentrenamiento del SAE.

5.5 Limitaciones interpretativas

La interpretación de los resultados anteriores está condicionada por cuatro elementos que el capítulo 6 desarrolla en detalle. Primero, el solapamiento documentado entre

Dermnet, HIBA, MSKCC y el corpus de preentrenamiento Derm1M introduce una incertidumbre acotada sobre las cifras de la familia DermLIP en estos tres datasets; las cifras de PanDerm, DINOv2, ConvNeXt-Large, EfficientNetV2-Large y SigLIP-Large no se ven afectadas. Segundo, los tamaños muestrales por subgrupo Fitzpatrick V y VI (169 y 73 imágenes respectivamente en el conjunto de test) producen intervalos de confianza amplios para las cifras de *gap*, lo que limita la cuantificación exacta de la desigualdad por fototipo. Tercero, la sensibilidad al *prompt* en zero-shot y en la evaluación de LLMs multimodales implica que las cifras reportadas son condicionales a una formulación concreta, y que la generalización a otras formulaciones requiere validación específica. Cuarto, el trabajo evalúa rendimiento sobre fotografías procedentes de archivos de investigación; la generalización a imagen real adquirida en flujos de teledermatología sobre cohorte hospitalaria prospectiva no se aborda y constituye una línea futura inmediata.

Estas limitaciones acotan el dominio de validez de las cifras reportadas pero no invalidan los patrones cualitativos identificados: la ventaja del preentrenamiento de dominio, la saturación temprana del sondeo lineal, el régimen $N_{\text{train}} \lesssim 500$ para preferencia de LP, la brecha entre especialistas y LLMs multimodales generalistas, y la existencia de un *gap* por fototipo sistemático y consistente entre encoders.

LIMITACIONES

El estudio presenta limitaciones de cinco órdenes que conviene declarar explícitamente. La presente sección las desarrolla por familia, cuantifica su magnitud cuando es posible y acota su impacto sobre la interpretación de los resultados del capítulo 4 y de la discusión del capítulo 5.

6.1 Limitaciones de disponibilidad

6.1.1 Modelos sin pesos públicos

Los pesos de DermFM-Zero [3] no son públicos en la fecha de cierre del presente trabajo. Esta restricción impide su evaluación empírica directa sobre los doce datasets externos contrastados y restringe su tratamiento al marco conceptual del capítulo 2. La comparación entre PanDerm Large y DermFM-Zero, que la publicación original reporta a favor del segundo, no puede verificarse de forma independiente con los mismos protocolos aplicados al resto de la comparativa. La disponibilidad eventual de los pesos liberaría una comparación directa con los hallazgos cuantitativos de este trabajo, en particular sobre las cifras de sondeo lineal de la tabla 4.1 y sobre el experimento de equidad de la tabla 4.13.

Los modelos cerrados accedidos vía API (GPT-4o, GPT-4o-mini, Gemini 2.5 Pro, Gemini 2.5 Flash) presentan una limitación estructural: no permiten controlar la versión exacta del modelo en el momento de la inferencia ni el posprocesado interno aplicado por el proveedor. Las cifras de la tabla 4.10 son condicionales a la versión disponible en la fecha del experimento (marzo de 2026) y no son estrictamente reproducibles ante actualizaciones silenciosas del proveedor. El coste agregado de la evaluación (\$4,07 aproximadamente entre GPT-4o y GPT-4o-mini, sin desglose público de tarifa por token de entrada y salida) introduce una segunda dependencia que limita la replicación por terceros.

6.1.2 Conjuntos de preentrenamiento no liberados

Los conjuntos de preentrenamiento internos del grupo de la Universidad Monash empleados en PanDerm [1] no son accesibles para terceros. Esta restricción impide reproducir la fase de preentrenamiento del modelo y limita la verificación a los pesos liberados. La consecuencia metodológica es que cualquier afirmación sobre la composición del corpus de preentrenamiento (*las cuatro modalidades dermatológicas, ~ 2,1 millones de imágenes*) descansa sobre la declaración de los autores y no sobre auditoría independiente. La misma restricción aplica al corpus Derm1M de la familia DermLIP, que se distribuye con *embeddings* agregados pero sin acceso íntegro al material de imagen original.

6.2 Limitaciones de los datos

6.2.1 Sesgo geográfico y lingüístico

Los doce datasets externos contrastados provienen mayoritariamente de instituciones de Estados Unidos (DDI), Australia (HAM10000 parcial), Europa central (BCN20000 sobre Hospital Clínic de Barcelona; HAM10000 parcial; ISIC2018; Dermnet) y Brasil (PAD-UFES-20). HIBA procede del Hospital Italiano de Buenos Aires y MSKCC del Memorial Sloan Kettering Cancer Center. La población hispanohablante europea, con la distribución epidemiológica documentada en DIADERM [5], no está representada de forma específica en los conjuntos de evaluación. La consecuencia es que las cifras agregadas de la tabla 4.1 no son directamente extrapolables al espectro diagnóstico atendido en el Hospital Universitario Son Llàtzer (HUSLL) [4] sin validación adicional.

La rama lingüística de los modelos vision-lenguaje contrastivos (DermLIP, Bio-medCLIP) está preentrenada sobre corpus en inglés. La sensibilidad documentada al tokenizador (sección 5.1.5, 48,8 pp AUROC entre la peor y la mejor configuración) se limita a las variantes evaluadas en inglés y no caracteriza el rendimiento sobre *prompts* en español, idioma sobre el que no se han evaluado por la ausencia de validación de los tokenizadores con vocabulario clínico hispanohablante. El corpus DermapixelAI 1.0 publicado como contribución del trabajo (sección 3.3) aborda esta brecha para la fase posterior al periodo cubierto por este documento.

6.2.2 Heterogeneidad taxonómica entre datasets

Las taxonomías diagnósticas nativas de los doce datasets son incompatibles entre sí. La formulación binaria melanoma/no-melanoma de Derm7pt clínico, Derm7pt dermo, HIBA y MSKCC contrasta con la multiclase de HAM10000 (7 clases), PAD-UFES-20 (6), DDI (2), Dermnet (23), BCN20000 (9), WSI patches (16) y Fitzpatrick17k (114 patologías). SkinCon emplea anotación basada en 48 conceptos clínicos visuales, taxonomía incompatible con la diagnóstica de los demás datasets.

La ontología jerárquica L1/L2/L3 introducida en sección 3.2 mitiga esta limitación al armonizar el dataset agregado sobre vocabulario común (72 654 imágenes etiquetadas, 4 categorías L1, 43 subcategorías L2 con cinco entradas sin desagregación a L3, y 367 diagnósticos L3 con codificación SNOMED CT y CIE-10), pero no la elimina por completo. Las comparaciones inter-dataset son defendibles a nivel L1 (cuatro familias

etiológicas) y L2 (43 entradas), pero a nivel L3 cada dataset conserva su cola larga propia y los contrastes directos requieren agregación adicional. Once de los doce datasets se mapean a la ontología; SkinCon queda fuera por el desajuste de granularidad ya mencionado.

La consecuencia operativa para los hallazgos del capítulo 4 es que el reporte por dataset de la tabla 4.1 mantiene fidelidad a la taxonomía nativa, y las cifras agregadas (filas *Media* de la misma tabla) deben interpretarse como promedios sobre tareas heterogéneas no estrictamente comparables entre sí.

6.2.3 Solapamiento con el dataset de preentrenamiento Derm1M

La auditoría descrita en sección 3.6.8 identifica tres datasets evaluados (Dermnet, HIBA, MSKCC) con solapamiento documentado frente al corpus de preentrenamiento Derm1M empleado por la familia DermLIP. La cardinalidad exacta de la intersección por hash MD5 sobre cada uno de los tres datasets es pendiente de cierre experimental (tabla 3.1, marcadores con asterisco).

Las métricas obtenidas sobre estos datasets con modelos cuya rama visual deriva de Derm1M (DermLIP v1, v2 y original) deben interpretarse con *caveat* y no son directamente comparables con las obtenidas sobre los datasets sin solapamiento documentado. La sensibilidad de la métrica AUROC a la presencia de imágenes previamente vistas en preentrenamiento puede inflar al alza las cifras de la tabla 4.9 sobre HIBA y MSKCC, particularmente en el régimen zero-shot.

Las cifras de PanDerm Base y Large, DINOv2 ViT-L/14, ConvNeXt-Large, EfficientNetV2-Large y SigLIP-Large SO400M no se ven afectadas por este solapamiento, dado que su preentrenamiento no incluye Derm1M. Por consiguiente, los hallazgos cuantitativos sobre la ventaja del preentrenamiento de dominio (sección 5.1.1), la eficiencia en etiquetas (sección 5.1.2) y la comparación con CNNs (tabla 4.3) permanecen defendibles incluso bajo el peor escenario de la auditoría.

6.2.4 Tamaños muestrales por subgrupo en el experimento de equidad

Los tamaños muestrales del experimento de equidad sobre Fitzpatrick17k son asimétricos entre fototipos cutáneos: 299 imágenes para FST I, 470 para FST II, 325 para FST III, 261 para FST IV, 169 para FST V y 73 para FST VI en el conjunto de test (N total = 1 597 con fototipo asignado). El subgrupo FST VI dispone de aproximadamente la cuarta parte de los ejemplos del subgrupo FST I y supone el 4,6 % del conjunto de test.

La consecuencia estadística es que los intervalos de confianza al 95 % por *bootstrap* sobre las cifras de BAcc por subgrupo de la tabla 4.13 son más amplios para FST V-VI que para FST I-IV, lo que limita la precisión cuantitativa del *gap* I-VI reportado. La interpretación cualitativa —rendimiento inferior sobre fototipos elevados— es robusta frente a esta asimetría muestral, pero la cuantificación exacta del *gap* debe acompañarse de los intervalos de confianza correspondientes en la versión final del documento. **[NO ESPECIFICADO: reportar los intervalos de confianza al 95 % por *bootstrap* sobre la BAcc por subgrupo y la potencia estadística del contraste entre FST I y FST VI.]**

6.3 Limitaciones del diseño experimental

6.3.1 Variabilidad inter-semilla

Los protocolos de sondeo lineal, eficiencia en etiquetas y evaluación de equidad por fototipo operan con una única semilla (`random_state = 42`); los protocolos de ajuste fino y segmentación con LoRA emplean también una única configuración de semillas (`torch`, `numpy`, `random` fijadas a 0). La variabilidad inter-semilla no se reporta de forma sistemática, lo que limita la cuantificación de la incertidumbre estadística asociada a la inicialización aleatoria del clasificador lineal y al orden de muestreo durante el entrenamiento.

La consecuencia es que las cifras de las tablas 4.1, 4.4, 4.5 y 4.13 son estimaciones puntuales sobre una trayectoria de optimización concreta y no incluyen su variabilidad esperable bajo distintas inicializaciones. Las heurísticas operativas extraídas en sección 5.1.3 (régimen $N_{\text{train}} \lesssim 500$ para preferencia de sondeo lineal) son cualitativas y robustas, pero los umbrales exactos pueden desplazarse bajo otras semillas.

6.3.2 Pruebas estadísticas y comparaciones múltiples

El protocolo declarado en sección 3.8 contempla intervalos de confianza al 95 % mediante *bootstrap* sobre 1 000 remuestreos y el test de DeLong [32] para contrastes pareados de AUROC. La función `resample_metric` en el código del proyecto soporta el *bootstrap* estratificado por clase. Sin embargo, las cifras reportadas en el capítulo 4 se presentan como valores puntuales, no como pares (estimador, IC), lo que limita la lectura estadísticamente informada de los contrastes entre modelos. El test de DeLong y la corrección por comparaciones múltiples (a elegir entre Bonferroni y Benjamini-Hochberg) están pendientes de implementación y ejecución sistemática.

[NO ESPECIFICADO: completar la ejecución del bootstrap estratificado sobre las cifras principales de las tablas 4.1, 4.4 y 4.13; implementar el test de DeLong para los contrastes pareados de AUROC entre PanDerm Large, DermLIP v2, DINOv2 y SigLIP-Large; aplicar corrección por comparaciones múltiples sobre el conjunto de contrastes reportados.]

La consecuencia operativa es que los hallazgos numéricos del capítulo 4 son defendibles en términos descriptivos y de magnitud, pero las afirmaciones sobre *superioridad estadísticamente significativa* de un modelo sobre otro requieren la cuantificación pendiente. Los patrones cualitativos identificados en la discusión (sección 5.1.1, sección 5.1.2, sección 5.1.3) son robustos frente a esta limitación por la magnitud absoluta de los efectos cuantificados.

6.3.3 Sensibilidad al *prompt* en zero-shot y LLMs

La evaluación zero-shot multimodal y la comparación con LLMs multimodales operan sobre formulaciones concretas de *prompts* que condicionan los resultados reportados. La diferencia de 48,8 pp AUROC entre la peor y la mejor configuración de DermLIP sobre HAM10000 (tabla 4.8) cuantifica la magnitud de esta dependencia para la rama contrastiva. La generalización a otras formulaciones requiere validación específica.

Para los LLMs multimodales, el *prompt* clínico de aproximadamente 300 palabras descrito en sección 3.6.6 introduce una formulación fija que no se ha auditado me-

diante barrido sistemático de longitud, orden de las clases candidatas o inclusión de descriptores anatómicos. El sesgo léxico documentado en sección 5.1.6 (GPT-4o emite 284 predicciones de dermatofibroma frente a 8 muestras reales) sugiere que el modelo responde al espacio léxico del *prompt*, lo que amplifica el efecto de la formulación. Las cifras de la tabla 4.10 son condicionales a este *prompt* y no caracterizan el rendimiento de los modelos bajo formulaciones alternativas. Una caracterización sistemática de la sensibilidad al *prompt* en LLMs queda fuera del alcance del trabajo y se documenta como línea futura en el Anexo G.

6.4 Limitaciones del corpus DermapixelAI 1.0

El corpus DermapixelAI 1.0 entregado como contribución del trabajo presenta cuatro limitaciones específicas declaradas explícitamente en el Anexo C y en el documento formal de entrega (Anexo E).

Desbalance estructural por modalidad. La distribución por modalidad es 1036 imágenes de fotografía clínica frente a 49 imágenes dermatoscópicas, lo que limita el uso del corpus para entrenamiento o evaluación de tareas dermatoscópicas. El predominio clínico refleja la finalidad docente original del archivo Dermapixel, no una decisión de diseño del trabajo, pero condiciona la utilidad del corpus para benchmarks comparativos con HAM10000, BCN20000, ISIC2018 u otros conjuntos dermatoscópicos.

Cobertura ontológica parcial. El corpus contiene anotación L3 sobre 250 diagnósticos distintos, sobre las 367 entradas declaradas en la ontología, lo que corresponde a una cobertura efectiva del 68,1 % del vocabulario L3 con al menos una imagen. El diagnóstico L3 más frecuente concentra aproximadamente el 32 % del corpus, lo que reproduce la cola larga típica del material clínico. Esta cobertura parcial limita el uso del corpus para evaluación granular sobre L3 sin agregación a L2.

Tres cifras de validación no intercambiables. La distinción entre los tres campos de validación documentados en el Anexo C es relevante para la interpretación correcta de las cifras de calidad. El 97,93 % del corpus con `label_source = ontology` indica mapeo ontológico validado del vocabulario, no verificación visual caso-a-caso. El 82,96 % con `rosa_verified` corresponde a la revisión visual explícita por la Dra. R. Taberner. La cifra de validación textual `diagnosis_source = expert_v3` (98,38 %) se refiere a la coherencia del razonamiento textual con el diagnóstico asignado, sin verificación visual de la imagen asociada. Las tres cifras deben declararse con precisión en cualquier comunicación derivada y no son intercambiables.

Splits y tamaños reducidos. La partición *case-aware* del corpus (891/157/41 imágenes en *train/val/test*) es metodológicamente correcta para evitar fuga de información entre imágenes del mismo caso clínico, pero produce un conjunto de test reducido (41 imágenes) que limita la potencia estadística de los contrastes realizados sobre él. La explotación experimental sistemática sobre DermapixelAI 1.0 se ha pospuesto al periodo posterior al cierre de este documento por esta razón.

6.5 Limitaciones de generalización clínica

6.5.1 Material de archivo frente a flujo asistencial real

El estudio mide rendimiento sobre fotografías procedentes de archivos de investigación curados (HAM10000, BCN20000, ISIC2018) o de archivos clínicos con verificación posterior (HIBA, MSKCC, DDI, Fitzpatrick17k). El rendimiento sobre material adquirido en el flujo real de teledermatología, sobre fotografías de atención primaria con dispositivos heterogéneos (variabilidad de iluminación, distancia focal, encuadre, calibración cromática) o sobre material adquirido en consulta presencial sin estandarización no se aborda en este trabajo. La extrapolación de las cifras de la tabla 4.1 a estos escenarios requiere validación adicional sobre cohorte representativa del entorno de despliegue previsto, particularmente en el contexto del proyecto institucional de teledermatología con IB-Salut descrito en sección 1.2.

6.5.2 Ausencia de validación prospectiva

El trabajo no aborda la validación clínica prospectiva sobre cohorte hospitalaria real con protocolo aprobado por Comité Ético de Investigación Clínica (CEIC). Esta limitación es estructural y se asume explícitamente como decisión de alcance en sección 1.5. La validación prospectiva del prototipo DermApIxel descrito en el Anexo H sobre cohorte del HUSLL requiere prerrequisitos administrativos y temporales (aprobación CEIC, definición de *endpoints* clínicos primarios y secundarios, cálculo muestral, contratación de revisores independientes) que exceden el alcance del Trabajo de Fin de Grado y se identifican como línea de continuación inmediata en la sección 7.5 del capítulo 7.

6.5.3 Elementos no abordados por decisión de alcance

Cuatro elementos quedan fuera del alcance declarados en sección 1.5 y deben reconocerse como limitaciones del documento aunque sean por decisión deliberada: (i) el preentrenamiento desde cero de un modelo fundacional propio, que requeriría acceso al material de las cuatro modalidades dermatológicas en volumen comparable al de PanDerm (~ 2,1 millones de imágenes); (ii) la integración operativa con el sistema PACS y el visor radiológico del HUSLL, que excede el alcance técnico del trabajo experimental; (iii) el reentrenamiento multilingüe de la rama lingüística sobre corpus en español de gran escala, condicionado a la disponibilidad futura de material en cantidad suficiente; (iv) la certificación CE como producto sanitario (*Software as a Medical Device*), que requiere un proceso regulatorio y de auditoría independiente no contemplado.

6.6 Síntesis: dominio de validez de los resultados

El conjunto de limitaciones declarado en este capítulo acota el dominio de validez de las cifras reportadas en el capítulo 4 pero no invalida los patrones cualitativos identificados en la discusión. Cuatro afirmaciones cualitativas resisten al peor escenario combinado de las limitaciones anteriores y constituyen la respuesta empírica defendible del trabajo a la pregunta de investigación formulada en sección 1.3.

Primero, la ventaja del preentrenamiento sobre el dominio clínico respecto a encoders generalistas se cuantifica en +4,1 pp accuracy y +9,0 pp BAcc de promedio entre

PanDerm Large y PanDerm Base sobre los diez datasets externos, patrón estable bajo cualquier interpretación de las limitaciones de muestreo y semilla. Segundo, la saturación temprana del sondeo lineal sobre encoders preentrenados a gran escala produce rendimientos competitivos con 1–5 % del conjunto de entrenamiento, hallazgo robusto sobre HAM10000 y PAD-UFES-20. Tercero, la brecha cuantitativa entre encoders específicos de dominio y LLMs multimodales generalistas sobre HAM10000 alcanza 43,5 pp accuracy entre el mejor especialista ajustado y el mejor LLM *zero-shot*, magnitud que sobrevive a la sensibilidad al *prompt* documentada y a las restricciones de modelos cerrados. Cuarto, el *gap* sistemático por fototipo cutáneo entre encoders, con sentido peor-en-fototipos-elevados, es coherente con la literatura previa y se observa en los cinco modelos contrastados pese a las limitaciones de tamaño muestral en FST V-VI.

Estas cuatro afirmaciones constituyen el núcleo defendible del trabajo y se retoman como conclusiones en el capítulo 7.

CONCLUSIONES

7.1 Respuesta a la pregunta de investigación

La pregunta formulada en sección 1.3 se respondió mediante la evaluación empírica de catorce modelos fundacionales sobre doce datasets externos públicos armonizados a una ontología jerárquica L1/L2/L3, bajo cuatro protocolos principales (sondeo lineal, ajuste fino supervisado, segmentación binaria con LoRA y clasificación zero-shot multimodal) y tres protocolos complementarios (equidad por fototipo cutáneo, comparación con modelos de lenguaje multimodales generalistas, auditoría de solapamiento con el dataset de preentrenamiento Derm1M). La evidencia disponible sostiene cuatro afirmaciones cualitativas, en las que se resumen los hallazgos defendibles del trabajo.

Primera. Ventaja del preentrenamiento sobre el dominio clínico. PanDerm Large constituye, entre los encoders contrastados con pesos públicos, el modelo con mejor rendimiento agregado sobre los diez datasets externos contrastados. La mejora media respecto a PanDerm Base es de +4,1 pp en accuracy, +9,0 pp en BAcc y +3,6 pp en AUROC bajo sondeo lineal. La mejora absoluta es máxima sobre Dermnet (+10,0 pp accuracy), WSI patches (+8,7 pp) y PAD-UFES-20 (+4,7 pp), datasets con mayor número de clases o mayor heterogeneidad de adquisición. El ajuste fino con la receta del paper original aumenta la BAcc en +47,1 pp sobre HAM10000 y +19,4 pp sobre PAD-UFES-20, atribuible al aprendizaje de las clases minoritarias. La especialización del dominio se cuantifica también frente a arquitecturas convolucionales supervisadas: la ventaja de PanDerm Large sobre la mejor CNN crece con la dificultad del dataset, desde +0,5 pp accuracy sobre HAM10000 hasta +8,2 pp sobre PAD-UFES-20.

Segunda. Saturación temprana del sondeo lineal. El sondeo lineal sobre encoders preentrenados específicos de dominio alcanza saturación con un volumen de datos etiquetados muy reducido: con 1 % del conjunto de entrenamiento de HAM10000 (82 imágenes), PanDerm Large recupera 95,7 % de la accuracy y 96,2 % del AUROC del

modelo entrenado con el conjunto completo; con 5 % (410 imágenes), AUROC alcanza 97,7 % del valor máximo. Sobre PAD-UFES-20, 14 imágenes de entrenamiento (1 %) bastan para alcanzar 0,907 AUROC, equivalente al 95,5 % del rendimiento con el conjunto completo. Esta eficiencia es relevante para contextos clínicos con disponibilidad limitada de etiquetas: enfermedades raras, centros de bajo volumen asistencial, subgrupos poco representados y extensión a especialidades dermatológicas no cubiertas por los benchmarks habituales.

Tercera. Brecha entre modelos específicos y LLMs multimodales generalistas. La comparación de paradigmas sobre HAM10000 cuantifica un gradiente de rendimiento de 43,5 pp de accuracy entre el mejor especialista ajustado (PanDerm Base FT con TTA, 0,920) y el mejor modelo de lenguaje multimodal generalista *zero-shot* (GPT-4o, 0,485). La adaptación con LoRA sobre MedGemma 27B reduce parcialmente esta brecha (+13,7 pp Acc HAM, +18,3 pp Acc DDI), pero no sistemáticamente entre datasets (−1,7 pp sobre PAD-UFES-20). La consecuencia operativa para sistemas de apoyo al diagnóstico es que los LLMs multimodales generalistas no constituyen sustitutos defendibles de los encoders fundacionales específicos del dominio en el régimen clínico evaluado, sin perjuicio de su papel complementario como generadores de razonamiento textual o explicaciones.

Cuarta. Gap sistemático por fototipo cutáneo. Los cinco encoders contrastados sobre Fitzpatrick17k completo presentan *gap* I-VI positivo sobre la formulación de tres clases de malignidad, con valores entre +0,124 pp BAcc (BiomedCLIP) y +0,306 pp (DINOv2 ViT-L/14). La paradoja BiomedCLIP, con *gap* mínimo asociado a la peor BAcc global (0,590), ilustra que la métrica de equidad aislada no constituye un criterio decisonal: un modelo uniformemente inferior puede presentar baja desigualdad sin ser equitativo en sentido sustantivo. El modelo con mejor compromiso entre rendimiento global y equidad es PanDerm Large (BAcc 0,699, *gap* +0,217 pp); DermLIP v2 ofrece la mejor BAcc global (0,721) con *gap* superior (+0,281 pp).

7.2 Contribuciones reproducibles

Las contribuciones del trabajo se enumeran en orden decreciente de centralidad respecto a la pregunta de investigación.

7.2.1 Contribuciones en el cuerpo del documento

1. **Reproducción experimental de PanDerm sobre arquitectura aarch64.** El pipeline de PanDerm Base y Large se ha verificado sobre NVIDIA DGX Spark con chip Grace Hopper GB10, 128 GB de memoria unificada, CUDA 13.0 y precisión BF16, con reproducción de los rangos numéricos reportados por Yan et al. [1] sobre los datasets compartidos. La portabilidad al chip Grace Hopper queda documentada como base operativa para grupos de investigación con hardware no estándar.
2. **Benchmark homogéneo de catorce modelos sobre doce datasets.** El estudio comparativo aplica cuatro protocolos principales bajo configuración estándar

(sección 3.6) sobre PanDerm Base y Large, DINOv2, ConvNeXt-Large, EfficientNetV2-Large, tres variantes de DermLIP, BiomedCLIP, SigLIP-Large, SAM2.1+LoRA, GPT-4o, Gemini 2.5 Pro, MedGemma 4B Vision y 27B Text, y BLIP-2. Las cifras se reportan con desglose por dataset y métrica (tabla 4.1, tabla 4.2, tabla 4.10).

3. **Ontología jerárquica L1/L2/L3.** Cuatro categorías etiológicas, 43 subcategorías clínicas y 367 diagnósticos individuales codificados en SNOMED CT y CIE-10, validados por revisión experta de la Dra. R. Taberner. La ontología se aplica a la armonización de once de los doce datasets externos contrastados, agregando 72 654 imágenes sobre vocabulario común y habilitando comparaciones inter-dataset defendibles a nivel L1 y L2.
4. **Dataset DermapixelAI 1.0.** Primer dataset dermatológico verificado en español con imagen, metadatos y texto narrativo asociado (1 089 imágenes, 669 casos clínicos, mediana de 223 palabras por caso). Particionado bajo regla *case-aware* (891/157/41) y distribuido bajo licencia CC-BY-NC-SA 4.0 con datasheet formal (Anexo C) y documento de entrega (Anexo E).
5. **Auditoría sistemática de solapamiento con DermIM.** Procedimiento por hash MD5 exhaustivo sobre los doce datasets externos contrastados, con identificación de tres conjuntos afectados (Dermnet, HIBA, MSKCC) y declaración de *caveat* explícito sobre las cifras zero-shot de la familia DermLIP en estos datasets.

7.2.2 Contribuciones complementarias

6. **Análisis empírico de equidad por fototipo.** Evaluación de cinco encoders sobre Fitzpatrick17k completo (16577 imágenes, 6 fototipos cutáneos) con cuantificación del *gap* I-VI por modelo (tabla 4.13) y análisis cruzado *Light* $\leftrightarrow$ *Dark* (tabla 4.14).
7. **Caracterización de la sensibilidad al tokenizador en DermLIP.** Identificación del tokenizador y la formulación del *prompt* como factores críticos del rendimiento zero-shot, con diferencia de 48,8 pp AUROC entre la peor y la mejor configuración sobre HAM10000.
8. **Adaptación de SAM2.1 al dominio dermatoscópico mediante LoRA.** Configuración con *rank* $r = 8$ sobre el *mask_decoder* y *promptable encoder*, congelando el *image_encoder* Hiera-Large preentrenado. Resultado de Dice 0,947 sobre ISIC2018 (+2,6 pp sobre la cifra publicada por Yan et al. [1]), con transferencia fuera de dominio prácticamente nula sobre ISIC2017 (0,945) y PH2 (0,960).
9. **Ensemble de seguridad para detección de melanoma.** Combinación OR *top-3* de PanDerm Large ajustado sobre HAM10000 (M1) y SigLIP-Large SO400M con sondeo lineal, que alcanza *recall* de melanoma del 100 % (70 de 70, *top-3*) sobre el conjunto de test de HAM10000.

7.3 Hallazgos metodológicos transferibles

Cinco hallazgos metodológicos del trabajo son transferibles a escenarios clínicos análogos y constituyen aportaciones operativas más allá del benchmark concreto evaluado.

Régimen de aplicabilidad del sondeo lineal. La comparación cuantitativa sobre cuatro datasets (sección 5.1.3) delimita un régimen operativo: para datasets con $N_{\text{train}} \lesssim 500$ imágenes, el sondeo lineal sobre PanDerm Large supera al ajuste fino completo en accuracy, BAcc, AUROC y F1 ponderada. El umbral se identifica sobre DDI ($N_{\text{train}} = 427$), donde el sondeo lineal mantiene AUROC 0,827 frente a 0,682 del ajuste fino.

Compatibilidad tokenizador-encoder en zero-shot. La AUROC en clasificación zero-shot con modelos vision-lenguaje contrastivos depende críticamente de la compatibilidad entre el tokenizador empleado para los *prompts* y el espacio de *embeddings* del encoder textual del modelo. La verificación empírica de esta compatibilidad sobre un conjunto de validación del dominio es prerequisite de cualquier despliegue zero-shot defendible.

LoRA sobre encoders promptables preentrenados a gran escala. La combinación SAM2.1-Large preentrenado más adaptación LoRA con *rank* bajo sobre el decodificador de máscaras supera al *fine-tuning* completo de baselines dermatológicos específicos, con incorporación de aproximadamente 4,5 M parámetros entrenables (inferior al 2 % del total). La generalización fuera de dominio es prácticamente nula, lo que sugiere que las primitivas geométricas codificadas por el encoder visual transfieren entre fuentes de adquisición sin reentrenamiento.

Limitación operativa del *gap* aislado como métrica de equidad. La paradoja BiomedCLyu—*gap* I-VI mínimo (+0,124 pp) asociado a la peor BAcc global (0,590)— demuestra que la métrica *gap* aislada puede inducir conclusiones erróneas sobre la equidad sustantiva de un modelo. El reporte conjunto de BAcc global, AUROC global y *gap* es metodológicamente preferible y debería adoptarse como práctica estándar en estudios de equidad dermatológica.

Sondeo lineal supera al ajuste fino bajo sobreajuste. El caso DDI ($N_{\text{train}} = 427$, descenso de AUROC −14,5 pp con ajuste fino respecto al sondeo lineal) es diagnóstico de la posibilidad de sobreajuste del encoder ajustado pese a las augmentaciones de la receta canónica (Mixup, CutMix, *weighted random sampler*). La heurística operativa derivada es que el ajuste fino sobre datasets pequeños debe ir acompañado de monitorización de AUROC sobre conjunto de validación independiente, y descartarse si el ranking de probabilidades degrada.

7.4 Aportaciones a la práctica clínica

El trabajo aporta cuatro elementos directamente aplicables al diseño de sistemas de apoyo al diagnóstico dermatológico en el contexto del Servicio de Dermatología del

HUSLL y, por extensión, al circuito de teledermatología institucional descrito en sección 1.2.

Arquitectura técnica defendible. Encoder PanDerm Large preentrenado y congelado por defecto, con cabeza lineal multi-clase mediante regresión logística L-BFGS ($C = 1,0$, $\text{max_iter} = 5000$) en datasets con $N_{\text{train}} \lesssim 500$, o cabeza ajustada con la receta de PanDerm Large en datasets con $N_{\text{train}} \gtrsim 5000$ y desbalance acusado. Segmentación con SAM2.1-Large adaptado mediante LoRA cuando la tarea requiera localización de lesión. Ensemble OR *top-3* de M1 (PanDerm Large *fine-tuned*) y SigLIP-Large con sondeo lineal cuando la tarea sea cribado oportunista de melanoma con prioridad de *recall*.

Ontología armonizada como columna vertebral. La ontología L1/L2/L3 con codificación SNOMED CT y CIE-10 proporciona una columna vertebral semántica reutilizable para sistemas de información hospitalarios y compatible con la nomenclatura clínica del entorno. La presentación jerárquica al usuario clínico (predicción L3 acompañada de su agregación L2 y L1) aporta robustez frente a la incertidumbre en la cola larga sin sacrificar especificidad cuando ésta sea fiable.

Dataset DermapixelAI 1.0 como recurso público en español. Habilita la reutilización del archivo Dermapixel en proyectos académicos posteriores, la adaptación de modelos vision-lenguaje a texto clínico en castellano y la validación de sistemas de apoyo sobre material de referencia docente reconocida en el ámbito hispanohablante.

Caveats explícitos sobre fuga de información. La auditoría de solapamiento entre datasets de evaluación y preentrenamiento aporta una práctica de reporte transferible a otros benchmarks dermatológicos. La declaración explícita de *caveats* de leakage en las tablas (tabla 3.1) y la consistencia entre la cifra reportada y su *caveat* asociado debería adoptarse como condición de defensibilidad en publicaciones del campo.

7.5 Líneas de investigación abiertas

Las líneas abiertas que se desarrollan a continuación constituyen propuestas concretas con experimentos identificados, prerequisites declarados y métricas esperables. No son trabajo simplemente pendiente, sino aportaciones intelectuales del proyecto cuya ejecución requiere recursos o aprobaciones específicas. Todas descansan sobre las contribuciones reproducibles enumeradas en sección 7.2.

7.5.1 Cobertura experimental sobre DermapixelAI 1.0: técnicas ejecutadas y pendientes

Las secciones 4.11 y 4.12 del capítulo 4 evalúan PanDerm Base, PanDerm Large, DermLIP v2, SigLIP-SO400M y BiomedCLIP sobre DermapixelAI 1.0 exclusivamente como extractores de *features* congelados, en combinación con cabezas paramétricas ligeras (regresión logística, k -NN, MLP de 512 unidades) o con clasificación contrastiva *zero-shot*. El espacio de hipótesis no explorado sobre el corpus en castellano incluye un conjunto de técnicas de *transfer learning* denso que la literatura sobre modelos

7. CONCLUSIONES

fundacionales en imagen médica documenta como aportando incrementos típicos de 10 a 20 pp en BAcc respecto al sondeo lineal congelado, en línea con los +47,1 pp BAcc sobre HAM10000 y +19,4 pp BAcc sobre PAD-UFES-20 cuantificados en la sección 4.3. La presente sección documenta de forma explícita estas técnicas pendientes y la cifra esperable sobre L2 (38 clases) tras su aplicación, condicionada a la disponibilidad del banco hospitalario HUSLL como ampliación del corpus.

Cuadro 7.1: Técnicas de *transfer learning* pendientes de aplicación sobre Dermapi-xelAI 1.0 con el cuerpo experimental del presente trabajo. *Coste*: orden de magnitud sobre NVIDIA DGX Spark GB10. *Esperado*: mejora cualitativa estimada a partir de las referencias internas del trabajo. *Estado*: situación respecto al cierre del presente TFG.

Método	Tipo	Coste estimado	Mejora esperada
Ajuste fino completo del encoder	Supervisado	~ 5 min Spark (3 niveles)	+18,2 pp BAcc L1 sobre LP CV; -4,0 pp BAcc L2 sobre LP CV
LoRA $r = 16$ (SpanDerm v0)	PEFT	~ 12 min Spark (3 seeds)	+19,5 pp BAcc L2 sobre LP CV; AUROC L2 sobre LP CV
<i>Test-time augmentation</i>	Inferencia	5–10 min	+3 a +22 pp Acc@3 (cf. sección 4.10)
Ensemble Base+Large+DermLIP	Inferencia	Trivial	+6,7 pp AUROC L2 con DermLIP individual
Pérdida focal / re-ponderación de clases	Entrenamiento	~ 5 min Spark	+3,3 pp BAcc L1 y +5,9 pp BAcc L2 sobre LP CV
CBM sobre conceptos SkinCon	Interpretable	Anotación dermatológica	Trazabilidad clínica
Banco hospitalario HUSLL (~ 22 K)	Datos	3–6 meses (CEIC)	Activación L3 directa (SpanDerm v1)

La elección de evaluar sobre encoder congelado en las secciones 4.11 y 4.12 sigue el protocolo estándar de la literatura sobre modelos fundacionales en imagen médica, que prioriza la cuantificación limpia del valor del preentrenamiento sobre datos del dominio sin contaminación por hiperparámetros específicos de ajuste fino. La familia PanDerm [1], DermLIP [2] y BiomedCLIP [17] reportan sus cifras principales bajo este protocolo, lo que permite la comparación directa con la literatura. Los métodos pendientes recogidos en la tabla 7.1 se concentran tras el cierre experimental del presente trabajo en la extensión del corpus vía banco hospitalario HUSLL (bloqueada por la revisión ética del CEIC) y en la línea de modelos de cuello de botella conceptual (CBM) sobre conceptos SkinCon, condicionada a la anotación dermatológica detallada en el Anexo F. Las restantes técnicas (ajuste fino denso L1+L2+L3, adaptación LoRA SpanDerm v0, *Test-Time Augmentation*, ensemble multi-codificador y pérdida focal) han sido ejecutadas y reportadas en las secciones correspondientes del capítulo 4.

Bajo la hipótesis de aplicación combinada de las técnicas pendientes (ajuste fino del encoder con la receta de la sección 4.3, ensemble PanDerm+DermLIP en la línea documentada en la sección 4.10 y ampliación con el banco hospitalario HUSLL hasta superar el umbral de aproximadamente 30 imágenes por clase L3 que activa la variante directa SpanDerm v1), las cifras esperables para un clasificador desplegable sobre L2 (38 subcategorías clínicas) en castellano se estiman en BAcc entre 0,45 y 0,55, orden de magnitud comparable con el rango reportado en la sección 4.3 para PanDerm Base ajustado sobre HAM10000 (BAcc 0,575 sobre 7 clases). Esta estimación es prospectiva, no constituye un compromiso ni una predicción puntual, y queda condicionada a la disponibilidad efectiva del banco hospitalario tras la revisión por el comité ético de investigación clínica y a la calibración empírica de la receta de ajuste fino sobre el material en castellano.

7.5.2 SpanDerm: modelo dermatológico clínico en español

El dataset DermapixelAI 1.0 habilita el desarrollo de un proyecto de modelos fundacionales dermatológicos clínicos en español, denominado SpanDerm. El proyecto se articula en dos ramas complementarias.

La primera es la rama **supervisada**: cabeza clasificadora sobre encoder PanDerm Large adaptado mediante *Low-Rank Adaptation*. Comprende SpanDerm v0 —cabeza L2 con LoRA $r = 16$ ejecutada y reportada en la sección 4.14— y SpanDerm v1 —cabeza L3 directa, condicionada al banco hospitalario HUSLL—, descritas a continuación en los párrafos correspondientes.

La segunda es la rama **zero-shot multimodal**: SpanDerm-CLIP, sistema dual-encoder estilo CLIP que alinea el encoder visual PanDerm Large con un encoder textual multilingüe (intfloat/multilingual-e5-base) sobre el mismo corpus DermapixelAI 1.0. Se han ejecutado cinco iteraciones experimentales (v1 a v5) reportadas íntegramente en la sección 4.17. La iteración v4 (LoRA visual $r = 32$ sobre los últimos doce bloques del ViT, régimen híbrido *H6* en inferencia) alcanza L3 *accuracy@1 zero-shot* = 0,2475 sobre el conjunto de test de 101 imágenes, esencialmente el umbral paper-grade 0,25 fijado a priori sobre vocabulario castellano fino. La iteración v5, bajo configuración LoRA idéntica y ampliación del corpus con 15 128 imágenes externas genéricas, reporta una ablación negativa documentada (0,2079, $-4,0$ pp): la escala genérica mejora las representaciones visuales aisladas pero erosiona la alineación cross-modal sobre el registro discursivo castellano. Las contribuciones empíricas complementarias son la recuperación cross-modal castellano-imagen **14,0** $\times$ lift sobre baseline aleatorio (v2, *i2t* R@5 = 0,654 frente a 0,047 en régimen de *caption* rica, *pool* = 107), el diagnóstico mecánico del techo del encoder visual congelado via *Linear Probing* y la reducción del ECE L3 del 97 % (0,7262 $\rightarrow$ 0,0213 con $\tau = 0,4165$ sobre v4) mediante *temperature scaling* [33]. Una ablación independiente con un modelo fundacional inglés grande pre-entrenado confirma que el cuello de botella experimental era la escala de la alineación cross-modal castellà, no el codificador visual ni la formulación textual (Anexo I). La rama zero-shot no es sustitutiva de la supervisada: ambas operan sobre regímenes de uso distintos (vocabulario abierto frente a vocabulario cerrado L2/L3) y la integración del prototipo DermApIxel (Anexo H) las expone como módulos paralelos del pipeline.

Los párrafos siguientes describen los prerrequisitos y el estado de las dos versiones de la rama supervisada.

SpanDerm v0. Cabeza L2 (38 clases efectivas tras consolidación de variantes ortográficas) sobre encoder PanDerm Large adaptado mediante *Low-Rank Adaptation* (LoRA, $r = 16$, $\alpha = 32$) sobre los dos últimos bloques de transformer, con ranking L3 por similitud coseno sobre los *embeddings* prototípicos del conjunto de entrenamiento de DermapixelAI 1.0. El protocolo es ejecutable sobre el hardware actual del proyecto sin recursos adicionales. La métrica primaria prevista era Acc-top-1 sobre L2 y *recall*-top-3 sobre L3 en el conjunto de test, con validación cruzada estratificada por L1 dada la limitación del tamaño muestral.

La ejecución del protocolo (sección 4.14 del capítulo 4) reporta sobre el nivel L2 BAcc = $0,363 \pm 0,007$, AUROC = $0,855 \pm 0,006$ y Acc@3 = $0,500 \pm 0,023$ (media $\pm$ desviación estándar sobre tres semillas, con 524 *K* parámetros entrenables que representan el 0,17 % del encoder). Sobre el ranking L3 por prototipos, Acc@1 = 0,167, Acc@3 = $0,259 \pm$

7. CONCLUSIONES

0,013 y $\text{Acc}@5 = 0,296 \pm 0,026$ sobre 250 clases. Las cifras observadas alcanzan o superan las expectativas del diseño: la BAcc L2 mejora en +19,5 pp la cifra de validación cruzada del sondeo lineal congelado y la AUROC L2 empata estadísticamente con la de DermLIP v2 individual, lo que valida empíricamente la línea LoRA como protocolo de referencia sobre el corpus en castellano.

SpanDerm v1. Cabeza L3 directa (251 diagnósticos efectivos sobre el vocabulario completo) condicionada a la incorporación del banco hospitalario del HUSLL (~ 22 000 estudios estimados tras aprobación CEIC). El umbral de activación es de al menos 30 imágenes por clase L3, condición no satisfecha por DermapixelAI 1.0 en aislamiento dado que 178 entradas L3 del vocabulario con muestras efectivas contienen ≤ 5 imágenes (cola larga estricta del vocabulario representado). La extensión vía banco HUSLL es condición necesaria y suficiente para la viabilidad de v1.

7.5.3 Derm7pt + Sparse Autoencoders: ground-truth conceptual para interpretabilidad

Las anotaciones *Seven-Point Checklist* de Derm7pt (siete criterios diagnósticos estructurados por imagen) constituyen ground-truth conceptual no explotada por la literatura previa sobre Sparse Autoencoders aplicados a dermatología. La propuesta de investigación contempla cuatro experimentos. Los tres primeros se han ejecutado y se reportan en la sección 4.15; el cuarto se ha ejecutado y se reporta en la sección 4.15 dentro de la misma sección de resultados.

E1. Correlación SAE-Derm7pt. Ejecutado. Cálculo de la AUROC efectiva de cada *feature* del SAE Large (16384 *features*) como predictor binario de cada uno de los siete criterios Derm7pt sobre las anotaciones de la variante dermatoscópica ($N = 1011$). El resultado, reportado en la tabla 4.32 de la sección 4.15, identifica AUROC efectivo *top-1* hasta 0,823 sobre *vascular structures* y entre 0,681 y 0,754 sobre los seis criterios restantes.

E2. Concept Bottleneck Model sobre Derm7pt. Ejecutado. Construcción de un CBM jerárquico análogo al utilizado sobre SkinCon [15], con los siete criterios Derm7pt como cuello de botella conceptual entre encoder y clasificador binario melanoma/no-melanoma sobre los *splits* oficiales (*train* = 413, *val* = 203, *test* = 395). La comparativa con el sondeo lineal directo (tabla 4.33 de la sección 4.15) cuantifica el compromiso interpretabilidad-precisión en -5,8 pp AUROC (0,890 $\rightarrow$ 0,832) sobre el conjunto de test. Los pesos del meta-clasificador (tabla 4.34) priorizan *blue whitish veil* y *regression structures* de forma coherente con la escala clínica.

E3. Cruce con conceptos del Grupo A. Ejecutado. Mapeo operativo de los 16 conceptos dermatoscópicos propuestos a la Dra. R. Taberner sobre los siete criterios del *Seven-Point Checklist* y validación de la cobertura del SAE Large sobre cada concepto mapeado. La tabla 4.35 de la sección 4.15 documenta que 11 de 16 conceptos admiten *mapping* y 7 de los 11 quedan cubiertos por al menos una *feature* SAE con AUROC $\geq 0,70$. El pico observado sobre vasos en horquilla (0,926, $N_+ = 15$) sostiene la línea

de interpretabilidad sin entrenamiento específico sobre el corpus en castellano. Los 5 conceptos sin *mapping* (empedrado, paralelos surcos/crestas, lagunas vasculares, vasos en corona) son estructuras no contempladas en la escala original y constituyen precisamente el contenido específico de la anotación clínica colaborativa con la Dra. R. Taberner.

E4. Fine-tuning multitarea concept-aware sobre Derm7pt. Ejecutado. Ajuste fino supervisado de PanDerm Large con adaptación de bajo rango (LoRA, $r = 16$) sobre los dos últimos bloques del codificador y ocho cabezas paralelas: una multi-clase por cada criterio del *Seven-Point Checklist* y una binaria para melanoma/no-melanoma. La pérdida es la suma equiponderada de entropías cruzadas sobre las ocho cabezas. La configuración, los hiperparámetros y los resultados se reportan en la sección 4.15: con sólo 0,56 M de parámetros entrenables (0,18 % del total) la cabeza melanoma alcanza AUROC test = 0,891 (IC95 % [0,856, 0,927]), superando marginalmente al sondeo lineal directo sobre el SAE (0,890) y mejorando el CBM jerárquico en +5,9 pp AUROC. Las siete cabezas conceptuales pierden entre 1 y 3 pp de AUROC respecto al sondeo lineal separado por concepto, coste compatible con el comportamiento típico del aprendizaje multitarea y aceptado a cambio de inferencia simultánea melanoma + siete criterios en una sola pasada. Este resultado consolida la integración del módulo M7 de interpretabilidad del prototipo DermApIxel (Anexo H) sobre una única arquitectura adaptada y elimina la dependencia de pipelines en cascada para producir inferencia conceptual.

7.5.4 Aprendizaje activo *in-domain* sobre clases L3 con peor cobertura

La trilogía experimental SpanDerm-CLIP reportada en sección 4.17 delimita con precisión la palanca correcta para superar el umbral L3 *accuracy@1* $\sim 0,25$ bajo *zero-shot* castellano. La iteración v4 (LoRA visual $r = 32$ sobre los últimos doce bloques del ViT, régimen híbrido H6 en inferencia) alcanza 0,2475 sobre el conjunto de test fijo, esencialmente el umbral fijado a priori. La iteración v5, bajo configuración arquitectónica idéntica y ampliación del corpus de entrenamiento con 15 128 imágenes externas genéricas, queda *flat-to-negative* (0,2079): la escala genérica mejora las representaciones visuales aisladas (+41,2 % relativo sobre régimen visual puro H1, +54,4 % relativo sobre techo *Linear Probing* L2 supervisado) pero erosiona la alineación cross-modal sobre el registro discursivo castellano del archivo original. La cola larga estructural del nivel L3 permanece sin cobertura: 327 clases con ≤ 5 imágenes sobre el vocabulario ontológico completo (178 con muestras 1–5 en entrenamiento, 149 sin imágenes en el corpus actual) no se rellenan tras la incorporación del corpus externo.

La línea identificada como palanca correcta para superar 0,25 bajo *zero-shot* castellano fino consiste en una estrategia de aprendizaje activo dirigida *in-domain*: en lugar de ampliar el corpus de entrenamiento de forma indiscriminada, se identifican las clases L3 con peor cobertura en el subconjunto castellano (las ocho clases críticas *deepened* en v5 —seis tumorales más dermatitis atópica y urticaria— como muestra inicial extensible) y se invierte esfuerzo experto en anotación dirigida sobre estas clases. Los candidatos a anotación se generan mediante consulta del prototipo DermApIxel sobre cohortes hospitalarias del HUSLL bajo revisión por la Dra. R. Taberner. El banco hospitalario HUSLL ($\sim 22\,000$ estudios estimados tras aprobación CEIC, sección 7.5.5) constituye el recurso natural para esta estrategia: su composición clínica refleja la

distribución diagnóstica real del Servicio de Dermatología, su material está alineado con el registro castellano del archivo Dermapixel 1.0 y su escala permite tanto el llenado dirigido de la cola larga L3 como la eventual activación del modelo supervisado directo L3 (SpanDerm v1) cuando se supere el umbral operativo de ~ 30 imágenes por clase L3 (sección 7.5.2). La consecución del umbral operativo 0,25 por v4 sobre el corpus actual hace que esta línea de continuación ya no se plantee como ruta hacia el *target*, sino como ruta de generalización del sistema hacia cobertura clínica completa. Esta dirección queda reforzada por la ablación del Anexo I: la palanca pendiente para SpanDerm-CLIP no es escala genérica de datos sino anotación experta *in-domain* sobre las clases L3 con peor cobertura.

7.5.5 Escalado del dataset con el banco hospitalario HUSLL

La extensión del dataset DermapixelAI 1.0 con el banco hospitalario del HUSLL constituye la línea de mayor impacto potencial sobre el rendimiento clínico real del sistema. La estimación preliminar es de aproximadamente 22000 estudios disponibles en archivo, con metadatos asociados (imagen clínica, dermatoscópica cuando disponible, diagnóstico final, edad y sexo del paciente). Los prerequisites son cuatro: aprobación del Comité Ético de Investigación Clínica de las Illes Balears (CEIC-IB), implementación de un protocolo de anonimización compatible con RGPD y la Ley Orgánica 3/2018, definición de un esquema de licencia compatible con la naturaleza hospitalaria del material (probablemente más restrictiva que CC-BY-NC-SA 4.0), y establecimiento de un equipo de validación experta liderado por la Dra. R. Taberner con apoyo de residentes de dermatología del HUSLL.

La incorporación del banco hospitalario habilita SpanDerm v1 (sección 7.5.2), la validación clínica prospectiva sobre cohorte real (sección 7.5.6) y un análisis de equidad sobre fototipo cutáneo más representativo de la población atendida por el sistema sanitario español que el disponible en Fitzpatrick17k.

7.5.6 Validación clínica prospectiva

La validación clínica prospectiva del prototipo DermApIxel (Anexo H) sobre cohorte hospitalaria real del HUSLL requiere un protocolo aprobado por CEIC-IB con cuatro elementos: definición de *endpoints* clínicos primarios (*recall* de melanoma, tasa de derivaciones evitadas) y secundarios (concordancia inter-observador, tiempo de diagnóstico, valoración subjetiva del clínico); cálculo muestral basado en los *recall* preliminares de $\sim 0,97$ obtenidos sobre HAM10000 con M1+SigLIP y un *estándar de oro* conservador; reclutamiento de dermatólogos revisores independientes para arbitraje en casos de discrepancia; y plan de análisis estadístico preregistrado.

La cifra de *recall* del 100 % sobre melanoma reportada en sección 4.10 es prueba de concepto sobre material de archivo, no resultado clínico validado. Su extrapolación al flujo asistencial real requiere la validación prospectiva aquí esbozada, identificada como prerequisite de cualquier despliegue operativo más allá del prototipo.

7.5.7 Auditoría sistemática de leakage extensible

La auditoría por hash MD5 desarrollada para Derm1M (sección 3.6.8) es directamente extensible a los demás corpora de preentrenamiento del ecosistema dermatológico

actual: SkinGPT-4, MONET, MM-Skin, MedSAM y SkinFM, entre otros. La propuesta consiste en aplicar el mismo procedimiento sobre los splits de evaluación canónicos contrastados en este trabajo y publicar las cardinalidades de intersección como recurso de referencia para la comunidad. El producto previsto es un reporte técnico con la tabla completa de solapamientos por (dataset de evaluación, corpus de preentrenamiento), acompañado del script auditable. El *caveat* cuantificado por dataset permitiría recalibrar las cifras zero-shot publicadas sobre estos corpora.

7.5.8 Recuperación visual densa como sistema de apoyo

La recuperación visual densa basada en FAISS sobre los *embeddings* de Derm1M (~421 000 imágenes preindexadas) constituye un componente del prototipo DermApIxel (sección H.3.4 del Anexo H) con latencia inferior a 150 milisegundos por consulta. La propuesta consiste en evaluar el valor clínico del módulo mediante un estudio mixto sobre cohorte HUSLL: cuantitativo (concordancia diagnóstico-recuperación, *precision@k* sobre L1 y L2 de la ontología) y cualitativo (valoración subjetiva del clínico sobre la utilidad de los casos recuperados como referencia diferencial). La integración con la historia clínica electrónica del HUSLL queda como prerrequisito técnico no abordado en el presente trabajo.

7.5.9 IA agéntica para razonamiento clínico estructurado

A medio plazo, la combinación de los componentes desarrollados (encoder PanDerm, ontología L1/L2/L3, dataset DermapixelAI, recuperación visual densa, LLM multimodal en local con MedGemma) habilita la construcción de un agente clínico orquestado bajo control del facultativo. El esquema previsto contempla herramientas externas auditables (acceso a literatura científica, verificación de criterios clínicos contra guías de práctica, consulta de la historia del paciente), invocadas por un LLM bajo prompt clínico estandarizado y con trazabilidad de cada paso de razonamiento. La diferencia operativa respecto al uso directo de un LLM multimodal generalista (sección 5.1.6) es la inclusión de evidencia estructurada externa al modelo, lo que reduce el sesgo léxico documentado y facilita la justificación clínica de la salida. El desarrollo es condicional a la disponibilidad de pesos abiertos con capacidad de razonamiento estructurado (MedGemma 27B y sucesores).

7.5.10 Reentrenamiento multilingüe de la rama lingüística

La sensibilidad documentada al tokenizador (sección 5.1.5) sugiere que un reentrenamiento dirigido del encoder textual de DermLIP sobre texto clínico en español aportaría mejoras significativas sobre el rendimiento zero-shot en el ámbito hispanohablante. La estrategia mínima viable consiste en aplicar *continued pretraining* del encoder textual sobre los 669 casos clínicos de DermapixelAI 1.0 con el razonamiento narrativo asociado, manteniendo congelado el encoder visual de DermLIP. La estrategia ampliada requiere un dataset de pares imagen-texto en español de mayor escala, no disponible en la fecha de cierre del trabajo y condicional al escalado descrito en sección 7.5.5.

7.6 Cierre

El trabajo ha caracterizado empíricamente el rendimiento y la capacidad de generalización de catorce modelos fundacionales para imagen dermatológica disponibles, bajo cuatro protocolos principales y tres complementarios, sobre doce datasets externos armonizados a una ontología jerárquica de tres niveles validada por revisión experta. La evidencia obtenida sostiene cuatro afirmaciones cualitativas defendibles (sección 7.1), nueve contribuciones reproducibles (sección 7.2), cinco hallazgos metodológicos transferibles (sección 7.3) y cuatro aportaciones a la práctica clínica (sección 7.4).

Las ocho líneas de investigación abiertas (sección 7.5) constituyen propuestas concretas con experimentos identificados y prerrequisitos declarados, no trabajo simplemente pendiente. Su ejecución completaría la cadena entre caracterización empírica del estado del arte, construcción de recursos públicos en español, validación clínica prospectiva y despliegue operativo en el sistema sanitario, recorrido cuya primera etapa cierra el presente documento.

La aportación intelectual del trabajo se sitúa en la conjunción del rigor metodológico del benchmark cuantitativo, la construcción de recursos abiertos para la comunidad y la formulación explícita de líneas de continuación con base técnica y clínica verificable. El siguiente paso natural es la primera publicación derivada del trabajo, centrada en la comparativa de modelos fundacionales bajo la ontología armonizada, seguida del desarrollo de SpanDerm como modelo dermatológico para texto clínico en español a partir del dataset DermapixelAI 1.0 extendido con el banco hospitalario del HUSLL.

BIBLIOGRAFÍA

- [1] Yan, S. *et al.* (2025). A multimodal vision foundation model for clinical dermatology. *Nature Medicine*, 31, 2691–2702. DOI: 10.1038/s41591-025-03747-y. Versión arXiv: 2410.15038v3. 2.3, 3.2, 3.6.2, 4.5, 4.6, 4.5, 4.5, 5.1.4, 5.2.1, 5.2.2, 6.1.2, 1, 8, 7.5.1, D.4
- [2] Yan, S., Hu, M., Jiang, Y., Li, X., Fei, H., Tschandl, P., Kittler, H., Ge, Z. (2025). Derm1M: A million-scale vision-language dataset aligned with clinical ontology knowledge for dermatology. arXiv:2503.14911v2. 2.4, 3.2, 3.6.5, 4.11, 4.12, 4.17, 5.1.1, 5.2.3, 7.5.1, D.4, I.2, I.4
- [3] Yan, S., Li, X. *et al.* (2026). DermFM-Zero: A vision-language foundation model for zero-shot clinical collaboration and automated concept discovery in dermatology. arXiv:2602.10624v1. 2.5, 3.4, 6.1.1, F1
- [4] Taberner, R., Nadal, C., Llambrich, A., Vila, I.T.A. (2010). Dermatology service utilization and reasons for consultation by Spanish and immigrant patients in the region served by Hospital Son Llàtzer, Palma de Majorca, Spain. *Actas Dermo-Sifiliográficas* 101(4):323–329. 1.1, 6.2.1
- [5] Buendía-Eisman, A., Arias-Santiago, S., Molina-Leyva, A., Gilaberte, Y., Fernández-Crehuet, P., Husein-ElAhmed, H., Viera-Ramírez, A., Fernández-Peñas, P., Taberner, R., Descalzo, M.Á., García-Doval, I. (2018). Análisis de los diagnósticos realizados en la actividad ambulatoria dermatológica en España: muestreo aleatorio nacional DIADERM. *Actas Dermo-Sifiliográficas* 109(5):416–423. DOI: 10.1016/j.ad.2018.02.003. 1.1, 6.2.1
- [6] Tu, T., Palepu, A., Schaekermann, M., Saab, K., Freyberg, J., Tanno, R., Wang, A., Li, B., Amin, M., Tomasev, N., Azizi, S., Singhal, K., Cheng, Y., Hou, L., Webson, A., Kulkarni, K., Mahdavi, S.S., Semturs, C., Gottweis, J., Barral, J., Chou, K., Corrado, G.S., Matias, Y., Karthikesalingam, A., Natarajan, V. (2024). Towards conversational diagnostic AI. arXiv:2401.05654. 2.7
- [7] Google DeepMind (2024). Advancing AMIE: a research AI agent for clinical reasoning, conversation and diagnosis (AI co-clinician). Disponible en <https://deepmind.google/blog/ai-co-clinician/>. Consultado en abril de 2026. 2.7
- [8] Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. 1, 2.1, 3.1

- [9] Kawahara, J., Daneshvar, S., Argenziano, G., Hamarneh, G. (2019). Seven-point checklist and skin lesion classification using multitask multimodal neural nets. *IEEE Journal of Biomedical and Health Informatics*, 23(2), 538–546. 1, 2.1, 3.1, 4.15, 4.15, 4.15, 4.17, 5.4, H.8.3
- [10] Codella, N. *et al.* (2019). Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the International Skin Imaging Collaboration (ISIC). arXiv:1902.03368. 1, 2.1, 2.6, 3.1, 3.6.4
- [11] Pacheco, A.G.C. *et al.* (2020). PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones. *Data in Brief*, 32, 106221. 1, 3.1, 4.42, 4.17
- [12] Daneshjou, R. *et al.* (2022). Disparities in dermatology AI performance on a diverse, curated clinical image set. *Science Advances*, 8(31), eabq6147. 1, 2.1, 3.1, 5.2.4
- [13] DermNet New Zealand Trust. DermNet NZ: The dermatology resource. <https://dermnetnz.org> 1, 3.1, 4.42, 4.17
- [14] Groh, M. *et al.* (2021). Evaluating deep neural networks trained on clinical images in dermatology with the Fitzpatrick 17k dataset. *CVPR Workshops*. 1, 2.1, 2.8, 3.1, 5.2.4
- [15] Daneshjou, R. *et al.* (2022). SkinCon: A skin disease dataset densely annotated by domain experts for fine-grained debugging and analysis. *NeurIPS Datasets and Benchmarks*. 1, 2.8, 3.1, 4.15, 5.4, 7.5.3, F, F4, F5, H.3.3
- [16] Oquab, M. *et al.* (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. 2.3, 3.2, 4.16
- [17] Zhang, S. *et al.* (2024). BiomedCLIP: A multimodal biomedical foundation model pretrained from fifteen million scientific image-text pairs. *NEJM AI*, 1(7). 2.4, 3.2, 7.5.1
- [18] Ravi, N. *et al.* (2024). SAM 2: Segment Anything in Images and Videos. arXiv:2408.00714. 1.4, 2.6, 3.2
- [19] Templeton, A. *et al.* (2024). Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet. Anthropic Research Blog. 1.4, 2.5, F1
- [20] Gershenwald, J.E., Scolyer, R.A., Hess, K.R., Sondak, V.K., Long, G.V., Ross, M.I., Lazar, A.J., Faries, M.B., Kirkwood, J.M., McArthur, G.A., Haydu, L.E., Eggermont, A.M.M., Flaherty, K.T., Balch, C.M., Thompson, J.F. (2017). Melanoma staging: Evidence-based changes in the American Joint Committee on Cancer eighth edition cancer staging manual. *CA: A Cancer Journal for Clinicians*, 67(6), 472–492. DOI: 10.3322/caac.21409. 1.1
- [21] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR 2021)*. 2.2

- [22] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Aspell, A., Mishkin, P., Clark, J., Krueger, G., Sutskever, I. (2021). Learning transferable visual models from natural language supervision. *Proceedings of the 38th International Conference on Machine Learning (ICML 2021)*, 8748–8763. 2.2, 2.4, 4.16, 4.17
- [23] Zhai, X., Mustafa, B., Kolesnikov, A., Beyer, L. (2023). Sigmoid loss for language image pre-training. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, 11975–11986. 2.4, 3.2
- [24] Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A.C., Lo, W.-Y., Dollár, P., Girshick, R. (2023). Segment anything. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, 4015–4026. 2.6
- [25] Li, J., Li, D., Savarese, S., Hoi, S.C.H. (2023). BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. *Proceedings of the 40th International Conference on Machine Learning (ICML 2023)*, 19730–19742. 2.5, 3.2
- [26] Johnson, J., Douze, M., Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535–547. DOI: 10.1109/TBDATA.2019.2921572. 1.4, 2.4, 3.5, 4.16, H.3.4, H.8.4
- [27] Combalia, M., Codella, N.C.F., Rotemberg, V., Helba, B., Vilaplana, V., Reiter, O., Carrera, C., Barreiro, A., Halpern, A.C., Puig, S., Malvehy, J. (2019). BCN20000: Dermoscopic lesions in the wild. arXiv:1908.02288. 1, 3.1
- [28] Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J.W., Wallach, H., Daumé III, H., Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92. DOI: 10.1145/3458723. Versión original arXiv:1803.09010 (2018). 1.4, E, E.6
- [29] Esteva, A., Kuprel, B., Novoa, R.A., Ko, J., Swetter, S.M., Blau, H.M., Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118. DOI: 10.1038/nature21056. 2.1
- [30] Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. DOI: 10.1038/sdata.2018.161. 2.1
- [31] Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W. (2022). LoRA: Low-Rank Adaptation of large language models. *International Conference on Learning Representations (ICLR 2022)*. arXiv:2106.09685. 1.4, 2.6, 3.6.4, 4.14
- [32] DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3), 837–845. 2.8, 3.8, 6.3.2
- [33] Guo, C., Pleiss, G., Sun, Y., Weinberger, K.Q. (2017). On calibration of modern neural networks. *Proceedings of the 34th International Conference on Machine Learning (ICML 2017)*, 1321–1330. 4.17, 4.17, 4.17, 7.5.2

- [34] Tejani, A.S., Klontzas, M.E., Gatti, A.A., Mongan, J.T., Moy, L., Park, S.H., Kahn Jr., C.E. (2024). Checklist for Artificial Intelligence in Medical Imaging (CLAIM): 2024 update. *Radiology: Artificial Intelligence*, 6(4), e240300. DOI: 10.1148/ryai.240300.2.8



MAPA DE TAREAS EXPERIMENTALES Y ESTRUCTURA DEL REPOSITORIO

Este anexo documenta el conjunto de tareas experimentales reproducibles ejecutadas durante el trabajo y la estructura del repositorio asociado. La finalidad es habilitar la reproducción independiente de las cifras del capítulo 4 a partir del código publicado y de los *checkpoints* de modelo.

A.1 Estructura del repositorio

El repositorio se organiza en cinco directorios principales que encapsulan responsabilidades disjuntas. La tabla A.1 sintetiza su contenido.

Cuadro A.1: Estructura del repositorio de código del trabajo.

Directorio	Contenido
classification/	Pipeline de sondeo lineal y ajuste fino. Carga de datasets, modelos.
classification/panderm_model/	<i>Wrappers</i> de encoders fundacionales (PanDerm, DINOv2, DermNet).
classification/panderm_model/downstream/eval_features/	Sondeo lineal, regresión logística L-BFGS, <i>bootstrap</i> .
classification/datasets/	Adaptadores por dataset, <i>splits</i> canónicos.
classification/models/	<i>Builder</i> de modelos, <i>timm wrappers</i> .
segmentation/	Pipeline de segmentación. SAM2.1 con LoRA, CAE-seg, dataset ISIC.
ontology/	Vocabulario L1/L2/L3, mapeos por dataset, scripts de armonización.
data/	Índices locales con <i>splits</i> , embeddings precomputados.
datasets/	Datasets y dataset DermapixelAI 1.0.
results/	Reportes técnicos por experimento (formato Markdown).
output/	Salidas de evaluación: predicciones, máscaras, <i>checkpoints</i> .
tfg_figures/	Figuras del documento, generadas por scripts reproducibles.

A.2 Mapa de tareas experimentales

La tabla A.2 enumera las tareas experimentales reproducibles del trabajo, su sección de referencia en el documento y la ubicación de los *outputs* en el repositorio. Las cifras del

capítulo 4 pueden reconstruirse íntegramente a partir de estos *outputs* sin reejecutar los experimentos.

Cuadro A.2: Tareas experimentales y *outputs* asociados.

Tarea	Referencia	Output principal
Sondeo lineal PanDerm Base/Large (10ds)	sección 4.1	RESULTADOS_TFG.md
Benchmark CNN vs encoders (3ds)	sección 4.2	results/CNN_BASELINE_RESULTS.md
Ajuste fino PanDerm Base (4ds)	sección 4.3	RESULTADOS_TFG.md
Eficiencia en etiquetas (HAM, PAD)	sección 4.4	RESULTADOS_TFG.md
Segmentación SAM2.1+LoRA (ISIC2018)	sección 4.5	results/SEG_GENERALIZATION_RESULTS.md
Zero-shot DermLIP (3 prompts, 2 tok.)	sección 4.6	results/zs_concepts_results.md
LLM multimodales (12 modelos, 3ds)	sección 4.7	results/{GPT4O, GEMINI, MEDGEMMA, BLIP2}_RESULTS.md
MedGemma 27B + LoRA (HAM, PAD, DDI)	sección 4.7	results/MEDGEMMA_FT_RESULTS.md
Equidad por fototipo (5 enc., 6 FST)	sección 4.8	results/FITZPATRICK_FULL_RESULTS.md
Equidad cruzada Light/Dark	sección 4.8	tfg_figures/fairness_5models/summary_5models.md
Ensemble seguridad melanoma	sección 4.10	output/ensemble_eval/ENSEMBLE_REPORT.md
SAE Large + CBM SkinCon	Anexo F	results/{SAE_LARGE, SKINCON_CBM}_RESULTS.md
Auditoría leakage MD5 (12ds vs Derm1M)	sección 4.9	[NO ESPECIFICADO]

A.3 Comandos de ejecución

A continuación se documenta el comando de ejecución de las tareas centrales del trabajo. Todos los comandos se ejecutan desde la raíz del repositorio sobre el entorno declarado en sección 3.5 (Python 3,12,3, PyTorch 2,11,0, timm 0,9,16, CUDA 13,0).

Extracción de *embeddings* (paso previo al sondeo lineal).

```
python -m classification.panderm_model.downstream.extract_features \
    --model panderm_large \
    --dataset ham10000 \
    --output data/embeddings/ham10000_panderm_large.npz
```

Sondeo lineal sobre *embeddings* extraídos.

```
python -m classification.panderm_model.downstream.eval_features.linear_probe \
    --embeddings data/embeddings/ham10000_panderm_large.npz \
    --C 1.0 --max_iter 5000 --random_state 42
```

Ajuste fino supervisado.

```
python -m classification.run_class_finetuning \
    --model panderm_base --dataset ham10000 \
    --opt adamw --weight_decay 0.05 --lr 5e-4 \
    --warmup_epochs 10 --epochs 50 \
    --layer_decay 0.65 --drop_path 0.2 --smoothing 0.1 \
    --mixup 0.8 --cutmix 1.0 --tta 5 --seed 0
```

Segmentación SAM2.1 con LoRA.

```
python -m segmentation.train_sam2_lora \
    --dataset isic2018 --rank 8 --lr 1e-4 \
    --weight_decay 0.05 --epochs 50 --batch_size 4 \
    --norm uniform_05 --seed 0
```

Evaluación zero-shot multimodal.

```
python -m classification.zs_eval \
    --model dermlip_original --dataset ham10000 \
    --prompts dermlm_a3 --tokenizer gpt2_clip
```

A.4 Versiones de software y semillas

El entorno de ejecución se fija explícitamente. Las semillas de torch, numpy y random se inicializan a 0 en los protocolos de *fine-tuning* y segmentación, y el parámetro random_state se fija a 42 en los basados en scikit-learn. La variable WANDB_MODE se fija a disabled y CUDA_VISIBLE_DEVICES a 0. La especificación completa del entorno se documenta en el archivo environment.yml del repositorio.

A.5 Checkpoints publicados

La tabla A.3 enumera los *checkpoints* de modelo derivados del trabajo, con su tamaño aproximado y la métrica de referencia sobre la que se evaluaron.

Cuadro A.3: *Checkpoints* publicados del trabajo.

<i>Checkpoint</i>	Modelo base	Tamaño	Métrica de referencia
panderm_base_ft_ham10000.pth	PanDerm Base + TTA	~ 350 MB	Acc HAM10000 0,920
panderm_large_ft_ham10000.pth	PanDerm Large	1,2 GB	Acc HAM10000 0,919
panderm_large_ft_padufes.pth	PanDerm Large	1,2 GB	Acc PAD-UFES 0,755
sam2_lora_isic2018.pth	SAM2.1-Large + LoRA	~ 17 MB	Dice 0,947
sae_large_panderm.pth	PanDerm Large + SAE	~ 200 MB	Esparsidad 16,5%
medgemma_27b_lora_ham10000.pth	MedGemma 27B + LoRA	~ 320 MB	Acc HAM10000 0,802

El acceso a los *checkpoints* se realiza mediante el repositorio de releases del proyecto, sujeto a la licencia declarada en el documento de entrega (Anexo E). La verificación de integridad se realiza por hash SHA-256 publicado junto a cada *checkpoint*.

TABLAS DETALLADAS DE RESULTADOS

Este anexo recoge desgloses y tablas adicionales a las del capítulo 4: cifras por clase de los protocolos de sondeo lineal y ajuste fino sobre HAM10000 y PAD-UFES-20, la caracterización completa por fototipo cutáneo en la formulación de 114 patologías sobre Fitzpatrick17k, y la tabla extendida de evaluación cruzada *Light* $\leftrightarrow$ *Dark*.

B.1 Desglose por clase sobre HAM10000

La tabla B.1 reporta el desglose por clase de la evaluación zero-shot con GPT-4o sobre HAM10000, ampliada respecto a la presentada en sección 4.7. La columna “Predicciones” indica el número total de imágenes asignadas a cada clase por el modelo, revelando el sesgo léxico discutido en sección 5.1.6.

Cuadro B.1: Desglose por clase del modelo GPT-4o zero-shot sobre HAM10000. *Recall*: proporción de imágenes de la clase correctamente identificadas. *Predicciones*: número de imágenes asignadas a la clase por el modelo (debe contrastarse con N_{test} para detectar sesgos sistemáticos).

Clase	N_{test}	Recall (GPT-4o)	Predicciones (GPT-4o)	Recall (GPT-4o-mini)
actinic keratosis	35	0,000	2	0,086
basal cell carcinoma	44	0,477	—	0,136
seborrheic keratosis	107	0,308	—	0,654
dermatofibroma	8	0,750	284	0,000
melanoma	70	0,686	299	0,571
melanocytic nevus	951	0,505	—	0,196
vascular lesion	17	0,529	—	0,588

La asimetría entre N_{test} y predicciones es máxima en dermatofibroma ($N_{\text{test}} = 8$, predicciones 284: factor 35,5 $\times$) y melanoma ($N_{\text{test}} = 70$, predicciones 299: factor 4,3 $\times$). El comportamiento es diagnóstico de un sesgo léxico hacia categorías con presencia elevada en el *prompt*, no hacia categorías mayoritarias en el dataset.

B.2 Desglose por clase del ajuste fino MedGemma 27B sobre HAM10000

Cuadro B.2: Desglose por clase de MedGemma 27B con LoRA sobre HAM10000 (*precision, recall, F1*).

Clase	<i>N</i> test	Precision	Recall	F1
actinic keratosis	35	0,32	0,26	0,29
basal cell carcinoma	44	0,34	0,25	0,29
dermatofibroma	8	0,00	0,00	0,00
melanocytic nevus	951	0,85	0,99	0,92
melanoma	70	0,38	0,36	0,37
seborrheic keratosis	107	0,67	0,04	0,07
vascular lesion	17	0,00	0,00	0,00

Tras la adaptación con LoRA, el modelo concentra el rendimiento en la clase mayoritaria (nevus melanocítico: *recall* 0,99) a costa de las clases menos representadas (dermatofibroma y vascular lesion: F1 0,00). Esta concentración es coherente con la accuracy de 0,802 reportada en la tabla 4.10 pese a una BAcc de sólo 0,270.

B.3 Equidad sobre Fitzpatrick17k: formulación de 114 patologías




Figura B.1: Rendimiento por fototipo Fitzpatrick sobre la formulación de 114 patologías de Fitzpatrick17k con PanDerm Large + sondeo lineal. El rendimiento crece de FST I a FST V y desciende bruscamente en FST VI.

La tabla B.3 reporta el rendimiento por fototipo Fitzpatrick de PanDerm Large sobre la formulación de 114 patologías (grano fino del dataset), complementaria a la formulación de tres clases de malignidad presentada en la tabla 4.13.

Cuadro B.3: Rendimiento por subgrupo Fitzpatrick sobre la formulación de 114 patologías de Fitzpatrick17k (PanDerm Large + sondeo lineal).

Fototipo (FST)	<i>N</i> test	Acc	BAcc	W-F1	AUROC
I	299	0,515	0,522	0,509	—
II	470	0,519	0,524	0,513	—
III	325	0,640	0,590	0,636	—
IV	261	0,670	0,602	0,654	—
V	169	0,692	0,614	0,680	—
VI	73	0,479	0,474	0,462	—
<i>Global</i>		0,581	0,549	0,576	0,968

La distribución es notablemente distinta a la formulación de tres clases de malignidad: el rendimiento crece desde FST I a FST V y cae bruscamente en FST VI. El *gap* entre FST V (mejor) y FST VI (peor) es de 0,213 pp accuracy. La interpretación sugiere que el grano fino de 114 patologías expone una capa de información clínica donde la representación visual de las lesiones sobre fototipos intermedios y altos (III, IV, V) supera a la de fototipos extremos (I, II y VI), mientras que la formulación gruesa de tres clases de malignidad refleja el patrón general peor-en-fototipos-elevados.

B.4 Evaluación cruzada Light/Dark sobre 114 patologías

La tabla B.4 reporta el experimento cruzado de entrenamiento/evaluación entre subgrupos *Light* (FST I-III) y *Dark* (FST IV-VI) sobre la formulación de 114 patologías de Fitzpatrick17k con PanDerm Large. *All* agrupa el conjunto de entrenamiento completo. Las celdas de número de clases en evaluación reflejan que algunas patologías no aparecen en la partición *Dark*, lo que reduce el número efectivo de clases sobre las que se evalúa.

Cuadro B.4: Evaluación cruzada *Light* ↔ *Dark* sobre 114 patologías de Fitzpatrick17k (PanDerm Large + sondeo lineal). *C*: número de clases efectivas en la evaluación.

Configuración	<i>N</i> train	<i>N</i> test	<i>C</i>	Acc	BAcc	AUROC
Light → Light	8845	1094	114	0,541	0,528	0,962
Light → Dark	8028	503	100	0,473	0,453	0,944
Dark → Dark	3807	503	100	0,616	0,519	0,948
Dark → Light	3958	1094	114	0,351	0,325	0,906
All → Light	12803	1094	114	0,559	0,547	0,965
All → Dark	11835	503	100	0,658	0,614	0,970

La asimetría más notable se observa en *Dark* → *Light* (BAcc 0,325, AUROC 0,906), configuración con menor volumen de entrenamiento (3958 imágenes) sobre un conjunto de evaluación mayor (1094 imágenes) y con 114 clases efectivas. La accuracy desciende desde 0,616 en *Dark* → *Dark* a 0,351 en *Dark* → *Light*, lo que cuantifica la pérdida sistemática asociada al cambio de distribución de fototipo a la inversa de la dirección habitual reportada en la literatura.

B.5 Resumen comparativo por paradigma sobre HAM10000

La tabla B.5 amplía la tabla 4.10 del cuerpo con los costes de entrenamiento e inferencia agregados por paradigma sobre HAM10000.

B. TABLAS DETALLADAS DE RESULTADOS

Cuadro B.5: Comparativa por paradigma sobre HAM10000. Datos etiquetados: tamaño del conjunto de entrenamiento empleado. Coste indicativo en EUR para los modelos de acceso comercial (cifras 2026); 0 EUR para los modelos locales.

Paradigma	Modelo	Datos etiq.	Acc	AUROC	Coste eval.
ZS (<i>prompts</i> genéricos)	DermLIP v1/v2	0	0,086	0,366	0
ZS (<i>prompts</i> A3 Derm1M)	DermLIP original	0	0,427	0,854	0
ZS LLM multimodal	GPT-4o	0	0,485	—	~\$2,71
ZS LLM multimodal	MedGemma 27B	0	0,665	—	0
LP (1 % entrenam.)	PanDerm Large	82	0,850	0,918	0
LP (100 % entrenam.)	PanDerm Base	8207	0,853	0,892	0
LP (100 % entrenam.)	PanDerm Large	8207	0,888	0,954	0
LP (100 % entrenam.)	SigLIP-Large	8207	0,900	0,971	0
FT LoRA LLM	MedGemma 27B + LoRA	8207	0,802	—	0
FT (receta paper) + TTA	PanDerm Base	8207	0,920	0,978	0




Figura B.2: Compromiso entre número de clases y accuracy sobre el dataset armonizado. La accuracy decrece conforme aumenta el número de categorías; el nivel L2 (43 clases) constituye el punto operativo más equilibrado entre granularidad clínica y rendimiento agregado.

Distribucion por categoria (Ontologia Dra. Taberner)




Figura B.3: Distribución de imágenes por categoría L1 sobre el dataset armonizado de 72654 imágenes. Predominio de patología tumoral y patología inflamatoria; patología infecciosa y genodermatosis representan la cola larga.

B. TABLAS DETALLADAS DE RESULTADOS




Figura B.4: Accuracy por clase L2 (43 entradas) sobre el clasificador unificado del dataset armonizado. Las clases con mayor accuracy corresponden a categorías con más representación en el conjunto de entrenamiento, mientras que la cola larga presenta variabilidad asociada al tamaño muestral.

B.6 Composición del conjunto de entrenamiento del SAE Large

El SAE Large utilizado en el módulo M3 del prototipo y descrito en detalle en el Anexo F se entrena sobre la concatenación de siete datasets dermatológicos. La tabla B.6 reporta la composición exacta.

B.6. Composición del conjunto de entrenamiento del SAE Large

Cuadro B.6: Composición del conjunto de entrenamiento del Sparse Autoencoder Large ($1024 \rightarrow 16384$ *features*).

Dataset	Imágenes
HAM10000	10015
BCN20000	12413
Dermnet	19559
PAD-UFES-20	2298
Fitzpatrick17k	3887
DDI	647
HIBA	1635
Total	50454

PIPELINE DE CONSTRUCCIÓN Y CARACTERIZACIÓN DEL DATASET DERMAPIXELAI 1.0

Este anexo documenta el pipeline de construcción y la caracterización cuantitativa completa del dataset DermapixelAI 1.0, descrito de forma resumida en la sección 3.1 del capítulo 3. El dataset se desarrolla en paralelo al trabajo experimental del TFG, en el marco de la modernización tecnológica del archivo Dermapixel introducida en el capítulo 1, y se publica como contribución independiente del trabajo a la comunidad investigadora.

C.1 Origen y materia prima

El dataset DermapixelAI se construye a partir del archivo del blog Dermapixel. La materia prima es el conjunto de casos publicados durante más de quince años por la Dra. R. Taberner, cada uno acompañado de imágenes (fotografía clínica y, cuando procede, imagen dermatoscópica), historia clínica abreviada en castellano y diagnóstico final con razonamiento.

C.2 Pipeline de construcción

La construcción del dataset se desarrolla como un proceso iterativo, ajustado en sucesivas revisiones internas en función de las auditorías de integridad realizadas sobre el dataset, hasta consolidar la versión 1.0 documentada en este anexo como primera versión estable y publicable. El pipeline final se compone de seis pasos.

(i) Extracción. Recogida de las publicaciones del blog y de los metadatos asociados por caso (título, fecha, texto narrativo, imágenes, diagnóstico final). El proceso se ejecuta

con scripts deterministas a partir de la fuente HTML del blog.

(ii) Deduplicación. Cálculo de hash MD5 sobre cada imagen y eliminación de duplicados exactos. Identificación de imágenes asociadas a la pista de solución de los casos del blog —imágenes que aparecen sólo en la entrada del solucionario y que llevan información asociada al diagnóstico final, susceptibles de inducir *leakage* si se incluyen— y su exclusión documentada.

(iii) Clasificación de modalidad. Asignación a cada imagen de su modalidad (*clinical*, *dermoscopy*, *histology*, *ultrasound* o *wood_lamp*) mediante una combinación de heurísticas sobre el nombre del fichero y revisión manual de los casos no resueltos automáticamente con confianza suficiente. El paso incluye una auditoría sistemática sobre la totalidad del dataset para detectar y corregir asignaciones erróneas, así como la exclusión de imágenes que tras la revisión visual resultan no ser contenido dermatológico (banners institucionales, ilustraciones, fotografías de eventos o material de archivo que pudiera haber entrado al dataset por el scraping inicial); estas últimas se trasladan a una carpeta `images/_excluded/` y se eliminan del fichero maestro `dataset.csv`, manteniéndose en `cases.csv` con `num_images_in_dataset = 0` cuando el caso resulta sin imágenes tras la exclusión.

(iv) Mapeo ontológico. Cada caso publicado contiene una etiqueta diagnóstica generada por revisión textual del título y del razonamiento. Esta etiqueta cruda se mapea, mediante revisión experta de la Dra. Taberner sobre la totalidad del dataset, a una entrada L3 de la ontología jerárquica descrita en la sección 3.2 del capítulo 3. La revisión genera tres campos asociados a cada imagen: `label_source` (origen de la etiqueta diagnóstica final), `diagnosis_source` (origen del razonamiento textual asociado al diagnóstico) y `rosa_verified` (validación visual de la imagen como caso representativo del diagnóstico asignado).

(v) Particionado. Asignación de cada imagen a uno de los tres splits (`train`, `val`, `test`) bajo regla de agrupamiento por caso (*case-aware split*): todas las imágenes de un mismo caso clínico van al mismo split, lo que previene la fuga de información entre conjuntos.

(vi) Auditoría de integridad. Verificación final de hashes MD5, ausencia de imágenes corruptas, consistencia entre la estructura de carpetas y `dataset.csv`, y ausencia de referencias a imágenes inexistentes en disco. Todas las modificaciones intermedias del dataset se acompañan de *backup* y registro de auditoría (`audit_log.txt` y `excluded_images.csv`) para preservar trazabilidad histórica.

La versión 1.0 del dataset, consolidada como resultado de este pipeline, contiene 1 089 imágenes vinculadas a 669 casos clínicos con identificador único resoluble, sobre un total de 698 casos catalogados en el archivo original (de los cuales 672 disponen de imagen efectiva antes de la deduplicación MD5; los tres casos restantes se pierden por duplicado exacto de imagen entre entradas distintas del blog).

C.3 Cardinalidades del corpus y splits experimentales

A lo largo del trabajo coexisten tres particiones distintas del corpus, todas derivadas del mismo pipeline pero filtradas con criterios específicos según el experimento. La tabla C.1 resume las cardinalidades para evitar confusión entre referencias cruzadas.

Cuadro C.1: Cardinalidades del corpus DermapixelAI 1.0 según configuración. Los splits son *case-aware* (ningún caso se reparte entre splits). El test del estudio principal sobre el corpus de producción es deliberadamente reducido para reservar masa de validación interna a la futura cohorte prospectiva del HUSLL (Sección 7.5.6).

Configuración	Imágenes	Casos	Train	Val/Test	Uso
Producción (<code>dataset.csv</code>)	1 089	669	891	157 / 41	Estudio principal del Capítulo 4
Filtrada (<code>dataset_filtered.csv</code>)	1 062	653	874	152 / 36	Restricción a <i>clinical+dermoscopy</i> con la <i>manifest</i>
SpanDerm-CLIP (Sec. 4.17)	1 062	653	854	107 / 101	Experimento dual-encoder con <i>manifest</i>

Las tres configuraciones comparten el archivo subyacente y la regla de partición *case-aware*, pero aplican filtros y *seeds* distintos. La cifra base 1 089 es el resultado del pipeline completo; el subconjunto filtrado de 1 062 excluye 27 imágenes que pierden trazabilidad ontológica tras la auditoría de mapeo; y los splits SpanDerm-CLIP de 854/107/101 son reproducibles a partir del *manifest* SHA-256 pinned en cada check-point del experimento (Sección 4.17).

C.4 Distribución por modalidad

La tabla C.2 resume la composición del dataset por modalidad.

Cuadro C.2: Distribución del dataset DermapixelAI 1.0 por modalidad de imagen.

Modalidad	N
clinical	1 036
dermoscopy	49
histology	2
ultrasound	1
wood_lamp	1
Total en dataset.csv	1 089

La fotografía clínica predomina con claridad sobre el resto de modalidades. El subconjunto dermatoscópico, con 49 imágenes, constituye un grupo reducido pero suficiente para análisis exploratorios específicos sobre esa modalidad.

C.5 Distribución por categoría etiológica L1

La distribución por L1 muestra el predominio de la patología inflamatoria, seguida por las patologías tumoral e infecciosa con pesos similares y un porcentaje residual de genodermatosis.

Cuadro C.3: Distribución del dataset DermapixelAI 1.0 por categoría etiológica L1. La fila “(sin asignar)” recoge las 19 imágenes cuyo mapeo ontológico no se ha completado (todas ellas corresponden a casos con `label_source = raw`).

Categoría L1	N	%
Patología inflamatoria	544	49,9
Patología tumoral	276	25,3
Patología infecciosa	259	23,8
Genodermatosis	11	1,0
(sin asignar)	19	—
Total	1 089	100,0

C.6 Distribución por subcategoría L2 y por diagnóstico L3

La figura C.1 ilustra la distribución L1 etiológica sobre el subconjunto filtrado (clínical + dermoscopy, con `label_source = ontology` y L1 asignada), utilizado en la caracterización del corpus efectivo. Patología inflamatoria concentra la mitad del corpus, mientras que Genodermatosis ocupa la cola corta con sólo 8 imágenes (0,8 %), lo que explica su ausencia en el split de test.




Figura C.1: Distribución L1 etiológica sobre las 1062 imágenes filtradas. Patología inflamatoria concentra el 50,1 %; Genodermatosis es la cola corta con 8 imágenes (0,8 %).

De las 43 entradas L2 del vocabulario, 38 aparecen representadas en el dataset DermapixelAI 1.0 con al menos una imagen. La cifra observada en la extracción inicial es 39, pero dos de esas 39 corresponden a variantes ortográficas de la misma subcategoría (*Trastornos de la queratinización* y *Trastornos queratinización*); la normalización pendiente reduce la cifra efectiva a 38. La figura C.2 muestra las veinte subcategorías L2 más representadas.

C.6. Distribución por subcategoría L2 y por diagnóstico L3




Figura C.2: Top-20 subcategorías L2 sobre las 38 efectivamente representadas en el corpus, ordenadas por número de imágenes.

A nivel L3, 250 entradas del vocabulario están representadas en el dataset, sobre las 367 entradas declaradas (cobertura efectiva del 68,1 %). El diagnóstico L3 más frecuente en el dataset es *Psoriasis en placas* (38 imágenes), seguido por *Tiña corporis* (32), *Liquen plano* (28) y *Nevo melanocítico adquirido* (25). Los veinte L3 más representados concentran aproximadamente el 32 % del dataset.

La tabla C.4 recoge los diez diagnósticos L3 con mayor número de imágenes en el corpus. Estos diez diagnósticos concentran 234 imágenes, equivalentes al 22,0 % del corpus filtrado.

Cuadro C.4: Top-10 diagnósticos L3 más frecuentes en el corpus DermapixelAI 1.0.

Diagnóstico L3	N
Psoriasis en placas	38
Tiña corporis	32
Liquen plano	28
Nevo melanocítico adquirido	25
Carcinoma basocelular	23
Queratosis actínica	21
Dermatitis alérgica de contacto	21
Acné	16
Dermatofibroma	16
Melanoma	14
Total top-10	234

C.7 Cola larga diagnóstica

La distribución por L3 presenta una cola larga pronunciada. La tabla C.5 cuantifica el reparto de las 250 clases L3 efectivamente representadas en el corpus según el número de imágenes asociadas a cada clase.

Cuadro C.5: Cola larga L3 sobre las 250 clases efectivas del corpus DermapixelAI 1.0.

Rango imgs/clase	Nº clases L3	% del total
1 img	64	25,6
2-5 imgs	129	51,6
6-10 imgs	39	15,6
11-20 imgs	11	4,4
21+ imgs	7	2,8
Total	250	100,0

El 77,2 % de las 250 clases L3 efectivamente representadas dispone de cinco imágenes o menos, y un cuarto del total (25,6 %) cuenta con una única imagen. Esta característica condiciona la viabilidad de un clasificador con cabeza directa a 250 clases L3 y justifica la estrategia operativa de cabeza L2 con ranking L3 por prototipos descrita en la sección 7.5 del capítulo 7.




Figura C.3: Distribución de las 250 clases L3 efectivas en los cinco rangos definidos en la tabla C.5. Las clases con cinco imágenes o menos suman el 77,2 % del total.




Figura C.4: Distribución rankeada del número de imágenes por clase L3 (eje vertical en escala logarítmica). El perfil decae rápidamente tras los diez diagnósticos más frecuentes, lo que evidencia la asimetría de la cola larga diagnóstica.

C.8 Particionado en train, validación y test

El dataset asigna sus splits bajo regla *case-aware*: cada caso clínico, identificado por `case_id`, está íntegro en un único split.

Cuadro C.6: Tamaño de los splits oficiales del dataset DermapixelAI 1.0 con regla *case-aware* (cada caso clínico íntegro en un único split).

Split	N
train	891
val	157
test	41
Total	1 089

La regla *case-aware* se mantiene íntegra: ningún `case_id` aparece en más de un split. La verificación explícita figura en el reporte de auditoría asociado al dataset.

La composición L1 dentro de cada split no es perfectamente estratificada. En particular, Genodermatosis carece de representación en `test` (las once imágenes de esta categoría se reparten entre `train` y `val`), y once entradas L2 carecen de imágenes en `val`, mientras que veintidós L2 carecen de imágenes en `test`. Estos huecos limitan la granularidad de la evaluación por L2 o por L1 sobre los splits oficiales.

C. PIPELINE DE CONSTRUCCIÓN Y CARACTERIZACIÓN DEL DATASET DERMAPIXELAI 1.0




Figura C.5: Balance L1 por split (train, val, test) sobre el subconjunto filtrado. Genodermatosis no aparece en test.

La tabla C.7 desagrega el número de imágenes, casos y entradas ontológicas únicas por nivel observadas en cada split sobre el subconjunto filtrado utilizado para la evaluación (clinical + dermoscopy con `label_source = ontology` y L1 asignada). Las cifras sobre el corpus completo (1 089 imágenes) son las de la tabla C.6.

Cuadro C.7: Cobertura ontológica por split sobre el subconjunto filtrado (1 062 imágenes). N° de entradas únicas observadas en cada nivel.

Split	Imágenes	Casos	L1	L2	L3
train	874	527	4	38	224
val	152	98	3	28	72
test	36	28	3	17	27

El tamaño del split test (36 imágenes, 28 casos, 17 L2 únicas, 27 L3 únicas) constituye una limitación intrínseca para la evaluación a niveles ontológicos profundos sobre los splits oficiales del corpus.




Figura C.6: Histograma del número de imágenes por caso clínico. La mayor parte de los casos aportan una o dos imágenes (media 1,63, mediana 2, máximo 5).

C.9 Texto narrativo asociado al caso

Cada caso lleva asociado un campo de texto narrativo en castellano (`case_text`) que reproduce, abreviada, la historia clínica publicada en el blog: motivo de consulta, antecedentes, evolución temporal y, en ocasiones, el razonamiento diagnóstico inicial. La longitud mediana del texto es de 223 palabras por caso, con cuartiles primero y tercero en 175 y 271 palabras respectivamente. La extensión es relativamente homogénea en el dataset.

Un subconjunto reducido de casos contiene en el texto narrativo la palabra “diagnóstico” o “diagnosticar” en construcciones que podrían anticipar el resultado diagnóstico final: 32 casos (4,6 % del dataset). Este número es bajo en términos relativos pero suficiente para justificar la exclusión de estos casos en escenarios de evaluación zero-shot textual donde el modelo recibe el `case_text` como entrada.

C.10 Validación experta y campos de calidad

El dataset DermapixelAI 1.0 incorpora tres campos de validación experta cuya distinción es relevante para la interpretación de las cifras:

`label_source = ontology` (97,89 % del dataset): la etiqueta diagnóstica L3 final está mapeada a la ontología jerárquica validada con revisión experta.

`diagnosis_source = expert_v3` (98,38 % del dataset): el razonamiento textual asociado al diagnóstico está respaldado por la tercera revisión experta de la Dra. Taberner sobre el dataset.

rosa_verified = True (84,39 % del dataset): *flag* operativo que indica que la imagen ha pasado por revisión visual explícita por la Dra. Taberner como ejemplo representativo del diagnóstico asignado.

Las tres cifras no son intercambiables y conviene declararlas con precisión en cualquier comunicación derivada del trabajo. En particular, la cifra que el TFG defendido y los reportes técnicos asocian a “validación experta del dataset” es la primera (97,93 %), no la tercera. La figura C.7 representa visualmente la composición de los tres campos.




Figura C.7: Distribución conjunta de los tres campos de calidad del dataset DermapixelAI 1.0: `label_source`, `rosa_verified` y `diagnosis_source`. La fracción con etiqueta L3 mapeada en la ontología (97,93 %) y la fracción con razonamiento textual respaldado (98,38 %) superan a la fracción operativa con revisión visual explícita (84,39 %).

C.11 Caracterización temporal y de exclusiones

C.11.1 Distribución temporal

Las imágenes del corpus DermapixelAI 1.0 se distribuyen en un rango temporal que abarca desde 2011 hasta 2026, en correspondencia con los más de quince años de publicación continuada del blog Dermapixel. La figura C.8 muestra la distribución anual de imágenes incorporadas al corpus. El año de mayor aportación es 2017 con 87 imágenes; el perfil agregado sugiere una agrupación natural por décadas (2011–2019 y 2020–2026) que puede emplearse como estratificación temporal en evaluaciones de robustez frente a cambios de equipamiento fotográfico o de criterio clínico.




Figura C.8: Distribución anual del número de imágenes incorporadas al corpus DermapixelAI 1.0. Rango 2011–2026; año pico 2017 con 87 imágenes.

C.11.2 Razones de exclusión

El pipeline de construcción descartó 80 imágenes del candidato original. La tabla C.8 desagrega las razones documentadas en `excluded_images.csv`.

Cuadro C.8: Razones de exclusión documentadas durante la construcción del dataset DermapixelAI 1.0.

Razón	N
not_found	35
not_derm_user_confirmed	19
md5_matches_solution	10
dermoscopy_pending	9
dedup_same_md5	6
not_derm_visual_review	1
Total	80

La razón más frecuente es `not_found` (35 imágenes, correspondientes a páginas del blog no recuperables en la fase de extracción). Le siguen `not_derm_user_confirmed` (19, imagen no dermatológica confirmada manualmente), `md5_matches_solution` (10, fuga directa con el panel de solución del blog, susceptible de inducir *leakage* diagnóstico), `dermoscopy_pending` (9, calidad dermatoscópica pendiente de validación experta), `dedup_same_md5` (6, duplicados exactos) y `not_derm_visual_review` (1, exclusión por revisión visual posterior). El registro íntegro de exclusiones permite la reproducción exacta del filtrado y la auditoría de integridad descrita en el paso (vi) del pipeline.

DECLARACIÓN SOBRE EL USO DE HERRAMIENTAS DE INTELIGENCIA ARTIFICIAL

Este anexo documenta el uso de herramientas de inteligencia artificial durante la elaboración del presente Trabajo de Fin de Grado, en cumplimiento de las directrices institucionales de la Universitat de les Illes Balears sobre transparencia académica en el uso de tecnologías generativas.

D.1 Alcance de la declaración

La declaración cubre la totalidad del periodo de redacción y desarrollo del presente trabajo (curso académico 2025-2026). Se distinguen tres ámbitos de uso, cuya descripción detallada se desarrolla en las secciones siguientes: uso académico (redacción del documento), uso técnico (desarrollo del código y de los experimentos) y uso documental (organización de notas y trazabilidad).

D.2 Herramientas empleadas

La tabla D.1 enumera las herramientas de inteligencia artificial empleadas durante el desarrollo del trabajo, su modalidad de uso y el ámbito al que se aplican.

Cuadro D.1: Herramientas de IA empleadas durante la elaboración del TFG.

Herramienta	Proveedor	Modalidad	Ámbito
Claude (Sonnet, Opus)	Anthropic	Asistente conversacional	Redacción, código, organización
GPT-4o, GPT-4o-mini	OpenAI	API programática	Evaluación experimental (objeto del trabajo)
GPT-5 (familia)	OpenAI	API programática	Razonamiento clínico del prototipo
Gemini 2.5 Pro/Flash	Google	API programática	Evaluación experimental (objeto del trabajo)
MedGemma 4B y 27B	Google	Modelos locales	Evaluación + razonamiento del prototipo
GitHub Copilot	GitHub	Asistencia en IDE	Sugerencias de código

D.3 Uso académico: redacción del documento

Las herramientas conversacionales (Claude Sonnet y Opus) se han utilizado durante la redacción del presente documento en cuatro modalidades: (i) revisión estilística y de coherencia narrativa sobre el texto producido por el autor; (ii) reformulación de párrafos con tono no académico hacia un tono paper estricto, conforme a las indicaciones explícitas del director del trabajo; (iii) verificación cruzada entre afirmaciones cuantitativas del texto y los reportes técnicos en el repositorio (auditoría descrita en sección D.7); (iv) asistencia en la generación de tablas LaTeX a partir de datos preexistentes en formato Markdown.

En ningún caso se ha utilizado la herramienta para generar contenido original sobre los resultados experimentales, la interpretación de los hallazgos o la formulación de las conclusiones. Las cifras reportadas en el capítulo 4 y discutidas en el capítulo 5 provienen exclusivamente de los experimentos ejecutados por el autor, documentados en los reportes técnicos del repositorio (sección A.2) y verificables de forma independiente.

D.4 Uso técnico: desarrollo del código

Las herramientas de asistencia en IDE (GitHub Copilot) se han utilizado durante el desarrollo del código en dos modalidades: (i) autocompletado de sentencias rutinarias (carga de datasets, formateo de salidas, configuración de *loggers*); (ii) generación inicial de plantillas de *tests* unitarios y de *wrappers* de modelos a partir de la documentación oficial de las bibliotecas empleadas.

El código de los protocolos experimentales centrales (sondeo lineal, ajuste fino, segmentación, evaluación zero-shot, auditoría de leakage) ha sido desarrollado por el autor con referencia explícita a la implementación original publicada por los autores de PanDerm [1] y de DermLIP [2]. La revisión de la corrección de los algoritmos y la validación de los resultados se ha realizado por el autor mediante reproducción cruzada de cifras de referencia (p. ej. ajustar los hiperparámetros hasta reproducir el rango de AUROC reportado por los autores sobre los datasets compartidos).

D.5 Uso documental: organización y trazabilidad

Las herramientas conversacionales se han utilizado adicionalmente para tareas de organización documental que no afectan al contenido del trabajo: redacción de notas internas, estructuración del índice del repositorio, formateo de documentación auxiliar (no incluida en el documento final) y generación de informes de estado del proyecto durante el desarrollo.

D.6 Modelos como objeto de evaluación

GPT-4o, GPT-4o-mini, Gemini 2.5 Pro, Gemini 2.5 Flash, MedGemma 4B Vision y MedGemma 27B Text constituyen *objetos de evaluación* del presente trabajo (capítulo 4, sección 4.7), no herramientas auxiliares de redacción. Su uso se documenta en los protocolos experimentales correspondientes (sección 3.6.6). La declaración del presente

anexo se refiere exclusivamente al uso de inteligencia artificial como *instrumento de apoyo* a la elaboración del documento, no como objeto experimental.

D.7 Verificación cruzada de cifras y citas

Durante la fase final de redacción se ha aplicado un protocolo sistemático de verificación cruzada entre las afirmaciones cuantitativas del texto y los reportes técnicos del repositorio. El procedimiento, descrito en el documento interno PRECAUCIONES_ANEXOS.md, consiste en: (i) identificación de cada cifra cuantitativa del documento; (ii) localización de la fuente verificable (RESULTADOS_TFG.md, archivos en results/ o output/); (iii) clasificación del estado en cuatro categorías: OK (cifra verificada), PARCIAL (existe el mecanismo pero falta la ejecución reportada), FALTA (sin evidencia) y CONTRADICCIÓN (divergencia entre texto y fuente). Las inconsistencias detectadas se han corregido antes del depósito o documentado explícitamente como [NO ESPECIFICADO] cuando la cifra exacta requería ejecución pendiente.

D.8 Responsabilidad sobre el contenido

La autoría intelectual del trabajo, la formulación de la pregunta de investigación, el diseño experimental, la ejecución de los experimentos, la interpretación de los resultados, la redacción final del documento y la responsabilidad sobre las afirmaciones contenidas corresponden íntegramente al autor del presente Trabajo de Fin de Grado, bajo la supervisión académica del director Dr. Javier Varona Gómez y con la colaboración clínica de la Dra. Rosa Taberner Ferrer. Las herramientas de inteligencia artificial empleadas constituyen instrumentos de apoyo cuya contribución se enmarca en los términos descritos en este anexo.

DOCUMENTO DE ENTREGA DEL DATASET DERMAPIXELAI 1.0

Este anexo recoge el documento de entrega formal del dataset DermapixelAI 1.0, complementario al anexo C que documenta su pipeline interno de construcción. El presente anexo sigue el formato *Datasheet for Datasets* propuesto por [28] y reúne la información necesaria para la reutilización académica del dataset.

E.1 Identidad del dataset

- **Nombre:** DermapixelAI.
- **Versión:** 1.0 (primera versión estable y publicable).
- **Fecha de cierre de la versión 1.0:** mayo de 2026.
- **Identificador persistente (DOI):** pendiente de asignación en el momento de la publicación efectiva del dataset. El depósito formal se realiza en **Zenodo** (<https://zenodo.org>) bajo licencia CC BY-NC-SA 4.0 con DOI permanente y citable, complementado con el repositorio de la Universitat de les Illes Balears cuando éste habilite el alojamiento de datasets binarios de tamaño equivalente.
- **Cita corta:** *Taberner, R. y Contestí Coll, A. (2026). DermapixelAI 1.0: dataset dermatológico clínico en castellano. Versión 1.0.*

E.2 Procedencia y autoría

El dataset DermapixelAI 1.0 se construye a partir del archivo del blog Dermapixel (<https://dermapixel.com>), mantenido desde hace más de quince años por la Dra. R. Taberner, dermatóloga clínica del Hospital Universitario Son Llàtzer. El archivo original

recoge casos clínicos comentados con fines docentes y representa la materia prima a partir de la cual se ha estructurado el dataset documentado en este anexo.

La construcción del dataset, el pipeline de extracción y estructuración, la definición de la ontología jerárquica L1/L2/L3 y el particionado han sido desarrollados por Antonio Contestí Coll en el marco del presente Trabajo de Fin de Grado y del trabajo paralelo de modernización tecnológica del archivo Dermapixel descrito en el capítulo 1. El uso del archivo Dermapixel como materia prima del dataset se ha realizado bajo acuerdo previo con la Dra. R. Taberner, formalizado por escrito en el marco de la colaboración entre ambos sobre la modernización del archivo y sobre el proyecto institucional de tele dermatología del IB-Salut. La revisión experta de las etiquetas diagnósticas, del mapeo a la ontología jerárquica y de los campos de validación asociados (`label_source`, `diagnosis_source`, `rosa_verified`) ha sido aportada por la Dra. Taberner.

En consecuencia, el dataset se publica con autoría compartida Taberner & Contestí Coll, en este orden, dado que el archivo Dermapixel del que deriva el dataset es propiedad intelectual de la Dra. Taberner y constituye el material original sin el cual el dataset no existiría. La cita recomendada (sección E.4) refleja esta autoría conjunta en el mismo orden.

E.3 Licencia de uso

DermapixelAI 1.0 se publica bajo la licencia **Creative Commons Reconocimiento–NoComercial–CompartirIgual 4.0 Internacional (CC BY-NC-SA 4.0)**. Texto canónico de la licencia: <https://creativecommons.org/licenses/by-nc-sa/4.0/deed.es>.

Esta licencia implica, en lo que respecta al uso del dataset:

- **Reconocimiento (BY)**. Cualquier uso del dataset o de obras derivadas exige la cita explícita del dataset original en la forma indicada en la sección E.4.
- **No comercial (NC)**. El dataset no puede emplearse con fines primordialmente comerciales. La investigación académica, el uso docente y el desarrollo de prototipos en fase no comercial quedan dentro del alcance de la licencia.
- **Compartir Igual (SA)**. Cualquier obra derivada del dataset —incluidas, por ejemplo, versiones ampliadas o subconjuntos re-annotados— deberá distribuirse bajo la misma licencia o una licencia compatible que preserve estas condiciones.

La elección de CC BY-NC-SA 4.0 responde a un equilibrio entre la voluntad de los autores de facilitar la reutilización académica del material y la naturaleza clínica del archivo original, derivado de casos asistenciales reales publicados con finalidad docente.

E.4 Cita recomendada

La cita en prosa recomendada para cualquier publicación que utilice el dataset es:

Taberner, R. y Contestí Coll, A. (2026). *DermapixelAI 1.0: dataset dermatológico clínico en castellano construido sobre el archivo Dermapixel*. Versión 1.0. Licencia CC BY-NC-SA 4.0.

Entrada BibTeX equivalente (pendiente de completar con el DOI tras la publicación efectiva):

```
@dataset{dermapixelai2026,
  author    = {Taberner, Rosa and Contestí Coll, Antonio},
  title     = {DermapixelAI 1.0: dataset dermatológico
              clínico en castellano construido sobre
              el archivo Dermapixel},
  year      = {2026},
  version   = {1.0},
  license   = {CC BY-NC-SA 4.0},
  doi       = {pendiente},
  url       = {pendiente},
}
```

E.5 Disponibilidad y distribución

La publicación efectiva del dataset en un repositorio externo está pendiente de decisión en la fecha de cierre del presente trabajo. La plataforma de distribución, la asignación del identificador persistente (DOI) y la disponibilidad pública se documentarán en el campo correspondiente de la cita BibTeX cuando se haya realizado el depósito. Mientras tanto, las consultas sobre acceso al dataset deben dirigirse al contacto indicado en la sección E.9.

La estructura del paquete previsto se compone de:

- `dataset.csv`: fichero maestro con una fila por imagen (1 089 filas) y campos de modalidad, ruta, hash MD5, diagnóstico L1/L2/L3, campos de validación experta, identificador de caso, texto narrativo y partición del split.
- `metadata/cases.csv`: una fila por caso clínico, incluidos los casos sin imagen en el dataset (`num_images_in_dataset = 0`) por trazabilidad.
- `metadata/ontology.csv`: vocabulario jerárquico L1/L2/L3 con códigos SNO-MED CT y CIE-10 asociados a cada entrada L3.
- `metadata/excluded_images.csv`: registro de imágenes descartadas durante el pipeline, con razón documentada.
- `metadata/audit_log.txt`: traza de auditoría de las modificaciones aplicadas al dataset.
- `splits/train.csv`, `splits/val.csv`, `splits/test.csv`: particiones canónicas case-aware.

- `images/`: imágenes organizadas por modalidad (`clinical/`, `dermoscopy/`, `histology/`, `ultrasound/`, `wood_lamp/`).
- `README.md`: documento que reproduce, en forma de fichero plano, el contenido del presente anexo.
- `LICENSE.txt`: texto canónico de la licencia CC BY-NC-SA 4.0 con cláusulas específicas de privacidad del paciente y provenance clínico.
- `CITATION.cff`: ficha de citación en formato Citation File Format 1.2.0, con el campo `preferred-citation` preparado para sustituir el DOI cuando Zenodo lo asigne.
- `MANIFEST.sha256`: manifiesto global del paquete con el hash SHA-256 de cada uno de los archivos distribuidos, verificable con `sha256sum -c MANIFEST.sha256`.
- `enriched_captions/`: corpus enriquecido SpanDerm-CLIP con captions sintéticas multi-perspectiva generadas por LLM (sección 4.17) y `spanderm_clip_trilogy/` con los resultados experimentales completos del experimento dual encoder.

La integridad reproducible del paquete se verifica en dos niveles: (i) el manifiesto interno de cada partición o subconjunto experimental, fijado en el *checkpoint* correspondiente; y (ii) el manifiesto global del paquete distribuido (`MANIFEST.sha256`), que cubre los 1 174 archivos del *bundle* y permite detectar cualquier alteración durante la descarga o el almacenamiento intermedio. Ambos niveles son independientes y se generan de forma determinista.

E.6 Datasheet for Datasets

Esta sección sigue el formato propuesto por [28] con las cuestiones más relevantes para el dataset.

Motivación

¿Para qué se creó el dataset? El dataset se ha construido para servir de material de investigación académica sobre dermatología clínica en castellano, con foco en el aprendizaje multimodal (imagen acompañada de texto clínico) y como base estable para trabajos posteriores. No se ha creado como benchmark de evaluación del presente TFG sino como contribución resultante del proyecto a la comunidad investigadora.

¿Quién lo financió? La construcción del dataset se ha realizado sin financiación específica, en el marco del presente Trabajo de Fin de Grado, desarrollado en la Escola Politècnica Superior de la Universitat de les Illes Balears, y de la colaboración con la Dra. R. Taberner sobre la modernización del archivo Dermapixel.

Composición

¿Qué representa cada instancia? Cada instancia es una imagen dermatológica asociada a un caso clínico publicado en el archivo Dermapixel.

¿Cuántas instancias hay? 1 089 imágenes vinculadas a 672 casos con imagen sobre 698 casos catalogados en total.

¿Es el dataset un subconjunto de uno mayor? El dataset se construye a partir del archivo público del blog Dermapixel (<https://dermapixel.com>), que tiene una composición más amplia en términos de publicaciones y elementos no clínicos (banners, ilustraciones, fotografías de eventos) que se filtran durante la construcción del dataset (sección C.2 del anexo C).

¿Qué información acompaña a cada imagen? Modalidad, diagnóstico L1/L2/L3, identificador de caso, texto narrativo asociado en castellano, campos de validación experta y particionado en train/val/test.

¿Hay etiquetas o ground-truth? Sí. El diagnóstico L3 está mapeado a la ontología jerárquica con revisión experta. El campo `rosa_verified` marca las imágenes adicionalmente validadas visualmente por la Dra. Taberner.

¿Hay información que se haya eliminado? Se han eliminado las imágenes asociadas a la pista de solución de los casos del blog (susceptibles de inducir *leakage*) y las imágenes no dermatológicas detectadas durante la auditoría de modalidad.

Proceso de recogida

El detalle del pipeline figura en la sección C.2 del anexo C.

Preprocesamiento, limpieza y etiquetado

Hash MD5 por imagen para integridad; deduplicación exacta; mapeo ontológico con revisión experta; particionado case-aware. Detalle en el anexo C.

Usos previstos

¿Para qué tipo de tareas se ha diseñado? Investigación académica sobre dermatología clínica en castellano, en particular los escenarios que requieren material multimodal imagen-texto en español, la armonización ontológica entre datasets dermatológicos heterogéneos, y la docencia universitaria sobre análisis de imagen médica.

¿Para qué tareas *no* debe usarse? El dataset no constituye un dispositivo médico ni puede emplearse como base de un sistema de diagnóstico autónomo destinado a uso clínico directo. Cualquier aplicación clínica derivada del dataset debe seguir los procesos regulatorios correspondientes y no puede sustituir al juicio del especialista.

Distribución

CC BY-NC-SA 4.0. Plataforma pendiente de decisión en la fecha de cierre del trabajo.

Mantenimiento

Versionado semántico. Política de errata reportable mediante el contacto de la sección E.9.

E.7 Uso responsable y limitaciones clínicas

El dataset DermapixelAI 1.0 se distribuye con las advertencias siguientes:

- **No es un dispositivo médico.** El dataset es material de investigación académica. Cualquier prototipo desarrollado a partir del dataset que aspire a uso clínico real debe seguir los procedimientos regulatorios aplicables (marcado CE, evaluación clínica, etc.).
- **No para uso diagnóstico autónomo.** Las predicciones generadas por modelos entrenados o evaluados sobre el dataset no pueden sustituir al juicio del dermatólogo. El dataset se ha diseñado para apoyar la investigación en sistemas de apoyo al diagnóstico, no para reemplazar la consulta especializada.
- **Limitaciones de cobertura.** El dataset presenta limitaciones específicas (desbalance de modalidad, cola larga diagnóstica, cobertura ontológica incompleta, cobertura parcial por subcategoría en los splits) documentadas en el anexo C. Cualquier publicación derivada debe declarar estas limitaciones cuando reporte cifras de rendimiento.
- **Generalización geográfica.** El dataset proviene del archivo Dermapixel, alimentado por casos atendidos en el HUSLL en Mallorca, España. La validez de los resultados sobre poblaciones de fototipo, geografía o circuito asistencial distintos requiere verificación independiente.

E.8 Privacidad y consentimiento

El archivo Dermapixel es un blog público dirigido a la formación de profesionales sanitarios. Las imágenes publicadas en el blog proceden de casos atendidos por la Dra. R. Taberner en su práctica clínica y se publicaron originalmente con consentimiento implícito en el marco del compromiso docente del blog y de la práctica asistencial habitual sobre material clínico anonimizado para uso formativo. El dataset DermapixelAI 1.0 hereda esta naturaleza de material docente público.

El dataset no contiene metadatos identificativos directos de pacientes (nombres, fechas de nacimiento, números de historia clínica, ubicación geográfica concreta). Las imágenes están recortadas a la lesión cuando procede; las fotografías macroscópicas preservan únicamente la región anatómica relevante.

Cualquier reusuario del dataset se compromete, en el momento de aceptar la licencia, a no intentar reidentificar a los pacientes representados en las imágenes ni a usar el material con finalidad distinta a la investigación académica o docente.

E.9 Mantenimiento y contacto

Política de versionado. El dataset se versiona siguiendo una numeración semántica MAJOR.MINOR. Cambios en el conjunto de imágenes incluidas o en la ontología canónica incrementan el campo MAJOR. Correcciones de etiquetado, normalización de campos o ampliaciones de los campos de validación experta incrementan el campo MINOR.

Reporte de errata. Cualquier discrepancia detectada entre las etiquetas asignadas y el diagnóstico correcto, o cualquier problema de integridad, puede reportarse al contacto indicado a continuación. Las erratas confirmadas se incorporan en la siguiente versión MINOR del dataset.

Contacto.

- **Propietaria del archivo original y revisión experta clínica:** Dra. Rosa Taberner
- **Autor técnico del dataset:** Antonio Contestí Coll
- **Afiliación principal:** Hospital Universitario Son Llàtzer y Universitat de les Illes Balears (Escola Politècnica Superior)
- **Canal de contacto preferente:** mediante el repositorio oficial del dataset una vez publicado; mientras tanto, a través del autor técnico del dataset, Antonio Contestí Coll.

SPARSE AUTOENCODERS Y DICCIONARIO DE CONCEPTOS CLÍNICOS

Este anexo documenta el módulo de interpretabilidad conceptual del trabajo, basado en Sparse Autoencoders (SAE) sobre las representaciones de PanDerm Large, su evaluación frente al diccionario SkinCon [15] y la propuesta de extensión con conceptos clínicos adicionales validados por la Dra. R. Taberner. El módulo se incorpora al prototipo DermApIxel como componente M3 (sección H.3.3) y constituye una contribución complementaria del trabajo (sección 7.2.2).

F.1 Motivación

La interpretabilidad de los modelos fundacionales constituye un requisito creciente en escenarios clínicos donde la trazabilidad del razonamiento es necesaria para la aceptación profesional. Los encoders auto-supervisados como PanDerm producen representaciones densas (vectores de 1 024 dimensiones para la variante *Large*) cuyos componentes individuales no admiten interpretación directa. Los Sparse Autoencoders [19] descomponen estas representaciones en un diccionario disperso de *features*, con la propiedad de que cada *feature* puede asociarse, en buena parte de los casos, a un concepto clínicamente identificable. DermFM-Zero [3] adopta este mecanismo de interpretabilidad como contribución de su diseño, pero sus pesos no son públicos (sección 6.1.1). El presente trabajo replica el procedimiento sobre PanDerm Large con pesos liberados y lo valida sobre SkinCon como ground-truth conceptual.

F.2 Arquitectura del SAE

La arquitectura del SAE empleado en el trabajo se compara con la descrita por los autores de DermFM-Zero sobre PanDerm Base. La tabla F.1 resume ambas configuraciones.

Cuadro F.1: Configuración comparada del SAE entrenado en el trabajo (“SAE Large”) y del SAE publicado por DermFM-Zero (“SAE Base”).

Parámetro	SAE Base (DermFM-Zero)	SAE Large (este trabajo)
Encoder visual base	PanDerm Base (ViT-B/16)	PanDerm Large (ViT-L/16)
Dimensión de entrada	768	1024
Features aprendidas	6144 (8×)	16384 (16×)
Arquitectura	TiedBias + UnitNormDecoder	Pre/PostBias + Linear + UnitNormDecoder
Pérdida	$L_1 (3 \times 10^{-5}) + L_2$	$L_1 (1 \times 10^{-3}) + \text{MSE}$
Datos de entrenamiento	No especificado (pipeline DermFM-Zero)	50454 imágenes (7 datasets)
Épocas	200	100 (convergado)
Sparsity media observada	—	16,5% (2753 ± 112 activas)

Los siete datasets de entrenamiento del SAE Large son HAM10000 (10015 imágenes), BCN20000 (12413), Dermnet (19559), PAD-UFES-20 (2298), Fitzpatrick17k (3887), DDI (647) e HIBA (1635), con un total de 50454 imágenes. La composición exacta se documenta en el Anexo B (tabla B.6). La elección de $L_1 (1 \times 10^{-3})$ en lugar del valor publicado por DermFM-Zero (3×10^{-5}) responde a la dimensión de entrada mayor: el factor L_1 relativo a la magnitud típica del *embedding* se mantiene comparable.

F.3 Comportamiento del SAE Large frente a SAE Base

La tabla F.2 compara la AUROC de cuatro tareas de discriminación binaria sobre los *embeddings* crudos (sin SAE) y sobre las activaciones del SAE para ambas configuraciones. Las cifras corresponden a la media y desviación estándar sobre veinte particiones aleatorias del conjunto de evaluación.

Cuadro F.2: Discriminación binaria sobre cuatro tareas con *embeddings* crudos y con activaciones del SAE. Media ± desviación estándar sobre 20 particiones aleatorias.

Tarea	Raw 768D (Base)	SAE Base (6144)	Raw 1024D (Large)	SAE Large (16384)
Melanoma	0,906 ± 0,020	0,897 ± 0,019	0,897 ± 0,020	0,900 ± 0,019
Sesgo pelo	0,888 ± 0,025	0,879 ± 0,023	0,884 ± 0,023	0,889 ± 0,024
Sesgo tinta	0,848 ± 0,024	0,836 ± 0,025	0,846 ± 0,028	0,851 ± 0,028
Sesgo regla	0,888 ± 0,024	0,889 ± 0,026	0,894 ± 0,022	0,908 ± 0,022

El SAE Base degrada consistentemente la AUROC respecto a los *embeddings* crudos correspondientes (promedio −0,008 pp), mientras que el SAE Large produce mejoras de +0,007 pp de promedio sobre los *embeddings* crudos de 1024 dimensiones. La interpretación operativa es que el SAE Large preserva la información discriminativa relevante para clasificación binaria pese a la proyección al espacio disperso de 16384 *features*, comportamiento que justifica su uso como módulo de interpretabilidad sin pérdida de utilidad diagnóstica.




Figura F.1: Comparativa AUROC entre *embeddings* crudos y activaciones del SAE sobre cuatro tareas binarias. El SAE Large (este trabajo, $1024 \rightarrow 16384$) preserva o mejora la información discriminativa frente al SAE Base ($768 \rightarrow 6144$), que degrada consistentemente la AUROC.

F.4 Concept Bottleneck Model sobre SkinCon

La validación clínica del SAE Large se realiza mediante un *Concept Bottleneck Model* (CBM) sobre el dataset SkinCon [15], que anota densamente 3230 imágenes con 48 conceptos clínicos por dermatólogos certificados. La hipótesis a contrastar es que las 16384 *features* del SAE Large contienen información suficiente para predecir los conceptos SkinCon mediante un clasificador lineal sobre cada concepto.

El procedimiento es el siguiente: cada imagen de SkinCon se codifica mediante PanDerm Large; su *embedding* de 1024 dimensiones se proyecta al espacio disperso del SAE Large; sobre las 16384 activaciones se entrena un clasificador lineal binario por concepto (regresión logística L-BFGS con $C = 1,0$, $\text{max_iter} = 5000$, $\text{random_state} = 42$). La métrica reportada es la AUROC del mejor *feature* individual como predictor del concepto.

F.4.1 Conceptos con mejor predictor

La tabla F.3 reporta los conceptos SkinCon con mejor predictor entre las 16384 *features* del SAE Large, ordenados por AUROC del mejor *feature* descendente.

Cuadro F.3: Conceptos SkinCon con mejor predictor entre las *features* del SAE Large. n_+ : número de imágenes positivas para el concepto en SkinCon. AUROC: del mejor *feature* individual del SAE como predictor binario del concepto.

Concepto clínico	n_+	Mejor <i>feature</i>	AUROC
Pedunculated	26	#1930	0,929
Friable	153	#5973	0,913
Exophytic/Fungating	42	#10114	0,908
Comedo	24	#7191	0,903
Ulcer	154	#13908	0,897
Exudate	144	#5973	0,884
Wheal	21	#9552	0,884
Black	90	#3926	0,846
Telangiectasia	100	#11172	0,828
Nodule	189	#1930	0,818
Umbilicated	49	#13783	0,810

Los conceptos con mejor predictor incluyen un núcleo de morfología elevada (*pedunculated*, *exophytic/fungating*, *nodule*: AUROC 0,818–0,929), de superficie alterada (*friable*, *ulcer*, *exudate*: AUROC 0,884–0,913) y de estructura específica (*telangiectasia*: AUROC 0,828). Cada *feature* del SAE puede actuar como predictor para más de un concepto relacionado (e.g. #1930 cubre *pedunculated* y *nodule*; #5973 cubre *friable* y *exudate*), lo que sugiere que el espacio disperso del SAE codifica dimensiones clínicas de granularidad superior a la del concepto individual.

F.4.2 Rendimiento agregado del CBM

Sobre los 22 conceptos de SkinCon con cobertura suficiente para el contraste, el protocolo *CBM-Selected* (regresión logística entrenada sobre 134 *features* del SAE Large correlacionadas con cada concepto) alcanza AUROC media de 0,880. El protocolo de comparación *LP-Direct* (regresión logística sobre el *embedding* crudo de 1024 dimensiones de PanDerm Large, sin pasar por el SAE) alcanza AUROC media de 0,864 sobre los mismos conceptos. CBM-Selected supera a LP-Direct en 16 de los 22 conceptos evaluados. El resultado indica que las *features* dispersas del SAE preservan —y en la mayoría de conceptos exceden— el poder predictivo de la representación densa subyacente, comportamiento que sostiene su uso como módulo de interpretabilidad en el prototipo descrito en la sección H.3.3 del Anexo H.

F5. Propuesta de extensión: quince conceptos clínicos adicionales




Figura F2: Concept Bottleneck Model sobre SkinCon: AUROC del mejor *feature* individual del SAE Large como predictor binario por concepto. Once conceptos superan AUROC 0,80, con máximos en *pedunculated* (0,929) y *friable* (0,913).

F.5 Propuesta de extensión: quince conceptos clínicos adicionales

El diccionario SkinCon, construido en el contexto del estudio de Daneshjou et al. [15], prioriza conceptos visuales estructurales de detección automatizable. La revisión clínica realizada por la Dra. R. Taberner sobre el dataset DermapixelAI 1.0 ha identificado 15 conceptos clínicos adicionales no contemplados por SkinCon que aparecen con frecuencia relevante en la práctica dermatológica hispanohablante y cuya inclusión enriquecería el diccionario operativo del prototipo. La tabla F.4 enumera los conceptos propuestos.

Cuadro F.4: Quince conceptos clínicos adicionales propuestos por la Dra. R. Taberner sobre la base del diccionario SkinCon.

Categoría	Concepto propuesto	Relevancia clínica
Pigmentación	Pigmentación reticular	Diagnóstico diferencial nevus
Pigmentación	Pseudorede	Lentigo solar <i>vs.</i> lentigo maligno
Vasculatura	Lagunas vasculares	Hemangioma, angioqueratoma
Vasculatura	Vasos en horquilla	Carcinoma basocelular
Estructura epidérmica	Hiperqueratosis	Queratosis seborreica
Estructura epidérmica	Comedo invertido	Queratosis seborreica adelgazada
Patrón inflamatorio	Eritema heliotropo	Dermatomiositis
Patrón inflamatorio	Patrón en <i>papel de seda</i>	Liquen escleroso
Distribución	Distribución dermatomérica	Herpes zóster
Distribución	Distribución <i>en alas</i>	Lupus subagudo
Superficie	Cráteres centrales	Molluscum contagioso
Superficie	Anillos concéntricos	Eritema multiforme
Color	Coloración <i>salmón</i>	Psoriasis guttata
Color	Halo blanco perilesional	Nevus halo
Otros	Bordes geográficos	Vitiligo segmentario

La incorporación de estos quince conceptos al diccionario operativo del prototipo

DermApIxel constituye una línea de continuación inmediata, condicionada al muestreo de aproximadamente 200 imágenes anotadas por concepto para entrenar el clasificador lineal correspondiente sobre las activaciones del SAE Large. El protocolo de anotación previsto utiliza la interfaz autocontenida descrita en la sección 7.5 del capítulo 7.

F.6 Limitaciones del módulo SAE

El módulo SAE presenta tres limitaciones declaradas. Primero, la asociación entre *feature* y concepto se establece sobre la base del mejor predictor individual, sin garantía de que la *feature* sea *monosemántica* en el sentido estricto del término (la misma *feature* puede correlacionarse con varios conceptos relacionados, como se observa en sección F.4.1). Segundo, el rendimiento del SAE Large sobre tareas de discriminación binaria (tabla F.2) es ligeramente superior al de los *embeddings* crudos correspondientes, pero esta mejora es del orden de la desviación estándar inter-partición, lo que limita la afirmación de *superioridad estadísticamente significativa* sin las pruebas pendientes (sección 6.3.2). Tercero, la validación sobre conceptos clínicos se realiza sobre SkinCon, dataset con sesgo de selección hacia patología dermatoscópica documentada, lo que condiciona la transferencia a otros contextos clínicos.

MODELOS DE LENGUAJE MULTIMODALES: COMPARACIÓN EXTENDIDA

Este anexo amplía la comparación entre modelos de lenguaje multimodales generalistas presentada en sección 4.7 del capítulo 4. Contiene el *prompt* clínico empleado en la evaluación, el análisis detallado de patrones de error sobre HAM10000, la caracterización de la sensibilidad al *prompt* en DermLIP v2 (que motiva el *wrapping* automático del prototipo) y la comparación de costes operativos agregados.

G.1 Modelos evaluados

La tabla G.1 enumera los modelos evaluados y sus condiciones de acceso. Los modelos accesibles vía API se han evaluado con la versión disponible en marzo de 2026; los modelos locales se han ejecutado sobre la DGX Spark con chip Grace Hopper GB10 en precisión BF16 sin cuantización adicional.

Cuadro G.1: Modelos de lenguaje multimodales generalistas evaluados.

Modelo	Proveedor	Parámetros	Acceso
GPT-4o	OpenAI	No público	API REST
GPT-4o-mini	OpenAI	No público	API REST
Gemini 2.5 Pro	Google	No público	API REST
Gemini 2.5 Flash	Google	No público	API REST
MedGemma 4B Vision	Google	~ 4 B	Local (Ollama)
MedGemma 27B Text	Google	~ 27 B	Local (DGX Spark, BF16)
MedGemma 27B + LoRA	Google	~ 27 B + 41 M LoRA	Local (DGX Spark, BF16)
BLIP-2 Flan-T5-XL	Salesforce	—	Local (HuggingFace)
InstructBLIP Flan-T5-XL	Salesforce	—	Local (HuggingFace)

G.2 Prompt clínico estandarizado

El *prompt* clínico empleado en la evaluación tiene aproximadamente 300 palabras y describe la tarea, presenta las clases candidatas y solicita el diagnóstico estructurado. La formulación se mantiene constante entre los nueve proveedores evaluados, lo que elimina la formulación del *prompt* como variable confusoria. La estructura es la siguiente:

You are assisting in a dermatology research study. This is a dermoscopic image of a skin lesion taken during clinical practice. Your task is to classify the lesion as exactly one of the following seven categories used in the HAM10000 dataset: melanoma (mel), melanocytic nevus (nv), basal cell carcinoma (bcc), actinic keratosis (akiec), seborrheic keratosis (bkl), dermatofibroma (df) or vascular lesion (vasc). Provide your answer as a single diagnostic label followed by a brief clinical justification (1–2 sentences). The justification should mention the morphological features that support the diagnosis (e.g., asymmetry, border regularity, color pattern, vascular structures). Avoid hedging language; commit to the most likely diagnosis based on the visible features. Do not refuse to answer. Respond only with the category name and the justification.

Para Gemini 2.5 Pro y Gemini 2.5 Flash, el *prompt* se ajusta levemente para evitar la activación de filtros de seguridad (refusal rate documentado: ~ 22% en Gemini 2.5 Pro sobre HAM10000 frente a < 1% en GPT-4o). La etiqueta predicha se extrae mediante *parsing* determinista que mapea sinónimos admitidos al código canónico de HAM10000.

G.3 Comparativa completa sobre HAM10000, PAD-UFES-20 y DDI

La tabla G.2 reproduce la comparativa de la tabla 4.10 del cuerpo, ampliada con las variantes Gemini Flash y BLIP-2 + InstructBLIP para incluir el espectro completo de modelos evaluados.

Cuadro G.2: Comparativa completa de modelos de lenguaje multimodales sobre HAM10000 ($N = 1\,232$), PAD-UFES-20 ($N = 461$) y DDI ($N = 137$).

Modelo	Modo	HAM Acc	HAM BAcc	PAD Acc	PAD BAcc	DDI Acc	DDI BAcc
MedGemma 27B + LoRA	FT	0,802	0,270	0,430	0,347	0,657	0,618
MedGemma 27B	ZS	0,665	0,243	0,447	0,342	0,474	0,566
GPT-4o	ZS	0,485	0,465	0,553	0,523	0,723	0,648
Gemini 2.5 Pro	ZS	0,403	—	0,477	—	0,441	—
Gemini 2.5 Flash	ZS	0,380	—	0,486	—	0,555	—
GPT-4o-mini	ZS	0,256	0,319	0,390	0,435	0,737	0,556
BLIP-2 (Flan-T5-XL)	ZS	0,015	0,145	0,017	0,167	0,796	0,542
InstructBLIP (Flan-T5-XL)	ZS	0,024	0,123	0,171	0,224	0,788	0,500

G.4 Latencias, refusal rates y costes operativos

La tabla G.3 reporta las características operativas de la evaluación: latencia media por imagen, tasa de respuestas no clasificables (*refusal rate*) y coste agregado sobre los tres datasets evaluados.

Cuadro G.3: Características operativas de la evaluación de LLMs multimodales. *Refusal* sobre Gemini 2.5 Pro corresponde a respuestas bloqueadas por filtros de seguridad. “Coste” agrega HAM10000 + PAD-UFES-20 + DDI.

Modelo	Latencia/imagen	Refusal HAM	Refusal PAD	Refusal DDI	Coste total
GPT-4o	~ 4 s	< 1 %	< 1 %	< 1 %	~\$2,71
GPT-4o-mini	~ 3 s	< 1 %	< 1 %	< 1 %	~\$1,36
Gemini 2.5 Pro	~ 8 s	21,5 %	15,0 %	18,2 %	—
Gemini 2.5 Flash	~ 2 s	0,3 %	2,4 %	2,7 %	—
MedGemma 27B	1,76 s	0 %	0 %	0 %	0 EUR
MedGemma 27B + LoRA	1,82 s	0 %	0 %	0 %	0 EUR (entrenam.)

Tres observaciones operativas: (i) Gemini 2.5 Pro presenta *refusal rate* elevado sobre HAM10000 (21,5 %), comportamiento atribuible a la activación de filtros de seguridad sobre imagen clínica. (ii) MedGemma 27B y su variante con LoRA operan localmente sin coste recurrente, con latencias medidas sobre la DGX Spark de ~ 1,8 segundos por imagen, inferiores a las de los proveedores comerciales. (iii) El coste agregado de GPT-4o-mini (~ \$1,36 sobre 1830 imágenes) es de aproximadamente \$0,001 por imagen, lo que hace operativamente viable la evaluación a escala moderada; el coste de GPT-4o (~ \$2,71) duplica esta cifra.

G.5 Patrones de error sobre HAM10000

La tabla G.4 reporta la matriz de predicciones de GPT-4o sobre HAM10000. La fila “*Predicciones totales*” indica el número de imágenes asignadas a cada clase por el modelo; la comparación con la fila “ N_{test} ” revela los sesgos sistemáticos.

Cuadro G.4: Distribución de predicciones de GPT-4o sobre HAM10000.

Clase	N_{test}	Predicciones GPT-4o	Factor
actinic keratosis	35	2	0,06×
basal cell carcinoma	44	—	—
seborrheic keratosis	107	—	—
dermatofibroma	8	284	35,5×
melanoma	70	299	4,3×
melanocytic nevus	951	—	—
vascular lesion	17	—	—

El sesgo más acusado es la sobreasignación de *dermatofibroma* (predicciones 284 frente a 8 muestras reales, factor 35,5×). La hipótesis sobre el mecanismo es que el modelo responde al espacio léxico del *prompt*: la enumeración explícita de *dermatofibroma* entre las clases candidatas activa preferentemente esta categoría como respuesta cuando la evidencia visual no es saliente. Un patrón análogo, aunque de menor magnitud, se observa con melanoma (factor 4,3×), clase clínicamente prioritaria que el

modelo podría sobreasignar por reflejar un sesgo precautorio aprendido durante el entrenamiento.

GPT-4o-mini presenta un patrón distinto: sesgo masivo hacia *seborrheic keratosis* (528 predicciones frente a 107 muestras reales) y melanoma (359 predicciones frente a 70). Sólo 196 de los 951 casos de *melanocytic nevus* se clasifican correctamente (*recall* 0,196), mientras GPT-4o alcanza *recall* de 0,505 sobre la misma clase.

G.6 MedGemma 27B con LoRA: análisis por dataset

La adaptación con LoRA sobre MedGemma 27B (*rank* $r = 16$, $\alpha = 32$, dropout 0,05, 1 época, $\eta = 2 \times 10^{-5}$, *effective batch* 8, ~ 41 M parámetros entrenables sobre el *split* de entrenamiento de HAM10000) produce las mejoras asimétricas reportadas en sección 5.1.6. La tabla G.5 reporta el desglose por clase sobre HAM10000 con la variante adaptada.

Cuadro G.5: Desglose por clase de MedGemma 27B + LoRA sobre HAM10000 (*precision*, *recall*, F1).

Clase	N_{test}	Precision	Recall	F1
actinic keratosis	35	0,32	0,26	0,29
basal cell carcinoma	44	0,34	0,25	0,29
dermatofibroma	8	0,00	0,00	0,00
melanocytic nevus	951	0,85	0,99	0,92
melanoma	70	0,38	0,36	0,37
seborrheic keratosis	107	0,67	0,04	0,07
vascular lesion	17	0,00	0,00	0,00

La concentración del rendimiento sobre la clase mayoritaria (nevus melanocítico: *recall* 0,99) a costa de las minoritarias (dermatofibroma y vascular lesion: F1 0,00) contrasta con el comportamiento de PanDerm Base con ajuste fino y TTA sobre el mismo dataset, que mantiene *recall* superior a 0,65 sobre todas las clases minoritarias gracias al *weighted random sampler* de la receta original (sección 3.6.2). La diferencia metodológica sugiere que el *fine-tuning* de LLMs multimodales sobre datasets desbalanceados requiere estrategias específicas de balanceo no contempladas en la configuración estándar de LoRA.

G.7 Sensibilidad al prompt en DermLIP v2

El módulo M6 del prototipo DermApIxel (sección H.3.6) opera sobre DermLIP v2 con *wrapping* automático del *prompt*. Esta sección documenta cuantitativamente el fenómeno que motiva el *wrapping*.

Cuadro G.6: Sensibilidad al *prompt* de DermLIP v2 sobre HAM10000: curva de AUROC observada en función de la longitud del *prompt*.

Longitud del <i>prompt</i>	Estrategia	AUROC HAM10000
1 palabra	Etiqueta desnuda	≈ aleatorio
~ 5 palabras	Envoltorio clínico (“ <i>dermoscopyimageof{X}</i> ”)	~ 0,72
8–15 palabras	Envoltorio + 1 rasgo clínico	0,854
~ 20 palabras	Envoltorio + 3 conceptos Derm1M	0,842
> 25 palabras	Envoltorio + 5 conceptos Derm1M	0,826

La curva presenta un punto óptimo en 8–15 palabras con un único rasgo clínico añadido (AUROC 0,854). El rendimiento decae tanto en el régimen de *prompt* muy corto (etiqueta desnuda: AUROC aleatorio) como en el régimen de *prompt* muy largo (> 25 palabras: AUROC 0,826).

La causa propuesta sobre el régimen de *prompt* muy corto es que PubMedBERT (encoder textual de DermLIP v2) está preentrenado sobre *captions* del corpus Derm1M con estructura “dermoscopy image of [clase], [descripción]”. Una palabra aislada se proyecta sobre regiones del espacio de *embedding* muy poco pobladas, lo que produce similitudes coseno arbitrarias frente al *embedding* visual. Sobre el régimen de *prompt* muy largo, la hipótesis es que la acumulación de conceptos clínicos introduce ruido semántico que diluye la señal de la clase principal.

El *wrapping* automático del prototipo implementa esta curva en tres capas: presets predefinidos con *prompts* ya en el punto óptimo, composable `useZeroShot.js` que aplica el envoltorio “*dermoscopyimageof{term}*” cuando la entrada del usuario contiene cinco o menos palabras, y conmutador en la interfaz que permite al dermatólogo desactivar el envoltorio si escribe descripciones completas propias. La caracterización **[NO ESPECIFICADO: ampliar el barrido sistemático de longitud del prompt sobre los demás datasets de evaluación]** constituye una línea de continuación inmediata.

G.8 Síntesis

La evaluación extendida documentada en este anexo confirma los patrones cualitativos identificados en sección 5.1.6 del capítulo 5: brecha de 43,5 pp accuracy entre el mejor especialista ajustado (PanDerm Base FT con TTA) y el mejor LLM multimodal generalista *zero-shot* (GPT-4o); sesgo léxico sistemático en los modelos cerrados; *refusal rates* elevados en Gemini 2.5 Pro que limitan su utilidad clínica; y asimetría en la adaptación con LoRA sobre MedGemma 27B. Las cifras detalladas refuerzan la conclusión de que los LLMs multimodales generalistas no constituyen sustitutos defendibles de los encoders fundacionales específicos del dominio en el régimen clínico evaluado, pero pueden complementarlos como generadores de razonamiento textual estructurado bajo el *prompt* clínico descrito en sección G.2.

PROTOTIPO DERMAPIXEL

Este anexo describe el prototipo *DermApIxel*, sistema integrado de apoyo al diagnóstico dermatológico construido como entorno operativo de los módulos derivados del trabajo experimental. La versión inicial documentada en las secciones H.1–H.7 opera con seis módulos de inteligencia artificial (M1–M6), estado correspondiente al despliegue *end-to-end* de 2026-04-05. La evolución posterior incorpora tres módulos castellanos adicionales (M7, M9, M10) más un módulo de recuperación sobre DermapixelAI 1.0 (M4-bis) y un ensemble ponderado (M11), descritos en la sección H.8. El prototipo no constituye objeto experimental del estudio principal del documento (sección 1.5), pero materializa la integración técnica entre los modelos evaluados en el capítulo 4 y un sistema operativo accesible desde navegador.

H.1 Motivación arquitectónica

La traslación de los hallazgos cuantitativos del benchmark a un entorno operativo plantea requisitos no satisfechos por las herramientas estándar de evaluación (notebooks de investigación, scripts CLI). Cuatro requisitos vertebran el diseño del prototipo: (i) separación física entre el equipo cliente (PC del clínico, sin GPU) y el servidor de inferencia (DGX Spark, con GPU); (ii) comunicación asíncrona entre ambos para evitar bloqueos en la interfaz durante inferencias de varios segundos; (iii) persistencia estructurada de imagen original, máscara, conceptos, casos similares, razonamiento textual y validación posterior por dermatólogo; y (iv) interfaz web multilingüe (catalán, español, inglés) compatible con flujos de teledermatología.

La arquitectura resultante (sección H.2) implementa una separación cliente-servidor con bus de mensajería intermedio sobre AMQP. El cliente expone una API REST sobre FastAPI que encapsula la lógica de persistencia y la sincronización asíncrona; el servidor de inferencia opera sobre la DGX Spark con todos los modelos cargados en VRAM unificada y consume mensajes del bus.

H.2 Arquitectura

H.2.1 Topología cliente-servidor

El sistema se distribuye en dos nodos físicos sobre una red local (LAN). El primer nodo, equipo Windows del usuario clínico (IP 192,168,1,37), aloja la API REST, la base de datos, el proxy inverso y la interfaz web. El segundo nodo, NVIDIA DGX Spark con chip Grace Hopper GB10 (IP 192,168,1,36), aloja el servidor de inferencia con los seis modelos cargados, el servidor del modelo de lenguaje multimodal de gran tamaño y los modelos de razonamiento auxiliares servidos vía Ollama. La comunicación entre ambos nodos se realiza exclusivamente vía AMQP sobre RabbitMQ, sin tráfico HTTP directo, lo que aísla operativamente el servidor de inferencia tras el firewall del proveedor de cómputo.

H.2.2 Componentes del backend

El backend (FastAPI 0,115 asíncrono) se despliega como contenedores Docker Compose con cinco servicios. La tabla H.1 sintetiza puertos y responsabilidades.

Cuadro H.1: Servicios del backend DermApIxel.

Servicio	Imagen	Puerto host	Función
derm-svc	FastAPI 0,115 + Uvicorn	9030	API REST principal
derm-mysql	MySQL 8,0	(interno)	Persistencia estructurada
derm-rabbitmq	RabbitMQ 3,13	5673/15675	Bus AMQP y panel de gestión
derm-nginx	Nginx 1,25	8091	Proxy inverso y archivos estáticos
result-consumer	Python asyncio	—	Worker asíncrono que recibe resultados

H.2.3 Persistencia: esquema de base de datos

La base de datos contiene once tablas relacionales que documentan cada estudio dermatológico, sus resultados parciales por módulo y las validaciones posteriores. La tabla raíz `derm_studies` contiene el identificador único, el estado del estudio (`pending`, `processing`, `done`, `error`), los *timings* por etapa y la imagen original almacenada como `LONGBLOB`. Las diez tablas restantes contienen los resultados de cada módulo y se enlazan a `derm_studies` mediante clave foránea con borrado en cascada. La separación por tabla, en lugar de un único documento JSON, facilita las consultas analíticas posteriores (estadísticas por clase, validación selectiva, exportación a CSV para reentrenamiento) y mantiene la integridad referencial bajo cargas concurrentes.

H.2.4 Bus de mensajería AMQP

La comunicación entre backend e inferencia se realiza mediante dos colas RabbitMQ con semántica distinta. La cola `derm.inference` es *work queue*: el backend publica una tarea por estudio (imagen + identificador único) y el servidor de inferencia la consume con confirmación explícita (*manual ack*) tras producir el resultado. La cola `derm.results` es *publish-subscribe* (configurada como *topic exchange*): el servidor de inferencia publica un mensaje por estudio completado, y el worker `result-consumer` del backend lo consume para actualizar la base de datos y notificar al frontend. El módulo M6 (clasificación zero-shot) utiliza una tercera vía RPC sobre AMQP para

invocaciones síncronas de baja latencia (~ 20 ms), apropiada para consultas interactivas del clínico.

La elección de AMQP sobre HTTP directo aporta tres ventajas operativas: tolerancia a fallos del servidor de inferencia (los mensajes quedan en cola), desacoplamiento temporal entre cliente y servidor (no se requiere conexión persistente), y trazabilidad auditable de cada mensaje a través del panel de gestión de RabbitMQ.

H.3 Módulos de inteligencia artificial

El servidor de inferencia tiene seis módulos cargados simultáneamente sobre la VRAM unificada de la DGX Spark. La tabla H.2 sintetiza su correspondencia con los modelos evaluados en el capítulo 4.

Cuadro H.2: Módulos del prototipo DermApIxel.

Módulo	Modelo subyacente	Latencia	Función
M1	PanDerm Large FT (HAM10000, TTA)	~ 315 ms	Clasificación cerrada 7 clases
M2	SAM2.1-Large + LoRA (ISIC2018)	—	Segmentación binaria de lesión
M3	SAE 1024 $\rightarrow$ 16384 + SkinCon	—	32 conceptos clínicos por imagen
M4	FAISS sobre Derm1M (421 327 vec.)	~ 150 ms	Recuperación visual densa <i>top-5</i>
M5	MedGemma 27B / GPT-4o / GPT-5 (9 prov.)	6–300 s	Razonamiento clínico estructurado
M6	DermLIP v2 (PubMedBERT)	~ 20 ms	Clasificación abierta zero-shot

El módulo M7 (clasificador unificado L1/L2/L3 sobre el dataset armonizado de 43 clases L3 y M8 (SigLIP-Large SO400M con sondeo lineal sobre HAM10000) están integrados en el pipeline de evaluación pero no se exponen como pestañas independientes de la interfaz clínica.

H.3.1 M1 – Clasificador cerrado

M1 es PanDerm Large *fine-tuned* sobre HAM10000 con la receta descrita en sección 3.6.2. La inferencia emplea *test-time augmentation* con cinco aumentaciones deterministas, lo que incrementa la latencia respecto a la inferencia simple (*recall* de melanoma sobre HAM10000: +4,3 pp con TTA, según se documenta en la sección 4.10). La salida es un vector de siete probabilidades softmax sobre las clases HAM10000, persistido en la tabla `derm_classifications`.

H.3.2 M2 – Segmentación binaria

M2 es SAM2.1-Large adaptado mediante LoRA conforme a la configuración descrita en sección 3.6.4. La inferencia recibe la imagen y, en el modo interactivo, un *prompt* espacial (punto o caja delimitadora). La salida es una máscara binaria almacenada como `LONGBLOB` en la tabla `derm_segmentations`, junto con métricas derivadas (asimetría, área estimada en píxeles, perímetro). La interfaz superpone la máscara sobre la imagen original como overlay semitransparente.

H.3.3 M3 – Conceptos clínicos

M3 es el módulo de interpretabilidad conceptual basado en Sparse Autoencoders. El procedimiento es el siguiente: la imagen se codifica mediante PanDerm Large, el

embedding de 1024 dimensiones se proyecta al espacio disperso de 16384 *features* mediante el SAE entrenado sobre 50454 imágenes de siete datasets (sección 5.1.7 para más detalle), y las activaciones se mapean a los 32 conceptos clínicos de SkinCon [15] mediante regresión logística por concepto. La salida es un vector de 32 activaciones interpretables (*pedunculado*, *ulcerado*, *eritematoso*, *escamoso*, etc.) que se muestra al clínico como apoyo visual al diagnóstico.

H.3.4 M4 – Recuperación visual densa

M4 indexa los 421327 *embeddings* DermLIP de las imágenes de Derm1M mediante FAISS [26] con índice HNSW (*Hierarchical Navigable Small Worlds*). La consulta produce las cinco imágenes más similares en el espacio de *embeddings*, junto con su diagnóstico asignado y la distancia coseno. La latencia media es de ~ 150 milisegundos por consulta sobre el equipo descrito en sección 3.5. La salida se persiste en `derm_similar_cases` y se presenta como galería navegable de casos comparables.

La distinción operativa entre M4 y un sistema RAG completo es relevante: M4 devuelve los casos análogos como referencia para inspección humana, sin alimentar un modelo generativo posterior con esos casos como contexto. La integración del retrieval con generación se materializa parcialmente en M5 (sección H.3.5), donde los hallazgos de M1–M4 se inyectan como contexto del prompt clínico.

H.3.5 M5 – Razonamiento clínico estructurado

M5 genera una explicación textual en español que integra los hallazgos de M1–M4 (y opcionalmente M6) en un razonamiento clínico estructurado. La arquitectura soporta nueve proveedores intercambiables mediante el parámetro `provider` del endpoint correspondiente, cuyo perfil de coste y latencia se sintetiza en la tabla H.3.

Cuadro H.3: Proveedores LLM soportados por M5. Latencias medidas sobre prompt clínico real (~ 1500 tokens entrada, ~ 500 tokens salida).

provider	Modelo	Latencia	Coste/llamada	Infraestructura
<code>gpt-4o-mini</code>	GPT-4o-mini	~ 6 s	~\$0,001	API OpenAI
<code>gpt-4o</code>	GPT-4o	~ 10 s	~\$0,01	API OpenAI
<code>gpt-5-mini</code>	GPT-5 mini	~ 15 s	~\$0,001	API OpenAI
<code>gpt-5-nano</code>	GPT-5 nano	~ 25 s	~\$0,0003	API OpenAI
<code>gpt-5</code>	GPT-5	~ 30 s	~\$0,01	API OpenAI
<code>medgemma-4b</code>	MedGemma 4B Vision	~ 40 s	0 EUR (local)	Ollama, ~ 4 GB VRAM
<code>medgemma-vision</code>	MedGemma 27B Vision (BF16)	3–5 min	0 EUR (local)	DGX Spark, 54,9 GB VRAM

El `provider` por defecto para la interfaz interactiva es `gpt-4o-mini` por su compromiso latencia-calidad. Los proveedores locales (`medgemma-4b` y `medgemma-vision`) se reservan para escenarios de cumplimiento estricto sobre datos sanitarios donde la exfiltración hacia APIs externas no es aceptable. La latencia de los proveedores locales es superior a la de los proveedores comerciales pese al tamaño nominalmente reducido, comportamiento documentado en sección 5.1.6 y atribuible a la diferencia de optimización entre infraestructuras dedicadas y hardware genérico.

Los nueve proveedores comparten el mismo *system prompt* de ≥ 300 palabras estructurado en cinco secciones obligatorias (morfología, dermatoscopia, criterios ABCDE con valores concretos por letra, integración con resultados de M1–M4, juicio

clínico), y el mismo contexto enriquecido generado por la función `_build_context()` que inyecta las cifras del pipeline al *prompt*. La salida es un JSON con tres campos: *reasoning* (texto estructurado), *differential_diagnosis* (tres a cinco objetos con diagnóstico, nivel de confianza y justificación) y *recommendation* (urgencia, acción concreta, signos de alarma).

H.3.6 M6 – Clasificación zero-shot abierta

M6 implementa la clasificación zero-shot multimodal descrita en sección 3.6.5 usando DermLIP v2 (ViT-B/16 + PubMedBERT) con los *prompts* A3 derivados de Derm1M. A diferencia de M1 (clasificador cerrado sobre siete clases HAM10000), M6 acepta una lista arbitraria de descripciones textuales y devuelve la similitud coseno softmax sobre cada una. La latencia es de ~ 20 milisegundos en *warm* sobre los embeddings precomputados.

El módulo expone cuatro *presets* clínicos predefinidos (tabla H.4) que cubren el espectro habitual de las consultas dermatológicas, con un total de 31 clases únicas. La opción por defecto en la interfaz es el preset más amplio (*all_dermatology*), elegido para mitigar el sesgo de selección documentado en la literatura sobre CLIP cuando se restringe artificialmente el espacio de clases.

Cuadro H.4: Presets clínicos del módulo M6.

preset	Clases	Uso clínico
<i>all_dermatology</i>	31	Default: el clínico no precategoriza
<i>common_dermatoses</i>	8	Dirigido a sospecha de patología inflamatoria
<i>infections</i>	9	Dirigido a sospecha de infección
<i>tumors_extended</i>	14	Dirigido a sospecha de tumor o lesión pigmentada

Un hallazgo operativo documentado durante el despliegue (sección 5.1.5) es la sensibilidad extrema de DermLIP v2 a la formulación del *prompt*: el uso de etiquetas desnudas (e.g. ["melanoma", "nevus", "eczema"]) produce predicciones efectivamente aleatorias, mientras que el envoltorio clínico estandarizado (e.g. "*dermoscopy image of melanoma, malignant skin cancer with irregular borders and asymmetry*") lo restaura al rendimiento esperado. La curva de degradación observada sobre HAM10000 sitúa el punto óptimo en 8–15 palabras por *prompt* con un rasgo clínico añadido (AUROC 0,854); fuera de este rango el rendimiento decae. El prototipo implementa *wrapping* automático en tres capas: presets predefinidos con descripciones ya envueltas, composable `useZeroShot.js` que aplica la plantilla "*dermoscopy image of {term}*" cuando la entrada del usuario contiene cinco o menos palabras, y conmutador en la interfaz que permite al dermatólogo desactivar el envoltorio cuando escribe descripciones completas propias.

H.4 Frontend e interfaz clínica

El frontend está implementado en Vue 3,5 con Tailwind CSS 4,2 y Vite 7, en tres idiomas (catalán, español, inglés) y con tema claro/oscuro conmutable. La vista principal `AnalyzeView` expone los resultados del pipeline en seis pestañas: CLASS (clasificación cerrada M1), SEG (segmentación M2 con overlay), CONC (conceptos M3), RAG (casos

similares M4), REASON (razonamiento M5) y Z-SHOT (clasificación abierta M6). Vistas complementarias (HistoryView, ValidationView, StatsView) cubren la consulta del histórico paginado, la validación posterior por el dermatólogo y las estadísticas agregadas del sistema.

La interacción con el visor de lesiones (LesionViewer) permite zoom real sobre la imagen, superposición de la máscara con opacidad ajustable, y deslizador de umbral dinámico que recalcula la predicción de M1 sobre la marcha sin nuevas inferencias en el servidor. El módulo ValidationPanel expone tres opciones de validación (*correcto*, *parcial*, *incorrecto*) y permite el dibujo manual de *bounding boxes* alternativas como mecanismo de corrección, con persistencia en la tabla `derm_manual_annotations` para realimentar el reentrenamiento posterior.

H.5 Rendimiento operativo

La tabla H.5 sintetiza los tiempos medios medidos sobre el sistema desplegado.

Cuadro H.5: Rendimiento operativo del prototipo DermApIxel (medidas del 2026-04-05).

Métrica	Valor	Notas
Pipeline M1–M4 <i>end-to-end</i>	~ 315 ms (warm)	Tras carga inicial
Pipeline M1–M4 <i>cold</i>	~ 450 ms	Primera inferencia tras reinicio
M6 Zero-shot (3 clases) <i>warm</i>	~ 20 ms server	~ 25 ms incluyendo red
M6 Zero-shot (3 clases) <i>cold</i>	~ 25,5 ms	~ 46,9 ms incluyendo red
M6 <i>warmup</i> kernel PubMedBERT (7 clases)	614 ms	Una vez tras reinicio
VRAM total app M1–M4 + M6	4,40 GB	Sin cuantización ni <i>offloading</i>
VRAM MedGemma 27B Vision	54,9 GB	Coexiste con app principal
VRAM total ocupada	~ 59 GB	Sobre 128 GB disponibles
Speedup M6 frente a M1–M4	~ 30×	Por arquitectura ligera y <i>embeddings</i> cacheados

La latencia agregada de un análisis completo (M1–M4 + M5 con `gpt-4o-mini`) sobre una imagen de prueba es del orden de 6–8 segundos, dominada por el componente generativo del razonamiento clínico. La latencia percibida por el usuario es inferior gracias al patrón asíncrono: los resultados de M1–M4 aparecen en la interfaz antes que el razonamiento de M5, lo que permite al clínico revisar el diagnóstico cerrado mientras el LLM produce la justificación textual.

H.6 Estado de despliegue

A fecha de cierre del documento, el sistema se encuentra en producción *end-to-end* sobre el entorno de desarrollo (Windows local + DGX Spark sobre red LAN), con seis módulos operativos (M1–M6) y validación funcional sobre casos de prueba controlados. El sistema no se ha desplegado sobre la infraestructura sanitaria del HUSLL y no ha sido validado sobre cohorte prospectiva real, lo que se identifica como línea de continuación inmediata en sección 7.5.6. Los elementos identificados como condiciones operativas para el despliegue hospitalario son: integración con el sistema PACS mediante DICOM C-STORE, autenticación con Keycloak OIDC, HTTPS con certificado institucional, servicio `systemd` para arranque automático del servidor de inferencia, y trazabilidad auditable conforme al Esquema Nacional de Seguridad (ENS) con logs

encadenados con SHA-256. Ninguno de estos elementos forma parte del alcance del Trabajo de Fin de Grado declarado en sección 1.5.

H.7 Discusión: rol del prototipo en el trabajo

La construcción del prototipo no constituye objeto experimental del trabajo. Las cifras de rendimiento sobre las que descansa la defensa empírica del documento se obtienen directamente de los modelos descritos en el capítulo 3 mediante protocolos estándar (sección 3.6). El prototipo materializa la integración técnica entre esos modelos, valida la viabilidad operativa de su despliegue conjunto sobre hardware accesible, y constituye el entorno previsto para la validación clínica prospectiva descrita en sección 7.5.6.

Tres aportaciones técnicas merecen mención específica. Primero, la verificación de que seis modelos heterogéneos (PanDerm Large FT, SAM2.1-Large+LoRA, SAE, FAISS sobre Derm1M, DermLIP v2, MedGemma 27B) coexisten en la VRAM unificada de la DGX Spark con consumo agregado de ~ 59 GB sobre los 128 GB disponibles, sin cuantización ni *offloading*. Segundo, la cuantificación del coste operativo por proveedor LLM en M5, que sostiene la afirmación de sección 5.1.6 sobre la brecha entre encoders específicos y LLMs multimodales generalistas en términos económicos además de en términos de rendimiento. Tercero, la documentación operativa del hallazgo sobre sensibilidad al *prompt* en DermLIP v2 (sección 5.1.5), cuya mitigación mediante *wrapping* automático en tres capas (presets, composable, conmutador UI) constituye una práctica de ingeniería transferible a otros despliegues de modelos vision-lenguaje contrastivos en producción clínica.

El despliegue hospitalario completo, la validación prospectiva sobre cohorte real y la certificación CE como producto sanitario quedan fuera del alcance declarado y se identifican como líneas de continuación inmediatas en la sección 7.5 del capítulo 7.

H.8 Evolución a M1–M11: módulos castellanos del prototipo

En los meses posteriores a la integración M1–M6 (estado documentado en las secciones previas con fecha de cierre 2026-04-05), el prototipo incorporó tres módulos castellanos adicionales (M9, M10, M4-bis) más un ensemble ponderado (M11) sobre la ontología jerárquica de la Dra. R. Taberner descrita en el Anexo C. La motivación se alinea con la limitación operativa identificada en sección H.7: el clasificador cerrado M1 sobre HAM10000 no cubre la *fingerprint* clínica del archivo de la Dra. R. Taberner, basada en un vocabulario de 4 categorías L1, 43 subcategorías L2 y 367 subcategorías L3, mayoritariamente disjunto del de HAM10000. Los nombres M1b, M7, M9, M10, M4-bis y M11 se conservan tal como aparecen en `pipeline.py` para preservar la trazabilidad código-documento.

H.8.1 M7 – Clasificador unificado jerárquico *merged43+TTA*

M7 es PanDerm Large *fine-tuned* sobre las 43 clases L3 de la ontología unificada multi-dataset, entrenado con *weighted sampling* sobre los siete datasets viables del *mapping* ontológico. La inferencia aplica *Test-Time Augmentation* (TTA) con cinco augmentaciones (original, simetría horizontal, simetría vertical, rotación 90° y rotación 270°)

promediando probabilidades *softmax*, no logits, por estabilidad numérica. La salida se proyecta jerárquicamente a L1 y L2 garantizando consistencia top-down. Sobre el conjunto de test fijo de DermapixelAI 1.0 alcanza L1 *accuracy* 0,947, L2 *accuracy* 0,819, L3 *accuracy* 0,797 y BAcc L3 0,818 (+4,72 pp BAcc con TTA respecto a la inferencia simple). La latencia *warm* es de ~ 80 ms. Tab UNIF del frontend, con vista jerárquica L1/L2/L3 y *badge* melanoma.

H.8.2 M9 – SpanDerm v0, clasificador L2 castellano supervisado

M9 es la implementación operativa del protocolo SpanDerm v0 descrito en sección 4.14. Cabeza *fully-connected* 1024 → 38 sobre PanDerm Large con LoRA $r = 16$ insertado en los dos últimos bloques transformer (*attn.qkv*, *attn.proj*, *mlp.fc1*, *mlp.fc2*), entrenada sobre las 874 imágenes *train* del manifiesto filtrado de DermapixelAI 1.0 (1062 imágenes; Anexo C). Las 38 clases L2 efectivas resultan de consolidar las dos variantes ortográficas L2 *queratinización* detectadas en el análisis exploratorio del corpus. El *checkpoint slim* conserva únicamente los pesos LoRA y la cabeza FC (~ 2,3 MB); el encoder PanDerm Large permanece congelado y se reutiliza del módulo M1. La inferencia aplica TTA con cinco aumentaciones y latencia ~ 91 ms. Tab SPAN del frontend. La diferencia respecto al sistema SpanDerm-CLIP descrito en sección 4.17 es operacional: aquí la cabeza es supervisada con clases L2 fijas; allí es *zero-shot open-class* por alineamiento texto-imagen.

H.8.3 M10 – Seven-Point Checklist multitarea

M10 implementa el protocolo multitarea de sección 4.15 sobre el corpus Derm7pt [9]: MultitaskDerm7 con siete cabezas conceptuales (una por criterio dermatoscópico del *Seven-Point Checklist*: *pigment network*, *streaks*, *pigmentation*, *regression structures*, *dots and globules*, *blue whitish veil*, *vascular structures*) más una cabeza binaria melanoma/no-melanoma, montadas sobre el mismo encoder PanDerm Large + LoRA $r = 16$. La inferencia aplica TTA promediando *softmax* de las ocho cabezas y latencia ~ 90 ms. Tab 7-P0I del frontend, con los siete criterios traducidos al castellano y el riesgo melanoma global. El módulo explota explícitamente las anotaciones conceptuales por imagen de Derm7pt, no aprovechadas en M1–M6 ni en otros experimentos del trabajo.

H.8.4 M4-bis – RAG castellano sobre DermapixelAI 1.0

M4-bis es un índice FAISS [26] IndexFlatIP sobre 874 *embeddings* PanDerm Large de 1024 dimensiones L2-normalizados, correspondientes al *split train+val* de DermapixelAI 1.0 (Anexo C). Para una imagen de consulta el módulo devuelve los k vecinos más similares por coseno con sus metadatos clínicos castellanos (*ontology_11*, *ontology_12*, *ontology_13*, *case_id*, *case_title*, *case_text_preview*, *rosa_verified*, *year*) y el voto mayoritario por nivel jerárquico. M4-bis complementa al módulo M4 (sección H.3.4) sobre Derm1M en inglés: donde M4 recupera patrones visuales sobre un atlas masivo no etiquetado en castellano, M4-bis devuelve casos del propio archivo de la Dra. R. Taberner con su clasificación L1/L2/L3 verificada y el extracto del texto clínico original. La latencia *warm* es de ~ 0,5 ms (FAISS sobre 874 vectores). Tab RAG-I del frontend con barras de similitud y voto mayoritario por nivel.

H.8.5 M11 – Ensemble ponderado por AUROC y coherencia jerárquica

M11 es la combinación ponderada (*weighted*) de M1, M7, M9 y M4-bis por niveles L1/L2/L3. Los pesos se derivaron en dos pasos: en primer lugar, lectura directa de las AUROC reportadas en el capítulo 4 (M7 *merged43*+TTA es el clasificador más fiable global, con AUROC L1 = 0,873, L2 = 0,860, L3 = 0,813); en segundo lugar, ajuste empírico por coherencia jerárquica top-down sobre casos clínicos representativos. La iteración estable es la versión v1.7, cuyos pesos se reportan en la tabla H.6.

Cuadro H.6: Pesos del ensemble M11 v1.7 por nivel jerárquico. La entrada (*no aplica*) indica que el módulo correspondiente no emite predicción al nivel ontológico de la fila.

Nivel	M1 (HAM FT)	M7 (<i>merged43</i> +TTA)	M9 (SpanDerm v0)	M4-bis (RAG ES)
L1	1,0	1,0	0,5	0,3
L2	(<i>no aplica</i>)	1,5	1,0	0,5
L3	(<i>no aplica</i>)	1,5	(<i>no aplica</i>)	0,5

El *mapping* castellano-inglés exhaustivo (4 L1 + 26 L2 + 33 L3) colapsa las duplicaciones que aparecen cuando M7 emite la ontología en inglés (*merged43*) mientras que M9 y M4-bis lo hacen en castellano. Sin este *mapping*, el ensemble contaría dos veces la misma clase con cadenas distintas. La coherencia jerárquica queda garantizada: para una imagen donde L1 indica *Patología tumoral* con probabilidad elevada y L3 indica *Melanoma* con probabilidad relevante, L2 debe indicar *Tumores malignos* y no *Neoplasias melanocíticas benignas* (este último era el comportamiento del ensemble cuando los pesos eran M7 = 1,0 y M9 = 1,5 en L2, antes del ajuste v1.7). M11 se expone en el tab M11 del frontend como vista de consenso, posicionada en primer lugar.

H.8.6 Sistema de consenso de cinco módulos y *warning* de derivación urgente

El frontend incorpora un *banner* superior con cinco *chips* que resumen la lectura de malignidad de cinco módulos independientes (M1, M7, M9, SigLIP-LP y M10) más un sexto *chip* M4-bis con la ontología del vecino *top-1* castellano. Cada *chip* muestra una etiqueta BEN / MAL / ? y un *badge* global *Consenso parcial* (X/5) o *Consenso fuerte*. Cuando ≥ 2 módulos votan melanoma con probabilidad alta, el sistema emite un *warning* explícito (“X clasificadores detectan melanoma – derivación urgente – derivar a especialista”). El diseño replica el patrón clínico de segunda opinión entre dermatólogos: no se confía en un único clasificador, se busca convergencia entre criterios independientes (cabeza supervisada HAM, cabeza supervisada L3 multidataset, cabeza supervisada L2 castellana, sondeo lineal SigLIP, multitarea Derm7pt). Un *caveat* metodológico explícito acompaña la formulación: el voto actual es por mayoría sin ponderación clínica, lo que no captura el caso en el que un módulo emite una señal dominante (*p. ej.* M10 con probabilidad 0,95 de melanoma) frente a otros con confianza baja. Una iteración futura debería ponderar por confianza per-módulo o exponer un *score* de melanoma agregado calibrado con datos prospectivos.

H.8.7 Migración a AMQP (2026-04-13)

Desde el 13 de abril de 2026 toda comunicación entre el backend Docker (PC Windows) y el servidor de inferencia (DGX Spark) circula por RabbitMQ (cola `derm.inference` para *requests*, `derm.results` para *replies*). Anteriormente coexistían HTTP directo y AMQP; tras la migración, HTTP queda reservado a `/health` y depuración. La configuración mantiene abierto el puerto 5673 en dirección backend → Spark. Los beneficios operativos son tres: resiliencia (los mensajes persisten ante caída transitoria del servidor de inferencia con reintento automático), trazabilidad auditable de cada *request* a través del panel de gestión de RabbitMQ, y desacoplamiento temporal entre frontend y GPU. La lección operacional documentada es que tras cualquier cambio del backend Docker es obligatorio reconstruir sin caché (`docker compose build --no-cache && docker compose up -d`) para que los nuevos *consumers* AMQP se registren correctamente.

H.8.8 Evaluación end-to-end del prototipo extendido

Para validar el comportamiento integrado de los módulos M1–M11 se ejecutó un *batch test* sobre 454 imágenes del conjunto de test de HAM10000 no vistas previamente por el prototipo. Los hallazgos cuantitativos justifican operacionalmente los pesos del ensemble M11 v1.7 y la presencia de SigLIP-LP como red de seguridad. M7 supera a M1 sobre HAM10000 con BAcc 0,886 frente a BAcc 0,743, lo que justifica el peso $M7 = 1,5$ en L2/L3 del ensemble a pesar de que M1 está *fine-tuned* específicamente sobre HAM. El *recall* de melanoma por módulo es de 40 % para M1, 60 % para M7 y 80 % para el OR *top-3* entre M1, M7 y SigLIP-LP, lo que justifica directamente el patrón de consenso de cinco módulos como red de seguridad clínica. El primer nivel jerárquico (Tumoral / Inflamatoria / Infecciosa / Genodermatosis) alcanza *accuracy* en el intervalo [0,80, 1,00] sobre las cuatro categorías, mientras que los errores *fine-grained* se concentran en L2 y L3, comportamiento coherente con la naturaleza progresivamente más específica de la jerarquía ontológica. TTA añade +74 ms de latencia por imagen y +4,72 pp de BAcc L3, compromiso latencia-rendimiento replicado además en M9 y M10. La evidencia operacional cierra el ciclo entre las métricas del capítulo 4 y el comportamiento del sistema integrado: los módulos castellanos M7–M11 mejoran las métricas críticas (*recall* de melanoma, BAcc sobre L2/L3) en el escenario clínico final sin sustituir a M1–M6.



ABLACIÓN: MODELO FUNDACIONAL INGLÉS (DERMLIP) CON TRADUCCIÓN ES-EN

Este anexo documenta una ablación independiente que cuantifica el *trade-off* entre el sistema SpanDerm-CLIP defendido en la sección 4.17 y un *wrapper* alternativo basado en un modelo fundacional dermatológico inglés (DermLIP v2) con traducción de etiquetas ES-EN, sobre el mismo conjunto de test *holdout* de DermapixelAI 1.0.

I.1 Motivación

Una pregunta legítima planteada durante la revisión paper-grade del sistema SpanDerm-CLIP es si el esfuerzo experimental documentado en la sección 4.17 (cinco iteraciones de entrenamiento cross-modal castellà) se justifica frente a una alternativa pragmática: emplear un modelo fundacional dermatológico inglés ya alineado imagen-texto, sin entrenar ningún modelo adicional, sobre las etiquetas castellanas traducidas al inglés. Esta ablación cuantifica el *trade-off* entre ambas estrategias sobre el mismo conjunto de test *holdout* de DermapixelAI 1.0.

I.2 Protocolo experimental

El modelo fundacional inglés evaluado es DermLIP v2 (PanDerm-base-w-PubMed-256), un sistema CLIP-style con codificador visual PanDerm-Base y codificador textual PubMedBERT, preentrenado contrastivamente sobre el corpus Derm1M [2] ($\approx 403\,000$ pares imagen-texto). Ambas torres permanecen congeladas; no se entrena ningún parámetro. Las 54 clases L3 representadas en el test se tradujeron al inglés clínico mediante un glosario estándar (Bologna/Rook) con verificación cruzada de unicidad, y por cada clase se generó un *rich prompt* clínico en inglés (~ 37 palabras, longitud equiparable a los *prompts* castellanos de SpanDerm-CLIP). La inferencia replica el protocolo híbrido

de la sección 4.17 (prototipos visuales sobre *train* más texto rico, régimen *H6* $w_v = 0,3$, $w_t = 0,7$) sobre las mismas 101 imágenes de test y 54 clases.

Adicionalmente, se midió el *eje idioma puro* sobre el propio *checkpoint* SpanDerm-CLIP v4: el mismo modelo evaluado con los *prompts* castellanos originales frente a los mismos *prompts* traducidos al inglés, aislando el efecto del idioma de consulta sobre una alineación cross-modal fija.

I.3 Resultados

La tabla I.1 reúne las seis configuraciones evaluadas sobre el mismo conjunto de test.

Cuadro I.1: Comparativa cuantitativa SpanDerm-CLIP v4 (*headline*) frente a la ablación con modelo fundacional inglés DermLIP v2 más traducción ES–EN. Test *holdout* DermapixelAI 1.0, $N = 101$, 54 clases L3 representadas; régimen *H6 hybrid v30_r70* salvo donde se indica.

Sistema	Régimen	acc@1 L3	BAcc L3	acc@5 L3
SpanDerm-CLIP v4	H6 hybrid (castellà)	0,2475	0,2685	0,4455
SpanDerm-CLIP v5	H6 hybrid (castellà)	0,2079	0,2185	0,4158
SpanDerm-CLIP v4	H6 hybrid (inglés)	0,2277	0,2556	0,4554
DermLIP v2	H6 hybrid (inglés)	0,2871	0,3667	0,6436
DermLIP v2	templates+rich (inglés)	0,3861	0,4099	0,6931
DermLIP v2	visual-only	0,2178	0,2278	0,4851

I.4 Interpretación

DermLIP v2 inglés supera a SpanDerm-CLIP v4 en el régimen comparable *H6* (0,2871 frente a 0,2475, +3,96 pp) y lo supera con mayor margen en su mejor régimen de plantillas más texto rico (0,3861, +13,86 pp), confirmando la hipótesis de partida de que el cuello de botella de SpanDerm-CLIP residía en la *escala* de la alineación cross-modal y no en la formulación textual. Un modelo fundacional preentrenado sobre $\approx 403\,000$ pares supera a un CLIP castellà dedicado entrenado sobre 854 pares, incluso pagando el ruido de la traducción de etiquetas.

El eje idioma matiza esta lectura: sobre el mismo *checkpoint* v4, la consulta en castellà supera a la consulta en inglés (0,2475 frente a 0,2277 en *H6*, +1,98 pp; y 0,1287 frente a 0,0891 en *rich-only*, +3,96 pp), mientras que el régimen visual-only permanece idéntico (0,1683). SpanDerm-CLIP sí captura un componente específico del registro clínico castellà, si bien de segundo orden frente a la ventaja de escala del modelo fundacional inglés.

El *trade-off* entre los dos enfoques es, por tanto, explícito:

- **DermLIP inglés más traducción:** rendimiento bruto superior, cero entrenamiento, pero dependencia de traducción de etiquetas y de un corpus de preentrenamiento externo (Derm1M [2]), con la consiguiente pérdida potencial de matices clínicos castellanos no traducibles uno a uno.
- **SpanDerm-CLIP:** entrenamiento dedicado sobre 854 pares reales castellanos, preservación de la *fingerprint* clínica del archivo de la Dra. R. Taberner, inferen-

cia sin traducción en *runtime* y operación *on-prem* compatible con la ruta de extensión al banco hospitalario HUSLL (sección 7.5.4).

La conclusión es que SpanDerm-CLIP no se justifica como sistema de mayor rendimiento bruto en *zero-shot* L3, sino por sus propiedades operativas de privacidad, especificidad lingüística y autonomía de despliegue. La superioridad de DermLIP re-fuerza, además, el diseño de la línea de continuación documentada en la sección 7.5.4: la palanca pendiente para SpanDerm-CLIP es la anotación experta dirigida *in-domain* sobre las clases L3 con peor cobertura, no la escala genérica.

I.5 Limitaciones de la ablación

La comparación no está equiparada en datos: DermLIP v2 se preentrena sobre $\approx 403\,000$ pares frente a los 854 pares castellanos de SpanDerm-CLIP, y los *backbones* visuales difieren (PanDerm-Base contrastivo frente a PanDerm-Large congelado con LoRA). El resultado debe leerse como “modelo fundacional inglés grande más traducción” frente a “CLIP castellà dedicado pequeño”, no como un contraste de igual presupuesto de datos.

La carga de DermLIP v2 requiere el *fork* de `open_clip` del proyecto Derm1M: la implementación estándar instancia un *Vision Transformer* genérico e ignora silenciosamente la torre visual PanDerm-Base (152 claves ausentes, codificador visual aleatorio), un modo de fallo verificado y evitado en esta ablación empleando el mismo *loader* que el módulo de producción (Anexo H).

La verificación de solapamiento con Derm1M se realizó a nivel de fuente: las fuentes constituyentes de Derm1M (vídeo, foros, literatura biomédica y libros de texto en inglés y chino) no incluyen ningún blog dermatológico español, y no se hallaron coincidencias para *dermapixel* ni *taberner* en las 417 257 filas del *manifest*. El archivo Dermapixel es privado y no figura como fuente, lo que sustenta razonablemente la asunción de ausencia de *leakage*; no se ejecutó una comparación perceptual exhaustiva imagen a imagen. La traducción ES-EN introduce, finalmente, un ruido no cuantificado en las etiquetas.

