



Universitat
de les Illes Balears

TRABAJO DE FIN DE GRADO

EVALUACIÓN DE MODELOS FUNDACIONALES PARA DERMATOLOGÍA CLÍNICA

Antonio Contestí Coll

Grau d'Enginyeria Informàtica

Escola Politècnica Superior

Año académico 2025–2026

EVALUACIÓN DE MODELOS FUNDACIONALES PARA DERMATOLOGÍA CLÍNICA

Antonio Contestí Coll

Trabajo de Fin de Grado

Escola Politècnica Superior

Universitat de les Illes Balears

Año académico 2025–2026

Paraules clau del treball: modelos fundacionales, dermatología clínica, PanDerm, DermLIP, evaluación empírica

Tutor: Dr. Javier Varona Gómez

ÍNDICE GENERAL

Índice general	i
Lista de acrónimos	iv
Resumen	v
Abstract	vii
1 Introducción	1
1.1 Contexto clínico	1
1.2 Análisis automatizado: paradigma clásico y limitaciones	2
1.3 Modelos fundacionales en imagen médica	2
1.4 Modelos fundacionales para dermatología	2
1.5 Brechas operativas y motivación	3
1.6 Marco operativo previo del autor	4
1.7 Pregunta de investigación	4
1.8 Objetivos del trabajo	5
1.9 Contribuciones	5
1.10 Restricciones del estudio	6
1.11 Estructura del documento	7
2 Estado del arte	9
2.1 Aprendizaje profundo aplicado a dermatología	9
2.2 Modelos fundacionales: arquitectura y objetivos	9
2.3 Encoders visuales auto-supervisados	10
2.4 Modelos vision-lenguaje contrastivos	10
2.5 Modelos integrados con zero-shot nativo	11
2.6 Segmentación promptable	11
2.7 Modelos de lenguaje multimodales generalistas	11
2.8 Problemas metodológicos y guías de reporte	12
2.9 Brechas operativas y posicionamiento	12
Bibliografía	13

LISTA DE ACRÓNIMOS

AdamW	Adaptive Moment Estimation with decoupled Weight decay
AJCC	American Joint Committee on Cancer
API	Application Programming Interface
AUROC	Area Under the Receiver Operating Characteristic Curve
BAcc	Balanced Accuracy
BCC	Carcinoma basocelular (<i>basal cell carcinoma</i>)
BCN	Barcelona
BF16	Brain Floating-Point de 16 bits
CAE	Convolutional AutoEncoder
CBM	Concept Bottleneck Model
CIE-10	Clasificación Internacional de Enfermedades, décima revisión
CLIP	Contrastive Language–Image Pre-training
DDI	Diverse Dermatology Images
DIADERM	Estudio observacional multicéntrico sobre demanda y prevalencia diagnóstica en dermatología en España
DSC	Dice Similarity Coefficient
EPS	Escola Politècnica Superior
FAISS	Facebook AI Similarity Search
FP	Fototipo (escala Fitzpatrick I–VI)
FT	Fine-tuning supervisado
GPU	Graphics Processing Unit
HAM	Human Against Machine
HIBA	Hospital Italiano de Buenos Aires
HNSW	Hierarchical Navigable Small Worlds
HUSLL	Hospital Universitario Son Llàtzer
IA	Inteligencia artificial
IB-Salut	Servicio de Salud de las Illes Balears
InfoNCE	Information Noise Contrastive Estimation
IoU	Intersection over Union (índice de Jaccard)
ISIC	International Skin Imaging Collaboration
L-BFGS	Limited-memory Broyden–Fletcher–Goldfarb–Shanno
LLM	Large Language Model (modelo de lenguaje de gran escala)
LoRA	Low-Rank Adaptation
LP	Linear Probing
MD5	Message Digest 5 (función de hash)
MSKCC	Memorial Sloan Kettering Cancer Center
PACS	Picture Archiving and Communication System
PAD-UFES	<i>Patient and Dataset of Skin Lesions, Universidade Federal do Espírito Santo</i>
RAG	Retrieval-Augmented Generation
SAE	Sparse Autoencoder
SAM	Segment Anything Model
SigLIP	Sigmoid Loss for Language Image Pre-training
SNOMED CT	Systematized Nomenclature of Medicine – Clinical Terms
SOTA	State of the Art (estado del arte)
TFG	Trabajo de Fin de Grado
TTA	Test-Time Augmentation
UIB	Universitat de les Illes Balears
ViT	Vision Transformer
VOA	Visual Question Answering

RESUMEN

Los modelos fundacionales aplicados a imagen dermatológica han proliferado en los últimos dos años, con tres referencias relevantes liberadas por el grupo de la Universidad Monash: PanDerm (encoder visual con pesos públicos), Derm1M y la familia DermLIP (modelos vision-lenguaje contrastivos) y DermFM-Zero (modelo vision-lenguaje con zero-shot nativo, sin pesos públicos en la fecha de cierre). La incorporación de estos modelos al flujo asistencial requiere caracterizar empíricamente su rendimiento sobre material clínico heterogéneo, su comportamiento frente a la heterogeneidad taxonómica entre datasets y su disparidad entre fototipos cutáneos.

Este trabajo evalúa catorce modelos fundacionales sobre doce datasets externos públicos armonizados a una ontología jerárquica L1/L2/L3 (cuatro categorías etiológicas, 43 subcategorías clínicas, 367 diagnósticos individuales) con códigos SNOMED CT y CIE-10. La evaluación abarca cuatro protocolos: sondeo lineal, ajuste fino supervisado, segmentación binaria con LoRA y clasificación zero-shot multimodal. La infraestructura experimental emplea una NVIDIA DGX Spark con chip Grace Hopper GB10, 128 GB de memoria unificada y precisión BF16.

Los resultados indican que PanDerm Large supera a PanDerm Base sobre los diez datasets externos contrastados en el sondeo lineal, con una mejora media de +4,1 pp en accuracy, +9,0 pp en BAcc y +3,6 pp en AUROC. El ajuste fino con la receta del paper original aumenta la BAcc en +47,1 pp sobre HAM10000 y +19,4 pp sobre PAD-UFES-20. El sondeo lineal satura con un volumen reducido de datos etiquetados (1 % del conjunto de entrenamiento de HAM10000 recupera 96,2 % del AUROC del modelo entrenado con el conjunto completo). La segmentación con SAM2.1-Large adaptado mediante LoRA alcanza Dice de test 0,894 sobre ISIC2018. La auditoría sistemática de solapamiento por hash MD5 identifica tres datasets (Dermnet, HIBA, MSKCC) con solapamiento documentado frente a Derm1M, condición que debe acompañar como *caveat* a cualquier cifra zero-shot reportada sobre ellos.

El trabajo aporta tres contribuciones reproducibles: el benchmark homogéneo, el dataset DermapixelAI 1.0 (1 089 imágenes verificadas, 672 casos clínicos con texto narrativo en español, licencia CC-BY-NC-SA 4.0) y la auditoría sistemática de solapamiento sobre los doce conjuntos de evaluación.

Palabras clave

modelos fundacionales, dermatología clínica, PanDerm, DermLIP, evaluación empírica, ontología, equidad, heterogeneidad taxonómica.

ABSTRACT

Foundation models for dermatological imaging have proliferated over the last two years, with three relevant references released by the Monash group: PanDerm (a vision encoder with public weights), Derm1M and the DermLIP family (contrastive vision-language models) and DermFM-Zero (a vision-language model with native zero-shot capability, weights not public at the time of writing). The integration of these models into clinical workflows requires the empirical characterisation of their performance on heterogeneous clinical material, their robustness against taxonomic heterogeneity across datasets, and their disparity across skin phototypes.

This work evaluates fourteen foundation models over twelve public external datasets, harmonised to a three-level hierarchical ontology (four aetiological families, 43 clinical subcategories, 367 individual diagnoses) with SNOMED CT and ICD-10 codes. The evaluation comprises four protocols: linear probing, supervised fine-tuning, binary lesion segmentation with LoRA and multimodal zero-shot classification. The experimental infrastructure is a NVIDIA DGX Spark with a Grace Hopper GB10 chip, 128 GB of unified memory and BF16 precision.

PanDerm Large outperforms PanDerm Base across the ten external datasets contrasted under linear probing, with mean improvements of +4,1 pp accuracy, +9,0 pp balanced accuracy and +3,6 pp AUROC. Supervised fine-tuning with the original paper recipe raises balanced accuracy by +47,1 pp on HAM10000 and +19,4 pp on PAD-UFES-20. Linear probing saturates with a small labelled budget (1 % of HAM10000 recovers 96,2 % of the full-data AUROC). LoRA-adapted SAM2.1-Large reaches Dice 0,894 on ISIC2018. The systematic MD5-based overlap audit identifies three datasets (Dermnet, HIBA, MSKCC) overlapping with Derm1M, a caveat that must accompany any zero-shot figure reported on them.

The work contributes three reproducible items: the homogeneous benchmark, the DermapixelAI 1.0 Spanish-language clinical dataset (1 089 verified images, 672 clinical cases with narrative text, CC-BY-NC-SA 4.0 licence) and the systematic overlap audit across the twelve evaluation sets.

Keywords

foundation models, clinical dermatology, PanDerm, DermLIP, empirical evaluation, ontology, fairness, taxonomic heterogeneity.

INTRODUCCIÓN

1.1 Contexto clínico

La dermatología clínica atiende un espectro amplio de entidades con distribución concentrada en un número reducido de motivos de consulta. El estudio observacional DIADERM, sobre 10 999 diagnósticos en 8 953 pacientes en territorio español, ordena los diez diagnósticos más prevalentes como queratosis actínica, carcinoma basocelular, nevus melanocítico, queratosis seborreica, otras neoplasias benignas, psoriasis, acné, verrugas víricas, otros trastornos de la pigmentación y otras dermatitis [5]. El trabajo local de Taberner et al. sobre el servicio dermatológico del Hospital Universitario Son Llàtzer (HUSLL) documenta 213 diagnósticos diferentes en un único año asistencial [4]. Ambos coinciden en un peso elevado de dermatosis benignas, inflamatorias e infecciosas habituales.

La sensibilidad temporal del proceso diagnóstico resulta crítica en el melanoma cutáneo. La supervivencia específica a cinco años desciende desde aproximadamente 99 % en estadio I hasta 25 % en estadio IV según la octava edición de la American Joint Committee on Cancer [20]. El acceso al especialista se realiza mediante derivación desde atención primaria. La capacidad asistencial del circuito presencial es limitada frente a una demanda creciente, lo que justifica el interés por sistemas de apoyo al diagnóstico basados en imagen.

El sustrato visual del diagnóstico dermatológico se articula en tres modalidades: fotografía clínica (presentación general y contexto anatómico), dermatoscopia (patrones pigmentarios y estructurales no visibles a simple vista) e histopatología (confirmación tisular). Sobre esta tríada operan los sistemas de apoyo basados en aprendizaje automático.

1.2 Análisis automatizado: paradigma clásico y limitaciones

El primer hito establecido del aprendizaje profundo en dermatología es el clasificador convolucional de Esteva et al. [29], con rendimiento equivalente al de dermatólogos certificados sobre un conjunto curado de lesiones. La aproximación clásica entrena arquitecturas convolucionales desde inicialización aleatoria o desde pesos preentrenados en ImageNet, ajustadas posteriormente sobre datasets dermatológicos etiquetados [30, 8]. La literatura posterior incorpora aumento de datos, balanceo de clases, ensembles y arquitecturas específicas para tareas concretas como segmentación binaria [10] o clasificación binaria melanoma/no-melanoma [9].

Tres limitaciones definen este paradigma. La primera es el coste de anotación: el rendimiento escala con el volumen de datos etiquetados y la anotación dermatológica requiere expertos clínicos con disponibilidad limitada. La segunda es la fragmentación entre conjuntos públicos: los datasets disponibles utilizan taxonomías heterogéneas, distintos protocolos de adquisición y diferentes esquemas de balance de clases, lo que limita comparaciones directas entre estudios y transferencia entre dominios. La tercera es la pérdida de rendimiento fuera del dominio de entrenamiento, documentada de forma reiterada en pacientes de fototipo cutáneo elevado [14, 12]. Estas tres limitaciones motivan la transición hacia el paradigma fundacional.

1.3 Modelos fundacionales en imagen médica

Los modelos fundacionales son arquitecturas preentrenadas sobre grandes datasets sin etiquetar mediante objetivos auto-supervisados o multimodales. Sus representaciones se adaptan posteriormente a tareas específicas con cantidades reducidas de datos etiquetados. Las arquitecturas predominantes son el Vision Transformer (ViT) y sus variantes [21]. Los objetivos de preentrenamiento más extendidos son la reconstrucción enmascarada, la destilación auto-supervisada y la alineación contrastiva imagen-texto al estilo CLIP [22, 23].

En imagen médica, DINOv2 [16] representa la referencia abierta de encoder auto-supervisado de propósito general, entrenado sobre ~ 142 millones de imágenes naturales mediante destilación entre vistas. BiomedCLIP [17] extiende el paradigma contrastivo al dominio biomédico sobre PMC-15M (~ 15 millones de pares figura-leyenda). El paradigma de segmentación promptable se establece con SAM [24] y su evolución SAM2.1 [18]; su transferencia a dominios médicos requiere adaptación, habitualmente vía LoRA [31]. La arquitectura BLIP-2 [25] bridge un encoder visual congelado con un modelo de lenguaje mediante un módulo intermedio (Q-Former). La evidencia disponible muestra que el preentrenamiento sobre datos del dominio clínico de interés incrementa de forma consistente el rendimiento respecto a encoders generalistas adaptados.

1.4 Modelos fundacionales para dermatología

Tres referencias relevantes liberadas por el grupo de la Universidad Monash definen el estado del arte específico durante el periodo 2024–2026.

PanDerm [1]. Encoder visual auto-supervisado entrenado mediante reconstrucción enmascarada sobre $\sim 2,1$ millones de imágenes dermatológicas en cuatro modalidades (fotografía corporal total, dermatoscopia, fotografía clínica, histopatología). Libera pesos en dos tamaños: *Base* (~ 86 M parámetros, embedding 768) y *Large* (~ 307 M parámetros, embedding 1024). Sus autores reportan una mejora media del $+10,2\%$ sobre el estado del arte previo en 28 tareas dermatológicas. La disponibilidad simultánea de pesos, código y benchmark hace de PanDerm el primer modelo fundacional dermatológico verificable de forma independiente.

Derm1M y la familia DermLIP [2]. Derm1M es un dataset dermatológico vision-lenguaje de $\sim 1,03$ millones de pares imagen-texto, construido a partir de fuentes clínicas y de literatura especializada. DermLIP es el modelo contrastivo entrenado sobre Derm1M al estilo CLIP [22], distribuido en variantes con encoder visual ViT-B/16 y encoder textual basado en PubMedBERT o GPT-2/CLIP. La alineación habilita clasificación zero-shot guiada por *prompts* y recuperación bidireccional visión-texto sin entrenamiento específico por tarea.

DermFM-Zero [3]. Integra encoder visual, rama lingüística y mecanismo de interpretabilidad mediante Sparse Autoencoders sobre las representaciones internas [19]. Reporta rendimientos superiores a PanDerm y DermLIP en los benchmarks que define. Sus pesos no son públicos en la fecha de cierre del trabajo, lo que restringe su tratamiento a la discusión conceptual.

A estos tres modelos específicos se añaden, en el espacio de comparación, encoders generalistas (DINOv2, BiomedCLIP, SigLIP-Large), arquitecturas convolucionales clásicas (ConvNeXt-L, EfficientNetV2-L), el modelo de segmentación SAM2.1 con adaptación LoRA y modelos de lenguaje multimodales (GPT-4o, Gemini 2.5 Pro, MedGemma 4B Vision, MedGemma 27B Text) [6], junto con BLIP-2 como referencia metodológica.

1.5 Brechas operativas y motivación

La revisión de la literatura identifica cinco brechas operativas sobre las que el presente estudio aporta evidencia empírica.

Benchmarks no homogéneos entre familias. Los benchmarks reportados por los autores originales de PanDerm, DermLIP y DermFM-Zero se construyen, en buena medida, sobre subconjuntos derivados de los datos de preentrenamiento, y aplican protocolos no equivalentes entre familias. La comparación entre encoders específicos de dominio, modelos contrastivos vision-lenguaje, encoders generalistas y modelos de lenguaje multimodales sobre un mismo conjunto de datasets externos y un mismo protocolo no está documentada en la literatura disponible.

Heterogeneidad taxonómica entre datasets. Los doce datasets externos públicos identificados como accesibles para el trabajo utilizan taxonomías nativas incompatibles: binarias melanoma/no-melanoma en Derm7pt, HIBA y MSKCC; multiclase con

$C \in [6, 23]$ en HAM10000, BCN20000, PAD-UFES-20, Dermnet y WSI patches; 114 patologías en Fitzpatrick17k [14]; 48 conceptos clínicos en SkinCon [15]. La comparación directa entre modelos sobre estos datasets exige un esquema explícito de armonización taxonómica que la literatura no proporciona.

Fuga de información entre conjuntos de evaluación y preentrenamiento. La construcción de Derm1M a partir de fuentes web abiertas introduce un riesgo no cuantificado de solapamiento con los conjuntos públicos habituales de evaluación. La cuantificación sistemática mediante hash MD5 exhaustivo no se documenta en la literatura previa al inicio del trabajo y constituye condición necesaria para la interpretación defendible de cualquier resultado zero-shot sobre estos datasets.

Datasets dermatológicos en español. Los datasets disponibles para preentrenamiento o adaptación de modelos vision-lenguaje son mayoritariamente angloparlantes (Derm1M, MONET, MM-Skin). La disponibilidad de material clínico en español con calidad docente verificada (imagen, metadatos clínicos y texto narrativo asociado) es marginal.

Reproducibilidad sobre hardware no estándar. La práctica totalidad de la literatura experimental se ejecuta sobre GPU NVIDIA A100 o H100 en plataformas x86_64. La aparición de plataformas alternativas basadas en arquitectura aarch64 (ARM de 64 bits), como la familia NVIDIA DGX Spark con chip Grace Hopper, introduce una variable no evaluada sobre la viabilidad de reproducción y el comportamiento numérico de los pipelines en BF16.

1.6 Marco operativo previo del autor

El presente trabajo se desarrolla en el marco de dos colaboraciones preexistentes con la Dra. R. Taberner, dermatóloga del HUSLL. La primera es la modernización tecnológica del archivo Dermapixel, blog mantenido por la Dra. Taberner desde 2010 que reúne más de 700 casos clínicos comentados con imagen clínica y dermatoscópica, historia abreviada, diagnóstico y razonamiento diferencial; el autor trabaja en su migración a una pila tecnológica propia. La segunda es un proyecto institucional del Servei de Salut de les Illes Balears (IB-Salut) sobre teledermatología hospitalaria, en el que se desarrolla una herramienta de apoyo a la primera valoración dermatológica en el circuito de derivación desde atención primaria. Ambas líneas orientan la decisión de priorizar modelos con código y pesos públicos por su viabilidad de integración.

1.7 Pregunta de investigación

El estudio se articula en torno a una pregunta única: *¿cuál es el rendimiento y la capacidad de generalización de los modelos fundacionales para imagen dermatológica disponibles, en función del volumen de datos etiquetados y del tipo de supervisión, y con qué robustez frente a la heterogeneidad taxonómica entre datasets y la disparidad por fototipo cutáneo?*

La respuesta empírica exige dos condiciones operativas: un protocolo de evaluación homogéneo aplicable a familias de modelos heterogéneas y un esquema explícito de armonización taxonómica entre datasets. El diseño descrito en el capítulo *Materiales y métodos* (en preparación) satisface ambas.

1.8 Objetivos del trabajo

El trabajo se articula en torno a dos objetivos formales, verificables sobre los resultados experimentales del capítulo *Resultados* (en preparación).

01. Evaluación experimental sistemática de los modelos fundacionales dermatológicos sobre conjuntos de datos externos. Sobre el hardware del proyecto (NVIDIA DGX Spark, chip Grace Hopper GB10, arquitectura aarch64, 128 GB memoria unificada, CUDA 13.0, BF16) se implementa el conjunto de modelos fundacionales con código y pesos públicos a la fecha de inicio. Se evalúa su comportamiento sobre doce datasets externos públicos¹ mediante cuatro protocolos principales (sondeo lineal, ajuste fino supervisado, segmentación binaria con LoRA [31] sobre SAM2.1 [18], clasificación zero-shot multimodal) y tres protocolos complementarios (comparación con modelos de lenguaje multimodales, análisis de equidad por fototipo Fitzpatrick, auditoría de solapamiento con Derm1M mediante hash MD5).

02. Construcción del dataset DermapixelAI 1.0. Se extrae, depura y estructura el material del archivo Dermapixel para conformar un dataset que vincula, para cada caso, imagen y modalidad, metadatos clínicos y texto narrativo en español. El dataset se publica bajo licencia CC-BY-NC-SA 4.0 con datasheet formal [28], particiones documentadas y mecanismo de cita recomendada. La explotación experimental sistemática sobre el dataset se inicia hacia el cierre del periodo cubierto por este documento y se desarrolla principalmente con posterioridad; la apartado *Líneas de investigación abiertas* (en preparación) del capítulo *Conclusiones* (en preparación) recoge el estado del dataset.

Los bloques derivados emergidos durante el desarrollo del proyecto (armonización ontológica jerárquica L1/L2/L3, ensemble de seguridad para detección de melanoma, análisis de equidad por fototipo, interpretabilidad mediante Sparse Autoencoders [19], recuperación visual densa basada en FAISS [26], integración en el prototipo DermApI-xel) no constituyen objetivos formales y se documentan en los anexos correspondientes con su estado, prerequisites y líneas futuras.

1.9 Contribuciones

Las contribuciones se enumeran a continuación. Las cuatro primeras sostienen la respuesta a la pregunta de investigación y se desarrollan en el cuerpo principal; las cinco siguientes constituyen material complementario y se documentan en los Anexos F–H (en preparación).

¹HAM10000 [8], BCN20000 [27], PAD-UFES-20 [11], DDI [12], Dermnet [13], Derm7pt (clínica y dermatoscópica) [9], HIBA, MSKCC, WSI patches, Fitzpatrick17k [14], SkinCon [15] e ISIC2018 [10].

1. Reproducción experimental del modelo PanDerm sobre arquitectura aarch64 (GB10/Grace Hopper) con verificación numérica respecto a los valores reportados en la publicación original.
2. Benchmark comparativo homogéneo de catorce modelos (PanDerm Base y Large, DINOv2, ConvNeXt-Large, EfficientNetV2-Large, tres variantes de DermLIP, Bio-medCLIP, SigLIP-Large, SAM2.1+LoRA, GPT-4o, Gemini 2.5 Pro, MedGemma 4B Vision y 27B Text, BLIP-2) bajo cuatro protocolos sobre doce datasets externos.
3. Ontología jerárquica L1/L2/L3 para armonización taxonómica entre datasets heterogéneos: cuatro categorías etiológicas, 43 subcategorías clínicas y 367 diagnósticos individuales, codificados en SNOMED CT y CIE-10 y validados por revisión experta.
4. Auditoría sistemática de solapamiento entre los doce conjuntos de evaluación y el dataset Derm1M mediante hash MD5 exhaustivo, con identificación de tres datasets afectados (Dermnet, HIBA, MSKCC) y cuantificación del impacto sobre las cifras zero-shot.
5. Dataset DermapixelAI 1.0, primer dataset dermatológico verificado en español con imagen, metadatos y texto narrativo asociado (1 089 imágenes vinculadas a 672 casos clínicos, mediana de 223 palabras por caso), distribuido bajo licencia CC-BY-NC-SA 4.0 con datasheet, particiones *case-aware* (891/157/41) y mecanismo de cita (Anexo *Entrega del dataset* (en preparación)).
6. Análisis empírico de equidad por fototipo Fitzpatrick sobre Fitzpatrick17k, comparando cinco arquitecturas y reportando la brecha de rendimiento entre fototipos extremos.
7. Caracterización de la sensibilidad de DermLIP al tokenizador y al diseño del *prompt* en clasificación zero-shot, con identificación del factor crítico (compatibilidad del tokenizador con el espacio de *embeddings* del modelo) (Anexo *Comparación LLM extendida* (en preparación)).
8. Replicación parcial del mecanismo de interpretabilidad basado en Sparse Autoencoders sobre las representaciones de PanDerm Large, validado mediante Concept Bottleneck Model sobre SkinCon [15] (Anexo *SAE y conceptos clínicos* (en preparación)).
9. Prototipo funcional DermApIxel como entorno integrado de despliegue de los módulos derivados del trabajo (Anexo *Prototipo DermApIxel* (en preparación)).

1.10 Restricciones del estudio

Tres restricciones explícitas condicionan el diseño experimental y la interpretación de los resultados. **Hardware:** todas las ejecuciones se realizan sobre NVIDIA DGX Spark con chip Grace Hopper GB10 y arquitectura aarch64, no coincidente con el hardware x86_64 dominante en la literatura. **Acceso a datos:** los conjuntos internos del grupo de Monash empleados en el preentrenamiento de PanDerm no son accesibles para

terceros, lo que limita el trabajo a los pesos liberados y a la evaluación sobre datasets externos públicos. **Acceso a modelos:** los pesos de DermFM-Zero no son públicos en la fecha de cierre, lo que impide su evaluación empírica directa y restringe su tratamiento a la discusión conceptual.

El trabajo no aborda, por decisión de alcance, los siguientes elementos: preentrenamiento desde cero de un modelo fundacional propio; validación clínica prospectiva sobre cohorte hospitalaria real con protocolo aprobado por Comité Ético de Investigación Clínica; integración operativa con el sistema PACS del HUSLL; reentrenamiento multilingüe de la rama lingüística sobre datasets en español de gran escala. Estos elementos se identifican como líneas futuras en la apartado *Líneas de investigación abiertas* (en preparación) del capítulo *Conclusiones* (en preparación).

1.11 Estructura del documento

El documento se compone de siete capítulos en el cuerpo principal, una bibliografía y diez anexos. El capítulo 2 sintetiza el estado del arte en cuatro bloques. El capítulo *Materiales y métodos* (en preparación) describe materiales y métodos: los doce datasets externos, la ontología jerárquica L1/L2/L3, el dataset DermapixelAI 1.0 (resumido; pipeline detallado en el Anexo *Pipeline DermapixelAI* (en preparación)), los catorce modelos evaluados, la infraestructura, los protocolos, las métricas y la trazabilidad. El capítulo *Resultados* (en preparación) reúne los resultados experimentales organizados por bloque. El capítulo *Discusión* (en preparación) interpreta los resultados en clave de hallazgos, comparación con la literatura e implicaciones operativas. El capítulo *Limitaciones* (en preparación) declara las limitaciones del estudio en seis dimensiones. El capítulo *Conclusiones* (en preparación) responde de forma compacta a la pregunta de investigación y enumera las contribuciones reproducibles.

Los anexos contienen, respectivamente, el mapa de tareas experimentales y la estructura del repositorio (Anexo *Tareas y reproducibilidad* (en preparación)), las tablas detalladas de resultados por dataset (Anexo *Tablas extendidas* (en preparación)), el pipeline de construcción y caracterización del dataset DermapixelAI 1.0 (Anexo *Pipeline DermapixelAI* (en preparación)), la declaración sobre el uso de herramientas de inteligencia artificial durante la elaboración del documento (Anexo *Declaración uso IA* (en preparación)), el documento de entrega formal del dataset con licencia, datasheet y consideraciones de privacidad (Anexo *Entrega del dataset* (en preparación)), la documentación de los Sparse Autoencoders y el diccionario de conceptos (Anexo *SAE y conceptos clínicos* (en preparación)), la comparación extendida con modelos de lenguaje multimodales generalistas (Anexo *Comparación LLM extendida* (en preparación)) y el prototipo DermApIxel (Anexo *Prototipo DermApIxel* (en preparación)).

ESTADO DEL ARTE

2.1 Aprendizaje profundo aplicado a dermatología

El trabajo de Esteva et al. [29] establece la primera referencia consolidada de clasificación dermatológica con redes convolucionales, con rendimiento equivalente al de un panel de dermatólogos certificados sobre clasificación binaria maligno/benigno. Las extensiones posteriores amplían el espectro diagnóstico y la diversidad de datos [30, 8] y formulan tareas adicionales como segmentación binaria de lesión [10] y clasificación binaria melanoma/no-melanoma con anotaciones estructuradas multi-criterio [9]. El paradigma común permanece estable: entrenamiento desde pesos de ImageNet, una arquitectura por tarea y dependencia de anotación experta. Tres limitaciones lo acotan: el coste de la anotación clínica, la fragmentación taxonómica entre conjuntos públicos y la pérdida de rendimiento fuera del dominio de entrenamiento, particularmente acusada en fototipos cutáneos elevados [14, 12].

2.2 Modelos fundacionales: arquitectura y objetivos

Los modelos fundacionales sustituyen el entrenamiento específico por encoders preentrenados de forma auto-supervisada o multimodal sobre datasets visuales masivos. La arquitectura predominante es el Vision Transformer [21], que procesa la imagen como una secuencia de parches y aprende dependencias globales mediante mecanismos de atención. Los objetivos de preentrenamiento más extendidos son tres: el *masked image modeling*, en el que la red reconstruye parches ocultos a partir del contexto visible; la destilación auto-supervisada entre vistas; y la alineación contrastiva imagen-texto al estilo CLIP [22]. La adaptación posterior a tareas específicas opera por sondeo lineal sobre representaciones congeladas, ajuste fino supervisado, o transferencia directa zero-shot guiada por *prompts* en los modelos con rama lingüística.

2.3 Encoders visuales auto-supervisados

DINOv2 [16] es la referencia abierta de encoder visual auto-supervisado de propósito general, entrenado sobre ~ 142 millones de imágenes naturales sin etiquetas mediante destilación entre vistas. Sus representaciones transfieren a tareas de clasificación, recuperación y segmentación sobre dominios naturales y biomédicos con ajuste mínimo, y constituyen una base habitual para adaptación a dominios especializados.

En el dominio dermatológico, PanDerm [1] es un encoder visual ViT (Base ~ 86 M y Large ~ 307 M parámetros) entrenado sobre $\sim 2,1$ millones de imágenes dermatológicas en cuatro modalidades (fotografía corporal total, dermatoscopia, fotografía clínica e histopatología). El preentrenamiento utiliza *masked latent modeling*: la red reconstruye representaciones latentes de regiones ocultas en lugar de píxeles, con un modelo CLIP-Large congelado como *teacher*. Sus autores reportan una mejora media del +10,2% sobre el estado del arte previo en 28 tareas dermatológicas. La disponibilidad simultánea de pesos, código y benchmarks lo convierte en el primer modelo fundacional dermatológico verificable de forma independiente.

2.4 Modelos vision-lenguaje contrastivos

CLIP [22] establece el preentrenamiento contrastivo imagen-texto sobre 400 millones de pares de la web. El objetivo InfoNCE aproxima la imagen a su descripción dentro del lote y la aleja del resto. El espacio compartido habilita dos modos operativos: clasificación zero-shot guiada por *prompts* textuales (la clase ganadora es la de mayor similitud coseno entre el vector visual y los vectores textuales de las clases candidatas) y recuperación bidireccional imagen-texto sobre datasets precomputados.

SigLIP [23] sustituye la pérdida softmax de CLIP por una pérdida sigmoide que reduce la dependencia del tamaño de batch y escala con mejor estabilidad. Su variante Large (SO400M) dispone de embedding de 1 152 dimensiones y ~ 878 M parámetros. BiomedCLIP [17] extiende el paradigma al dominio biomédico sobre PMC-15M (~ 15 millones de pares figura-leyenda de literatura científica); su cobertura dermatológica específica es limitada por el sesgo de selección del dataset.

En dermatología, Derm1M y la familia DermLIP [2] añaden la rama lingüística contrastiva al estado del arte de la disciplina. Derm1M reúne 1 029 761 pares imagen-texto sobre 403 563 imágenes únicas, organizados según una ontología jerárquica de cuatro niveles construida por dermatólogos. La familia DermLIP combina varios encoders visuales (PanDerm Base, ConvNeXt-Large) con varios encoders textuales (PubMedBERT extendido a 256 tokens, GPT-2 dermatológico con tokenizador de CLIP a 77 tokens). La configuración con mejor rendimiento reportada por los autores combina PanDerm Base como encoder visual y PubMedBERT como encoder textual, superando a BiomedCLIP en los benchmarks zero-shot evaluados.

La implementación operativa de la recuperación visual densa sobre datasets a gran escala requiere índices vectoriales optimizados para búsqueda aproximada del vecino más próximo. FAISS [26] y estructuras basadas en grafos del tipo Hierarchical Navigable Small Worlds permiten consultas en el orden de 10^2 milisegundos sobre datasets de centenares de miles a millones de *embeddings* precomputados.

2.5 Modelos integrados con zero-shot nativo

DermFM-Zero [3] integra el preentrenamiento visual auto-supervisado y la alineación contrastiva imagen-texto en un único modelo con capacidad zero-shot nativa. El entrenamiento se estructura en dos fases: *masked latent modeling* sobre tres millones de imágenes en la primera, y *bootstrapped contrastive learning* sobre un millón de pares texto-imagen en la segunda. El encoder textual es PubMedBERT. El modelo incorpora interpretabilidad emergente mediante Sparse Autoencoders [19], redes auxiliares que descomponen la representación interna en un diccionario disperso de direcciones asociables a conceptos clínicamente identificables. Sus autores reportan validación en tres *reader studies* con más de mil cien clínicos. Sus pesos no son públicos en la fecha de cierre del presente trabajo, lo que restringe su tratamiento a la discusión conceptual.

BLIP-2 [25] introduce un patrón arquitectónico distinto: conecta un encoder visual congelado con un modelo de lenguaje preentrenado mediante un módulo intermedio ligero (*Q-Former* o *Querying Transformer*) que transforma las representaciones visuales en una secuencia reducida de tokens interpretables por el modelo de lenguaje. Sólo el Q-Former se entrena. No existe, en la fecha de cierre, una adaptación pública específica de BLIP-2 al dominio dermatológico.

2.6 Segmentación promptable

SAM [24] establece el paradigma de segmentación promptable: produce máscaras a partir de *prompts* visuales (puntos, cajas, máscaras parciales) sobre imagen natural. Su preentrenamiento utiliza ~ 11 millones de imágenes con más de mil millones de máscaras generadas mediante un proceso semi-automatizado. SAM2 [18] amplía el enfoque al dominio del vídeo y mejora el rendimiento sobre imágenes estáticas.

La transferencia a dominios médicos requiere adaptación supervisada sobre conjuntos con máscaras binarias. La estrategia habitual combina un modelo SAM/SAM2 preentrenado con *fine-tuning* sobre ISIC2018 [10] y adaptadores LoRA [31], que incorporan un número reducido de parámetros entrenables manteniendo congelado el peso original del encoder visual. Esta estrategia reduce los requisitos de memoria y cómputo y permite la adaptación sobre hardware modesto.

2.7 Modelos de lenguaje multimodales generalistas

Los modelos de lenguaje multimodales preentrenados sobre datasets web masivos constituyen una referencia de comparación inevitable: GPT-4o (OpenAI), Gemini 2.5 Pro (Google DeepMind) y la familia MedGemma (versiones 4B Vision y 27B Text, Google). Su número de parámetros supera al de los encoders fundacionales específicos en uno o dos órdenes de magnitud. Su modo de uso característico es la inferencia guiada por *prompts* sin *fine-tuning* específico por tarea. Trabajos recientes documentan su uso conversacional para soporte al razonamiento clínico [6, 7]. Los modelos de acceso restringido (GPT-4o, Gemini) sólo se evalúan mediante API; MedGemma libera pesos y se evalúa en local.

2.8 Problemas metodológicos y guías de reporte

La aplicación de modelos fundacionales a imagen médica plantea tres problemas metodológicos directamente relevantes para el presente trabajo. El primero es la fuga de información entre conjuntos de evaluación y dataset de preentrenamiento. La construcción de Derm1M sobre fuentes web abiertas implica que datasets como Dermnet, HIBA o MSKCC pueden solaparse con su dataset de entrenamiento, lo que sesga al alza las métricas zero-shot reportadas. El segundo es la heterogeneidad taxonómica entre datasets, que impide comparaciones directas sin un paso explícito de armonización. El tercero es la disparidad de rendimiento por fototipo cutáneo, documentada en Fitzpatrick17k [14] y atendida específicamente por SkinCon [15] mediante anotación basada en 48 conceptos clínicos visuales.

Las guías de reporte recientes para inteligencia artificial en imagen médica —CLAIM [33] y la actualización TRIPOD+AI— establecen la transparencia metodológica como condición de defensibilidad: cohorte, particiones, métricas, incertidumbre y limitaciones deben constar explícitamente en el informe completo. El reporte de pruebas estadísticas (intervalos de confianza por *bootstrap*, comparaciones múltiples, contrastes pareados de AUROC mediante el test de DeLong [32], y tamaños muestrales por subgrupo) constituye un requisito creciente en publicaciones de la disciplina.

2.9 Brechas operativas y posicionamiento

Cinco brechas operativas delimitan el espacio en el que el presente trabajo aporta evidencia empírica. **(i) Disponibilidad real de los modelos.** PanDerm y DermLIP liberan pesos y código; DermFM-Zero no lo hace. BiomedCLIP, DINOv2, SigLIP, SAM, SAM2 y BLIP-2 son abiertos. Los modelos generalistas ofrecen acceso parcial por API. Cualquier evaluación empírica externa queda condicionada por esta disponibilidad. **(ii) Benchmarks no homogéneos entre familias.** Los benchmarks reportados por los autores se construyen sobre subconjuntos derivados del propio preentrenamiento y aplican protocolos no equivalentes entre familias. La comparación bajo un mismo protocolo y un mismo conjunto de datasets externos no está documentada. **(iii) Heterogeneidad taxonómica.** La comparación inter-dataset exige un esquema de armonización que la literatura no proporciona de forma consolidada. **(iv) Concentración geográfica y lingüística.** Los datasets proceden mayoritariamente de instituciones de Australia, Estados Unidos y Europa central, y los encoders textuales se preentrenan sobre datasets en inglés. La disponibilidad de material clínico en español con texto narrativo asociado es marginal. **(v) Distancia entre evaluación experimental e integración hospitalaria.** La evaluación sobre *benchmarks* públicos no cubre las condiciones operativas asociadas al despliegue en un entorno sanitario real (hardware no estándar, restricciones de privacidad, trazabilidad, interacción con sistemas hospitalarios).

La contribución empírica del trabajo, cuyo diseño se describe en el capítulo *Materiales y métodos* (en preparación) y cuyos resultados se presentan cuantitativamente en el capítulo *Resultados* (en preparación), se sitúa sobre estas cinco brechas.

BIBLIOGRAFÍA

- [1] Yan, S. *et al.* (2025). A multimodal vision foundation model for clinical dermatology. *Nature Medicine*, 31, 2691–2702. DOI: 10.1038/s41591-025-03747-y. Versión arXiv: 2410.15038v3. 1.4, 2.3
- [2] Yan, S., Hu, M., Jiang, Y., Li, X., Fei, H., Tschandl, P., Kittler, H., Ge, Z. (2025). Derm1M: A million-scale vision-language dataset aligned with clinical ontology knowledge for dermatology. arXiv:2503.14911v2. 1.4, 2.4
- [3] Yan, S., Li, X. *et al.* (2026). DermFM-Zero: A vision-language foundation model for zero-shot clinical collaboration and automated concept discovery in dermatology. arXiv:2602.10624v1. 1.4, 2.5
- [4] Taberner, R., Nadal, C., Llambrich, A., Vila, I.T.A. (2010). Dermatology service utilization and reasons for consultation by Spanish and immigrant patients in the region served by Hospital Son Llàtzer, Palma de Majorca, Spain. *Actas Dermo-Sifiliográficas* 101(4):323–329. 1.1
- [5] Buendía-Eisman, A., Arias-Santiago, S., Molina-Leyva, A., Gilaberte, Y., Fernández-Crehuet, P., Husein-ElAhmed, H., Viera-Ramírez, A., Fernández-Peñas, P., Taberner, R., Descalzo, M.Á., García-Doval, I. (2018). Análisis de los diagnósticos realizados en la actividad ambulatoria dermatológica en España: muestreo aleatorio nacional DIADERM. *Actas Dermo-Sifiliográficas* 109(5):416–423. DOI: 10.1016/j.ad.2018.02.003. 1.1
- [6] Tu, T., Palepu, A., Schaekermann, M., Saab, K., Freyberg, J., Tanno, R., Wang, A., Li, B., Amin, M., Tomasev, N., Azizi, S., Singhal, K., Cheng, Y., Hou, L., Webson, A., Kulkarni, K., Mahdavi, S.S., Semturs, C., Gottweis, J., Barral, J., Chou, K., Corrado, G.S., Matias, Y., Karthikesalingam, A., Natarajan, V. (2024). Towards conversational diagnostic AI. arXiv:2401.05654. 1.4, 2.7
- [7] Google DeepMind (2024). Advancing AMIE: a research AI agent for clinical reasoning, conversation and diagnosis (AI co-clinician). Disponible en <https://deepmind.google/blog/ai-co-clinician/>. Consultado en abril de 2026. 2.7
- [8] Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. 1.2, 1, 2.1

- [9] Kawahara, J., Daneshvar, S., Argenziano, G., Hamarneh, G. (2019). Seven-point checklist and skin lesion classification using multitask multimodal neural nets. *IEEE Journal of Biomedical and Health Informatics*, 23(2), 538–546. 1.2, 1, 2.1
- [10] Codella, N. *et al.* (2019). Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the International Skin Imaging Collaboration (ISIC). arXiv:1902.03368. 1.2, 1, 2.1, 2.6
- [11] Pacheco, A.G.C. *et al.* (2020). PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones. *Data in Brief*, 32, 106221. 1
- [12] Daneshjou, R. *et al.* (2022). Disparities in dermatology AI performance on a diverse, curated clinical image set. *Science Advances*, 8(31), eabq6147. 1.2, 1, 2.1
- [13] DermNet New Zealand Trust. DermNet NZ: The dermatology resource. <https://dermnetnz.org> 1
- [14] Groh, M. *et al.* (2021). Evaluating deep neural networks trained on clinical images in dermatology with the Fitzpatrick 17k dataset. *CVPR Workshops*. 1.2, 1.5, 1, 2.1, 2.8
- [15] Daneshjou, R. *et al.* (2022). SkinCon: A skin disease dataset densely annotated by domain experts for fine-grained debugging and analysis. *NeurIPS Datasets and Benchmarks*. 1.5, 1, 8, 2.8
- [16] Oquab, M. *et al.* (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. 1.3, 2.3
- [17] Zhang, S. *et al.* (2024). BiomedCLIP: A multimodal biomedical foundation model pretrained from fifteen million scientific image-text pairs. *NEJM AI*, 1(7). 1.3, 2.4
- [18] Ravi, N. *et al.* (2024). SAM 2: Segment Anything in Images and Videos. arXiv:2408.00714. 1.3, 1.8, 2.6
- [19] Templeton, A. *et al.* (2024). Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet. Anthropic Research Blog. 1.4, 1.8, 2.5
- [20] Gershenwald, J.E., Scolyer, R.A., Hess, K.R., Sondak, V.K., Long, G.V., Ross, M.I., Lazar, A.J., Faries, M.B., Kirkwood, J.M., McArthur, G.A., Haydu, L.E., Eggermont, A.M.M., Flaherty, K.T., Balch, C.M., Thompson, J.F. (2017). Melanoma staging: Evidence-based changes in the American Joint Committee on Cancer eighth edition cancer staging manual. *CA: A Cancer Journal for Clinicians*, 67(6), 472–492. DOI: 10.3322/caac.21409. 1.1
- [21] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR 2021)*. 1.3, 2.2

- [22] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Aspell, A., Mishkin, P., Clark, J., Krueger, G., Sutskever, I. (2021). Learning transferable visual models from natural language supervision. *Proceedings of the 38th International Conference on Machine Learning (ICML 2021)*, 8748–8763. 1.3, 1.4, 2.2, 2.4
- [23] Zhai, X., Mustafa, B., Kolesnikov, A., Beyer, L. (2023). Sigmoid loss for language image pre-training. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, 11975–11986. 1.3, 2.4
- [24] Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A.C., Lo, W.-Y., Dollár, P., Girshick, R. (2023). Segment anything. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, 4015–4026. 1.3, 2.6
- [25] Li, J., Li, D., Savarese, S., Hoi, S.C.H. (2023). BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. *Proceedings of the 40th International Conference on Machine Learning (ICML 2023)*, 19730–19742. 1.3, 2.5
- [26] Johnson, J., Douze, M., Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535–547. DOI: 10.1109/TBDATA.2019.2921572. 1.8, 2.4
- [27] Combalia, M., Codella, N.C.F., Rotemberg, V., Helba, B., Vilaplana, V., Reiter, O., Carrera, C., Barreiro, A., Halpern, A.C., Puig, S., Malvehy, J. (2019). BCN20000: Dermoscopic lesions in the wild. arXiv:1908.02288. 1
- [28] Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J.W., Wallach, H., Daumé III, H., Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92. DOI: 10.1145/3458723. Versión original arXiv:1803.09010 (2018). 1.8
- [29] Esteva, A., Kuprel, B., Novoa, R.A., Ko, J., Swetter, S.M., Blau, H.M., Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118. DOI: 10.1038/nature21056. 1.2, 2.1
- [30] Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. DOI: 10.1038/sdata.2018.161. 1.2, 2.1
- [31] Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W. (2022). LoRA: Low-Rank Adaptation of large language models. *International Conference on Learning Representations (ICLR 2022)*. arXiv:2106.09685. 1.3, 1.8, 2.6
- [32] DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3), 837–845. 2.8
- [33] Tejani, A.S., Klontzas, M.E., Gatti, A.A., Mongan, J.T., Moy, L., Park, S.H., Kahn Jr., C.E. (2024). Checklist for Artificial Intelligence in Medical Imaging (CLAIM): 2024

BIBLIOGRAFÍA

update. *Radiology: Artificial Intelligence*, 6(4), e240300. DOI: 10.1148/ryai.240300.
2.8