



Universitat
de les Illes Balears

TRABAJO DE FIN DE GRADO

DERMAPIXEL: EVALUACIÓN DE MODELOS FUNDACIONALES PARA DERMATOLOGÍA CLÍNICA

Antonio Contestí Coll

Grau d'Enginyeria Informàtica

Escola Politècnica Superior

Año académico 2025–2026

DERMAPIXEL: EVALUACIÓN DE MODELOS FUNDACIONALES PARA DERMATOLOGÍA CLÍNICA

Antonio Contestí Coll

Trabajo de Fin de Grado

Escola Politècnica Superior

Universitat de les Illes Balears

Año académico 2025–2026

Paraules clau del treball: modelos fundacionales, dermatología clínica, PanDerm, DermLIP, evaluación empírica, ontología, equidad, interpretabilidad

Tutor: Dr. Javier Varona Gómez

A la Dra. Rosa Taberner, por su excepcional trabajo en Dermapixel y por su dilatada trayectoria en teledermatología, siendo un referente en el ámbito. Por la generosidad con la que me ha transmitido su conocimiento y por el tiempo que me ha dedicado de forma totalmente desinteresada a lo largo de este proyecto.

A mi tutor, el Dr. Javier Varona, por transmitirme el conocimiento con tanta claridad y pasión, por contagiarme esa ilusión por aprender, por su apoyo constante, por saber guiarme y centrarme en cada momento, y, sobre todo, por ser mucho más que un tutor: un gran amigo.

A todos los profesores de la Universitat de les Illes Balears que he tenido durante estos años, por su profesionalidad, dedicación y por el trato cercano y respetuoso que siempre me han brindado.

A mis compañeros de clase (Marc, Jordi, Dylan, Andres, Josep, Xisco, Carlos, Jesus, David), por hacerme sentir uno más desde el primer día. Me llevo no solo grandes profesionales con ambición y talento, sino también excelentes personas y amigos.

A Marc y a Jordi, compañeros de clase y también de prácticas, por haberse convertido en grandes amigos que sé que durarán toda la vida. Por todo lo que nos hemos ayudado mutuamente sin esperar nada a cambio, por el apoyo constante en los momentos difíciles y, en especial, por haber estado ahí en uno de los momentos más complicados del camino.

A David, por ser un ejemplo de superación. Por su esfuerzo constante, por su capacidad de lucha día tras día y por su actitud siempre positiva ante las dificultades.

A mis padres, por darme todo y por permitirme hoy devolverles, con este logro, una pequeña parte de lo que me han dado. Esta meta también es vuestra.

A mi hermano, y a mis sobrinos Albert y Marta, con la ilusión de poder transmitirles que, con humildad, esfuerzo y constancia, cualquier objetivo es alcanzable.

A Bruno, Marta y Jaume, los hijos de mi mujer y también mis hijos, por el apoyo, la comprensión y el cariño que me han demostrado en casa durante todo este tiempo.

A mi mujer, por su apoyo incondicional, por su paciencia infinita y por todo lo que ha sacrificado durante estos años, renunciando a muchos momentos juntos para que yo pudiera seguir adelante. Este trabajo es tanto suyo como mío.

Y, finalmente, a todos los pacientes, que son la verdadera razón de este camino.

ÍNDICE GENERAL

Índice general	iii
Lista de acrónimos	xii
Resumen	xiii
Abstract	xv
1 Introducción	1
1.1 Contexto clínico	1
1.2 Marco operativo previo	2
1.3 Pregunta de investigación	2
1.4 Objetivos del trabajo	3
1.5 Restricciones del estudio	4
1.6 Estructura del documento	4
2 Estado del arte	7
2.1 Aprendizaje profundo aplicado a dermatología	7
2.2 Modelos fundacionales: arquitectura y objetivos	7
2.3 Encoders visuales auto-supervisados	8
2.4 Modelos vision-lenguaje contrastivos	8
2.5 Modelos integrados con zero-shot nativo	9
2.6 Segmentación promptable	9
2.7 Modelos de lenguaje multimodales generalistas	9
2.8 Problemas metodológicos y guías de reporte	10
2.9 Brechas operativas y posicionamiento	10
3 Materiales y métodos	13
3.1 Datasets	13
3.2 Ontología jerárquica L1/L2/L3	14
3.3 Dataset DermapixelAI 1.0	15
3.4 Modelos evaluados	15
3.5 Infraestructura experimental	16
3.6 Protocolos experimentales	17
3.6.1 Sondeo lineal (LP)	17
3.6.2 Ajuste fino supervisado (FT)	17
3.6.3 Eficiencia en etiquetas	18

3.6.4	Segmentación binaria de lesión	18
3.6.5	Clasificación zero-shot multimodal	19
3.6.6	Comparación con modelos de lenguaje multimodales	20
3.6.7	Evaluación de equidad por fototipo	20
3.6.8	Auditoría de solapamiento con Derm1M	21
3.7	Métricas	21
3.8	Pruebas estadísticas	22
3.9	Trazabilidad y reproducibilidad	24
4	Resultados	25
4.1	Validez experimental: auditoría de solapamiento con Derm1M	26
4.2	Reproducción de PanDerm: sondeo lineal sobre diez datasets	26
4.3	Benchmark comparativo entre familias	28
4.4	Ajuste fino supervisado	30
4.5	Eficiencia en etiquetas	30
4.6	Segmentación binaria de lesión	31
4.6.1	Comparativa de arquitecturas promptables	33
4.6.2	Valor del prompt: control automático sin caja	33
4.6.3	Robustez del resultado: validación cruzada, prompt y calibración	34
4.6.4	El techo de la métrica: acuerdo inter-anotador	35
4.7	Clasificación zero-shot multimodal	36
4.8	Comparación con modelos de lenguaje multimodales	37
4.8.1	Ajuste supervisado de un LLM multimodal: MedGemma con LoRA	38
4.9	Equidad por fototipo cutáneo	38
4.9.1	Validación estadística del ranking de encoders: test de DeLong	41
4.10	Validación en castellano sobre DermapixelAI 1.0	41
4.10.1	Transferencia congelada: sondeo lineal y validación cruzada	42
4.10.2	Validación del procedimiento de etiquetado	43
4.10.3	Estrategias de adaptación más allá del sondeo lineal	43
4.10.4	LoRA frente a ajuste fino denso	45
4.10.5	Limitaciones del ajuste fino en la cola larga	45
4.11	Validación <i>zero-shot</i> multimodal sobre DermapixelAI 1.0	46
4.12	Ajuste fino con LoRA: Dermapixel R0 (cabeza supervisada L2)	48
4.12.1	Diseño de Dermapixel R0	48
4.12.2	Resultados principales L2	48
4.12.3	Adaptación eficiente frente a ajuste denso	48
4.12.4	Limitaciones en L3	49
4.13	Dermapixel R0: rama contrastiva multimodal castellano zero-shot sobre DermapixelAI 1.0	49
4.13.1	Diseño experimental	49
4.13.2	Evolución v1→v5	49
4.13.3	Hallazgos científicos	50
4.13.4	Recuperación multimodal	51
4.14	Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos	52
4.15	Síntesis comparativa de métodos sobre DermapixelAI 1.0	55

5	Discusión	57
5.1	Significado de los resultados	57
5.1.1	Ausencia de un método óptimo único: especialización por tarea	57
5.1.2	DermapixelAI 1.0 como contribución metodológica	60
5.1.3	Eficiencia en etiquetas y régimen de saturación	60
5.1.4	Sondeo lineal frente a ajuste fino	61
5.1.5	Segmentación promptable y adaptación de bajo coste	62
5.1.6	Sensibilidad al tokenizador en zero-shot multimodal	64
5.1.7	Brecha entre modelos específicos y LLMs multimodales	65
5.1.8	Equidad por fototipo cutáneo	66
5.1.9	El cuello de botella ya no es sólo el modelo	67
5.1.10	Estimación robusta del rendimiento sobre datasets de tamaño moderado	68
5.2	Comparación con la literatura	68
5.2.1	Reproducción del benchmark de PanDerm	69
5.2.2	Segmentación binaria de lesión	69
5.2.3	Comportamiento zero-shot	70
5.2.4	Disparidad por fototipo	71
5.3	Implicaciones operativas	72
5.3.1	Arquitectura defendible para sistemas de apoyo al diagnóstico .	72
5.3.2	Ventana operativa por fototipo cutáneo	73
5.3.3	Ensemble de seguridad para detección de melanoma	73
5.4	Hallazgos no anticipados	74
5.5	Limitaciones interpretativas	75
6	Limitaciones	77
6.1	Limitaciones de disponibilidad	77
6.1.1	Modelos sin pesos públicos	77
6.1.2	Conjuntos de preentrenamiento no liberados	78
6.1.3	Dependencia de modelos fundacionales externos	78
6.2	Limitaciones de los datos	78
6.2.1	Sesgo geográfico y lingüístico	78
6.2.2	Heterogeneidad taxonómica entre datasets	78
6.2.3	Solapamiento con el dataset de preentrenamiento Derm1M . .	79
6.2.4	Tamaños muestrales por subgrupo en el experimento de equidad	80
6.3	Limitaciones del diseño experimental	80
6.3.1	Variabilidad inter-semilla	80
6.3.2	Pruebas estadísticas y comparaciones múltiples	81
6.3.3	Sensibilidad al <i>prompt</i> en zero-shot y LLMs	81
6.4	Limitaciones del dataset DermapixelAI 1.0	81
6.5	Limitaciones de generalización clínica	82
6.5.1	Material de archivo frente a flujo asistencial real	82
6.5.2	Sesgo de modalidad de los componentes evaluados	83
6.5.3	Ausencia de validación prospectiva	83
6.5.4	Elementos no abordados por decisión de alcance	83
6.6	Síntesis: dominio de validez de los resultados	83

7 Conclusiones	85
7.1 Respuesta a la pregunta de investigación	85
7.2 Contribuciones reproducibles	87
7.2.1 Contribuciones en el cuerpo del documento	87
7.2.2 Contribuciones complementarias	88
7.3 Hallazgos metodológicos transferibles	89
7.4 Aportaciones a la práctica clínica	90
7.5 Líneas de investigación abiertas	91
7.5.1 Cobertura experimental sobre DermapixelAI 1.0: técnicas ejecu- tadas y pendientes	91
7.5.2 Dermapixel R0: primer modelo fundacional dermatológico en español	93
7.5.3 Derm7pt + Sparse Autoencoders: ground-truth conceptual para interpretabilidad	95
7.5.4 Aprendizaje activo <i>in-domain</i> sobre clases L3 con peor cobertura	95
7.5.5 Selección de arquitectura para segmentación promptable	96
7.5.6 Escalado del dataset con el banco hospitalario HUSLL	96
7.5.7 Validación clínica prospectiva	96
7.5.8 Auditoría sistemática de leakage extensible	97
7.5.9 Recuperación visual densa como sistema de apoyo	97
7.5.10 IA agéntica para razonamiento clínico estructurado	97
7.5.11 Reentrenamiento multilingüe de la rama lingüística	97
7.6 Cierre	97
Bibliografía	99
A Mapa de tareas experimentales y estructura del repositorio	103
A.1 Estructura del repositorio	103
A.2 Mapa de tareas experimentales	103
A.3 Comandos de ejecución	104
A.4 Configuraciones de entrenamiento por experimento	105
A.5 Versiones de software y semillas	106
A.6 Checkpoints publicados	106
B Tablas detalladas de resultados	107
B.1 Desglose por clase sobre HAM10000	107
B.2 Desglose por clase del ajuste fino MedGemma 27B sobre HAM10000 . .	108
B.3 Equidad sobre Fitzpatrick17k: formulación de 114 patologías	108
B.4 Evaluación cruzada Light/Dark sobre 114 patologías	109
B.5 Resumen comparativo por paradigma sobre HAM10000	109
B.6 Composición del conjunto de entrenamiento del SAE Large	112
B.7 Segmentación: generalización fuera de dominio (Dice e IoU)	113
B.8 Equidad por fototipo: tablas complementarias	113
C Pipeline de construcción y caracterización del dataset DermapixelAI 1.0	115
C.1 Origen y materia prima	115
C.2 Pipeline de construcción	115

C.3	Cardinalidades del dataset y splits experimentales	116
C.4	Distribución por modalidad	117
C.5	Distribución por categoría etiológica L1	117
C.6	Distribución por subcategoría L2 y por diagnóstico L3	117
C.7	Cola larga diagnóstica	119
C.8	Particionado en train, validación y test	120
C.9	Texto narrativo asociado al caso	122
C.10	Validación experta y campos de calidad	122
C.11	Caracterización temporal y de exclusiones	123
C.11.1	Distribución temporal	123
C.11.2	Razones de exclusión	123
D	Declaración sobre el uso de herramientas de inteligencia artificial	125
D.1	Alcance de la declaración	125
D.2	Herramientas empleadas	125
D.3	Uso académico: redacción del documento	125
D.4	Uso técnico: desarrollo del código	126
D.5	Uso documental: organización y trazabilidad	126
D.6	Modelos como objeto de evaluación	126
D.7	Verificación cruzada de cifras y citas	126
D.8	Responsabilidad sobre el contenido	127
E	Documento de entrega del dataset DermapixelAI 1.0	129
E.1	Identidad del dataset	129
E.2	Procedencia y autoría	129
E.3	Licencia de uso	130
E.4	Cita recomendada	130
E.5	Disponibilidad y distribución	130
E.6	Datasheet for Datasets	131
E.7	Uso responsable y limitaciones clínicas	132
E.8	Privacidad y consentimiento	133
E.9	Mantenimiento y contacto	133
F	Sparse Autoencoders y diccionario de conceptos clínicos	135
F.1	Motivación	135
F.2	Arquitectura del SAE	135
F.3	Comportamiento del SAE Large frente a SAE Base	136
F.4	Concept Bottleneck Model sobre SkinCon	137
F.4.1	Conceptos con mejor predictor	137
F.4.2	Rendimiento agregado del CBM	138
F.5	Propuesta de extensión: quince conceptos clínicos adicionales	139
F.6	Limitaciones del módulo SAE	139
F.7	Tablas de detalle del experimento Derm7pt	139
G	Modelos de lenguaje multimodales: comparación extendida	143
G.1	Modelos evaluados	143
G.2	Prompt clínico estandarizado	143

G.3	Comparativa completa sobre HAM10000, PAD-UFES-20 y DDI	144
G.4	Latencias, refusal rates y costes operativos	144
G.5	Patrones de error sobre HAM10000	145
G.6	MedGemma 27B con LoRA: análisis por dataset	145
G.7	Sensibilidad al prompt en DermLIP v2	146
G.8	Síntesis	146
H	Prototipo DermApIxel	147
H.1	Motivación arquitectónica	147
H.2	Arquitectura	147
H.2.1	Topología cliente-servidor	147
H.2.2	Componentes del backend	148
H.2.3	Persistencia: esquema de base de datos	148
H.2.4	Bus de mensajería AMQP	148
H.3	Módulos de inteligencia artificial	148
H.3.1	M1 – Clasificador cerrado	149
H.3.2	M2 – Segmentación binaria	149
H.3.3	M3 – Conceptos clínicos	149
H.3.4	M4 – Recuperación visual densa	149
H.3.5	M5 – Razonamiento clínico estructurado	149
H.3.6	M6 – Clasificación zero-shot abierta	150
H.4	Frontend e interfaz clínica	151
H.5	Rendimiento operativo	151
H.6	Estado de despliegue	151
H.7	Discusión: rol del prototipo en el trabajo	152
H.8	Evolución a M1–M11: módulos castellanos del prototipo	152
H.8.1	M7 – Clasificador unificado jerárquico <i>merged43</i> +TTA	152
H.8.2	M9 – Dermapixel R0 (cabeza L2), clasificador L2 castellano su- pervisado	152
H.8.3	M10 – <i>Seven-Point Checklist</i> multitarea	153
H.8.4	M4-bis – RAG castellano sobre DermapixelAI 1.0	153
H.8.5	M11 – Ensemble ponderado por AUROC y coherencia jerárquica	153
H.8.6	Sistema de consenso de cinco módulos y <i>warning</i> de derivación urgente	154
H.8.7	Estrategias de seguridad clínica: ensemble para detección de melanoma	154
H.8.8	Migración a AMQP (2026-04-13)	155
H.8.9	Evaluación end-to-end del prototipo extendido	155
I	Ablación: modelo fundacional inglés (DermLIP) con traducción ES–EN	157
I.1	Motivación	157
I.2	Protocolo experimental	157
I.3	Resultados	158
I.4	Interpretación	158
I.5	Limitaciones de la ablación	158
I.6	Detalles de reproducibilidad de la rama contrastiva	159
I.7	Material complementario de la rama contrastiva	159

I.7.1	Cabeza supervisada L2: <i>best-checkpoint</i> frente a últimas épocas	159
I.7.2	Barrido de épocas de la iteración v3	160
I.7.3	Techo de <i>Linear Probing</i> y diagnóstico mecánico	160
I.7.4	Calibración por <i>temperature scaling</i>	161
I.7.5	Diagnóstico cuantitativo del techo sobre L2	162
I.7.6	Síntesis de las cinco iteraciones	162
J	Ablaciones complementarias sobre DermapixelAI 1.0	165
J.1	Validación del procedimiento de etiquetado: subestudio <i>rosa_verified</i> .	165
J.2	Ranking L3 por prototipos coseno de Dermapixel R0	166
J.3	Cabezas alternativas sobre embeddings congelados	166
J.4	Función de pérdida: Cross-Entropy frente a Focal	166
J.5	Aumento en tiempo de inferencia	167
J.6	Codificadores generalistas no médicos: DINOv2 y CLIP-L	168
J.7	<i>Retrieval k</i> -NN con índice FAISS sobre embeddings PanDerm Large . .	169
J.8	<i>Zero-shot</i> jerárquico: cascada L1→L2→L3 con propagación de errores .	169

LISTA DE ACRÓNIMOS

AdamW	Adaptive Moment Estimation with decoupled Weight decay
AJCC	American Joint Committee on Cancer
AMQP	Advanced Message Queuing Protocol
API	Application Programming Interface
AUROC	Area Under the Receiver Operating Characteristic Curve
B _{Acc}	Balanced Accuracy
BCC	Carcinoma basocelular (<i>basal cell carcinoma</i>)
BCN	Barcelona
BF16	Brain Floating-Point de 16 bits
CAE	Convolutional AutoEncoder
CBM	Concept Bottleneck Model
CEIC	Comité Ético de Investigación Clínica
CIE-10	Clasificación Internacional de Enfermedades, décima revisión
CLIP	Contrastive Language–Image Pre-training
CV	Cross-Validation (validación cruzada)
DDI	Diverse Dermatology Images
ECE	Expected Calibration Error (error de calibración esperado)
DIADERM	Estudio observacional multicéntrico sobre demanda y prevalencia diagnóstica en dermatología en España
DICOM	Digital Imaging and Communications in Medicine
DSC	Dice Similarity Coefficient
ENS	Esquema Nacional de Seguridad
EPS	Escola Politècnica Superior
FAISS	Facebook AI Similarity Search
FP	Fototipo (escala Fitzpatrick I–VI)
FST	Fitzpatrick Skin Type (fototipo cutáneo Fitzpatrick)
FT	Fine-tuning supervisado
GPU	Graphics Processing Unit
HAM	Human Against Machine
HD95	Distancia de Hausdorff, percentil 95
HIBA	Hospital Italiano de Buenos Aires
HNSW	Hierarchical Navigable Small Worlds
HUSLL	Hospital Universitario Son Llàtzer
IA	Inteligencia artificial
IB-Salut	Servicio de Salud de las Illes Balears
IC	Intervalo de confianza
InfoNCE	Information Noise Contrastive Estimation
IoU	Intersection over Union (índice de Jaccard)
ISIC	International Skin Imaging Collaboration
ITA	Individual Typology Angle (ángulo tipológico individual)
L-BFGS	Limited-memory Broyden–Fletcher–Goldfarb–Shanno
LLM	Large Language Model (modelo de lenguaje de gran escala)
LoRA	Low-Rank Adaptation
LP	Linear Probing
MD5	Message Digest 5 (función de hash)
MLP	Multi-Layer Perceptron (perceptrón multicapa)
MSE	Mean Squared Error (error cuadrático medio)
MSKCC	Memorial Sloan Kettering Cancer Center
OIDC	OpenID Connect
PACS	Pictogram Analysis and Communication System

RESUMEN

Este trabajo evalúa el rendimiento y la capacidad de generalización de los modelos fundacionales dermatológicos disponibles, en función del volumen de datos etiquetados, del tipo de supervisión, de la heterogeneidad taxonómica entre conjuntos de datos y de la disparidad entre fototipos cutáneos. Su respuesta condiciona la viabilidad de integrarlos en teledermatología hospitalaria con cohortes mediterráneas en español, escenario donde las referencias recientes del grupo de la Universidad Monash —PanDerm, la familia DermLIP sobre Derm1M y DermFM-Zero— carecen de evaluación independiente comparable a la fecha de cierre.

Para responderla, se evalúan catorce modelos fundacionales sobre doce conjuntos de datos externos públicos, armonizados mediante una ontología jerárquica de tres niveles (4 categorías etiológicas, 43 subcategorías clínicas y 367 diagnósticos) codificada en SNOMED CT y CIE-10. La evaluación combina cuatro protocolos —sondeo lineal, ajuste fino supervisado, segmentación binaria promptable y clasificación zero-shot multimodal— ejecutados sobre una NVIDIA DGX Spark (chip Grace Hopper GB10, 128 GB unificados, BF16), plataforma aarch64 no habitual en la literatura.

PanDerm Large se confirma como el codificador congelado más fiable, con una mejora media de +9,0 pp en exactitud balanceada respecto a PanDerm Base, y satura con un volumen reducido de datos etiquetados: el 1 % del conjunto de entrenamiento de HAM10000 recupera el 96,2 % del AUROC obtenido con el conjunto completo. La evaluación zero-shot multimodal queda 29,4 pp por debajo del sondeo lineal supervisado en exactitud balanceada de nivel L1 sobre el dataset DermapixelAI 1.0 (PanDerm Large 0,735 frente a 0,441 de la mejor configuración zero-shot), lo que acota el coste de prescindir de adaptación supervisada. La auditoría por hash MD5 detecta que uno de los doce datasets de evaluación, Dermnet, está íntegramente contenido (100 %) en el preentrenamiento de Derm1M, por lo que sus cifras zero-shot previas deben interpretarse con *caveat*. La validación sobre DermapixelAI 1.0 confirma la transferencia a material clínico no anglosajón sin reentrenar la rama lingüística. Leído en conjunto, el estudio no identifica un único modelo óptimo, sino una especialización por tarea y nivel ontológico —la ventaja de PanDerm Large no se extiende uniformemente a la subcategoría clínica L2 ni a la cola larga L3—, lo que desplaza el cuello de botella del avance desde el codificador hacia la taxonomía, las etiquetas, el alineamiento texto-imagen, los *prompts* y la equidad.

El trabajo aporta tres contribuciones reproducibles principales: un benchmark comparativo homogéneo de catorce modelos fundacionales bajo un mismo protocolo, el dataset DermapixelAI 1.0 —1 089 imágenes y 669 casos clínicos con texto narrativo en castellano, bajo licencia CC-BY-NC-SA 4.0— y la auditoría de solapamiento sobre los doce datasets. Sobre esta base se introduce Dermapixel R0, el primer modelo fundacional dermatológico en español, inicializado desde PanDerm y adaptado con DermapixelAI 1.0 como versión base; su escalado completo queda como línea futura.

Palabras clave

modelos fundacionales, dermatología clínica, PanDerm, DermLIP, evaluación empírica, ontología, equidad, heterogeneidad taxonómica.

ABSTRACT

This work evaluates the performance and generalisation capacity of the available dermatology foundation models, as a function of the labelled data budget, the supervision regime, taxonomic heterogeneity across datasets and skin phototype disparity. Its answer conditions the viability of integrating these models into hospital teledermatology workflows on Spanish-speaking Mediterranean cohorts, a scenario in which the recent references from the Monash group —PanDerm, the DermLIP family over Derm1M and DermFM-Zero— lack an independent comparable evaluation at the time of writing.

To answer it, fourteen foundation models are evaluated over twelve public external datasets, harmonised through a three-level hierarchical ontology (4 aetiological families, 43 clinical subcategories and 367 diagnoses) encoded in SNOMED CT and ICD-10. The evaluation combines four protocols —linear probing, supervised fine-tuning, promptable binary lesion segmentation and multimodal zero-shot classification— executed on a NVIDIA DGX Spark with a Grace Hopper GB10 chip (128 GB unified, BF16 precision), an aarch64 platform uncommon in the experimental literature.

PanDerm Large stands out as the most reliable frozen encoder, with a mean improvement of +9,0 pp in balanced accuracy over PanDerm Base, and saturates with a small labelled budget: 1 % of the HAM10000 training set recovers 96,2 % of the AU-ROC obtained with the full set. Multimodal zero-shot evaluation falls 29,4 pp below supervised linear probing in L1 balanced accuracy on the DermapixelAI 1.0 dataset (PanDerm Large 0,735 versus 0,441 for the best zero-shot configuration), bounding the cost of forgoing supervised adaptation. The MD5-based overlap audit detects that one of the twelve evaluation datasets, Dermnet, is fully contained (100 %) in the Derm1M pretraining set, so its prior zero-shot figures must be read with this *caveat*. Validation on DermapixelAI 1.0 confirms model transfer to non-Anglophone clinical material without retraining the language branch. Taken together, the study does not identify a single optimal model but a specialisation by task and ontological level —PanDerm Large’s advantage does not extend uniformly to the intermediate L2 subcategory or the L3 long tail—, shifting the bottleneck of progress from the encoder towards taxonomy, labels, text-image alignment, *prompts* and fairness.

The work contributes three reproducible items: a homogeneous comparative benchmark of the fourteen families under a common protocol, the DermapixelAI 1.0 dataset —1 089 images linked to 669 clinical cases with narrative text and synthetic captions in Spanish, under a CC-BY-NC-SA 4.0 licence— and the overlap audit across the twelve evaluation sets. Building on this basis, Dermapixel R0 is introduced: a Spanish dermatology foundation model initialised from PanDerm and subsequently adapted using the DermapixelAI 1.0 dataset as an initial base, whose full scaling is left as future work.

Keywords

foundation models, clinical dermatology, PanDerm, DermLIP, empirical evaluation, ontology, fairness, taxonomic heterogeneity.

INTRODUCCIÓN

En el presente Trabajo Final de Grado (TFG) se evalúa de forma sistemática el rendimiento de los modelos fundacionales disponibles para imagen dermatológica clínica, sobre un conjunto homogéneo de protocolos experimentales y datasets externos públicos. Por *modelo fundacional* se entiende en este trabajo un modelo de gran escala preentrenado sobre un volumen amplio de datos y reutilizable, mediante adaptación, en múltiples tareas posteriores; el estudio evalúa los disponibles con pesos abiertos y, sobre esa base, construye una adaptación propia.

El trabajo articula así tres aportaciones de naturaleza distinta pero complementaria: un *benchmark* independiente y reproducible de catorce modelos fundacionales bajo un protocolo común; un *dataset* clínico propio en español, DermapixelAI 1.0, entregado como contribución independiente; y un *modelo adaptado*, Dermapixel R0, que demuestra la viabilidad de especializar un modelo fundacional preexistente al castellano con recursos modestos. Las tres se desarrollan en el marco de dos colaboraciones preexistentes con la Dra. R. Taberner del Hospital Universitario Son Llàtzer (HUSLL).

En este capítulo se presenta el contexto clínico del problema, el marco operativo en el que se inscribe el trabajo, la pregunta de investigación que articula el estudio, los objetivos formales, las restricciones explícitas del diseño y la estructura del resto del documento. El estado del arte específico —modelos fundacionales para imagen médica y dermatológica, métodos de adaptación y evaluación zero-shot— se desarrolla en el capítulo 2.

1.1 Contexto clínico

La dermatología clínica atiende un espectro amplio de entidades con distribución concentrada en un número reducido de motivos de consulta. El estudio observacional DIADERM, sobre 10999 diagnósticos en 8953 pacientes en territorio español, ordena los diez diagnósticos más prevalentes como queratosis actínica, carcinoma basocelular, nevus melanocítico, queratosis seborreica, otras neoplasias benignas, psoriasis, acné,

verrugas víricas, otros trastornos de la pigmentación y otras dermatitis [5]. El trabajo local de Taberner et al. sobre el servicio dermatológico del HUSLL documenta 213 diagnósticos diferentes en un único año asistencial [4]. Ambos coinciden en un peso elevado de dermatosis benignas, inflamatorias e infecciosas habituales.

La sensibilidad temporal del proceso diagnóstico resulta crítica en el melanoma cutáneo. La supervivencia específica a cinco años desciende desde aproximadamente 99 % en estadio I hasta 25 % en estadio IV según la octava edición de la American Joint Committee on Cancer [21]. El acceso al especialista se realiza mediante derivación desde atención primaria. La capacidad asistencial del circuito presencial es limitada frente a una demanda creciente, lo que justifica el interés por sistemas de apoyo al diagnóstico basados en imagen.

El sustrato visual del diagnóstico dermatológico se articula en tres modalidades: fotografía clínica (presentación general y contexto anatómico), dermatoscopia (patrones pigmentarios y estructurales no visibles a simple vista) e histopatología (confirmación tisular). Sobre esta tríada operan los sistemas de apoyo basados en aprendizaje automático.

1.2 Marco operativo previo

Las dos colaboraciones preexistentes con la Dra. R. Taberner, dermatóloga del HUSLL, en cuyo marco se desarrolla el trabajo, se detallan a continuación. La primera es la modernización tecnológica del archivo Dermapixel, blog mantenido por la Dra. Taberner desde 2010. El archivo reúne más de 700 casos clínicos comentados con imagen clínica y dermatoscópica, historia abreviada, diagnóstico y razonamiento diferencial. En paralelo a este TFG se ha desarrollado su migración a una pila tecnológica propia. La segunda es un proyecto institucional del Servei de Salut de les Illes Balears (IB-Salut) sobre teledermatología hospitalaria. En él se desarrolla una herramienta de apoyo a la primera valoración dermatológica en el circuito de derivación desde atención primaria. Ambas líneas orientan la decisión de priorizar modelos con código y pesos públicos, por su viabilidad de integración hospitalaria y su reproducibilidad. Esta prioridad introduce un sesgo de selección explícito —deja fuera modelos cerrados potencialmente más capaces, como DermFM-Zero, cuyos pesos no son públicos (sección 1.5)—, asumido a cambio de un marco de evaluación íntegramente reproducible; los modelos cerrados accesibles vía API se incorporan únicamente como comparadores contextuales.

1.3 Pregunta de investigación

El estado del arte en modelos fundacionales para imagen dermatológica (capítulo 2) ha avanzado con rapidez; a pesar de ello, persisten varias cuestiones abiertas. En primer lugar, la mayoría de trabajos evalúan los modelos sobre un número limitado de datasets y bajo protocolos heterogéneos, lo que dificulta la comparación directa entre arquitecturas. En segundo lugar, existe escasa evidencia sobre la transferencia de estos modelos a idiomas distintos del inglés y a escenarios multimodales que integren texto clínico narrativo. Por último, aspectos como la eficiencia en etiquetas, la equidad entre fototipos y la posible contaminación entre los datasets de preentrenamiento y los

de evaluación continúan insuficientemente caracterizados. Estas brechas motivan el presente trabajo.

El estudio se articula en torno a una pregunta única: *¿cuál es el rendimiento y la capacidad de generalización de los modelos fundacionales para imagen dermatológica disponibles, en función del volumen de datos etiquetados y del tipo de supervisión, y con qué robustez frente a la heterogeneidad taxonómica entre datasets y la disparidad por fototipo cutáneo?*

La pregunta no presupone la existencia de un modelo uniformemente superior. Se formula en términos condicionales —rendimiento en función del régimen de datos etiquetados, del tipo de supervisión, del nivel ontológico de la tarea y de la estrategia de adaptación—, de modo que su respuesta pueda adoptar la forma de una especialización por tarea antes que la de una ordenación única. Esta lectura se desarrolla como tesis transversal en el capítulo 5 (sección 5.1.1) y se sintetiza en el capítulo 7.

La respuesta empírica exige dos condiciones operativas: un protocolo de evaluación homogéneo aplicable a familias de modelos heterogéneas y un esquema explícito de armonización taxonómica entre datasets. El diseño descrito en el capítulo 3 satisface ambas.

1.4 Objetivos del trabajo

El trabajo se articula en torno a tres objetivos formales, verificables sobre los resultados experimentales del capítulo 4.

O1. Evaluación experimental sistemática de los modelos fundacionales dermatológicos sobre conjuntos de datos externos. Sobre el hardware del proyecto —una NVIDIA DGX Spark de arquitectura aarch64, cuya configuración completa se detalla en la sección 3.5— se implementa el conjunto de modelos fundacionales con código y pesos públicos a la fecha de inicio. Se evalúa su comportamiento sobre doce datasets externos públicos¹ mediante cuatro protocolos principales (sondeo lineal, ajuste fino supervisado, segmentación binaria promptable sobre SAM2.1 [19], clasificación zero-shot multimodal) y tres protocolos complementarios (comparación con modelos de lenguaje multimodales, análisis de equidad por fototipo Fitzpatrick, auditoría de solapamiento con Derm1M mediante hash MD5).

O2. Construcción del dataset DermapixelAI 1.0. Se extrae, depura y estructura el material del archivo Dermapixel para conformar un dataset que vincula, para cada caso, imagen y modalidad, metadatos clínicos y texto narrativo en español. El dataset se publica bajo licencia CC-BY-NC-SA 4.0 con datasheet formal [29], particiones documentadas y mecanismo de cita recomendada. Sobre él se ejecuta además parte de la evaluación experimental del capítulo 4, que contrasta el sondeo lineal supervisado frente a la clasificación zero-shot multimodal en los tres niveles ontológicos (secciones 4.10 y 4.11).

¹HAM10000 [8], BCN20000 [28], PAD-UFES-20 [11], DDI [12], Dermnet [13], Derm7pt (clínica y dermatoscópica) [9], HIBA, MSKCC, WSI patches, Fitzpatrick17k [14], SkinCon [15] e ISIC2018 [10].

O3. Inicialización y caracterización de Dermapixel R0, línea base dermatológica en español adaptada sobre un modelo fundacional preexistente. Partiendo del codificador PanDerm Large y del dataset DermapixelAI 1.0, se obtiene una versión base (R0) mediante adaptación supervisada de bajo rango y se caracteriza su comportamiento sobre los niveles ontológicos L2 y L3 (sección 4.12), junto con una rama contrastiva multimodal en español (sección 4.13). El objetivo no persigue un rendimiento de referencia, sino establecer una semilla reproducible y honestamente acotada que habilite el escalado documentado en la sección 7.5.2.

Los bloques derivados emergidos durante el desarrollo del proyecto (armonización ontológica jerárquica L1/L2/L3, ensemble de seguridad para detección de melanoma, análisis de equidad por fototipo, interpretabilidad mediante Sparse Autoencoders [20], recuperación visual densa basada en FAISS [27], integración en el prototipo DermApixel) no constituyen objetivos formales y se documentan en los anexos y secciones correspondientes con su estado, prerequisites y líneas futuras.

1.5 Restricciones del estudio

Tres restricciones explícitas condicionan el diseño experimental y la interpretación de los resultados. **Hardware:** todas las ejecuciones se realizan sobre el hardware descrito en el objetivo O1 (sección 1.4), cuya arquitectura aarch64 no coincide con el hardware x86_64 dominante en la literatura. **Acceso a datos:** los conjuntos internos del grupo de Monash empleados en el preentrenamiento de PanDerm no son accesibles para terceros, lo que limita el trabajo a los pesos liberados y a la evaluación sobre datasets externos públicos. **Acceso a modelos:** los pesos de DermFM-Zero no son públicos en la fecha de cierre, lo que impide su evaluación empírica directa y restringe su tratamiento a la discusión conceptual.

El trabajo no aborda, por decisión de alcance, los siguientes elementos: preentrenamiento desde cero de un modelo fundacional propio; validación clínica prospectiva sobre cohorte hospitalaria real con protocolo aprobado por Comité Ético de Investigación Clínica; reentrenamiento multilingüe de la rama lingüística sobre datasets en español de gran escala. Estos elementos se identifican como líneas futuras en la sección 7.5 del capítulo 7.

1.6 Estructura del documento

El documento se compone de siete capítulos en el cuerpo principal, una bibliografía y diez anexos. El capítulo 2 sintetiza el estado del arte en cuatro bloques: aprendizaje profundo aplicado a dermatología, modelos fundacionales en imagen médica, modelos específicos para dermatología y brechas operativas no resueltas por la literatura. El capítulo 3 describe materiales y métodos: los doce datasets externos, la ontología jerárquica L1/L2/L3, el dataset DermapixelAI 1.0 (resumido; pipeline detallado en el Anexo C), los catorce modelos fundacionales evaluados, la infraestructura, los protocolos, las métricas y la trazabilidad. El capítulo 4 reúne los resultados experimentales organizados por bloque. El capítulo 5 interpreta los resultados en clave de hallazgos, comparación con la literatura e implicaciones operativas. El capítulo 6 declara las limitaciones del

estudio en seis dimensiones. El capítulo 7 responde de forma compacta a la pregunta de investigación y enumera las contribuciones reproducibles.

Los anexos contienen, respectivamente, el mapa de tareas experimentales y la estructura del repositorio (Anexo A), las tablas detalladas de resultados por dataset (Anexo B), el pipeline de construcción y caracterización del dataset DermapixelAI 1.0 (Anexo C), la declaración sobre el uso de herramientas de inteligencia artificial durante la elaboración del documento (Anexo D), el documento de entrega formal del dataset con licencia, datasheet y consideraciones de privacidad (Anexo E), la documentación de los Sparse Autoencoders y el diccionario de conceptos (Anexo F), la comparación extendida con modelos de lenguaje multimodales generalistas (Anexo G), el prototipo DermApIxel (Anexo H), la ablación del modelo fundacional inglés con traducción ES-EN (Anexo I) y las ablaciones complementarias sobre DermapixelAI 1.0 —cabezas alternativas, función de pérdida, *Test-Time Augmentation*, codificadores generalistas y arquitecturas de inferencia alternativas— (Anexo J).

ESTADO DEL ARTE

2.1 Aprendizaje profundo aplicado a dermatología

El trabajo de Esteva et al. [30] establece la primera referencia consolidada de clasificación dermatológica con redes convolucionales, con rendimiento equivalente al de un panel de dermatólogos certificados sobre clasificación binaria maligno/benigno. Las extensiones posteriores amplían el espectro diagnóstico y la diversidad de datos [31, 8] y formulan tareas adicionales como segmentación binaria de lesión [10] y clasificación binaria melanoma/no-melanoma con anotaciones estructuradas multi-criterio [9]. El paradigma común permanece estable: entrenamiento desde pesos de ImageNet, una arquitectura por tarea y dependencia de anotación experta. Tres limitaciones lo acotan: el coste de la anotación clínica, la fragmentación taxonómica entre conjuntos públicos y la pérdida de rendimiento fuera del dominio de entrenamiento, particularmente acusada en fototipos cutáneos elevados [14, 12].

2.2 Modelos fundacionales: arquitectura y objetivos

Los modelos fundacionales sustituyen el entrenamiento específico por encoders preentrenados de forma auto-supervisada o multimodal sobre datasets visuales masivos. La arquitectura predominante es el Vision Transformer [22], que procesa la imagen como una secuencia de parches y aprende dependencias globales mediante mecanismos de atención. Los objetivos de preentrenamiento más extendidos son tres: el *masked image modeling*, en el que la red reconstruye parches ocultos a partir del contexto visible; la destilación auto-supervisada entre vistas; y la alineación contrastiva imagen-texto al estilo CLIP [23]. La adaptación posterior a tareas específicas opera por sondeo lineal sobre representaciones congeladas, ajuste fino supervisado, o transferencia directa zero-shot guiada por *prompts* en los modelos con rama lingüística.

2.3 Encoders visuales auto-supervisados

DINOv2 [17] es la referencia abierta de encoder visual auto-supervisado de propósito general, entrenado sobre ~ 142 millones de imágenes naturales sin etiquetas mediante destilación entre vistas. Sus representaciones transfieren a tareas de clasificación, recuperación y segmentación sobre dominios naturales y biomédicos con ajuste mínimo, y constituyen una base habitual para adaptación a dominios especializados.

En el dominio dermatológico, PanDerm [1] es un encoder visual ViT (Base ~ 86 M y Large ~ 307 M parámetros) entrenado sobre $\sim 2,1$ millones de imágenes dermatológicas en cuatro modalidades (fotografía corporal total, dermatoscopia, fotografía clínica e histopatología). El preentrenamiento utiliza *masked latent modeling*: la red reconstruye representaciones latentes de regiones ocultas en lugar de píxeles, con un modelo CLIP-Large congelado como *teacher*. Sus autores reportan una mejora media del $+10,2\%$ sobre el estado del arte previo en 28 tareas dermatológicas. La disponibilidad simultánea de pesos, código y benchmarks lo convierte en el primer modelo fundacional dermatológico verificable de forma independiente.

2.4 Modelos vision-lenguaje contrastivos

CLIP [23] establece el preentrenamiento contrastivo imagen-texto sobre 400 millones de pares de la web. El objetivo InfoNCE aproxima la imagen a su descripción dentro del lote y la aleja del resto. El espacio compartido habilita dos modos operativos: clasificación zero-shot guiada por *prompts* textuales (la clase ganadora es la de mayor similitud coseno entre el vector visual y los vectores textuales de las clases candidatas) y recuperación bidireccional imagen-texto sobre datasets precomputados.

SigLIP [24] sustituye la pérdida softmax de CLIP por una pérdida sigmoide que reduce la dependencia del tamaño de batch y escala con mejor estabilidad. Su variante Large (SO400M) dispone de embedding de 1152 dimensiones y ~ 878 M parámetros. BiomedCLIP [18] extiende el paradigma al dominio biomédico sobre PMC-15M (~ 15 millones de pares figura-leyenda de literatura científica); su cobertura dermatológica específica es limitada por el sesgo de selección del dataset.

En dermatología, Derm1M y la familia DermLIP [2] añaden la rama lingüística contrastiva al estado del arte de la disciplina. Derm1M reúne 1 029 761 pares imagen-texto sobre 403 563 imágenes únicas, organizados según una ontología jerárquica de cuatro niveles construida por dermatólogos. La familia DermLIP combina varios encoders visuales (PanDerm Base, ConvNeXt-Large) con varios encoders textuales (PubMedBERT extendido a 256 tokens, GPT-2 dermatológico con tokenizador de CLIP a 77 tokens). La configuración con mejor rendimiento reportada por los autores combina PanDerm Base como encoder visual y PubMedBERT como encoder textual, superando a BiomedCLIP en los benchmarks zero-shot evaluados.

La implementación operativa de la recuperación visual densa sobre datasets a gran escala requiere índices vectoriales optimizados para búsqueda aproximada del vecino más próximo. FAISS [27] y estructuras basadas en grafos del tipo Hierarchical Navigable Small Worlds permiten consultas en el orden de 10^2 milisegundos sobre datasets de centenares de miles a millones de *embeddings* precomputados.

2.5 Modelos integrados con zero-shot nativo

DermFM-Zero [3] integra el preentrenamiento visual auto-supervisado y la alineación contrastiva imagen-texto en un único modelo con capacidad zero-shot nativa. El entrenamiento se estructura en dos fases: *masked latent modeling* sobre tres millones de imágenes en la primera, y *bootstrapped contrastive learning* sobre un millón de pares texto-imagen en la segunda. El encoder textual es PubMedBERT. El modelo incorpora interpretabilidad emergente mediante Sparse Autoencoders [20], redes auxiliares que descomponen la representación interna en un diccionario disperso de direcciones asociables a conceptos clínicamente identificables. Sus autores reportan validación en tres *reader studies* con más de mil cien clínicos. Sus pesos no son públicos en la fecha de cierre del presente trabajo, lo que restringe su tratamiento a la discusión conceptual.

BLIP-2 [26] introduce un patrón arquitectónico distinto: conecta un encoder visual congelado con un modelo de lenguaje preentrenado mediante un módulo intermedio ligero (*Q-Former* o *Querying Transformer*) que transforma las representaciones visuales en una secuencia reducida de tokens interpretables por el modelo de lenguaje. Sólo el Q-Former se entrena. No existe, en la fecha de cierre, una adaptación pública específica de BLIP-2 al dominio dermatológico.

2.6 Segmentación promptable

SAM [25] establece el paradigma de segmentación promptable: produce máscaras a partir de *prompts* visuales (puntos, cajas, máscaras parciales) sobre imagen natural. Su preentrenamiento utiliza ~ 11 millones de imágenes con más de mil millones de máscaras generadas mediante un proceso semi-automatizado. SAM2 [19] amplía el enfoque al dominio del vídeo y mejora el rendimiento sobre imágenes estáticas.

La transferencia a dominios médicos requiere adaptación supervisada sobre conjuntos con máscaras binarias. La estrategia habitual combina un modelo SAM/SAM2 preentrenado con *fine-tuning* sobre ISIC2018 [10] y adaptadores de bajo rango (*Low-Rank Adaptation*, LoRA) [32], que incorporan un número reducido de parámetros entrenables manteniendo congelado el peso original del encoder visual. Esta estrategia reduce los requisitos de memoria y cómputo y permite la adaptación sobre hardware modesto.

2.7 Modelos de lenguaje multimodales generalistas

Los modelos de lenguaje multimodales preentrenados sobre datasets web masivos constituyen una referencia de comparación pertinente: GPT-4o (OpenAI), Gemini 2.5 Pro (Google DeepMind) y la familia MedGemma (versiones 4B Vision y 27B Text, Google). Su número de parámetros supera al de los encoders fundacionales específicos en uno o dos órdenes de magnitud. Su modo de uso característico es la inferencia guiada por *prompts* sin *fine-tuning* específico por tarea. Trabajos recientes documentan su uso conversacional para soporte al razonamiento clínico [6, 7]. Los modelos de acceso restringido (GPT-4o, Gemini) sólo se evalúan mediante API; MedGemma libera pesos y se evalúa en local.

2.8 Problemas metodológicos y guías de reporte

La aplicación de modelos fundacionales a imagen médica plantea tres problemas metodológicos directamente relevantes para el presente trabajo. El primero es la fuga de información entre conjuntos de evaluación y dataset de preentrenamiento. La construcción de Derm1M sobre fuentes web abiertas implica que datasets como Dermnet, HIBA o MSKCC pueden solaparse con su dataset de entrenamiento, lo que sesga al alza las métricas zero-shot reportadas. El segundo es la heterogeneidad taxonómica entre datasets, que impide comparaciones directas sin un paso explícito de armonización. El tercero es la disparidad de rendimiento por fototipo cutáneo, documentada en Fitzpatrick17k [14] y atendida específicamente por SkinCon [15] mediante anotación basada en 48 conceptos clínicos visuales.

Las guías de reporte recientes para inteligencia artificial en imagen médica —CLAIM [36] y la actualización TRIPOD+AI [37]— establecen la transparencia metodológica como condición de defensibilidad: cohorte, particiones, métricas, incertidumbre y limitaciones deben constar explícitamente en el informe completo. El reporte de pruebas estadísticas (intervalos de confianza por *bootstrap*, comparaciones múltiples, contrastes pareados de AUROC mediante el test de DeLong [33], y tamaños muestrales por subgrupo) constituye un requisito creciente en publicaciones de la disciplina.

2.9 Brechas operativas y posicionamiento

Cinco brechas operativas delimitan el espacio en el que el presente trabajo aporta evidencia empírica. **(i) Disponibilidad real de los modelos.** PanDerm y DermLIP liberan pesos y código; DermFM-Zero no lo hace. BiomedCLIP, DINOv2, SigLIP, SAM, SAM2 y BLIP-2 son abiertos. Los modelos generalistas ofrecen acceso parcial por API. Cualquier evaluación empírica externa queda condicionada por esta disponibilidad. **(ii) Benchmarks no homogéneos entre familias.** Los benchmarks reportados por los autores se construyen sobre subconjuntos derivados del propio preentrenamiento y aplican protocolos no equivalentes entre familias. La comparación bajo un mismo protocolo y un mismo conjunto de datasets externos no está documentada. **(iii) Heterogeneidad taxonómica.** La comparación inter-dataset exige un esquema de armonización que la literatura no proporciona de forma consolidada. **(iv) Concentración geográfica y lingüística.** Los datasets proceden mayoritariamente de instituciones de Australia, Estados Unidos y Europa central, y los encoders textuales se preentrenan sobre datasets en inglés. La disponibilidad de material clínico en español con texto narrativo asociado es marginal. La aparición reciente de datasets dermatológicos multimodales con *captions* clínicas ricas no reduce esta brecha, sino que la perfila con mayor nitidez. SkinCAP [16], por ejemplo, anota con descripciones clínicas en inglés 4000 imágenes procedentes de Fitzpatrick17k [14] y DDI [12] —dos de los datasets que este trabajo también evalúa—: enriquece con lenguaje natural recursos en inglés ya existentes, pero no aporta material en castellano, texto narrativo de un archivo clínico real ni independencia respecto a los datasets de preentrenamiento. Un recurso en español con texto narrativo de caso y particionado *case-aware* es, por tanto, complementario y no redundante frente a esa tendencia. **(v) Distancia entre evaluación experimental e integración hospitalaria.** La evaluación sobre *benchmarks* públicos no cubre las condiciones operativas asocia-

das al despliegue en un entorno sanitario real (hardware no estándar, restricciones de privacidad, trazabilidad, interacción con sistemas hospitalarios).

Por *benchmark independiente* se entiende aquí la evaluación de las familias de modelos bajo un protocolo común, ejecutada por un equipo ajeno al ecosistema que originó cada modelo y sobre datasets externos que ninguno de ellos seleccionó. La contribución empírica del trabajo, cuyo diseño se describe en el capítulo 3 y cuyos resultados se presentan en el capítulo 4, se dirige específicamente a estas cinco brechas: el benchmark homogéneo responde a (ii); la ontología jerárquica L1/L2/L3, a (iii); la auditoría de solapamiento por hash —reacción directa al problema de fuga y duplicación entre datasets de evaluación y preentrenamiento (sección 2.8)— a (i); el dataset DermapixelAI 1.0, a (iv); y la integración en el prototipo DermApIxel, a (v).

El alcance de esta revisión se acota deliberadamente a los modelos con pesos públicos como conjunto *evaluable*: los sistemas cerrados o de aparición muy reciente —DermFM-Zero, cuyos pesos no se liberan, o los modelos accesibles únicamente vía API— se posicionan conceptualmente pero no se evalúan de forma empírica directa. Esta decisión es coherente con la prioridad de reproducibilidad declarada en la sección 1.2 y se asume como un sesgo de selección explícito, no como una pretensión de exhaustividad sobre todo el ecosistema dermatológico.

MATERIALES Y MÉTODOS

Este capítulo describe lo necesario para reproducir el capítulo 4. Se presenta primero el material: los doce datasets externos, la ontología que los unifica bajo un vocabulario común y el dataset propio DermapixelAI 1.0. A continuación se enumeran los catorce modelos fundacionales evaluados, las dos líneas de base convolucionales y la infraestructura de cómputo. El capítulo cierra con los protocolos experimentales, las métricas, las pruebas estadísticas y las medidas de trazabilidad que permiten reconstruir cualquier cifra a partir de los artefactos publicados.

3.1 Datasets

La selección de datasets persigue medir la capacidad de generalización de los modelos entre modalidades de imagen, dominios clínicos y tareas. Por ello se emplean doce datasets externos públicos que cubren dermatoscopia, fotografía clínica, histopatología, análisis de equidad y aprendizaje basado en conceptos, agrupados por modalidad y finalidad. La tabla 3.1 resume sus características.

3. MATERIALES Y MÉTODOS

Cuadro 3.1: Datasets externos empleados en la evaluación. N_{test} : tamaño nominal del *split* de evaluación canónico; “Clases”: número de categorías diagnósticas o conceptos en la convención propia del dataset. El asterisco (*) marca los datasets con solapamiento documentado frente al dataset de preentrenamiento Derm1M (auditoría en sección 3.6.8). Las dos variantes de Derm7pt (clínica y dermatoscópica) comparten origen (Seven-Point Checklist) y se reportan como un único dataset en el conteo agregado de doce datasets externos.

Dataset	N_{test}	Clases	Modalidad	Uso
HAM10000 [8]	1 232	7	Dermoscopia	LP, FT, ZS, LLMs
BCN20000 [28]	1 242	9	Dermoscopia	LP
PAD-UFES-20 [11]	461	6	Clínica móvil	LP, FT
DDI [12]	137	2	Clínica	LP, FT, equidad
Dermnet [13]	4 002	23	Clínica	LP*
Derm7pt clínico [9]	168	2	Clínica	LP
Derm7pt dermo [9]	225	2	Dermoscopia	LP
HIBA	334	2	Dermoscopia	LP*
MSKCC	1 664	2	Dermoscopia	LP, FT*
WSI patches	12 354	16	Histopatología	LP
ISIC2018 [10]	2 594	binaria	Dermoscopia	Segmentación
Fitzpatrick17k [14]	16 577	114 + FP	Clínica	Equidad
SkinCon [15]	3 230	48 conc.	Clínica	CBM

Los datasets cubren las tres modalidades del diagnóstico dermatológico. La dermatoscopia (HAM10000, BCN20000, Derm7pt dermo, HIBA, MSKCC, ISIC2018) aporta imagen polarizada adquirida con dermatoscopio. La fotografía clínica (PAD-UFES-20, DDI, Dermnet, Derm7pt clínico) reproduce las condiciones de captura en consulta y atención primaria. La histopatología la aporta WSI patches, con 12 354 *parches* en 16 categorías. Dos datasets cumplen un papel específico: Fitzpatrick17k habilita el análisis de equidad, al anotar conjuntamente patología (114 categorías) y fototipo cutáneo (escala Fitzpatrick I-VI), y SkinCon aporta anotación densa de 48 conceptos clínicos visuales para los Concept Bottleneck Models. En todos los casos se respetan las particiones *train/val/test* canónicas de cada dataset, sin reasignación.

3.2 Ontología jerárquica L1/L2/L3

Comparar modelos entre datasets exige resolver un problema previo: cada conjunto usa su propia taxonomía, y esas taxonomías no son compatibles entre sí. Dos diagnósticos equivalentes pueden aparecer bajo denominaciones distintas o con niveles de granularidad diferentes. Para unificarlas se diseñó, en colaboración con la Dra. R. Taberner, una ontología jerárquica de tres niveles que actúa como vocabulario común a todos los protocolos del trabajo.

El nivel L1 (etiológico) reparte los diagnósticos en cuatro familias: patología inflamatoria, tumoral, infecciosa y genodermatosis. El nivel L2 (subcategoría clínica) contiene 43 entradas; cinco de ellas no se desagregan en L3 por considerarse ya suficientemente específicas (*Esclerosis tuberosa*, *Neurofibromatosis tipo 1*, *Incontinentia pigmenti*, *Queratoderma palmoplantar hereditaria* y *Pseudoxantoma elástico*). El nivel L3 (diagnóstico) contiene 367 entradas individuales, cada una con sus códigos SNOMED CT y CIE-10 para garantizar interoperabilidad con sistemas clínicos.

Once de los doce datasets se mapean a la ontología; SkinCon queda fuera por estar anotado con conceptos, no con diagnósticos. El conjunto armonizado resultante reúne 72 654 imágenes etiquetadas sobre vocabulario común.

3.3 Dataset DermapixelAI 1.0

DermapixelAI 1.0 es un dataset dermatológico en español construido en este trabajo a partir del archivo del blog Dermapixel de la Dra. R. Taberner; su construcción materializa el objetivo O2 (sección 1.4). A diferencia de los datasets públicos utilizados en la evaluación, DermapixelAI 1.0 incorpora texto narrativo clínico en español asociado a cada caso, lo que permite estudiar escenarios multimodales y de transferencia lingüística no cubiertos por los conjuntos de referencia internacionales. La elaboración comprende la extracción del material del archivo, la depuración, la estructuración que vincula para cada caso imagen y modalidad, metadatos clínicos y texto narrativo, y el etiquetado contra la ontología jerárquica L1/L2/L3; el pipeline completo se documenta en el Anexo C. La versión utilizada reúne 1 089 imágenes vinculadas a 669 casos clínicos, cada uno con su texto narrativo asociado (mediana de 223 palabras). Predomina la fotografía clínica (1 036 imágenes), con un subconjunto dermatoscópico reducido (49).

Las imágenes se etiquetan según la ontología L1/L2/L3 y se particionan bajo regla *case-aware* (891/157/41 imágenes; 538/100/31 casos), de modo que todas las imágenes de un mismo caso caen en el mismo *split* y no hay fuga entre conjuntos. Dos campos cuantifican la calidad del etiquetado: el 97,89% del dataset está mapeado a la ontología con revisión experta del vocabulario (`label_source = ontology`) y el 84,39% ha pasado además revisión visual caso-a-caso por la Dra. R. Taberner (`rosa_verified`). Ambas cifras no son intercambiables y se detallan, junto a un tercer campo de validación textual, en el Anexo C.

El dataset se distribuye bajo licencia CC-BY-NC-SA 4.0. Su pipeline de construcción, caracterización completa y datasheet figuran en el Anexo C, y el documento formal de entrega, en el Anexo E. La validación experimental sobre DermapixelAI 1.0 forma parte de los resultados de este trabajo: las secciones 4.10 y 4.11 del capítulo 4 evalúan sobre este dataset el sondeo lineal supervisado y la clasificación zero-shot multimodal en los tres niveles ontológicos.

3.4 Modelos evaluados

Los modelos incluidos en el estudio se seleccionan con el objetivo de representar los principales paradigmas actualmente utilizados en visión artificial y aprendizaje multimodal aplicado a dermatología. La comparación combina modelos específicamente entrenados para dermatología, modelos visuales generalistas de referencia, arquitecturas visión-lenguaje biomédicas y modelos multimodales de propósito general. Esta diversidad permite evaluar hasta qué punto la especialización dermatológica aporta ventajas medibles frente a modelos más generales y situar el rendimiento de los modelos fundacionales dermatológicos dentro del ecosistema actual de inteligencia artificial médica.

La tabla 3.2 resume los dieciséis sistemas evaluados: catorce modelos fundacionales —encoders visuales de dominio (PanDerm) y generales (DINOv2), modelos

visión-lenguaje (la familia DermLIP, BiomedCLIP y SigLIP), el segmentador promptable SAM2.1 y los modelos de lenguaje multimodales (GPT-4o, Gemini 2.5 Pro, MedGemma y BLIP-2)— y dos líneas de base de redes convolucionales supervisadas (ConvNeXt-Large y EfficientNetV2-Large), incluidas como referencia no fundacional frente a la que medir el valor del preentrenamiento.

Cuadro 3.2: Modelos evaluados.

Modelo	Familia	Parámetros	Referencia
PanDerm Base	Encoder visual derm.	~ 86 M	[1]
PanDerm Large	Encoder visual derm.	~ 307 M	[1]
DINOv2 ViT-L/14	Encoder visual general	~ 300 M	[17]
ConvNeXt-Large	ConvNet supervisada	~ 198 M	—
EfficientNetV2-Large	ConvNet supervisada	~ 118 M	—
DermLIP v1 (PubMedBERT)	Vision-lenguaje derm.	—	[2]
DermLIP v2 (PubMedBERT)	Vision-lenguaje derm.	—	[2]
DermLIP original (GPT-2)	Vision-lenguaje derm.	—	[2]
BiomedCLIP	Vision-lenguaje biomédico	—	[18]
SigLIP-Large SO400M	Vision-lenguaje general	~ 878 M	[24]
SAM2.1-Large (decoder FT)	Segmentación	~ 227 M	[19]
GPT-4o	LLM multimodal	no público	—
Gemini 2.5 Pro	LLM multimodal	no público	—
MedGemma 4B Vision	LLM multimodal biomédico	~ 4 B	—
MedGemma 27B Text+LoRA	LLM multimodal biomédico	~ 27 B	—
BLIP-2 (Q-Former)	Vision-lenguaje general	—	[26]

Los encoders difieren en la dimensión de sus *embeddings*: 768 en PanDerm Base; 1 024 en PanDerm Large y DINOv2 ViT-L/14; 1 152 en SigLIP-Large SO400M. La cifra de ~ 307 M parámetros de PanDerm Large es el valor nominal del ViT-L/16 publicado por sus autores. Al cargarlo como extractor de características y sustituir la cabeza original por la identidad quedan 303,3 M parámetros efectivos. Esta diferencia no afecta al rendimiento, porque la cabeza descartada no interviene en la inferencia. La familia DermLIP usa ViT-B/16 como encoder visual y dos encoders textuales alternativos: PubMedBERT extendido a 256 tokens (variantes v1 y v2) y GPT-2 con tokenizador de CLIP a 77 tokens (variante original). DermFM-Zero [3] se incluye en la discusión pero no en la evaluación empírica, ya que sus pesos no estaban disponibles a la fecha de cierre.

3.5 Infraestructura experimental

Todos los experimentos corren sobre una NVIDIA DGX Spark con chip Grace Hopper GB10, 128 GB de memoria unificada compartida entre CPU y GPU, Linux ARM aarch64 y CUDA 13.0. La precisión nativa es BF16 (*brain floating-point* de 16 bits) en inferencia y entrenamiento, con FP32 en optimizador y pérdida durante el ajuste fino (precisión mixta canónica). La memoria unificada es clave para este trabajo: permite mantener cargados modelos del orden de 55 GB en BF16 sin *offloading* ni cuantización, de modo que incluso MedGemma 27B opera localmente y sin comprimir. El software queda fijado en Python 3.12.3, PyTorch 2.11.0, timm 0.9.16, scikit-learn, transformers, open_clip, sam2, peft y FAISS [27].

Los tiempos de cálculo característicos sobre este equipo orientan sobre el coste de cada protocolo: un sondeo lineal completo de un encoder sobre un dataset estándar

tarda 1–3 minutos; el ajuste fino de PanDerm Large sobre HAM10000 (50 épocas con TTA), unas 15 horas; el ajuste fino del decodificador de SAM2.1-Large sobre ISIC2018 (50 épocas), unas 24 horas; la validación cruzada de cinco pliegues del modelo de segmentación, con la ablación de rango *LoRA* asociada, unas 18 horas; y el entrenamiento de un Sparse Autoencoder Large (16384 características), unas 4 horas.

3.6 Protocolos experimentales

Los protocolos experimentales se diseñan para caracterizar distintas capacidades de los modelos fundacionales dermatológicos bajo condiciones complementarias. Cada protocolo responde a una pregunta específica: el sondeo lineal evalúa la calidad intrínseca de las representaciones aprendidas durante el preentrenamiento; el ajuste fino cuantifica el rendimiento máximo alcanzable tras adaptación supervisada; la eficiencia en etiquetas analiza la cantidad de datos anotados necesaria para obtener resultados competitivos; la segmentación estudia la localización espacial de lesiones; la clasificación zero-shot mide la capacidad de transferencia sin entrenamiento específico; la comparación con modelos multimodales generalistas sitúa el rendimiento de los modelos especializados en el contexto actual de los grandes modelos fundacionales; la evaluación de equidad analiza el comportamiento sobre diferentes fototipos cutáneos; y la auditoría de solapamiento con Derm1M permite interpretar correctamente los resultados de transferencia y zero-shot. En conjunto, estos experimentos proporcionan una caracterización multidimensional de los modelos evaluados, más allá de una única métrica o tarea aislada. Todos los protocolos comparten la infraestructura (sección 3.5) y las semillas declaradas (sección 3.9), de modo que sus cifras son comparables entre sí.

3.6.1 Sondeo lineal (LP)

El sondeo lineal mide el valor de las representaciones de un encoder sin modificarlo: se congela el encoder y se entrena un clasificador lineal sobre los *embeddings* que extrae. La extracción usa la normalización canónica de cada modelo —parámetros ImageNet ($\mu = [0,485, 0,456, 0,406]$, $\sigma = [0,229, 0,224, 0,225]$) para PanDerm y DINOv2, y parámetros OpenAI CLIP para DermLIP, BiomedCLIP y SigLIP— y los vectores se guardan en disco para no recomputarlos entre experimentos. El clasificador es una regresión logística multinomial (L-BFGS, penalización L2 con $C = 1,0$, $\text{max_iter} = 5000$, $\text{random_state} = 42$) entrenada sobre las particiones canónicas de la tabla 3.1. El protocolo se aplica a PanDerm Base y Large, DINOv2, ConvNeXt-Large, EfficientNetV2-Large y la rama visual de DermLIP v2, BiomedCLIP y SigLIP-Large.

3.6.2 Ajuste fino supervisado (FT)

A diferencia del sondeo lineal, el ajuste fino sí modifica el encoder: entrena de forma conjunta el encoder visual y una cabeza de clasificación. La receta reproduce la del paper original de PanDerm [1], para que la comparación sea directa. El optimizador es AdamW (*weight decay* 0,05) con tasa de aprendizaje inicial $\eta = 5 \times 10^{-4}$, *cosine annealing* y *warmup* lineal de 10 épocas. La regularización combina *layer decay* 0,65, *drop-path* 0,2, *label smoothing* $\epsilon = 0,1$, Mixup $\alpha = 0,8$ y CutMix $\alpha = 1,0$, junto a un *weighted*

random sampler con pesos inversos a la frecuencia de clase. El entrenamiento dura 50 épocas en precisión mixta canónica, con las semillas de *torch*, *numpy* y *random* fijadas a 0. En la evaluación final sobre HAM10000 se añade *test-time augmentation* (TTA): se promedian los logits de 5 aumentaciones deterministas por imagen (volteos horizontal y vertical, rotación y *jitter* de color). El protocolo se aplica a PanDerm Base y Large sobre HAM10000, PAD-UFES-20, DDI y MSKCC.

3.6.3 Eficiencia en etiquetas

Este protocolo responde a una pregunta práctica: cuántas etiquetas hacen falta. Manteniendo el encoder congelado, se entrenan clasificadores lineales (misma configuración que el sondeo lineal, sección 3.6.1) sobre submuestreos estratificados del conjunto de entrenamiento de HAM10000 y PAD-UFES-20 al 1 %, 5 %, 10 %, 20 %, 50 % y 100 %. La estratificación preserva la proporción de clases en cada subconjunto y los submuestreos se generan con *random_state* = 42. PanDerm Large es el encoder principal; PanDerm Base se usa como referencia adicional sobre HAM10000.

3.6.4 Segmentación binaria de lesión

La segmentación constituye una tarea complementaria a la clasificación, ya que permite evaluar no solo si un modelo reconoce correctamente una lesión, sino también si es capaz de localizarla con precisión dentro de la imagen. En el contexto de los modelos fundacionales recientes basados en la familia *Segment Anything*, surge además una cuestión relevante: determinar hasta qué punto el rendimiento observado depende de la arquitectura utilizada, del preentrenamiento específico en imagen médica o del tamaño del *backbone* visual. Para responder a estas preguntas, la evaluación se organiza en dos protocolos complementarios y varios análisis de robustez.

Adaptación de SAM2.1-Large al dominio dermatológico. El primer protocolo adapta SAM2.1-Large mediante *fine-tuning* denso de su decodificador: se ajustan el decodificador de máscaras (*mask_decoder*) y el *promptable encoder*, mientras que el *image_encoder* (Hiera-Large preentrenado) permanece congelado, de modo que solo ~ 4,2 M parámetros resultan entrenables (~ 17 MB de *checkpoint*). La optimización usa AdamW ($\eta = 1 \times 10^{-4}$, *weight decay* 0,05) y una pérdida que combina *cross-entropy* y *Dice loss* sobre la máscara binaria; el *batch* es de 4 (limitado por el coste de SAM2.1-Large en BF16) y la normalización es uniforme ($\mu = \sigma = 0,5$ en los tres canales), según la convención de SAM2. Se contrastan 50 épocas (resultado de referencia) y 100 con *early stopping* sobre el Dice de validación. El entrenamiento es sobre ISIC2018 [10] y la transferencia fuera de dominio se evalúa sobre ISIC2017 y PH2 sin reentrenamiento. Como referencias no adaptadas se incluyen SAM2 *zero-shot* sin *fine-tuning* y un *Convolutional AutoEncoder* (CAE-seg) entrenado desde cero con idéntica pérdida y optimización.

Comparación controlada entre arquitecturas de segmentación. El segundo protocolo separa los tres factores que determinan el rendimiento —generación de arquitectura, preentrenamiento de dominio y tamaño de *backbone*— mediante una comparativa pareada de cinco arquitecturas de segmentación *promptable*: MedSAM2-tiny [39],

SAM2.1-tiny y SAM2.1-Large (familia SAM2 [19]), y SAM-Med2D [40] y MedSAM v1 [38] (familia SAM [25]). Todas se entrenan bajo un régimen común (*fine-tuning* denso del decodificador y el *promptable encoder*, encoder visual congelado, *prompt* de *bounding box* derivada de la máscara de referencia, AdamW $\eta = 1 \times 10^{-4}$, pérdida Dice+BCE, 30 épocas con *early stopping*) sobre un dataset dermatoscópico ampliado y deduplicado por hash MD5 de píxel (14 201 imágenes únicas de ISIC2018, ISIC2017, HAM10000-seg y PH2), y se evalúan sobre el mismo test canónico de ISIC2018 ($N = 1\,000$, blindado frente al entrenamiento). La significación de las diferencias de Dice se contrasta con el test de Wilcoxon pareado [34].

Análisis complementarios. Para interpretar correctamente las diferencias observadas entre arquitecturas, se realizan además tres análisis complementarios dirigidos a evaluar la contribución del *prompt*, la estabilidad del entrenamiento y la robustez de las predicciones. Para aislar la contribución del *prompt*, un control automático sin caja —una U-Net con codificador ResNet-101 preentrenado en ImageNet (51,5 M parámetros)— se entrena sobre el mismo dataset y se evalúa sin recibir *bounding box*. La estabilidad de la mejor configuración se estima mediante validación cruzada de cinco pliegues estratificados por dataset de origen y una ablación del rango de adaptación de bajo rango (*LoRA*, $r \in \{4, 8, 16, 32\}$); su robustez frente a la calidad del *prompt* se mide bajo perturbaciones controladas de la *bounding box* (desplazamiento de esquinas y cambio de escala), y la confianza de las máscaras se calibra *a posteriori* mediante *temperature scaling*. Por último, el techo de la métrica se contextualiza frente al acuerdo inter-anotador del propio dataset.

3.6.5 Clasificación zero-shot multimodal

La clasificación zero-shot constituye una de las capacidades más características de los modelos fundacionales multimodales. A diferencia de los enfoques supervisados, estos modelos pueden realizar tareas de clasificación sin haber sido entrenados específicamente sobre las clases objetivo, utilizando únicamente descripciones textuales de las categorías candidatas. Evaluar esta capacidad permite estimar el grado de generalización adquirido durante el preentrenamiento y determinar hasta qué punto el conocimiento dermatológico puede transferirse a nuevos conjuntos de datos sin adaptación adicional.

El zero-shot mide qué pueden clasificar los modelos vision-lenguaje sin ningún entrenamiento específico, aprovechando su espacio compartido imagen-texto. Cada clase candidata se formula como una o varias frases de plantilla, que el encoder textual codifica y —cuando hay varias por clase— promedia en un único vector. La imagen se codifica con el encoder visual y gana la clase de mayor similitud coseno. Sobre HAM10000 se comparan tres formulaciones de *prompt*: (i) genéricos en inglés, una plantilla por clase (p. ej. “*a dermoscopic image of a melanoma*”); (ii) el conjunto A3 del paper de Derm1M [2], con varias plantillas por clase; y (iii) una versión enriquecida de A3 con descriptores clínicos (modalidad, localización, criterios visuales). El conjunto A3 es la estrategia de *prompting* propuesta en Derm1M [2] que sustituye el nombre simple de cada enfermedad por un conjunto de descripciones clínicas y visuales más completas: en lugar de representar una clase únicamente con la palabra *melanoma*, emplea varias frases que describen sus características diagnósticas, lo que

produce representaciones textuales más informativas y mejora el rendimiento *zero-shot*. Para caracterizar la sensibilidad al tokenizador, el protocolo se ejecuta con los dos tokenizadores de la familia DermLIP: PubMedBERT a 256 tokens (v1/v2) y GPT-2 con tokenizador de CLIP a 77 tokens (original). Sobre HIBA, MSKCC, DDI y Derm7pt clínico se corre la versión binaria melanoma/no-melanoma con *prompts* genéricos y A3. De este modo, el protocolo permite aislar el efecto de tres componentes fundamentales del rendimiento *zero-shot*: el modelo multimodal utilizado, la formulación textual de las clases y el tokenizador empleado por la rama lingüística.

3.6.6 Comparación con modelos de lenguaje multimodales

La rápida evolución de los modelos multimodales de propósito general plantea una cuestión relevante para la dermatología computacional: determinar si los grandes modelos fundacionales capaces de procesar simultáneamente imagen y texto pueden competir con modelos especializados entrenados específicamente para imagen dermatológica. Este protocolo evalúa dicha hipótesis comparando varios modelos multimodales de última generación frente a los encoders dermatológicos analizados en las secciones anteriores bajo un escenario común de clasificación diagnóstica. La comparación contrapone así dos paradigmas —la especialización dermatológica explícita de los encoders de las secciones anteriores frente a la escala de los grandes modelos generalistas—, con los modelos biomédicos generales (MedGemma) en una posición intermedia, lo que permite contrastar la contribución relativa de la especialización de dominio frente a la escala del preentrenamiento.

Para situar a los encoders frente a los grandes modelos generalistas, el protocolo evalúa GPT-4o (API OpenAI), Gemini 2.5 Pro (API Google), MedGemma 4B Vision (local) y MedGemma 27B Text (local en BF16) sobre el mismo *split* de test de HAM10000 (1 232 imágenes) usado en sondeo lineal y ajuste fino. El *prompt* clínico estandarizado (unas 300 palabras) plantea la tarea como apoyo al diagnóstico —no sustitución del juicio clínico—, presenta las siete categorías de HAM10000 con una descripción breve y pide el diagnóstico más probable con razonamiento estructurado. La etiqueta se extrae por *parsing* determinista que mapea el nombre del diagnóstico al código de HAM10000; las respuestas no mapeables (menos del 1 % en todos los modelos) cuentan como incorrectas. El modo principal es *zero-shot*; para MedGemma 27B se evalúa además una variante ajustada con LoRA ($r = 8$) sobre el entrenamiento de HAM10000.

3.6.7 Evaluación de equidad por fototipo

La equidad constituye una dimensión relevante en la evaluación de sistemas de inteligencia artificial aplicados a dermatología. Diversos estudios han señalado que muchos conjuntos de entrenamiento presentan una representación desigual de los distintos fototipos cutáneos, lo que puede traducirse en diferencias de rendimiento entre grupos poblacionales. En consecuencia, además de evaluar la precisión global de los modelos, resulta necesario analizar si su comportamiento se mantiene estable a lo largo de todo el espectro de fototipos definido por la escala de Fitzpatrick.

Este protocolo mide si el rendimiento se mantiene entre fototipos cutáneos. Cinco encoders (PanDerm Large, PanDerm Base, la rama visual de DermLIP v2, DINOv2 ViT-L/14 y BiomedCLIP) se evalúan sobre Fitzpatrick17k completo (16577 imágenes, 114

patologías, 6 fototipos I-VI) por sondeo lineal (configuración de sección 3.6.1, con la normalización canónica de cada modelo). Se reportan dos formulaciones: clasificación a 114 patologías (grano fino) y a 3 clases de malignidad (benigno / no neoplásico / maligno), esta última habitual en estudios de equidad sobre Fitzpatrick17k. Las métricas se calculan por subgrupo sobre los seis fototipos, y la equidad se resume con la brecha entre los extremos $\text{Gap}_{I \rightarrow VI} = \text{BAcc}_I - \text{BAcc}_{VI}$. La brecha entre fototipos extremos resume de forma sencilla la estabilidad del rendimiento entre grupos; su interpretación, no obstante, debe realizarse conjuntamente con la exactitud global, ya que una diferencia reducida puede reflejar tanto un comportamiento equitativo como un rendimiento uniformemente bajo en todos los subgrupos. El experimento se verifica re-ejecutando el sondeo sobre PanDerm Large y comprobando coincidencia hasta cuatro decimales con el resultado original.

3.6.8 Auditoría de solapamiento con Derm1M

La interpretación de los resultados zero-shot requiere verificar previamente la independencia entre los conjuntos de evaluación y los datos utilizados durante el preentrenamiento. Si un modelo ha visto durante su entrenamiento imágenes posteriormente utilizadas como test, las métricas obtenidas pueden reflejar memorización parcial del conjunto de evaluación y no capacidad real de generalización. Por este motivo, se realiza una auditoría sistemática de solapamiento entre los datasets evaluados y Derm1M, principal dataset de preentrenamiento de la familia PanDerm y DermLIP.

La auditoría lo cuantifica: cada imagen se reduce a su hash MD5 (biblioteca estándar de Python) y la intersección de hashes identifica las imágenes presentes en ambos datasets. La cardinalidad se reporta por dataset en el capítulo 4. Se auditan los doce datasets externos, salvo SkinCon (no evaluado sobre clases diagnósticas).

El alcance de esta auditoría se declara con precisión. El hash MD5 detecta coincidencias *exactas* a nivel de bytes y, por tanto, identifica duplicados idénticos, pero no *near-duplicates*—recortes, reescalados, recompresiones o alteraciones leves de una misma imagen—. La auditoría sostiene, en consecuencia, la ausencia de *solapamiento exacto*, no la ausencia completa de contaminación visual. Esta elección prioriza la trazabilidad y el bajo coste del hash exacto frente a la cobertura perceptual; el *perceptual hashing* o la comparación por *embeddings* visuales constituyen su extensión natural, y las implicaciones de este alcance acotado para la interpretación de los resultados se retoman en la sección 6.2.3.

3.7 Métricas

Ninguna métrica individual captura por sí sola todos los aspectos relevantes del rendimiento de un modelo de inteligencia artificial. En problemas dermatológicos, caracterizados por distribuciones de clases desbalanceadas, diferentes niveles de granularidad diagnóstica y requisitos clínicos diversos, resulta necesario combinar métricas complementarias que evalúen discriminación, robustez, concordancia, equidad y viabilidad operativa. Por este motivo, el presente trabajo reporta un conjunto de métricas específicas para clasificación, segmentación, equidad y rendimiento computacional.

Clasificación. La métrica principal es la *Balanced Accuracy* (BAcc, promedio del *recall* por clase): se adopta porque asigna el mismo peso a todas las clases con independencia de su frecuencia, lo que evita que las categorías mayoritarias dominen la evaluación en los datasets desbalanceados de este trabajo. La *accuracy* acompaña como referencia comparativa entre modelos sobre la misma distribución. Se reportan además la F1 ponderada (media armónica de precisión y *recall*, pesada por frecuencia de clase), la AUROC *one-vs-rest* (`multi_class='ovr'` en `scikit-learn`, promediada sobre clases) y el coeficiente kappa de Cohen, que corrige la concordancia por azar. *Recall@k*—presencia de la etiqueta verdadera entre las k primeras posiciones del ranking— se reporta específicamente para melanoma sobre HAM10000.

Segmentación. La calidad de las máscaras predichas se evalúa mediante el coeficiente Dice (DSC) y la intersección sobre unión (IoU), dos métricas estándar que cuantifican el grado de solapamiento entre la segmentación automática y la máscara de referencia: $DSC = 2|P \cap G|/(|P| + |G|)$ e $IoU = |P \cap G|/|P \cup G|$, con P la máscara predicha y G la de referencia.

Equidad. BAcc por subgrupo Fitzpatrick (I-VI) sobre la formulación de tres clases de malignidad, y *gap* $Gap_{I-VI} = BAcc_I - BAcc_{VI}$. Un valor próximo a cero indica rendimiento comparable entre fototipos extremos; su interpretación conjunta con la BAcc global se discute en la sección 3.6.7.

Operativas. Además del rendimiento predictivo, se evalúa el coste computacional asociado a cada modelo, que permite valorar la viabilidad de un despliegue en entornos clínicos con recursos limitados: latencia por consulta en milisegundos (inferencia más posproceso) y huella de memoria (VRAM en gigabytes, BF16), medidas sobre la infraestructura de sección 3.5.

Agregación entre datasets. Algunas vistas panorámicas del capítulo 4 reportan la media de una métrica sobre varios datasets externos. Dicha media se interpreta como *brújula descriptiva*—resume una tendencia sobre conjuntos de distinta taxonomía, modalidad y prevalencia—, no como un marcador conmensurable que defina un ranking absoluto entre modelos: HAM10000, DDI, PAD-UFES-20 o Dermnet no son objetos perfectamente comparables. Por ello toda cifra agregada se acompaña siempre del desglose por dataset y por nivel ontológico, que es la base sobre la que se sostienen las conclusiones comparativas; la media entre tareas heterogéneas se usa para describir, no para ordenar.

3.8 Pruebas estadísticas

La comparación de modelos no debe limitarse a la observación de diferencias en las métricas de rendimiento. Incluso cuando un modelo obtiene una puntuación superior a otro, resulta necesario determinar si dicha diferencia refleja una ventaja real o puede explicarse por la variabilidad inherente de la muestra utilizada para la evaluación. Esta consideración es especialmente relevante en dermatología, donde los conjuntos de

datos suelen presentar tamaños moderados, distribuciones de clases desequilibradas y una elevada heterogeneidad clínica.

Con este objetivo, el presente trabajo incorpora un protocolo estadístico explícito, en línea con las guías de reporte para inteligencia artificial en imagen médica (CLAIM [36] y TRIPOD+AI [37]), basado en la estimación de intervalos de confianza mediante *bootstrap*, la comparación formal de curvas ROC mediante el test de DeLong y el control del riesgo de falsos positivos en escenarios con múltiples comparaciones. De este modo, los resultados presentados en el capítulo 4 pueden interpretarse como evidencia estadística reproducible y no únicamente como un ordenamiento de modelos derivado de una realización concreta de los datos.

La incertidumbre de cada métrica principal se cuantifica mediante *bootstrap* no paramétrico con 1 000 remuestreos del conjunto de evaluación, estratificado por clase, del que se derivan los intervalos de confianza al 95 %. No requiere asumir normalidad ni varianza conocida, lo que es necesario sobre los conjuntos de test reducidos y desbalanceados de este trabajo, donde la aproximación asintótica de los estimadores no es fiable.

Las comparaciones de AUROC entre dos modelos sobre el mismo conjunto emplean el test de DeLong [33]. Su motivación es metodológica: ambos modelos se evalúan sobre las mismas imágenes, de modo que sus curvas ROC están correlacionadas; tratar las dos AUROC como muestras independientes subestima la varianza del contraste y sobrestima su significación. DeLong estima esa covarianza de forma no paramétrica y produce un contraste pareado válido. Se aplica a los contrastes pareados entre los cinco encoders sobre Fitzpatrick17k (sección 4.9.1, tabla B.10).

Los p -valores se reportan como nominales y, de forma complementaria, bajo corrección de Bonferroni para el número de comparaciones. Exponer ambos es intencionado: la corrección controla la tasa de falsos positivos a costa de potencia estadística, y mostrar el valor nominal junto al corregido permite al lector juzgar la robustez de cada contraste sin imponer una única política de corrección. Dada la magnitud de las diferencias observadas (con p varios órdenes por debajo de 0,05), las conclusiones principales se mantienen bajo cualquier corrección estándar. Los tamaños muestrales por subgrupo del experimento de equidad se reportan junto a sus cifras en el capítulo 4.

El alcance de este protocolo estadístico es, no obstante, heterogéneo entre bloques experimentales, y conviene declararlo de forma explícita. El contraste pareado de DeLong y la corrección por comparaciones múltiples se aplican donde la comparación entre modelos es el objeto central —el ranking de encoders en detección de malignidad (sección 4.9.1)—; la estimación por *bootstrap* acompaña a las métricas principales sobre DermapixelAI 1.0 y a la validación cruzada de segmentación. Otros bloques —el sondeo lineal sobre los datasets externos, la eficiencia en etiquetas y la equidad por fototipo— se reportan como estimaciones puntuales bajo semilla única (sección 6.3.1). En consecuencia, la fuerza de las afirmaciones comparativas se modula según el cierre estadístico disponible: se sostienen como patrones cualitativos robustos cuando la magnitud del efecto excede holgadamente la variabilidad esperable, y se enuncian con la cautela correspondiente cuando el contraste formal queda fuera del alcance del trabajo.

3.9 Trazabilidad y reproducibilidad

La reproducibilidad no constituye un complemento documental, sino una condición necesaria para la validación independiente de los resultados. Un experimento cuyos resultados no pueden reconstruirse de forma consistente resulta difícil de verificar y limita la confianza en las conclusiones derivadas. El trabajo se diseña, por tanto, para que cualquier número del capítulo 4 se reconstruya a partir de artefactos persistentes y no de la memoria de una ejecución concreta. Tres mecanismos articulan esta garantía.

El primero es el determinismo de la ejecución. Las semillas aleatorias se fijan a 0 para `torch`, `numpy` y `random` en *fine-tuning* y segmentación, y a 42 en `random_state` para los protocolos basados en `scikit-learn` (sondeo lineal, eficiencia en etiquetas, equidad). El entorno queda fijado a las versiones de sección 3.5, y cualquier desviación se documenta en el experimento afectado. Por último, se deshabilita la telemetría externa y se fija explícitamente el dispositivo de ejecución para evitar variaciones no controladas del entorno experimental.

El segundo mecanismo es la persistencia de las salidas. Los resultados numéricos se vuelcan a ficheros CSV o JSON con esquema estable, lo que permite reconstruir cualquier tabla o figura del capítulo 4 sin reejecutar nada, y los mapeos de etiquetas nativas a la ontología L1/L2/L3 se mantienen fijos entre experimentos. El tercero es la integridad de la cadena de cómputo: cuando un experimento toma como entrada la salida de otro —por ejemplo, los *embeddings* del sondeo lineal alimentan la rama visual del zero-shot—, la identidad de esa entrada se preserva mediante hash MD5 del fichero. El encadenamiento por hash convierte el conjunto de experimentos en un grafo de dependencias verificable: cualquier alteración silenciosa de una entrada intermedia invalidaría el hash y sería detectable, lo que protege la cadena de evidencia frente a la deriva de datos entre etapas dependientes. El listado completo de tareas reproducibles, con sus comandos, ficheros de salida y *checkpoints*, figura en el Anexo A.

CAPÍTULO 4

RESULTADOS

Este capítulo presenta los resultados de la evaluación de modelos fundacionales dermatológicos y de las contribuciones originales del trabajo, que concretan sus objetivos formales (sección 1.4). La secuencia es acumulativa: se verifica primero la independencia entre los conjuntos de evaluación y el preentrenamiento (sección 4.1); sobre esa base se estudia la transferencia supervisada (sondeo lineal, ajuste fino, eficiencia en etiquetas), las tareas de segmentación, clasificación *zero-shot* y razonamiento multimodal, y los aspectos de equidad y seguridad diagnóstica; y, finalmente, las contribuciones propias sobre DermapixelAI 1.0 y Dermapixel R0, la interpretabilidad mediante *Sparse Autoencoders* y una síntesis comparativa. En conjunto, los experimentos permiten analizar el impacto del preentrenamiento específico de dominio, las distintas estrategias de adaptación y el papel de los datos en la transferencia de modelos fundacionales a un entorno clínico dermatológico en castellano. La figura 4.1 resume esta organización.




Figura 4.1: Organización experimental del capítulo: de la validación de la independencia de los datos a las contribuciones propias en castellano.

4.1 Validez experimental: auditoría de solapamiento con Derm1M

La validez de toda comparación de transferencia y *zero-shot* de este capítulo depende de que los conjuntos de test no se solapen con el dataset de preentrenamiento; por ello el capítulo abre comprobándolo. La auditoría intersecta los hashes MD5 de los doce datasets externos con los 415451 hashes únicos de la fracción accesible de Derm1M e identifica un único dataset con solapamiento exacto: **Dermnet**, cuyas 18302 imágenes están todas contenidas en Derm1M (100%). Los once datasets restantes no arrojan ninguna coincidencia. En particular, HIBA y MSKCC —cuyo origen en el ISIC archive motivaba una sospecha de procedencia— presentan 0 coincidencias MD5, por lo que esa sospecha no se traduce en solapamiento exacto. El resultado completo por dataset figura en el Anexo A.

El solapamiento de Dermnet no invalida las cifras que se reportan en la sección 4.2 para PanDerm, DINOv2, ConvNeXt-Large, EfficientNetV2-Large y SigLIP-Large, cuyo preentrenamiento no incluye Derm1M. Sí condiciona, en cambio, la interpretación de las cifras *zero-shot* de la familia DermLIP sobre Dermnet (sección 4.7), ya que DermLIP se entrenó sobre Derm1M y vio durante el preentrenamiento la totalidad de ese conjunto.

4.2 Reproducción de PanDerm: sondeo lineal sobre diez datasets

Esta sección evalúa si las representaciones de un modelo fundacional dermatológico, sin reajustar el encoder, clasifican lesiones en datasets externos no vistos. El codificador de mayor capacidad transfiere de forma robusta entre datasets, con ventaja creciente en los escenarios de mayor heterogeneidad de adquisición y complejidad taxonómica, como cuantifican los diez datasets externos a continuación.

4.2. Reproducción de PanDerm: sondeo lineal sobre diez datasets

La tabla 4.1 aplica este protocolo a PanDerm Base y Large sobre los diez datasets externos contrastados, conforme a sección 3.6.1. Se reportan cinco métricas: *accuracy* (Acc), *balanced accuracy* (BAcc), AUROC *one-vs-rest*, F1 ponderada (W-F1) y coeficiente kappa de Cohen.

Cuadro 4.1: Sondeo lineal con PanDerm Base y Large sobre diez datasets externos. El asterisco (*) marca Dermnet, el único dataset con solapamiento exacto frente a Derm1M (100 % por hash MD5; sección 4.1). Mejores valores por dataset y métrica en negrita.

Dataset	Modelo	Acc	BAcc	AUROC	W-F1	Kappa
HAM10000	Base	0,853	0,381	0,892	0,829	0,709
HAM10000	Large	0,888	0,575	0,954	0,880	0,814
BCN20000	Base	0,659	0,292	0,855	0,615	0,447
BCN20000	Large	0,702	0,382	0,903	0,676	0,527
PAD-UFES-20	Base	0,725	0,510	0,913	0,692	0,369
PAD-UFES-20	Large	0,772	0,642	0,949	0,760	0,527
Dermnet*	Base	0,450	0,381	0,888	0,432	0,437
Dermnet*	Large	0,550	0,495	0,931	0,540	0,555
WSI patches	Base	0,781	0,640	0,976	0,774	0,842
WSI patches	Large	0,868	0,792	0,991	0,871	0,896
DDI	Base	0,847	0,714	0,827	0,836	0,482
DDI	Large	0,847	0,764	0,860	0,846	0,535
Derm7pt clín.	Base	0,762	0,675	0,808	0,736	0,397
Derm7pt clín.	Large	0,798	0,732	0,869	0,784	0,506
Derm7pt dermo	Base	0,818	0,749	0,841	0,811	0,528
Derm7pt dermo	Large	0,836	0,766	0,858	0,829	0,570
HIBA	Base	0,883	0,595	0,894	0,853	0,275
HIBA	Large	0,904	0,701	0,942	0,892	0,494
MSKCC	Base	0,721	0,654	0,746	0,720	0,309
MSKCC	Large	0,746	0,644	0,751	0,732	0,316
<i>Media</i>	Base	0,750	0,559	0,865	0,730	—
<i>Media</i>	Large	0,791	0,649	0,901	0,781	—

Sobre los diez datasets evaluados (estimación de semilla única, sección 3.8), PanDerm Large supera a PanDerm Base en cuatro de las cinco métricas, con mejoras medias de +4,1 pp en *accuracy*, +9,0 pp en *balanced accuracy* y +3,6 pp en AUROC (figura 4.2); la única excepción es la BAcc de MSKCC (−1,0 pp).

Las mayores ganancias aparecen en Dermnet, WSI patches y PAD-UFES-20 —los escenarios más heterogéneos del benchmark—, lo que sugiere que el aumento de capacidad del encoder beneficia especialmente la generalización compleja. Dermnet, no obstante, está íntegramente contenido en Derm1M (100 % por hash MD5; sección 4.1) y su cifra debe leerse con ese *caveat*.

4. RESULTADOS




Figura 4.2: Sondeo lineal con PanDerm Base y Large sobre los diez datasets externos contrastados. Diferencia absoluta en BAcc (+9,0 pp de promedio) y AUROC (+3,6 pp de promedio) a favor de PanDerm Large.

En conjunto, estos resultados indican que las representaciones aprendidas por la familia PanDerm transfieren de forma consistente más allá del dataset de origen, a múltiples cohortes externas, modalidades de imagen y condiciones de adquisición. La ventaja de PanDerm Large se observa en las tres modalidades evaluadas —clínica, dermatoscópica e histopatológica—, lo que sugiere que el aumento de capacidad del encoder produce representaciones transferibles más allá de una única modalidad de adquisición. Las medias por columna agregan datasets de taxonomía, modalidad y prevalencia heterogéneas, por lo que se interpretan como brújula descriptiva de la tendencia y no como marcador absoluto del mejor modelo (sección 3.7).

4.3 Benchmark comparativo entre familias

Para distinguir si la ventaja de PanDerm Large refleja el preentrenamiento dermatológico o una mera comparación favorable frente a su versión Base, se sitúa frente a familias con filosofías de aprendizaje distintas: arquitecturas convolucionales supervisadas, modelos auto-supervisados generalistas y sistemas visión-lenguaje a gran escala. La tabla 4.2 compara cinco modelos representativos sobre HAM10000, PAD-UFES-20 y DDI bajo el mismo protocolo de sondeo lineal.

Cuadro 4.2: Benchmark comparativo bajo sondeo lineal sobre HAM10000, PAD-UFES-20 y DDI. Mejor valor por columna en negrita.

Modelo	Tipo	Params	HAM Acc	HAM AUROC	PAD Acc	PAD AUROC	DDI AUROC
ConvNeXt-Large	ConvNet sup.	197 M	0,883	0,967	0,668	0,894	0,774
EfficientNetV2-Large	ConvNet sup.	118 M	0,860	0,950	0,690	0,895	0,766
DINOv2 ViT-L/14	SSL general	307 M	0,744	0,847	—	—	—
PanDerm Large	SSL derm.	307 M	0,888	0,954	0,772	0,949	0,860
SigLIP-Large SO400M	Vis-leng. gen.	400 M	0,900	0,971	0,718	0,903	0,793

La tabla 4.3 cuantifica la ventaja de PanDerm Large sobre la mejor CNN supervisada en cada dataset.

4.3. Benchmark comparativo entre familias

Cuadro 4.3: PanDerm Large frente a la mejor CNN supervisada (la mejor de ConvNeXt-L y EfficientNetV2-L para cada métrica).

Dataset	CNN Acc	PanDerm Acc	Δ Acc (pp)	CNN AUROC	PanDerm AUROC	Δ AUROC (pp)
HAM10000	0,883	0,888	+0,5	0,967	0,954	-1,3
PAD-UFES-20	0,690	0,772	+8,2	0,895	0,949	+5,4
DDI	0,818	0,847	+2,9	0,774	0,860	+8,6

PanDerm Large supera en accuracy a la mejor CNN supervisada sobre los tres datasets (figura 4.3), con ventaja no uniforme: +0,5 pp en HAM10000 (dermatoscopia estandarizada) frente a +8,2 pp en PAD-UFES-20 (fotografía móvil) y +2,9 pp en DDI. HAM10000 constituye una excepción parcial: SigLIP-Large SO400M obtiene la mejor accuracy y AUROC, y ConvNeXt-Large supera ligeramente a PanDerm Large en AUROC (-1,3 pp). Este comportamiento sugiere que los beneficios del preentrenamiento de dominio son menores en entornos dermatoscópicos altamente estandarizados; en cambio, PanDerm Large encabeza en PAD-UFES-20 y DDI, los datasets clínicos más alejados del dominio web.




Figura 4.3: Benchmark comparativo bajo sondeo lineal sobre HAM10000, PAD-UFES-20 y DDI. ConvNeXt-Large supera a PanDerm Large en AUROC sobre HAM10000 (-1,3 pp); PanDerm Large domina sobre PAD-UFES-20 (+8,2 pp Acc) y DDI (+8,6 pp AUROC).

Estos resultados muestran que no existe una jerarquía universal entre familias de modelos: los sistemas visión-lenguaje generalistas pueden igualar o superar a los especializados en escenarios dermatoscópicos muy estandarizados, mientras que los modelos dermatológicos mantienen una ventaja clara cuando aumenta la variabilidad clínica y de adquisición. El preentrenamiento de dominio ofrece, por tanto, una ventaja *creciente* con la heterogeneidad del dominio, no una superioridad absoluta —lectura que anticipa la tesis de especialización por tarea desarrollada en el capítulo 5 (sección 5.1.1).

4.4 Ajuste fino supervisado

Esta sección delimita cuándo el ajuste fino del encoder mejora sobre la representación congelada y cuándo es contraproducente, decisión central para los datasets clínicos pequeños. El ajuste fino mejora con una cantidad moderada o elevada de datos de entrenamiento y puede degradar el rendimiento bajo baja disponibilidad de muestras. La tabla 4.4 lo concreta comparando el sondeo lineal con el ajuste fino supervisado de PanDerm Base sobre cuatro datasets de tamaño dispar, con la configuración descrita en sección 3.6.2. Sobre HAM10000 se añade además *test-time augmentation* con cinco aumentaciones deterministas.

Cuadro 4.4: Sondeo lineal (LP) frente a ajuste fino (FT) con PanDerm Base. Δ Bacc en puntos porcentuales respecto al LP.

Dataset	Modo	Acc	Bacc	AUROC	W-F1	Δ Bacc
HAM10000	LP	0,853	0,381	0,892	0,829	—
HAM10000	FT	0,920	0,852	0,978	0,923	+47,1
PAD-UFES-20	LP	0,725	0,510	0,913	0,692	—
PAD-UFES-20	FT	0,755	0,704	0,935	0,757	+19,4
DDI	LP	0,847	0,714	0,827	0,836	—
DDI	FT	0,774	0,693	0,682	0,780	-2,1
MSKCC	LP	0,721	0,654	0,746	0,720	—
MSKCC	FT	0,731	0,684	0,719	0,735	+3,0

El ajuste fino mejora sustancialmente el rendimiento en HAM10000 (+47,1 pp Bacc) y PAD-UFES-20 (+19,4 pp), especialmente sobre las clases minoritarias (*melanoma, akiec, df, vasc*), responsables de la baja *balanced accuracy* del sondeo lineal. Sin embargo, el beneficio desaparece cuando disminuye la disponibilidad de datos: DDI muestra una degradación global compatible con sobreajuste y MSKCC sólo obtiene mejoras marginales. En conjunto, los resultados sugieren que el ajuste fino resulta ventajoso cuando existe una cantidad moderada o elevada de ejemplos etiquetados, mientras que las representaciones congeladas son más robustas en escenarios de datos limitados.

Este resultado justifica la exploración posterior de técnicas de adaptación eficiente de parámetros (PEFT), que buscan capturar parte de las ventajas del ajuste fino reduciendo el riesgo de sobreajuste en datasets clínicos de tamaño moderado (sección 4.12). Cabe asimismo cuantificar cuántas etiquetas son realmente necesarias para aprovechar estas representaciones, objeto de la sección siguiente.

4.5 Eficiencia en etiquetas

Se mide el rendimiento de PanDerm Large bajo submuestreos estratificados crecientes del conjunto de entrenamiento, dado que el etiquetado experto es el principal cuello de botella en dermatología. Una fracción mínima del conjunto basta para casi saturar el rendimiento. La tabla 4.5 lo cuantifica con submuestreos al 1 %, 5 %, 10 %, 20 %, 50 % y 100 % sobre HAM10000 y PAD-UFES-20.

Cuadro 4.5: Eficiencia en etiquetas (sondeo lineal con PanDerm Large). N_{train} : tamaño efectivo del subconjunto de entrenamiento. Mejor valor por columna en negrita.

% entrenam.	N_{train}	Acc	BAcc	AUROC	W-F1
<i>HAM10000</i>					
1 %	82	0,850	0,406	0,918	0,828
5 %	410	0,870	0,481	0,932	0,855
10 %	820	0,875	0,480	0,939	0,863
20 %	1 641	0,882	0,547	0,951	0,873
50 %	4 103	0,894	0,589	0,952	0,887
100 %	8 207	0,888	0,575	0,954	0,880
<i>PAD-UFES-20</i>					
1 %	14	0,740	0,599	0,907	0,727
5 %	74	0,751	0,632	0,919	0,742
10 %	149	0,738	0,593	0,923	0,724
20 %	298	0,748	0,587	0,931	0,728
50 %	746	0,757	0,611	0,941	0,742
100 %	1 493	0,772	0,642	0,949	0,760

La AUROC muestra una saturación temprana en ambos datasets. En HAM10000, el 1 % de las imágenes de entrenamiento (82) ya recupera una AUROC de 0,918, mientras que el 5 % (410) alcanza el 97,7 % del rendimiento máximo observado. Un comportamiento similar aparece en PAD-UFES-20, donde 14 imágenes permiten recuperar el 95,5 % de la AUROC final. La *balanced accuracy*, en cambio, continúa mejorando con el aumento del conjunto de entrenamiento, lo que refleja una mayor sensibilidad a las clases minoritarias.

Este comportamiento sugiere que gran parte del conocimiento visual relevante ya ha sido adquirido durante el preentrenamiento, de modo que el aprendizaje supervisado posterior actúa principalmente como un mecanismo de calibración de la frontera de decisión: la mayor parte de la capacidad discriminativa reside ya en el encoder preentrenado, lo que reduce la dependencia de grandes volúmenes etiquetados en escenarios clínicos. Las cifras proceden de una única partición y semilla por nivel de submuestreo, por lo que delimitan una tendencia y no un margen con cierre estadístico.

4.6 Segmentación binaria de lesión

Este bloque evalúa si un modelo fundacional de segmentación adaptado al dominio dermatológico alcanza una delimitación de lesión de calidad clínica y qué factores la determinan. La tabla 4.6 compara SAM2.1-Large adaptado al dominio mediante *fine-tuning* del decodificador frente a SAM2 sin adaptar (*zero-shot*), un autoencoder convolucional sobre PanDerm Large (CAE-seg) y la referencia publicada por Yan et al. [1], analizando además su generalización fuera de dominio sobre ISIC2017 y PH2; las subsecciones posteriores aíslan el efecto de la arquitectura, del *prompt* y de la variabilidad inter-anotador.

4. RESULTADOS

Cuadro 4.6: Segmentación binaria de lesión: Dice de test sobre tres datasets dermatoscópicos. Modelos entrenados sobre ISIC2018 y evaluados sin reentrenamiento sobre ISIC2017 y PH2.

Configuración	ISIC2018 Dice	ISIC2017 Dice	PH2 Dice
SAM2 <i>zero-shot</i> (bbox de GT)	—	0,797	0,886
CAE-seg (PanDerm-L) FT ISIC2018	0,894	0,879	0,924
PanDerm [1] (ref.)	0,921	—	—
SAM2.1-L (decoder FT) ISIC2018	0,947	0,945	0,960

El detalle con la desviación estándar y el IoU sobre los datasets de transferencia (ISIC2017 y PH2) figura en el Anexo B (tabla B.7).

SAM2.1-L con *fine-tuning* del decodificador alcanza Dice 0,947 sobre ISIC2018, +2,6 pp sobre la cifra publicada por Yan et al. [1] y +5,3 pp sobre el CAE-seg: supera, por tanto, la referencia previa. Su generalización fuera de dominio es prácticamente nula (Dice 0,945 en ISIC2017 y 0,960 en PH2, este último superior por su mayor limpieza visual). Y, sobre todo, la adaptación del decodificador aporta +14,8 pp en ISIC2017 (0,797 $\rightarrow$ 0,945) y +7,4 pp en PH2 (0,886 $\rightarrow$ 0,960) frente a SAM2 sin adaptar (figura 4.4): es la adaptación al dominio, y no el tamaño bruto del modelo, lo que explica la mayor parte de la mejora.

Desde una perspectiva aplicada, este resultado anticipa una lectura que las subsecciones siguientes confirman: una vez disponible una caja que *localice* la lesión, la calidad del contorno depende poco del segmentador concreto (sección 4.6.2), de modo que localizar la lesión puede importar más que la precisión absoluta de la máscara.




Figura 4.4: Segmentación binaria de lesión. SAM2.1-Large con *fine-tuning* del decodificador alcanza Dice 0,947 sobre ISIC2018, +2,6 pp sobre el resultado publicado por Yan et al. [1], con transferencia OOD prácticamente nula sobre ISIC2017 (0,945) y PH2 (0,960).

4.6.1 Comparativa de arquitecturas promptables

La cifra anterior mezcla generación de arquitectura, preentrenamiento de dominio y tamaño de *backbone*. Para separarlos, se evalúan de forma pareada cinco arquitecturas *promptables* sobre un dataset dermatoscópico ampliado y deduplicado por hash MD5 (14 201 imágenes únicas de ISIC2018, ISIC2017, HAM10000-seg y PH2), bajo régimen común (*fine-tuning* denso del decodificador y el *promptable encoder*, encoder visual congelado, *prompt* de *bounding box* de referencia; detalle de optimización en Cap. 3) y sobre el mismo test canónico de ISIC2018 ($N = 1\,000$, blindado) que la cifra de referencia 0,947 de la tabla 4.6. La tabla 4.7 reporta el Dice resultante.

Cuadro 4.7: Comparativa de cinco arquitecturas promptables sobre el test canónico de ISIC2018 ($N = 1\,000$). Régimen común de *fine-tuning* del decodificador con *prompt* de *bounding box*. Las diferencias de Dice son modestas en valor absoluto pero significativas al test de Wilcoxon pareado [34] ($p < 10^{-6}$ en todos los contrastes).

Modelo	Arquitectura	Preentr.	Params	Dice	Latencia
MedSAM2-tiny [39]	SAM2 [19]	médico	39 M	0,9556	26 ms
SAM2.1-tiny	SAM2 [19]	general	39 M	0,9517	26 ms
SAM2.1-Large	SAM2 [19]	general	224 M	0,9503	96 ms
SAM-Med2D [40]	SAM [25]	médico	271 M	0,9465	20 ms
MedSAM v1 [38]	SAM [25]	médico	94 M	0,9458	74 ms

Tres conclusiones emergen de la comparación (todos los contrastes pareados son significativos al test de Wilcoxon, $p < 10^{-6}$; tabla 4.7). *Primero*, la generación SAM2 aporta más que el preentrenamiento médico: los tres modelos SAM2 superan a los basados en SAM v1, incluso a los de preentrenamiento médico. *Segundo*, el preentrenamiento médico ofrece una mejora adicional, pero solo dentro de la misma generación y de menor magnitud. *Tercero*, el tamaño del *backbone* aporta poco en régimen *box-prompted*: SAM2.1-tiny iguala o supera a SAM2.1-Large con 5,7 veces menos parámetros y menor latencia. La mejor configuración es MedSAM2-tiny (0,9556, 26 ms), que combina generación SAM2 y preentrenamiento médico en el *backbone* más compacto. Que la arquitectura pese más que el preentrenamiento médico matiza la hipótesis central del trabajo: en este régimen, el diseño del segmentador domina sobre la especialización dermatológica. Las tres subsecciones siguientes acotan cuánto del resultado depende del *prompt*, su estabilidad y su techo real.

4.6.2 Valor del prompt: control automático sin caja

Toda la comparativa anterior opera en régimen *box-prompted*: cada predicción parte de una *bounding box* derivada de la máscara de referencia. Para aislar la contribución de ese *prompt* se entrena un control automático que no recibe caja alguna —una U-Net con codificador ResNet-101 preentrenado en ImageNet, ajuste fino denso de 51,5 M de parámetros sobre el mismo dataset *v1c*— y se evalúa sobre el test canónico de ISIC2018. La tabla 4.8 contrasta su Dice con el del mejor modelo *promptable*.

4. RESULTADOS

Cuadro 4.8: Control automático *frente a* régimen *promptable* sobre el test canónico de ISIC2018 ($N = 1\,000$). La diferencia de Dice cuantifica el aporte de la caja-*prompt*.

Modelo	Régimen	Dice	IoU	Precisión	Recall
MedSAM2-tiny	<i>promptable</i>	0,9556	0,916	—	—
U-Net (ResNet-101)	automático	0,8811	0,804	0,856	0,942

El control automático alcanza Dice 0,8811, 7,5 pp por debajo del mejor modelo *box-prompted* (0,9556). La comparación de magnitudes es reveladora: la arquitectura mueve $\sim 1,0$ pp de Dice (tabla 4.7) y el preentrenamiento médico $\sim 0,4$ pp, pero retirar la caja cuesta 7,5 pp —entre seis y siete veces más que cualquiera de los otros dos factores—. El factor dominante de la segmentación dermatoscópica no es, por tanto, ni la arquitectura ni el preentrenamiento, sino la disponibilidad de una localización razonable de la lesión. El perfil de error del modo automático lo confirma —recall alto (0,942) pero precisión desplomada (0,856) y Hausdorff 95 entre 2,5 y 3 veces peor (desv. 0,121), señal de fallos catastróficos puntuales que la caja elimina—. El control valida además que la comparativa fue justa: todos los modelos compartían el mismo *prompt*, de modo que sus diferencias reflejan el segmentador y no la información de localización.

4.6.3 Robustez del resultado: validación cruzada, prompt y calibración

La cifra de 0,9556 procede de una única partición. Una validación cruzada de cinco pliegues sobre MedSAM2-tiny confirma su robustez: Dice $0,9554 \pm 0,0010$ (IC95 % [0,9543, 0,9564]), con la cifra principal dentro del intervalo y una desviación interpliegue (8×10^{-4}) que descarta dependencia de una partición afortunada.

La estabilidad frente a la calidad del *prompt* es crítica en despliegue, donde la caja procede de un anotador o detector y no de la máscara de referencia. La figura 4.5 reporta el Dice bajo perturbaciones controladas. El *jitter* de esquinas (± 20 px) apenas resta 0,86 pp, pero la escala es crítica y asimétrica: apretar la caja es catastrófico ($-6,8$ pp al -10% , $-15,4$ pp al -20% , por recortar lesión real) mientras que aflojarla degrada poco ($-2,8$ pp al $+10\%$, manteniendo Dice $\approx 0,93$). La lectura operativa se desarrolla en sección 5.1.10.




Figura 4.5: Robustez de MedSAM2-tiny a la calidad de la caja-*prompt* sobre el test canónico de ISIC2018 ($N = 1000$). El *jitter* de esquinas es prácticamente inocuo ($-0,86$ pp), pero la escala es crítica y asimétrica: apretar la caja degrada mucho más que aflojarla.

El resto de comprobaciones confirman un modelo bien comportado y no alteran la conclusión: el ajuste de bajo rango (LoRA $r \in \{4, 8, 16, 32\}$) iguala al ajuste denso del decodificador; la calibración a nivel de píxel es buena (ECE 0,0082); la equidad por fototipo (ITA) muestra una brecha de solo 1,1 pp entre fototipos extremos; y el aumento en test y el *ensemble* de pliegues aportan mejoras marginales ($+0,13/+0,14$ pp) que no compensan su coste, por lo que se recomienda un único modelo.

4.6.4 El techo de la métrica: acuerdo inter-anotador

El hallazgo más relevante de este bloque no es la cifra absoluta de Dice, sino su relación con el límite humano. El Dice se mide contra una máscara de referencia trazada por una persona, y el contorno de una lesión es intrínsecamente ambiguo: sobre el subconjunto de IMA++ con anotación múltiple (312 imágenes con dos o más máscaras independientes, reservado y nunca usado en entrenamiento), el acuerdo *inter-anotador* es de solo 0,728, mientras que el modelo concuerda con el consenso en 0,915 —es decir, coincide con el consenso mejor de lo que los propios humanos coinciden entre sí— y cae dentro de la envolvente de las máscaras humanas el 97,8% de las veces.

La consecuencia es interpretativa y profunda: las diferencias de ~ 1 pp entre arquitecturas (tabla 4.7) son menores que el desacuerdo entre anotadores humanos, de modo que perseguir mejoras de décimas de Dice tiene escaso sentido práctico — el resultado ya se sitúa en el techo que la propia tarea permite. El modelo es algo sobreconfiado en bordes ambiguos: su error de calibración contra la máscara de consenso blanda sube a 0,094, frente al 0,0082 contra una referencia binaria. Dentro del alcance evaluado —segmentación binaria de lesión sobre imagen dermatoscópica, con *prompt* de caja y test blindado de ISIC2018— la principal limitación reside ya en la incertidumbre de la anotación humana, no en el segmentador; el resultado no se extiende a la segmentación multilesión, a la adquisición clínica no dermatoscópica ni al régimen sin caja-*prompt* (sección 4.6.2). La supervisión en forma de lenguaje, en cambio, motiva el bloque siguiente sobre clasificación *zero-shot* multimodal.

4.7 Clasificación zero-shot multimodal

Esta sección analiza de qué depende que un modelo visión-lenguaje clasifique bien sin entrenar cabeza alguna, régimen que prometería despliegue inmediato sin etiquetas. El factor crítico no es la imagen sino la compatibilidad entre el tokenizador del texto y el espacio del encoder. La tabla 4.9 lo cuantifica sobre HAM10000 (7 clases) con tres configuraciones de *prompts* y dos tokenizadores distintos.

Cuadro 4.9: Zero-shot multimodal sobre HAM10000 ($N_{\text{test}} = 1\,232$, 7 clases). Mejor valor por columna en negrita.

Modelo	Tokenizador	Prompts	Acc	AUROC	F1-macro
DermLIP v1/v2	PubMedBERT	Genéricos	0,086	0,366	0,023
DermLIP v1/v2	PubMedBERT	Derm1M A3	—	0,516	—
DermLIP original	GPT-2/CLIP	Derm1M A3	0,427	0,854	—

El rendimiento depende drásticamente de cómo se construye el texto. Pasar de *prompts* genéricos en inglés con tokenizador PubMedBERT al conjunto A3 de Derm1M con tokenizador GPT-2/CLIP eleva la AUROC de 0,366 a 0,854 (+48,8 pp), como ilustra la figura 4.6. Los *prompts* genéricos con PubMedBERT quedan en $\text{AUROC} < 0,5$, señal de que proyectan en un espacio no alineado con el encoder visual de la variante v1/v2. Cambiar solo el conjunto A3, sin tocar el tokenizador, sube la AUROC a 0,516; cambiar solo el tokenizador, manteniendo A3, la lleva a 0,854. El principal cuello de botella del régimen *zero-shot* no reside, por tanto, en la representación visual —idéntica en todas las configuraciones—, sino en la alineación entre el espacio textual y el espacio visual.

Esta diferencia de casi 50 pp de AUROC, obtenida sin modificar el encoder visual ni las imágenes, tiene una implicación metodológica directa: evaluar un modelo *zero-shot* con una única configuración de *prompts* o tokenizadores puede falsear sus capacidades reales, y una comparación entre modelos puede incluso invertirse según el *prompt* elegido.

La generalización de este comportamiento a escenarios clínicos externos se evalúa sobre la tarea binaria melanoma/no-melanoma en cuatro datasets independientes (DDI, MSKCC, HIBA y Derm7pt clínico) con la configuración PubMedBERT de DermLIP v1/v2 (tabla 4.10).

Cuadro 4.10: Zero-shot binario melanoma/no-melanoma con DermLIP v1/v2 (*prompts* genéricos).

Dataset	N_{test}	Acc	BAcc	AUROC	F1-macro
DDI	137	0,766	0,499	0,436	0,463
MSKCC	1 664	0,716	0,500	0,430	0,417
HIBA	334	0,859	0,497	0,502	0,462
Derm7pt clín.	168	0,589	0,472	0,337	0,439

La sensibilidad observada en HAM10000 se reproduce en los cuatro datasets externos: bajo la configuración PubMedBERT con *prompts* genéricos, DermLIP opera cerca del azar ($\text{BAcc} \approx 0,5$), lo que confirma que el rendimiento *zero-shot* depende críticamente de la alineación texto-imagen y limita la robustez del paradigma zero-shot puro (análisis extendido en el Anexo G).

4.8. Comparación con modelos de lenguaje multimodales




Figura 4.6: Sensibilidad zero-shot al tokenizador y a la formulación del *prompt* sobre HAM10000. La AUROC oscila entre 0,366 (DermLIP v1/v2 + PubMedBERT + prompts genéricos) y 0,854 (DermLIP original + GPT-2/CLIP + prompts A3 de Derm1M), un rango de 48,8 pp para variaciones que no afectan al encoder visual.

4.8 Comparación con modelos de lenguaje multimodales

Esta sección contrasta si los grandes modelos de lenguaje multimodales, entrenados sobre datasets mucho mayores, cierran la brecha frente a los especialistas. La tabla 4.11 evalúa seis modelos de lenguaje multimodales sobre HAM10000, PAD-UFES-20 y DDI, junto a los modelos de referencia de las secciones 4.2 y 4.4.

Cuadro 4.11: Comparación de paradigmas sobre HAM10000, PAD-UFES-20 y DDI ($N_{\text{test}} = 1232/461/137$). FT: ajuste fino, LP: sondeo lineal, ZS: zero-shot.

Modelo	Modo	HAM Acc	HAM BAcc	PAD Acc	PAD BAcc	DDI Acc	DDI BAcc
PanDerm Base (TTA HAM)	FT	0,920	0,852	0,755	0,704	0,774	0,693
PanDerm Large	LP	0,888	0,575	0,772	0,642	0,847	0,764
SigLIP-Large	LP	0,900	—	0,718	—	0,789	—
MedGemma 27B + LoRA	FT	0,802	0,270	0,430	0,347	0,657	0,618
MedGemma 27B	ZS	0,665	0,243	0,447	0,342	0,474	0,566
GPT-4o	ZS	0,485	0,465	0,553	0,523	0,723	0,648
GPT-4o-mini	ZS	0,256	0,319	0,390	0,435	0,737	0,556
Gemini 2.5 Pro	ZS	0,403	—	0,477	—	0,441	—
Gemini 2.5 Flash	ZS	0,380	—	0,486	—	0,555	—
DermLIP	ZS	0,239	0,581	0,601	—	0,329	—
BLIP-2 (Flan-T5-XL)	ZS	0,015	0,145	0,017	0,167	0,796	0,542
InstructBLIP (Flan-T5-XL)	ZS	0,024	0,123	0,171	0,224	0,788	0,500

Los resultados separan claramente especialistas y generalistas. El mejor sistema dermatológico (PanDerm Base ajustado con TTA) alcanza accuracy 0,920 sobre HAM10000, frente a 0,485 del mejor generalista *zero-shot* (GPT-4o) —una diferencia de 43,5 pp que se mantiene en PAD-UFES-20 y DDI (figura 4.7)—; en el extremo inferior, BLIP-2 e InstructBLIP caen a accuracy $\sim 0,02$ sobre HAM10000. La lectura no es que un modelo generalista sea deficiente, sino que, cuando el problema es extremadamente

4. RESULTADOS

visual y especializado, el conocimiento dermatológico adquirido durante el preentrenamiento domina sobre la mayor capacidad lingüística de los modelos multimodales generalistas.¹

4.8.1 Ajuste supervisado de un LLM multimodal: MedGemma con LoRA

MedGemma es el único LLM multimodal que se acerca, y lo hace gracias a la adaptación al dominio: el ajuste con LoRA sobre MedGemma 27B mejora +13,7 pp de accuracy sobre HAM10000 respecto a su variante *zero-shot* (0,665 → 0,802) —un salto que vuelve a señalar que es la adaptación, y no la escala bruta, lo que cierra la brecha—. Aun así, incluso adaptado queda 11,8 pp por debajo del mejor especialista y la mejora no transfiere de forma sistemática (sin ganancia sobre PAD-UFES-20). El desglose por dataset, los patrones de error de GPT-4o y los costes de inferencia figuran en el Anexo G.




Figura 4.7: Comparativa de paradigmas sobre HAM10000. Gradiente de 43,5 pp accuracy entre el mejor especialista ajustado (PanDerm Base FT con TTA, 0,920) y el mejor LLM multimodal generalista *zero-shot* (GPT-4o, 0,485). BLIP-2 e InstructBLIP descienden hasta accuracy ~ 0,02.

4.9 Equidad por fototipo cutáneo

Esta sección analiza si los modelos rinden de forma equitativa entre fototipos cutáneos y cómo distinguir una equidad real de una métrica engañosa: un *gap* pequeño puede esconder un modelo uniformemente peor, de modo que la métrica aislada no decide,

¹Las cifras de los modelos accesibles por API comercial corresponden al *prompt* y a la versión del proveedor disponibles en la fecha de evaluación, no reproducible ante actualizaciones silenciosas (sección 6.1.1); documentan un punto de comparación reproducible en su formulación, no el techo intrínseco de cada sistema.

como establecen la comparación de cinco encoders y el test de DeLong. El rendimiento global de los cinco encoders sobre Fitzpatrick17k completo ($N = 16577$), en las dos formulaciones consideradas —114 patologías y 3 clases de malignidad—, figura en el Anexo B (tabla B.8); el análisis de equidad se centra en la formulación de 3 clases. La tabla 4.12 reporta la BAcc por fototipo Fitzpatrick sobre esa formulación.

Cuadro 4.12: BAcc por subgrupo Fitzpatrick (3 clases de malignidad) y *gap* entre fototipos extremos. Tamaños muestrales por subgrupo: 299/470/325/261/169/73 para FST I a VI.

Modelo	FST I	FST II	FST III	FST IV	FST V	FST VI	Gap I-VI
PanDerm Large	0,723	0,708	0,743	0,669	0,568	0,506	+0,217
PanDerm Base	0,653	0,693	0,669	0,630	0,585	0,384	+0,269
DermLIP v2 (visual)	0,716	0,730	0,765	0,710	0,693	0,434	+0,281
DINOv2 ViT-L/14	0,673	0,671	0,679	0,654	0,553	0,368	+0,306
BiomedCLIP	0,569	0,602	0,606	0,566	0,590	0,445	+0,124

Los cinco modelos tienen *gap* I-VI positivo: todos rinden peor sobre los fototipos elevados (figura 4.8). Pero el ranking de equidad no coincide con el de rendimiento. DermLIP v2 logra la mejor BAcc global (0,721 sobre 3 clases) y la mejor AUROC (0,909), pero con un *gap* I-VI (+0,281) mayor que el de PanDerm Large (+0,217); y BiomedCLIP exhibe el *gap* menor (+0,124) pero la peor BAcc global (0,590).

Este contraste encierra la principal aportación metodológica de la sección: **el *gap* aislado no constituye una métrica suficiente de equidad**. Un modelo uniformemente peor entre subgrupos puede presentar una brecha reducida simplemente porque falla en todos ellos —ser equitativamente malo no es ser equitativo en sentido sustantivo—. La interpretación debe además acotarse por el reducido tamaño muestral del fototipo VI ($N = 73$, frente a 299 en FST I; sección 6.2.4), que ensancha los intervalos del *gap* sobre los fototipos oscuros. El contraste con cierre estadístico se reserva al test de DeLong (sección 4.9.1).

Un experimento cruzado *Light* $\leftrightarrow$ *Dark* (*Light* agrupa FST I-III; *Dark*, FST IV-VI; matriz completa en el Anexo B, tabla B.9) añade una segunda lectura, más fuerte que el simple *gap*. Entrenar solo con fototipos claros y evaluar sobre oscuros (L $\rightarrow$ D frente a L $\rightarrow$ L) penaliza el rendimiento. La caída es mayor en DINOv2 ($\Delta = -0,132$ pp BAcc) y menor en BiomedCLIP ($\Delta = -0,063$ pp). DermLIP v2 muestra la menor caída Dark $\rightarrow$ Light frente a Dark $\rightarrow$ Dark ($\Delta = +0,016$ pp), lo que apunta a representaciones más invariantes al fototipo cutáneo (figura 4.9).

4. RESULTADOS




Figura 4.8: Equidad por fototipo Fitzpatrick (formulación de tres clases de malignidad) sobre los cinco encoders evaluados. Los cinco presentan *gap* I-VI positivo (entre +0,124 y +0,306 pp BAcc). Paradoja BiomedCLIP: *gap* mínimo asociado a peor BAcc global, lo que demuestra el carácter no decisonal de la métrica aislada.




Figura 4.9: Evaluación cruzada *Light* ↔ *Dark* sobre Fitzpatrick17k (BAcc en formulación de tres clases). La caída L→D vs L→L cuantifica la pérdida de rendimiento al entrenar sólo con fototipos claros y evaluar sobre fototipos oscuros, máxima en DINOv2 ($\Delta = -0,132$ pp).

La proximidad entre algunos resultados —especialmente entre PanDerm Large y DermLIP v2— plantea si las diferencias reflejan una ventaja real o son compatibles con la variabilidad muestral, lo que motiva un contraste formal mediante el test de DeLong.

4.9.1 Validación estadística del ranking de encoders: test de DeLong

Las diferencias de AUROC entre encoders se contrastan mediante el test de DeLong [33], que controla la correlación de evaluar los cinco modelos sobre las mismas imágenes, sobre el endpoint binario de malignidad (*maligno* frente al resto) en el test de Fitzpatrick17k ($N = 1\,658$, 226 malignos), con regresión logística binaria por encoder sobre sus *features* congeladas (sección 3.6.1). La tabla 4.13 reporta la AUROC binaria con IC95 % por la varianza de DeLong; la matriz completa de p -valores pareados (dos colas) figura en el Anexo B (tabla B.10).

Cuadro 4.13: AUROC binaria de detección de malignidad (*maligno* frente al resto) sobre el test de Fitzpatrick17k ($N = 1\,658$, 226 malignos), con intervalo de confianza al 95 % por la varianza de DeLong. Mejor valor en negrita.

Modelo	AUROC	IC95 % (DeLong)
PanDerm Large	0,9488	[0,9350, 0,9626]
DermLIP v2	0,9452	[0,9307, 0,9598]
PanDerm Base	0,9296	[0,9130, 0,9463]
DINOv2 ViT-L/14	0,9150	[0,8932, 0,9367]
BiomedCLIP	0,8915	[0,8672, 0,9158]

El test de DeLong confirma que PanDerm Large y DermLIP v2 presentan un rendimiento estadísticamente indistinguible ($\Delta\text{AUROC} = 0,0036$, $p = 0,55$): ningún dato sostiene una jerarquía entre ambos sobre este *endpoint*. Los dos superan, en cambio, de forma significativa a los encoders generalistas (DINOv2 y BiomedCLIP) y a PanDerm Base ($p \leq 7,3 \times 10^{-3}$ en los seis contrastes), lo que respalda cuantitativamente la ventaja del preentrenamiento específico de dominio. Tras corrección de Bonferroni (umbral 0,005), la mayoría de estas diferencias se mantienen significativas, mientras que algunas comparaciones entre generalistas (DINOv2–BiomedCLIP, DINOv2–PanDerm Base) dejan de ser concluyentes, delimitando qué distinciones del *ranking* son señal y cuáles ruido muestral.

La lectura que el contraste habilita es más sólida que coronar a un único modelo: los resultados no identifican un encoder dermatológico claramente superior, sino una *familia* de encoders dermatológicos que supera de forma consistente a los modelos generalistas —conclusión que se retoma en la discusión (sección 5.1.1).

4.10 Validación en castellano sobre DermapixelAI 1.0

Los bloques anteriores evalúan los modelos sobre datasets externos anglosajones. El objetivo de generalización de la sección 1.3 exige comprobar si los hallazgos se sostienen sobre material clínico en castellano, independiente y libre de fuga frente al preentrenamiento. DermapixelAI 1.0 reúne ambas condiciones. El bloque que se extiende hasta la sección 4.13 responde a si los modelos fundacionales transfieren a este material y comparte un hallazgo transversal: no existe un método óptimo único, sino que la mejor configuración depende del nivel ontológico evaluado. La tabla 4.14 fija la nomenclatura de los cuatro sistemas contrastados.

4. RESULTADOS

Cuadro 4.14: Nomenclatura de los cuatro sistemas evaluados sobre DermapixelAI 1.0 a lo largo del bloque secciones 4.10–4.13.

Sistema	Qué es	Sección
PanDerm LP	Codificador congelado + regresión logística	\$4.10
DermLIP <i>zero-shot</i>	Modelo visión-lenguaje externo (sin cabeza entrenada)	\$4.11
Dermapixel R0 (cabeza superv. L2)	Rama supervisada con adaptación LoRA $r = 16$	\$4.12
Dermapixel R0 (rama contrastiva)	Rama <i>CLIP-style</i> castellana <i>zero-shot open</i>	\$4.13

Frente al solapamiento de Dermnet (sección 4.1), DermapixelAI 1.0 (Anexo E) es completamente independiente del preentrenamiento de la familia PanDerm/DermLIP: la auditoría por hash MD5 sobre 507 657 imágenes catalogadas (Derm1M 415 451 ítems más los once datasets externos del capítulo) reporta intersección nula (0 coincidencias sobre las 1 062 imágenes evaluables). Esta evaluación no está, por tanto, sujeta a fuga de información.

4.10.1 Transferencia congelada: sondeo lineal y validación cruzada

Sondeo lineal sobre el *split* fijo. Se aplica el protocolo de sondeo lineal (sección 3.6.1) sobre las 1 062 imágenes con `label_source=ontology` (train $N = 874$, validación $N = 152$, test $N = 36$), con PanDerm Base (768-D) y Large (1 024-D) como extractores congelados y cabeza *LogisticRegression*. La evaluación L2 usa las 38 subcategorías efectivas tras consolidar las dos variantes ortográficas de *Trastornos de la queratinización* (Anexo C, sección C.6).

Cuadro 4.15: Sondeo lineal con PanDerm Base y Large sobre DermapixelAI 1.0 en los tres niveles de la ontología jerárquica ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$ en L1/L2 y $N_{\text{test}} = 28$ en L3 tras filtrar clases ausentes en train). Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos). Mejor valor por columna y nivel en negrita.

Nivel	Modelo	Acc	BAcc	AUROC	W-F1	Kappa
L1 (4 clases)	Base	0,639 [0,472–0,778]	0,570 [0,371–0,751]	0,697 [0,527–0,841]	0,624 [0,457–0,760]	0,296
L1 (4 clases)	Large	0,750 [0,639–0,861]	0,735 [0,637–0,835]	0,796 [0,656–0,930]	0,722 [0,596–0,845]	0,520
L2 (38 clases)	Base	0,222 [0,139–0,333]	0,221 [0,147–0,294]	0,707 [0,666–0,747]	0,212 [0,092–0,302]	0,170
L2 (38 clases)	Large	0,250 [0,167–0,333]	0,265 [0,206–0,338]	0,793 [0,749–0,837]	0,223 [0,139–0,291]	0,199
L3 (224 clases)	Base	0,143 [0,107–0,179]	0,132 [0,105–0,158]	0,735 [0,693–0,779]	0,107 [0,064–0,141]	0,112
L3 (224 clases)	Large	0,179 [0,143–0,214]	0,184 [0,158–0,211]	0,813 [0,769–0,856]	0,143 [0,100–0,184]	0,154

PanDerm Large supera a Base en las cinco métricas y los tres niveles (entre +7,8 y +9,9 pp de AUROC y entre +4,4 y +16,5 pp de BAcc), y el rendimiento decrece monótonamente con la granularidad: la BAcc de Large cae de 0,735 (L1) a 0,265 (L2) y 0,184 (L3, 224 diagnósticos), si bien aún multiplica el azar por $2,9 \times / 10,2 \times / 40,9 \times$. La cifra L1 BAcc = 0,735 (IC95 % [0,637–0,835]) se sitúa dentro del rango de los diez datasets externos (tabla 4.1), lo que ubica a DermapixelAI 1.0 como *benchmark* exigente en castellano sin marcas dermatoscópicas estandarizadas.

Validación cruzada agrupada por caso. Dado que el test fijo $N = 36$ es un único *split*, se estima el rendimiento esperado mediante validación cruzada de cinco *folds* agrupada por `case_id` (*StratifiedGroupKFold* por L1 sobre las 1 062 imágenes), sin que ninguna imagen del mismo caso caiga a la vez en *train* y *test*. La tabla 4.16 reporta media y desviación sobre los cinco *folds*.

Cuadro 4.16: Validación cruzada agrupada por caso (cinco *folds*, estratificado por L1 sobre *case_id*) con PanDerm Large sobre DermapixelAI 1.0. Cifras: media $\pm$ desviación estándar sobre los cinco *folds*. La cardinalidad L3 reportada aquí (250 clases) corresponde a las clases efectivas en el dataset completo; las restantes tablas del split fijo (tabla 4.15, tabla 4.17 y las del Anexo J) usan 224 clases L3, las únicas representadas en el split *train*.

Nivel	Acc@1	Acc@3	BAcc	AUROC	W-F1	Kappa
L1 (4 cls)	0,574 $\pm$ 0,029	0,994 $\pm$ 0,004	0,440 $\pm$ 0,058	0,753 $\pm$ 0,054	0,569 $\pm$ 0,025	0,314 $\pm$ 0,035
L2 (38 cls)	0,227 $\pm$ 0,015	0,418 $\pm$ 0,037	0,168 $\pm$ 0,020	0,749 $\pm$ 0,019	0,221 $\pm$ 0,022	0,186 $\pm$ 0,015
L3 (250 cls)	0,124 $\pm$ 0,007	0,232 $\pm$ 0,028	0,108 $\pm$ 0,014	0,800 $\pm$ 0,018	0,124 $\pm$ 0,005	0,110 $\pm$ 0,005

La validación cruzada agrupada por caso es la estimación defendible del rendimiento esperado. El test fijo sobrestima la media de los cinco *folds* en +29,5 pp BAcc en L1, +9,7 pp en L2 y +7,6 pp en L3, por la distribución favorable del split publicado (sin *Genodermatosis* en test y baja densidad de cola larga L3): el split fijo es, por tanto, optimista. La AUROC, en cambio, se mantiene estable frente a la partición (caídas < 5 pp: 0,796 $\rightarrow$ 0,753 en L1, 0,793 $\rightarrow$ 0,749 en L2, 0,813 $\rightarrow$ 0,800 en L3). Las cifras del test fijo (tabla 4.15) se conservan como punto operativo y base de comparación con el experimento *zero-shot* (sección 4.11), que reutiliza el mismo test.

4.10.2 Validación del procedimiento de etiquetado

Dado que parte de las etiquetas etiológicas procede de la ontología y no de revisión individual, se compara el sondeo lineal sobre el subconjunto verificado (*rosa_verified*) frente al dataset completo. Las diferencias son pequeñas, inconsistentes en dirección y compatibles con la variabilidad muestral: la imputación etiológica no degrada apreciablemente el rendimiento (resultados completos en el Anexo J, tabla J.1). Diversas ablaciones adicionales sobre los mismos *embeddings* (cabezas *k*-NN/MLP, función de pérdida, *Test-Time Augmentation*) tampoco modifican las conclusiones y se documentan en el mismo anexo.

4.10.3 Estrategias de adaptación más allá del sondeo lineal

Más allá de la representación congelada, dos estrategias buscan mejorar el rendimiento sobre DermapixelAI 1.0: combinar codificadores complementarios y ajustar finamente el encoder.

Combinación de codificadores. Para evaluar si las representaciones de distintos codificadores son complementarias, se entrena una cabeza logística por codificador (PanDerm Base, Large y DermLIP v2; protocolo de sección 3.6.1) sobre los *embeddings* congelados y se contrastan frente a cinco estrategias de combinación (promedio de las tres, promedio Large+DermLIP, máximo por clase y apilado con meta-cabeza). La tabla 4.17 reporta los tres niveles en el mismo test fijo.

4. RESULTADOS

Cuadro 4.17: Combinación de codificadores sobre DermapixelAI 1.0. LP individual sobre PanDerm Base, PanDerm Large y DermLIP v2; tres estrategias de combinación: promedio Large+DermLIP, máximo por clase entre los tres, y apilado con meta-cabeza. Mejor valor por columna y nivel en negrita.

Nivel	Estrategia	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	LP PanDerm Base	0,639	—	0,570	0,697
L1 (4 cls)	LP PanDerm Large	0,750	1,000	0,735	0,796
L1 (4 cls)	LP DermLIP v2	0,694	1,000	0,680	0,789
L1 (4 cls)	Avg L+D	0,750	1,000	0,702	0,817
L1 (4 cls)	Avg 3	0,722	1,000	0,694	0,811
L1 (4 cls)	Máx 3	0,694	1,000	0,652	0,805
L1 (4 cls)	Stack 3	0,694	1,000	0,703	0,790
L2 (38 cls)	LP PanDerm Base	0,222	—	0,221	0,707
L2 (38 cls)	LP PanDerm Large	0,250	0,500	0,265	0,793
L2 (38 cls)	LP DermLIP v2	0,333	0,528	0,279	0,860
L2 (38 cls)	Avg L+D	0,278	0,556	0,279	0,832
L2 (38 cls)	Avg 3	0,278	0,528	0,268	0,821
L2 (38 cls)	Máx 3	0,222	0,528	0,235	0,797
L2 (38 cls)	Stack 3	0,250	0,528	0,258	0,804
L3 (224 cls)	LP PanDerm Base	0,143	—	0,132	0,735
L3 (224 cls)	LP PanDerm Large	0,179	0,286	0,184	0,813
L3 (224 cls)	LP DermLIP v2	0,107	0,214	0,079	0,809
L3 (224 cls)	Avg L+D	0,179	0,250	0,184	0,802
L3 (224 cls)	Avg 3	0,143	0,250	0,152	0,795
L3 (224 cls)	Máx 3	0,143	0,250	0,132	0,780
L3 (224 cls)	Stack 3	0,143	0,250	0,158	0,791

Ningún codificador lidera simultáneamente L1, L2 y L3. En L1 lidera la combinación avg Large+DermLIP en AUROC (0,796 $\rightarrow$ 0,817); en L2, DermLIP v2 individual en todas las métricas (+6,7 pp AUROC sobre PanDerm Large, 0,793 $\rightarrow$ 0,860), sin que ningún *ensemble* lo supere, en coherencia con el experimento *zero-shot* (sección 4.11); en L3 lidera PanDerm Large individual, donde la cola larga limita la señal complementaria.

Ajuste fino parcial del codificador. Este protocolo replica sobre DermapixelAI 1.0 el ajuste fino supervisado (FT) de la sección 4.4. El encoder es PanDerm Large con las dos últimas capas descongeladas (25,2 M parámetros entrenables, 8,3 % del encoder) y cabeza *fully-connected*, con entropía cruzada reponderada por el desbalance de *Genodermatosis* (receta en Anexo A, tabla A.5).

Sobre el nivel L1, el ajuste fino parcial alcanza BAcc 0,622 (IC95 % [0,510–0,735]) y AUROC 0,715, lo que mejora en +18,2 pp la cifra de validación cruzada agrupada por caso del sondeo lineal congelado (BAcc 0,440 $\pm$ 0,058, tabla 4.16), con intervalos no solapados: el ajuste fino aporta valor real más allá del ruido de partición. No obstante, no supera a la combinación lineal de codificadores congelados avg_large_dermlip (sección 4.10.3; BAcc 0,702, AUROC 0,817). La replicación sobre L2 y L3 mantiene el mismo protocolo, variando únicamente la cabeza supervisada. La tabla 4.18 compara las métricas sobre los tres niveles.

Cuadro 4.18: Ajuste fino parcial del codificador (PanDerm Large, dos últimas capas descongeladas) sobre los tres niveles ontológicos de DermapixelAI 1.0. Test fijo $N_{\text{test}} = 36$ en L1/L2 y $N_{\text{test}} = 28$ en L3. La cabeza L2 de este protocolo dimensiona $1024 \rightarrow 37$: son las 37 clases L2 efectivas en el *train* del ajuste fino, de las 38 del corpus tras fusionar las dos variantes ortográficas de “queratinización” (39 en bruto); las 38 clases son la cardinalidad nominal del nivel L2. Entre corchetes, IC95% por *bootstrap* estratificado (1 000 remuestreos). Mejor valor por columna en negrita.

Nivel	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	0,583 [0,444–0,722]	0,972 [0,917–1,000]	0,622 [0,510–0,735]	0,715 [0,603–0,830]
L2 (37 cls)	0,250 [0,167–0,333]	0,500 [0,389–0,611]	0,324 [0,265–0,397]	0,852 [0,814–0,888]
L3 (224 cls)	0,179 [0,143–0,214]	0,286 [0,214–0,357]	0,184 [0,158–0,211]	0,804 [0,773–0,835]

El ajuste fino denso parcial mejora al sondeo lineal en L1 y L2, pero no es la forma de adaptación más eficiente, como revela la comparación directa con la adaptación de bajo rango (subsección siguiente). En conjunto, ni la combinación de codificadores ni el ajuste fino identifican una opción óptima universal: **el rendimiento depende simultáneamente del nivel ontológico, de la estrategia de adaptación y del criterio de evaluación**, de modo que la búsqueda de un único codificador *ganador* resulta una simplificación excesiva del problema (lectura de diseño en sección 5.1.1).

4.10.4 LoRA frente a ajuste fino denso

Sobre el nivel L2, el FT parcial denso (25,2 M parámetros entrenables) alcanza BAcc 0,324 y AUROC 0,852, cifras que la adaptación de bajo rango (LoRA [32]) del protocolo Dermapixel R0 (sección 4.12) supera —BAcc $0,363 \pm 0,007$ y AUROC $0,855 \pm 0,006$ — movilizandando 48 veces menos parámetros (tabla 4.19).

Cuadro 4.19: Comparativa sobre el nivel L2 de DermapixelAI 1.0 entre el sondeo lineal congelado (referencia), el ajuste fino parcial denso con dos últimas capas descongeladas y el protocolo Dermapixel R0 (cabeza supervisada L2) con adaptación LoRA. Mismo conjunto de test ($N_{\text{test}} = 36$, 37–38 clases según consolidación de variantes ortográficas de queratinización descrita en sección 4.12). Mejor valor por columna en negrita.

Protocolo	BAcc L2	AUROC L2	Params entren.
LP test fijo (referencia, tabla 4.15)	0,265	0,793	39 K
FT parcial denso (este trabajo)	0,324	0,852	25,2 M
Dermapixel R0 (LoRA)	0,363 $\pm$ 0,007	0,855 $\pm$ 0,006	524 K

Bajo el régimen de datos disponible ($N_{\text{train}} = 874$), el cuello de botella no es la capacidad del modelo sino la eficiencia de la adaptación: LoRA supera al FT denso parcial movilizandando el 2% de sus parámetros (524 K frente a 25,2 M, 48× menos), lo que justifica la decisión arquitectónica de Dermapixel R0 (sección 4.12).

4.10.5 Limitaciones del ajuste fino en la cola larga

Sobre el nivel L3, el ajuste fino denso parcial no supera al sondeo lineal congelado (BAcc 0,184 en ambos): la cola larga severa del nivel (77% de las clases con ≤ 5 ejemplos) anula el beneficio del ajuste fino, lo que reserva L3 al ranking por prototipos coseno

de Dermapixel R0 (tabla J.2) o a la ampliación del dataset vía banco hospitalario del HUSLL.

Tres *caveats* acotan la interpretación de las cifras de esta sección: el conjunto de test es reducido ($N = 36$ en L1/L2, $N = 28$ en L3), lo que ensancha los IC95 %; la categoría etiológica *Genodermatosis* no aparece en el test de L1 (0/36), por lo que las métricas reflejan una clasificación efectiva de tres clases; y la cola larga de L3 limita el rendimiento absoluto alcanzable bajo cualquier protocolo de ajuste denso sobre el dataset actual.

4.11 Validación *zero-shot* multimodal sobre DermapixelAI 1.0

Esta sección evalúa hasta qué punto un modelo fundacional dermatológico transfiere al dataset clínico en castellano sin entrenar cabeza supervisada. La brecha entre el régimen *zero-shot* y el supervisado depende del nivel ontológico: amplía en L1 y L3, pero prácticamente nula en L2, donde DermLIP v2 *zero-shot* alcanza una AUROC (0,794) indistinguible de la del sondeo lineal supervisado de PanDerm Large (0,793).

El experimento opera sobre el mismo test que la sección 4.10 ($N_{\text{test}} = 36$ en L1/L2, 28 en L3), sin cabeza clasificadora y con no solapamiento garantizado (0/507657 coincidencias MD5). Se evalúan tres modelos contrastivos —DermLIP v2 (Derm1M), SigLIP-SO400M (WebLI) y BiomedCLIP (PubMed-15M)— por *argmax* sobre la similitud coseno con un *ensemble* de tres plantillas por nivel, contrastando *prompt* en castellano frente a inglés; L3 se evalúa sólo en castellano por falta de traducción inglesa validada para sus 224 clases (tabla 4.20).

Cuadro 4.20: Clasificación *zero-shot* multimodal sobre el conjunto de test de DermapixelAI 1.0 ($N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos) para las dos métricas primarias (Acc@1 y AUROC). Las métricas BAcc y Acc@3 se reportan como valor puntual por concisión; los IC95 % correspondientes están disponibles en el material reproducible. L3 se evalúa únicamente en castellano. Mejor valor por columna, nivel e idioma en negrita.

Nivel	Modelo	Lang	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	BiomedCLIP	es	0,389 [0,250–0,528]	0,944	0,375	0,679 [0,562–0,781]
L1 (4 cls)	BiomedCLIP	en	0,389 [0,250–0,528]	0,972	0,324	0,639 [0,524–0,738]
L1 (4 cls)	SigLIP-SO400M	es	0,222 [0,111–0,361]	0,917	0,178	0,650 [0,571–0,735]
L1 (4 cls)	SigLIP-SO400M	en	0,333 [0,194–0,472]	0,889	0,292	0,663 [0,595–0,719]
L1 (4 cls)	DermLIP v2	es	0,361 [0,222–0,500]	0,861	0,379	0,699 [0,600–0,794]
L1 (4 cls)	DermLIP v2	en	0,500 [0,333–0,667]	0,917	0,441	0,709 [0,565–0,841]
L2 (38 cls)	BiomedCLIP	es	0,111 [0,111–0,111]	0,278	0,118	0,647 [0,604–0,688]
L2 (38 cls)	BiomedCLIP	en	0,083 [0,056–0,111]	0,250	0,088	0,655 [0,601–0,713]
L2 (38 cls)	SigLIP-SO400M	es	0,139 [0,139–0,139]	0,250	0,235	0,636 [0,589–0,680]
L2 (38 cls)	SigLIP-SO400M	en	0,194 [0,111–0,278]	0,278	0,221	0,697 [0,640–0,747]
L2 (38 cls)	DermLIP v2	es	0,222 [0,167–0,278]	0,333	0,265	0,762 [0,721–0,805]
L2 (38 cls)	DermLIP v2	en	0,250 [0,194–0,306]	0,417	0,294	0,794 [0,747–0,837]
L3 (224 cls)	BiomedCLIP	es	0,107 [0,036–0,179]	0,214	0,079	0,703 [0,673–0,732]
L3 (224 cls)	SigLIP-SO400M	es	0,071 [0,000–0,143]	0,214	0,053	0,696 [0,667–0,723]
L3 (224 cls)	DermLIP v2	es	0,107 [0,071–0,143]	0,214	0,079	0,740 [0,719–0,763]

La evaluación *zero-shot* sobre DermapixelAI 1.0 arroja tres hallazgos principales: (1) DermLIP v2 es el modelo más competitivo en los tres niveles ontológicos; (2) el

idioma del *prompt* afecta significativamente a los modelos preentrenados mayoritariamente en inglés; y (3) la necesidad de supervisión depende del nivel ontológico —crítica en L1 y L3, pero mínima en L2—.

Primero, DermLIP v2 obtiene el mejor o equivalente rendimiento en las cinco métricas sobre los tres niveles (salvo Acc@3 L1, liderada por BiomedCLIP), coherente con su preentrenamiento sobre Derm1M, el único dataset específicamente dermatológico de los tres [2].

Segundo, traducir el *prompt* del inglés al castellano reduce la Acc@1 en L1 entre 11 y 14 puntos porcentuales en los modelos anglófonos (DermLIP v2 –13,9 pp, de 0,500 a 0,361; SigLIP-SO400M –11,1 pp), mientras que BiomedCLIP mantiene su cifra en ambos idiomas. La penalización es consistente con el predominio del inglés en el preentrenamiento —aunque el diseño no permite atribuirle causalmente a ese único factor— y motiva directamente la rama textual castellana de Dermapixel R0: sin penalización lingüística, una rama en castellano no estaría justificada.

Tercero, la comparación con el sondeo lineal supervisado (tabla 4.15) cuantifica la brecha entre un sistema entrenado y uno *zero-shot*: +29,4 pp BAcc en L1 y +10,5 pp en L3 a favor del LP. El comportamiento se invierte, en cambio, en L2, y aquí aparece el resultado más llamativo de la sección: DermLIP v2 *zero-shot* en inglés (AUROC 0,794) iguala al mejor sondeo lineal supervisado (PanDerm Large, 0,793) dentro de los intervalos de confianza. Esto sugiere que, a nivel de subcategorías dermatológicas, una parte sustancial del conocimiento discriminativo ya está codificada en el espacio multimodal preentrenado y puede recuperarse mediante texto, sin entrenamiento adicional; el grano grueso L1 y la cola larga L3 sí requieren, en cambio, clasificador supervisado.

La tabla 4.21 resume las brechas cuantificadas en esta sección.

Cuadro 4.21: Brechas *zero-shot* cuantificadas sobre DermapixelAI 1.0: penalización por idioma (castellano frente a inglés) y distancia al sondeo lineal supervisado (LP).

Contraste	Métrica	Gap
DermLIP v2, L1, castellano vs. inglés	Acc@1	–13,9 pp
SigLIP-SO400M, L1, castellano vs. inglés	Acc@1	–11,1 pp
DermLIP v2, L2, castellano vs. inglés	AUROC	–3,2 pp
LP supervisado vs. <i>zero-shot</i> , L1	BAcc	+29,4 pp
LP supervisado vs. <i>zero-shot</i> , L3	BAcc	+10,5 pp

Caveats

Las cautelas sobre el tamaño del conjunto de test ($N = 36$ en L1/L2, $N = 28$ en L3) y sobre la ausencia de solapamiento frente a Derm1M ya enunciadas para el sondeo lineal (sección 4.10) aplican también a esta evaluación *zero-shot*. Dos *caveats* adicionales son específicos del régimen *zero-shot*. Primero, el *ensemble* de tres plantillas textuales por nivel constituye una formulación mínima de *prompt engineering*; la literatura sobre *zero-shot* multimodal emplea típicamente entre diez y ochenta plantillas generadas con asistencia de LLMs, lo que sitúa las cifras reportadas como cota inferior del rendimiento alcanzable. Segundo, la evaluación L3 únicamente en castellano impide cuantificar la penalización por idioma sobre la cola larga diagnóstica, dado que el vocabulario ontológico no dispone de traducción inglesa validada para sus 224 clases.

4.12 Ajuste fino con LoRA: Dermapixel R0 (cabeza supervisada L2)

4.12.1 Diseño de Dermapixel R0

Frente a los experimentos anteriores, que evalúan modelos existentes, esta subsección aborda la contribución propia: **Dermapixel R0**, una adaptación mediante LoRA [32] de PanDerm Large sobre DermapixelAI 1.0 —una adaptación de un modelo fundacional preexistente, no un preentrenamiento a escala; la denominación R0 designa una versión base sobre un dataset reducido—. Entrena únicamente 524 K parámetros (0,17 % del modelo) y se orienta al nivel L2 (38 clases efectivas), donde la disponibilidad de muestras permite entrenamiento supervisado; el nivel L3 se evalúa mediante ranking por prototipos coseno por la extrema escasez de ejemplos por clase. La configuración completa (LoRA $r = 16$, optimización, semillas) figura en el Anexo A (tabla A.3).

4.12.2 Resultados principales L2

La tabla 4.22 compara Dermapixel R0 con las referencias internas sobre el nivel L2 ($N_{\text{test}} = 36$): el sondeo lineal congelado bajo validación cruzada agrupada por caso (tabla 4.16), el sondeo lineal sobre el *split* fijo (tabla 4.15) y DermLIP v2 individual (sección 4.10.3).

Cuadro 4.22: Comparativa sobre el nivel L2 de DermapixelAI 1.0 (38 clases con queratinización consolidada, $N_{\text{test}} = 36$) entre Dermapixel R0 y las referencias internas del trabajo. La fila LP CV se considera la cifra honesta del sondeo lineal congelado por su independencia del *split* fijo y por su anclaje en validación cruzada agrupada por caso (sección 4.10). Mejor valor por columna en negrita.

Método	Encoder	Params entren.	BAcc L2	AUROC L2
LP test fijo (tabla 4.15)	PanDerm Large 1 024 (cong.)	39 K	0,265	0,793
LP 5-fold CV (tabla 4.16)	PanDerm Large 1 024 (cong.)	39 K	0,168 ± 0,020	0,749 ± 0,019
DermLIP v2 individual (sección 4.10.3)	DermLIP 512 (cong.)	19,5 K	0,279	0,860
Dermapixel R0 (este trabajo)	PanDerm Large 1 024 + LoRA	524 K	0,363 ± 0,007	0,855 ± 0,006

Dermapixel R0 alcanza la mejor BAcc L2 documentada sobre el dataset (0,363 ± 0,007, media ± desviación sobre tres semillas), superando tanto al sondeo lineal congelado como a DermLIP v2; la ventaja se mantiene frente a la estimación más conservadora por validación cruzada agrupada por caso (+19,5 pp BAcc). En AUROC, R0 (0,855 ± 0,006) empata con DermLIP v2 (0,860), lo que sugiere que la adaptación ligera de PanDerm Large recupera prácticamente todo el techo discriminativo del modelo contrastivo especializado, con ventaja en las clases minoritarias.

4.12.3 Adaptación eficiente frente a ajuste denso

La adaptación de bajo rango de Dermapixel R0 entrena 524 K parámetros frente a los 25,2 M del ajuste fino parcial denso (sección 4.10.3) y obtiene mejor BAcc L2: **Dermapixel R0 rinde mejor entrenando 48 veces menos parámetros**. La adaptación eficiente de parámetros (PEFT) supera, por tanto, al ajuste fino parcial denso en este régimen de datos.

4.12.4 Limitaciones en L3

El rendimiento cae notablemente en L3 (ranking por prototipos coseno, $\text{Acc}@1 = 0,167, \times 42$ sobre el azar), donde 178 de las 250 clases disponen de cinco o menos imágenes de *train*: la principal limitación deja de ser el modelo y pasa a ser la disponibilidad de datos. Las cifras completas figuran en el Anexo J (tabla J.2); la cabeza L3 directa queda condicionada al banco hospitalario del HUSLL (≥ 30 imágenes/clase, sección 7.5.1).

4.13 Dermapixel R0: rama contrastiva multimodal castellano zero-shot sobre DermapixelAI 1.0

A diferencia de la cabeza supervisada L2, esta rama mapea texto clínico libre en castellano sobre el espacio de imágenes sin vocabulario cerrado, condición relevante para la búsqueda documental sobre el archivo clínico. La progresión de cinco iteraciones ($v1 \rightarrow v5$) sobre una adaptación de PanDerm Large —no un preentrenamiento a escala— indica que la palanca decisiva es la capacidad del codificador visual, no la escala de datos externos, e incluye un resultado negativo de escala. La condicionalidad del *zero-shot* L3 al volumen de pares y a la cobertura de la cola larga se mantiene como cautela transversal.

4.13.1 Diseño experimental

La rama contrastiva es un sistema dual-encoder estilo CLIP [23] (encoder visual PanDerm Large + encoder textual multilingüe adaptado al castellano clínico). Se entrenan cinco iteraciones diseñadas para aislar tres factores: adaptación textual, adaptación visual y aumento de escala mediante datos externos genéricos; el objetivo, fijado a priori, es L3 $\text{accuracy}@1 \geq 0,25$ en *zero-shot*. La arquitectura, los hiperparámetros, las particiones *case-aware*, la justificación frente a un *wrapper* inglés con traducción ES-EN y la generación de *captions* figuran en los Anexos A (tabla A.4), C y I.

4.13.2 Evolución $v1 \rightarrow v5$

La tabla 4.23 reporta la $\text{accuracy}@1$ sobre las 101 imágenes de test bajo régimen híbrido H6 (logits visuales y textuales con pesos $w_v = 0,3$, $w_t = 0,7$ calibrados sobre validación), uniforme a las cinco iteraciones para la comparativa cross-checkpoint. Los niveles L1 y L2 *zero-shot* sólo se reportan para v4 y v5.

4. RESULTADOS

Cuadro 4.23: Clasificación *zero-shot* de la rama contrastiva de Dermapixel R0 sobre el conjunto de test de 101 imágenes (per-case estratificado por L1) bajo régimen híbrido *H6* homogéneo ($w_v = 0,3$, $w_t = 0,7$) aplicado a las cinco iteraciones. La columna *Objetivo* corresponde al umbral fijado en el diseño experimental antes de observar resultados. Mejor cifra por fila excluyendo la columna *Objetivo* en negrita. La trayectoria completa con configuración LoRA por iteración, lift de recuperación y techo *Linear Probing* figura en el Anexo I (tabla I.6). Provenance: commit d0190c3 del repositorio *spanderm-clip*.

Tarea	Random	v1	v2	v3	v4	v5	Objetivo
L1 acc@1 (4 cls)	0,250	—	—	—	0,4257	0,4554	—
L2 acc@1 (23 cls)	0,043	—	—	—	0,1837	0,2041	—
L3 acc@1 (54 cls)	0,019	0,1782	0,1980	0,1980	0,2475	0,2079	$\geq 0,25$

Las tres primeras iteraciones quedan empatadas en [0,1782, 0,1980]. La cuarta alcanza 0,2475, a una imagen de test del objetivo predefinido (0,25). La quinta, ablación deliberada de escala bajo idéntica LoRA que v4, reduce el rendimiento a 0,2079 (−4,0 pp). El barrido de épocas y la síntesis tabular completa figuran en el Anexo I (figura I.1, tabla I.6).

4.13.3 Hallazgos científicos

El experimento arroja tres conclusiones diferenciadas.

(1) La adaptación textual aporta mejoras limitadas. Las iteraciones v1→v3, que actúan sobre el codificador textual y las *captions* ricas, quedan empatadas (0,178 → 0,198, ruido experimental): ninguna intervención textual extrae información que las *features* visuales no contengan ya (el diagnóstico de techo *Linear Probing* figura en el Anexo I, tabla I.3).

(2) La adaptación visual es la principal fuente de mejora. El salto +4,95 pp entre v3 y v4 (0,198 → 0,248, idéntico régimen *H6*) se atribuye a la ampliación de capacidad del codificador visual (LoRA $r = 32$ sobre doce bloques frente a $r = 16$ sobre cuatro). El cuello de botella era visual, no textual: es la palanca de mayor efecto del experimento.

(3) Ampliar con datos externos genéricos no mejora (resultado negativo). La quinta iteración añade 15 128 imágenes externas (PAD-UFES-20 [11], DermNet [13]) con *captions* sintéticas y reduce la *accuracy@1* L3 a 0,2079 (−4,0 pp): aunque el encoder visual mejora aislado (*H1* 0,168 → 0,238), las *captions* externas no preservan el registro del archivo y erosionan la alineación castellana sobre la que se calibra *H6*. La cola larga tampoco se rellena (327 clases L3 con ≤ 5 imágenes; sólo ocho ganan cobertura): superar el *zero-shot* L3 $\sim 0,25$ exige anotación experta *in-domain*, no escala genérica (sección 7.5.4). Convergente con la sensibilidad de DermLIP al tokenizador (sección 4.7), el hallazgo confirma que **la alineación cross-modal de un dominio clínico de alta especificidad lingüística es un recurso frágil**.

Una ablación con el modelo inglés DermLIP v2 ($\approx 403\,000$ pares Derm1M [2]) refuerza el diagnóstico: alcanza *accuracy@1* L3 = 0,287 (+3,96 pp sobre v4), de modo que la palanca limitante es la *escala* de la alineación cross-modal y no la formulación textual (eje idioma puro y *trade-off* operativo en el Anexo I). La cabeza supervisada cerrada

4.13. Dermapixel R0: rama contrastiva multimodal castellano zero-shot sobre DermapixelAI 1.0

con LoRA (sección 4.12) alcanza $\text{Acc}@1$ 0,250 en L2 frente a 0,133 de la rama contrastiva *zero-shot open-class* (v2): la ventaja de la rama no es la exactitud, sino aceptar consultas textuales libres en castellano sin vocabulario fijo, propiedad explotada en el módulo RAG del prototipo (Anexo H; comparativa en tabla I.5).

4.13.4 Recuperación multimodal

El segundo eje es la recuperación cross-modal per-imagen sobre los 107 pares (imagen, caption rica) de validación, con script idéntico entre versiones. La tabla 4.24 reporta el régimen *rich-caption* (l1m_case_summary, el más representativo del lenguaje clínico real de la Dra. R. Taberner).

Cuadro 4.24: Recuperación cross-modal i2t R@5 de la rama contrastiva de Dermapixel R0 sobre los 107 pares (imagen, caption rica) de validación, régimen *rich-caption* (l1m_case_summary). La columna *Lift* reporta el factor multiplicativo sobre el baseline aleatorio ($pool = 107$, baseline $R@5 = 5/107 = 0,0467$). v2 marca el pico histórico de alineación cross-modal castellano; v5 muestra descenso coherente con la degradación documentada en la tabla 4.23 sobre el régimen híbrido. v1 y v3 no se reportan por insuficiencia de datos en el régimen homogéneo cross-checkpoint. El *lift* (factor de mejora sobre el azar) se calcula como $R@5_{\text{abs}} / (k/N_{\text{pool}})$, con $k = 5$ y $N_{\text{pool}} = 107$; normaliza respecto a la dificultad intrínseca del *pool* y constituye la métrica honesta para comparar entre *checkpoints*.

Versión	i2t R@5 absoluto	Referencia azar	<i>Lift</i> sobre azar
v2	0,654	0,047	14,0×
v4	0,579	0,047	12,4×
v5	0,505	0,047	10,8×

La recuperación cross-modal alcanza su pico en v2: i2t R@5 = 0,654, un *lift* de **14,0×** sobre el azar (figura 4.10), y desciende en las iteraciones posteriores (v4 12,4×, v5 10,8×). El dato relevante es la tensión que revela: v4 es la mejor versión *clasificando* (0,2475 en L3) pero v2 es la mejor *recuperando*. Optimizar la clasificación y optimizar la búsqueda semántica no son, por tanto, el mismo problema: la LoRA visual (v4) y las *captions* externas (v5) reesculpen el espacio embebido a favor de la primera y en contra de la segunda.

4. RESULTADOS




Figura 4.10: Recuperación cross-modal i2t R@5 de la rama contrastiva de Dermapixel R0 sobre 107 pares de validación, régimen *rich-caption*. Pico v2 de **14,0 $\times$** de *lift* sobre el azar (0,047 $\rightarrow$ 0,654) atribuible al conjunto LoRA textual + *captions* sintéticas ricas generadas mediante un modelo de lenguaje grande. v4 y v5 conservan *lift* sustancial (12,4 $\times$ y 10,8 $\times$ respectivamente) pero descienden respecto al pico, en coherencia con la degradación documentada sobre el régimen híbrido.

La calibración de los logits *zero-shot* de la rama contrastiva por *temperature scaling* reduce el *Expected Calibration Error* (ECE) L3 un $\sim 97\%$ sobre v4 (0,7262 $\rightarrow$ 0,0213, $\tau = 0,4165$); el procedimiento, el diagrama de fiabilidad y la limitación de convergencia sobre v5 figuran en el Anexo I (tabla I.4, figura I.2). El sistema v4 es candidato a módulo de búsqueda textual castellano del prototipo DermApIxel (Anexo H), con la calibración escalar $\tau = 0,4165$ como capa final.

4.14 Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos

Esta sección analiza si las representaciones internas del modelo se corresponden con los conceptos que usa un dermatólogo, base de la interpretabilidad clínica. Las *features* del autoencoder disperso se alinean con los criterios dermatoscópicos clásicos, aunque forzar un cuello de botella conceptual cuesta exactitud, como muestran los experimentos sobre Derm7pt.

La línea de interpretabilidad mediante Sparse Autoencoders (SAE) del Anexo F introduce un SAE Large de 16384 *features* entrenado sobre las activaciones de PanDerm Large y validado sobre los 48 conceptos visuales de SkinCon [15]. Esta sección extiende la validación a Derm7pt [9] (1011 lesiones dermatoscópicas, *splits* oficiales 413/203/395, 24,5% melanomas) y explota las anotaciones del *Seven-Point Checklist*. Se realizan cuatro experimentos complementarios para evaluar si las representaciones del SAE codifican conceptos dermatoscópicos clínicamente relevantes (E1 alineamiento *single-feature*; E3 cruce con el Grupo A de la Dra. R. Taberner) y si dichos conceptos pueden

4.14. Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos

sostener modelos interpretables sin penalizar el rendimiento (E2 *Concept Bottleneck Model*; E4 *fine-tuning* multitarea). Todos sobre DGX Spark GB10.

E1 evalúa, para cada uno de los siete criterios binarizados, la AUROC efectiva $\max(\text{AUROC}, 1 - \text{AUROC})$ de cada una de las 16384 *features* como predictor binario. La tabla 4.25 reporta el AUROC efectivo de la mejor *feature* por criterio (*top-1*) y el promedio de las diez mejores (*top-10*) sobre Derm7pt completo ($N = 1011$).

Cuadro 4.25: Alineamiento *single-feature* entre las 16384 *features* del SAE Large y los siete criterios del *Seven-Point Checklist* sobre Derm7pt ($N = 1011$). AUROC efectiva $\max(\text{AUROC}, 1 - \text{AUROC})$ de la mejor *feature* individual (*top-1*) y promedio sobre las diez mejores (*top-10*). Mejor cifra agregada en negrita.

Criterio	N_+	N_-	AUROC <i>top-1</i>	AUROC <i>top-10</i>
pigment_network	611	400	0,754	0,737
streaks	358	653	0,688	0,684
pigmentation	423	588	0,700	0,657
regression_structures	253	758	0,687	0,673
dots_and_globules	782	229	0,681	0,663
blue_whitish_veil	195	816	0,746	0,721
vascular_structures	188	823	0,823	0,782

Las mejores *features* alcanzan AUROC efectivo entre 0,681 y 0,823 según el criterio evaluado (máximo sobre *vascular structures*). La estabilidad entre el *top-1* y el *top-10* (diferencia $\leq 0,043$) indica que el alineamiento no se concentra en una *feature* aislada: el SAE codifica los conceptos mediante un pequeño subconjunto coherente de activaciones.

E2 construye un CBM jerárquico de dos etapas: una cabeza logística sobre las 16384 activaciones estima la probabilidad de los siete criterios, y un meta-clasificador logístico predice melanoma/no-melanoma a partir de esas siete estimaciones. La comparativa con el sondeo lineal directo sin cuello de botella figura en la tabla 4.26.

Cuadro 4.26: Comparativa entre sondeo lineal directo sobre las 16384 *features* del SAE Large y CBM jerárquico con los siete criterios *Seven-Point Checklist* como cuello de botella. Conjunto de test Derm7pt ($N_{\text{test}} = 395$, 100 melanomas). AUROC en negrita.

Arquitectura	Acc@1	BAcc	AUROC	W-F1	Kappa
Sondeo lineal directo (SAE $\rightarrow$ melanoma)	0,841	0,735	0,890	0,829	0,527
CBM (SAE $\rightarrow$ 7 conceptos $\rightarrow$ melanoma)	0,825	0,681	0,832	0,801	0,440

La pérdida de 5,8pp de AUROC ($0,890 \rightarrow 0,832$) cuantifica el coste de obligar al modelo a razonar exclusivamente mediante conceptos explícitos. Los pesos del meta-clasificador identifican *blue whitish veil* y *regression structures* como conceptos dominantes para la decisión melanoma, jerarquía coherente con el peso que el *Seven-Point Checklist* [9] asigna a ambos (criterios mayores de 2 puntos); el desglose completo figura en el Anexo F (tabla F.5).

E3 cruza los 16 conceptos del Grupo A propuestos a la Dra. R. Taberner (sección 3.3) con el *Seven-Point Checklist*: 11 admiten *mapping* operativo y 7 quedan cubiertos por al menos una *feature* SAE con AUROC efectivo $\geq 0,70$ (incluido un concepto con sólo 15 positivos, lo que sugiere que el SAE captura conceptos poco frecuentes sin contaminación por la clase mayoritaria). Los 5 sin *mapping* corresponden a estructuras

no contempladas en la escala original y definen el contenido de la anotación clínica colaborativa (detalle completo en el Anexo F, tabla F6).

Ajuste fino multitarea: cabezas conceptuales y melanoma

E4 replica el protocolo multitarea de Kawahara et al. [9] sustituyendo la red convolucional por PanDerm Large, con LoRA ($r = 16$) sobre los dos últimos bloques (*blocks.22-23*), idéntico al protocolo de Dermapixel R0 (sección 4.12). Sobre la representación adaptada se conectan ocho cabezas paralelas (una por criterio del *Seven-Point Checklist* más una binaria de melanoma), optimizadas con la suma equiponderada de entropías cruzadas $\mathcal{L} = \sum_{i=1}^7 \text{CE}(\hat{c}_i, c_i) + \text{CE}(\hat{m}, m)$ y *class weight* balanceado (0,56 M parámetros entrenables, 0,18% del codificador). La tabla 4.27 compara E4 con el sondeo lineal directo (E2 Direct LP) y el CBM jerárquico (E2 CBM) sobre el test Derm7pt ($N_{\text{test}} = 395$, $n_{\text{mel}} \approx 98$), con IC95% por *bootstrap*.

Cuadro 4.27: Comparativa sobre la tarea binaria melanoma/no-melanoma entre sondeo lineal directo sobre las 16384 *features* del SAE Large (E2 Direct LP), CBM jerárquico de siete conceptos (E2 CBM) y *fine-tuning* multitarea LoRA con ocho cabezas paralelas (E4). Conjunto de test Derm7pt ($N_{\text{test}} = 395$, $n_{\text{mel}} \approx 98$), mismo *split* oficial. AUROC en negrita.

Método	Params entr.	Acc@1	BAcc	AUROC	W-F1	Kappa
E2 Direct LP (SAE $\rightarrow$ melanoma)	16 K	0,841	0,735	0,890	0,829	0,527
E2 CBM (SAE $\rightarrow$ 7 conceptos $\rightarrow$ mel)	~ 120	0,825	0,681	0,832	0,801	0,440
E4 FT multitarea LoRA	0,56 M	0,841	0,804	0,891	0,843	0,590

La cabeza melanoma del *fine-tuning* multitarea alcanza AUROC test = 0,891 (IC95% [0,856, 0,927]), que iguala al sondeo lineal directo (0,890, dentro del ruido del *bootstrap*) y mejora el CBM jerárquico en +5,9 pp. **A diferencia del CBM jerárquico, el aprendizaje multitarea conserva la capacidad discriminativa del modelo mientras mantiene salidas conceptuales explícitas:** ofrece predicción de melanoma e inferencia sobre los siete criterios en una sola pasada sin coste apreciable. Las cabezas conceptuales pierden entre 1 y 3 pp frente al sondeo lineal separado (Anexo F, tabla F7), pero que la cabeza melanoma no sufra penalización medible indica que *el aprendizaje multitarea no degrada la tarea principal cuando los conceptos auxiliares son taxonómicamente coherentes con ella*, como ocurre con el *Seven-Point Checklist*, instrumento diagnóstico de melanoma por construcción [9].

En síntesis, el SAE Large codifica conceptos dermatoscópicos clásicos sin supervisión explícita y generaliza a Derm7pt sin reentrenamiento (E1), el CBM jerárquico cuantifica el compromiso interpretabilidad–precisión (−5,8 pp AUROC, E2), el *fine-tuning* multitarea LoRA iguala al sondeo lineal directo en melanoma preservando inferencia concepto-a-concepto (E4), y 7 de los 11 conceptos del Grupo A con *mapping* quedan cubiertos por *features* SAE, definiendo los 5 restantes el contenido de la anotación clínica colaborativa (sección 7.5.3). El conjunto refuerza la viabilidad del módulo M3 de interpretabilidad del prototipo DermApIxel (Anexo H).

4.15 Síntesis comparativa de métodos sobre DermapixelAI 1.0

Las secciones 4.10–4.13 evalúan codificadores de dominio (PanDerm Base/Large, DermLIP v2), vision-lenguaje médicos (BiomedCLIP, SigLIP-SO400M) y las dos ramas de Dermapixel R0 sobre DermapixelAI 1.0. El Anexo J añade dos ablaciones complementarias —codificadores generalistas no médicos (DINOv2, CLIP-L) bajo sondeo lineal y dos arquitecturas de inferencia (*retrieval k*-NN con FAISS y *zero-shot* jerárquico en cascada)—, integradas en la síntesis. La tabla 4.28 consolida BAcc y AUROC por nivel ontológico para el conjunto completo de métodos.

Cuadro 4.28: Síntesis de codificadores y arquitecturas evaluados sobre DermapixelAI 1.0 (test fijo: $N = 36$ en L1/L2, $N = 28$ en L3). La columna *Ref.* remite a la sección de origen de las cifras completas con sus intervalos de confianza. Mejor valor por columna y nivel en negrita.

Método	Ref.	L1		L2		L3	
		BAcc	AUROC	BAcc	AUROC	BAcc	AUROC
PanDerm Base LP	\$4.11	0,570	0,697	0,221	0,707	0,132	0,735
PanDerm Large LP	\$4.11	0,735	0,796	0,265	0,793	0,184	0,813
DermLIP v2 LP	\$4.11	—	—	—	0,860	—	—
DINOv2 ViT-L LP	Anx. J	0,537	0,650	0,250	0,718	0,211	0,794
CLIP-L-336 LP	Anx. J	0,556	0,658	0,279	0,826	0,184	0,827
Dermapixel R0 LoRA	\$4.14	—	—	0,363	0,855	—	—
FT parcial denso L1+L2+L3	\$4.11	0,622	0,715	0,324	0,852	0,184	0,804
<i>k</i> -NN FAISS PanDerm Large	Anx. J	0,686	0,748	0,265	0,700	0,210	0,719

No existe un método universalmente superior sobre DermapixelAI 1.0: el rendimiento depende simultáneamente del nivel ontológico considerado (L1–L3) y del criterio de evaluación (clasificación equilibrada, discriminación probabilística o recuperación basada en similitud). Las cifras de esta síntesis se reportan sobre el test fijo ($N = 36$ en L1/L2, $N = 28$ en L3), por lo que las jerarquías entre métodos en L2 y L3 deben leerse como indicio y remitirse a la validación cruzada agrupada por caso (tabla 4.16) como estimación defendible del rendimiento esperado del sondeo lineal congelado. Sobre L1, el sondeo lineal sobre PanDerm Large encabeza simultáneamente BAcc (0,735) y AUROC (0,796); sobre L2, Dermapixel R0 LoRA encabeza la BAcc (0,363) y CLIP-L-336 LP encabeza la AUROC (0,826); sobre L3, el *retrieval k*-NN FAISS sobre embeddings de PanDerm Large encabeza la BAcc (0,210) y CLIP-L-336 LP encabeza la AUROC (0,827). La discriminación binaria melanoma/no-melanoma sobre Derm7pt (sección 4.14, fuera de DermapixelAI 1.0) alcanza AUROC 0,891 con el *fine-tuning* multitarea LoRA E4 sobre las activaciones del SAE. En conjunto, los resultados del capítulo muestran tres regularidades. Primero, los modelos preentrenados específicamente sobre dermatología (PanDerm y DermLIP) superan de forma consistente a las alternativas generalistas cuando la tarea exige transferencia clínica fina. Segundo, la adaptación eficiente mediante LoRA permite especializar estos modelos a un dominio local en castellano con mejoras relevantes sobre las representaciones congeladas y sin necesidad de reajuste completo. Tercero, el rendimiento no depende únicamente de la escala del modelo o del volumen de datos, sino de la calidad de la alineación entre imágenes, etiquetas y lenguaje clínico. La elección de la arquitectura óptima queda así condicionada por el nivel ontológico objetivo y por el uso previsto del sistema (clasificación, recuperación o soporte explicativo), en línea con la lectura interpretativa de la sección 5.1.1.

4. RESULTADOS

Como exploración aplicada orientada a seguridad clínica, se evaluó un *ensemble* entre modelos dermatológicos y generalistas para maximizar la sensibilidad en melanoma; al tratarse de una característica del prototipo y no de un resultado central sobre modelos fundacionales, los detalles completos (configuración, tabla comparativa y análisis de complementariedad) se presentan en el Anexo H (sección H.8.7).

DISCUSIÓN

5.1 Significado de los resultados

La lectura agregada de los experimentos no apunta a la existencia de un único modelo vencedor, sino a que el rendimiento dermatológico está condicionado por cuatro dimensiones principales: el nivel ontológico al que se evalúa, el régimen de datos etiquetados disponible, la modalidad de entrada y la estrategia de adaptación empleada. Los resultados sugieren que, una vez alcanzado un determinado nivel de capacidad representacional en los codificadores visuales modernos, las diferencias de rendimiento dependen cada vez más de factores relacionados con los datos, la formulación de la tarea y la integración multimodal. Entre ellos destacan la taxonomía utilizada para organizar las clases, el volumen y la calidad de las etiquetas, el alineamiento texto-imagen de las ramas contrastivas, la formulación de los *prompts*, la equidad entre subgrupos y la propia estrategia de despliegue. Las subsecciones siguientes interpretan estos factores a partir de la evidencia empírica del capítulo 4, mientras que la sección 5.3 deriva sus implicaciones operativas para el diseño de sistemas dermatológicos basados en modelos fundacionales.

5.1.1 Ausencia de un método óptimo único: especialización por tarea

La síntesis transversal de los experimentos sobre DermapixelAI 1.0 (tabla 4.28) muestra que no existe un método universalmente superior para todas las tareas evaluadas. Los distintos modelos alcanzan su mejor rendimiento en escenarios diferentes según el nivel ontológico, la modalidad de entrada y el criterio de evaluación considerado. Así, los codificadores especializados destacan en transferencia visual y clasificación supervisada, las arquitecturas contrastivas muestran ventajas en recuperación multimodal y búsqueda semántica, los métodos basados en recuperación resultan competitivos en escenarios de cola larga diagnóstica y los *ensembles* aportan sensibilidad adicional en tareas de seguridad clínica como el cribado de melanoma.

Esta diversidad de resultados sugiere que el problema no puede formularse en términos de un único modelo vencedor. La elección óptima depende del objetivo perseguido: clasificación general, subcategorización clínica, recuperación de casos similares, segmentación, razonamiento multimodal o maximización de sensibilidad diagnóstica. En consecuencia, la pregunta relevante deja de ser *qué modelo es el mejor* en términos absolutos y pasa a ser *qué combinación de codificador, estrategia de adaptación y mecanismo de inferencia resulta más adecuada para una tarea concreta*.

Este hallazgo conecta con una idea recurrente a lo largo del capítulo 4: a medida que los modelos fundacionales alcanzan niveles elevados de capacidad representacional, las diferencias de rendimiento dependen cada vez más de cómo se formula el problema, de la estructura de los datos y del objetivo clínico perseguido que de la arquitectura aislada del modelo. Las subsecciones siguientes desarrollan esta conclusión desde tres perspectivas complementarias: el nivel ontológico de clasificación, la estrategia de adaptación y el paradigma de inferencia empleado.

5.1.1.1 Especialización por nivel ontológico

El peso del preentrenamiento de dominio queda establecido por el sondeo lineal (sección 4.2, sección 4.3): PanDerm Large supera a PanDerm Base con una mejora media de +9,0 pp en BAcc sobre los diez datasets externos contrastados (tabla 4.1). El detalle por dataset matiza el origen del beneficio: es modesto sobre dermatoscopia estandarizada —donde una arquitectura convolucional supervisada sobre ImageNet-21K llega a empatar la AUROC— y crece sobre fotografía clínica con dispositivos heterogéneos. Los resultados sugieren que la ventaja del preentrenamiento de dominio aumenta con la distancia entre el dataset y los datasets web generalistas, lo que la hace especialmente relevante en condiciones clínicas no estandarizadas, como la atención primaria o la teledermatología. SigLIP-Large SO400M confirma esta lectura desde el extremo opuesto: lidera sobre HAM10000 (tabla 4.2) por la sobrerrepresentación de dermatoscopia estandarizada en su preentrenamiento web, pero esa superioridad se desvanece sobre el material clínico heterogéneo.

Esta ventaja, sin embargo, no es uniforme entre niveles ontológicos. Sobre la cardinalidad clínica intermedia L2, DermLIP v2 se sitúa como la mejor cabeza individual, con una ventaja de +6,7 pp de AUROC sobre PanDerm Large (sección 4.10.3), y lidera también la AUROC L2 en régimen *zero-shot* sin entrenar cabeza alguna (sección 4.11). Ambos resultados sugieren que el preentrenamiento contrastivo texto-imagen de Derm1M [2] captura la granularidad de subcategoría clínica con mayor fidelidad que el preentrenamiento auto-supervisado puro de la familia PanDerm. La jerarquía PanDerm Large > DermLIP v2, válida en la mayoría de datasets, se invierte por tanto en L2: el codificador óptimo depende del nivel ontológico objetivo.

5.1.1.2 Adaptación eficiente frente a ajuste denso

El ajuste fino parcial sobre DermapixelAI 1.0 (sección 4.10.3), con un volumen de entrenamiento reducido ($N_{\text{train}} = 874$), mejora sustancialmente la BAcc sobre el sondeo lineal congelado, pero no supera al *ensemble* lineal de codificadores congelados, que lo aventaja en BAcc y AUROC (tabla 4.17). El patrón es coherente con la literatura sobre régimen de bajo N : combinar linealmente codificadores fundacionales congelados

aprovecha la diversidad de sus representaciones sin añadir los parámetros que el ajuste denso debe estimar sobre un dataset reducido.

La cabeza supervisada L2 de Dermapixel R0 (sección 4.12) confirma esta lectura y aporta la cifra-ancla del argumento: la adaptación LoRA sobre los dos últimos bloques de PanDerm Large —524 K parámetros entrenables, una razón aproximada de $48\times$ frente a los 25,2 M del ajuste denso parcial— alcanza la mejor BAcc L2 documentada sobre el dataset, y su AUROC L2 empata estadísticamente con la de DermLIP v2 nativo (tabla 4.18). El ajuste denso, pese a su mayor parametrización, no supera a la adaptación de bajo rango sobre el mismo encoder; sobre L3, además, ningún protocolo de ajuste denso rebasa el techo que impone la cola larga estructural. La implicación de diseño es directa y motiva la arquitectura de Dermapixel R0 (sección 7.5.2): en régimen de bajo N , la adaptación de bajo rango y la combinación de codificadores con cabezas ligeras son preferibles al ajuste fino denso clásico.

Más allá de sus métricas concretas, Dermapixel R0 constituye una prueba de viabilidad de la adaptación eficiente de modelos fundacionales en entornos hospitalarios. Los resultados muestran que es posible construir un modelo dermatológico adaptado al castellano mediante técnicas PEFT sobre pesos previamente entrenados, sin necesidad de reproducir la escala de datos ni de cómputo del preentrenamiento original. Mientras que el entrenamiento fundacional sigue estando reservado a grandes consorcios de investigación, la evidencia obtenida indica que instituciones sanitarias y grupos académicos pueden desarrollar adaptaciones especializadas con recursos sustancialmente más modestos. En este sentido, Dermapixel R0 debe interpretarse menos como un sistema de máximo rendimiento y más como una demostración de que la especialización dermatológica de bajo coste resulta técnicamente factible.

5.1.1.3 Retrieval frente a clasificación paramétrica

Una tercera fuente de especialización emerge sobre la cola larga, en el paradigma de clasificación. Dos observaciones la sostienen. Primero, CLIP-L-336, un codificador generalista sin material biomédico en su preentrenamiento, encabeza la AUROC bajo sondeo lineal sobre L2 y L3 (sección J.6), lo que matiza la hipótesis de especialización de dominio cuando la métrica es el ranking probabilístico. Este resultado no contradice la ventaja global del preentrenamiento dermatológico, sino que pone de manifiesto que la AUROC y la BAcc capturan propiedades distintas del espacio de representación: la primera mide la ordenación probabilística y la segunda el acierto equilibrado por clase. Segundo, sustituir el clasificador paramétrico por *retrieval* k -NN con índice FAISS sobre los mismos *embeddings* de PanDerm Large (sección J.7) supera al sondeo lineal en el régimen de cola larga severa L3, donde el escaso número de muestras por clase penaliza a los clasificadores paramétricos. La recuperación por vecindad, además, es operativamente atractiva: no exige reentrenar una cabeza al incorporar clases nuevas y permite mostrar los casos similares que sustentan la predicción. Ambas observaciones cierran la lectura: la elección óptima debe condicionarse al nivel ontológico y al criterio operativo predominante, no a un codificador o clasificador presupuesto como universal. Esta lectura sobre L3 debe entenderse, no obstante, como indicio y no como ordenación cerrada: la cola larga extrema y el tamaño reducido del conjunto de test en ese nivel (sección 6.4) limitan la fuerza de cualquier ranking sobre L3.

5.1.2 DermapixelAI 1.0 como contribución metodológica

Buena parte de la lectura anterior se apoya en DermapixelAI 1.0, cuyo papel en este trabajo conviene precisar: no es un dataset auxiliar de validación, sino una contribución metodológica en sí misma. Se trata de un dataset clínico construido en castellano, independiente del dataset de preentrenamiento Derm1M y auditado por hash MD5 frente a él (sección 4.1), lo que permite evaluar transferencia, *zero-shot*, adaptación LoRA y *retrieval* sin la incertidumbre de solapamiento que afecta a otros conjuntos. Su organización conforme a la ontología jerárquica L1/L2/L3 habilita la comparación de modelos a varios niveles de granularidad sobre un mismo material, y su disponibilidad documentada lo sitúa como punto de partida para evaluar modelos fundacionales sobre dermatología clínica en español.

Más aún, DermapixelAI 1.0 no se limita a proporcionar un nuevo conjunto de imágenes dermatológicas, sino que habilita preguntas experimentales que los *benchmarks* clásicos no permiten abordar. La estructura jerárquica L1/L2/L3 posibilita estudiar el comportamiento de los modelos a diferentes niveles de granularidad diagnóstica; la disponibilidad simultánea de imagen y texto clínico en castellano permite evaluar recuperación multimodal y alineamiento *cross-modal*; y la auditoría explícita frente a Derm1M garantiza que los experimentos de transferencia, *zero-shot* y adaptación se realizan en un escenario libre de contaminación conocida. En este sentido, DermapixelAI 1.0 actúa simultáneamente como *benchmark*, banco de pruebas para modelos fundacionales dermatológicos y demostrador metodológico para futuros estudios en español.

A diferencia de los grandes repositorios internacionales, concebidos principalmente para clasificación supervisada, DermapixelAI 1.0 ha sido diseñado desde su origen para soportar tareas heterogéneas —clasificación, recuperación multimodal, razonamiento asistido por RAG y adaptación eficiente de modelos fundacionales—, aproximándose más a las necesidades reales de un entorno clínico digital. Esta orientación lo convierte, antes que en un *dataset*, en la plataforma experimental sobre la que se han generado los resultados de las secciones 4.10–4.15.

La interpretación debe acotarse: se trata de una primera versión de tamaño limitado y con una cola larga marcada a nivel L3, por lo que las cifras derivadas requieren la estimación robusta discutida en sección 5.1.10 y no admiten extrapolación directa a la práctica asistencial.

5.1.3 Eficiencia en etiquetas y régimen de saturación

Si el preentrenamiento de dominio es tan determinante, cabe preguntarse cuántas etiquetas son realmente necesarias para explotarlo. La curva de eficiencia en etiquetas (sección 4.5, tabla 4.5) muestra un comportamiento característico de los modelos fundacionales: la mayor parte de la capacidad discriminativa ya está codificada en las representaciones aprendidas durante el preentrenamiento, de modo que el clasificador supervisado sólo necesita una pequeña cantidad de ejemplos para adaptarse a una tarea concreta.

Sobre HAM10000, PanDerm Large alcanza 0,850 de *accuracy* y 0,918 de AUROC utilizando únicamente el 1 % del conjunto de entrenamiento (82 imágenes), lo que equivale al 95,7 % y al 96,2 % del rendimiento obtenido con el conjunto completo.

Con sólo el 5 % de los datos (410 imágenes) la AUROC asciende a 0,932, el 97,7 % del máximo observado y a sólo 2,2 pp de la cifra con el 100 %. La *balanced accuracy* continúa mejorando con el incremento de muestras y no alcanza su mejor valor (0,589) hasta el 50 % del conjunto, reflejando que las clases minoritarias siguen beneficiándose de un mayor volumen de ejemplos.

El mismo patrón aparece sobre PAD-UFES-20 ($N_{\text{train}} = 1\,493$ con el conjunto completo). Con únicamente 14 imágenes de entrenamiento (1 %), PanDerm Large obtiene 0,740 de *accuracy* y una AUROC de 0,907, equivalente al 95,5 % del rendimiento alcanzado con todas las etiquetas disponibles. La rápida saturación observada en ambos datasets sugiere que gran parte del conocimiento visual relevante para la dermatología ya se encuentra internalizado en las representaciones del codificador.

Este comportamiento tiene una consecuencia práctica importante. En los modelos supervisados clásicos, la obtención de nuevas etiquetas suele constituir la principal vía para mejorar el rendimiento; en cambio, en los modelos fundacionales dermatológicos la rentabilidad marginal de cada nueva etiqueta disminuye rápidamente una vez superado un umbral relativamente bajo de ejemplos. A partir de ese punto, la calidad del preentrenamiento y la adecuación del dominio pueden resultar más determinantes que el simple aumento del tamaño del conjunto etiquetado.

Desde una perspectiva clínica, el resultado es especialmente relevante para enfermedades raras, centros con bajo volumen asistencial o subgrupos infrarrepresentados, donde la obtención de miles de anotaciones expertas es poco realista. Los datos sugieren que una estrategia basada en codificadores fundacionales especializados y cabezas ligeras puede ofrecer rendimientos cercanos al máximo alcanzable incluso en escenarios de escasez de datos. Esta observación refuerza una de las ideas centrales del trabajo: en dermatología, el cuello de botella deja de ser necesariamente la disponibilidad de etiquetas y pasa a ser, en muchos escenarios, la calidad del preentrenamiento del que se parte.

5.1.4 Sondeo lineal frente a ajuste fino

La elección entre congelar el encoder o reentrenarlo no tiene una respuesta única, y esta subsección discute de qué depende. La comparación directa entre sondeo lineal y ajuste fino sobre cuatro datasets (sección 4.4, tabla 4.4) revela un patrón asimétrico con implicaciones para el diseño de sistemas clínicos. Sobre HAM10000 y PAD-UFES-20, datasets de tamaño intermedio o alto ($N \in [1\,493, 8\,207]$), el ajuste fino mejora la BAcc en +47,1 pp y +19,4 pp respectivamente. Esto confirma la utilidad de la receta original de PanDerm —*weighted random sampler*, Mixup, CutMix y *layer decay*— para aprender las clases minoritarias bajo desbalance acusado.

El comportamiento se invierte cuando el dataset es pequeño. Sobre DDI, con $N_{\text{train}} = 427$, el sondeo lineal supera al ajuste fino en *accuracy* (+7,3 pp), BAcc (+2,1 pp), AUROC (+14,5 pp) y F1 ponderada (+5,6 pp). El descenso de AUROC (0,827 $\rightarrow$ 0,682) es especialmente diagnóstico: el encoder ajustado pierde capacidad de ranking sobre el *test*, lo que es compatible con sobreajuste a la distribución de entrenamiento pese a las aumentaciones empleadas. Sobre MSKCC ($N_{\text{train}} = 6\,189$), la mejora de BAcc es marginal (+3,0 pp) y la AUROC desciende ligeramente (−2,7 pp). La asimetría admite una explicación común: el ajuste fino sólo rentabiliza su mayor capacidad cuando el conjunto de entrenamiento basta para estimar los nuevos pesos sin memorizar la

distribución; por debajo de ese umbral, congelar el encoder actúa como regularización implícita y preserva la capacidad de *ranking* heredada del preentrenamiento.

Estos tres casos delimitan un régimen operativo cuantificable. Para datasets con $N_{\text{train}} \lesssim 500$ imágenes, el sondeo lineal sobre PanDerm Large es la opción de referencia. Para $N_{\text{train}} \gtrsim 5000$, el ajuste fino con la receta original es preferible, siempre que existan clases minoritarias clínicamente relevantes que el sondeo lineal no logre discriminar. Entre ambos regímenes, la decisión depende del desbalance de clases y del coste computacional asumible.

La oposición no se reduce, sin embargo, a congelar frente a ajustar el encoder completo: cabe una tercera vía intermedia. La evidencia sobre DermapixelAI 1.0 a nivel L2 (sección 4.10.3) indica que la adaptación de bajo rango mediante LoRA mejora la BAcc frente al ajuste fino parcial denso entrenando del orden de 48 veces menos parámetros. Este patrón condiciona la estrategia recomendable bajo N reducido: la adaptación eficiente es preferible al ajuste denso, no sólo por coste computacional sino por menor exposición al sobreajuste. La implicación de diseño es directa y se materializa en la decisión arquitectónica de Dermapixel R0 (sección 4.12), que adopta LoRA sobre los últimos bloques de PanDerm Large en lugar de un ajuste fino denso sobre el mismo encoder.

En conjunto, la evidencia ordena las tres estrategias en una regla escalonada por volumen de datos: con $N_{\text{train}} \lesssim 500$ imágenes, sondeo lineal sobre el encoder congelado; en el régimen intermedio, adaptación de bajo rango (LoRA), preferible al ajuste denso por su menor exposición al sobreajuste a igualdad o mejora de rendimiento; y sólo con $N_{\text{train}} \gtrsim 5000$ imágenes y clases minoritarias clínicamente relevantes, ajuste fino denso con la receta original. La capacidad del modelo a desplegar debe escalar, por tanto, con los datos disponibles, no fijarse a priori.

5.1.5 Segmentación promptable y adaptación de bajo coste

La segmentación aporta el hallazgo de mayor magnitud absoluta del trabajo, y conviene discutir tanto su alcance como su origen. Sobre ISIC2018 (sección 4.6, tabla 4.6), SAM2.1-Large con *fine-tuning* de su decodificador alcanza Dice 0,947 en el conjunto de test. Supera en +2,6 pp la cifra publicada por Yan et al. [1] (0,921) y en +5,3 pp al baseline CAE-seg con backbone PanDerm Large entrenado desde cero (0,894). El ajuste mantiene congelado el *image_encoder* y entrena sólo el decodificador de máscaras y el *promptable encoder*. Por eso los pesos actualizados se limitan a $\sim 4,2$ M sobre los ~ 227 M de SAM2.1-Large (menos del 2%), con un coste computacional bajo.

La transferencia fuera de dominio es prácticamente nula: el Dice apenas varía sobre ISIC2017 y PH2 respecto a ISIC2018. Este patrón sugiere que las representaciones del encoder visual congelado (Hiera-Large) codifican primitivas geométricas y de contorno suficientemente generales, de modo que el ajuste del decodificador de máscaras y del *promptable encoder* captura los matices del dominio dermatoscópico sin sobreajustar a una fuente de adquisición concreta. La magnitud del efecto de la adaptación de dominio, cuantificada en sección 4.6 frente a SAM2 *zero-shot*, confirma que el coste de adaptación se concentra en el decodificador y no en el encoder.

La comparativa pareada de arquitecturas promptables (sección 4.6.1, tabla 4.7) matiza, no obstante, dónde reside ese valor. La generación de la arquitectura pesa más que el preentrenamiento médico: SAM2.1-tiny generalista supera a MedSAM v1

con preentrenamiento médico, y el tamaño de *backbone* no aporta en el régimen *box-prompted*. La especialización dermatológica del segmentador parece, por tanto, un factor secundario frente al diseño del modelo. Esta asimetría contrasta con el peso decisivo del preentrenamiento de dominio observado en clasificación (sección 5.1.1) e invita a tratar por separado ambas familias de tareas.

Este resultado sugiere que la segmentación constituye un caso particular dentro de los modelos fundacionales médicos. Mientras que en clasificación la especialización de dominio emerge como el principal determinante del rendimiento (sección 5.1.1), en segmentación la capacidad de la arquitectura parece dominar sobre el origen del preentrenamiento. Dicho de otro modo, reconocer *qué* lesión aparece en una imagen sigue dependiendo en gran medida del conocimiento dermatológico adquirido durante el preentrenamiento, mientras que delimitar *dónde* termina la lesión parece depender principalmente de mecanismos geométricos y espaciales más generales.

El control automático sin caja (sección 4.6.2) reordena, sin embargo, esta jerarquía de factores. Si las cinco arquitecturas *promptables* caben en ~ 1 pp pero retirar el *prompt* cuesta 7,5 pp, el determinante real del rendimiento no es el segmentador sino la caja: la información de localización pesa entre seis y siete veces más que la elección de modelo. La consecuencia de diseño es directa —el esfuerzo de ingeniería rinde más en el detector que produce la caja que en sustituir un segmentador por otro— y conecta con la decisión de producto de ofrecer un modo interactivo, en el que el clínico aporta la caja, junto a uno automático. Desde una perspectiva metodológica, este hallazgo obliga además a reinterpretar las comparaciones habituales entre segmentadores: cuando la diferencia entre arquitecturas es del orden de un punto porcentual y la calidad del *prompt* modifica el rendimiento en más de siete, una parte sustancial de la literatura comparativa puede estar midiendo indirectamente diferencias en localización más que diferencias reales entre segmentadores. Para este último, el análisis de robustez (sección 4.6.3) deja una especificación poco habitual pero accionable: dado que apretar la caja degrada el Dice mucho más que aflojarla, el detector debe sesgarse hacia cajas ligeramente holgadas. La validación cruzada de cinco pliegues sitúa además el *headline* en $0,9554 \pm 0,0010$, lo que eleva la cifra de segmentación de estimación puntual a estimación con intervalo, a diferencia del resto de protocolos del trabajo.

Conviene, por último, no sobreinterpretar la magnitud absoluta. El análisis sobre anotación múltiple (sección 4.6.4) muestra que el acuerdo entre dermatólogos sobre el mismo contorno es de apenas 0,728 de Dice, mientras que el modelo concuerda con el consenso en 0,915. El 0,9556 se sitúa, por tanto, cerca del techo que impone la propia ambigüedad del borde lesional: las diferencias de ~ 1 pp entre arquitecturas son inferiores al desacuerdo inter-anotador y el «error» residual frente a una referencia única es, en buena medida, ruido de etiqueta. La salvedad pertinente es que esa consistencia convive con una ligera sobreconfianza en los bordes dudosos, donde el modelo traza una frontera nítida que los humanos no comparten. En consecuencia, el valor de Dice debe interpretarse como una aproximación al consenso humano más que como una medida absoluta de verdad geométrica: una vez alcanzado el entorno de 0,95 frente a una referencia única, el margen de mejora técnica disponible pasa a estar condicionado por la propia incertidumbre de la anotación clínica.

5.1.6 Sensibilidad al tokenizador en zero-shot multimodal

El rendimiento zero-shot no depende sólo del modelo, sino de cómo se le interroga. La evaluación sobre HAM10000 (sección 4.7, tabla 4.9) revela una sensibilidad acusada al tokenizador y a la formulación de los *prompts*. La AUROC oscila entre 0,366 (DermLIP v1/v2 con tokenizador PubMedBERT y *prompts* genéricos) y 0,854 (DermLIP original con tokenizador GPT-2/CLIP y *prompts* A3 de Derm1M). Es un rango de 48,8 pp para variaciones que no tocan los pesos visuales, sino sólo la rama lingüística y la formulación textual de las clases.

A diferencia de los clasificadores supervisados convencionales, donde la etiqueta final se obtiene a partir de una cabeza entrenada explícitamente para la tarea, los sistemas *vision-lenguaje zero-shot* realizan una comparación geométrica entre *embeddings* visuales y textuales. En consecuencia, la calidad de la predicción depende simultáneamente de ambos espacios y, sobre todo, de su alineamiento mutuo: un encoder visual excelente puede producir resultados mediocres si las representaciones textuales no ocupan la región adecuada del espacio compartido.

El valor AUROC < 0,5 de la configuración inicial es diagnóstico de un desalineamiento entre el espacio textual proyectado por PubMedBERT y el espacio visual del encoder de DermLIP v1/v2, hasta el punto de invertir la correlación respecto a la tarea de clasificación. El experimento de modificaciones aisladas (sección 4.7) permite atribuir la recuperación del rendimiento a la combinación de dos factores —el cambio de tokenizador y el cambio al conjunto de *prompts* A3—, sin que la evidencia disponible permita aislar una causa única de forma concluyente, puesto que ambos operan sobre la misma rama textual. La lectura no debe, por tanto, formularse como causalidad absoluta de un único componente, sino como el efecto conjunto del tokenizador, los *prompts* y el alineamiento texto-imagen resultante. Los resultados sugieren que, en régimen *zero-shot*, la rama textual deja de ser un mecanismo de entrada y pasa a formar parte efectiva del modelo de decisión: desde esta perspectiva, el tokenizador, los *prompts* y el encoder textual no son hiperparámetros externos, sino componentes funcionales del clasificador. De aquí se sigue una implicación práctica directa: todo despliegue *zero-shot* debe validar empíricamente, sobre un conjunto del dominio, no sólo el modelo sino también su tokenizador y la formulación de los *prompts*, porque la transferencia desde la configuración publicada por los autores no está garantizada. El experimento cuestiona, además, una práctica habitual en la literatura multimodal: reportar resultados *zero-shot* utilizando una única configuración de *prompts*. Sobre los datos de este trabajo, la variabilidad inducida por la formulación textual supera ampliamente la diferencia entre algunas arquitecturas visuales, lo que sugiere que las comparaciones entre modelos sin controlar el espacio de *prompts* pueden resultar difíciles de interpretar.

La evaluación adicional sobre DermapixelAI 1.0 (sección 4.11, tabla 4.20) extiende esta lectura al idioma. DermLIP v2 con *prompts* en inglés alcanza Acc@1 = 0,500 sobre la categoría etiológica L1, frente a 0,361 con *prompts* equivalentes en castellano (−13,9 pp); SigLIP-SO400M cae −11,1 pp en la misma comparación. BiomedCLIP, en cambio, mantiene Acc@1 = 0,389 en ambos idiomas. Esto sitúa la penalización por castellano como dependiente del dataset textual de preentrenamiento. La magnitud de la caída motiva, como línea futura inmediata, construir modelos *vision-lenguaje* contrastivos con rama textual entrenada sobre material clínico en castellano. Esta

penalización proporciona, además, una posible explicación mecánica para parte de los resultados obtenidos posteriormente con Dermapixel R0 (sección 5.1.1): si una simple traducción del vocabulario diagnóstico reduce el rendimiento entre 11 y 14 pp, resulta razonable esperar que una adaptación explícita de la rama textual al lenguaje clínico castellano aporte beneficios incluso cuando la representación visual permanece inalterada.

5.1.7 Brecha entre modelos específicos y LLMs multimodales

La sensibilidad de la rama contrastiva al texto invitaba a comprobar si los grandes modelos de lenguaje multimodales, con dataset de preentrenamiento mucho mayores, cierran la distancia con los especialistas. La comparación de paradigmas sobre HAM10000 (sección 4.8, tabla 4.11) muestra lo contrario y fija un orden de magnitud entre familias relevante para elegir arquitectura en escenarios clínicos. El gradiente de accuracy entre el mejor especialista ajustado (PanDerm Base con ajuste fino y *test-time augmentation*) y el mejor LLM multimodal *zero-shot* (GPT-4o) supera los 43 pp; la tabla 4.11 desglosa la escala completa de configuraciones intermedias. La magnitud de la diferencia observada sugiere que, al menos en dermatología visual, el conocimiento específico del dominio continúa siendo más determinante que la escala general del modelo: la disponibilidad de miles de millones de parámetros y de grandes capacidades lingüísticas no compensa la ausencia de una representación dermatológica especializada.

Tres observaciones cualitativas, detalladas en sección 4.8, matizan esta brecha sin reducirla. Primero, la adaptación con LoRA sobre MedGemma 27B mejora la accuracy sobre los datasets vistos en entrenamiento pero no transfiere de forma sistemática al resto, lo que aconseja reportar su rendimiento por dataset y no agregado. Segundo, GPT-4o y GPT-4o-mini exhiben un sesgo de error hacia clases minoritarias del *prompt* —con sobreproducción de predicciones de dermatofibroma y melanoma muy por encima de su prevalencia real—, lo que sugiere que responden al espacio léxico de la consigna tanto como a la evidencia visual. Este patrón es compatible con un razonamiento guiado parcialmente por asociaciones semánticas aprendidas durante el preentrenamiento generalista y no exclusivamente por evidencia visual, por lo que la interpretación de las respuestas de los LLM multimodales requiere cautela cuando se aplican a taxonomías clínicas especializadas. Tercero, BLIP-2 e InstructBLIP con *Q-Former* preentrenado producen una accuracy incompatible con cualquier uso clínico, atribuible a la falta de adaptación al vocabulario dermatológico. Las tres observaciones convergen en que la distancia entre especialistas y LLMs multimodales generalistas no se explica por capacidad bruta del modelo, sino por su grado de adaptación al dominio. La conclusión queda acotada, en todo caso, a los *prompts* estandarizados y a la versión de los modelos cerrados disponible en la fecha de evaluación (sección 6.1.1): no afirma el techo teórico de estos modelos, sino su rendimiento en el régimen de uso evaluado.

De forma consistente con otros experimentos del trabajo, la escala del modelo no emerge como la variable dominante. En segmentación el principal determinante fue la disponibilidad del *prompt* espacial (sección 5.1.5); en *zero-shot* multimodal, la alineación texto-imagen (sección 5.1.6); y en clasificación dermatológica, el preentrenamiento de dominio (sección 5.1.1). La capacidad paramétrica por sí sola no explica el rendimiento observado en ninguno de los tres regímenes.

La brecha tiene además una vertiente de coste. La evaluación con APIs comerciales sobre los tres datasets cuesta unos \$4,07. MedGemma 27B, en cambio, opera localmente en BF16 sobre los 128 GB de memoria unificada de la DGX Spark sin cuantización, con latencia media de 1,49 segundos por imagen. La diferencia operativa importa para un despliegue hospitalario: los modelos cerrados añaden coste recurrente y dependencia de un proveedor externo, sin mejora apreciable de rendimiento clínico. Desde una perspectiva hospitalaria, el resultado desplaza el criterio de selección desde la popularidad del modelo hacia su adecuación al dominio: bajo las condiciones evaluadas, los modelos fundacionales dermatológicos ofrecen simultáneamente mejor rendimiento, menor coste operativo y mayor soberanía tecnológica que las alternativas multimodales cerradas de propósito general.

5.1.8 Equidad por fototipo cutáneo

La generalización entre fototipos es una condición de seguridad clínica, y los resultados la cuantifican sin ambigüedad. La evaluación sobre Fitzpatrick17k completo (sección 4.9, tablas 4.12 y B.9) reproduce un patrón conocido en la literatura: los cinco encoders contrastados presentan *gap* I-VI positivo en la formulación de tres clases de malignidad, con valores entre +0,124 y +0,306 pp de BAcc. Ese *gap* no se interpreta en aislamiento, sino junto a la BAcc global de cada modelo. DermLIP v2 obtiene la mejor BAcc global (0,721) y la mejor AUROC global (0,909), pero su *gap* I-VI es +0,281 pp: el rendimiento sobre FST VI (0,434) cae mucho respecto a FST III (0,765). PanDerm Large presenta un *gap* menor (+0,217 pp) con BAcc global ligeramente inferior (0,699). BiomedCLIP exhibe el *gap* mínimo (+0,124 pp), pero la peor BAcc global (0,590).

Esta última asimetría —*gap* mínimo con BAcc global inferior— ilustra que la métrica de equidad aislada no es decisional. **Un modelo uniformemente malo entre subgrupos puede mostrar baja desigualdad aritmética sin ser equitativo en sentido sustantivo**, porque su rendimiento es bajo en todos los fototipos por igual. El *gap* mínimo de BiomedCLIP no señala, por tanto, un modelo más justo, sino uno uniformemente peor: la equidad no puede medirse al margen del rendimiento que reparte. Por eso BAcc global y *gap* deben leerse de forma conjunta. Considerando conjuntamente rendimiento global y magnitud del *gap*, PanDerm Large presenta el equilibrio más favorable entre ambas dimensiones dentro de los modelos evaluados, seguido de DermLIP v2 cuando se ponderan el rendimiento sobre FST I-IV y la AUROC global.

Desde una perspectiva asistencial, el hallazgo implica que un modelo validado únicamente mediante métricas globales puede ocultar pérdidas relevantes de sensibilidad en pacientes con fototipos menos representados. La validación estratificada por fototipo debería considerarse, por tanto, un requisito de seguridad y no únicamente una evaluación complementaria de equidad. Esta exigencia adquiere además relevancia regulatoria: los marcos emergentes de evaluación de sistemas de IA sanitaria enfatizan la necesidad de identificar degradaciones sistemáticas del rendimiento entre subpoblaciones, especialmente cuando dichas diferencias pueden traducirse en desigualdades diagnósticas.

El experimento cruzado *Light* ↔ *Dark* (tabla B.9) añade una segunda lectura. La caída de rendimiento al entrenar sólo con fototipos claros y evaluar sobre fototipos oscuros (L→D vs L→L) es máxima en DINOv2 ($\Delta = -0,132$ pp BAcc) y mínima en BiomedCLIP ($\Delta = -0,063$ pp). DermLIP v2 mantiene la menor caída Dark→Light vs Dark→Dark

($\Delta = +0,016$ pp), lo que sugiere mayor invariancia de sus representaciones al fototipo. El patrón es coherente con su dataset de preentrenamiento Derm1M, derivado de fuentes web abiertas con representación variable de fototipos.

Este experimento cruzado es, en cierto sentido, más informativo que el *gap* I-VI descriptivo, porque responde a una pregunta causal: qué ocurre al entrenar con unos fototipos y desplegar sobre otros. La caída sistemática observada en el escenario L→D confirma que el sesgo no se limita a diferencias de prevalencia entre grupos, sino que emerge incluso cuando el entrenamiento excluye explícitamente parte de la variabilidad fenotípica. El fenómeno es compatible con una dependencia real de las representaciones visuales respecto al tono cutáneo, y no con un mero artefacto de muestreo.

Ninguno de los cinco encoders evaluados elimina completamente la degradación observada en fototipos elevados. La convergencia de resultados entre arquitecturas muy distintas sugiere que la limitación no reside exclusivamente en un modelo concreto, sino que refleja un problema más amplio de representación de fototipos oscuros en los datos disponibles para entrenamiento. Los resultados justifican, en consecuencia, la incorporación explícita de diversidad fenotípica en futuras versiones de DermapixelAI: la expansión del repositorio clínico del HUSLL (sección 5.1.2) ofrece una oportunidad para aumentar la representación de fototipos infrarrepresentados y reducir la dependencia de distribuciones procedentes de datasets públicos.

5.1.9 El cuello de botella ya no es sólo el modelo

La evidencia acumulada a lo largo del trabajo sugiere que el rendimiento dermatológico no está limitado principalmente por la arquitectura del modelo. En varios experimentos, modificaciones en el diseño del sistema —tokenización, *prompts*, estrategia de adaptación, estructura ontológica, equilibrio de clases, recuperación por similitud o validación por subgrupos— producen variaciones comparables o superiores a las obtenidas al sustituir el codificador visual. Estas decisiones, más que la elección aislada de un codificador, determinan el rendimiento alcanzable, y la lectura desplaza parcialmente el foco desde el diseño del modelo hacia el diseño del sistema completo.

Esta evolución es coherente con la madurez progresiva de los modelos fundacionales. A medida que las representaciones visuales alcanzan niveles elevados de calidad, el margen de mejora se desplaza desde la arquitectura hacia aspectos tradicionalmente considerados periféricos: datos, ontologías, alineamiento multimodal, calibración, equidad e integración operativa. En este sentido, Dermapixel R0 no representa la construcción de un modelo mayor, sino de un sistema mejor adaptado al problema: la contribución no reside en la escala, sino en identificar qué componentes limitan realmente el rendimiento y actuar sobre ellos.

Desde una perspectiva de despliegue clínico, la consecuencia es clara: optimizar exclusivamente el modelo puede producir retornos decrecientes si no se acompaña de mejoras equivalentes en los datos, la taxonomía diagnóstica, la estrategia de adaptación, la validación por subgrupos y la integración en el flujo asistencial. Esta lectura constituye el objeto de las implicaciones operativas que se desarrollan en la sección 5.3.

5.1.10 Estimación robusta del rendimiento sobre datasets de tamaño moderado

La fiabilidad de las cifras sobre un dataset pequeño depende del método de estimación empleado. La validación cruzada de cinco *folds* agrupada por caso clínico sobre DermapixelAI 1.0 (sección 4.10, tabla 4.16) ilustra un punto metodológico relevante para evaluar modelos fundacionales sobre datasets de tamaño moderado: la diferencia entre la cifra puntual del *split* fijo y la media de los *folds* es sustancial sobre las métricas dependientes de umbral (BAcc) y casi nula sobre la AUROC *one-vs-rest*. Esta observación matiza la lectura de toda cifra de BAcc puntual sobre un *test* reducido. La validación cruzada transforma así la interpretación del resultado desde una estimación puntual hacia una estimación de su variabilidad: la cifra puntual no es el rendimiento, sino una observación; el rendimiento es una distribución. En datasets clínicos de tamaño moderado, esta información resulta tan importante como la propia métrica central. De aquí se siguen dos lecturas operativas. *Primero*, la cifra del *split* publicado conserva validez como punto operativo de referencia —y como base de la comparación cruzada con la evaluación *zero-shot* sobre el mismo *test* (sección 4.11)—, pero requiere la estimación cruzada para defender el rendimiento esperado del sistema. *Segundo*, sobre datasets clínicos de tamaño moderado la AUROC es la métrica primaria recomendable para comparar configuraciones de *transfer learning* congelado, mientras que la BAcc y la *accuracy* deben acompañarse de su intervalo de confianza o de su estimación cruzada por *folds*. La estabilidad de la AUROC frente a las métricas dependientes de umbral explica además su uso recurrente a lo largo del trabajo como métrica primaria de comparación entre codificadores: mientras que la BAcc depende de una frontera de decisión concreta, la AUROC evalúa la capacidad de ordenación del modelo y resulta menos sensible a fluctuaciones muestrales en conjuntos reducidos.

En consecuencia, los *rankings* observados entre modelos sobre DermapixelAI 1.0 deben interpretarse como estimaciones sujetas a incertidumbre muestral y no como jerarquías absolutas. La validación cruzada agrupada por caso proporciona una aproximación más robusta al rendimiento esperado en despliegue que cualquier partición fija individual, y protege la lectura de las cifras de los niveles L2 y L3 —los de *test* más reducido— frente a la sobreinterpretación de diferencias dentro del margen de error.

5.2 Comparación con la literatura

Los resultados discutidos en la sección anterior adquieren significado únicamente en relación con la evidencia previa disponible. Por ello, esta sección contrasta los hallazgos obtenidos con los principales trabajos de referencia en modelos fundacionales dermatológicos, segmentación médica, aprendizaje multimodal, equidad por fototipo e interpretabilidad basada en conceptos.

El objetivo no es únicamente verificar la reproducibilidad de resultados previamente publicados, sino también identificar los puntos de convergencia y divergencia que emergen al evaluar estos modelos sobre datasets externos, en castellano y bajo condiciones de despliegue diferentes a las descritas en los trabajos originales. Este contraste permite situar las contribuciones de DermapixelAI 1.0 y Dermapixel R0 dentro del estado actual de la investigación, delimitando qué observaciones confirman la literatura existente, cuáles la matizan y cuáles aportan evidencia nueva.

5.2.1 Reproducción del benchmark de PanDerm

El primer contraste con la literatura corresponde a la reproducibilidad del propio modelo fundacional. Yan et al. [1] reportan para PanDerm Large una mejora media del +10,2% sobre el estado del arte previo a través de los 28 *downstream tasks* de su benchmark interno. Las cifras de sondeo lineal obtenidas en este trabajo sobre los datasets compartidos (HAM10000, PAD-UFES-20 y Derm7pt; tabla 4.1) se sitúan dentro del rango descrito por los autores y reproducen cualitativamente las relaciones de rendimiento entre PanDerm Base y PanDerm Large.

Esta concordancia resulta especialmente relevante porque la evaluación se ha realizado bajo condiciones de ejecución distintas a las del trabajo original. Los experimentos se ejecutaron sobre arquitectura ARM64 (aarch64), aceleración CUDA 13.0 y precisión BF16 en la plataforma NVIDIA Grace Hopper GB10, mientras que la validación original se realizó sobre infraestructura x86_64. La proximidad de los resultados —dentro de las tolerancias esperables por aritmética BF16 y por diferencias de versiones de cuDNN— indica que el comportamiento del modelo es robusto frente a diferencias razonables de hardware y entorno de ejecución, y documenta la portabilidad práctica del *pipeline* hacia arquitecturas de nueva generación orientadas a IA.

La magnitud de la mejora observada también es consistente con la literatura. Sobre los diez datasets externos evaluados en este trabajo, PanDerm Large supera a PanDerm Base en +4,1 pp de *accuracy* y +9,0 pp de *balanced accuracy*. Este último valor se aproxima notablemente al +10,2% reportado por Yan et al. sobre su benchmark interno, pese a que los datasets empleados aquí son externos al desarrollo original. La convergencia entre ambos resultados sugiere que la ventaja de PanDerm Large no depende exclusivamente de los conjuntos utilizados durante el desarrollo del modelo, sino que se mantiene cuando se evalúa sobre cohortes independientes.

Más allá de validar la reproducibilidad numérica, este resultado aporta evidencia externa sobre la generalización del modelo fundacional. En un contexto donde numerosos modelos recientes muestran pérdidas apreciables de rendimiento al abandonar los datasets de desarrollo, la estabilidad observada entre el benchmark interno del grupo de Monash y los conjuntos públicos utilizados en este trabajo constituye un indicador favorable de robustez y transferibilidad.

5.2.2 Segmentación binaria de lesión

En segmentación, la cifra obtenida también supera la referencia publicada y conviene interpretar las razones probables de esta diferencia. SAM2.1-Large con *fine-tuning* del decodificador sobre ISIC2018 alcanza Dice = 0,947, mejorando en +2,6 pp el resultado reportado por Yan et al. [1] (0,921 Dice con 100 épocas).

Tres factores pueden explicar plausiblemente esta diferencia. *Primero*, la arquitectura *promptable* de SAM2.1 incorpora una señal espacial explícita mediante la *bounding box*, lo que restringe el espacio de búsqueda de la segmentación y reduce la ambigüedad de los contornos. *Segundo*, el encoder Hiera-Large de SAM2.1, preentrenado sobre ~ 11 millones de imágenes y más de mil millones de máscaras, proporciona representaciones geométricas y de contorno extremadamente robustas, probablemente más adecuadas para esta tarea que las aprendidas por encoders entrenados exclusivamente sobre imágenes dermatológicas. *Tercero*, la adaptación restringida al decodificador de

máscaras y al *promptable encoder* concentra la capacidad de ajuste en los componentes directamente responsables de la segmentación, minimizando el riesgo de sobreajuste y reduciendo significativamente el coste computacional frente a un *fine-tuning* más amplio.

Los experimentos adicionales realizados en este trabajo refuerzan esta interpretación. La comparación pareada entre arquitecturas *promptables* (sección 4.6.1) muestra que las diferencias entre segmentadores son relativamente pequeñas (≈ 1 pp de Dice), mientras que retirar la caja-*prompt* produce una degradación de 7,5 pp (sección 4.6.2). El principal determinante del rendimiento no parece ser, por tanto, el segmentador concreto, sino la disponibilidad de una localización inicial fiable de la lesión.

La literatura reciente ha tendido a interpretar la mejora de la segmentación médica principalmente como consecuencia de arquitecturas cada vez mayores o de preentrenamientos más especializados. Los resultados obtenidos aquí sugieren una lectura parcialmente distinta: una vez alcanzado un determinado nivel de calidad en las representaciones visuales, el beneficio marginal de aumentar el tamaño del modelo es reducido frente al efecto de disponer de información espacial explícita y de una adaptación específica de bajo coste.

La validación cruzada (Dice = $0,9554 \pm 0,0010$) y el análisis inter-anotador aportan además una lectura complementaria. El acuerdo medio entre dermatólogos sobre el contorno de una misma lesión (0,728 Dice) es sustancialmente inferior al acuerdo del modelo respecto al consenso (0,915), lo que indica que gran parte del error residual se sitúa ya en la incertidumbre inherente a la anotación humana. En este contexto, la segmentación binaria de lesión dermatoscópica parece aproximarse a un régimen de saturación práctica cuando se combina un encoder *promptable* preentrenado a gran escala con una adaptación específica de bajo coste sobre ISIC2018.

5.2.3 Comportamiento zero-shot

El comportamiento zero-shot observado en este trabajo es consistente con la literatura previa sobre modelos contrastivos dermatológicos, pero introduce una matización relevante sobre los factores que condicionan su rendimiento. DermLIP alcanza valores de AUROC comparables a los reportados en Derm1M [2] —máxima de 0,854 sobre HAM10000— cuando se emplea una configuración textual alineada con la utilizada durante su desarrollo, lo que respalda la reproducibilidad general del paradigma.

Sin embargo, los experimentos realizados muestran que una parte sustancial del rendimiento zero-shot no depende exclusivamente del encoder visual ni del volumen de imágenes empleado durante el preentrenamiento. La sensibilidad observada frente a cambios en el tokenizador y en la formulación de los *prompts* (sección 5.1.6) —hasta 48,8 pp de AUROC sobre el mismo encoder visual— sugiere que la alineación texto-imagen constituye un componente crítico del sistema. Esta observación resulta especialmente relevante porque la mayoría de trabajos reportan una única configuración textual, dificultando estimar hasta qué punto el rendimiento atribuido al modelo depende realmente de la arquitectura o de la formulación lingüística empleada; su cuantificación sistemática no figura en la literatura previa sobre la familia DermLIP y constituye una aportación empírica de este trabajo.

Los resultados obtenidos son coherentes con la hipótesis de que, una vez alcanzado un determinado nivel de calidad en las representaciones visuales, las limitaciones del

paradigma zero-shot pueden desplazarse hacia la rama textual. La penalización observada posteriormente al utilizar castellano en lugar de inglés sobre DermapixelAI 1.0 (sección 5.1.6) refuerza esta interpretación y sugiere que la disponibilidad de recursos lingüísticos específicos del dominio puede ser tan importante como la disponibilidad de imágenes.

Desde una perspectiva metodológica, estos hallazgos recomiendan cautela al comparar modelos multimodales exclusivamente a partir de métricas zero-shot. Diferencias atribuidas aparentemente a la arquitectura pueden reflejar, al menos en parte, diferencias en la formulación textual utilizada durante la evaluación. La comparación entre modelos debería considerar explícitamente este factor, especialmente en dominios clínicos donde la terminología es altamente especializada.

5.2.4 Disparidad por fototipo

La disparidad observada por fototipo es coherente con los resultados previamente descritos en Fitzpatrick17k [14] y con la motivación que impulsó la creación del dataset DDI [12]. Al igual que en esos trabajos, los modelos evaluados muestran un descenso sistemático del rendimiento sobre los fototipos más oscuros, lo que confirma que el sesgo asociado a la representación desigual de tonos de piel continúa siendo un problema abierto incluso en los modelos fundacionales dermatológicos más recientes.

La aportación de este trabajo no reside tanto en identificar nuevamente la existencia de esa disparidad como en compararla de forma homogénea entre cinco familias de codificadores bajo un mismo protocolo experimental. Esta comparación permite observar que la relación entre rendimiento global y equidad no es necesariamente directa. DermLIP v2 obtiene la mejor capacidad discriminativa global, mientras que PanDerm Large presenta un compromiso más equilibrado entre rendimiento y estabilidad entre fototipos. Por el contrario, BiomedCLIP exhibe el menor *gap* entre los grupos extremos, pero también el peor rendimiento global.

Esta última observación resulta especialmente relevante desde una perspectiva metodológica. Un *gap* reducido puede reflejar una distribución más homogénea del error entre subgrupos, pero también puede aparecer cuando el modelo presenta un rendimiento bajo de forma generalizada. La denominada paradoja de BiomedCLIP pone de manifiesto que la interpretación aislada de métricas de equidad puede conducir a conclusiones engañosas: un modelo uniformemente mediocre puede parecer más equitativo que otro claramente superior simplemente porque falla de manera similar en todos los grupos.

Los resultados respaldan, por tanto, una recomendación alineada con las discusiones recientes sobre evaluación responsable de sistemas de IA: las métricas de equidad deben interpretarse conjuntamente con las métricas de rendimiento global. Ni el *gap* entre subgrupos ni la *accuracy* o la AUROC son suficientes por sí solas para caracterizar el comportamiento de un sistema clínico. La evaluación de modelos dermatológicos debería reportar simultáneamente rendimiento global, rendimiento por subgrupo y magnitud de las diferencias observadas entre ellos.

La evaluación cruzada *Light* $\leftrightarrow$ *Dark* (tabla B.9) aporta además una segunda evidencia consistente con la literatura reciente. Los modelos preentrenados específicamente sobre dermatología muestran una mayor robustez frente a cambios en la distribución de fototipos que los encoders visuales generalistas. Este resultado sugiere que parte

del beneficio del preentrenamiento de dominio no se limita a mejorar la discriminación diagnóstica, sino que también puede contribuir a una representación más estable frente a variaciones demográficas clínicamente relevantes. En conjunto, la mejora del rendimiento global no garantiza automáticamente una mejora equivalente en equidad, y la reducción del *gap* entre subgrupos tampoco garantiza un comportamiento clínicamente adecuado —una tensión que se retoma entre las limitaciones del trabajo (capítulo 6)—.

5.3 Implicaciones operativas

Los resultados obtenidos no sólo permiten comparar modelos, sino también extraer consecuencias prácticas para el diseño de futuros sistemas dermatológicos asistidos por inteligencia artificial. A diferencia de la literatura inicial sobre modelos fundacionales, donde el objetivo principal era identificar un único modelo capaz de superar al estado del arte en múltiples tareas, la evidencia acumulada en este trabajo apunta hacia una conclusión diferente: distintos problemas dermatológicos favorecen arquitecturas distintas.

La clasificación jerárquica, la segmentación, la recuperación de casos similares, la búsqueda multimodal mediante lenguaje natural, la interpretación conceptual o el cribado de seguridad presentan requisitos técnicos diferentes, y no existe un único modelo que optimice simultáneamente todos ellos. Los resultados sugieren que la estrategia más defendible para un entorno clínico consiste en combinar varios componentes especializados dentro de una arquitectura modular, seleccionando cada uno de ellos según la tarea concreta que deba resolver. Las subsecciones siguientes traducen los hallazgos experimentales del capítulo 4 en decisiones de diseño aplicables a sistemas reales de apoyo al diagnóstico dermatológico.

5.3.1 Arquitectura defendible para sistemas de apoyo al diagnóstico

Los cuatro bloques de evidencia anteriores convergen en una arquitectura técnicamente defendible para sistemas de apoyo al diagnóstico dermatológico construidos sobre los modelos fundacionales disponibles. La estructura recomendable es la siguiente. El encoder es PanDerm Large preentrenado, congelado por defecto y ajustado sólo bajo demanda. La cabeza es una regresión logística multi-clase (L-BFGS, $C = 1,0$, $\text{max_iter} = 5000$) cuando el dataset de entrenamiento es reducido ($N_{\text{train}} \lesssim 500$), o una cabeza ajustada con la receta de PanDerm Large (Mixup, CutMix, *weighted random sampler*, 50 épocas) cuando $N_{\text{train}} \gtrsim 5000$ y existe desbalance acusado. La segmentación se resuelve con SAM2.1-Large adaptado mediante *fine-tuning* del decodificador cuando la tarea requiera localizar la lesión.

Las ramas textuales se incorporan con cautela. La rama lingüística contrastiva (DermLIP) sólo entra con prompts validados y tokenizador compatible, verificado sobre un conjunto de validación del dominio. La rama LLM multimodal generalista (GPT-4o, Gemini, MedGemma) no se usa como clasificador principal, dado el orden de magnitud de rendimiento inferior cuantificado en sección 5.1.7. Su rol natural es complementario: generar razonamiento textual o explicaciones para casos ya clasificados por el encoder especializado.

La consecuencia de diseño que se desprende del conjunto de hallazgos (sección 5.4) es que la arquitectura defendible es modular, no un modelo único: PanDerm Large para la transferencia visual general, adaptación LoRA para la subcategoría clínica bajo *N* reducido, *retrieval* FAISS para la cola larga, SAM2.1 para la segmentación y un *ensemble* acotado para el cribado de melanoma, seleccionando el componente según la tarea y el nivel ontológico. Sobre esta estructura, dos validaciones son condición necesaria antes del despliegue: la de los *prompts* y el tokenizador de cualquier rama contrastiva sobre un conjunto del dominio, dada la sensibilidad documentada en sección 5.1.6, y la validación por fototipo cutáneo que se detalla en sección 5.3.2.

Esta arquitectura modular hereda, por último, una decisión taxonómica. La ontología no sólo permite comparar datasets, sino que obliga a elegir a qué nivel se compara. La heterogeneidad taxonómica entre datasets, mitigada mediante la ontología jerárquica L1/L2/L3 descrita en sección 3.2, sigue requiriendo una decisión explícita sobre el nivel de agregación de los contrastes. La comparación inter-dataset es defendible a nivel L1 (cuatro familias etiológicas) y L2 (43 subcategorías clínicas) sobre el dataset armonizado de 72 654 imágenes. El nivel L3 (367 diagnósticos individuales) conserva la cola larga propia de cada dataset y no admite contrastes directos sin agregación adicional. La implicación para un sistema de producción es que la jerarquía debe mostrarse de forma explícita al usuario clínico: presentar la predicción L3 junto a su agregación L2 y L1 da robustez frente a la incertidumbre de la cola larga sin sacrificar especificidad cuando ésta es fiable.

5.3.2 Ventana operativa por fototipo cutáneo

El rendimiento desigual entre fototipos también acota dónde puede desplegarse el sistema con garantías. Esa ventana operativa, definida en el experimento de equidad (tabla 4.12), condiciona la generalización a poblaciones con fototipos elevados. Los cinco encoders presentan *gap* I-VI positivo entre +0,124 y +0,306 pp BAcc. La paradoja BiomedCLIP —*gap* mínimo asociado a la peor BAcc global— vuelve a ilustrar que el *gap* aislado no es una métrica decisional. El mejor compromiso entre BAcc global y *gap* sobre la formulación de tres clases es PanDerm Large, seguido de DermLIP v2 cuando se prioriza la AUROC global. La implicación clínica es clara: desplegar sobre poblaciones con representación significativa de fototipos elevados exige validación específica por subgrupos y mecanismos de revisión humana cuando el modelo opere en su régimen de menor confianza.

5.3.3 Ensemble de seguridad para detección de melanoma

La detección de melanoma admite un esquema orientado a la seguridad, y conviene discutir tanto su valor como sus costes. El protocolo auxiliar de ensemble (sección H.8.7, tabla H.7) muestra que la combinación OR *top-3* de PanDerm Large *fine-tuned* sobre HAM10000 (M1) y SigLIP-Large SO400M con sondeo lineal alcanza *recall* de melanoma del 100 % (70 de 70) sobre el *split* de test de HAM10000. El análisis de errores explica por qué: los dos melanomas que M1 no captura en *top-3* sí los captura SigLIP, lo que confirma la complementariedad de los *backbones* y justifica la elección del par. M7 (clasificador unificado sobre el dataset armonizado de 43 clases) no añade melanomas

adicionales sobre HAM, pero mantiene valor en escenarios multidataset por su mayor cobertura ontológica.

Tres caveats acompañan la lectura operativa de este resultado. (i) El *recall* del 100 % es *top-3*, no *top-1*, por lo que exige una interfaz que presente al clínico las tres clases más probables. (ii) El tamaño muestral de melanomas es $N = 70$, lo que produce intervalos de confianza al 95 % amplios y obliga a validación prospectiva sobre una cohorte mayor. (iii) El coste en falsos positivos del esquema OR *top-3* es elevado (885 FP sobre 1 162 no-melanomas): asumible en un cribado oportunista, pero suficiente para descartar su uso aislado como clasificación primaria. La lectura operativa, coherente con la arquitectura modular de sección 5.3.1, es que este *ensemble* debe integrarse como mecanismo de apoyo orientado a la sensibilidad —priorizar la detección de melanoma asumiendo falsos positivos— y nunca como decisión diagnóstica autónoma.

Más allá del caso concreto del melanoma, el conjunto de resultados obtenidos en esta tesis apunta hacia una conclusión arquitectónica más general. Ninguno de los modelos evaluados domina simultáneamente la clasificación jerárquica, la segmentación, la recuperación multimodal, la interpretabilidad conceptual y el cribado de seguridad; por el contrario, cada tarea presenta un candidato óptimo diferente.

Esta observación cuestiona la búsqueda de un único modelo dermatológico universal y favorece un paradigma alternativo basado en la composición de módulos especializados. En este escenario, los modelos fundacionales actúan como infraestructura común sobre la que se construyen componentes específicos para segmentación, clasificación, recuperación documental, razonamiento multimodal o interpretación clínica.

La arquitectura propuesta para DermApIxel se alinea con esta visión: más que un modelo único, constituye un ecosistema de modelos especializados coordinados alrededor de una ontología común y de una representación dermatológica compartida. Los resultados obtenidos sugieren que esta aproximación modular puede ser una vía más realista y escalable para la integración de la inteligencia artificial en la práctica dermatológica que la búsqueda de un único sistema capaz de resolver todas las tareas clínicas simultáneamente.

5.4 Hallazgos no anticipados

Cinco observaciones del trabajo no se anticipaban desde la literatura y, a diferencia de las conclusiones robustas que se sintetizan en el capítulo 6, contradicen una expectativa previa razonable. Por ese motivo merecen atención específica como aportaciones empíricas con entidad propia.

Sensibilidad extrema al tokenizador y al *prompt*. La AUROC *zero-shot* de la familia DermLIP sobre HAM10000 varía en un rango comparable al de cambiar de paradigma completo, sin modificar los pesos del encoder visual, en función del tokenizador y de la formulación de los *prompts* (sección 5.1.6). Esta sensibilidad no está cuantificada de forma sistemática en la literatura previa sobre DermLIP y desplaza parte de la atención metodológica del modelo hacia su configuración operativa.

Retrieval competitivo en la cola larga L3. La sustitución del clasificador lineal por *retrieval* k -NN con índice FAISS sobre los mismos *embeddings* PanDerm Large supera al sondeo lineal en el régimen de cola larga severa L3 de DermapixelAI 1.0 (sección J.7). El hallazgo indica que, cuando el número de muestras por clase es muy bajo, un esquema no paramétrico basado en vecindad puede ser preferible al ajuste de una frontera de decisión paramétrica.

Sondeo lineal supera al ajuste fino en DDI. Sobre DDI ($N_{\text{train}} = 427$), el sondeo lineal sobre PanDerm Large supera al ajuste fino en accuracy, AUROC, BAcc y F1 ponderada (sección 5.1.4). El comportamiento, atribuible a sobreajuste bajo N reducido, no se documenta de forma explícita en la literatura sobre PanDerm y ofrece una heurística operativa para datasets pequeños.

Más datos externos no siempre mejoran el modelo. La transición v4→v5 de Dermapixel R0 constituye un resultado negativo de interés: añadir 15 128 imágenes externas genéricas (PAD-UFES-20, DermNet) con *captions* sintéticas *reduce* la *accuracy@1 zero-shot* L3 ($0,2475 \rightarrow 0,2079$, sección 4.13.3). El resultado contradice la hipótesis razonable de que aumentar el volumen de datos mejora el rendimiento y sugiere que, en un dominio clínico de alta especificidad lingüística, la alineación entre dominio y lenguaje puede ser más determinante que la escala bruta de imágenes.

Interpretabilidad emergente del SAE Large sobre Derm7pt. La validación independiente del SAE Large (16384 *features*) sobre el dataset Derm7pt [9], reportada en sección 4.14, identifica *features* individuales con AUROC efectivo hasta 0,823 sobre *vascular structures* y hasta 0,926 sobre vasos en horquilla ($N_+ = 15$ positivos). Las anotaciones del *Seven-Point Checklist* no se usaron ni en el preentrenamiento del SAE ni en el del encoder PanDerm Large. Esto implica que la base sparse aprendida sobre Derm1M (507 657 imágenes) ya ha capturado representaciones alineadas con la taxonomía dermatoscópica clásica. El hallazgo sostiene la interpretabilidad mediante Sparse Autoencoders más allá de los 48 conceptos visuales de SkinCon [15] sobre los que se diseñó el experimento original del Anexo F. El *Concept Bottleneck Model* con cuello de botella sobre los siete criterios cuantifica además el coste de esta interpretabilidad sobre la tarea binaria melanoma/no-melanoma ($-5,8$ pp AUROC, $0,890 \rightarrow 0,832$). La jerarquía de pesos del meta-clasificador (*blue whitish veil* +2,54, *regression structures* +2,07) es coherente con el peso clínico de estos criterios en la escala diagnóstica de referencia [9]. La lectura operativa es que el SAE no es sólo un mecanismo de reducción dimensional: admite interpretación concepto-a-concepto sobre el vocabulario dermatoscópico. Esto refuerza la viabilidad del módulo de interpretabilidad del prototipo (Anexo H) sin reentrenar el SAE.

5.5 Limitaciones interpretativas

Conviene cerrar la discusión acotando hasta dónde llegan estas conclusiones. Seis elementos condicionan la interpretación de los resultados, y el capítulo 6 los desarrolla en detalle. Primero, el solapamiento exacto de Dermnet con el dataset de preentrenamiento Derm1M (100 % por hash MD5) introduce una incertidumbre acotada sobre las cifras

de la familia DermLIP en ese dataset —HIBA y MSKCC, pese a su origen ISIC-archive, no presentan solapamiento MD5—; las cifras de PanDerm, DINOv2, ConvNeXt-Large, EfficientNetV2-Large y SigLIP-Large no se ven afectadas. Conviene además precisar el alcance de esa auditoría: el hash MD5 detecta coincidencias exactas pero no *near-duplicates* —recortes, reescalados o recompresiones de una misma imagen—, de modo que lo verificado es la ausencia de solapamiento *exacto*, no de toda contaminación visual posible (sección 6.2.3). Segundo, los tamaños muestrales de los subgrupos Fitzpatrick V y VI (169 y 73 imágenes respectivamente en el conjunto de test) producen intervalos de confianza amplios para las cifras de *gap*, lo que limita la cuantificación exacta de la desigualdad por fototipo. Tercero, la sensibilidad al *prompt* en zero-shot y en la evaluación de LLMs multimodales hace que las cifras reportadas sean condicionales a una formulación concreta; generalizarlas a otras formulaciones requiere validación específica. Cuarto, el trabajo evalúa rendimiento sobre fotografías de archivos de investigación; la generalización a imagen real adquirida en flujos de teledermatología sobre cohorte hospitalaria prospectiva no se aborda y constituye una línea futura inmediata. Quinto, la denominación de Dermapixel R0 como primer modelo fundacional dermatológico en español es una afirmación de prioridad deliberadamente acotada: designa la adaptación de un modelo fundacional preexistente al castellano, no un preentrenamiento a gran escala, y su condición de *primero* se circunscribe a esa categoría —pesos abiertos, texto clínico narrativo y registro en español— (sección 7.5.2); una reivindicación de prioridad histórica exhaustiva excedería el alcance bibliográfico de este trabajo. Sexto, la evaluación sobre DermapixelAI 1.0 se realiza sobre un conjunto de tamaño moderado y con una distribución fuertemente desbalanceada en los niveles ontológicos más finos: en particular, la cola larga de L3 limita la estabilidad de las estimaciones por clase y obliga a interpretar los resultados de ese nivel como evidencia exploratoria más que como una ordenación definitiva entre métodos. Esta limitación afecta especialmente a las comparaciones entre clasificadores sobre L3 —*retrieval k*-NN, sondeo lineal y Dermapixel R0— y motiva la necesidad de ampliar el banco hospitalario en trabajos futuros (sección 6.4).

Estas limitaciones acotan el dominio de validez de las cifras, pero no invalidan los patrones cualitativos identificados: la ventaja del preentrenamiento de dominio, la saturación temprana del sondeo lineal, el régimen $N_{\text{train}} \lesssim 500$ como umbral de preferencia del LP, la brecha entre especialistas y LLMs multimodales generalistas, y la existencia de un *gap* por fototipo sistemático y consistente entre encoders.

LIMITACIONES

El estudio presenta limitaciones de cinco órdenes que conviene declarar explícitamente. La presente sección las desarrolla por familia, cuantifica su magnitud cuando es posible y acota su impacto sobre la interpretación de los resultados del capítulo 4 y de la discusión del capítulo 5.

6.1 Limitaciones de disponibilidad

6.1.1 Modelos sin pesos públicos

Los pesos de DermFM-Zero [3] no son públicos en la fecha de cierre del presente trabajo. Esta restricción impide su evaluación empírica directa sobre los doce datasets externos contrastados y restringe su tratamiento al marco conceptual del capítulo 2. La comparación entre PanDerm Large y DermFM-Zero, que la publicación original reporta a favor del segundo, no puede verificarse de forma independiente con los mismos protocolos. La disponibilidad eventual de los pesos permitiría esa comparación directa con los hallazgos cuantitativos del trabajo (tabla 4.1, tabla 4.12).

Los modelos cerrados accedidos vía API (GPT-4o, GPT-4o-mini, Gemini 2.5 Pro, Gemini 2.5 Flash) presentan una limitación estructural: no permiten controlar la versión exacta del modelo en el momento de la inferencia ni el posprocesado interno aplicado por el proveedor. Las cifras de la tabla 4.11 son condicionales a la versión disponible en la fecha del experimento (marzo de 2026) y no son estrictamente reproducibles ante actualizaciones silenciosas del proveedor. El coste agregado de la evaluación (\$4,07 aproximadamente entre GPT-4o y GPT-4o-mini, sin desglose público de tarifa por token de entrada y salida) introduce una segunda dependencia que limita la replicación por terceros.

6.1.2 Conjuntos de preentrenamiento no liberados

Los conjuntos de preentrenamiento internos del grupo de la Universidad Monash empleados en PanDerm [1] no son accesibles para terceros, lo que impide reproducir la fase de preentrenamiento y limita la verificación a los pesos liberados. En consecuencia, cualquier afirmación sobre la composición del dataset de preentrenamiento (las cuatro modalidades dermatológicas, ~ 2,1 millones de imágenes) descansa sobre la declaración de los autores y no sobre auditoría independiente. La misma restricción aplica al dataset Derm1M de la familia DermLIP, distribuido con *embeddings* agregados pero sin acceso íntegro al material de imagen original.

6.1.3 Dependencia de modelos fundacionales externos

El trabajo evalúa principalmente estrategias de adaptación, transferencia e integración sobre modelos fundacionales desarrollados por terceros (PanDerm, DermLIP, SAM2.1, SigLIP, BiomedCLIP). Por tanto, parte de las conclusiones depende de las decisiones de diseño y de los sesgos heredados de dichos modelos. Aunque esta situación refleja el escenario real de adopción clínica actual —en el que una institución sanitaria parte de pesos preentrenados disponibles y no de un preentrenamiento propio a gran escala—, limita la capacidad de atribuir causalmente determinados comportamientos a componentes específicos del entrenamiento original.

6.2 Limitaciones de los datos

6.2.1 Sesgo geográfico y lingüístico

Los doce datasets externos contrastados provienen mayoritariamente de instituciones de Estados Unidos (DDI), Australia (HAM10000 parcial), Europa central (BCN20000 sobre Hospital Clínic de Barcelona; HAM10000 parcial; ISIC2018; Dermnet) y Brasil (PAD-UFES-20). HIBA procede del Hospital Italiano de Buenos Aires y MSKCC del Memorial Sloan Kettering Cancer Center. La población hispanohablante europea, con la distribución epidemiológica documentada en DIADERM [5], no está representada de forma específica en los conjuntos de evaluación. La consecuencia es que las cifras agregadas de la tabla 4.1 no son directamente extrapolables al espectro diagnóstico atendido en el Hospital Universitario Son Llàtzer (HUSLL) [4] sin validación adicional.

La rama lingüística de los modelos vision-lenguaje contrastivos (DermLIP, BiomedCLIP) está preentrenada sobre dataset en inglés. La sensibilidad documentada al tokenizador (sección 5.1.6, 48,8 pp AUROC entre la peor y la mejor configuración) se limita a las variantes evaluadas en inglés y no caracteriza el rendimiento sobre *prompts* en español, idioma sobre el que no se han evaluado por la ausencia de validación de los tokenizadores con vocabulario clínico hispanohablante. El dataset DermapixelAI 1.0 publicado como contribución del trabajo (sección 3.3) aborda esta brecha para la fase posterior al periodo cubierto por este documento.

6.2.2 Heterogeneidad taxonómica entre datasets

Las taxonomías diagnósticas nativas de los doce datasets son incompatibles entre sí. La formulación binaria melanoma/no-melanoma de Derm7pt clínico, Derm7pt dermo,

HIBA y MSKCC contrasta con la multiclase de HAM10000 (7 clases), PAD-UFES-20 (6), DDI (2), Dermnet (23), BCN20000 (9), WSI patches (16) y Fitzpatrick17k (114 patologías). SkinCon emplea anotación basada en 48 conceptos clínicos visuales, taxonomía incompatible con la diagnóstica de los demás datasets.

La ontología jerárquica L1/L2/L3 introducida en sección 3.2 mitiga esta limitación al armonizar el dataset agregado sobre vocabulario común (72 654 imágenes etiquetadas, 4 categorías L1, 43 subcategorías L2 con cinco entradas sin desagregación a L3, y 367 diagnósticos L3 con codificación SNOMED CT y CIE-10), pero no la elimina por completo. Las comparaciones inter-dataset son defendibles a nivel L1 (cuatro familias etiológicas) y L2 (43 entradas), pero a nivel L3 cada dataset conserva su cola larga propia y los contrastes directos requieren agregación adicional. Once de los doce datasets se mapean a la ontología; SkinCon queda fuera por el desajuste de granularidad ya mencionado.

La consecuencia operativa para los hallazgos del capítulo 4 es que el reporte por dataset de la tabla 4.1 mantiene fidelidad a la taxonomía nativa, y las cifras agregadas (filas *Media* de la misma tabla) deben interpretarse como promedios sobre tareas heterogéneas no estrictamente comparables entre sí.

6.2.3 Solapamiento con el dataset de preentrenamiento Derm1M

La auditoría descrita en sección 3.6.8 identifica un único dataset evaluado, **Dermnet**, con solapamiento exacto frente al dataset de preentrenamiento Derm1M empleado por la familia DermLIP: sus 18 302 imágenes están íntegramente contenidas en Derm1M (100 % por hash MD5). HIBA y MSKCC, pese a su origen en el ISIC archive, no presentan ninguna coincidencia MD5 con Derm1M, por lo que la sospecha de procedencia no se confirma como solapamiento exacto (tabla 3.1).

Las métricas obtenidas sobre Dermnet con modelos cuya rama visual deriva de Derm1M (DermLIP v1, v2 y original) deben interpretarse con *caveat* y no son directamente comparables con las obtenidas sobre los datasets sin solapamiento. La sensibilidad de la métrica AUROC a la presencia de imágenes ya vistas en preentrenamiento puede inflar al alza las cifras zero-shot de DermLIP sobre Dermnet.

Las cifras de PanDerm Base y Large, DINOv2 ViT-L/14, ConvNeXt-Large, EfficientNetV2-Large y SigLIP-Large SO400M no se ven afectadas por este solapamiento, dado que su preentrenamiento no incluye Derm1M. Por consiguiente, los hallazgos cuantitativos sobre la ventaja del preentrenamiento de dominio (sección 5.1.1), la eficiencia en etiquetas (sección 5.1.3) y la comparación con CNNs (tabla 4.3) permanecen defendibles incluso bajo el peor escenario de la auditoría.

La auditoría acota, no obstante, su propio alcance epistemológico. El hash MD5 detecta coincidencias *exactas* a nivel de bytes, pero no identifica *near-duplicates*: recortes, reescalados, recompresiones o alteraciones leves de una misma imagen. Lo que la auditoría sostiene es, por tanto, la ausencia de duplicación *exacta* entre los datasets de evaluación y Derm1M, no la ausencia completa de contaminación visual. Las cifras declaradas libres de solapamiento deben leerse en sentido estricto como libres de *solapamiento exacto*; la extensión natural —*perceptual hashing* o comparación por *embeddings* visuales— se identifica como refinamiento metodológico de la auditoría.

6.2.4 Tamaños muestrales por subgrupo en el experimento de equidad

Los tamaños muestrales del experimento de equidad sobre Fitzpatrick17k son asimétricos entre fototipos cutáneos: 299 imágenes para FST I, 470 para FST II, 325 para FST III, 261 para FST IV, 169 para FST V y 73 para FST VI en el conjunto de test (N total = 1597 con fototipo asignado). El subgrupo FST VI dispone de aproximadamente la cuarta parte de los ejemplos del subgrupo FST I y supone el 4,6% del conjunto de test.

La consecuencia estadística es que los intervalos de confianza al 95% por *bootstrap* sobre las cifras de BAcc por subgrupo de la tabla 4.12 son más amplios para FST V-VI que para FST I-IV, lo que limita la precisión cuantitativa del *gap* I-VI reportado. La interpretación cualitativa —rendimiento inferior sobre fototipos elevados— es robusta frente a esta asimetría muestral; la cuantificación exacta del *gap*, en cambio, queda condicionada por la menor masa muestral de los fototipos oscuros, y su acompañamiento sistemático con intervalos de confianza por *bootstrap* se identifica como refinamiento estadístico de la línea de trabajo.

6.3 Limitaciones del diseño experimental

6.3.1 Variabilidad inter-semilla

Los protocolos de sondeo lineal, eficiencia en etiquetas y evaluación de equidad por fototipo operan con una única semilla (`random_state = 42`); el protocolo de ajuste fino emplea también una única configuración de semillas (`torch`, `numpy`, `random` fijadas a 0). La variabilidad inter-semilla no se reporta de forma sistemática en estos protocolos, lo que limita la cuantificación de la incertidumbre estadística asociada a la inicialización aleatoria del clasificador lineal y al orden de muestreo durante el entrenamiento. La segmentación constituye la excepción: el cifra principal de Dice se acompaña de una validación cruzada de cinco pliegues con su intervalo de confianza (sección 4.6.3), por lo que en esa tarea la incertidumbre de partición sí queda acotada.

La consecuencia es que las cifras de las tablas 4.1, 4.4, 4.5 y 4.12 son estimaciones puntuales sobre una trayectoria de optimización concreta y no incluyen su variabilidad esperable bajo distintas inicializaciones. Las heurísticas operativas extraídas en sección 5.1.4 (régimen $N_{\text{train}} \lesssim 500$ para preferencia de sondeo lineal) son cualitativas y robustas, pero los umbrales exactos pueden desplazarse bajo otras semillas.

Esta limitación se acota por dos consideraciones. La semilla fija respondió al objetivo de comparar arquitecturas bajo un protocolo constante, aislando el efecto del modelo del de la inicialización. Y la magnitud de los efectos cualitativos sobre los que se sostienen las conclusiones —del orden de +9,0 pp en la ventaja del preentrenamiento de dominio o de 43,5 pp en la brecha entre encoders especializados y LLMs generalistas— excede ampliamente la variabilidad inter-semilla esperable para un clasificador lineal sobre estos tamaños muestrales, por lo que no se anticipan cambios cualitativos en las conclusiones. El reporte sistemático de media y desviación estándar sobre múltiples semillas constituye, en todo caso, la extensión natural de este protocolo.

6.3.2 Pruebas estadísticas y comparaciones múltiples

El test de DeLong [33] se ha aplicado de forma sistemática a los contrastes pareados entre los cinco encoders sobre el *endpoint* binario de detección de malignidad en Fitzpatrick17k, con corrección de Bonferroni para las diez comparaciones (sección 4.9.1, tabla B.10). Su extensión al resto de *endpoints* y tablas del capítulo, junto con la presentación de cada cifra principal como par (estimador, IC *bootstrap*) en lugar de valor puntual, permanece como refinamiento estadístico de la versión publicable.

La consecuencia operativa es que la superioridad entre encoders sobre la detección de malignidad queda establecida estadísticamente, mientras que el resto de hallazgos numéricos del capítulo 4 deben interpretarse en términos descriptivos y de magnitud del efecto: las afirmaciones de *superioridad estadísticamente significativa* en los demás *endpoints* requieren la cuantificación pendiente. Los patrones cualitativos identificados en la discusión son, no obstante, robustos frente a esta limitación por la magnitud absoluta de los efectos cuantificados.

6.3.3 Sensibilidad al *prompt* en zero-shot y LLMs

La evaluación zero-shot multimodal y la comparación con LLMs multimodales operan sobre formulaciones concretas de *prompts* que condicionan los resultados reportados. La diferencia de 48,8 pp AUROC entre la peor y la mejor configuración de DermLIP sobre HAM10000 (tabla 4.9) cuantifica la magnitud de esta dependencia para la rama contrastiva. La generalización a otras formulaciones requiere validación específica.

Para los LLMs multimodales, el *prompt* clínico de aproximadamente 300 palabras descrito en sección 3.6.6 introduce una formulación fija que no se ha auditado mediante barrido sistemático de longitud, orden de las clases candidatas o inclusión de descriptores anatómicos. El sesgo léxico documentado en sección 5.1.7 (GPT-4o emite 284 predicciones de dermatofibroma frente a 8 muestras reales) sugiere que el modelo responde al espacio léxico del *prompt*, lo que amplifica el efecto de la formulación. Las cifras de la tabla 4.11 son condicionales a este *prompt* y no caracterizan el rendimiento de los modelos bajo formulaciones alternativas. Una caracterización sistemática de la sensibilidad al *prompt* en LLMs queda fuera del alcance del trabajo y se documenta como línea futura en el Anexo G.

6.4 Limitaciones del dataset DermapixelAI 1.0

El dataset DermapixelAI 1.0 entregado como contribución del trabajo presenta cuatro limitaciones específicas declaradas explícitamente en el Anexo C y en el documento formal de entrega (Anexo E).

Desbalance estructural por modalidad. La distribución por modalidad es 1036 imágenes de fotografía clínica frente a 49 imágenes dermatoscópicas, lo que limita el uso del dataset para entrenamiento o evaluación de tareas dermatoscópicas. El predominio clínico refleja la finalidad docente original del archivo Dermapixel, no una decisión de diseño del trabajo, pero condiciona la utilidad del dataset para benchmarks comparativos con HAM10000, BCN20000, ISIC2018 u otros conjuntos dermatoscópicos.

Cobertura ontológica parcial. El dataset contiene anotación L3 sobre 250 diagnósticos distintos, sobre las 367 entradas declaradas en la ontología, lo que corresponde a una cobertura efectiva del 68,1 % del vocabulario L3 con al menos una imagen. El diagnóstico L3 más frecuente concentra aproximadamente el 32 % del dataset, lo que reproduce la cola larga típica del material clínico. Esta cobertura parcial limita el uso del dataset para evaluación granular sobre L3 sin agregación a L2.

Tres cifras de validación no intercambiables. La distinción entre los tres campos de validación documentados en el Anexo C es relevante para la interpretación correcta de las cifras de calidad. El 97,89 % del dataset con `label_source = ontology` indica mapeo ontológico validado del vocabulario, no verificación visual caso-a-caso. El 84,39 % con `rosa_verified` corresponde a la revisión visual explícita por la Dra. R. Taberner. La cifra de validación textual `diagnosis_source = expert_v3` (98,38 %) se refiere a la coherencia del razonamiento textual con el diagnóstico asignado, sin verificación visual de la imagen asociada. Las tres cifras deben declararse con precisión en cualquier comunicación derivada y no son intercambiables.

Splits y tamaños reducidos. La partición *case-aware* del dataset (891/157/41 imágenes en *train/val/test*) es metodológicamente correcta para evitar fuga de información entre imágenes del mismo caso clínico, pero produce un conjunto de test reducido (41 imágenes en el *split* de producción; los contrastes por nivel ontológico se evalúan sobre el subconjunto filtrado, $N = 36$ en L1/L2 y $N = 28$ en L3) que limita la potencia estadística de los contrastes realizados sobre él. La explotación experimental sistemática sobre DermapixelAI 1.0 se ha pospuesto al periodo posterior al cierre de este documento por esta razón. En consecuencia, las conclusiones comparativas sobre el dataset —en particular la jerarquía entre métodos en L2 y L3 y la narrativa de Dermapixel R0— se anclan en la validación cruzada agrupada por caso (sección 5.1.10, tabla 4.16) y no en la cifra puntual del *split* fijo, que sobrestima la BAcc sobre este *test* reducido.

6.5 Limitaciones de generalización clínica

6.5.1 Material de archivo frente a flujo asistencial real

El estudio mide rendimiento sobre fotografías procedentes de archivos de investigación curados (HAM10000, BCN20000, ISIC2018) o de archivos clínicos con verificación posterior (HIBA, MSKCC, DDI, Fitzpatrick17k). El rendimiento sobre material adquirido en el flujo real de teledermatología, sobre fotografías de atención primaria con dispositivos heterogéneos (variabilidad de iluminación, distancia focal, encuadre, calibración cromática) o sobre material adquirido en consulta presencial sin estandarización no se aborda en este trabajo. La extrapolación de las cifras de la tabla 4.1 a estos escenarios requiere validación adicional sobre cohorte representativa del entorno de despliegue previsto, particularmente en el contexto del proyecto institucional de teledermatología con IB-Salut descrito en sección 1.2.

6.5.2 Sesgo de modalidad de los componentes evaluados

Varios de los protocolos evaluados se apoyan en dataset predominantemente dermatoscópicos: la clasificación adaptada sobre HAM10000, la segmentación promptable adaptada sobre ISIC2018 (sección 4.6) y la lista de comprobación de siete puntos, cuyos criterios son intrínsecamente dermatoscópicos. Dado que la entrada mayoritaria en un escenario de teledermatología real es la fotografía clínica —como refleja la propia composición del dataset DermapixelAI 1.0, con 1 036 imágenes clínicas frente a 49 dermatoscópicas (sección 6.4)—, la transferencia de estos componentes a fotografía clínica no estandarizada queda como limitación operativa conocida. Su mitigación —clasificación previa de la modalidad de imagen y encaminamiento diferenciado por tipo— se identifica como línea de continuación y no se aborda en este trabajo.

6.5.3 Ausencia de validación prospectiva

El trabajo no aborda la validación clínica prospectiva sobre cohorte hospitalaria real con protocolo aprobado por Comité Ético de Investigación Clínica (CEIC). Esta limitación es estructural y se asume explícitamente como decisión de alcance en sección 1.5. La validación prospectiva del prototipo DermApIxel descrito en el Anexo H sobre cohorte del HUSLL requiere prerequisites administrativos y temporales (aprobación CEIC, definición de *endpoints* clínicos primarios y secundarios, cálculo muestral, contratación de revisores independientes) que exceden el alcance del Trabajo de Fin de Grado y se identifican como línea de continuación inmediata en la sección 7.5 del capítulo 7.

6.5.4 Elementos no abordados por decisión de alcance

Cuatro elementos quedan fuera del alcance declarados en sección 1.5 y deben reconocerse como limitaciones del documento aunque sean por decisión deliberada: (i) el preentrenamiento desde cero de un modelo fundacional propio, que requeriría acceso al material de las cuatro modalidades dermatológicas en volumen comparable al de PanDerm (~ 2,1 millones de imágenes); (ii) la integración operativa con el sistema PACS y el visor radiológico del HUSLL, que excede el alcance técnico del trabajo experimental; (iii) el reentrenamiento multilingüe de la rama lingüística sobre dataset en español de gran escala, condicionado a la disponibilidad futura de material en cantidad suficiente; (iv) la certificación CE como producto sanitario (*Software as a Medical Device*), que requiere un proceso regulatorio y de auditoría independiente no contemplado.

6.6 Síntesis: dominio de validez de los resultados

El conjunto de limitaciones declarado en este capítulo acota el dominio de validez de las cifras reportadas en el capítulo 4 pero no invalida los patrones cualitativos identificados en la discusión. Cinco afirmaciones resisten al peor escenario combinado de muestreo, semilla, sensibilidad al *prompt* y restricciones de modelos cerrados, y constituyen la respuesta empírica defendible del trabajo a la pregunta de investigación formulada en sección 1.3:

1. La **ventaja del preentrenamiento sobre el dominio clínico** frente a codificadores generalistas.

2. La **saturación temprana del sondeo lineal** , que alcanza el grueso de su rendimiento con 1–5 % de los datos etiquetados.
3. La **brecha entre codificadores específicos y LLMs multimodales generalistas** , a favor de los primeros.
4. El **gap sistemático por fototipo cutáneo** , con sentido peor-en-fototipos-elevados y consistente entre encoders.
5. La **ausencia de un método óptimo único y la consiguiente especialización por tarea** (sección 5.1.1), lectura transversal que sintetiza las cuatro anteriores.

Las cuatro primeras son afirmaciones directas; la quinta es una lectura de orden superior que emerge de leerlas en conjunto. Su cuantificación y su lectura como conclusiones se desarrollan en el capítulo 7 (sección 7.1). La quinta está, además, acotada por el tamaño moderado del dataset DermapixelAI 1.0 (sección 6.4), su cola larga en el nivel L3 y el carácter exploratorio de varios de los contrastes por nivel ontológico: el patrón cualitativo es robusto, pero no constituye una ordenación cuantitativa cerrada entre métodos, cuya validación requeriría los tamaños muestrales y la cohorte prospectiva descritos en el capítulo 7.

CONCLUSIONES

7.1 Respuesta a la pregunta de investigación

La pregunta formulada en sección 1.3 se respondió mediante la evaluación empírica de catorce modelos fundacionales sobre doce datasets externos públicos armonizados a una ontología jerárquica L1/L2/L3, bajo cuatro protocolos principales (sondeo lineal, ajuste fino supervisado, segmentación binaria promptable y clasificación zero-shot multimodal) y tres protocolos complementarios (equidad por fototipo cutáneo, comparación con modelos de lenguaje multimodales generalistas, auditoría de solapamiento con el dataset de preentrenamiento Derm1M). La evidencia disponible sostiene cuatro afirmaciones cualitativas, en las que se resumen los hallazgos defendibles del trabajo.

Primera. Ventaja del preentrenamiento sobre el dominio clínico. PanDerm Large constituye, entre los encoders contrastados con pesos públicos, el modelo con mejor rendimiento agregado sobre los diez datasets externos contrastados. La mejora media respecto a PanDerm Base es de +4,1 pp en accuracy, +9,0 pp en BAcc y +3,6 pp en AUROC bajo sondeo lineal. La mejora absoluta es máxima sobre Dermnet (+10,0 pp accuracy), WSI patches (+8,7 pp) y PAD-UFES-20 (+4,7 pp), datasets con mayor número de clases o mayor heterogeneidad de adquisición. El ajuste fino con la receta del paper original aumenta la BAcc en +47,1 pp sobre HAM10000 y +19,4 pp sobre PAD-UFES-20, atribuible al aprendizaje de las clases minoritarias. La especialización del dominio se cuantifica también frente a arquitecturas convolucionales supervisadas: la ventaja de PanDerm Large sobre la mejor CNN crece con la dificultad del dataset, desde +0,5 pp accuracy sobre HAM10000 hasta +8,2 pp sobre PAD-UFES-20.

Segunda. Saturación temprana del sondeo lineal. El sondeo lineal sobre encoders preentrenados específicos de dominio alcanza saturación con un volumen de datos etiquetados muy reducido: con 1 % del conjunto de entrenamiento de HAM10000 (82 imágenes), PanDerm Large recupera 95,7 % de la accuracy y 96,2 % del AUROC del

7. CONCLUSIONES

modelo entrenado con el conjunto completo; con 5 % (410 imágenes), AUROC alcanza 97,7 % del valor máximo. Sobre PAD-UFES-20, 14 imágenes de entrenamiento (1 %) bastan para alcanzar 0,907 AUROC, equivalente al 95,5 % del rendimiento con el conjunto completo. Esta eficiencia es relevante para contextos clínicos con disponibilidad limitada de etiquetas: enfermedades raras, centros de bajo volumen asistencial, subgrupos poco representados y extensión a especialidades dermatológicas no cubiertas por los benchmarks habituales.

Tercera. Brecha entre modelos específicos y LLMs multimodales generalistas. La comparación de paradigmas sobre HAM10000 cuantifica un gradiente de rendimiento de 43,5 pp de accuracy entre el mejor especialista ajustado (PanDerm Base FT con TTA, 0,920) y el mejor modelo de lenguaje multimodal generalista *zero-shot* (GPT-4o, 0,485). La adaptación con LoRA sobre MedGemma 27B reduce parcialmente esta brecha (+13,7 pp Acc HAM, +18,3 pp Acc DDI), pero no sistemáticamente entre datasets (−1,7 pp sobre PAD-UFES-20). La consecuencia operativa para sistemas de apoyo al diagnóstico es que los LLMs multimodales generalistas no constituyen sustitutos defendibles de los encoders fundacionales específicos del dominio en el régimen clínico evaluado, sin perjuicio de su papel complementario como generadores de razonamiento textual o explicaciones.

Cuarta. Gap sistemático por fototipo cutáneo. Los cinco encoders contrastados sobre Fitzpatrick17k completo presentan *gap* I-VI positivo sobre la formulación de tres clases de malignidad, con valores en BAcc entre +0,124 (BiomedCLIP) y +0,306 (DINOv2 ViT-L/14). La paradoja BiomedCLIP, con *gap* mínimo asociado a la peor BAcc global (0,590), ilustra que la métrica de equidad aislada no constituye un criterio decisonal: un modelo uniformemente inferior puede presentar baja desigualdad sin ser equitativo en sentido sustantivo. El modelo con mejor compromiso entre rendimiento global y equidad es PanDerm Large (BAcc 0,699, *gap* +0,217); DermLIP v2 ofrece la mejor BAcc global (0,721) con *gap* superior (+0,281).

Síntesis. No hay modelo universalmente superior, sino especialización por tarea. Leídas en conjunto, las cuatro afirmaciones anteriores no convergen en la designación de un modelo vencedor único, sino en una lectura matizada de la pregunta de investigación. La evidencia empírica apunta a que el rendimiento dermatológico no es una propiedad absoluta del codificador, sino una función conjunta del nivel ontológico evaluado, del régimen de datos etiquetados disponibles, de la modalidad de entrada y de la estrategia de adaptación. Cada escenario favorece una combinación distinta de modelo y protocolo: clasificación general, subcategoría clínica L2, cola larga L3, ranking probabilístico, segmentación y cribado de seguridad de melanoma no se resuelven con el mismo método óptimo. Esta lectura, desarrollada como tesis transversal en sección 5.1.1, desplaza el cuello de botella del avance: deja de residir únicamente en la capacidad representacional del encoder y pasa a localizarse en la taxonomía diagnóstica, la calidad y cobertura de las etiquetas, el alineamiento texto-imagen, la formulación de los *prompts*, la equidad por fototipo cutáneo y la estrategia de despliegue. La respuesta a la pregunta formulada en sección 1.3 es, por tanto, condicional: el

modelo y el protocolo adecuados se seleccionan en función del objetivo clínico y de las restricciones de cómputo, datos y supervisión, no en abstracto.

Corolario: la palanca de mejora son los datos. Si el cuello de botella ya no reside únicamente en la capacidad representacional del codificador, el corolario transversal del trabajo es que la palanca dominante de mejora son los datos. La evidencia lo sugiere de forma recurrente: la ventaja de PanDerm y de DermLIP procede de la escala y el dominio de su preentrenamiento; la adaptación eficiente de Dermapixel R0 sólo es viable porque dispone de datos clínicos en castellano; el nivel L3 fracasa por falta de muestras en la cola larga; y la línea de mayor impacto potencial es la ampliación del dataset con el banco hospitalario del HUSLL. El siguiente salto en rendimiento clínico no se espera, por tanto, de sustituir el codificador, sino de ampliar y mejorar los datos —en cobertura diagnóstica, representación de fototipos y registro lingüístico— sobre los que se adapta y evalúa.

7.2 Contribuciones reproducibles

Las contribuciones del trabajo se enumeran en orden decreciente de centralidad respecto a la pregunta de investigación.

7.2.1 Contribuciones en el cuerpo del documento

1. **Reproducción experimental de PanDerm sobre arquitectura aarch64.** El pipeline de PanDerm Base y Large se ha verificado sobre NVIDIA DGX Spark con chip Grace Hopper GB10, 128 GB de memoria unificada, CUDA 13.0 y precisión BF16, con reproducción de los rangos numéricos reportados por Yan et al. [1] sobre los datasets compartidos. La portabilidad al chip Grace Hopper queda documentada como base operativa para grupos de investigación con hardware no estándar.
2. **Benchmark homogéneo de catorce modelos fundacionales sobre doce datasets.** El estudio comparativo aplica cuatro protocolos principales bajo configuración estándar (sección 3.6) sobre PanDerm Base y Large, DINOv2, tres variantes de DermLIP, BiomedCLIP, SigLIP-Large, SAM2.1-Large, GPT-4o, Gemini 2.5 Pro, MedGemma 4B Vision y 27B Text, y BLIP-2, más dos líneas de base de redes convolucionales supervisadas (ConvNeXt-Large y EfficientNetV2-Large) como referencia no fundacional. Las cifras se reportan con desglose por dataset y métrica (tabla 4.1, tabla 4.2, tabla 4.11).
3. **Ontología jerárquica L1/L2/L3.** Cuatro categorías etiológicas, 43 subcategorías clínicas y 367 diagnósticos individuales codificados en SNOMED CT y CIE-10, validados por revisión experta de la Dra. R. Taberner. La ontología se aplica a la armonización de once de los doce datasets externos contrastados, agregando 72 654 imágenes sobre vocabulario común y habilitando comparaciones inter-dataset defendibles a nivel L1 y L2.
4. **Dataset DermapixelAI 1.0.** Primer dataset dermatológico verificado en español con imagen, metadatos y texto narrativo asociado (1 089 imágenes, 669 casos clínicos, mediana de 223 palabras por caso). Particionado bajo regla *case-aware*

7. CONCLUSIONES

(891/157/41) y distribuido bajo licencia CC-BY-NC-SA 4.0 con datasheet formal (Anexo C) y documento de entrega (Anexo E).

5. **Auditoría sistemática de solapamiento con Derm1M.** Procedimiento por hash MD5 exhaustivo sobre los doce datasets externos contrastados, con identificación de Dermnet como único conjunto con solapamiento exacto (100 % contenido en Derm1M) y declaración de *caveat* explícito sobre las cifras zero-shot de la familia DermLIP en ese dataset.
6. **Marco metodológico reproducible de evaluación.** Más allá de las contribuciones anteriores tomadas por separado, su articulación bajo un protocolo común—benchmark homogéneo, ontología jerárquica, auditoría de *leakage*, análisis de equidad por fototipo, interpretabilidad mediante Sparse Autoencoders, segmentación promptable y clasificación zero-shot multimodal—constituye en sí misma un marco de evaluación reproducible y transferible a futuros modelos fundacionales dermatológicos, con código, *splits* canónicos y *outputs* documentados en el Anexo A.

7.2.2 Contribuciones complementarias

6. **Análisis empírico de equidad por fototipo.** Evaluación de cinco encoders sobre Fitzpatrick17k completo (16577 imágenes, 6 fototipos cutáneos) con cuantificación del *gap* I-VI por modelo (tabla 4.12) y análisis cruzado *Light* ↔ *Dark* (tabla B.9).
7. **Caracterización de la sensibilidad al tokenizador en DermLIP.** Identificación del tokenizador y la formulación del *prompt* como factores críticos del rendimiento zero-shot, con diferencia de 48,8 pp AUROC entre la peor y la mejor configuración sobre HAM10000.
8. **Adaptación de SAM2.1 al dominio dermatoscópico mediante *fine-tuning* del decodificador.** Ajuste denso del *mask_decoder* y el *promptable encoder* (~ 4,2 M pesos entrenables), congelando el *image_encoder* Hiera-Large preentrenado. Resultado de Dice 0,947 sobre ISIC2018 (+2,6 pp sobre la cifra publicada por Yan et al. [1]), con transferencia fuera de dominio prácticamente nula sobre ISIC2017 (0,945) y PH2 (0,960).
9. **Ensemble de seguridad para detección de melanoma.** Combinación OR *top-3* de PanDerm Large ajustado sobre HAM10000 (M1) y SigLIP-Large SO400M con sondeo lineal, que alcanza *recall* de melanoma del 100 % (70 de 70, *top-3*) sobre el conjunto de test de HAM10000.
10. **Modelo de cuello de botella conceptual SAE × SkinCon.** Replicación del mecanismo de interpretabilidad por Sparse Autoencoders sobre PanDerm Large (SAE Large, 1024 → 16384 *features*, entrenado sobre 50 454 imágenes) y su validación frente al diccionario clínico SkinCon [15] mediante un *Concept Bottleneck Model*, con AUROC media de 0,880 sobre los 22 conceptos con cobertura suficiente y 11 conceptos con AUROC del mejor predictor superior a 0,80. Los experimentos E1–E4 de validación conceptual sobre Derm7pt se detallan en el Anexo F.

11. **Dermapixel R0: primer modelo fundacional dermatológico en español.** Modelo inicializado desde el codificador PanDerm Large y adaptado sobre el dataset DermapixelAI 1.0, articulado en una rama supervisada (cabeza L2 con LoRA $r = 16$, BAcc $0,363 \pm 0,007$ y AUROC $0,855 \pm 0,006$, sección 4.12) y una rama contrastiva multimodal castellano (sección 4.13). Constituye una versión base entrenada sobre un corpus reducido: la contribución reside en ser el primero de su clase y en la metodología reproducible que establece, no en un rendimiento competitivo. Su escalado con el banco hospitalario del HUSLL se documenta como línea de continuación en la sección 7.5.2.

7.3 Hallazgos metodológicos transferibles

Los hallazgos metodológicos del trabajo son transferibles a escenarios clínicos análogos y constituyen aportaciones operativas más allá del benchmark concreto evaluado. El primero es de orden estructural —la inexistencia de un método óptimo único— y enmarca a los restantes, que precisan las condiciones bajo las que cada estrategia resulta preferible.

Ausencia de un método óptimo único. El hallazgo transversal del trabajo es que ningún codificador ni estrategia de adaptación domina todos los escenarios: la configuración preferible depende del nivel ontológico, del régimen de datos, de la modalidad de entrada y del objetivo clínico (clasificación general, subcategoría clínica L2, cola larga L3, ranking probabilístico, segmentación o cribado de seguridad). Esta especialización por tarea, sostenida en sección 5.1.1, implica que el diseño de un sistema de apoyo dermatológico debe formularse como selección condicional de modelo y protocolo, y no como adopción de un único encoder de referencia.

Régimen de aplicabilidad del sondeo lineal. La comparación cuantitativa sobre cuatro datasets (sección 5.1.4) delimita un régimen operativo: para datasets con $N_{\text{train}} \lesssim 500$ imágenes, el sondeo lineal sobre PanDerm Large supera al ajuste fino completo en accuracy, BAcc, AUROC y F1 ponderada. El umbral se identifica sobre DDI ($N_{\text{train}} = 427$), donde el sondeo lineal mantiene AUROC 0,827 frente a 0,682 del ajuste fino.

Compatibilidad tokenizador-encoder en zero-shot. La AUROC en clasificación zero-shot con modelos vision-lenguaje contrastivos depende críticamente de la compatibilidad entre el tokenizador empleado para los *prompts* y el espacio de *embeddings* del encoder textual del modelo. La verificación empírica de esta compatibilidad sobre un conjunto de validación del dominio es prerequisite de cualquier despliegue zero-shot defendible.

Ajuste del decodificador sobre encoders promptables preentrenados a gran escala. La combinación de SAM2.1-Large preentrenado con *fine-tuning* del decodificador de máscaras, manteniendo congelado el encoder visual, supera al *fine-tuning* completo de baselines dermatológicos específicos, con actualización de aproximadamente 4,2 M parámetros entrenables (inferior al 2 % del total). La generalización fuera de dominio

es prácticamente nula, lo que sugiere que las primitivas geométricas codificadas por el encoder visual transfieren entre fuentes de adquisición sin reentrenamiento.

Limitación operativa del *gap* aislado como métrica de equidad. La paradoja Bio-medCLIP —*gap* I-VI mínimo (+0,124 en BAcc) asociado a la peor BAcc global (0,590)— demuestra que la métrica *gap* aislada puede inducir conclusiones erróneas sobre la equidad sustantiva de un modelo. El reporte conjunto de BAcc global, AUROC global y *gap* es metodológicamente preferible y debería adoptarse como práctica estándar en estudios de equidad dermatológica.

Sondeo lineal supera al ajuste fino bajo sobreajuste. El caso DDI ($N_{\text{train}} = 427$, descenso de AUROC $-14,5$ pp con ajuste fino respecto al sondeo lineal) es diagnóstico de la posibilidad de sobreajuste del encoder ajustado pese a las aumentaciones de la receta canónica (Mixup, CutMix, *weighted random sampler*). La heurística operativa derivada es que el ajuste fino sobre datasets pequeños debe ir acompañado de monitorización de AUROC sobre conjunto de validación independiente, y descartarse si el ranking de probabilidades degrada.

Recuperación k -NN como alternativa competitiva en la cola larga. La evidencia empírica apunta a que, sobre el nivel diagnóstico fino L3, dominado por una distribución de cola larga estricta, la recuperación por vecinos más próximos con índice FAISS sobre *embeddings* congelados resulta competitiva frente a las cabezas paramétricas, que carecen de muestras suficientes por clase para estimar fronteras de decisión estables (sección 5.1.1). La heurística operativa es que, cuando la cardinalidad de clases excede la disponibilidad de etiquetas, la recuperación no paramétrica sobre el espacio de representación es preferible a la clasificación supervisada directa.

Interpretabilidad conceptual emergente vía Sparse Autoencoders. La descomposición del espacio de representación de PanDerm Large mediante Sparse Autoencoders revela *features* alineadas con conceptos dermatológicos clínicamente interpretables sin supervisión conceptual durante el preentrenamiento, validadas frente al diccionario SkinCon [15] y frente a las anotaciones *Seven-Point Checklist* de Derm7pt. Esta interpretabilidad emergente habilita modelos de cuello de botella conceptual que acotan el compromiso interpretabilidad-precisión, y constituye una vía de trazabilidad clínica transferible a otros encoders fundacionales del dominio.

7.4 Aportaciones a la práctica clínica

El trabajo aporta cuatro elementos directamente aplicables al diseño de sistemas de apoyo al diagnóstico dermatológico en el contexto del Servicio de Dermatología del HUSLL y, por extensión, al circuito de teledermatología institucional descrito en sección 1.2.

Arquitectura técnica defendible. Encoder PanDerm Large preentrenado y congelado por defecto, con cabeza lineal multi-clase mediante regresión logística L-BFGS ($C = 1,0$, $\text{max_iter} = 5000$) en datasets con $N_{\text{train}} \lesssim 500$, o cabeza ajustada con la receta de

PanDerm Large en datasets con $N_{\text{train}} \gtrsim 5000$ y desbalance acusado. Segmentación con SAM2.1-Large adaptado mediante *fine-tuning* del decodificador cuando la tarea requiera localización de lesión. Ensemble OR *top-3* de M1 (PanDerm Large *fine-tuned*) y SigLIP-Large con sondeo lineal cuando la tarea sea cribado oportunista de melanoma con prioridad de *recall*.

Ontología armonizada como columna vertebral. La ontología L1/L2/L3 con codificación SNOMED CT y CIE-10 proporciona una columna vertebral semántica reutilizable para sistemas de información hospitalarios y compatible con la nomenclatura clínica del entorno. La presentación jerárquica al usuario clínico (predicción L3 acompañada de su agregación L2 y L1) aporta robustez frente a la incertidumbre en la cola larga sin sacrificar especificidad cuando ésta sea fiable.

Dataset DermapixelAI 1.0 como recurso público en español. Habilita la reutilización del archivo Dermapixel en proyectos académicos posteriores, la adaptación de modelos vision-lenguaje a texto clínico en castellano y la validación de sistemas de apoyo sobre material de referencia docente reconocida en el ámbito hispanohablante.

Caveats explícitos sobre fuga de información. La auditoría de solapamiento entre datasets de evaluación y preentrenamiento aporta una práctica de reporte transferible a otros benchmarks dermatológicos. La declaración explícita de *caveats* de leakage en las tablas (tabla 3.1) y la consistencia entre la cifra reportada y su *caveat* asociado debería adoptarse como condición de defensibilidad en publicaciones del campo.

7.5 Líneas de investigación abiertas

Las líneas abiertas que se desarrollan a continuación constituyen propuestas concretas con experimentos identificados, prerequisites declarados y métricas esperables. Todas descansan sobre las contribuciones reproducibles enumeradas en sección 7.2.

Conviene distinguir con precisión dos registros dentro de esta sección. Algunas subsecciones recogen trabajo ya *ejecutado* y reportado en el capítulo 4 —la cobertura experimental sobre DermapixelAI 1.0, el eje Derm7pt + Sparse Autoencoders y la selección de arquitectura de segmentación—, que se presenta aquí como base consolidada y no como agenda pendiente. Las restantes —el escalado con el banco hospitalario del HUSLL, la validación clínica prospectiva, el aprendizaje activo, la IA agéntica y el reentrenamiento multilingüe de la rama lingüística— son agenda futura genuina, condicionada a recursos o aprobaciones específicas y no ejecutada en este trabajo.

7.5.1 Cobertura experimental sobre DermapixelAI 1.0: técnicas ejecutadas y pendientes

Las secciones 4.10 y 4.11 del capítulo 4 evalúan PanDerm Base, PanDerm Large, DermLIP v2, SigLIP-SO400M y BiomedCLIP sobre DermapixelAI 1.0 exclusivamente como extractores de *features* congelados, en combinación con cabezas paramétricas ligeras (regresión logística, k -NN, MLP de 512 unidades) o con clasificación contrastiva *zero-shot*. El espacio de hipótesis no explorado sobre el dataset en castellano incluye

7. CONCLUSIONES

un conjunto de técnicas de *transfer learning* denso que la literatura sobre modelos fundacionales en imagen médica documenta como aportando incrementos típicos de 10 a 20 pp en BAcc respecto al sondeo lineal congelado, en línea con los +47,1 pp BAcc sobre HAM10000 y +19,4 pp BAcc sobre PAD-UFES-20 cuantificados en la sección 4.4. La presente sección documenta de forma explícita estas técnicas pendientes y la cifra esperable sobre L2 (38 clases) tras su aplicación, condicionada a la disponibilidad del banco hospitalario HUSLL como ampliación del dataset.

Cuadro 7.1: Técnicas de *transfer learning* pendientes de aplicación sobre DermapixelAI 1.0 con el cuerpo experimental del presente trabajo. *Coste*: orden de magnitud sobre NVIDIA DGX Spark GB10. *Esperado*: mejora cualitativa estimada a partir de las referencias internas del trabajo. *Estado*: situación respecto al cierre del presente TFG.

Método	Tipo	Coste estimado	Mejora esperada	Estado
Ajuste fino completo del encoder	Supervisado	~ 5 min Spark (3 niveles)	+18,2 pp BAcc L1 sobre LP CV; -4,0 pp BAcc L2 frente a Dermapixel R0 LoRA; sin mejora sobre LP en L3	Ejecutado (L1+L2+L3), sección 4.10.3
LoRA $r = 16$ (Dermapixel R0)	PEFT	~ 12 min Spark (3 seeds)	+19,5 pp BAcc L2 sobre LP CV; AUROC L2 0,855 empata con DermLIP individual	Ejecutado , sección 4.12
<i>Test-time augmentation</i>	Inferencia	5–10 min	+3 a +22 pp Acc@3 (cf. sección H.8.7)	Probado , sección J.5
Ensemble Base+Large+DermLIP	Inferencia	Trivial	+6,7 pp AUROC L2 con DermLIP individual; +2,1 pp AUROC L1 con avg Large+DermLIP	Probado , sección 4.10.3
Pérdida focal / reponderación de clases	Entrenamiento	~ 15 min Spark	+3,3 pp BAcc L1 y +5,9 pp BAcc L2 sobre LP CE ($\gamma = 2,0$); sin efecto L3	Ejecutado ($\gamma \in \{1, 2, 5\} \times \{\text{none, balanced}\}$), sección J.4
CBM sobre conceptos SkinCon	Interpretable	Anotación dermatológica	Trazabilidad clínica	Diseñado (Anexo F)
Banco hospitalario HUSLL (~ 22 K)	Datos	3–6 meses (CEIC)	Activación L3 directa (cabeza L3 de Dermapixel R0)	Bloqueado (revisión ética)

La elección de evaluar sobre encoder congelado en las secciones 4.10 y 4.11 sigue el protocolo estándar de la literatura sobre modelos fundacionales en imagen médica, que prioriza la cuantificación limpia del valor del preentrenamiento sobre datos del dominio sin contaminación por hiperparámetros específicos de ajuste fino. La familia PanDerm [1], DermLIP [2] y BiomedCLIP [18] reportan sus cifras principales bajo este protocolo, lo que permite la comparación directa con la literatura. Los métodos pendientes recogidos en la tabla 7.1 se concentran tras el cierre experimental del presente trabajo en la extensión del dataset vía banco hospitalario HUSLL (bloqueada por la revisión ética del CEIC) y en la línea de modelos de cuello de botella conceptual (CBM) sobre conceptos SkinCon, condicionada a la anotación dermatológica detallada en el Anexo F. Las restantes técnicas (ajuste fino denso L1+L2+L3, adaptación LoRA de Dermapixel R0, *Test-Time Augmentation*, ensemble multi-codificador y pérdida focal) han sido ejecutadas y reportadas en las secciones correspondientes del capítulo 4.

Bajo la hipótesis de aplicación combinada de las técnicas pendientes (ajuste fino del encoder con la receta de la sección 4.4, ensemble PanDerm+DermLIP en la línea documentada en la sección H.8.7 y ampliación con el banco hospitalario HUSLL hasta superar el umbral de aproximadamente 30 imágenes por clase L3 que activa la variante

con cabeza L3 directa de Dermapixel R0), las cifras esperables para un clasificador desplegable sobre L2 (38 subcategorías clínicas) en castellano se estiman en BAcc entre 0,45 y 0,55, orden de magnitud comparable con el rango reportado en la sección 4.4 para PanDerm Base ajustado sobre HAM10000 (BAcc 0,575 sobre 7 clases). Esta estimación es prospectiva, no constituye un compromiso ni una predicción puntual, y queda condicionada a la disponibilidad efectiva del banco hospitalario tras la revisión por el comité ético de investigación clínica y a la calibración empírica de la receta de ajuste fino sobre el material en castellano.

7.5.2 Dermapixel R0: primer modelo fundacional dermatológico en español

Dermapixel R0 constituye, a juicio de este trabajo, su aportación más original: el primer modelo fundacional dermatológico adaptado al español del que se tiene constancia a la fecha de cierre. La denominación se emplea en sentido preciso: Dermapixel R0 no es un preentrenamiento fundacional a gran escala —como PanDerm o Derm1M—, sino la adaptación de un modelo fundacional preexistente (PanDerm Large) al registro clínico en castellano; el calificativo *primero* se acota a esa categoría —adaptación con pesos abiertos, texto clínico narrativo y registro en español— y no a una prioridad histórica absoluta sobre cualquier recurso dermatológico hispanohablante. Su relevancia no reside en una métrica de máximo rendimiento —es, por diseño, una versión base (R0) entrenada sobre un dataset reducido, un punto de partida y no un modelo terminado—, sino en lo que demuestra: que un modelo dermatológico especializado en castellano puede construirse sobre un modelo fundacional liberado mediante técnicas de adaptación eficiente, con un presupuesto de cómputo y de datos al alcance de una institución hospitalaria y un grupo académico. El preentrenamiento de los modelos de base exige los grandes datasets y el cómputo de grupos de investigación especializados; este trabajo evidencia que la especialización posterior —lingüística y clínica— no comparte esa barrera de entrada.

Dermapixel R0 se inicializa desde el codificador PanDerm Large, se adapta sobre el dataset DermapixelAI 1.0 y se articula en dos ramas complementarias.

La primera es la rama **supervisada**: cabeza clasificadora sobre encoder PanDerm Large adaptado mediante *Low-Rank Adaptation*. Comprende la cabeza L2 con LoRA $r = 16$ ejecutada y reportada en la sección 4.12 y una cabeza L3 directa —condicionada al banco hospitalario HUSLL—, descritas a continuación en los párrafos correspondientes.

La segunda es la rama **zero-shot multimodal**: la rama contrastiva de Dermapixel R0, sistema dual-encoder estilo CLIP que alinea el encoder visual PanDerm Large con un encoder textual multilingüe (intfloat/multilingual-e5-base) sobre el mismo dataset DermapixelAI 1.0. Se han ejecutado cinco iteraciones experimentales (v1 a v5) reportadas íntegramente en la sección 4.13. La iteración v4 (LoRA visual $r = 32$ sobre los últimos doce bloques del ViT, régimen híbrido *H6* en inferencia) alcanza L3 *accuracy@1 zero-shot* = 0,2475 sobre el conjunto de test de 101 imágenes, esencialmente el umbral paper-grade 0,25 fijado a priori sobre vocabulario castellano fino. La iteración v5, bajo configuración LoRA idéntica y ampliación del dataset con 15 128 imágenes externas genéricas, reporta una ablación negativa documentada (0,2079, −4,0 pp): la escala genérica mejora las representaciones visuales aisladas pero erosiona la alineación cross-modal sobre el registro discursivo castellano. La rama aporta tres resultados

empíricos complementarios. El primero es la recuperación cross-modal castellano-imagen, con un *lift* de $14,0\times$ sobre el azar ($v2, i2t R@5 = 0,654$ frente a $0,047$ en régimen de *caption* rica, $pool = 107$). El segundo es el diagnóstico mecanístico del techo del encoder visual congelado mediante *Linear Probing*. El tercero es la reducción del ECE L3 en un 97 % ($0,7262 \rightarrow 0,0213$ con $\tau = 0,4165$ sobre $v4$) mediante *temperature scaling* [35]. Una ablación independiente con un modelo fundacional inglés grande preentrenado confirma que el cuello de botella experimental era la escala de la alineación cross-modal castellano, no el codificador visual ni la formulación textual (Anexo I). La rama zero-shot no es sustitutiva de la supervisada: ambas operan sobre regímenes de uso distintos (vocabulario abierto frente a vocabulario cerrado L2/L3) y la integración del prototipo DermApIxel (Anexo H) las expone como módulos paralelos del pipeline.

Los párrafos siguientes describen los prerequisites y el estado de las dos versiones de la rama supervisada.

Dermapixel R0 (cabeza supervisada L2). Cabeza L2 (38 clases efectivas tras consolidación de variantes ortográficas) sobre encoder PanDerm Large adaptado mediante *Low-Rank Adaptation* (LoRA, $r = 16$, $\alpha = 32$) sobre los dos últimos bloques de transformer, con ranking L3 por similitud coseno sobre los *embeddings* prototípicos del conjunto de entrenamiento de DermapixelAI 1.0. El protocolo es ejecutable sobre el hardware actual del proyecto sin recursos adicionales. La métrica primaria prevista era Acc-top-1 sobre L2 y *recall*-top-3 sobre L3 en el conjunto de test, con validación cruzada estratificada por L1 dada la limitación del tamaño muestral.

La ejecución del protocolo (sección 4.12 del capítulo 4) reporta sobre el nivel L2 BAcc = $0,363 \pm 0,007$, AUROC = $0,855 \pm 0,006$ y Acc@3 = $0,500 \pm 0,023$ (media $\pm$ desviación estándar sobre tres semillas, con 524 K parámetros entrenables que representan el 0,17 % del encoder). Sobre el ranking L3 por prototipos, Acc@1 = $0,167$, Acc@3 = $0,259 \pm 0,013$ y Acc@5 = $0,296 \pm 0,026$ sobre 250 clases. Las cifras observadas alcanzan o superan las expectativas del diseño: la BAcc L2 mejora en +19,5 pp la cifra de validación cruzada del sondeo lineal congelado y la AUROC L2 empata estadísticamente con la de DermLIP v2 individual, lo que valida empíricamente la línea LoRA como protocolo de referencia sobre el dataset en castellano.

Dermapixel R0 (cabeza L3 directa). Cabeza L3 directa (251 diagnósticos efectivos sobre el vocabulario completo) condicionada a la incorporación del banco hospitalario del HUSLL (~ 22 000 estudios estimados tras aprobación CEIC). El umbral de activación es de al menos 30 imágenes por clase L3, condición no satisfecha por DermapixelAI 1.0 en aislamiento dado que 178 entradas L3 del vocabulario con muestras efectivas contienen ≤ 5 imágenes (cola larga estricta del vocabulario representado). La extensión vía banco HUSLL es condición necesaria y suficiente para la viabilidad de esta cabeza L3 directa.

En conjunto, Dermapixel R0 traslada al dominio dermatológico en español una conclusión de alcance más amplio: la frontera de la especialización ya no la marca el acceso a grandes infraestructuras de preentrenamiento, sino la disponibilidad de datos clínicos bien curados y de un protocolo de adaptación adecuado. La rama supervisada L2 ya ejecutada (sección 4.12) demuestra el principio sobre la cardinalidad clínica intermedia, y la cabeza L3 directa —condicionada al banco hospitalario HUSLL— defi-

ne la ruta de escalado natural. Como semilla reproducible y honestamente acotada, Dermapixel R0 deja establecida una línea de continuación que otras instituciones con archivos clínicos en su propia lengua podrían replicar sobre la misma receta de adaptación eficiente.

7.5.3 Derm7pt + Sparse Autoencoders: ground-truth conceptual para interpretabilidad

Las anotaciones *Seven-Point Checklist* de Derm7pt (siete criterios diagnósticos por imagen) constituyen ground-truth conceptual no explotada por la literatura previa sobre Sparse Autoencoders en dermatología. Los cuatro experimentos previstos sobre este eje (E1, correlación SAE-Derm7pt; E2, *Concept Bottleneck Model*; E3, cruce con los conceptos del Grupo A; E4, *fine-tuning* multitarea *concept-aware*) se han *ejecutado* y se reportan en la sección 4.14 y en el Anexo F; no constituyen, por tanto, trabajo pendiente, sino contribución ya realizada. Su resultado principal es que la base *sparse* aprendida sobre Derm1M alinea *features* individuales con la taxonomía dermatoscópica sin entrenamiento específico (AUROC efectivo hasta 0,926 sobre vasos en horquilla), y que el *fine-tuning* multitarea con LoRA produce inferencia simultánea de melanoma y los siete criterios en una sola pasada (cabeza melanoma AUROC 0,891), consolidando el módulo de interpretabilidad del prototipo (Anexo H) sin pipelines en cascada.

La línea genuinamente abierta es la extensión del diccionario conceptual a los 15 conceptos clínicos adicionales propuestos por la Dra. R. Taberner (Anexo F) —no contemplados por SkinCon ni por el *Seven-Point Checklist*—, condicionada al muestreo y anotación de aproximadamente 200 imágenes por concepto.

7.5.4 Aprendizaje activo *in-domain* sobre clases L3 con peor cobertura

La trilogía contrastiva de Dermapixel R0 (sección 4.13) mostró que ampliar el dataset de entrenamiento con escala genérica externa (v5) no rellena la cola larga de L3 —327 clases con ≤ 5 imágenes en el vocabulario ontológico— y erosiona la alineación cross-modal sobre el registro castellano, mientras que la iteración v4 ya alcanza el umbral *a priori* de *accuracy@1* $\sim 0,25$. La palanca correcta para extender la cobertura no es, por tanto, más datos genéricos, sino aprendizaje activo dirigido *in-domain*: identificar las clases L3 con peor cobertura en el subconjunto castellano e invertir en ellas anotación experta, con los candidatos generados por el prototipo DermApIxel sobre cohortes del HUSLL bajo revisión de la Dra. R. Taberner.

El banco hospitalario HUSLL ($\sim 22\,000$ estudios tras aprobación CEIC, sección 7.5.6) es el recurso natural: refleja la distribución diagnóstica real del servicio, está alineado con el registro castellano del archivo Dermapixel y permite tanto el llenado dirigido de la cola larga como la eventual activación de la cabeza L3 directa al superar las ~ 30 imágenes por clase (sección 7.5.2). Tras alcanzar v4 el umbral operativo, esta línea se replantea como ruta de generalización hacia cobertura clínica completa, no hacia el *target*. La ablación del Anexo I la refuerza: la palanca pendiente es anotación experta *in-domain*, no escala genérica de datos.

7.5.5 Selección de arquitectura para segmentación promptable

La comparativa pareada de arquitecturas promptables (sección 4.6.1) ya está ejecutada y delimita una pauta de selección reproducible: la generación SAM2 domina sobre SAM v1 con independencia del preentrenamiento de dominio, el factor determinante del rendimiento es la caja-*prompt* y no el segmentador, y MedSAM2-tiny (Dice 0,9556, 26 ms) se identifica como candidata de referencia para despliegues con restricciones de cómputo, con la cifra estable bajo validación cruzada y próxima al techo de acuerdo inter-anotador. La línea abierta se reduce, por tanto, a dos elementos no resueltos en este trabajo: la evaluación con un detector de lesión extremo a extremo que sustituya la caja manual y la validación prospectiva sobre adquisición clínica no dermatoscópica.

7.5.6 Escalado del dataset con el banco hospitalario HUSLL

La extensión del dataset DermapixelAI 1.0 con el banco hospitalario del HUSLL constituye la línea de mayor impacto potencial sobre el rendimiento clínico real del sistema. La estimación preliminar es de aproximadamente 22 000 estudios disponibles en archivo, con metadatos asociados (imagen clínica, dermatoscópica cuando disponible, diagnóstico final, edad y sexo del paciente). Los prerequisites son cuatro: aprobación del Comité Ético de Investigación Clínica de las Illes Balears (CEIC-IB), implementación de un protocolo de anonimización compatible con RGPD y la Ley Orgánica 3/2018, definición de un esquema de licencia compatible con la naturaleza hospitalaria del material (probablemente más restrictiva que CC-BY-NC-SA 4.0), y establecimiento de un equipo de validación experta liderado por la Dra. R. Taberner con apoyo de residentes de dermatología del HUSLL.

La incorporación del banco hospitalario habilita la cabeza L3 directa de Dermapixel R0 (sección 7.5.2), la validación clínica prospectiva sobre cohorte real (sección 7.5.7) y un análisis de equidad sobre fototipo cutáneo más representativo de la población atendida por el sistema sanitario español que el disponible en Fitzpatrick17k.

7.5.7 Validación clínica prospectiva

La validación clínica prospectiva del prototipo DermApIxel (Anexo H) sobre cohorte hospitalaria real del HUSLL requiere un protocolo aprobado por CEIC-IB con cuatro elementos: definición de *endpoints* clínicos primarios (*recall* de melanoma, tasa de derivaciones evitadas) y secundarios (concordancia inter-observador, tiempo de diagnóstico, valoración subjetiva del clínico); cálculo muestral basado en los *recall* preliminares de ~ 0,97 obtenidos sobre HAM10000 con M1+SigLIP y un *estándar de oro* conservador; reclutamiento de dermatólogos revisores independientes para arbitraje en casos de discrepancia; y plan de análisis estadístico preregistrado.

La cifra de *recall* del 100 % sobre melanoma reportada en sección H.8.7 es prueba de concepto sobre material de archivo, no resultado clínico validado. Su extrapolación al flujo asistencial real requiere la validación prospectiva aquí esbozada, identificada como prerequisite de cualquier despliegue operativo más allá del prototipo.

7.5.8 Auditoría sistemática de leakage extensible

La auditoría por hash MD5 desarrollada para Derm1M (sección 3.6.8) es directamente extensible a los demás datasets de preentrenamiento del ecosistema dermatológico (SkinGPT-4, MONET, MM-Skin, SkinFM, entre otros). La línea abierta consiste en aplicar el mismo procedimiento sobre los *splits* de evaluación canónicos y publicar las cardinalidades de intersección, con su script auditable, como recurso de referencia que permita recalibrar las cifras zero-shot publicadas sobre esos datasets.

7.5.9 Recuperación visual densa como sistema de apoyo

La recuperación visual densa basada en FAISS sobre los *embeddings* de Derm1M (~ 421 000 imágenes preindexadas) ya opera como componente del prototipo DermApixel (sección H.3.4 del Anexo H) con latencia inferior a 150 ms por consulta. La línea abierta es evaluar su valor clínico mediante un estudio mixto sobre cohorte HUSLL—*precision@k* sobre L1/L2 y valoración subjetiva de la utilidad de los casos recuperados como referencia diferencial—, con la integración en la historia clínica electrónica como prerrequisito técnico pendiente.

7.5.10 IA agéntica para razonamiento clínico estructurado

A medio plazo, la combinación de los componentes desarrollados (encoder PanDerm, ontología L1/L2/L3, dataset DermapixelAI, recuperación visual densa y LLM multimodal en local) habilita la construcción de un agente clínico orquestado bajo control del facultativo, que incorpore evidencia estructurada externa y auditable. Frente al uso directo de un LLM multimodal generalista (sección 5.1.7), este esquema reduciría el sesgo léxico documentado y facilitaría la justificación clínica de la salida. Su desarrollo es condicional a la disponibilidad de pesos abiertos con capacidad de razonamiento estructurado y se detalla en el Anexo H.

7.5.11 Reentrenamiento multilingüe de la rama lingüística

La sensibilidad documentada al tokenizador (sección 5.1.6) sugiere que un reentrenamiento dirigido del encoder textual de DermLIP sobre texto clínico en español aportaría mejoras apreciables sobre el rendimiento zero-shot en el ámbito hispanohablante. La estrategia mínima viable consiste en aplicar *continued pretraining* del encoder textual sobre los 669 casos clínicos de DermapixelAI 1.0 con el razonamiento narrativo asociado, manteniendo congelado el encoder visual de DermLIP. La estrategia ampliada requiere un dataset de pares imagen-texto en español de mayor escala, no disponible en la fecha de cierre del trabajo y condicional al escalado descrito en sección 7.5.6.

7.6 Cierre

El trabajo ha caracterizado empíricamente el rendimiento y la capacidad de generalización de catorce modelos fundacionales para imagen dermatológica disponibles, bajo cuatro protocolos principales y tres complementarios, sobre doce datasets externos armonizados a una ontología jerárquica de tres niveles validada por revisión experta. La evidencia obtenida sostiene cuatro afirmaciones cualitativas defendibles

(sección 7.1), las contribuciones reproducibles enumeradas en sección 7.2, los hallazgos metodológicos transferibles de la sección 7.3 y cuatro aportaciones a la práctica clínica (sección 7.4).

La lectura de conjunto de esta evidencia no es la designación de un codificador vencedor, sino una tesis matizada: el rendimiento dermatológico depende del nivel ontológico, del régimen de datos, de la modalidad de entrada y de la estrategia de adaptación, de modo que la elección de modelo y protocolo se resuelve en función del objetivo clínico y no en abstracto (sección 5.1.1). Esta lectura matiza cualquier ordenación global de los modelos evaluados y desplaza la palanca de mejora desde la capacidad representacional del encoder hacia la taxonomía diagnóstica, la cobertura de etiquetas, el alineamiento texto-imagen, los *prompts*, la equidad por fototipo cutáneo y la estrategia de despliegue.

Las líneas de investigación abiertas (sección 7.5) constituyen propuestas concretas con experimentos identificados y prerequisites declarados, no trabajo simplemente pendiente. Su ejecución completaría la cadena entre caracterización empírica del estado del arte, construcción de recursos públicos en español —el benchmark DermapixelAI 1.0 y la semilla Dermapixel R0, primer modelo fundacional dermatológico adaptado al español—, validación clínica prospectiva y despliegue operativo en el sistema sanitario, recorrido cuya primera etapa cierra el presente documento.

La aportación intelectual del trabajo se sitúa en la conjunción de tres elementos. El primero es una contribución empírica: la evaluación rigurosa y multi-eje del estado del arte, que cuantifica la dependencia del rendimiento respecto al nivel ontológico, el régimen de datos, la modalidad y la estrategia de adaptación. El segundo es una contribución de recurso: el dataset DermapixelAI 1.0 y la semilla Dermapixel R0 (contribuciones 7.2.1 y 7.2.2), primeros de su clase para texto clínico dermatológico en español. El tercero es la formulación explícita de líneas de continuación con base técnica y clínica verificable. De esta evidencia se desprende que el avance del campo no pasa por un único encoder de referencia, sino por una arquitectura modular que combine codificadores, niveles ontológicos y estrategias de adaptación según la tarea, junto con decisiones de despliegue que contemplen cobertura de etiquetas, equidad y trazabilidad. El siguiente paso natural es la primera publicación derivada del trabajo, centrada en la comparativa de modelos fundacionales bajo la ontología armonizada, seguida del escalado de Dermapixel R0 como modelo fundacional dermatológico para texto clínico en español a partir del dataset DermapixelAI 1.0 extendido con el banco hospitalario del HUSLL.

BIBLIOGRAFÍA

- [1] Yan, S. *et al.* (2025). A multimodal vision foundation model for clinical dermatology. *Nature Medicine*, 31, 2691–2702. DOI: 10.1038/s41591-025-03747-y. Versión arXiv: 2410.15038v3. 2.3, 3.2, 3.6.2, 4.6, 4.6, 4.4, 5.1.5, 5.2.1, 5.2.2, 6.1.2, 1, 8, 7.5.1, D.4
- [2] Yan, S., Hu, M., Jiang, Y., Li, X., Fei, H., Tschandl, P., Kittler, H., Ge, Z. (2025). Derm1M: A million-scale vision-language dataset aligned with clinical ontology knowledge for dermatology. arXiv:2503.14911v2. 2.4, 3.2, 3.6.5, 4.11, 4.13.3, 5.1.1.1, 5.2.3, 7.5.1, D.4, I.2, I.4
- [3] Yan, S., Li, X. *et al.* (2026). DermFM-Zero: A vision-language foundation model for zero-shot clinical collaboration and automated concept discovery in dermatology. arXiv:2602.10624v1. 2.5, 3.4, 6.1.1, F1
- [4] Taberner, R., Nadal, C., Llambrich, A., Vila, I.T.A. (2010). Dermatology service utilization and reasons for consultation by Spanish and immigrant patients in the region served by Hospital Son Llàtzer, Palma de Majorca, Spain. *Actas Dermo-Sifiliográficas* 101(4):323–329. 1.1, 6.2.1
- [5] Buendía-Eisman, A., Arias-Santiago, S., Molina-Leyva, A., Gilaberte, Y., Fernández-Crehuet, P., Husein-ElAhmed, H., Viera-Ramírez, A., Fernández-Peñas, P., Taberner, R., Descalzo, M.Á., García-Doval, I. (2018). Análisis de los diagnósticos realizados en la actividad ambulatoria dermatológica en España: muestreo aleatorio nacional DIADERM. *Actas Dermo-Sifiliográficas* 109(5):416–423. DOI: 10.1016/j.ad.2018.02.003. 1.1, 6.2.1
- [6] Tu, T., Palepu, A., Schaekermann, M., Saab, K., Freyberg, J., Tanno, R., Wang, A., Li, B., Amin, M., Tomasev, N., Azizi, S., Singhal, K., Cheng, Y., Hou, L., Webson, A., Kulkarni, K., Mahdavi, S.S., Semturs, C., Gottweis, J., Barral, J., Chou, K., Corrado, G.S., Matias, Y., Karthikesalingam, A., Natarajan, V. (2024). Towards conversational diagnostic AI. arXiv:2401.05654. 2.7
- [7] Google DeepMind (2024). Advancing AMIE: a research AI agent for clinical reasoning, conversation and diagnosis (AI co-clinician). Disponible en <https://deepmind.google/blog/ai-co-clinician/>. Consultado en abril de 2026. 2.7
- [8] Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. 1, 2.1, 3.1

- [9] Kawahara, J., Daneshvar, S., Argenziano, G., Hamarneh, G. (2019). Seven-point checklist and skin lesion classification using multitask multimodal neural nets. *IEEE Journal of Biomedical and Health Informatics*, 23(2), 538–546. 1, 2.1, 3.1, 4.14, 4.14, 4.14, 5.4, H.8.3, I.7.6
- [10] Codella, N. *et al.* (2019). Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the International Skin Imaging Collaboration (ISIC). *arXiv:1902.03368*. 1, 2.1, 2.6, 3.1, 3.6.4
- [11] Pacheco, A.G.C. *et al.* (2020). PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones. *Data in Brief*, 32, 106221. 1, 3.1, 4.13.3, A.4
- [12] Daneshjou, R. *et al.* (2022). Disparities in dermatology AI performance on a diverse, curated clinical image set. *Science Advances*, 8(31), eabq6147. 1, 2.1, 2.9, 3.1, 5.2.4
- [13] DermNet New Zealand Trust. DermNet NZ: The dermatology resource. <https://dermnetnz.org> 1, 3.1, 4.13.3, A.4
- [14] Groh, M. *et al.* (2021). Evaluating deep neural networks trained on clinical images in dermatology with the Fitzpatrick 17k dataset. *CVPR Workshops*. 1, 2.1, 2.8, 2.9, 3.1, 5.2.4
- [15] Daneshjou, R. *et al.* (2022). SkinCon: A skin disease dataset densely annotated by domain experts for fine-grained debugging and analysis. *NeurIPS Datasets and Benchmarks*. 1, 2.8, 3.1, 4.14, 5.4, 10, 7.3, F, F4, E5, H.3.3
- [16] Shen, Y. *et al.* (2024). SkinCAP: A multi-modal dermatology dataset annotated with rich medical captions. *arXiv preprint arXiv:2405.18004*. 2.9
- [17] Oquab, M. *et al.* (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. 2.3, 3.2, J.6
- [18] Zhang, S. *et al.* (2024). BiomedCLIP: A multimodal biomedical foundation model pretrained from fifteen million scientific image-text pairs. *NEJM AI*, 1(7). 2.4, 3.2, 7.5.1
- [19] Ravi, N. *et al.* (2024). SAM 2: Segment Anything in Images and Videos. *arXiv:2408.00714*. 1.4, 2.6, 3.2, 3.6.4, 4.7
- [20] Templeton, A. *et al.* (2024). Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet. *Anthropic Research Blog*. 1.4, 2.5, F.1
- [21] Gershenwald, J.E., Scolyer, R.A., Hess, K.R., Sondak, V.K., Long, G.V., Ross, M.I., Lazar, A.J., Faries, M.B., Kirkwood, J.M., McArthur, G.A., Haydu, L.E., Eggermont, A.M.M., Flaherty, K.T., Balch, C.M., Thompson, J.F. (2017). Melanoma staging: Evidence-based changes in the American Joint Committee on Cancer eighth edition cancer staging manual. *CA: A Cancer Journal for Clinicians*, 67(6), 472–492. DOI: 10.3322/caac.21409. 1.1

- [22] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR 2021)*. 2.2
- [23] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askeell, A., Mishkin, P., Clark, J., Krueger, G., Sutskever, I. (2021). Learning transferable visual models from natural language supervision. *Proceedings of the 38th International Conference on Machine Learning (ICML 2021)*, 8748–8763. 2.2, 2.4, 4.13.1, J.6
- [24] Zhai, X., Mustafa, B., Kolesnikov, A., Beyer, L. (2023). Sigmoid loss for language image pre-training. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, 11975–11986. 2.4, 3.2
- [25] Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A.C., Lo, W.-Y., Dollár, P., Girshick, R. (2023). Segment anything. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, 4015–4026. 2.6, 3.6.4, 4.7
- [26] Li, J., Li, D., Savarese, S., Hoi, S.C.H. (2023). BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. *Proceedings of the 40th International Conference on Machine Learning (ICML 2023)*, 19730–19742. 2.5, 3.2
- [27] Johnson, J., Douze, M., Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535–547. DOI: 10.1109/TBDATA.2019.2921572. 1.4, 2.4, 3.5, H.3.4, H.8.4, J.7
- [28] Combalia, M., Codella, N.C.F., Rotemberg, V., Helba, B., Vilaplana, V., Reiter, O., Carrera, C., Barreiro, A., Halpern, A.C., Puig, S., Malvehy, J. (2019). BCN20000: Dermoscopic lesions in the wild. arXiv:1908.02288. 1, 3.1
- [29] Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J.W., Wallach, H., Daumé III, H., Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92. DOI: 10.1145/3458723. Versión original arXiv:1803.09010 (2018). 1.4, E, E.6
- [30] Esteva, A., Kuprel, B., Novoa, R.A., Ko, J., Swetter, S.M., Blau, H.M., Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118. DOI: 10.1038/nature21056. 2.1
- [31] Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. DOI: 10.1038/sdata.2018.161. 2.1
- [32] Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W. (2022). LoRA: Low-Rank Adaptation of large language models. *International Conference on Learning Representations (ICLR 2022)*. arXiv:2106.09685. 2.6, 4.10.4, 4.12.1

- [33] DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3), 837–845. 2.8, 3.8, 4.9.1, 6.3.2
- [34] Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83. DOI: 10.2307/3001968. 3.6.4, 4.7
- [35] Guo, C., Pleiss, G., Sun, Y., Weinberger, K.Q. (2017). On calibration of modern neural networks. *Proceedings of the 34th International Conference on Machine Learning (ICML 2017)*, 1321–1330. 7.5.2, I.7.4
- [36] Tejani, A.S., Klontzas, M.E., Gatti, A.A., Mongan, J.T., Moy, L., Park, S.H., Kahn Jr., C.E. (2024). Checklist for Artificial Intelligence in Medical Imaging (CLAIM): 2024 update. *Radiology: Artificial Intelligence*, 6(4), e240300. DOI: 10.1148/ryai.240300. 2.8, 3.8
- [37] Collins, G.S., Moons, K.G.M., Dhiman, P., Riley, R.D., Beam, A.L., Van Calster, B., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378. DOI: 10.1136/bmj-2023-078378. 2.8, 3.8
- [38] Ma, J., He, Y., Li, F., Han, L., You, C., Wang, B. (2024). Segment anything in medical images. *Nature Communications*, 15, 654. DOI: 10.1038/s41467-024-44824-z. 3.6.4, 4.7
- [39] Ma, J., Yang, Z., Kim, S., Chen, B., Baharoon, M., Fallahpour, A., Asakereh, R., Lyu, H., Wang, B. (2024). MedSAM2: Segment anything in medical images and videos. arXiv:2408.03322. [Datos de venue aproximados.] 3.6.4, 4.7
- [40] Cheng, J., Ye, J., Deng, Z., Chen, J., Li, T., Wang, H., Su, Y., Huang, Z., Chen, J., Jiang, L., Sun, H., He, J., Zhang, S., Zhu, M., Qiao, Y. (2023). SAM-Med2D. arXiv:2308.16184. 3.6.4, 4.7

MAPA DE TAREAS EXPERIMENTALES Y ESTRUCTURA DEL REPOSITORIO

Este anexo documenta el conjunto de tareas experimentales reproducibles ejecutadas durante el trabajo y la estructura del repositorio asociado. La finalidad es habilitar la reproducción independiente de las cifras del capítulo 4 a partir del código publicado y de los *checkpoints* de modelo.

A.1 Estructura del repositorio

El repositorio se organiza en cinco directorios principales que encapsulan responsabilidades disjuntas. La tabla A.1 sintetiza su contenido.

Cuadro A.1: Estructura del repositorio de código del trabajo.

Directorio	Contenido
classification/	Pipeline de sondeo lineal y ajuste fino. Carga de datasets, modelos, métricas.
classification/panderm_model/	<i>Wrappers</i> de encoders fundacionales (PanDerm, DINOv2, DermLIP).
classification/panderm_model/downstream/eval_features/	Sondeo lineal, regresión logística L-BFGS, <i>bootstrap</i> .
classification/datasets/	Adaptadores por dataset, <i>splits</i> canónicos.
classification/models/	<i>Builder</i> de modelos, <i>timm wrappers</i> .
segmentation/	Pipeline de segmentación. SAM2.1 (FT del decodificador), CAE-seg, dataset ISIC2018.
ontology/	Vocabulario L1/L2/L3, mapeos por dataset, scripts de armonización.
data/	Índices locales con <i>splits</i> , embeddings precomputados.
datasets/	Datasets y dataset DermapixelAI 1.0.
results/	Reportes técnicos por experimento (formato Markdown).
output/	Salidas de evaluación: predicciones, máscaras, <i>checkpoints</i> .
tfg_figures/	Figuras del documento, generadas por scripts reproducibles.

A.2 Mapa de tareas experimentales

La tabla A.2 enumera las tareas experimentales reproducibles del trabajo, su sección de referencia en el documento y la ubicación de los *outputs* en el repositorio. Las cifras del capítulo 4 pueden reconstruirse íntegramente a partir de estos *outputs* sin reejecutar los experimentos.

Cuadro A.2: Tareas experimentales y *outputs* asociados.

Tarea	Referencia	Output principal
Sondeo lineal PanDerm Base/Large (10ds)	sección 4.2	RESULTADOS_TFG.md
Benchmark CNN vs encoders (3ds)	sección 4.3	results/CNN_BASELINE_RESULTS.md
Ajuste fino PanDerm Base (4ds)	sección 4.4	RESULTADOS_TFG.md
Eficiencia en etiquetas (HAM, PAD)	sección 4.5	RESULTADOS_TFG.md
Segmentación SAM2.1 decoder FT (ISIC2018)	sección 4.6	results/SEG_GENERALIZATION_RESULTS.md
Zero-shot DermLIP (3 prompts, 2 tok.)	sección 4.7	results/zs_concepts_results.md
LLM multimodales (12 modelos, 3ds)	sección 4.8	results/{GPT40,GEMINI,MEDGEMMA,BLIP2}_RESULTS.md
MedGemma 27B + LoRA (HAM, PAD, DDI)	sección 4.8	results/MEDGEMMA_FT_RESULTS.md
Equidad por fototipo (5 enc., 6 FST)	sección 4.9	results/FITZPATRICK_FULL_RESULTS.md
Equidad cruzada Light/Dark	sección 4.9	tfg_figures/fairness_5models/summary_5models.md
Contraste DeLong AUROC malignidad (5 enc.)	sección 4.9.1	output/fitzpatrick17k_fairness/delong_malignancy_results.json
Ensemble seguridad melanoma	sección H.8.7	output/ensemble_eval/ENSEMBLE_REPORT.md
SAE Large + CBM SkinCon	Anexo F	results/{SAE_LARGE,SKINCON_CBM}_RESULTS.md
Auditoría leakage MD5 (12ds vs Derm1M)	sección 4.1	output/leakage_audit_12ds_vs_derm1m/report.md

A.3 Comandos de ejecución

A continuación se documenta el comando de ejecución de las tareas centrales del trabajo. Todos los comandos se ejecutan desde la raíz del repositorio sobre el entorno declarado en sección 3.5 (Python 3,12,3, PyTorch 2,11,0, timm 0,9,16, CUDA 13,0).

Extracción de *embeddings* (paso previo al sondeo lineal).

```
python -m classification.panderm_model.downstream.extract_features \
    --model panderm_large \
    --dataset ham10000 \
    --output data/embeddings/ham10000_panderm_large.npz
```

Sondeo lineal sobre *embeddings* extraídos.

```
python -m classification.panderm_model.downstream.eval_features.linear_probe \
    --embeddings data/embeddings/ham10000_panderm_large.npz \
    --C 1.0 --max_iter 5000 --random_state 42
```

Ajuste fino supervisado.

```
python -m classification.run_class_finetuning \
    --model panderm_base --dataset ham10000 \
    --opt adamw --weight_decay 0.05 --lr 5e-4 \
    --warmup_epochs 10 --epochs 50 \
    --layer_decay 0.65 --drop_path 0.2 --smoothing 0.1 \
    --mixup 0.8 --cutmix 1.0 --tta 5 --seed 0
```

Segmentación SAM2.1 (fine-tuning del decodificador).

```
python -m segmentation.train_sam2_decoder \
    --dataset isic2018 --lr 1e-4 \
    --weight_decay 0.05 --epochs 50 --batch_size 4 \
    --norm uniform_05 --seed 0
```

Evaluación zero-shot multimodal.

```
python -m classification.zs_eval \
    --model dermlip_original --dataset ham10000 \
    --prompts derm1m_a3 --tokenizer gpt2_clip
```

A.4 Configuraciones de entrenamiento por experimento

Esta sección reúne las configuraciones completas de hiperparámetros de los experimentos que adaptan o entrenan parámetros, separadas del capítulo 4 para no interrumpir la lectura de los resultados. Cada tabla se referencia desde la sección correspondiente del cuerpo.

Cuadro A.3: Configuración del protocolo Dermapixel R0 (cabeza supervisada L2) sobre PanDerm Large con adaptación LoRA (sección 4.12). Los 524288 parámetros entrenables corresponden a 39 K en la cabeza FC 1024 $\rightarrow$ 38 y 485 K en los ocho módulos LoRA insertados en las capas lineales de los dos últimos bloques de transformer.

Componente	Configuración
Encoder base	PanDerm Large (1024 dim, 303,85 M params, congelado)
LoRA	$r = 16$, $\alpha = 32$, $dropout = 0,1$
Capas adaptadas	<code>blocks.22</code> y <code>blocks.23</code> : <code>attn.qkv</code> , <code>attn.proj</code> , <code>mlp.fc1</code> , <code>mlp.fc2</code> (8 capas)
Cabeza supervisada	FC 1024 $\rightarrow$ 38 (L2 con queratinización consolidada)
Parámetros entrenables	524288 (0,17% del total)
Optimizador	AdamW, $lr_{head} = 10^{-3}$, $lr_{LoRA} = 5 \times 10^{-4}$, $wd = 10^{-4}$
<i>Scheduler</i>	Cosine con <i>warmup</i> de una época
Pérdida	<i>Cross-entropy</i> con <code>class_weight=balanced</code>
<i>Batch size</i>	16
Épocas	15
Augmentaciones <i>train</i>	RandomResizedCrop(0,7–1,0), hflip, vflip ($p = 0,3$), ColorJitter (0,1)
Selección	Mejor BAcc de validación; reporte adicional de la media de las últimas cinco épocas
Semillas	{42, 43, 44}

Cuadro A.4: Configuración de las cinco iteraciones de la rama contrastiva de Dermapixel R0 entrenadas sobre DermapixelAI 1.0 (sección 4.13). Las versiones v1–v4 comparten el mismo *split* per-case (854 *train* / 107 *val* / 101 *test*) y el mismo manifiesto SHA-256. La versión v5 amplía el conjunto de entrenamiento con 15 128 imágenes externas (PAD-UFES-20 [11] y DermNet [13]) reponderadas mediante *Weighted Random Sampler* con ratio efectivo $6\times$ en favor del subconjunto castellano original, manteniendo los conjuntos de validación y test idénticos.

Versión	Image encoder	Text encoder	Train
v1	PanDerm-Large frozen	E5-base <i>full FT</i>	854 castellano
v2	PanDerm-Large frozen	E5-base + LoRA $r = 16$, $\alpha = 32$	854 castellano
v3	PanDerm-Large + LoRA $r = 16$ (últimos 4/24 bloques)	E5-base + LoRA $r = 16$, $\alpha = 32$	854 castellano
v4	PanDerm-Large + LoRA $r = 32$ (últimos 12/24 bloques)	E5-base + LoRA $r = 32$, $\alpha = 64$	854 castellano
v5	PanDerm-Large + LoRA $r = 32$ (últimos 12/24 bloques)	E5-base + LoRA $r = 32$, $\alpha = 64$	854 cast. + 15 128 ext.

Cuadro A.5: Receta de ajuste fino denso parcial sobre DermapixelAI 1.0 (sección 4.10.3): PanDerm Large con las dos últimas capas descongeladas (25,2 M parámetros, 8,3% del encoder) más cabeza *fully-connected*.

Componente	Configuración
Optimizador	AdamW, $lr_{cabeza} = 10^{-3}$, $lr_{encoder} = 10^{-5}$, $wd = 10^{-4}$
<i>Scheduler</i>	Cosine con <i>warmup</i> de una época
<i>Batch size</i>	16
Épocas	10
Pérdida	<i>Cross-entropy</i> con <code>class_weight='balanced'</code>
Augmentaciones <i>train</i>	RandomResizedCrop, hflip, vflip ($p = 0,3$), ColorJitter
Selección	Mejor BAcc de validación

A.5 Versiones de software y semillas

El entorno de ejecución se fija explícitamente. Las semillas de `torch`, `numpy` y `random` se inicializan a 0 en los protocolos de *fine-tuning* y segmentación, y el parámetro `random_state` se fija a 42 en los basados en `scikit-learn`. La variable `WANDB_MODE` se fija a `disabled` y `CUDA_VISIBLE_DEVICES` a 0. La especificación completa del entorno se documenta en el archivo `environment.yml` del repositorio.

A.6 Checkpoints publicados

La tabla A.6 enumera los *checkpoints* de modelo derivados del trabajo, con su tamaño aproximado y la métrica de referencia sobre la que se evaluaron.

Cuadro A.6: *Checkpoints* publicados del trabajo.

<i>Checkpoint</i>	Modelo base	Tamaño	Métrica de referencia
<code>panderm_base_ft_ham10000.pth</code>	PanDerm Base + TTA	~ 350 MB	Acc HAM10000 0,920
<code>panderm_large_ft_ham10000.pth</code>	PanDerm Large	1,2 GB	Acc HAM10000 0,919
<code>panderm_large_ft_padufes.pth</code>	PanDerm Large	1,2 GB	Acc PAD-UFES 0,755
<code>sam2_seg_isic2018.pth</code>	SAM2.1-L (decoder FT)	~ 17 MB	Dice 0,947
<code>sae_large_panderm.pth</code>	PanDerm Large + SAE	~ 200 MB	Esparsidad 16,5%
<code>medgemma_27b_lora_ham10000.pth</code>	MedGemma 27B + LoRA	~ 320 MB	Acc HAM10000 0,802

El acceso a los *checkpoints* se realiza mediante el repositorio de releases del proyecto, sujeto a la licencia declarada en el documento de entrega (Anexo E). La verificación de integridad se realiza por hash SHA-256 publicado junto a cada *checkpoint*.

TABLAS DETALLADAS DE RESULTADOS

Este anexo recoge desgloses y tablas adicionales a las del capítulo 4: cifras por clase de los protocolos de sondeo lineal y ajuste fino sobre HAM10000 y PAD-UFES-20, la caracterización completa por fototipo cutáneo en la formulación de 114 patologías sobre Fitzpatrick17k, y la tabla extendida de evaluación cruzada *Light* $\leftrightarrow$ *Dark*.

B.1 Desglose por clase sobre HAM10000

La tabla B.1 reporta el desglose por clase de la evaluación zero-shot con GPT-4o sobre HAM10000, ampliada respecto a la presentada en sección 4.8. La columna “Predicciones” indica el número total de imágenes asignadas a cada clase por el modelo, revelando el sesgo léxico discutido en sección 5.1.7.

Cuadro B.1: Desglose por clase del modelo GPT-4o zero-shot sobre HAM10000. *Recall*: proporción de imágenes de la clase correctamente identificadas. *Predicciones*: número de imágenes asignadas a la clase por el modelo (debe contrastarse con N_{test} para detectar sesgos sistemáticos).

Clase	N_{test}	Recall (GPT-4o)	Predicciones (GPT-4o)	Recall (GPT-4o-mini)
actinic keratosis	35	0,000	2	0,086
basal cell carcinoma	44	0,477	—	0,136
seborrheic keratosis	107	0,308	—	0,654
dermatofibroma	8	0,750	284	0,000
melanoma	70	0,686	299	0,571
melanocytic nevus	951	0,505	—	0,196
vascular lesion	17	0,529	—	0,588

La asimetría entre N_{test} y predicciones es máxima en dermatofibroma ($N_{\text{test}} = 8$, predicciones 284: factor 35,5 $\times$) y melanoma ($N_{\text{test}} = 70$, predicciones 299: factor 4,3 $\times$). El comportamiento es diagnóstico de un sesgo léxico hacia categorías con presencia elevada en el *prompt*, no hacia categorías mayoritarias en el dataset.

B.2 Desglose por clase del ajuste fino MedGemma 27B sobre HAM10000

La tabla B.2 desglosa por clase el rendimiento de MedGemma 27B con LoRA sobre el conjunto de test de HAM10000.

Cuadro B.2: Desglose por clase de MedGemma 27B con LoRA sobre HAM10000 (*precision, recall, F1*).

Clase	<i>N</i> test	Precision	Recall	F1
actinic keratosis	35	0,32	0,26	0,29
basal cell carcinoma	44	0,34	0,25	0,29
dermatofibroma	8	0,00	0,00	0,00
melanocytic nevus	951	0,85	0,99	0,92
melanoma	70	0,38	0,36	0,37
seborrheic keratosis	107	0,67	0,04	0,07
vascular lesion	17	0,00	0,00	0,00

Tras la adaptación con LoRA, el modelo concentra el rendimiento en la clase mayoritaria (nevus melanocítico: *recall* 0,99) a costa de las clases menos representadas (dermatofibroma y vascular lesion: F1 0,00). Esta concentración es coherente con la accuracy de 0,802 reportada en la tabla 4.11 pese a una BAcc de sólo 0,270.

B.3 Equidad sobre Fitzpatrick17k: formulación de 114 patologías




Figura B.1: Rendimiento por fototipo Fitzpatrick sobre la formulación de 114 patologías de Fitzpatrick17k con PanDerm Large + sondeo lineal. El rendimiento crece de FST I a FST V y desciende bruscamente en FST VI.

La figura B.1 y la tabla B.3 reportan el rendimiento por fototipo Fitzpatrick de PanDerm Large sobre la formulación de 114 patologías (grano fino del dataset), complementaria a la formulación de tres clases de malignidad presentada en la tabla 4.12.

B.4. Evaluación cruzada Light/Dark sobre 114 patologías

Cuadro B.3: Rendimiento por subgrupo Fitzpatrick sobre la formulación de 114 patologías de Fitzpatrick17k (PanDerm Large + sondeo lineal).

Fototipo (FST)	<i>N</i> test	Acc	BAcc	W-F1	AUROC
I	299	0,515	0,522	0,509	—
II	470	0,519	0,524	0,513	—
III	325	0,640	0,590	0,636	—
IV	261	0,670	0,602	0,654	—
V	169	0,692	0,614	0,680	—
VI	73	0,479	0,474	0,462	—
<i>Global</i>		0,581	0,549	0,576	0,968

La distribución es notablemente distinta a la formulación de tres clases de malignidad: el rendimiento crece desde FST I a FST V y cae bruscamente en FST VI. El *gap* entre FST V (mejor) y FST VI (peor) es de 0,213 pp accuracy. La interpretación sugiere que el grano fino de 114 patologías expone una capa de información clínica donde la representación visual de las lesiones sobre fototipos intermedios y altos (III, IV, V) supera a la de fototipos extremos (I, II y VI), mientras que la formulación gruesa de tres clases de malignidad refleja el patrón general peor-en-fototipos-elevados.

B.4 Evaluación cruzada Light/Dark sobre 114 patologías

La tabla B.4 reporta el experimento cruzado de entrenamiento/evaluación entre subgrupos *Light* (FST I-III) y *Dark* (FST IV-VI) sobre la formulación de 114 patologías de Fitzpatrick17k con PanDerm Large. *All* agrupa el conjunto de entrenamiento completo. Las celdas de número de clases en evaluación reflejan que algunas patologías no aparecen en la partición *Dark*, lo que reduce el número efectivo de clases sobre las que se evalúa.

Cuadro B.4: Evaluación cruzada *Light* ↔ *Dark* sobre 114 patologías de Fitzpatrick17k (PanDerm Large + sondeo lineal). *C*: número de clases efectivas en la evaluación.

Configuración	<i>N</i> train	<i>N</i> test	<i>C</i>	Acc	BAcc	AUROC
Light → Light	8845	1094	114	0,541	0,528	0,962
Light → Dark	8028	503	100	0,473	0,453	0,944
Dark → Dark	3807	503	100	0,616	0,519	0,948
Dark → Light	3958	1094	114	0,351	0,325	0,906
All → Light	12803	1094	114	0,559	0,547	0,965
All → Dark	11835	503	100	0,658	0,614	0,970

La asimetría más notable se observa en *Dark* → *Light* (BAcc 0,325, AUROC 0,906), configuración con menor volumen de entrenamiento (3958 imágenes) sobre un conjunto de evaluación mayor (1094 imágenes) y con 114 clases efectivas. La accuracy desciende desde 0,616 en *Dark* → *Dark* a 0,351 en *Dark* → *Light*, lo que cuantifica la pérdida sistemática asociada al cambio de distribución de fototipo a la inversa de la dirección habitual reportada en la literatura.

B.5 Resumen comparativo por paradigma sobre HAM10000

La tabla B.5 amplía la tabla 4.11 del cuerpo con los costes de entrenamiento e inferencia agregados por paradigma sobre HAM10000.

B. TABLAS DETALLADAS DE RESULTADOS

Cuadro B.5: Comparativa por paradigma sobre HAM10000. Datos etiquetados: tamaño del conjunto de entrenamiento empleado. Coste indicativo en EUR para los modelos de acceso comercial (cifras 2026); 0 EUR para los modelos locales.

Paradigma	Modelo	Datos etiq.	Acc	AUROC	Coste eval.
ZS (<i>prompts</i> genéricos)	DermLIP v1/v2	0	0,086	0,366	0
ZS (<i>prompts</i> A3 Derm1M)	DermLIP original	0	0,427	0,854	0
ZS LLM multimodal	GPT-4o	0	0,485	—	~\$2,71
ZS LLM multimodal	MedGemma 27B	0	0,665	—	0
LP (1 % entrenam.)	PanDerm Large	82	0,850	0,918	0
LP (100 % entrenam.)	PanDerm Base	8207	0,853	0,892	0
LP (100 % entrenam.)	PanDerm Large	8207	0,888	0,954	0
LP (100 % entrenam.)	SigLIP-Large	8207	0,900	0,971	0
FT LoRA LLM	MedGemma 27B + LoRA	8207	0,802	—	0
FT (receta paper) + TTA	PanDerm Base	8207	0,920	0,978	0

Las figuras B.2, B.3 y B.4 caracterizan el dataset armonizado de 72654 imágenes empleado en el clasificador unificado: el compromiso entre número de clases y *accuracy*, la distribución de imágenes por categoría L1 y la *accuracy* por clase L2, respectivamente.




Figura B.2: Compromiso entre número de clases y *accuracy* sobre el dataset armonizado. La *accuracy* decrece conforme aumenta el número de categorías; el nivel L2 (43 clases) constituye el punto operativo más equilibrado entre granularidad clínica y rendimiento agregado.

Distribucion por categoria (Ontologia Dra. Taberner)




Figura B.3: Distribución de imágenes por categoría L1 sobre el dataset armonizado de 72654 imágenes. Predominio de patología tumoral y patología inflamatoria; patología infecciosa y genodermatosis representan la cola larga.

B. TABLAS DETALLADAS DE RESULTADOS




Figura B.4: Accuracy por clase L2 (43 entradas) sobre el clasificador unificado del dataset armonizado. Las clases con mayor accuracy corresponden a categorías con más representación en el conjunto de entrenamiento, mientras que la cola larga presenta variabilidad asociada al tamaño muestral.

B.6 Composición del conjunto de entrenamiento del SAE Large

El SAE Large utilizado en el módulo M3 del prototipo y descrito en detalle en el Anexo F se entrena sobre la concatenación de siete datasets dermatológicos. La tabla B.6 reporta la composición exacta.

B.7. Segmentación: generalización fuera de dominio (Dice e IoU)

Cuadro B.6: Composición del conjunto de entrenamiento del Sparse Autoencoder Large ($1024 \rightarrow 16384$ features).

Dataset	Imágenes
HAM10000	10015
BCN20000	12413
Dermnet	19559
PAD-UFES-20	2298
Fitzpatrick17k	3887
DDI	647
HIBA	1635
Total	50454

B.7 Segmentación: generalización fuera de dominio (Dice e IoU)

La tabla B.7 amplía el resultado de segmentación de la sección 4.6 con la desviación estándar y el IoU sobre los dos datasets de transferencia (ISIC2017 y PH2).

Cuadro B.7: Generalización fuera de dominio: Dice e IoU (media $\pm$ desv. estándar) sobre ISIC2017 ($N = 600$) y PH2 ($N = 200$).

Modelo	Dataset	Dice	IoU
SAM2 <i>zero-shot</i> (bbox)	ISIC2017	$0,797 \pm 0,158$	$0,686 \pm 0,183$
SAM2 <i>zero-shot</i> (bbox)	PH2	$0,886 \pm 0,199$	$0,830 \pm 0,198$
SAM2.1-L (decoder FT) ISIC2018	ISIC2017	$0,945 \pm 0,046$	$0,898 \pm 0,065$
SAM2.1-L (decoder FT) ISIC2018	PH2	$0,960 \pm 0,022$	$0,925 \pm 0,039$
CAE-seg (PanDerm-L) FT ISIC2018	ISIC2017	$0,879 \pm 0,139$	$0,803 \pm 0,166$
CAE-seg (PanDerm-L) FT ISIC2018	PH2	$0,924 \pm 0,066$	$0,865 \pm 0,098$

B.8 Equidad por fototipo: tablas complementarias

Tablas de apoyo a la sección 4.9: el rendimiento global de los cinco encoders sobre Fitzpatrick17k (tabla B.8) y la matriz completa de la evaluación cruzada *Light* $\leftrightarrow$ *Dark* (tabla B.9).

Cuadro B.8: Equidad sobre Fitzpatrick17k completo. Rendimiento global en las dos formulaciones. Mejor valor por columna en negrita.

Modelo	114 patologías				3 clases malignidad			
	Acc	BAcc	AUROC	W-F1	Acc	BAcc	AUROC	W-F1
PanDerm Large	0,581	0,549	0,968	0,576	0,835	0,699	0,908	0,828
PanDerm Base	0,500	0,478	0,955	0,491	0,819	0,657	0,882	0,807
DermLIP v2 (visual)	0,572	0,549	0,971	0,569	0,852	0,721	0,909	0,846
DINOv2 ViT-L/14	0,519	0,485	0,947	0,516	0,809	0,656	0,854	0,801
BiomedCLIP	0,334	0,321	0,910	0,323	0,799	0,590	0,830	0,776

B. TABLAS DETALLADAS DE RESULTADOS

Cuadro B.9: Evaluación cruzada *Light* $\leftrightarrow$ *Dark* (BAcc, formulación de 3 clases). *L*: *Light*; *D*: *Dark*; *All*: ambos grupos.

Modelo	L→L	L→D	D→D	D→L	All→L	All→D
PanDerm Large	0,699	0,589	0,701	0,667	0,726	0,627
PanDerm Base	0,673	0,557	0,621	0,629	0,673	0,594
DermLIP v2 (visual)	0,729	0,651	0,667	0,683	0,745	0,682
DINOv2 ViT-L/14	0,655	0,523	0,625	0,569	0,682	0,589
BiomedCLIP	0,595	0,532	0,571	0,551	0,594	0,565

Cuadro B.10: Test de DeLong pareado entre encoders sobre la AUROC binaria de malignidad (*maligno* frente al resto, test de Fitzpatrick17k): *p*-valor a dos colas. Valores no significativos al nivel nominal 0,05 en cursiva. *Provenance*: `delong_malignancy_results.json` del repositorio de investigación.

	DermLIP v2	PanDerm Base	DINOv2	BiomedCLIP
PanDerm Large	0,55	$1,2 \times 10^{-3}$	$4,2 \times 10^{-5}$	$8,7 \times 10^{-9}$
DermLIP v2	—	$7,3 \times 10^{-3}$	$2,4 \times 10^{-3}$	$6,0 \times 10^{-7}$
PanDerm Base	—	—	0,12	$1,2 \times 10^{-4}$
DINOv2	—	—	—	0,066

PIPELINE DE CONSTRUCCIÓN Y CARACTERIZACIÓN DEL DATASET DERMAPIXELAI 1.0

Este anexo documenta el pipeline de construcción y la caracterización cuantitativa completa del dataset DermapixelAI 1.0, descrito de forma resumida en la sección 3.1 del capítulo 3. El dataset se desarrolla en paralelo al trabajo experimental del TFG, en el marco de la modernización tecnológica del archivo Dermapixel introducida en el capítulo 1, y se publica como contribución independiente del trabajo a la comunidad investigadora.

C.1 Origen y materia prima

El dataset DermapixelAI se construye a partir del archivo del blog Dermapixel. La materia prima es el conjunto de casos publicados durante más de quince años por la Dra. R. Taberner, cada uno acompañado de imágenes (fotografía clínica y, cuando procede, imagen dermatoscópica), historia clínica abreviada en castellano y diagnóstico final con razonamiento.

C.2 Pipeline de construcción

La construcción del dataset se desarrolla como un proceso iterativo, ajustado en sucesivas revisiones internas en función de las auditorías de integridad realizadas sobre el dataset, hasta consolidar la versión 1.0 documentada en este anexo como primera versión estable y publicable. El pipeline final se compone de seis pasos.

(i) Extracción. Recogida de las publicaciones del blog y de los metadatos asociados por caso (título, fecha, texto narrativo, imágenes, diagnóstico final). El proceso se ejecuta con scripts deterministas a partir de la fuente HTML del blog.

(ii) Deduplicación. Cálculo de hash MD5 sobre cada imagen y eliminación de duplicados exactos. Identificación de imágenes asociadas a la pista de solución de los casos del blog —imágenes que aparecen sólo en la entrada del solucionario y que llevan información asociada al diagnóstico final, susceptibles de inducir *leakage* si se incluyen— y su exclusión documentada.

(iii) Clasificación de modalidad. Asignación a cada imagen de su modalidad (*clinical*, *dermoscopy*, *histology*, *ultrasound* o *wood_lamp*) mediante una combinación de heurísticas sobre el nombre del fichero y revisión manual de los casos no resueltos automáticamente con confianza suficiente. El paso incluye una auditoría sistemática sobre la totalidad del dataset para detectar y corregir asignaciones erróneas, así como la exclusión de imágenes que tras la revisión visual resultan no ser contenido dermatológico (banners institucionales, ilustraciones, fotografías de eventos o material de archivo que pudiera haber entrado al dataset por el scraping inicial); estas últimas se trasladan a una carpeta `images/_excluded/` y se eliminan del fichero maestro `dataset.csv`, manteniéndose en `cases.csv` con `num_images_in_dataset = 0` cuando el caso resulta sin imágenes tras la exclusión.

(iv) Mapeo ontológico. Cada caso publicado contiene una etiqueta diagnóstica generada por revisión textual del título y del razonamiento. Esta etiqueta cruda se mapea, mediante revisión experta de la Dra. Taberner sobre la totalidad del dataset, a una entrada L3 de la ontología jerárquica descrita en la sección 3.2 del capítulo 3. La revisión genera tres campos asociados a cada imagen: `label_source` (origen de la etiqueta diagnóstica final), `diagnosis_source` (origen del razonamiento textual asociado al diagnóstico) y `rosa_verified` (validación visual de la imagen como caso representativo del diagnóstico asignado).

(v) Particionado. Asignación de cada imagen a uno de los tres splits (`train`, `val`, `test`) bajo regla de agrupamiento por caso (*case-aware split*): todas las imágenes de un mismo caso clínico van al mismo split, lo que previene la fuga de información entre conjuntos.

(vi) Auditoría de integridad. Verificación final de hashes MD5, ausencia de imágenes corruptas, consistencia entre la estructura de carpetas y `dataset.csv`, y ausencia de referencias a imágenes inexistentes en disco. Todas las modificaciones intermedias del dataset se acompañan de *backup* y registro de auditoría (`audit_log.txt` y `excluded_images.csv`) para preservar trazabilidad histórica.

La versión 1.0 del dataset, consolidada como resultado de este pipeline, contiene 1 089 imágenes vinculadas a 669 casos clínicos con identificador único resoluble, sobre un total de 698 casos catalogados en el archivo original (de los cuales 672 disponen de imagen efectiva antes de la deduplicación MD5; los tres casos restantes se pierden por duplicado exacto de imagen entre entradas distintas del blog).

C.3 Cardinalidades del dataset y splits experimentales

A lo largo del trabajo coexisten tres particiones distintas del dataset, todas derivadas del mismo pipeline pero filtradas con criterios específicos según el experimento. La tabla C.1 resume las cardinalidades para evitar confusión entre referencias cruzadas.

Cuadro C.1: Cardinalidades del dataset DermapixelAI 1.0 según configuración. Los splits son *case-aware* (ningún caso se reparte entre splits). El test del estudio principal sobre el dataset de producción es deliberadamente reducido para reservar masa de validación interna a la futura cohorte prospectiva del HUSLL (Sección 7.5.7).

Configuración	Imágenes	Casos	Train	Val/Test	Uso
Producción (<code>dataset.csv</code>)	1 089	669	891	157 / 41	Estudio principal del Capítulo 4
Filtrada (<code>dataset_filtered.csv</code>)	1 062	653	874	152 / 36	Restricción a <i>clinical+dermoscopy</i> con <code>label_source=ontology</code>
Dermapixel R0 con- trastivo (Sec. 4.13)	1 062	653	854	107 / 101	Experimento dual-encoder con <i>manifest</i> SHA-256 propio

Las tres configuraciones comparten el archivo subyacente y la regla de partición *case-aware*, pero aplican filtros y *seeds* distintos. La cifra base 1 089 es el resultado del pipeline completo; el subconjunto

filtrado de 1 062 excluye 27 imágenes que pierden trazabilidad ontológica tras la auditoría de mapeo; y los splits de la rama contrastiva de Dermapixel R0 de 854/107/101 son reproducibles a partir del *manifest* SHA-256 pinned en cada checkpoint del experimento (Sección 4.13).

C.4 Distribución por modalidad

La tabla C.2 resume la composición del dataset por modalidad.

Cuadro C.2: Distribución del dataset DermapixelAI 1.0 por modalidad de imagen.

Modalidad	N
clinical	1 036
dermoscopy	49
histology	2
ultrasound	1
wood_lamp	1
Total en dataset.csv	1 089

La fotografía clínica predomina con claridad sobre el resto de modalidades. El subconjunto dermatoscópico, con 49 imágenes, constituye un grupo reducido pero suficiente para análisis exploratorios específicos sobre esa modalidad.

C.5 Distribución por categoría etiológica L1

La distribución por L1 (tabla C.3) muestra el predominio de la patología inflamatoria, seguida por las patologías tumoral e infecciosa con pesos similares y un porcentaje residual de genodermatosis.

Cuadro C.3: Distribución del dataset DermapixelAI 1.0 por categoría etiológica L1. La fila “(sin asignar)” recoge las 19 imágenes cuyo mapeo ontológico no se ha completado (todas ellas corresponden a casos con `label_source = raw`).

Categoría L1	N	%
Patología inflamatoria	544	49,9
Patología tumoral	276	25,3
Patología infecciosa	259	23,8
Genodermatosis	11	1,0
(sin asignar)	19	—
Total	1 089	100,0

C.6 Distribución por subcategoría L2 y por diagnóstico L3

La figura C.1 ilustra la distribución L1 etiológica sobre el subconjunto filtrado (clinical + dermoscopy, con `label_source = ontology` y L1 asignada), utilizado en la caracterización del dataset efectivo. Patología inflamatoria concentra la mitad del dataset, mientras que Genodermatosis ocupa la cola corta con sólo 8 imágenes (0,8%), lo que explica su ausencia en el split de `test`.

C. PIPELINE DE CONSTRUCCIÓN Y CARACTERIZACIÓN DEL DATASET DERMAPIXELAI 1.0




Figura C.1: Distribución L1 etiológica sobre las 1062 imágenes filtradas. Patología inflamatoria concentra el 50,1%; Genodermatosis es la cola corta con 8 imágenes (0,8%).

De las 43 entradas L2 del vocabulario, 38 aparecen representadas en el dataset DermapixelAI 1.0 con al menos una imagen. La cifra observada en la extracción inicial es 39, pero dos de esas 39 corresponden a variantes ortográficas de la misma subcategoría (*Trastornos de la queratinización* y *Trastornos queratinización*); la normalización pendiente reduce la cifra efectiva a 38. La figura C.2 muestra las veinte subcategorías L2 más representadas.




Figura C.2: Top-20 subcategorías L2 sobre las 38 efectivamente representadas en el dataset, ordenadas por número de imágenes.

A nivel L3, 250 entradas del vocabulario están representadas en el dataset, sobre las 367 entradas declaradas (cobertura efectiva del 68,1 %). El diagnóstico L3 más frecuente en el dataset es *Psoriasis en placas* (38 imágenes), seguido por *Tiña corporis* (32), *Liquen plano* (28) y *Nevo melanocítico adquirido* (25). Los veinte L3 más representados concentran aproximadamente el 32 % del dataset.

La tabla C.4 recoge los diez diagnósticos L3 con mayor número de imágenes en el dataset. Estos diez diagnósticos concentran 234 imágenes, equivalentes al 22,0 % del dataset filtrado.

Cuadro C.4: Top-10 diagnósticos L3 más frecuentes en el dataset DermapixelAI 1.0.

Diagnóstico L3	N
Psoriasis en placas	38
Tiña corporis	32
Liquen plano	28
Nevo melanocítico adquirido	25
Carcinoma basocelular	23
Queratosis actínica	21
Dermatitis alérgica de contacto	21
Acné	16
Dermatofibroma	16
Melanoma	14
Total top-10	234

C.7 Cola larga diagnóstica

La distribución por L3 presenta una cola larga pronunciada (figura C.4). La tabla C.5 cuantifica el reparto de las 250 clases L3 efectivamente representadas en el dataset según el número de imágenes asociadas a cada clase.

Cuadro C.5: Cola larga L3 sobre las 250 clases efectivas del dataset DermapixelAI 1.0.

Rango imgs/clase	Nº clases L3	% del total
1 img	64	25,6
2–5 imgs	129	51,6
6–10 imgs	39	15,6
11–20 imgs	11	4,4
21+ imgs	7	2,8
Total	250	100,0

El 77,2 % de las 250 clases L3 efectivamente representadas dispone de cinco imágenes o menos, y un cuarto del total (25,6 %) cuenta con una única imagen (figura C.3). Esta característica condiciona la viabilidad de un clasificador con cabeza directa a 250 clases L3 y justifica la estrategia operativa de cabeza L2 con ranking L3 por prototipos descrita en la sección 7.5 del capítulo 7.




Figura C.3: Distribución de las 250 clases L3 efectivas en los cinco rangos definidos en la tabla C.5. Las clases con cinco imágenes o menos suman el 77,2 % del total.




Figura C.4: Distribución rankeada del número de imágenes por clase L3 (eje vertical en escala logarítmica). El perfil decae rápidamente tras los diez diagnósticos más frecuentes, lo que evidencia la asimetría de la cola larga diagnóstica.

C.8 Particionado en train, validación y test

El dataset asigna sus splits bajo regla *case-aware*: cada caso clínico, identificado por `case_id`, está íntegro en un único split. La figura C.6 resume cuántas imágenes aporta cada caso (media 1,63, mediana 2, máximo 5).

Cuadro C.6: Tamaño de los splits oficiales del dataset DermapixelAI 1.0 con regla case-aware (cada caso clínico íntegro en un único split).

Split	N
train	891
val	157
test	41
Total	1 089

La regla *case-aware* se mantiene íntegra: ningún *case_id* aparece en más de un split. La verificación explícita figura en el reporte de auditoría asociado al dataset.

La composición L1 dentro de cada split no es perfectamente estratificada. En particular, Genodermatosis carece de representación en test (las once imágenes de esta categoría se reparten entre train y val), y once entradas L2 carecen de imágenes en val, mientras que veintidós L2 carecen de imágenes en test. Estos huecos limitan la granularidad de la evaluación por L2 o por L1 sobre los splits oficiales (figura C.5).




Figura C.5: Balance L1 por split (train, val, test) sobre el subconjunto filtrado. Genodermatosis no aparece en test.

La tabla C.7 desagrega el número de imágenes, casos y entradas ontológicas únicas por nivel observadas en cada split sobre el subconjunto filtrado utilizado para la evaluación (clinical + dermoscopy con *label_source* = *ontology* y L1 asignada). Las cifras sobre el dataset completo (1 089 imágenes) son las de la tabla C.6.

Cuadro C.7: Cobertura ontológica por split sobre el subconjunto filtrado (1 062 imágenes). N° de entradas únicas observadas en cada nivel.

Split	Imágenes	Casos	L1	L2	L3
train	874	527	4	38	224
val	152	98	3	28	72
test	36	28	3	17	27

El tamaño del split test (36 imágenes, 28 casos, 17 L2 únicas, 27 L3 únicas) constituye una limitación intrínseca para la evaluación a niveles ontológicos profundos sobre los splits oficiales del dataset.




Figura C.6: Histograma del número de imágenes por caso clínico. La mayor parte de los casos aportan una o dos imágenes (media 1,63, mediana 2, máximo 5).

C.9 Texto narrativo asociado al caso

Cada caso lleva asociado un campo de texto narrativo en castellano (`case_text`) que reproduce, abreviada, la historia clínica publicada en el blog: motivo de consulta, antecedentes, evolución temporal y, en ocasiones, el razonamiento diagnóstico inicial. La longitud mediana del texto es de 223 palabras por caso, con cuartiles primero y tercero en 175 y 271 palabras respectivamente. La extensión es relativamente homogénea en el dataset.

Un subconjunto reducido de casos contiene en el texto narrativo la palabra “diagnóstico” o “diagnosticar” en construcciones que podrían anticipar el resultado diagnóstico final: 32 casos (4,6% del dataset). Este número es bajo en términos relativos pero suficiente para justificar la exclusión de estos casos en escenarios de evaluación zero-shot textual donde el modelo recibe el `case_text` como entrada.

C.10 Validación experta y campos de calidad

El dataset DermalPixelAI 1.0 incorpora tres campos de validación experta cuya distinción es relevante para la interpretación de las cifras:

label_source = ontology (97,89% del dataset): la etiqueta diagnóstica L3 final está mapeada a la ontología jerárquica validada con revisión experta.

diagnosis_source = expert_v3 (98,38% del dataset): el razonamiento textual asociado al diagnóstico está respaldado por la tercera revisión experta de la Dra. Taberner sobre el dataset.

rosa_verified = True (84,39% del dataset): *flag* operativo que indica que la imagen ha pasado por revisión visual explícita por la Dra. Taberner como ejemplo representativo del diagnóstico asignado.

Las tres cifras no son intercambiables y conviene declararlas con precisión en cualquier comunicación derivada del trabajo. En particular, la cifra que el TFG defendido y los reportes técnicos asocian a “validación experta del dataset” es la primera (97,89%), no la tercera. La figura C.7 representa visualmente la composición de los tres campos.




Figura C.7: Distribución conjunta de los tres campos de calidad del dataset DermapixelAI 1.0: `label_source`, `rosa_verified` y `diagnosis_source`. La fracción con etiqueta L3 mapeada en la ontología (97,89 %) y la fracción con razonamiento textual respaldado (98,38 %) superan a la fracción operativa con revisión visual explícita (84,39 %).

C.11 Caracterización temporal y de exclusiones

C.11.1 Distribución temporal

Las imágenes del dataset DermapixelAI 1.0 se distribuyen en un rango temporal que abarca desde 2011 hasta 2026, en correspondencia con los más de quince años de publicación continuada del blog Dermapixel. La figura C.8 muestra la distribución anual de imágenes incorporadas al dataset. El año de mayor aportación es 2017 con 87 imágenes; el perfil agregado sugiere una agrupación natural por décadas (2011–2019 y 2020–2026) que puede emplearse como estratificación temporal en evaluaciones de robustez frente a cambios de equipamiento fotográfico o de criterio clínico.




Figura C.8: Distribución anual del número de imágenes incorporadas al dataset DermapixelAI 1.0. Rango 2011–2026; año pico 2017 con 87 imágenes.

C.11.2 Razones de exclusión

El pipeline de construcción descartó 80 imágenes del candidato original. La tabla C.8 desagrega las razones documentadas en `excluded_images.csv`.

C. PIPELINE DE CONSTRUCCIÓN Y CARACTERIZACIÓN DEL DATASET DERMAPIXELAI 1.0

Cuadro C.8: Razones de exclusión documentadas durante la construcción del dataset DermapixelAI 1.0.

Razón	N
not_found	35
not_derm_user_confirmed	19
md5_matches_solution	10
dermoscopy_pending	9
dedup_same_md5	6
not_derm_visual_review	1
Total	80

La razón más frecuente es `not_found` (35 imágenes, correspondientes a páginas del blog no recuperables en la fase de extracción). Le siguen `not_derm_user_confirmed` (19, imagen no dermatológica confirmada manualmente), `md5_matches_solution` (10, fuga directa con el panel de solución del blog, susceptible de inducir *leakage* diagnóstico), `dermoscopy_pending` (9, calidad dermatoscópica pendiente de validación experta), `dedup_same_md5` (6, duplicados exactos) y `not_derm_visual_review` (1, exclusión por revisión visual posterior). El registro íntegro de exclusiones permite la reproducción exacta del filtrado y la auditoría de integridad descrita en el paso (vi) del pipeline.

DECLARACIÓN SOBRE EL USO DE HERRAMIENTAS DE INTELIGENCIA ARTIFICIAL

Este anexo documenta el uso de herramientas de inteligencia artificial durante la elaboración del presente Trabajo de Fin de Grado, en cumplimiento de las directrices institucionales de la Universitat de les Illes Balears sobre transparencia académica en el uso de tecnologías generativas.

D.1 Alcance de la declaración

La declaración cubre la totalidad del periodo de redacción y desarrollo del presente trabajo (curso académico 2025-2026). Se distinguen tres ámbitos de uso, cuya descripción detallada se desarrolla en las secciones siguientes: uso académico (redacción del documento), uso técnico (desarrollo del código y de los experimentos) y uso documental (organización de notas y trazabilidad).

D.2 Herramientas empleadas

La tabla D.1 enumera las herramientas de inteligencia artificial empleadas durante el desarrollo del trabajo, su modalidad de uso y el ámbito al que se aplican.

Cuadro D.1: Herramientas de IA empleadas durante la elaboración del TFG.

Herramienta	Proveedor	Modalidad	Ámbito
Claude (Sonnet, Opus)	Anthropic	Asistente conversacional	Redacción, código, organización
GPT-4o, GPT-4o-mini	OpenAI	API programática	Evaluación experimental (objeto del trabajo)
GPT-5 (familia)	OpenAI	API programática	Razonamiento clínico del prototipo
Gemini 2.5 Pro/Flash	Google	API programática	Evaluación experimental (objeto del trabajo)
MedGemma 4B y 27B	Google	Modelos locales	Evaluación + razonamiento del prototipo
GitHub Copilot	GitHub	Asistencia en IDE	Sugerencias de código

D.3 Uso académico: redacción del documento

Las herramientas conversacionales (Claude Sonnet y Opus) se han utilizado durante la redacción del presente documento en cuatro modalidades: (i) revisión estilística y de coherencia narrativa sobre el texto

producido por el autor; (ii) reformulación de párrafos con tono no académico hacia un tono paper estricto, conforme a las indicaciones explícitas del director del trabajo; (iii) verificación cruzada entre afirmaciones cuantitativas del texto y los reportes técnicos en el repositorio (auditoría descrita en sección D.7); (iv) asistencia en la generación de tablas LaTeX a partir de datos preexistentes en formato Markdown.

En ningún caso se ha utilizado la herramienta para generar contenido original sobre los resultados experimentales, la interpretación de los hallazgos o la formulación de las conclusiones. Las cifras reportadas en el capítulo 4 y discutidas en el capítulo 5 provienen exclusivamente de los experimentos ejecutados por el autor, documentados en los reportes técnicos del repositorio (sección A.2) y verificables de forma independiente.

D.4 Uso técnico: desarrollo del código

Las herramientas de asistencia en IDE (GitHub Copilot) se han utilizado durante el desarrollo del código en dos modalidades: (i) autocompletado de sentencias rutinarias (carga de datasets, formateo de salidas, configuración de *loggers*); (ii) generación inicial de plantillas de *tests* unitarios y de *wrappers* de modelos a partir de la documentación oficial de las bibliotecas empleadas.

El código de los protocolos experimentales centrales (sondeo lineal, ajuste fino, segmentación, evaluación zero-shot, auditoría de leakage) ha sido desarrollado por el autor con referencia explícita a la implementación original publicada por los autores de PanDerm [1] y de DermLIP [2]. La revisión de la corrección de los algoritmos y la validación de los resultados se ha realizado por el autor mediante reproducción cruzada de cifras de referencia (p. ej. ajustar los hiperparámetros hasta reproducir el rango de AUROC reportado por los autores sobre los datasets compartidos).

D.5 Uso documental: organización y trazabilidad

Las herramientas conversacionales se han utilizado adicionalmente para tareas de organización documental que no afectan al contenido del trabajo: redacción de notas internas, estructuración del índice del repositorio, formateo de documentación auxiliar (no incluida en el documento final) y generación de informes de estado del proyecto durante el desarrollo.

D.6 Modelos como objeto de evaluación

GPT-4o, GPT-4o-mini, Gemini 2.5 Pro, Gemini 2.5 Flash, MedGemma 4B Vision y MedGemma 27B Text constituyen *objetos de evaluación* del presente trabajo (capítulo 4, sección 4.8), no herramientas auxiliares de redacción. Su uso se documenta en los protocolos experimentales correspondientes (sección 3.6.6). La declaración del presente anexo se refiere exclusivamente al uso de inteligencia artificial como *instrumento de apoyo* a la elaboración del documento, no como objeto experimental.

D.7 Verificación cruzada de cifras y citas

Durante la fase final de redacción se ha aplicado un protocolo sistemático de verificación cruzada entre las afirmaciones cuantitativas del texto y los reportes técnicos del repositorio. El procedimiento, descrito en el documento interno PRECAUCIONES_ANEXOS.md, consiste en: (i) identificación de cada cifra cuantitativa del documento; (ii) localización de la fuente verificable (RESULTADOS_TFG.md, archivos en results/ o output/); (iii) clasificación del estado en cuatro categorías: OK (cifra verificada), PARCIAL (existe el mecanismo pero falta la ejecución reportada), FALTA (sin evidencia) y CONTRADICCIÓN (divergencia entre texto y fuente). Las inconsistencias detectadas se han corregido antes del depósito o documentado explícitamente como [NO ESPECIFICADO] cuando la cifra exacta requería ejecución pendiente.

D.8 Responsabilidad sobre el contenido

La autoría intelectual del trabajo, la formulación de la pregunta de investigación, el diseño experimental, la ejecución de los experimentos, la interpretación de los resultados, la redacción final del documento y la responsabilidad sobre las afirmaciones contenidas corresponden íntegramente al autor del presente Trabajo de Fin de Grado, bajo la supervisión académica del director Dr. Javier Varona Gómez y con la colaboración clínica de la Dra. Rosa Taberner Ferrer. Las herramientas de inteligencia artificial empleadas constituyen instrumentos de apoyo cuya contribución se enmarca en los términos descritos en este anexo.

DOCUMENTO DE ENTREGA DEL DATASET DERMAPIXELAI 1.0

Este anexo recoge el documento de entrega formal del dataset DermapixelAI 1.0, complementario al anexo C que documenta su pipeline interno de construcción. El presente anexo sigue el formato *Datasheet for Datasets* propuesto por [29] y reúne la información necesaria para la reutilización académica del dataset.

E.1 Identidad del dataset

- **Nombre:** DermapixelAI.
- **Versión:** 1.0 (primera versión estable y publicable).
- **Fecha de cierre de la versión 1.0:** mayo de 2026.
- **Identificador persistente (DOI):** pendiente de asignación en el momento de la publicación efectiva del dataset. El depósito formal se realiza en **Zenodo** (<https://zenodo.org>) bajo licencia CC BY-NC-SA 4.0 con DOI permanente y citable, complementado con el repositorio de la Universitat de les Illes Balears cuando éste habilite el alojamiento de datasets binarios de tamaño equivalente.
- **Cita corta:** *Taberner, R. y Contestí Coll, A. (2026). DermapixelAI 1.0: dataset dermatológico clínico en castellano. Versión 1.0.*

E.2 Procedencia y autoría

El dataset DermapixelAI 1.0 se construye a partir del archivo del blog Dermapixel (<https://dermapixel.com>), mantenido desde hace más de quince años por la Dra. R. Taberner, dermatóloga clínica del Hospital Universitario Son Llàtzer. El archivo original recoge casos clínicos comentados con fines docentes y representa la materia prima a partir de la cual se ha estructurado el dataset documentado en este anexo.

La construcción del dataset, el pipeline de extracción y estructuración, la definición de la ontología jerárquica L1/L2/L3 y el particionado han sido desarrollados por Antonio Contestí Coll en el marco del presente Trabajo de Fin de Grado y del trabajo paralelo de modernización tecnológica del archivo Dermapixel descrito en el capítulo 1. El uso del archivo Dermapixel como materia prima del dataset se ha realizado bajo acuerdo previo con la Dra. R. Taberner, formalizado por escrito en el marco de la colaboración entre ambos sobre la modernización del archivo y sobre el proyecto institucional de tele dermatología del IB-Salut. La revisión experta de las etiquetas diagnósticas, del mapeo a la ontología jerárquica y de los campos

E. DOCUMENTO DE ENTREGA DEL DATASET DERMAPIXELAI 1.0

de validación asociados (`label_source`, `diagnosis_source`, `rosa_verified`) ha sido aportada por la Dra. Taberner.

En consecuencia, el dataset se publica con autoría compartida Taberner & Contestí Coll, en este orden, dado que el archivo Dermapixel del que deriva el dataset es propiedad intelectual de la Dra. Taberner y constituye el material original sin el cual el dataset no existiría. La cita recomendada (sección E.4) refleja esta autoría conjunta en el mismo orden.

E.3 Licencia de uso

DermapixelAI 1.0 se publica bajo la licencia **Creative Commons Reconocimiento–NoComercial–CompartirIgual 4.0 Internacional (CC BY-NC-SA 4.0)**. Texto canónico de la licencia: <https://creativecommons.org/licenses/by-nc-sa/4.0/deed.es>.

Esta licencia implica, en lo que respecta al uso del dataset:

- **Reconocimiento (BY)**. Cualquier uso del dataset o de obras derivadas exige la cita explícita del dataset original en la forma indicada en la sección E.4.
- **No comercial (NC)**. El dataset no puede emplearse con fines primordialmente comerciales. La investigación académica, el uso docente y el desarrollo de prototipos en fase no comercial quedan dentro del alcance de la licencia.
- **Compartir Igual (SA)**. Cualquier obra derivada del dataset —incluidas, por ejemplo, versiones ampliadas o subconjuntos re-anotados— deberá distribuirse bajo la misma licencia o una licencia compatible que preserve estas condiciones.

La elección de CC BY-NC-SA 4.0 responde a un equilibrio entre la voluntad de los autores de facilitar la reutilización académica del material y la naturaleza clínica del archivo original, derivado de casos asistenciales reales publicados con finalidad docente.

E.4 Cita recomendada

La cita en prosa recomendada para cualquier publicación que utilice el dataset es:

Taberner, R. y Contestí Coll, A. (2026). *DermapixelAI 1.0: dataset dermatológico clínico en castellano construido sobre el archivo Dermapixel*. Versión 1.0. Licencia CC BY-NC-SA 4.0.

Entrada BibTeX equivalente (pendiente de completar con el DOI tras la publicación efectiva):

```
@dataset{dermapixelai2026,  
  author    = {Taberner, Rosa and Contestí Coll, Antonio},  
  title      = {DermapixelAI 1.0: dataset dermatológico  
               clínico en castellano construido sobre  
               el archivo Dermapixel},  
  year       = {2026},  
  version    = {1.0},  
  license    = {CC BY-NC-SA 4.0},  
  doi        = {pendiente},  
  url        = {pendiente},  
}
```

E.5 Disponibilidad y distribución

La publicación efectiva del dataset en un repositorio externo está pendiente de decisión en la fecha de cierre del presente trabajo. La plataforma de distribución, la asignación del identificador persistente (DOI) y la disponibilidad pública se documentarán en el campo correspondiente de la cita BibTeX cuando se haya realizado el depósito. Mientras tanto, las consultas sobre acceso al dataset deben dirigirse al contacto indicado en la sección E.9.

La estructura del paquete previsto se compone de:

- `dataset.csv`: fichero maestro con una fila por imagen (1 089 filas) y campos de modalidad, ruta, hash MD5, diagnóstico L1/L2/L3, campos de validación experta, identificador de caso, texto narrativo y partición del split.
- `metadata/cases.csv`: una fila por caso clínico, incluidos los casos sin imagen en el dataset (`num_images_in_dataset = 0`) por trazabilidad.
- `metadata/ontology.csv`: vocabulario jerárquico L1/L2/L3 con códigos SNOMED CT y CIE-10 asociados a cada entrada L3.
- `metadata/excluded_images.csv`: registro de imágenes descartadas durante el pipeline, con razón documentada.
- `metadata/audit_log.txt`: traza de auditoría de las modificaciones aplicadas al dataset.
- `splits/train.csv`, `splits/val.csv`, `splits/test.csv`: particiones canónicas case-aware.
- `images/`: imágenes organizadas por modalidad (`clinical/`, `dermoscopy/`, `histology/`, `ultrasound/`, `wood_lamp/`).
- `README.md`: documento que reproduce, en forma de fichero plano, el contenido del presente anexo.
- `LICENSE.txt`: texto canónico de la licencia CC BY-NC-SA 4.0 con cláusulas específicas de privacidad del paciente y provenance clínico.
- `CITATION.cff`: ficha de citación en formato Citation File Format 1.2.0, con el campo `preferred-citation` preparado para sustituir el DOI cuando Zenodo lo asigne.
- `MANIFEST.sha256`: manifiesto global del paquete con el hash SHA-256 de cada uno de los archivos distribuidos, verificable con `sha256sum -c MANIFEST.sha256`.
- `enriched_captions/`: dataset enriquecido para la rama contrastiva de Dermapixel R0 con captions sintéticas multi-perspectiva generadas por LLM (sección 4.13) y `spanderm_clip_trilogy/` con los resultados experimentales completos del experimento dual encoder.

La integridad reproducible del paquete se verifica en dos niveles: (i) el manifiesto interno de cada partición o subconjunto experimental, fijado en el *checkpoint* correspondiente; y (ii) el manifiesto global del paquete distribuido (`MANIFEST.sha256`), que cubre los 1 174 archivos del *bundle* y permite detectar cualquier alteración durante la descarga o el almacenamiento intermedio. Ambos niveles son independientes y se generan de forma determinista.

E.6 Datasheet for Datasets

Esta sección sigue el formato propuesto por [29] con las cuestiones más relevantes para el dataset.

Motivación

¿Para qué se creó el dataset? El dataset se ha construido para servir de material de investigación académica sobre dermatología clínica en castellano, con foco en el aprendizaje multimodal (imagen acompañada de texto clínico) y como base estable para trabajos posteriores. No se ha creado como benchmark de evaluación del presente TFG sino como contribución resultante del proyecto a la comunidad investigadora.

¿Quién lo financió? La construcción del dataset se ha realizado sin financiación específica, en el marco del presente Trabajo de Fin de Grado, desarrollado en la Escola Politècnica Superior de la Universitat de les Illes Balears, y de la colaboración con la Dra. R. Taberner sobre la modernización del archivo Dermapixel.

Composición

¿Qué representa cada instancia? Cada instancia es una imagen dermatológica asociada a un caso clínico publicado en el archivo Dermapixel.

¿Cuántas instancias hay? 1 089 imágenes vinculadas a 672 casos con imagen —de los cuales 669 se retienen en el *split* de producción del dataset— sobre 698 casos catalogados en total.

¿Es el dataset un subconjunto de uno mayor? El dataset se construye a partir del archivo público del blog Dermapixel (<https://dermapixel.com>), que tiene una composición más amplia en términos

de publicaciones y elementos no clínicos (banners, ilustraciones, fotografías de eventos) que se filtran durante la construcción del dataset (sección C.2 del anexo C).

¿Qué información acompaña a cada imagen? Modalidad, diagnóstico L1/L2/L3, identificador de caso, texto narrativo asociado en castellano, campos de validación experta y particionado en train/val/test.

¿Hay etiquetas o ground-truth? Sí. El diagnóstico L3 está mapeado a la ontología jerárquica con revisión experta. El campo `rosa_verified` marca las imágenes adicionalmente validadas visualmente por la Dra. Taberner.

¿Hay información que se haya eliminado? Se han eliminado las imágenes asociadas a la pista de solución de los casos del blog (susceptibles de inducir *leakage*) y las imágenes no dermatológicas detectadas durante la auditoría de modalidad.

Proceso de recogida

El detalle del pipeline figura en la sección C.2 del anexo C.

Preprocesamiento, limpieza y etiquetado

Hash MD5 por imagen para integridad; deduplicación exacta; mapeo ontológico con revisión experta; particionado case-aware. Detalle en el anexo C.

Usos previstos

¿Para qué tipo de tareas se ha diseñado? Investigación académica sobre dermatología clínica en castellano, en particular los escenarios que requieren material multimodal imagen-texto en español, la armonización ontológica entre datasets dermatológicos heterogéneos, y la docencia universitaria sobre análisis de imagen médica.

¿Para qué tareas *no* debe usarse? El dataset no constituye un dispositivo médico ni puede emplearse como base de un sistema de diagnóstico autónomo destinado a uso clínico directo. Cualquier aplicación clínica derivada del dataset debe seguir los procesos regulatorios correspondientes y no puede sustituir al juicio del especialista.

Distribución

CC BY-NC-SA 4.0. Plataforma pendiente de decisión en la fecha de cierre del trabajo.

Mantenimiento

Versionado semántico. Política de errata reportable mediante el contacto de la sección E.9.

E.7 Uso responsable y limitaciones clínicas

El dataset DermapixelAI 1.0 se distribuye con las advertencias siguientes:

- **No es un dispositivo médico.** El dataset es material de investigación académica. Cualquier prototipo desarrollado a partir del dataset que aspire a uso clínico real debe seguir los procedimientos regulatorios aplicables (marcado CE, evaluación clínica, etc.).
- **No para uso diagnóstico autónomo.** Las predicciones generadas por modelos entrenados o evaluados sobre el dataset no pueden sustituir al juicio del dermatólogo. El dataset se ha diseñado para apoyar la investigación en sistemas de apoyo al diagnóstico, no para reemplazar la consulta especializada.
- **Limitaciones de cobertura.** El dataset presenta limitaciones específicas (desequilibrio de modalidad, cola larga diagnóstica, cobertura ontológica incompleta, cobertura parcial por subcategoría en los splits) documentadas en el anexo C. Cualquier publicación derivada debe declarar estas limitaciones cuando reporte cifras de rendimiento.

- **Generalización geográfica.** El dataset proviene del archivo Dermapixel, alimentado por casos atendidos en el HUSLL en Mallorca, España. La validez de los resultados sobre poblaciones de fototipo, geografía o circuito asistencial distintos requiere verificación independiente.

E.8 Privacidad y consentimiento

El archivo Dermapixel es un blog público dirigido a la formación de profesionales sanitarios. Las imágenes publicadas en el blog proceden de casos atendidos por la Dra. R. Taberner en su práctica clínica y se publicaron originalmente con consentimiento implícito en el marco del compromiso docente del blog y de la práctica asistencial habitual sobre material clínico anonimizado para uso formativo. El dataset DermapixelAI 1.0 hereda esta naturaleza de material docente público.

El dataset no contiene metadatos identificativos directos de pacientes (nombres, fechas de nacimiento, números de historia clínica, ubicación geográfica concreta). Las imágenes están recortadas a la lesión cuando procede; las fotografías macroscópicas preservan únicamente la región anatómica relevante.

Cualquier reusuario del dataset se compromete, en el momento de aceptar la licencia, a no intentar reidentificar a los pacientes representados en las imágenes ni a usar el material con finalidad distinta a la investigación académica o docente.

E.9 Mantenimiento y contacto

Política de versionado. El dataset se versiona siguiendo una numeración semántica MAJOR.MINOR. Cambios en el conjunto de imágenes incluidas o en la ontología canónica incrementan el campo MAJOR. Correcciones de etiquetado, normalización de campos o ampliaciones de los campos de validación experta incrementan el campo MINOR.

Reporte de errata. Cualquier discrepancia detectada entre las etiquetas asignadas y el diagnóstico correcto, o cualquier problema de integridad, puede reportarse al contacto indicado a continuación. Las erratas confirmadas se incorporan en la siguiente versión MINOR del dataset.

Contacto.

- **Propietaria del archivo original y revisión experta clínica:** Dra. Rosa Taberner
- **Autor técnico del dataset:** Antonio Contestí Coll
- **Afiliación principal:** Hospital Universitario Son Llàtzer y Universitat de les Illes Balears (Escola Politècnica Superior)
- **Canal de contacto preferente:** mediante el repositorio oficial del dataset una vez publicado; mientras tanto, a través del autor técnico del dataset, Antonio Contestí Coll.

SPARSE AUTOENCODERS Y DICCIONARIO DE CONCEPTOS CLÍNICOS

Este anexo documenta el módulo de interpretabilidad conceptual del trabajo, basado en Sparse Autoencoders (SAE) sobre las representaciones de PanDerm Large, su evaluación frente al diccionario SkinCon [15] y la propuesta de extensión con conceptos clínicos adicionales validados por la Dra. R. Taberner. El módulo se incorpora al prototipo DermAplxel como componente M3 (sección H.3.3) y constituye una contribución complementaria del trabajo (sección 7.2.2).

F.1 Motivación

La interpretabilidad de los modelos fundacionales constituye un requisito creciente en escenarios clínicos donde la trazabilidad del razonamiento es necesaria para la aceptación profesional. Los encoders auto-supervisados como PanDerm producen representaciones densas (vectores de 1 024 dimensiones para la variante *Large*) cuyos componentes individuales no admiten interpretación directa. Los Sparse Autoencoders [20] descomponen estas representaciones en un diccionario disperso de *features*, con la propiedad de que cada *feature* puede asociarse, en buena parte de los casos, a un concepto clínicamente identificable. DermFM-Zero [3] adopta este mecanismo de interpretabilidad como contribución de su diseño, pero sus pesos no son públicos (sección 6.1.1). El presente trabajo replica el procedimiento sobre PanDerm Large con pesos liberados y lo valida sobre SkinCon como ground-truth conceptual.

F.2 Arquitectura del SAE

La arquitectura del SAE empleado en el trabajo se compara con la descrita por los autores de DermFM-Zero sobre PanDerm Base. La tabla F.1 resume ambas configuraciones.

Cuadro F.1: Configuración comparada del SAE entrenado en el trabajo (“SAE Large”) y del SAE publicado por DermFM-Zero (“SAE Base”).

Parámetro	SAE Base (DermFM-Zero)	SAE Large (este trabajo)
Encoder visual base	PanDerm Base (ViT-B/16)	PanDerm Large (ViT-L/16)
Dimensión de entrada	768	1 024
Features aprendidas	6 144 (8×)	16 384 (16×)
Arquitectura	TiedBias + UnitNormDecoder	Pre/PostBias + Linear + UnitNormDecoder
Pérdida	$L_1 (3 \times 10^{-5}) + L_2$	$L_1 (1 \times 10^{-3}) + \text{MSE}$
Datos de entrenamiento	No especificado (pipeline DermFM-Zero)	50 454 imágenes (7 datasets)
Épocas	200	100 (convergió)
Sparsity media observada	—	16,5% (2 753 $\pm$ 112 activas)

Los siete datasets de entrenamiento del SAE Large son HAM10000 (10 015 imágenes), BCN20000 (12 413), Dermnet (19 559), PAD-UFES-20 (2 298), Fitzpatrick17k (3 887), DDI (647) e HIBA (1 635), con un total de 50 454 imágenes. La composición exacta se documenta en el Anexo B (tabla B.6). La elección de L_1 (1×10^{-3}) en lugar del valor publicado por DermFM-Zero (3×10^{-5}) responde a la dimensión de entrada mayor: el factor L_1 relativo a la magnitud típica del *embedding* se mantiene comparable.

F.3 Comportamiento del SAE Large frente a SAE Base

La tabla F.2 compara la AUROC de cuatro tareas de discriminación binaria sobre los *embeddings* crudos (sin SAE) y sobre las activaciones del SAE para ambas configuraciones. Las cifras corresponden a la media y desviación estándar sobre veinte particiones aleatorias del conjunto de evaluación.

Cuadro F.2: Discriminación binaria sobre cuatro tareas con *embeddings* crudos y con activaciones del SAE. Media $\pm$ desviación estándar sobre 20 particiones aleatorias.

Tarea	Raw 768D (Base)	SAE Base (6 144)	Raw 1 024D (Large)	SAE Large (16 384)
Melanoma	0,906 $\pm$ 0,020	0,897 $\pm$ 0,019	0,897 $\pm$ 0,020	0,900 $\pm$ 0,019
Sesgo pelo	0,888 $\pm$ 0,025	0,879 $\pm$ 0,023	0,884 $\pm$ 0,023	0,889 $\pm$ 0,024
Sesgo tinta	0,848 $\pm$ 0,024	0,836 $\pm$ 0,025	0,846 $\pm$ 0,028	0,851 $\pm$ 0,028
Sesgo regla	0,888 $\pm$ 0,024	0,889 $\pm$ 0,026	0,894 $\pm$ 0,022	0,908 $\pm$ 0,022

El SAE Base degrada consistentemente la AUROC respecto a los *embeddings* crudos correspondientes (promedio $-0,008$ pp), mientras que el SAE Large produce mejoras de $+0,007$ pp de promedio sobre los *embeddings* crudos de 1 024 dimensiones. La interpretación operativa es que el SAE Large preserva la información discriminativa relevante para clasificación binaria pese a la proyección al espacio disperso de 16 384 *features*, comportamiento que justifica su uso como módulo de interpretabilidad sin pérdida de utilidad diagnóstica (figura F.1).




Figura F.1: Comparativa AUROC entre *embeddings* crudos y activaciones del SAE sobre cuatro tareas binarias. El SAE Large (este trabajo, $1024 \rightarrow 16384$) preserva o mejora la información discriminativa frente al SAE Base ($768 \rightarrow 6144$), que degrada consistentemente la AUROC.

F.4 Concept Bottleneck Model sobre SkinCon

La validación clínica del SAE Large se realiza mediante un *Concept Bottleneck Model* (CBM) sobre el dataset SkinCon [15], que anota densamente 3230 imágenes con 48 conceptos clínicos por dermatólogos certificados. La hipótesis a contrastar es que las 16384 *features* del SAE Large contienen información suficiente para predecir los conceptos SkinCon mediante un clasificador lineal sobre cada concepto.

El procedimiento es el siguiente: cada imagen de SkinCon se codifica mediante PanDerm Large; su *embedding* de 1024 dimensiones se proyecta al espacio disperso del SAE Large; sobre las 16384 activaciones se entrena un clasificador lineal binario por concepto (regresión logística L-BFGS con $C = 1,0$, $\text{max_iter} = 5000$, $\text{random_state} = 42$). La métrica reportada es la AUROC del mejor *feature* individual como predictor del concepto.

F.4.1 Conceptos con mejor predictor

La tabla F.3 reporta los conceptos SkinCon con mejor predictor entre las 16384 *features* del SAE Large, ordenados por AUROC del mejor *feature* descendente.

Cuadro F3: Conceptos SkinCon con mejor predictor entre las *features* del SAE Large. n_+ : número de imágenes positivas para el concepto en SkinCon. AUROC: del mejor *feature* individual del SAE como predictor binario del concepto.

Concepto clínico	n_+	Mejor <i>feature</i>	AUROC
Pedunculated	26	#1930	0,929
Friable	153	#5973	0,913
Exophytic/Fungating	42	#10114	0,908
Comedo	24	#7191	0,903
Ulcer	154	#13908	0,897
Exudate	144	#5973	0,884
Wheal	21	#9552	0,884
Black	90	#3926	0,846
Telangiectasia	100	#11172	0,828
Nodule	189	#1930	0,818
Umbilicated	49	#13783	0,810

Los conceptos con mejor predictor incluyen un núcleo de morfología elevada (*pedunculated*, *exophytic/fungating*, *nodule*: AUROC 0,818–0,929), de superficie alterada (*friable*, *ulcer*, *exudate*: AUROC 0,884–0,913) y de estructura específica (*telangiectasia*: AUROC 0,828). Cada *feature* del SAE puede actuar como predictor para más de un concepto relacionado (e.g. #1930 cubre *pedunculated* y *nodule*; #5973 cubre *friable* y *exudate*), lo que sugiere que el espacio disperso del SAE codifica dimensiones clínicas de granularidad superior a la del concepto individual.

F.4.2 Rendimiento agregado del CBM

Sobre los 22 conceptos de SkinCon con cobertura suficiente para el contraste, el protocolo *CBM-Selected* (regresión logística entrenada sobre 134 *features* del SAE Large correlacionadas con cada concepto) alcanza AUROC media de 0,880. El protocolo de comparación *LP-Direct* (regresión logística sobre el *embedding* crudo de 1024 dimensiones de PanDerm Large, sin pasar por el SAE) alcanza AUROC media de 0,864 sobre los mismos conceptos. CBM-Selected supera a LP-Direct en 16 de los 22 conceptos evaluados. El resultado indica que las *features* dispersas del SAE preservan —y en la mayoría de conceptos exceden— el poder predictivo de la representación densa subyacente (figura F2), comportamiento que sostiene su uso como módulo de interpretabilidad en el prototipo descrito en la sección H.3.3 del Anexo H.




Figura F2: Concept Bottleneck Model sobre SkinCon: AUROC del mejor *feature* individual del SAE Large como predictor binario por concepto. Once conceptos superan AUROC 0,80, con máximos en *pedunculated* (0,929) y *friable* (0,913).

F5 Propuesta de extensión: quince conceptos clínicos adicionales

El diccionario SkinCon, construido en el contexto del estudio de Daneshjou et al. [15], prioriza conceptos visuales estructurales de detección automatizable. La revisión clínica realizada por la Dra. R. Taberner sobre el dataset DermapixelAI 1.0 ha identificado 15 conceptos clínicos adicionales no contemplados por SkinCon que aparecen con frecuencia relevante en la práctica dermatológica hispanohablante y cuya inclusión enriquecería el diccionario operativo del prototipo. La tabla F4 enumera los conceptos propuestos.

Cuadro F4: Quince conceptos clínicos adicionales propuestos por la Dra. R. Taberner sobre la base del diccionario SkinCon.

Categoría	Concepto propuesto	Relevancia clínica
Pigmentación	Pigmentación reticular	Diagnóstico diferencial nevus
Pigmentación	Pseudored	Lentigo solar <i>vs.</i> lentigo maligno
Vasculatura	Lagunas vasculares	Hemangioma, angioqueratoma
Vasculatura	Vasos en horquilla	Carcinoma basocelular
Estructura epidérmica	Hiperqueratosis	Queratosis seborreica
Estructura epidérmica	Comedo invertido	Queratosis seborreica adelgazada
Patrón inflamatorio	Eritema heliotropo	Dermatomiositis
Patrón inflamatorio	Patrón en <i>papel de seda</i>	Liquen escleroso
Distribución	Distribución dermatomérica	Herpes zóster
Distribución	Distribución <i>en alas</i>	Lupus subagudo
Superficie	Cráteres centrales	Molluscum contagioso
Superficie	Anillos concéntricos	Eritema multiforme
Color	Coloración <i>salmón</i>	Psoriasis guttata
Color	Halo blanco perilesional	Nevus halo
Otros	Bordes geográficos	Vitiligo segmentario

La incorporación de estos quince conceptos al diccionario operativo del prototipo DermApIxl constituye una línea de continuación inmediata, condicionada al muestreo de aproximadamente 200 imágenes anotadas por concepto para entrenar el clasificador lineal correspondiente sobre las activaciones del SAE Large. El protocolo de anotación previsto utiliza la interfaz autocontenida descrita en la sección 7.5 del capítulo 7.

F6 Limitaciones del módulo SAE

El módulo SAE presenta tres limitaciones declaradas. Primero, la asociación entre *feature* y concepto se establece sobre la base del mejor predictor individual, sin garantía de que la *feature* sea *monosemántica* en el sentido estricto del término (la misma *feature* puede correlacionarse con varios conceptos relacionados, como se observa en sección F4.1). Segundo, el rendimiento del SAE Large sobre tareas de discriminación binaria (tabla F2) es ligeramente superior al de los *embeddings* crudos correspondientes, pero esta mejora es del orden de la desviación estándar inter-partición, lo que limita la afirmación de *superioridad estadísticamente significativa* sin las pruebas pendientes (sección 6.3.2). Tercero, la validación sobre conceptos clínicos se realiza sobre SkinCon, dataset con sesgo de selección hacia patología dermatoscópica documentada, lo que condiciona la transferencia a otros contextos clínicos.

F7 Tablas de detalle del experimento Derm7pt

Este apartado recoge tres tablas de detalle de los experimentos de interpretabilidad sobre Derm7pt descritos en la sección 4.14, separadas del cuerpo por su carácter de soporte cuantitativo: los pesos por concepto del *Concept Bottleneck Model* (E2), el cruce de los conceptos del Grupo A con el *Seven-Point Checklist* (E3) y la comparativa concepto a concepto entre sondeo lineal y *fine-tuning* multitarea (E4).

Cuadro F5: Cabeza intermedia del CBM: AUROC binario sobre el conjunto de test Derm7pt ($N_{\text{test}} = 395$) por concepto del *Seven-Point Checklist*, y peso aprendido por el meta-clasificador logístico para la predicción binaria melanoma/no-melanoma. Pesos ordenados de mayor a menor importancia relativa.

Concepto	AUROC concepto	Peso meta-LP
blue_whitish_veil	0,895	+2,54
regression_structures	0,818	+2,07
streaks	0,829	+1,78
vascular_structures	0,906	+1,65
pigmentation	0,792	+1,44
dots_and_globules	0,723	+1,41
pigment_network	0,901	+1,04

La AUROC binaria de la cabeza intermedia se sitúa en el intervalo [0,723, 0,906] sobre los siete conceptos, con *vascular structures* (0,906), *pigment network* (0,901) y *blue whitish veil* (0,895) como las predicciones conceptuales más fiables. Los pesos del meta-clasificador identifican *blue whitish veil* y *regression structures* como los conceptos con mayor peso relativo para la decisión final melanoma/no-melanoma (+2,54 y +2,07 respectivamente), jerarquía que coincide cualitativamente con el peso clínico asignado a estos criterios en el *Seven-Point Checklist*.

Cuadro F6: Cruce de los 16 conceptos dermatoscópicos del Grupo A propuestos a la Dra. R. Taberner con los siete criterios del *Seven-Point Checklist* sobre Derm7pt ($N = 1011$). Para los conceptos con *mapping* se reporta la AUROC efectiva de la mejor *feature* SAE Large sobre la binarización correspondiente. Conceptos cubiertos (AUROC $\geq 0,70$) en negrita.

#	Concepto Rosa (Grupo A)	Mapping Derm7pt	N_+	AUROC eff	Cobertura
1	Red dermatoscópica regular	pigment_network=typical	381	0,748	✓
2	Red dermatoscópica atípica	pigment_network=atypical	230	0,732	✓
3	Glóbulos pigmentarios	dots_and_globules	782	0,681	—
4	Puntos pigmentarios	dots_and_globules	782	0,681	—
5	Estrías radiales	streaks	358	0,688	—
6	Pseudopodios	streaks=irregular	251	0,729	✓
7	Velo azul-blanquecino	blue_whitish_veil=present	195	0,746	✓
8	Estructuras de regresión	regression_structures $\neq$ absent	253	0,687	—
9	Patrón empedrado	—	—	—	—
10	Patrón paralelo de surcos	—	—	—	—
11	Patrón paralelo de crestas	—	—	—	—
12	Lagunas vasculares	—	—	—	—
13	Vasos polimorfos	vascular_structures (agregado)	140	0,810	✓
14	Vasos en horquilla	vascular_structures=hairpin	15	0,926	✓
15	Vasos en corona	—	—	—	—
16	Patrón homogéneo desestructurado	pigmentation (<i>diffuse</i>)	380	0,704	✓

De los 16 conceptos del Grupo A, 11 admiten *mapping* operativo a un criterio o subcategoría del *Seven-Point Checklist* (directo en tres casos, por subcategoría en ocho), y los 5 restantes (patrón empedrado, patrón paralelo de surcos, patrón paralelo de crestas, lagunas vasculares, vasos en corona) corresponden a estructuras dermatoscópicas no contempladas en la escala original. Sobre los 11 conceptos mapeados, 7 quedan cubiertos por al menos una *feature* SAE con AUROC efectivo $\geq 0,70$, con un máximo absoluto de 0,926 sobre vasos en horquilla (sólo 15 positivos sobre 1011 imágenes).

Cuadro F7: AUROC binaria *present/absent* por concepto del *Seven-Point Checklist* sobre el conjunto de test Derm7pt ($N_{\text{test}} = 395$). Comparativa entre sondeo lineal separado por concepto sobre las activaciones SAE Large (E2 LP separado, una regresión logística por concepto) y las siete cabezas conceptuales del *fine-tuning* multitarea LoRA (E4). Δ en puntos porcentuales.

Concepto	E2 LP separado	E4 multitarea	Δ
pigment_network	0,901	0,889	−1,2 pp
vascular_structures	0,906	0,880	−2,6 pp
blue_whitish_veil	0,895	0,879	−1,6 pp
streaks	0,829	0,818	−1,1 pp
pigmentation	0,792	0,793	+0,1 pp
regression_structures	0,818	0,791	−2,7 pp
dots_and_globules	0,723	0,725	+0,2 pp

Las cabezas conceptuales del régimen multitarea (E4) pierden entre 1 y 3 pp de AUROC binaria frente al sondeo lineal separado (E2) en seis de los siete conceptos, con un máximo de −2,7 pp en *regression structures*: una degradación menor que confirma que el aprendizaje conjunto de melanoma y conceptos no compromete la calidad conceptual.

MODELOS DE LENGUAJE MULTIMODALES: COMPARACIÓN EXTENDIDA

Este anexo amplía la comparación entre modelos de lenguaje multimodales generalistas presentada en sección 4.8 del capítulo 4. Contiene el *prompt* clínico empleado en la evaluación, el análisis detallado de patrones de error sobre HAM10000, la caracterización de la sensibilidad al *prompt* en DermLIP v2 (que motiva el *wrapping* automático del prototipo) y la comparación de costes operativos agregados.

G.1 Modelos evaluados

La tabla G.1 enumera los modelos evaluados y sus condiciones de acceso. Los modelos accesibles vía API se han evaluado con la versión disponible en marzo de 2026; los modelos locales se han ejecutado sobre la DGX Spark con chip Grace Hopper GB10 en precisión BF16 sin cuantización adicional.

Cuadro G.1: Modelos de lenguaje multimodales generalistas evaluados.

Modelo	Proveedor	Parámetros	Acceso
GPT-4o	OpenAI	No público	API REST
GPT-4o-mini	OpenAI	No público	API REST
Gemini 2.5 Pro	Google	No público	API REST
Gemini 2.5 Flash	Google	No público	API REST
MedGemma 4B Vision	Google	~ 4 B	Local (Ollama)
MedGemma 27B Text	Google	~ 27 B	Local (DGX Spark, BF16)
MedGemma 27B + LoRA	Google	~ 27 B + 41 M LoRA	Local (DGX Spark, BF16)
BLIP-2 Flan-T5-XL	Salesforce	—	Local (HuggingFace)
InstructBLIP Flan-T5-XL	Salesforce	—	Local (HuggingFace)

G.2 Prompt clínico estandarizado

El *prompt* clínico empleado en la evaluación tiene aproximadamente 300 palabras y describe la tarea, presenta las clases candidatas y solicita el diagnóstico estructurado. La formulación se mantiene constante entre los nueve proveedores evaluados, lo que elimina la formulación del *prompt* como variable confusoria. La estructura es la siguiente:

You are assisting in a dermatology research study. This is a dermoscopic image of a skin lesion taken during clinical practice. Your task is to classify the lesion as exactly one of the following seven categories used in the HAM10000 dataset: melanoma (mel), melanocytic nevus (nv), basal cell carcinoma (bcc), actinic keratosis (akiec), seborrheic keratosis (bkl), dermatofibroma (df) or vascular lesion (vasc). Provide your answer as a single diagnostic label followed by a brief clinical justification (1–2 sentences). The justification should mention the morphological features that support the diagnosis (e.g., asymmetry, border regularity, color pattern, vascular structures). Avoid hedging language; commit to the most likely diagnosis based on the visible features. Do not refuse to answer. Respond only with the category name and the justification.

Para Gemini 2.5 Pro y Gemini 2.5 Flash, el *prompt* se ajusta levemente para evitar la activación de filtros de seguridad (refusal rate documentado: ~ 22 % en Gemini 2.5 Pro sobre HAM10000 frente a < 1 % en GPT-4o). La etiqueta predicha se extrae mediante *parsing* determinista que mapea sinónimos admitidos al código canónico de HAM10000.

G.3 Comparativa completa sobre HAM10000, PAD-UFES-20 y DDI

La tabla G.2 reproduce la comparativa de la tabla 4.11 del cuerpo, ampliada con las variantes Gemini Flash y BLIP-2 + InstructBLIP para incluir el espectro completo de modelos evaluados.

Cuadro G.2: Comparativa completa de modelos de lenguaje multimodales sobre HAM10000 ($N = 1\,232$), PAD-UFES-20 ($N = 461$) y DDI ($N = 137$).

Modelo	Modo	HAM Acc	HAM BAcc	PAD Acc	PAD BAcc	DDI Acc	DDI BAcc
MedGemma 27B + LoRA	FT	0,802	0,270	0,430	0,347	0,657	0,618
MedGemma 27B	ZS	0,665	0,243	0,447	0,342	0,474	0,566
GPT-4o	ZS	0,485	0,465	0,553	0,523	0,723	0,648
Gemini 2.5 Pro	ZS	0,403	—	0,477	—	0,441	—
Gemini 2.5 Flash	ZS	0,380	—	0,486	—	0,555	—
GPT-4o-mini	ZS	0,256	0,319	0,390	0,435	0,737	0,556
BLIP-2 (Flan-T5-XL)	ZS	0,015	0,145	0,017	0,167	0,796	0,542
InstructBLIP (Flan-T5-XL)	ZS	0,024	0,123	0,171	0,224	0,788	0,500

G.4 Latencias, refusal rates y costes operativos

La tabla G.3 reporta las características operativas de la evaluación: latencia media por imagen, tasa de respuestas no clasificables (*refusal rate*) y coste agregado sobre los tres datasets evaluados.

Cuadro G.3: Características operativas de la evaluación de LLMs multimodales. *Refusal* sobre Gemini 2.5 Pro corresponde a respuestas bloqueadas por filtros de seguridad. “Coste” agrega HAM10000 + PAD-UFES-20 + DDI.

Modelo	Latencia/imagen	Refusal HAM	Refusal PAD	Refusal DDI	Coste total
GPT-4o	~ 4 s	< 1 %	< 1 %	< 1 %	~\$2,71
GPT-4o-mini	~ 3 s	< 1 %	< 1 %	< 1 %	~\$1,36
Gemini 2.5 Pro	~ 8 s	21,5 %	15,0 %	18,2 %	—
Gemini 2.5 Flash	~ 2 s	0,3 %	2,4 %	2,7 %	—
MedGemma 27B	1,76 s	0 %	0 %	0 %	0 EUR
MedGemma 27B + LoRA	1,82 s	0 %	0 %	0 %	0 EUR (entrenam.)

Tres observaciones operativas: (i) Gemini 2.5 Pro presenta *refusal rate* elevado sobre HAM10000 (21,5 %), comportamiento atribuible a la activación de filtros de seguridad sobre imagen clínica. (ii) MedGemma 27B y su variante con LoRA operan localmente sin coste recurrente, con latencias medidas sobre

la DGX Spark de $\sim 1,8$ segundos por imagen, inferiores a las de los proveedores comerciales. (iii) El coste agregado de GPT-4o-mini ($\sim \$1,36$ sobre 1 830 imágenes) es de aproximadamente \$0,001 por imagen, lo que hace operativamente viable la evaluación a escala moderada; el coste de GPT-4o ($\sim \$2,71$) duplica esta cifra.

G.5 Patrones de error sobre HAM10000

La tabla G.4 reporta la matriz de predicciones de GPT-4o sobre HAM10000. La fila “*Predicciones totales*” indica el número de imágenes asignadas a cada clase por el modelo; la comparación con la fila “ N_{test} ” revela los sesgos sistemáticos.

Cuadro G.4: Distribución de predicciones de GPT-4o sobre HAM10000.

Clase	N_{test}	Predicciones GPT-4o	Factor
actinic keratosis	35	2	0,06×
basal cell carcinoma	44	—	—
seborrheic keratosis	107	—	—
dermatofibroma	8	284	35,5×
melanoma	70	299	4,3×
melanocytic nevus	951	—	—
vascular lesion	17	—	—

El sesgo más acusado es la sobreasignación de *dermatofibroma* (predicciones 284 frente a 8 muestras reales, factor 35,5×). La hipótesis sobre el mecanismo es que el modelo responde al espacio léxico del *prompt*: la enumeración explícita de *dermatofibroma* entre las clases candidatas activa preferentemente esta categoría como respuesta cuando la evidencia visual no es saliente. Un patrón análogo, aunque de menor magnitud, se observa con melanoma (factor 4,3×), clase clínicamente prioritaria que el modelo podría sobreasignar por reflejar un sesgo precautorio aprendido durante el entrenamiento.

GPT-4o-mini presenta un patrón distinto: sesgo masivo hacia *seborrheic keratosis* (528 predicciones frente a 107 muestras reales) y melanoma (359 predicciones frente a 70). Sólo 196 de los 951 casos de *melanocytic nevus* se clasifican correctamente (*recall* 0,196), mientras GPT-4o alcanza *recall* de 0,505 sobre la misma clase.

G.6 MedGemma 27B con LoRA: análisis por dataset

La adaptación con LoRA sobre MedGemma 27B (*rank* $r = 16$, $\alpha = 32$, dropout 0,05, 1 época, $\eta = 2 \times 10^{-5}$, *effective batch* 8, ~ 41 M parámetros entrenables sobre el *split* de entrenamiento de HAM10000) produce las mejoras asimétricas reportadas en sección 5.1.7. La tabla G.5 reporta el desglose por clase sobre HAM10000 con la variante adaptada.

Cuadro G.5: Desglose por clase de MedGemma 27B + LoRA sobre HAM10000 (*precision*, *recall*, F1).

Clase	N_{test}	Precision	Recall	F1
actinic keratosis	35	0,32	0,26	0,29
basal cell carcinoma	44	0,34	0,25	0,29
dermatofibroma	8	0,00	0,00	0,00
melanocytic nevus	951	0,85	0,99	0,92
melanoma	70	0,38	0,36	0,37
seborrheic keratosis	107	0,67	0,04	0,07
vascular lesion	17	0,00	0,00	0,00

La concentración del rendimiento sobre la clase mayoritaria (nevus melanocítico: *recall* 0,99) a costa de las minoritarias (dermatofibroma y vascular lesion: F1 0,00) contrasta con el comportamiento de PanDerm Base con ajuste fino y TTA sobre el mismo dataset, que mantiene *recall* superior a 0,65 sobre

todas las clases minoritarias gracias al *weighted random sampler* de la receta original (sección 3.6.2). La diferencia metodológica sugiere que el *fine-tuning* de LLMs multimodales sobre datasets desbalanceados requiere estrategias específicas de balanceo no contempladas en la configuración estándar de LoRA.

G.7 Sensibilidad al prompt en DermLIP v2

El módulo M6 del prototipo DermApIxel (sección H.3.6) opera sobre DermLIP v2 con envoltorio automático del *prompt*. Esta sección documenta cuantitativamente el fenómeno que motiva el envoltorio, resumido en la tabla G.6.

Cuadro G.6: Sensibilidad al *prompt* de DermLIP v2 sobre HAM10000: curva de AUROC observada en función de la longitud del *prompt*.

Longitud del <i>prompt</i>	Estrategia	AUROC HAM10000
1 palabra	Etiqueta desnuda	≈ aleatorio
~ 5 palabras	Envoltorio clínico (“ <i>dermoscopyimageof</i> {X}”)	~ 0,72
8–15 palabras	Envoltorio + 1 rasgo clínico	0,854
~ 20 palabras	Envoltorio + 3 conceptos Derm1M	0,842
> 25 palabras	Envoltorio + 5 conceptos Derm1M	0,826

La curva presenta un punto óptimo en 8–15 palabras con un único rasgo clínico añadido (AUROC 0,854). El rendimiento decae tanto en el régimen de *prompt* muy corto (etiqueta desnuda: AUROC aleatorio) como en el régimen de *prompt* muy largo (> 25 palabras: AUROC 0,826).

La causa propuesta sobre el régimen de *prompt* muy corto es que PubMedBERT (encoder textual de DermLIP v2) está preentrenado sobre *captions* del dataset Derm1M con estructura “dermoscopy image of [clase], [descripción]”. Una palabra aislada se proyecta sobre regiones del espacio de *embedding* muy poco pobladas, lo que produce similitudes coseno arbitrarias frente al *embedding* visual. Sobre el régimen de *prompt* muy largo, la hipótesis es que la acumulación de conceptos clínicos introduce ruido semántico que diluye la señal de la clase principal.

El *wrapping* automático del prototipo implementa esta curva en tres capas: presets predefinidos con *prompts* ya en el punto óptimo, composable `useZeroShot . js` que aplica el envoltorio “*dermoscopy image of {term}*” cuando la entrada del usuario contiene cinco o menos palabras, y conmutador en la interfaz que permite al dermatólogo desactivar el envoltorio si escribe descripciones completas propias. La extensión de este barrido sistemático de longitud de *prompt* a los demás datasets de evaluación constituye una línea de continuación inmediata.

G.8 Síntesis

La evaluación extendida documentada en este anexo confirma los patrones cualitativos identificados en sección 5.1.7 del capítulo 5: brecha de 43,5 pp accuracy entre el mejor especialista ajustado (PanDerm Base FT con TTA) y el mejor LLM multimodal generalista *zero-shot* (GPT-4o); sesgo léxico sistemático en los modelos cerrados; *refusal rates* elevados en Gemini 2.5 Pro que limitan su utilidad clínica; y asimetría en la adaptación con LoRA sobre MedGemma 27B. Las cifras detalladas refuerzan la conclusión de que los LLMs multimodales generalistas no constituyen sustitutos defendibles de los encoders fundacionales específicos del dominio en el régimen clínico evaluado, pero pueden complementarlos como generadores de razonamiento textual estructurado bajo el *prompt* clínico descrito en sección G.2.



PROTOTIPO DERMAPIXEL

Este anexo describe el prototipo *DermApIxel*, sistema integrado de apoyo al diagnóstico dermatológico construido como entorno operativo de los módulos derivados del trabajo experimental. La versión inicial documentada en las secciones H.1–H.7 opera con seis módulos de inteligencia artificial (M1–M6), estado correspondiente al despliegue *end-to-end* de 2026-04-05. La evolución posterior incorpora tres módulos castellanos adicionales (M7, M9, M10) más un módulo de recuperación sobre DermapixelAI 1.0 (M4-bis) y un ensemble ponderado (M11), descritos en la sección H.8. El prototipo no constituye objeto experimental del estudio principal del documento (sección 1.5), pero materializa la integración técnica entre los modelos evaluados en el capítulo 4 y un sistema operativo accesible desde navegador.

H.1 Motivación arquitectónica

La traslación de los hallazgos cuantitativos del benchmark a un entorno operativo plantea requisitos no satisfechos por las herramientas estándar de evaluación (notebooks de investigación, scripts CLI). Cuatro requisitos vertebran el diseño del prototipo: (i) separación física entre el equipo cliente (PC del clínico, sin GPU) y el servidor de inferencia (DGX Spark, con GPU); (ii) comunicación asíncrona entre ambos para evitar bloqueos en la interfaz durante inferencias de varios segundos; (iii) persistencia estructurada de imagen original, máscara, conceptos, casos similares, razonamiento textual y validación posterior por dermatólogo; y (iv) interfaz web multilingüe (catalán, español, inglés) compatible con flujos de teledermatología.

La arquitectura resultante (sección H.2) implementa una separación cliente-servidor con bus de mensajería intermedio sobre AMQP. El cliente expone una API REST sobre FastAPI que encapsula la lógica de persistencia y la sincronización asíncrona; el servidor de inferencia opera sobre la DGX Spark con todos los modelos cargados en VRAM unificada y consume mensajes del bus.

H.2 Arquitectura

H.2.1 Topología cliente-servidor

El sistema se distribuye en dos nodos físicos sobre una red local (LAN). El primer nodo, equipo Windows del usuario clínico, aloja la API REST, la base de datos, el proxy inverso y la interfaz web. El segundo nodo, servidor GPU on-prem NVIDIA DGX Spark con chip Grace Hopper GB10, aloja el servidor de inferencia con los seis modelos cargados, el servidor del modelo de lenguaje multimodal de gran tamaño y los modelos de razonamiento auxiliares servidos vía Ollama. La comunicación entre ambos nodos se realiza

exclusivamente vía AMQP sobre RabbitMQ, sin tráfico HTTP directo, lo que aísla operativamente el servidor de inferencia tras el firewall del proveedor de cómputo.

H.2.2 Componentes del backend

El backend (FastAPI 0,115 asíncrono) se despliega como contenedores Docker Compose con cinco servicios. La tabla H.1 sintetiza puertos y responsabilidades.

Cuadro H.1: Servicios del backend DermApiXel.

Servicio	Imagen	Puerto host	Función
derm-svc	FastAPI 0,115 + Uvicorn	9030	API REST principal
derm-mysql	MySQL 8,0	(interno)	Persistencia estructurada
derm-rabbitmq	RabbitMQ 3,13	5673/15675	Bus AMQP y panel de gestión
derm-nginx	Nginx 1,25	8091	Proxy inverso y archivos estáticos
result-consumer	Python asincio	—	Worker asíncrono que recibe resultados

H.2.3 Persistencia: esquema de base de datos

La base de datos contiene doce tablas relacionales que documentan cada estudio dermatológico, sus resultados parciales por módulo y las validaciones posteriores. La tabla raíz `derm_studies` contiene el identificador único, el estado del estudio (`pending`, `processing`, `done`, `error`), los *timings* por etapa y la imagen original almacenada como `LONGBLOB`. Las diez tablas restantes contienen los resultados de cada módulo y se enlazan a `derm_studies` mediante clave foránea con borrado en cascada. La separación por tabla, en lugar de un único documento JSON, facilita las consultas analíticas posteriores (estadísticas por clase, validación selectiva, exportación a CSV para reentrenamiento) y mantiene la integridad referencial bajo cargas concurrentes.

H.2.4 Bus de mensajería AMQP

La comunicación entre backend e inferencia se realiza mediante dos colas RabbitMQ con semántica distinta. La cola `derm.inference` es *work queue*: el backend publica una tarea por estudio (imagen + identificador único) y el servidor de inferencia la consume con confirmación explícita (*manual ack*) tras producir el resultado. La cola `derm.results` es *publish-subscribe* (configurada como *topic exchange*): el servidor de inferencia publica un mensaje por estudio completado, y el worker `result-consumer` del backend lo consume para actualizar la base de datos y notificar al frontend. El módulo M6 (clasificación zero-shot) utiliza una tercera vía RPC sobre AMQP para invocaciones síncronas de baja latencia (~ 20 ms), apropiada para consultas interactivas del clínico.

La elección de AMQP sobre HTTP directo aporta tres ventajas operativas: tolerancia a fallos del servidor de inferencia (los mensajes quedan en cola), desacoplamiento temporal entre cliente y servidor (no se requiere conexión persistente), y trazabilidad auditable de cada mensaje a través del panel de gestión de RabbitMQ.

H.3 Módulos de inteligencia artificial

El servidor de inferencia tiene seis módulos cargados simultáneamente sobre la VRAM unificada de la DGX Spark. La tabla H.2 sintetiza su correspondencia con los modelos evaluados en el capítulo 4.

Cuadro H.2: Módulos del prototipo DermApIxel.

Módulo	Modelo subyacente	Latencia	Función
M1	PanDerm Large FT (HAM10000, TTA)	~ 315 ms	Clasificación cerrada 7 clases
M2	SAM2.1-Large (decoder FT, ISIC2018)	—	Segmentación binaria de lesión
M3	SAE 1024 → 16384 + SkinCon	—	32 conceptos clínicos por imagen
M4	FAISS sobre Derm1M (421 327 vec.)	~ 150 ms	Recuperación visual densa <i>top-5</i>
M5	MedGemma 27B / GPT-4o / GPT-5 (9 prov.)	6–300 s	Razonamiento clínico estructurado
M6	DermLIP v2 (PubMedBERT)	~ 20 ms	Clasificación abierta zero-shot

El módulo M7 (clasificador unificado L1/L2/L3 sobre el dataset armonizado de 43 clases L3 y M8 (SigLIP-Large SO400M con sondeo lineal sobre HAM10000) están integrados en el pipeline de evaluación pero no se exponen como pestañas independientes de la interfaz clínica.

H.3.1 M1 – Clasificador cerrado

M1 es PanDerm Large *fine-tuned* sobre HAM10000 con la receta descrita en sección 3.6.2. La inferencia emplea *test-time augmentation* con cinco aumentaciones deterministas, lo que incrementa la latencia respecto a la inferencia simple (*recall* de melanoma sobre HAM10000: +4,3 pp con TTA, según se documenta en la sección H.8.7). La salida es un vector de siete probabilidades softmax sobre las clases HAM10000, persistido en la tabla `derm_classifications`.

H.3.2 M2 – Segmentación binaria

M2 es SAM2.1-Large adaptado mediante *fine-tuning* de su decodificador conforme a la configuración descrita en sección 3.6.4. La inferencia recibe la imagen y, en el modo interactivo, un *prompt* espacial (punto o caja delimitadora). La salida es una máscara binaria almacenada como `LONGLOB` en la tabla `derm_segmentations`, junto con métricas derivadas (asimetría, área estimada en píxeles, perímetro). La interfaz superpone la máscara sobre la imagen original como overlay semitransparente.

H.3.3 M3 – Conceptos clínicos

M3 es el módulo de interpretabilidad conceptual basado en Sparse Autoencoders. El procedimiento es el siguiente: la imagen se codifica mediante PanDerm Large, el *embedding* de 1024 dimensiones se proyecta al espacio disperso de 16384 *features* mediante el SAE entrenado sobre 50454 imágenes de siete datasets (sección 5.1.8 para más detalle), y las activaciones se mapean a los 32 conceptos clínicos de SkinCon [15] mediante regresión logística por concepto. La salida es un vector de 32 activaciones interpretables (*pedunculado*, *ulcerado*, *eritematoso*, *escamoso*, etc.) que se muestra al clínico como apoyo visual al diagnóstico.

H.3.4 M4 – Recuperación visual densa

M4 indexa los 421 327 *embeddings* DermLIP de las imágenes de Derm1M mediante FAISS [27] con índice HNSW (*Hierarchical Navigable Small Worlds*). La consulta produce las cinco imágenes más similares en el espacio de *embeddings*, junto con su diagnóstico asignado y la distancia coseno. La latencia media es de ~ 150 milisegundos por consulta sobre el equipo descrito en sección 3.5. La salida se persiste en `derm_similar_cases` y se presenta como galería navegable de casos comparables.

La distinción operativa entre M4 y un sistema RAG completo es relevante: M4 devuelve los casos análogos como referencia para inspección humana, sin alimentar un modelo generativo posterior con esos casos como contexto. La integración del retrieval con generación se materializa parcialmente en M5 (sección H.3.5), donde los hallazgos de M1–M4 se inyectan como contexto del prompt clínico.

H.3.5 M5 – Razonamiento clínico estructurado

M5 genera una explicación textual en español que integra los hallazgos de M1–M4 (y opcionalmente M6) en un razonamiento clínico estructurado. La arquitectura soporta nueve proveedores intercambiables

H. PROTOTIPO DERMAPIXEL

mediante el parámetro `provider` del endpoint correspondiente, cuyo perfil de coste y latencia se sintetiza en la tabla H.3.

Cuadro H.3: Proveedores LLM soportados por M5. Latencias medidas sobre prompt clínico real (~ 1 500 tokens entrada, ~ 500 tokens salida).

provider	Modelo	Latencia	Coste/llamada	Infraestructura
gpt-4o-mini	GPT-4o-mini	~ 6 s	~\$0,001	API OpenAI
gpt-4o	GPT-4o	~ 10 s	~\$0,01	API OpenAI
gpt-5-mini	GPT-5 mini	~ 15 s	~\$0,001	API OpenAI
gpt-5-nano	GPT-5 nano	~ 25 s	~\$0,0003	API OpenAI
gpt-5	GPT-5	~ 30 s	~\$0,01	API OpenAI
medgemma-4b	MedGemma 4B Vision	~ 40 s	0 EUR (local)	Ollama, ~ 4 GB VRAM
medgemma-vision	MedGemma 27B Vision (BF16)	3–5 min	0 EUR (local)	DGX Spark, 54,9 GB VRAM

El provider por defecto para la interfaz interactiva es `gpt-4o-mini` por su compromiso latencia-calidad. Los proveedores locales (`medgemma-4b` y `medgemma-vision`) se reservan para escenarios de cumplimiento estricto sobre datos sanitarios donde la exfiltración hacia APIs externas no es aceptable. La latencia de los proveedores locales es superior a la de los proveedores comerciales pese al tamaño nominalmente reducido, comportamiento documentado en sección 5.1.7 y atribuible a la diferencia de optimización entre infraestructuras dedicadas y hardware genérico.

Los nueve proveedores comparten el mismo *system prompt* de ≥ 300 palabras estructurado en cinco secciones obligatorias (morfología, dermatoscopia, criterios ABCDE con valores concretos por letra, integración con resultados de M1–M4, juicio clínico), y el mismo contexto enriquecido generado por la función `_build_context()` que inyecta las cifras del pipeline al *prompt*. La salida es un JSON con tres campos: `reasoning` (texto estructurado), `differential_diagnosis` (tres a cinco objetos con diagnóstico, nivel de confianza y justificación) y `recommendation` (urgencia, acción concreta, signos de alarma).

H.3.6 M6 – Clasificación zero-shot abierta

M6 implementa la clasificación zero-shot multimodal descrita en sección 3.6.5 usando DermLIP v2 (ViT-B/16 + PubMedBERT) con los *prompts* A3 derivados de Derm1M. A diferencia de M1 (clasificador cerrado sobre siete clases HAM10000), M6 acepta una lista arbitraria de descripciones textuales y devuelve la similitud coseno softmax sobre cada una. La latencia es de ~ 20 milisegundos en *warm* sobre los embeddings precomputados.

El módulo expone cuatro *presets* clínicos predefinidos (tabla H.4) que cubren el espectro habitual de las consultas dermatológicas, con un total de 31 clases únicas. La opción por defecto en la interfaz es el preset más amplio (`all_dermatology`), elegido para mitigar el sesgo de selección documentado en la literatura sobre CLIP cuando se restringe artificialmente el espacio de clases.

Cuadro H.4: Presets clínicos del módulo M6.

preset	Clases	Uso clínico
<code>all_dermatology</code>	31	Default: el clínico no precategoriza
<code>common_dermatoses</code>	8	Dirigido a sospecha de patología inflamatoria
<code>infections</code>	9	Dirigido a sospecha de infección
<code>tumors_extended</code>	14	Dirigido a sospecha de tumor o lesión pigmentada

La nomenclatura y los recuentos de la tabla H.4 corresponden a la configuración inicial del prototipo; el catálogo de *presets* se amplió con posterioridad —con selecciones por subcategoría L2 y un ajuste de las claves de los *presets* etiológicos— sin alterar el diseño descrito.

Un hallazgo operativo documentado durante el despliegue (sección 5.1.6) es la sensibilidad extrema de DermLIP v2 a la formulación del *prompt*: el uso de etiquetas desnudas (e.g. ["`melanoma`", "`nevus`", "`eczema`"]) produce predicciones efectivamente aleatorias, mientras que el envoltorio clínico estandarizado (e.g. "*dermoscopy image of melanoma, malignant skin cancer with irregular borders and asymmetry*") lo restaura al rendimiento esperado. La curva de degradación observada sobre HAM10000 sitúa el punto

óptimo en 8–15 palabras por *prompt* con un rasgo clínico añadido (AUROC 0,854); fuera de este rango el rendimiento decae. El prototipo implementa *wrapping* automático en tres capas: presets predefinidos con descripciones ya envueltas, composable `useZeroShot.js` que aplica la plantilla “*dermoscopy image of {term}*” cuando la entrada del usuario contiene cinco o menos palabras, y conmutador en la interfaz que permite al dermatólogo desactivar el envoltorio cuando escribe descripciones completas propias.

H.4 Frontend e interfaz clínica

El frontend está implementado en Vue 3,5 con Tailwind CSS 4,2 y Vite 7, en tres idiomas (catalán, español, inglés) y con tema claro/oscuro conmutable. La vista principal `AnalyzeView` expone los resultados del pipeline en seis pestañas: CLASS (clasificación cerrada M1), SEG (segmentación M2 con overlay), CONC (conceptos M3), RAG (casos similares M4), REASON (razonamiento M5) y Z-SHOT (clasificación abierta M6). Vistas complementarias (`HistoryView`, `ValidationView`, `StatsView`) cubren la consulta del histórico paginado, la validación posterior por el dermatólogo y las estadísticas agregadas del sistema.

La interacción con el visor de lesiones (`LesionViewer`) permite zoom real sobre la imagen, superposición de la máscara con opacidad ajustable, y deslizador de umbral dinámico que recalcula la predicción de M1 sobre la marcha sin nuevas inferencias en el servidor. El módulo `ValidationPanel` expone tres opciones de validación (*correcto*, *parcial*, *incorrecto*) y permite el dibujo manual de *bounding boxes* alternativas como mecanismo de corrección, con persistencia en la tabla `derm_manual_annotations` para realimentar el reentrenamiento posterior.

H.5 Rendimiento operativo

La tabla H.5 sintetiza los tiempos medios medidos sobre el sistema desplegado.

Cuadro H.5: Rendimiento operativo del prototipo DermApIxel (medidas del 2026-04-05).

Métrica	Valor	Notas
Pipeline M1–M4 <i>end-to-end</i>	~ 315 ms (warm)	Tras carga inicial
Pipeline M1–M4 <i>cold</i>	~ 450 ms	Primera inferencia tras reinicio
M6 Zero-shot (3 clases) <i>warm</i>	~ 20 ms server	~ 25 ms incluyendo red
M6 Zero-shot (3 clases) <i>cold</i>	~ 25,5 ms	~ 46,9 ms incluyendo red
M6 <i>warmup</i> kernel PubMedBERT (7 clases)	614 ms	Una vez tras reinicio
VRAM total app M1–M4 + M6	4,40 GB	Sin cuantización ni <i>offloading</i>
VRAM MedGemma 27B Vision	54,9 GB	Coexiste con app principal
VRAM total ocupada	~ 59 GB	Sobre 128 GB disponibles
Speedup M6 frente a M1–M4	~ 30×	Por arquitectura ligera y <i>embeddings</i> cacheados

La latencia agregada de un análisis completo (M1–M4 + M5 con `gpt-4o-mini`) sobre una imagen de prueba es del orden de 6–8 segundos, dominada por el componente generativo del razonamiento clínico. La latencia percibida por el usuario es inferior gracias al patrón asíncrono: los resultados de M1–M4 aparecen en la interfaz antes que el razonamiento de M5, lo que permite al clínico revisar el diagnóstico cerrado mientras el LLM produce la justificación textual.

H.6 Estado de despliegue

A fecha de cierre del documento, el sistema se encuentra en producción *end-to-end* sobre el entorno de desarrollo (Windows local + DGX Spark sobre red LAN), con seis módulos operativos (M1–M6) y validación funcional sobre casos de prueba controlados. El sistema no se ha desplegado sobre la infraestructura sanitaria del HUSLL y no ha sido validado sobre cohorte prospectiva real, lo que se identifica como línea de continuación inmediata en sección 7.5.7. Los elementos identificados como condiciones operativas para el despliegue hospitalario son: integración con el sistema PACS mediante DICOM C-STORE, autenticación con Keycloak OIDC, HTTPS con certificado institucional, servicio `systemd` para arranque automático del

servidor de inferencia, y trazabilidad auditable conforme al Esquema Nacional de Seguridad (ENS) con logs encadenados con SHA-256. Ninguno de estos elementos forma parte del alcance del Trabajo de Fin de Grado declarado en sección 1.5.

H.7 Discusión: rol del prototipo en el trabajo

La construcción del prototipo no constituye objeto experimental del trabajo. Las cifras de rendimiento sobre las que descansa la defensa empírica del documento se obtienen directamente de los modelos descritos en el capítulo 3 mediante protocolos estándar (sección 3.6). El prototipo materializa la integración técnica entre esos modelos, valida la viabilidad operativa de su despliegue conjunto sobre hardware accesible, y constituye el entorno previsto para la validación clínica prospectiva descrita en sección 7.5.7.

Tres aportaciones técnicas merecen mención específica. Primero, la verificación de que seis modelos heterogéneos (PanDerm Large FT, SAM2.1-Large decoder FT, SAE, FAISS sobre Derm1M, DermLIP v2, MedGemma 27B) coexisten en la VRAM unificada de la DGX Spark con consumo agregado de ~ 59 GB sobre los 128 GB disponibles, sin cuantización ni *offloading*. Segundo, la cuantificación del coste operativo por proveedor LLM en M5, que sostiene la afirmación de sección 5.1.7 sobre la brecha entre encoders específicos y LLMs multimodales generalistas en términos económicos además de en términos de rendimiento. Tercero, la documentación operativa del hallazgo sobre sensibilidad al *prompt* en DermLIP v2 (sección 5.1.6), cuya mitigación mediante *wrapping* automático en tres capas (presets, composable, conmutador UI) constituye una práctica de ingeniería transferible a otros despliegues de modelos vision-lenguaje contrastivos en producción clínica.

El despliegue hospitalario completo, la validación prospectiva sobre cohorte real y la certificación CE como producto sanitario quedan fuera del alcance declarado y se identifican como líneas de continuación inmediatas en la sección 7.5 del capítulo 7.

H.8 Evolución a M1–M11: módulos castellanos del prototipo

En los meses posteriores a la integración M1–M6 (estado documentado en las secciones previas con fecha de cierre 2026-04-05), el prototipo incorporó tres módulos castellanos adicionales (M9, M10, M4-bis) más un ensemble ponderado (M11) sobre la ontología jerárquica de la Dra. R. Taberner descrita en el Anexo C. La motivación se alinea con la limitación operativa identificada en sección H.7: el clasificador cerrado M1 sobre HAM10000 no cubre la *fingerprint* clínica del archivo de la Dra. R. Taberner, basada en un vocabulario de 4 categorías L1, 43 subcategorías L2 y 367 subcategorías L3, mayoritariamente disjunto del de HAM10000. Los nombres M1b, M7, M9, M10, M4-bis y M11 se conservan tal como aparecen en `pipeline.py` para preservar la trazabilidad código-documento.

H.8.1 M7 – Clasificador unificado jerárquico *merged43+TTA*

M7 es PanDerm Large *fine-tuned* sobre las 43 clases L3 de la ontología unificada multi-dataset, entrenado con *weighted sampling* sobre los siete datasets viables del *mapping* ontológico. La inferencia aplica *Test-Time Augmentation* (TTA) con cinco augmentaciones (original, simetría horizontal, simetría vertical, rotación 90° y rotación 270°) promediando probabilidades *softmax*, no logits, por estabilidad numérica. La salida se proyecta jerárquicamente a L1 y L2 garantizando consistencia top-down. Sobre el conjunto de test fijo de DermapixelAI 1.0 alcanza L1 *accuracy* 0,947, L2 *accuracy* 0,819, L3 *accuracy* 0,797 y BAcc L3 0,818 (+4,72 pp BAcc con TTA respecto a la inferencia simple). La latencia *warm* es de ~ 80 ms. Tab UNIF del frontend, con vista jerárquica L1/L2/L3 y *badge* melanoma.

H.8.2 M9 – Dermapixel R0 (cabeza L2), clasificador L2 castellano supervisado

M9 es la implementación operativa de la cabeza supervisada L2 de Dermapixel R0 descrita en sección 4.12. Cabeza *fully-connected* 1024 → 38 sobre PanDerm Large con LoRA $r = 16$ insertado en los dos últimos bloques transformer (`attn.qkv`, `attn.proj`, `mip.fc1`, `mip.fc2`), entrenada sobre las 874 imágenes *train* del manifiesto filtrado de DermapixelAI 1.0 (1 062 imágenes; Anexo C). Las 38 clases L2 efectivas resultan

de consolidar las dos variantes ortográficas L2 *queratinización* detectadas en el análisis exploratorio del dataset. El *checkpoint slim* conserva únicamente los pesos LoRA y la cabeza FC (~ 2,3 MB); el encoder PanDerm Large permanece congelado y se reutiliza del módulo M1. La inferencia aplica TTA con cinco aumentaciones y latencia ~ 91 ms. Tab SPAN del frontend. La diferencia respecto a la rama contrastiva de Dermapixel R0 descrita en sección 4.13 es operacional: aquí la cabeza es supervisada con clases L2 fijas; allí es *zero-shot open-class* por alineamiento texto-imagen.

H.8.3 M10 – Seven-Point Checklist multitarea

M10 implementa el protocolo multitarea de sección 4.14 sobre el dataset Derm7pt [9]: MultitaskDerm7 con siete cabezas conceptuales (una por criterio dermatoscópico del *Seven-Point Checklist*: *pigment network, streaks, pigmentation, regression structures, dots and globules, blue whitish veil, vascular structures*) más una cabeza binaria melanoma/no-melanoma, montadas sobre el mismo encoder PanDerm Large + LoRA $r = 16$. La inferencia aplica TTA promediando *softmax* de las ocho cabezas y latencia ~ 90 ms. Tab 7–POI del frontend, con los siete criterios traducidos al castellano y el riesgo melanoma global. El módulo explota explícitamente las anotaciones conceptuales por imagen de Derm7pt, no aprovechadas en M1–M6 ni en otros experimentos del trabajo.

H.8.4 M4-bis – RAG castellano sobre DermapixelAI 1.0

M4-bis es un índice FAISS [27] IndexFlatIP sobre 874 *embeddings* PanDerm Large de 1024 dimensiones L2-normalizados, correspondientes al *split train+val* de DermapixelAI 1.0 (Anexo C). Para una imagen de consulta el módulo devuelve los k vecinos más similares por coseno con sus metadatos clínicos castellanos (*ontology_l1, ontology_l2, ontology_l3, case_id, case_title, case_text_preview, rosa_verified, year*) y el voto mayoritario por nivel jerárquico. M4-bis complementa al módulo M4 (sección H.3.4) sobre Derm1M en inglés: donde M4 recupera patrones visuales sobre un atlas masivo no etiquetado en castellano, M4-bis devuelve casos del propio archivo de la Dra. R. Taberner con su clasificación L1/L2/L3 verificada y el extracto del texto clínico original. La latencia *warm* es de ~ 0,5 ms (FAISS sobre 874 vectores). Tab RAG–I del frontend con barras de similitud y voto mayoritario por nivel.

H.8.5 M11 – Ensemble ponderado por AUROC y coherencia jerárquica

M11 es la combinación ponderada (*weighted*) de M1, M7, M9 y M4-bis por niveles L1/L2/L3. Los pesos se derivaron en dos pasos: en primer lugar, lectura directa de las AUROC reportadas en el capítulo 4 (M7 *merged43*+TTA es el clasificador más fiable global, con AUROC L1 = 0,873, L2 = 0,860, L3 = 0,813); en segundo lugar, ajuste empírico por coherencia jerárquica top-down sobre casos clínicos representativos. La iteración estable es la versión v1.7, cuyos pesos se reportan en la tabla H.6.

Cuadro H.6: Pesos del ensemble M11 v1.7 por nivel jerárquico. La entrada (*no aplica*) indica que el módulo correspondiente no emite predicción al nivel ontológico de la fila.

Nivel	M1 (HAM FT)	M7 (<i>merged43</i> +TTA)	M9 (Dermapixel R0)	M4-bis (RAG ES)
L1	1,0	1,0	0,5	0,3
L2	(no aplica)	1,5	1,0	0,5
L3	(no aplica)	1,5	(no aplica)	0,5

El *mapping* castellano-inglés exhaustivo (4 L1 + 26 L2 + 33 L3) colapsa las duplicaciones que aparecen cuando M7 emite la ontología en inglés (*merged43*) mientras que M9 y M4-bis lo hacen en castellano. Sin este *mapping*, el ensemble contaría dos veces la misma clase con cadenas distintas. La coherencia jerárquica queda garantizada: para una imagen donde L1 indica *Patología tumoral* con probabilidad elevada y L3 indica *Melanoma* con probabilidad relevante, L2 debe indicar *Tumores malignos* y no *Neoplasias melanocíticas benignas* (este último era el comportamiento del ensemble cuando los pesos eran M7 = 1,0 y M9 = 1,5 en L2, antes del ajuste v1.7). M11 se expone en el tab M11 del frontend como vista de consenso, posicionada en primer lugar.

H.8.6 Sistema de consenso de cinco módulos y *warning* de derivación urgente

El frontend incorpora un *banner* superior con cinco *chips* que resumen la lectura de malignidad de cinco módulos independientes (M1, M7, M9, SigLIP-LP y M10) más un sexto *chip* M4-bis con la ontología del vecino *top-1* castellano. Cada *chip* muestra una etiqueta *BEN / MAL / ?* y un *badge* global *Consenso parcial (X/5)* o *Consenso fuerte*. Cuando ≥ 2 módulos votan melanoma con probabilidad alta, el sistema emite un *warning* explícito (“X clasificadores detectan melanoma – derivación urgente – derivar a especialista”). El diseño replica el patrón clínico de segunda opinión entre dermatólogos: no se confía en un único clasificador, se busca convergencia entre criterios independientes (cabeza supervisada HAM, cabeza supervisada L3 multidataset, cabeza supervisada L2 castellana, sondeo lineal SigLIP, multitarea Derm7pt). Un *caveat* metodológico explícito acompaña la formulación: el voto actual es por mayoría sin ponderación clínica, lo que no captura el caso en el que un módulo emite una señal dominante (*p. ej.* M10 con probabilidad 0,95 de melanoma) frente a otros con confianza baja. Una iteración futura debería ponderar por confianza per-módulo o exponer un *score* de melanoma agregado calibrado con datos prospectivos.

H.8.7 Estrategias de seguridad clínica: ensemble para detección de melanoma

Más allá de la comparación de modelos individuales, resulta relevante explorar si la complementariedad entre arquitecturas puede explotarse para maximizar la sensibilidad diagnóstica. Esta cuestión es especialmente importante en melanoma, donde el coste clínico de un falso negativo es potencialmente muy superior al de un falso positivo. Por ello se evalúa un *ensemble* orientado explícitamente a maximizar el *recall* de melanoma sobre HAM10000.

Se combinan tres clasificadores independientes sobre el *split* de test de HAM10000 ($N = 1\,232$ imágenes, 70 melanomas): M1 (PanDerm Large *fine-tuned* sobre HAM10000), SigLIP-Large SO400M con sondeo lineal sobre los *embeddings* de 1 152 dimensiones, y M7 (clasificador unificado sobre el *merged43* del dataset armonizado, descrito en el Anexo H).

Cuadro H.7: Ensemble sobre HAM10000 ($N = 1\,232$, 70 melanomas). *Recall top-3*: la clase melanoma aparece entre las tres primeras del ranking. FP mel: falsos positivos melanoma (imágenes no-melanoma marcadas).

Configuración	Acc	BAcc	AUROC	Mel rec. top-1	Mel rec. top-3	FP mel
M1 (PanDerm FT)	0,919	0,813	0,986	0,714 (50/70)	0,971 (68/70)	36
SigLIP-L LP	0,900	0,776	0,971	0,614 (43/70)	0,986 (69/70)	31
Avg M1 + SigLIP	0,917	0,836	0,986	0,686	0,986	32
MaxMel M1 + SigLIP	0,909	0,832	0,985	0,771	1,000	50
OR top-3 M1 + SigLIP	—	—	—	—	1,000 (70/70)	885

La combinación OR *top-3* de M1 y SigLIP alcanza un *recall* de melanoma del 100 % (70 de 70), pero a costa de 885 falsos positivos sobre las 1 232 imágenes del test: la sensibilidad máxima se obtiene marcando como sospechosa cerca del 72 % del conjunto, lo que reduce drásticamente la precisión y acota su utilidad a un escenario de *cribado*, nunca de decisión diagnóstica.

El principal hallazgo de esta sección, sin embargo, no es ese 100 % —una cifra trivialmente alcanzable ampliando el margen de sospecha de cualquier clasificador— sino la evidencia de complementariedad entre una arquitectura especializada (M1, PanDerm *fine-tuned in-domain*) y una generalista (SigLIP con sondeo lineal): ambas recuperan melanomas distintos. Los dos melanomas que M1 omite en *top-3* (ISIC_0024886.jpg e ISIC_0030360.jpg) sí los recupera SigLIP y el único melanoma que SigLIP no sitúa en *top-3* sí lo recupera M1. Este resultado indica que los errores de ambos modelos no están completamente correlacionados —condición necesaria para que una estrategia de *ensemble* aporte un beneficio clínico real, y no una mera redundancia— y sugiere que cada arquitectura explota representaciones parcialmente diferentes de la lesión. M7, evaluado sobre el subconjunto de 198 imágenes con predicción simultánea de los tres modelos (12 melanomas), no recupera melanomas adicionales sobre el par, pero aporta cobertura sobre las 43 clases ontológicas del dataset armonizado.

Tres *caveats* acompañan la interpretación de este resultado: (i) el *recall* del 100 % es *top-3*, no *top-1*; (ii) el tamaño muestral de melanomas es $N = 70$, con intervalos de confianza al 95 % amplios; (iii) no existe

validación prospectiva sobre cohorte hospitalaria. El resultado se interpreta como prueba de concepto para un escenario de cribado oportunista, no como sustituto del juicio clínico.

H.8.8 Migración a AMQP (2026-04-13)

Desde el 13 de abril de 2026 toda comunicación entre el backend Docker (PC Windows) y el servidor de inferencia (DGX Spark) circula por RabbitMQ (cola `derm.inference` para `requests`, `derm.results` para `replies`). Anteriormente coexistían HTTP directo y AMQP; tras la migración, HTTP queda reservado a `/health` y depuración. La configuración mantiene abierto el puerto 5673 en dirección backend → Spark. Los beneficios operativos son tres: resiliencia (los mensajes persisten ante caída transitoria del servidor de inferencia con reintento automático), trazabilidad auditable de cada `request` a través del panel de gestión de RabbitMQ, y desacoplamiento temporal entre frontend y GPU. La lección operacional documentada es que tras cualquier cambio del backend Docker es obligatorio reconstruir sin caché (`docker compose build --no-cache && docker compose up -d`) para que los nuevos `consumers` AMQP se registren correctamente.

H.8.9 Evaluación end-to-end del prototipo extendido

Para validar el comportamiento integrado de los módulos M1–M11 se ejecutó un *batch test* sobre 454 imágenes del conjunto de test de HAM10000 no vistas previamente por el prototipo. Los hallazgos cuantitativos justifican operacionalmente los pesos del ensemble M11 v1.7 y la presencia de SigLIP-LP como red de seguridad. M7 supera a M1 sobre HAM10000 con BAcc 0,886 frente a BAcc 0,743, lo que justifica el peso $M7 = 1,5$ en L2/L3 del ensemble a pesar de que M1 está *fine-tuned* específicamente sobre HAM. El *recall* de melanoma por módulo es de 40% para M1, 60% para M7 y 80% para el OR *top-3* entre M1, M7 y SigLIP-LP, lo que justifica directamente el patrón de consenso de cinco módulos como red de seguridad clínica. El primer nivel jerárquico (Tumoral / Inflamatoria / Infecciosa / Genodermatosis) alcanza *accuracy* en el intervalo [0,80, 1,00] sobre las cuatro categorías, mientras que los errores *fine-grained* se concentran en L2 y L3, comportamiento coherente con la naturaleza progresivamente más específica de la jerarquía ontológica. TTA añade +74 ms de latencia por imagen y +4,72 pp de BAcc L3, compromiso latencia-rendimiento replicado además en M9 y M10. La evidencia operacional cierra el ciclo entre las métricas del capítulo 4 y el comportamiento del sistema integrado: los módulos castellanos M7–M11 mejoran las métricas críticas (*recall* de melanoma, BAcc sobre L2/L3) en el escenario clínico final sin sustituir a M1–M6.



ABLACIÓN: MODELO FUNDACIONAL INGLÉS (DERMLIP) CON TRADUCCIÓN ES-EN

Este anexo documenta una ablación independiente que cuantifica el *trade-off* entre la rama contrastiva de Dermapixel R0 defendida en la sección 4.13 y un *wrapper* alternativo basado en un modelo fundacional dermatológico inglés (DermLIP v2) con traducción de etiquetas ES-EN, sobre el mismo conjunto de test *holdout* de DermapixelAI 1.0.

I.1 Motivación

Una pregunta legítima planteada durante la revisión paper-grade de la rama contrastiva de Dermapixel R0 es si el esfuerzo experimental documentado en la sección 4.13 (cinco iteraciones de entrenamiento cross-modal castellano) se justifica frente a una alternativa pragmática: emplear un modelo fundacional dermatológico inglés ya alineado imagen-texto, sin entrenar ningún modelo adicional, sobre las etiquetas castellanas traducidas al inglés. Esta ablación cuantifica el *trade-off* entre ambas estrategias sobre el mismo conjunto de test *holdout* de DermapixelAI 1.0.

I.2 Protocolo experimental

El modelo fundacional inglés evaluado es DermLIP v2 (PanDerm-base-w-PubMed-256), un sistema CLIP-style con codificador visual PanDerm-Base y codificador textual PubMedBERT, preentrenado contrastivamente sobre el dataset Derm1M [2] ($\approx 403\,000$ pares imagen-texto). Ambas torres permanecen congeladas; no se entrena ningún parámetro. Las 54 clases L3 representadas en el test se tradujeron al inglés clínico mediante un glosario estándar (Bologna/Rook) con verificación cruzada de unicidad, y por cada clase se generó un *rich prompt* clínico en inglés (~ 37 palabras, longitud equiparable a los *prompts* castellanos de Dermapixel R0). La inferencia replica el protocolo híbrido de la sección 4.13 (prototipos visuales sobre *train* más texto rico, régimen $H6$ $w_v = 0,3$, $w_t = 0,7$) sobre las mismas 101 imágenes de test y 54 clases.

Adicionalmente, se midió el *eje idioma puro* sobre el propio *checkpoint* v4 de Dermapixel R0: el mismo modelo evaluado con los *prompts* castellanos originales frente a los mismos *prompts* traducidos al inglés, aislando el efecto del idioma de consulta sobre una alineación cross-modal fija.

I.3 Resultados

La tabla I.1 reúne las seis configuraciones evaluadas sobre el mismo conjunto de test.

Cuadro I.1: Comparativa cuantitativa de Dermapixel R0 v4 (*headline*) frente a la ablación con modelo fundacional inglés DermLIP v2 más traducción ES-EN. Test *holdout* DermapixelAI 1.0, $N = 101$, 54 clases L3 representadas; régimen *H6 hybrid v30_r70* salvo donde se indica.

Sistema	Régimen	acc@1 L3	BAcc L3	acc@5 L3
Dermapixel R0 v4	H6 hybrid (castellano)	0,2475	0,2685	0,4455
Dermapixel R0 v5	H6 hybrid (castellano)	0,2079	0,2185	0,4158
Dermapixel R0 v4	H6 hybrid (inglés)	0,2277	0,2556	0,4554
DermLIP v2	H6 hybrid (inglés)	0,2871	0,3667	0,6436
DermLIP v2	templates+rich (inglés)	0,3861	0,4099	0,6931
DermLIP v2	visual-only	0,2178	0,2278	0,4851

I.4 Interpretación

DermLIP v2 inglés supera a Dermapixel R0 v4 en el régimen comparable *H6* (0,2871 frente a 0,2475, +3,96 pp) y lo supera con mayor margen en su mejor régimen de plantillas más texto rico (0,3861, +13,86 pp), confirmando la hipótesis de partida de que el cuello de botella de Dermapixel R0 residía en la *escala* de la alineación cross-modal y no en la formulación textual. Un modelo fundacional preentrenado sobre $\approx 403\,000$ pares supera a un CLIP castellano dedicado entrenado sobre 854 pares, incluso pagando el ruido de la traducción de etiquetas.

El eje idioma matiza esta lectura: sobre el mismo *checkpoint* v4, la consulta en castellano supera a la consulta en inglés (0,2475 frente a 0,2277 en *H6*, +1,98 pp; y 0,1287 frente a 0,0891 en *rich-only*, +3,96 pp), mientras que el régimen visual-only permanece idéntico (0,1683). Dermapixel R0 sí captura un componente específico del registro clínico castellano, si bien de segundo orden frente a la ventaja de escala del modelo fundacional inglés.

El *trade-off* entre los dos enfoques es, por tanto, explícito:

- **DermLIP inglés más traducción:** rendimiento bruto superior, cero entrenamiento, pero dependencia de traducción de etiquetas y de un dataset de preentrenamiento externo (Derm1M [2]), con la consiguiente pérdida potencial de matices clínicos castellanos no traducibles uno a uno.
- **Dermapixel R0 (rama contrastiva):** entrenamiento dedicado sobre 854 pares reales castellanos, preservación de la *fingerprint* clínica del archivo de la Dra. R. Taberner, inferencia sin traducción en *runtime* y operación *on-prem* compatible con la ruta de extensión al banco hospitalario HUSLL (sección 7.5.4).

La conclusión es que la rama contrastiva de Dermapixel R0 no se justifica como sistema de mayor rendimiento bruto en *zero-shot* L3, sino por sus propiedades operativas de privacidad, especificidad lingüística y autonomía de despliegue. La superioridad de DermLIP refuerza, además, el diseño de la línea de continuación documentada en la sección 7.5.4: la palanca pendiente para Dermapixel R0 es la anotación experta dirigida *in-domain* sobre las clases L3 con peor cobertura, no la escala genérica.

I.5 Limitaciones de la ablación

La comparación no está equiparada en datos: DermLIP v2 se preentrena sobre $\approx 403\,000$ pares frente a los 854 pares castellanos de Dermapixel R0, y los *backbones* visuales difieren (PanDerm-Base contrastivo frente a PanDerm-Large congelado con LoRA). El resultado debe leerse como “modelo fundacional inglés grande más traducción” frente a “CLIP castellano dedicado pequeño”, no como un contraste de igual presupuesto de datos.

La carga de DermLIP v2 requiere el *fork* de `open_clip` del proyecto Derm1M: la implementación estándar instancia un *Vision Transformer* genérico e ignora silenciosamente la torre visual PanDerm-Base

(152 claves ausentes, codificador visual aleatorio), un modo de fallo verificado y evitado en esta ablación empleando el mismo *loader* que el módulo de producción (Anexo H).

La verificación de solapamiento con Derm1M se realizó a nivel de fuente: las fuentes constituyentes de Derm1M (vídeo, foros, literatura biomédica y libros de texto en inglés y chino) no incluyen ningún blog dermatológico español, y no se hallaron coincidencias para *dermapixel* ni *taberner* en las 417 257 filas del *manifest*. El archivo *Dermapixel* es privado y no figura como fuente, lo que sustenta razonablemente la asunción de ausencia de *leakage*; no se ejecutó una comparación perceptual exhaustiva imagen a imagen. La traducción ES-EN introduce, finalmente, un ruido no cuantificado en las etiquetas.

I.6 Detalles de reproducibilidad de la rama contrastiva

Este apartado recoge los detalles de procedencia y reproducibilidad de la rama contrastiva de *Dermapixel* R0 (sección 4.13), separados del cuerpo por no afectar a las conclusiones científicas.

Generación de *captions* sintéticas. Las ocho perspectivas clínicas por imagen se generan mediante un modelo de lenguaje grande a partir del texto original de cada caso del blog y de sus metadatos. El total alcanza 7 680 *captions* sobre 960 imágenes (fase v1-v4); 102 imágenes fallan la generación automática y conservan únicamente el texto base. El coste real de generación es de 32,54 USD (0,030 USD por imagen completa) y la longitud media es de 87,5 palabras por *caption*. Combinadas con las nueve variantes textuales base (plantillas L1/L2/L3, jerárquicas L1L2L3, título de blog, tres *chunks* de *case_text* y *diagnosis_raw*), el dataset de entrenamiento alcanza del orden de 22 000 pares (imagen, texto), muestreados por hash determinista (*seed*, *epoch*, *image_id*).

Tiempos de entrenamiento. Sobre NVIDIA DGX Spark GB10: ~ 18 min (v1), ~ 3 min (v2), ~ 5 min (v3), ~ 9 min (v4) y ~ 54 min (v5).

Lección metodológica: longitud de las *captions*. La generación de *captions* sintéticas del dataset externo de v5 (coste 42,33 USD) reveló la importancia de calibrar la longitud objetivo respecto al umbral del verificador automático posterior. Un primer intento con rango 30-40 palabras produjo una tasa de rechazo del 54 % —las *captions* se agrupaban en el suelo del rango y el verificador descartaba las más cortas—; recalibrar el objetivo a 40-55 palabras redujo el rechazo a cero. La regla operativa derivada es dimensionar la longitud objetivo con margen explícito sobre el umbral mínimo aceptable, no sobre la media deseada.

I.7 Material complementario de la rama contrastiva

Este apartado recoge las tablas y figuras de detalle de la sección 4.13, desplazadas del cuerpo por constituir diagnóstico secundario sin alterar las conclusiones científicas allí defendidas.

I.7.1 Cabeza supervisada L2: *best-checkpoint* frente a últimas épocas

La cabeza supervisada L2 de *Dermapixel* R0 (sección 4.12) se reporta sobre el test L2 ($N_{\text{test}} = 36$) con dos estimaciones: el *best val checkpoint* (selección por máxima BAcc de validación) y la media de las últimas cinco épocas sin selección, esta última como comportamiento asintótico sin la varianza del criterio de selección (tabla I.2).

Cuadro I.2: Métricas de Dermapixel R0 (cabeza supervisada L2) sobre el conjunto de test L2 de DermapixelAI 1.0 ($N_{\text{test}} = 36, 38$ clases con queratinización consolidada). Cifras: media $\pm$ desviación estándar sobre tres semillas ({42, 43, 44}). La columna *best val* aplica selección por máxima BAcc de validación; la columna *últimas 5 ép.* promedia las cinco épocas finales sin selección. Mejor por fila en negrita.

Métrica	Best val checkpoint	Media últimas 5 ép.
Acc@1	0,250 $\pm$ 0,000	0,209 $\pm$ 0,005
Acc@3	0,500 $\pm$ 0,023	0,457 $\pm$ 0,011
BAcc	0,363 $\pm$ 0,007	0,309 $\pm$ 0,006
AUROC	0,855 $\pm$ 0,006	0,837 $\pm$ 0,008
W-F1	0,218 $\pm$ 0,013	—
Kappa	0,220 $\pm$ 0,001	—

La estabilidad entre semillas es alta (desviación $\leq 0,013$, $\leq 0,008$ sobre AUROC y BAcc). La diferencia entre el *best val checkpoint* y la media de las últimas cinco épocas (+5,4 pp BAcc, +1,8 pp AUROC, +4,1 pp Acc@1) refleja un sobreajuste suave análogo al del FT parcial denso (sección 4.10.3), atenuado por la restricción al 0,17 % de parámetros entrenables de LoRA.

I.7.2 Barrido de épocas de la iteración v3




Figura I.1: Barrido de épocas de la iteración contrastiva v3 de Dermapixel R0 sobre el conjunto de test de 101 imágenes. *Accuracy@1* L1, L2 y L3 y *val i2t_R@5* frente al paso de entrenamiento. L3 oscila en el intervalo [0,04, 0,12] a lo largo de las diez épocas sin aproximarse al objetivo $\geq 0,25$, mientras que *val i2t_R@5* alcanza su máximo en la época 2 y desciende con el entrenamiento conjunto adicional del codificador visual.

I.7.3 Techo de *Linear Probing* y diagnóstico mecánico

Para entender por qué ningún cambio textual mueve el *zero-shot* L3 se mide el techo *Linear Probing* sobre las *features* 1024-D del encoder visual, con script idéntico para v2 (frozen) y v3 (LP en épocas 2 y 6). La tabla I.3 reúne los tres puntos de la comparación.

Cuadro I.3: Techo *Linear Probing* supervisado sobre *features* 1024-D del image encoder. Comparativa *frozen* (v2 e7) frente a image-LoRA tras entrenamiento adicional (v3 época 6). Métrica: *accuracy@1*. Las cifras de v3 corresponden a la evaluación intermedia conservada del Sprint97; la reejecución posterior arroja desviaciones $< 0,01$ absolutas, consistentes con ruido de muestreo ($N = 101$) y sin alterar la lectura ($+0,01 \approx$ ruido).

Nivel	LP v2-e7 frozen	LP v3 best.pt (e2)	LP v3 e6 (+image train)	Δ frozen $\rightarrow$ trained
L1 (4 vías)	0,584	0,584	0,594	+0,01
L2 (38 vías)	0,214	0,214	0,225	+0,01
L3 (225 vías)	0,079	0,079	0,089	+0,01

Dos observaciones estructuran el diagnóstico. Primero, el *zero-shot* L3 de v1/v2/v3 ($\sim 0,13$) supera ya el techo LP supervisado (0,079–0,089) sobre el mismo encoder frozen: las *features* 1024-D del PanDerm-Large congelado no separan linealmente los diagnósticos castellanos finos, y ningún ajuste textual puede extraer información que las *features* visuales no contienen. Segundo, la LoRA visual de v3 (últimos cuatro bloques, 1,05 M parámetros) eleva el techo LP sólo +0,01 por nivel, dentro del ruido: capacidad insuficiente para reesculpir las *features* en el régimen *fine-grained* castellano (veredicto “*image LoRA did not help*”: no destruye el preentrenamiento —el LP nunca cae— pero tampoco lo mejora).

El mecanismo por el que el *zero-shot* de v3 cae sin que el LP suba es que el entrenamiento conjunto desplaza los embeddings visuales hacia el espacio de captions ricas y los aleja del de plantillas de nombre de clase: L1 *zero-shot accuracy@1* cae 0,426 (e2) $\rightarrow$ 0,287 (e7) mientras el *train loss* sigue bajando a 0,29, señal de sobreajuste *rich-caption*. La capacidad arquitectónica (v4) es la palanca efectiva; la escala externa genérica (v5) no. En corpora clínicos pequeños de alta especificidad lingüística, la palanca correcta es ampliar la capacidad del lado visual sobre el propio dataset, no incorporar imágenes externas estilísticamente discordantes.

I.7.4 Calibración por *temperature scaling*

Los logits *zero-shot* de la rama contrastiva están severamente sobreconfiados, propiedad esperada en arquitecturas CLIP-style con InfoNCE. La calibración con *temperature scaling* de un parámetro escalar [35] sobre los 107 pares de validación reduce el ECE sobre los 101 pares de test (tabla I.4, figura I.2).

Cuadro I.4: Calibración post-hoc por *temperature scaling* sobre la iteración contrastiva v4 de Dermapixel R0. Ajuste del escalar τ por optimización LBFGS sobre 107 pares de validación; ECE medido sobre 101 pares de test. La calibración sobre v5 no converge (la optimización LBFGS diverge sobre el espacio embebido *image-LoRA* expandido y $\tau \rightarrow 0$), por lo que queda registrada como limitación metodológica abierta.

Nivel	ECE antes	ECE después	τ
L3 (v4)	0,7262	0,0213	0,4165

I. ABLACIÓN: MODELO FUNDACIONAL INGLÉS (DERMLIP) CON TRADUCCIÓN ES-EN




Figura I.2: Diagrama de fiabilidad sobre L3 antes y después de *temperature scaling* ($\tau = 0,4165$) sobre la iteración contrastiva v4 de Dermapixel R0. ECE desciende de 0,7262 a 0,0213 (−97%). La calibración escalar de un parámetro restaura la interpretabilidad probabilística de los logits sin alterar el *ranking* entre clases.

La reducción del ECE es del −97% sobre L3 con un único parámetro escalar. Convergente con la sensibilidad de DermLIP (sección 4.7): sin calibración post-hoc, las probabilidades de un sistema CLIP-style *zero-shot* castellano no son interpretables como confianza clínica, por lo que el despliegue debe incorporar este escalado como capa final ajustado sobre el archivo de destino. La extensión a v5 no converge ($\tau \rightarrow 0$ sobre el espacio *image-LoRA* expandido), limitación que no afecta al resultado principal de v4.

I.7.5 Diagnóstico cuantitativo del techo sobre L2

La tabla I.5 sitúa la iteración contrastiva v2 en *zero-shot* L2 frente a las dos referencias internas del capítulo de resultados (sección 4.10 y 4.12).

Cuadro I.5: Rama contrastiva de Dermapixel R0 *zero-shot* L2 frente a las dos referencias internas del capítulo sobre el mismo nivel ontológico. Las tres referencias evalúan sobre el conjunto de test de DermapixelAI 1.0; la cifra de la iteración v2 corresponde al test de 101 imágenes del *split* per-case del experimento contrastivo y las dos restantes al test fijo $N_{\text{test}} = 36$ de la sección 4.10. La comparación es indicativa por la diferencia muestral.

Sistema	Régimen	Acc@1 L2	Observaciones
LP PanDerm Large (referencia, tabla 4.15)	Supervisado L2 cerrado	0,250	38 clases, $N_{\text{test}} = 36$
Dermapixel R0 cabeza L2 (tabla I.2)	Supervisado L2 cerrado	0,250	38 clases, $N_{\text{test}} = 36$
Dermapixel R0 contrastivo v2	<i>Zero-shot</i> open	0,133	23 clases efectivas, $N_{\text{test}} = 101$

La jerarquía entre regímenes es la esperada: la cabeza supervisada cerrada con LoRA (Dermapixel R0, cabeza L2) alcanza Acc@1 0,250 sobre L2, frente a 0,133 de la rama contrastiva *zero-shot open-class* (v2) sobre las 23 clases efectivas del test per-case. La diferencia operativa es la capacidad de la rama contrastiva de aceptar consultas textuales libres en castellano sin fijar el vocabulario, propiedad explotada en el módulo RAG del prototipo (Anexo H).

I.7.6 Síntesis de las cinco iteraciones

La tabla I.6 sintetiza la trayectoria completa de la rama contrastiva, articulando por iteración la configuración LoRA, el régimen de inferencia, las dos cifras de referencia (L3 *accuracy@1 zero-shot* y lift de recuperación *i2t R@5*) y la lectura asociada.

Cuadro I.6: Comparativa de las cinco iteraciones del entrenamiento contrastivo de Dermapixel R0 sobre el dataset DermapixelAI 1.0. Régimen evaluativo *zero-shot* L3 sobre 101 imágenes de test (54 clases L3 representadas), *H6 hybrid* v30_r70 (combinación 30% prototipos visuales + 70% texto rico) aplicado de forma homogénea a las cinco iteraciones. v4 queda a 0,0025 del objetivo fijado a priori de 0,25 acc@1 L3 (dentro del ruido de muestreo) mediante expansión arquitectónica (*image-LoRA* $r = 32$ sobre 12 bloques + *ensemble* híbrido texto-visual). v5 confirma negativamente que la escala externa genérica con *captions* sintéticas no supera v4. Para v1–v3 los prototipos visuales derivan del espacio embebido del *checkpoint* sin LoRA visual; v4–v5 emplean prototipos sobre el espacio embebido con *image-LoRA* expandido. La comparativa permanece interpretable porque los prototipos derivan del propio espacio embebido del *checkpoint* evaluado. Provenance: commit d0190c3 del repositorio `spanderm-clip`. Las cifras Linear Probing BAcc L2 absolutas para v4 (0,1860) y v5 (0,2871) proceden de los ficheros JSON `eval_v5/linear_probe_v4ref.json` y `eval_v5/linear_probe_v5.json`; el delta relativo +54,4% queda confirmado.

Versión	LoRA texto	LoRA visual	acc@1 L3	Lift i2t R@5	LP BAcc L2	Notas
v1	—	—	0,1782	—	—	Baseline e5 <i>full FT</i>
v2	$r = 16, \alpha = 32$	—	0,1980	14,0×	—	Pico retrieval rich
v3	$r = 16, \alpha = 32$	$r = 16$, últ. 4/24	0,1980	—	—	Image-LoRA infradotado
v4	$r = 32, \alpha = 64$	$r = 32$, últ. 12/24	0,2475	12,4×	0,1860	A 0,0025 del objetivo
v5	$r = 32, \alpha = 64$	$r = 32$, últ. 12/24	0,2079	10,8×	0,2871	FLAT: escala externa (+54,4% relativo sobre v4)

Nota histórica. Los valores *rich-only baseline* (~30–80 palabras/clase) fueron 0,1287 (v1), 0,1386 (v2) y 0,1089 (v3); la transición al régimen *H6 hybrid* homogéneo de esta tabla permite la comparativa *cross-checkpoint* (detalle en Anexo G).

El experimento articula tres ejes. La capacidad arquitectónica (v3→v4) es la palanca efectiva: el cuello de botella reside en el *image encoder*, no en la formulación textual. La escala externa (v5) queda *flat-to-negative*, convergente con la sensibilidad de DermLIP al tokenizador (sección 4.7). El eje de supervisión conceptual —anotaciones del *Seven-Point Checklist* [9] o del Grupo A (Anexo F)— queda abierto como línea de aprendizaje activo dirigido (sección 7.5.4). El experimento valida así la utilidad de PanDerm Large para tareas castellanas más allá del LP/FT supervisado (v4 a 0,0025 del umbral objetivo L3 0,25) y establece una metodología reproducible para evaluaciones CLIP-style sobre archivos privados de pequeña escala.

ABLACIONES COMPLEMENTARIAS SOBRE DERMAPIXELAI 1.0

Este anexo recoge varios estudios complementarios sobre DermapixelAI 1.0 que confirman, sin desplazarla, la línea experimental principal del capítulo 4 (secciones 4.10 y 4.11): la validación del procedimiento de etiquetado del dataset, tres variantes de clasificación sobre *embeddings* congelados —cabezas alternativas, función de pérdida y *Test-Time Augmentation*— y dos extensiones con codificadores generalistas y arquitecturas de inferencia alternativas. Ninguno modifica las conclusiones del cuerpo principal; se documentan aquí por completitud y trazabilidad.

J.1 Validación del procedimiento de etiquetado: subestudio *rosa_verified*

La sección 4.10 resume el subestudio que cuantifica si las etiquetas etiológicas derivadas de la ontología, no revisadas individualmente por la dermatóloga, degradan el rendimiento. La tabla J.1 reporta la comparación completa, por sondeo lineal, entre el subconjunto verificado caso a caso (*rosa_verified*=True, $N = 919$; train = 744, test = 32) y el dataset completo (*all_verified*, $N = 1062$; train = 874, test = 36), sobre los tres niveles ontológicos.

Cuadro J.1: Subestudio *rosa_verified*: comparación entre el subconjunto verificado caso a caso por la dermatóloga ($N_{\text{train}} = 744$, $N_{\text{test}} = 32$) y el dataset completo ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$). Entre corchetes, IC95 % por *bootstrap* estratificado.

Modelo	Subconjunto	Nivel	Acc	BAcc	W-F1
PanDerm Large	<i>rosa_true_only</i>	L1	0,719 [0,594–0,844]	0,747 [0,646–0,865]	0,700 [0,550–0,841]
PanDerm Large	<i>all_verified</i>	L1	0,750 [0,639–0,861]	0,735 [0,637–0,835]	0,722 [0,596–0,845]
PanDerm Large	<i>rosa_true_only</i>	L2	0,250 [0,188–0,344]	0,250 [0,203–0,313]	0,227 [0,150–0,304]
PanDerm Large	<i>all_verified</i>	L2	0,250 [0,167–0,333]	0,265 [0,206–0,338]	0,223 [0,139–0,291]
PanDerm Large	<i>rosa_true_only</i>	L3	0,167 [0,167–0,167]	0,176 [0,176–0,176]	0,125 [0,117–0,139]
PanDerm Large	<i>all_verified</i>	L3	0,179 [0,143–0,214]	0,184 [0,158–0,211]	0,143 [0,100–0,184]
PanDerm Base	<i>rosa_true_only</i>	L1	0,625 [0,469–0,781]	0,523 [0,326–0,735]	0,618 [0,451–0,773]
PanDerm Base	<i>all_verified</i>	L1	0,639 [0,472–0,778]	0,570 [0,371–0,751]	0,624 [0,457–0,760]

J.2 Ranking L3 por prototipos coseno de Dermapixel R0

La sección 4.12 resume el ranking del nivel L3 de Dermapixel R0 por prototipos coseno (media de las representaciones de entrenamiento por clase). La tabla J.2 reporta las cifras completas sobre las 250 clases efectivas del vocabulario de entrenamiento.

Cuadro J.2: Ranking L3 por prototipos coseno de Dermapixel R0 sobre el conjunto de test de DermapixelAI 1.0 (250 clases efectivas del vocabulario de entrenamiento). Cifras: media $\pm$ desviación estándar sobre tres semillas. La columna $\times$ azar reporta el factor de mejora respecto a la asignación aleatoria uniforme sobre 250 clases ($1/250 = 0,004$).

Métrica	Media	Std	$\times$ azar
Acc@1	0,167	0,000	$\times 42$
Acc@3	0,259	0,013	$\times 22$
Acc@5	0,296	0,026	$\times 15$
BAcc	0,148	0,000	—

J.3 Cabezas alternativas sobre embeddings congelados

Sobre los mismos *embeddings* de PanDerm Large utilizados en la tabla 4.15 se evalúan tres cabezas adicionales: k -vecinos más cercanos con distancia coseno ($k = 10$, valor óptimo dentro de $k \in \{1, 5, 10\}$), perceptrón multicapa con una capa oculta de 512 unidades y *dropout* 0,3 (MLP 512), y regresión logística con `class_weight='balanced'` (LogReg *balanced*). El protocolo de partición es el del split fijo de la tabla 4.15 ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). La tabla J.3 recoge la AUROC *one-vs-rest*, métrica discriminativa robusta al desbalance, como criterio comparativo.

Cuadro J.3: Cabezas alternativas sobre *embeddings* congelados de PanDerm Large (test fijo de DermapixelAI 1.0). AUROC *one-vs-rest* por nivel ontológico. LP: regresión logística estándar (referencia tabla 4.15); kNN $k = 10$: k -vecinos con distancia coseno; MLP 512: perceptrón multicapa con 512 unidades ocultas y *dropout* 0,3; LogReg *balanced*: regresión logística con `class_weight = balanced`. Mejor valor por nivel en negrita.

Cabeza	L1 (4 cls)	L2 (38 cls)	L3 (224 cls)
LP (referencia)	0,796	0,793	0,813
kNN $k = 10$	0,752	0,698	0,694
MLP 512	0,817	0,812	0,827
LogReg <i>balanced</i>	0,797	0,800	0,810

El MLP de 512 unidades alcanza la mejor AUROC sobre los tres niveles, con incrementos modestos pero consistentes sobre la cabeza lineal de referencia: +2,1 pp en L1 (0,796 $\rightarrow$ 0,817), +1,9 pp en L2 (0,793 $\rightarrow$ 0,812) y +1,4 pp en L3 (0,813 $\rightarrow$ 0,827). La regresión logística con re-ponderación de clases mantiene Acc@1 idéntico al LP estándar y mejora la BAcc sobre L1 (0,703 frente a 0,735 del LP estándar dentro de los IC95% solapados), sin diferencias relevantes sobre L2 y L3. La cabeza k -NN queda por debajo de las cabezas paramétricas en los tres niveles, lo que se interpreta como insuficiente densidad local en el espacio de *embeddings* para $N_{\text{train}} = 874$ frente a un vocabulario de 224 clases L3. La elección de la regresión logística estándar como cabeza primaria en la tabla 4.15 se mantiene defendible: la mejora absoluta del MLP no compensa la pérdida de interpretabilidad lineal de los coeficientes ni la mayor sensibilidad a la inicialización aleatoria, especialmente con el tamaño muestral del test.

J.4 Función de pérdida: Cross-Entropy frente a Focal

La cola larga severa del dataset, particularmente acusada en el nivel L3 (77% de las clases con ≤ 5 ejemplos de entrenamiento, 3,9 muestras por clase de media en *train*, ver Anexo C), motiva contrastar la pérdida de entropía cruzada estándar con *Focal Loss* de Lin et al. 2017, diseñada explícitamente para mitigar

el efecto del desbalance reduciendo el peso de los ejemplos fáciles vía el factor $(1 - p_t)^\gamma$. Sobre los *embeddings* congelados de PanDerm Large del split fijo de la tabla 4.15 se reentrena la cabeza lineal con *Focal Loss* bajo dos parámetros de focalización ($\gamma \in \{1,0, 2,0, 5,0\}$) y dos regímenes de ponderación de clase (`class_weight = None` frente a `class_weight = balanced`), optimizada con LBFGS y evaluada sobre el mismo conjunto de test que el sondeo lineal estándar. La tabla J.4 reporta la mejor variante por nivel junto a las dos referencias previas (LP CE estándar, LogReg *balanced*) de la tabla J.3.

Cuadro J.4: Función de pérdida sobre *embeddings* congelados de PanDerm Large (test fijo de DermapixelAI 1.0, $N_{\text{test}} = 36$ en L1/L2 y $N_{\text{test}} = 28$ en L3). LP CE: regresión logística con entropía cruzada estándar (referencia tabla 4.15); LogReg *balanced*: re-ponderación inversa por frecuencia de clase (tabla J.3); *Focal* γ : pérdida focal sin re-ponderación con parámetro de focalización indicado. Mejor valor por columna y nivel en negrita.

Nivel	Pérdida	Acc@1	BAcc	AUROC
L1 (4 cls)	LP CE (referencia)	0,750	0,735	0,796
L1 (4 cls)	LogReg <i>balanced</i>	0,694	0,703	0,797
L1 (4 cls)	<i>Focal</i> $\gamma = 2,0$	0,778	0,768	0,800
L2 (38 cls)	LP CE (referencia)	0,250	0,265	0,793
L2 (38 cls)	LogReg <i>balanced</i>	0,250	0,265	0,800
L2 (38 cls)	<i>Focal</i> $\gamma = 2,0$	0,278	0,324	0,778
L2 (38 cls)	<i>Focal</i> $\gamma = 5,0$	0,278	0,324	0,793
L3 (224 cls)	LP CE (referencia)	0,143	0,132	0,813
L3 (224 cls)	<i>Focal</i> $\gamma = 2,0$	0,143	0,132	0,771

Focal Loss con $\gamma = 2,0$ y sin re-ponderación de clase supera marginalmente a la entropía cruzada estándar sobre L1 (+3,3 pp BAcc) y L2 (+5,9 pp BAcc), pero degrada la AUROC L2 en $-1,5$ pp ($0,793 \rightarrow 0,778$). Añadir `class_weight = balanced` no aporta, porque el factor $(1 - p_t)^\gamma$ ya modula el peso por dificultad. Sobre L3 ningún ajuste de la pérdida mejora a la entropía cruzada (Acc@1 y BAcc idénticos en 0,143 y 0,132; AUROC $-4,2$ pp). Como en el FT denso (sección 4.10.3), la cola larga estructural de L3 no admite mitigación por la función de pérdida sobre el dataset actual.

El patrón observado es análogo al documentado en el aumento en tiempo de inferencia (TTA, sección J.5): *Focal Loss* desplaza el régimen Acc@1/BAcc-AUROC favoreciendo la primera dimensión sobre la segunda, pero no resuelve el cuello de botella estructural impuesto por la cardinalidad y la cola larga del dataset. La elección del LP CE estándar como cabeza primaria de la tabla 4.15 se mantiene defendible: la mejora de *Focal Loss* sobre L1 y L2 está dentro de los IC95% solapados y no compensa la pérdida de interpretabilidad probabilística calibrada de la entropía cruzada estándar.

J.5 Aumento en tiempo de inferencia

La sección H.8.7 documenta la aplicación de *Test-Time Augmentation* (TTA) sobre el clasificador M1 (PanDerm Large *fine-tuned*) del servidor de inferencia, con un patrón de cinco aumentaciones deterministas (original, simetría horizontal, simetría vertical, rotación de 90° y rotación de 270° , omitiendo la rotación de 180°). El presente experimento replica el protocolo sobre la cabeza lineal entrenada sobre los *embeddings* de PanDerm Large del dataset DermapixelAI 1.0: para cada imagen de test se extraen los cinco *embeddings* correspondientes a las cinco aumentaciones, cada uno se evalúa con la cabeza lineal entrenada sobre el conjunto de *train* original y las cinco distribuciones de probabilidad se promedian antes del *argmax* final. La tabla J.5 compara el sondeo lineal sin TTA (referencia tabla 4.15) frente al sondeo lineal con TTA sobre los tres niveles ontológicos.

Cuadro J.5: Sondeo lineal con PanDerm Large sobre DermapixelAI 1.0: referencia sin TTA frente a TTA con cinco aumentaciones deterministas (original, simetría horizontal, simetría vertical, rotación 90°, rotación 270°). Promedio de probabilidades sobre las cinco aumentaciones antes del *argmax*. Mejor valor por par en negrita.

Nivel	Modo	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	LP	0,750	0,944	0,735	0,796
L1 (4 cls)	LP + TTA	0,694	1,000	0,703	0,779
L2 (38 cls)	LP	0,250	0,278	0,265	0,793
L2 (38 cls)	LP + TTA	0,222	0,500	0,250	0,787
L3 (224 cls)	LP	0,179	0,214	0,184	0,813
L3 (224 cls)	LP + TTA	0,179	0,250	0,184	0,807

El patrón es consistente sobre los tres niveles ontológicos: TTA degrada Acc@1, BAcc y AUROC en magnitudes pequeñas (−5,6, −2,8 y 0,0 pp Acc@1 sobre L1, L2 y L3 respectivamente; −3,2, −1,5 y 0,0 pp BAcc; −1,7, −0,6 y −0,6 pp AUROC) y mejora sistemáticamente Acc@3 (+5,6 pp en L1 hasta alcanzar 1,000, +22,2 pp en L2 y +3,6 pp en L3). El comportamiento es coherente con la observación reportada en sección H.8.7 para M1 sobre HAM10000, donde TTA produce −2,6 pp BAcc y +4,3 pp *recall* de melanoma. La interpretación es que el promediado sobre cinco aumentaciones suaviza la distribución de probabilidad y reduce la confianza en la clase *argmax* pero distribuye masa de probabilidad entre clases visualmente cercanas, lo que penaliza la precisión *top-1* y mejora el conjunto *top-3*. PanDerm Base presenta la misma dirección de efecto (cifras completas en el material reproducible). La recomendación operativa derivada es que TTA es preferible en escenarios de cribado con presentación *top-k* de diagnósticos diferenciales al clínico (Acc@3 L2 = 0,500 frente a 0,278 sin TTA), y el sondeo lineal sin TTA es preferible para decisiones automatizadas *top-1*.

J.6 Codificadores generalistas no médicos: DINOv2 y CLIP-L

Se evalúan dos codificadores fuera del dominio biomédico bajo el protocolo de sondeo lineal congelado descrito en la sección 4.10, sobre el mismo *split* fijo ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). DINOv2 ViT-L (vit_large_patch14_dinov2.lvd142m, embedding 1024-D, CLS) corresponde al modelo auto-supervisado visual generalista de Meta sobre LVD-142M [17]; CLIP-L-336 (OpenAI, ViT-L/14 con resolución 336) corresponde al modelo contrastivo texto-imagen generalista entrenado sobre 400 millones de pares web [23], con embedding proyectado de 768-D. La cabeza es regresión logística L-BFGS con $C = 1,0$ y $\text{max_iter} = 5000$, idéntica a la sección 4.10. La tabla J.6 recoge los resultados.

Cuadro J.6: Sondeo lineal sobre embeddings congelados de codificadores generalistas no médicos en DermapixelAI 1.0 ($N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). Referencia: PanDerm Large (tabla 4.15). Mejor valor por columna y nivel en negrita.

Encoder	L1 (4 cls)		L2 (38 cls)		L3 (224 cls)	
	BAcc	AUROC	BAcc	AUROC	BAcc	AUROC
PanDerm Large	0,735	0,796	0,265	0,793	0,184	0,813
DINOv2 ViT-L	0,537	0,650	0,250	0,718	0,211	0,794
CLIP-L-336	0,556	0,658	0,279	0,826	0,184	0,827

CLIP-L-336 alcanza la mejor AUROC sobre L2 (0,826 frente a 0,793 de PanDerm Large, +3,3 pp) y sobre L3 (0,827 frente a 0,813, +1,4 pp) a pesar de no incorporar material biomédico en su preentrenamiento. DINOv2 ViT-L, auto-supervisado puro sin componente textual, gana la BAcc L3 (0,211 frente a 0,184 de PanDerm Large, +2,7 pp) pero pierde sistemáticamente sobre L1 (−19,8 pp BAcc, −14,6 pp AUROC) y se mantiene por debajo sobre L2 (−1,5 pp BAcc, −7,5 pp AUROC). PanDerm Large conserva la primacía sobre L1 en BAcc y AUROC. Ningún codificador domina simultáneamente en todas las métricas y los tres niveles ontológicos, patrón coherente con la lectura de la sección 4.10 sobre la complementariedad entre el preentrenamiento auto-supervisado de PanDerm y el contrastivo texto-imagen de DermLIP. La clasificación *zero-shot* con CLIP-L (*prompts* en castellano e inglés idénticos a la sección 4.11) resulta catastrófica sobre los tres niveles (AUROC L1 0,559 en castellano y 0,635 en inglés, AUROC L2 0,699 en

castellano, AUROC L3 0,617 en castellano), confirmando que los codificadores generalistas requieren adaptación supervisada para operar sobre material clínico dermatológico.

J.7 Retrieval k -NN con índice FAISS sobre embeddings PanDerm Large

Una alternativa al clasificador paramétrico sobre el espacio de *embeddings* congelados consiste en la recuperación basada en similitud: dado un *embedding* de consulta, se recuperan sus k vecinos más próximos del conjunto de entrenamiento bajo similitud coseno y se predice por votación. Se construye un índice IndexFlatIP de FAISS [27] sobre los 874 *embeddings* L2-normalizados de PanDerm Large correspondientes al conjunto de *train* de la sección 4.10 y se evalúan dos variantes (votación por mayoría y *softmax* ponderado por similitud) cruzadas con $k \in \{1, 5, 10, 20\}$. La tabla J.7 reporta la mejor combinación por nivel y métrica frente a la referencia LP paramétrica.

Cuadro J.7: Retrieval k -NN sobre embeddings PanDerm Large con índice FAISS (IndexFlatIP, similitud coseno tras L2-normalize). Mejor combinación $k \times$ variante por nivel y métrica. Referencia: sondeo lineal paramétrico sobre el mismo encoder (LP, tabla 4.15). Mejor valor por columna y nivel en negrita.

Nivel	Método	Acc@1	BAcc	AUROC
L1	LP paramétrico (LR)	0,750	0,735	0,796
L1	k -NN $k = 10$ <i>majority</i>	0,722	0,686	0,748
L2	LP paramétrico (LR)	0,250	0,265	0,793
L2	k -NN $k = 20$ <i>majority</i>	0,278	0,265	0,700
L3	LP paramétrico (LR)	0,179	0,184	0,813
L3	k -NN $k = 5$ <i>majority</i>	0,214	0,210	0,615
L3	k -NN $k = 20$ <i>weighted</i>	0,214	0,210	0,719

El retrieval k -NN supera al sondeo lineal paramétrico sobre el régimen de cola larga severa L3 (224 clases efectivas, 3,5 muestras/clase media en *train*): +3,5 pp Acc@1 (0,179 $\rightarrow$ 0,214) y +2,6 pp BAcc (0,184 $\rightarrow$ 0,210) con $k = 5$ y votación por mayoría. Sobre L2, k -NN con $k = 20$ empata en BAcc (0,265) y mejora Acc@1 en +2,8 pp (0,250 $\rightarrow$ 0,278). Sobre L1, en cambio, k -NN pierde respecto al LP paramétrico (−4,9 pp BAcc, −4,8 pp AUROC), comportamiento consistente con que la cardinalidad reducida del nivel (4 clases) favorece a la regresión logística sobre la votación de vecinos. La AUROC global del k -NN es sistemáticamente inferior a la del LP (diferencias entre −4,8 y −9,3 pp según nivel), atribuible a que la estimación de probabilidad por frecuencia relativa de vecinos no es densa sobre el conjunto de clases. El hallazgo es coherente con la arquitectura del módulo M4 del prototipo de producción (*retrieval* sobre Derm1M descrito en el Anexo H), que emplea el mismo principio de similitud coseno sobre *embeddings* PanDerm Large como soporte conceptual al diagnóstico ofrecido por las cabezas paramétricas.

J.8 Zero-shot jerárquico: cascada L1 $\rightarrow$ L2 $\rightarrow$ L3 con propagación de errores

La sección 4.11 evalúa la clasificación *zero-shot* sobre los tres niveles ontológicos de forma independiente, considerando en cada caso todas las clases candidatas del nivel. Una estrategia alternativa, motivada por el flujo diagnóstico clínico real, consiste en una cascada jerárquica: predecir primero L1, restringir las candidatas L2 a las hijas del L1 predicho, y restringir las candidatas L3 a las hijas del L2 predicho. La jerarquía L1 $\rightarrow$ L2 utilizada se deriva del dataset de *train* (Inflamatoria: 25 subcategorías L2; Infecciosa: 5; Tumoral: 12; Genodermatosis: 2). El encoder es DermLIP v2 (el mejor *zero-shot* de la sección 4.11), bajo *prompts* en castellano. Se contrastan tres variantes: el *zero-shot* plano de la sección 4.11 (todas las clases del nivel como candidatas), la cascada jerárquica estricta con el L1 argmáx, y una variante *top-3 L1* que mantiene las tres categorías L1 más probables como candidatas y agrega sus hijas L2. La tabla J.8 compara las tres variantes.

Cuadro J.8: Comparación entre clasificación *zero-shot* plana y *zero-shot jerárquico* en cascada sobre el conjunto de test de DermapixelAI 1.0 ($N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). Encoder: DermLIP v2, prompts en castellano. La fila “L2 hier | L1 correcto” restringe la evaluación a las muestras con L1 predicho correctamente. Mejor valor por columna en negrita; la cifra condicionada se reporta separadamente.

Variante	L1 Acc@1	L2 Acc@1	L3 Acc@1
ZS plano (referencia, sección 4.11)	0,361	0,222	0,107
ZS jerárquico (cascada estricta)	0,361	0,139	0,036
ZS jerárquico (top-3 L1)	0,361	0,194	0,036
L2 hier L1 correcto (condicionada)	—	0,385	—

La cascada jerárquica estricta degrada el rendimiento plano sobre L2 en $-8,3$ pp Acc@1 ($0,222 \rightarrow 0,139$) y sobre L3 en $-7,1$ pp Acc@1 ($0,107 \rightarrow 0,036$). La causa principal es la propagación de errores desde el nivel L1: dado que DermLIP v2 acierta L1 sólo en el 36,1 % de los casos, el 63,9 % restante recibe en L2 un conjunto de candidatas desalineado con la verdad de terreno, lo que invalida toda predicción posterior independientemente del codificador. La variante *top-3 L1* amortigua parcialmente la propagación al mantener las tres categorías L1 más probables como hipótesis activa y recupera 0,194 Acc@1 sobre L2 ($-2,8$ pp respecto a plano), sin efecto sobre L3. Condicionado a L1 correcto, la cascada jerárquica L2 alcanza $\text{Acc@1} = 0,385$, casi el doble del plano, evidencia de que la restricción del espacio de candidatas a las subcategorías clínicamente coherentes con la categoría etiológica acertada incrementa la discriminación de forma sustancial. La implicación clínica es directa: la arquitectura jerárquica funciona si la decisión inicial sobre la familia etiológica es robusta; con *zero-shot* modesto, la cascada acumula errores y degrada el rendimiento plano.