



Universitat
de les Illes Balears

TRABAJO DE FIN DE GRADO

DERMAPIXEL: EVALUACIÓN DE MODELOS FUNDACIONALES PARA DERMATOLOGÍA CLÍNICA

Antonio Contestí Coll

Grau d'Enginyeria Informàtica

Escola Politècnica Superior

Año académico 2025–2026

DERMAPIXEL: EVALUACIÓN DE MODELOS FUNDACIONALES PARA DERMATOLOGÍA CLÍNICA

Antonio Contestí Coll

Trabajo de Fin de Grado

Escola Politècnica Superior

Universitat de les Illes Balears

Año académico 2025–2026

Paraules clau del treball: modelos fundacionales, dermatología clínica, PanDerm, DermLIP, evaluación empírica, ontología, equidad, interpretabilidad

Tutor: Dr. Javier Varona Gómez

A la Dra. Rosa Taberner, por su excepcional trabajo en Dermapixel y por su dilatada trayectoria en teledermatología, siendo un referente en el ámbito. Por la generosidad con la que me ha transmitido su conocimiento y por el tiempo que me ha dedicado de forma totalmente desinteresada a lo largo de este proyecto.

A mi tutor, el Dr. Javier Varona, por transmitirme el conocimiento con tanta claridad y pasión, por contagiarme esa ilusión por aprender, por su apoyo constante, por saber guiarme y centrarme en cada momento, y, sobre todo, por ser mucho más que un tutor: un gran amigo.

A todos los profesores de la Universitat de les Illes Balears que he tenido durante estos años, por su profesionalidad, dedicación y por el trato cercano y respetuoso que siempre me han brindado.

A mis compañeros de clase (Marc, Jordi, Dylan, Andres, Josep, Xisco, Carlos, Jesus, David), por hacerme sentir uno más desde el primer día. Me llevo no solo grandes profesionales con ambición y talento, sino también excelentes personas y amigos.

A Marc y a Jordi, compañeros de clase y también de prácticas, por haberse convertido en grandes amigos que sé que durarán toda la vida. Por todo lo que nos hemos ayudado mutuamente sin esperar nada a cambio, por el apoyo constante en los momentos difíciles y, en especial, por haber estado ahí en uno de los momentos más complicados del camino.

A David, por ser un ejemplo de superación. Por su esfuerzo constante, por su capacidad de lucha día tras día y por su actitud siempre positiva ante las dificultades.

A mis padres, por darme todo y por permitirme hoy devolverles, con este logro, una pequeña parte de lo que me han dado. Esta meta también es vuestra.

A mi hermano, y a mis sobrinos Albert y Marta, con la ilusión de poder transmitirles que, con humildad, esfuerzo y constancia, cualquier objetivo es alcanzable.

A Bruno, Marta y Jaume, los hijos de mi mujer y también mis hijos, por el apoyo, la comprensión y el cariño que me han demostrado en casa durante todo este tiempo.

A mi mujer, por su apoyo incondicional, por su paciencia infinita y por todo lo que ha sacrificado durante estos años, renunciando a muchos momentos juntos para que yo pudiera seguir adelante. Este trabajo es tanto suyo como mío.

Y, finalmente, a todos los pacientes, que son la verdadera razón de este camino.

ÍNDICE GENERAL

Índice general	iii
Lista de acrónimos	vii
Resumen	ix
Abstract	xi
1 Introducción	1
1.1 Contexto clínico	1
1.2 Objetivo general y enfoque	2
2 Estado del arte	3
2.1 Aprendizaje profundo aplicado a dermatología	3
2.2 Inteligencia artificial en imagen dermatoscópica y clínica	3
2.3 Modelos fundacionales: arquitectura y objetivos	4
2.4 Encoders visuales auto-supervisados	4
2.5 Modelos vision-language contrastivos	5
2.6 Modelos integrados con zero-shot nativo	5
2.7 Segmentación promptable	6
2.8 Modelos de lenguaje multimodales generalistas	6
2.9 Problemas metodológicos y guías de reporte	6
2.10 Resumen del estado del arte	7
3 Metodología	9
3.1 Datasets	9
3.1.1 Independencia frente al preentrenamiento: solapamiento con Derm1M	9
3.2 Ontología jerárquica L1/L2/L3	11
3.3 Dataset DermapixelAI 1.0	11
3.4 Modelos evaluados	12
3.5 Infraestructura experimental	13
3.6 Métricas	13
3.7 Pruebas estadísticas	14
3.8 Trazabilidad y reproducibilidad	16
3.9 Experimentos	16
3.9.1 Linear probe (LP)	17

3.9.2	Fine-tuning supervisado (FT)	17
3.9.3	Eficiencia en etiquetas	18
3.9.4	Segmentación binaria de lesión	18
3.9.5	Clasificación zero-shot multimodal	19
3.9.6	Comparación con modelos de lenguaje multimodales	19
3.9.7	Evaluación de equidad por fototipo	20
4	Resultados	21
4.1	Evaluación de PanDerm	21
4.2	Comparación con otras familias de modelos	23
4.3	Fine-tuning supervisado	24
4.4	Eficiencia en etiquetas	24
4.5	Segmentación binaria de lesión	25
4.5.1	Comparativa de arquitecturas promptables	26
4.5.2	Valor del prompt: control automático sin caja	27
4.5.3	Robustez del resultado: validación cruzada, prompt y calibración	27
4.5.4	El techo de la métrica: acuerdo inter-anotador	27
4.6	Clasificación zero-shot multimodal	28
4.7	Comparación con modelos generativos generalistas	29
4.7.1	Ajuste supervisado de un LLM multimodal: MedGemma con LoRA	30
4.8	Equidad por fototipo cutáneo	31
4.8.1	Validación estadística del ranking de encoders: test de DeLong	32
4.9	Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos	34
5	Dermapixel	37
5.1	Evaluación de los modelos fundacionales sobre DermapixelAI	37
5.1.1	Transferencia congelada: linear probe y validación cruzada	38
5.1.2	Validación del procedimiento de etiquetado	39
5.1.3	Estrategias de adaptación más allá del linear probe	39
5.1.4	Limitaciones del fine-tuning en la long tail	41
5.2	Validación <i>zero-shot</i> multimodal sobre DermapixelAI 1.0	41
5.3	Dermapixel R0: adaptación supervisada con LoRA (nivel L2)	43
5.3.1	Diseño de Dermapixel R0	43
5.3.2	Resultados principales L2	43
5.3.3	Adaptación eficiente frente a ajuste denso	43
5.3.4	Limitaciones en L3	44
5.4	Dermapixel R0: rama contrastiva en castellano	44
5.4.1	Diseño experimental	44
5.4.2	Evolución $v1 \rightarrow v5$	44
5.4.3	Hallazgos científicos	45
5.4.4	Recuperación multimodal	46
5.5	Síntesis comparativa de métodos sobre DermapixelAI 1.0	46
6	Discusión	48
6.1	Significado de los resultados	48
6.1.1	Ausencia de un método óptimo único: especialización por tarea	48

6.1.2	DermapixelAI 1.0 como contribución metodológica	51
6.1.3	Eficiencia en etiquetas y régimen de saturación	51
6.1.4	Linear probe frente a fine-tuning	52
6.1.5	Segmentación promptable y adaptación de bajo coste	52
6.1.6	Sensibilidad al tokenizer en zero-shot multimodal	54
6.1.7	Brecha entre modelos específicos y LLMs multimodales	55
6.1.8	Equidad por fototipo cutáneo	56
6.1.9	El cuello de botella ya no es sólo el modelo	56
6.1.10	Estimación robusta del rendimiento sobre datasets de tamaño moderado	57
6.2	Comparación con la literatura	57
6.2.1	Reproducción del benchmark de PanDerm	58
6.2.2	Segmentación binaria de lesión	58
6.2.3	Comportamiento zero-shot	58
6.2.4	Disparidad por fototipo	59
6.3	Implicaciones operativas	59
6.3.1	Arquitectura defendible para sistemas de apoyo al diagnóstico .	60
6.3.2	Ensemble de seguridad para detección de melanoma	60
6.4	Hallazgos no anticipados	61
6.5	Limitaciones interpretativas	62
7	Limitaciones	63
7.1	Limitaciones de disponibilidad	63
7.1.1	Modelos sin pesos públicos	63
7.1.2	Conjuntos de preentrenamiento no liberados	64
7.1.3	Dependencia de modelos fundacionales externos	64
7.2	Limitaciones de los datos	64
7.2.1	Sesgo geográfico y lingüístico	64
7.2.2	Heterogeneidad taxonómica entre datasets	64
7.2.3	Solapamiento con el dataset de preentrenamiento Derm1M . .	65
7.2.4	Tamaños muestrales por subgrupo en el experimento de equidad	66
7.3	Limitaciones del diseño experimental	66
7.3.1	Variabilidad inter-semilla	66
7.3.2	Pruebas estadísticas y comparaciones múltiples	67
7.3.3	Sensibilidad al <i>prompt</i> en zero-shot y LLMs	67
7.4	Limitaciones del dataset DermapixelAI 1.0	67
7.5	Limitaciones de generalización clínica	68
7.5.1	Material de archivo frente a flujo asistencial real	68
7.5.2	Sesgo de modalidad de los componentes evaluados	69
7.5.3	Ausencia de validación prospectiva	69
7.5.4	Elementos no abordados por decisión de alcance	69
7.6	Síntesis: dominio de validez de los resultados	70
8	Conclusiones	71
8.1	Síntesis de la evaluación	71
8.2	Contribuciones reproducibles	73
8.2.1	Contribuciones en el cuerpo del documento	73

8.2.2	Contribuciones complementarias	74
8.3	Hallazgos metodológicos transferibles	74
8.4	Aportaciones a la práctica clínica	76
8.5	Trabajo futuro	76
8.5.1	Escalado del dataset con el banco hospitalario HUSLL	77
8.5.2	Dermapixel R0: adaptación dermatológica multimodal en español	77
8.5.3	Validación clínica prospectiva	78
8.5.4	IA agéntica y modelos multimodales en español	78
8.6	Cierre	79
Bibliografía		80
A Material complementario y repositorio reproducible		84
A.1	Repositorio público	84
A.2	Estructura de carpetas	84
A.3	Índice de correspondencia	85
A.4	Datasheet del dataset DermapixelAI 1.0	85
A.5	Tablas detalladas de resultados	85
A.6	Intervalos de confianza por <i>bootstrap</i>	86
A.7	Calibración en el <i>endpoint</i> de melanoma de HAM10000	86
A.8	Ablaciones complementarias	86
A.9	Sparse Autoencoders y diccionario de conceptos	86
A.10	Modelos de lenguaje multimodales	86
A.11	Prototipo DermApIxel	87
A.12	Declaración de uso de inteligencia artificial	87
A.13	Reproducibilidad	87

LISTA DE ACRÓNIMOS

AdamW	Adaptive Moment Estimation with decoupled Weight decay
AJCC	American Joint Committee on Cancer
AMQP	Advanced Message Queuing Protocol
API	Application Programming Interface
AUROC	Area Under the Receiver Operating Characteristic Curve
BAcc	Balanced Accuracy
BCC	Carcinoma basocelular (<i>basal cell carcinoma</i>)
BCN	Barcelona
BF16	Brain Floating-Point de 16 bits
CAE	Convolutional AutoEncoder
CBM	Concept Bottleneck Model
CEIC	Comité Ético de Investigación Clínica
CIE-10	Clasificación Internacional de Enfermedades, décima revisión
CLIP	Contrastive Language–Image Pre-training
CV	Cross-Validation (validación cruzada)
DDI	Diverse Dermatology Images
ECE	Expected Calibration Error (error de calibración esperado)
DIADERM	Estudio observacional multicéntrico sobre demanda y prevalencia diagnóstica en dermatología en España
DICOM	Digital Imaging and Communications in Medicine
DSC	Dice Similarity Coefficient
ENS	Esquema Nacional de Seguridad
EPS	Escola Politècnica Superior
FAISS	Facebook AI Similarity Search
FP	Fototipo (escala Fitzpatrick I-VI)
FST	Fitzpatrick Skin Type (fototipo cutáneo Fitzpatrick)
FT	Fine-tuning supervisado
GPU	Graphics Processing Unit
HAM	Human Against Machine
HD95	Distancia de Hausdorff, percentil 95
HIBA	Hospital Italiano de Buenos Aires
HNSW	Hierarchical Navigable Small Worlds
HUSLL	Hospital Universitario Son Llàtzer
IA	Inteligencia artificial
IB-Salut	Servicio de Salud de las Illes Balears
IC	Intervalo de confianza

InfoNCE	Information Noise Contrastive Estimation
IoU	Intersection over Union (índice de Jaccard)
ISIC	International Skin Imaging Collaboration
ITA	Individual Typology Angle (ángulo tipológico individual)
L-BFGS	Limited-memory Broyden–Fletcher–Goldfarb–Shanno
LLM	Large Language Model (modelo de lenguaje de gran escala)
LoRA	Low-Rank Adaptation
LP	Linear Probing
MD5	Message Digest 5 (función de hash)
MLP	Multi-Layer Perceptron (perceptrón multicapa)
MSE	Mean Squared Error (error cuadrático medio)
MSKCC	Memorial Sloan Kettering Cancer Center
OIDC	OpenID Connect
PACS	Picture Archiving and Communication System
PAD-UFES	<i>Patient and Dataset of Skin Lesions, Universidade Federal do Espírito Santo</i>
RAG	Retrieval-Augmented Generation
SAE	Sparse Autoencoder
SAM	Segment Anything Model
SigLIP	Sigmoid Loss for Language Image Pre-training
SNOMED CT	Systematized Nomenclature of Medicine – Clinical Terms
SOTA	State of the Art (estado del arte)
TFG	Trabajo de Fin de Grado
TRIPOD+AI	Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis, extensión para inteligencia artificial
TTA	Test-Time Augmentation
UIB	Universitat de les Illes Balears
ViT	Vision Transformer
VQA	Visual Question Answering
WSI	Whole-Slide Image (imagen completa de portaobjetos histopatológico)
XAI	Explainable Artificial Intelligence (IA explicable)
ZS	Zero-shot

RESUMEN

La dermatología clínica afronta una demanda asistencial creciente frente a un acceso limitado al especialista, lo que ha impulsado el interés por los sistemas de apoyo al diagnóstico basados en imagen. En los últimos años han aparecido *modelos fundacionales* —modelos de gran escala, preentrenados y reutilizables mediante adaptación— específicos para dermatología; sin embargo, su rendimiento real fuera de los conjuntos con los que se desarrollaron, y muy especialmente sobre material clínico en español, apenas se ha evaluado de forma independiente. Junto al rendimiento sobre la imagen, este trabajo atiende una vía menos explorada: el uso del texto clínico asociado a cada caso como contexto para la predicción, frente al predominio de los enfoques basados únicamente en la imagen.

Este trabajo aporta tres contribuciones cerradas y reproducibles. Primero, una **evaluación comparativa homogénea e independiente**, centrada en PanDerm y extendida a hasta catorce modelos fundacionales con pesos públicos como comparadores, sobre un conjunto común de tareas —clasificación, segmentación, recuperación de casos y clasificación *zero-shot* guiada por texto— y de datasets públicos armonizados mediante una ontología clínica de tres niveles; la evaluación cubre tanto el rendimiento a partir de la imagen como el papel del texto asociado, mediante la clasificación guiada por lenguaje y la recuperación multimodal. Segundo, **DermapixelAI 1.0**, un dataset clínico en castellano con texto narrativo asociado a cada caso, entregado con documentación formal. Tercero, **Dermapixel R0**, una adaptación propia que demuestra que un modelo fundacional puede especializarse al castellano con recursos modestos.

Leídos en conjunto, los resultados no señalan un modelo universalmente superior, sino una especialización por tarea: la elección depende del tipo de problema, del volumen de datos etiquetados y de la disparidad entre fototipos cutáneos. En cuanto a la segunda vía, el texto asociado a las imágenes aporta valor de forma desigual: ayuda con claridad a la recuperación de casos y al alineamiento multimodal, pero su uso como contexto para la clasificación fina sigue siendo una línea abierta. De aquí se desprende una idea central: una vez los codificadores visuales alcanzan cierta madurez, el principal factor limitante deja de ser la arquitectura y pasa a ser la calidad, diversidad y cobertura de los datos disponibles. El escalado del dataset con material hospitalario y la validación clínica prospectiva constituyen la continuación natural del trabajo para su futura integración en sistemas de teledermatología hospitalaria.

El proyecto Dermapixel, desarrollado en colaboración con la Dra. Rosa M. Taberner Ferrer (Servicio de Dermatología del Hospital Universitario Son Llàtzer), ha sido distinguido con la *Beca de Innovación e Inteligencia Artificial* de la Academia Española de Dermatología y Venereología (AEDV) —dotada con 10 000 euros para su puesta en

producción— en el 53.^{er} Congreso Nacional de Dermatología y Venereología (Maspalomas, mayo de 2026), por el trabajo *Demapixel 5.0: plataforma de teledermatología stand-alone con IA multimodal y motor de razonamiento clínico-docente*.

Palabras clave

modelos fundacionales, dermatología clínica, PanDerm, DermLIP, evaluación empírica, ontología, equidad, dataset en español.

ABSTRACT

Clinical dermatology faces growing demand against limited access to specialists, which has driven interest in image-based diagnostic support systems. Recent years have seen the emergence of *foundation models*—large, pretrained models reusable through adaptation—specific to dermatology; their real-world performance beyond the datasets they were developed on, and particularly on Spanish-language clinical material, has barely been evaluated independently. Beyond image-based performance, this work also addresses a less-explored avenue: using the clinical text associated with each case as context for prediction, against the prevailing image-only approaches.

This work delivers three closed, reproducible contributions. First, a **homogeneous, independent comparative evaluation**—centred on PanDerm and extended to up to fourteen public-weight foundation models as comparators—across a common set of tasks—classification, segmentation, case retrieval and text-guided zero-shot classification—and public datasets harmonised through a three-level clinical ontology; the evaluation covers both image-based performance and the role of the associated text, through language-guided classification and multimodal retrieval. Second, **DermapixelAI 1.0**, a Spanish clinical dataset with narrative text linked to each case, released with formal documentation. Third, **Dermapixel R0**, an in-house adaptation showing that a foundation model can be specialised to Spanish with modest resources.

Taken together, the results point not to a universally superior model but to a specialisation by task: the right choice depends on the problem type, the labelled-data budget and skin-phototype disparity. As for the second avenue, the text associated with images proves unevenly useful: it clearly helps case retrieval and multimodal alignment, while its use as context for fine-grained classification remains open. A central idea follows: once visual encoders reach a certain maturity, the main limiting factor shifts from architecture to the quality, diversity and coverage of the available data. Scaling the dataset with hospital material and prospective clinical validation constitute the natural continuation of this work towards its future integration into hospital teledermatology systems.

The Dermapixel project, developed in collaboration with Dr. Rosa M. Taberner Ferrer (Department of Dermatology, Hospital Universitari Son Llàtzer), was awarded the *Innovation and Artificial Intelligence Grant* of the Spanish Academy of Dermatology and Venereology (AEDV)—endowed with 10 000 euros for its deployment into production—at the 53rd National Congress of Dermatology and Venereology (Maspalomas, May 2026), for the work *Dermapixel 5.0: a stand-alone teledermatology platform with multimodal AI and a clinical-educational reasoning engine*.

Keywords

foundation models, clinical dermatology, PanDerm, DermLIP, empirical evaluation, ontology, fairness, Spanish dataset.

INTRODUCCIÓN

1.1 Contexto clínico

Aunque existen centenares de enfermedades cutáneas distintas, la actividad asistencial diaria de los servicios de dermatología se concentra principalmente en un número limitado de diagnósticos frecuentes. El estudio observacional DIADERM, sobre 10999 diagnósticos en 8953 pacientes en territorio español, sitúa entre los diagnósticos más prevalentes la queratosis actínica, el carcinoma basocelular, los nevus melanocíticos, la queratosis seborreica, la psoriasis, el acné y las verrugas víricas [5]. Por su parte, Taberner et al. documentaron 213 diagnósticos diferentes en un único año asistencial en el Hospital Universitario Son Llàtzer (HUSLL) [4]. Ambos trabajos reflejan una realidad común: una elevada diversidad diagnóstica sustentada sobre un núcleo relativamente reducido de dermatosis benignas, inflamatorias e infecciosas de alta frecuencia.

La sensibilidad temporal del proceso diagnóstico resulta crítica en el melanoma cutáneo: la supervivencia específica a cinco años desciende desde aproximadamente 99 % en estadio I hasta 25 % en estadio IV según la octava edición de la American Joint Committee on Cancer [22]. El acceso al especialista se realiza mediante derivación desde atención primaria, y la capacidad del circuito presencial es limitada frente a una demanda creciente, lo que motiva el interés por sistemas de apoyo al diagnóstico basados en imagen. El sustrato visual de ese diagnóstico se articula en tres modalidades —fotografía clínica, dermatoscopia e histopatología—, sobre las que operan hoy sistemas contruidos a partir de *modelos fundacionales*: modelos de gran escala, preentrenados sobre un volumen amplio de datos y reutilizables, mediante adaptación, en múltiples tareas posteriores.

Este trabajo nace de dos colaboraciones preexistentes con la Dra. R. Taberner, dermatóloga del HUSLL. La primera es la modernización tecnológica del archivo Dermapixel, blog mantenido por la Dra. Taberner desde 2010, que reúne más de 700 casos clínicos comentados con imagen clínica y dermatoscópica, historia abreviada, diagnóstico y razonamiento diferencial; en paralelo a este TFG se ha desarrollado su migración a una pila tecnológica propia. La segunda es un proyecto institucional del Servei de

Salut de les Illes Balears (IB-Salut) sobre teledermatología hospitalaria, orientado a apoyar la primera valoración dermatológica en el circuito de derivación desde atención primaria. Ambas líneas orientan una decisión que condiciona todo el trabajo: priorizar modelos con código y pesos públicos, por su viabilidad de integración hospitalaria y su reproducibilidad. Esta prioridad introduce un sesgo de selección explícito —deja fuera modelos cerrados potencialmente más capaces, como DermFM-Zero, cuyos pesos no son públicos (sección 7.1.1)—, asumido a cambio de un marco de evaluación íntegramente reproducible; los modelos cerrados accesibles vía API se incorporan únicamente como comparadores contextuales.

1.2 Objetivo general y enfoque

El objetivo último de este trabajo es avanzar hacia un sistema de apoyo diagnóstico capaz de operar tanto sobre fotografía clínica como sobre dermatoscopia, y sobre el conjunto amplio de patologías cutáneas, no solo el melanoma. La motivación es una asimetría clara del estado actual: la dermatoscopia está relativamente madura para la detección de melanoma, pero mucho menos para el resto de patologías, mientras que la fotografía clínica —la modalidad más accesible en atención primaria y en teledermatología— sigue muy poco explorada. Ahí residen la necesidad clínica y la oportunidad.

Dentro de ese objetivo conviven dos enfoques complementarios. El primero es el papel de los modelos fundacionales para mejorar el diagnóstico a partir de la imagen. El segundo, menos explorado, es el uso del texto clínico asociado a cada imagen como contexto para la predicción: la mayoría de los trabajos se apoyan únicamente en la imagen, y la hipótesis de fondo es que incorporar el lenguaje natural que acompaña a cada caso —la descripción, el razonamiento, la historia— puede mejorar el reconocimiento de patologías, en especial en fotografía clínica y más allá del melanoma.

El modo de proceder es, por tanto, empezar por el principio: examinar qué ofrecen y qué les falta a los modelos fundacionales disponibles. De ese análisis del estado del arte se derivarán los objetivos concretos y el enfoque experimental de este trabajo.

ESTADO DEL ARTE

2.1 Aprendizaje profundo aplicado a dermatología

El trabajo de Esteva et al. [31] establece la primera referencia consolidada de clasificación dermatológica con redes convolucionales, con rendimiento equivalente al de un panel de dermatólogos certificados sobre clasificación binaria maligno/benigno. Las extensiones posteriores amplían el espectro diagnóstico y la diversidad de datos [32, 9] y formulan tareas adicionales como segmentación binaria de lesión [11] y clasificación binaria melanoma/no-melanoma con anotaciones estructuradas multi-criterio [10]. El paradigma común permanece estable: entrenamiento desde pesos de ImageNet, una arquitectura por tarea y dependencia de anotación experta. Tres limitaciones lo acotan: el coste de la anotación clínica, la fragmentación taxonómica entre conjuntos públicos y la pérdida de rendimiento fuera del dominio de entrenamiento, particularmente acusada en fototipos cutáneos elevados [15, 13].

2.2 Inteligencia artificial en imagen dermatoscópica y clínica

La modalidad en la que la inteligencia artificial está más madura es la dermatoscopia aplicada al melanoma. El motivo es, en buena medida, la disponibilidad de datasets públicos amplios y bien anotados y de una serie de competiciones internacionales que han fijado un banco de pruebas común. Los retos de la *International Skin Imaging Collaboration* (ISIC), celebrados de forma anual desde 2016 junto a congresos de visión por computador, se apoyan en un archivo público de más de medio millón de imágenes de lesiones cutáneas, en su mayoría dermatoscópicas [35]. Sobre datasets de este tipo, como HAM10000 [9], los modelos alcanzan un rendimiento comparable al del dermatólogo experto en la distinción entre melanoma y lesiones benignas; una revisión sistemática con meta-análisis reciente concluye que, para la clasificación de cáncer de piel, los algoritmos igualan a los dermatólogos expertos y superan a los clínicos no especializados [33].

Fuera del melanoma y del cáncer cutáneo queratinocítico, el avance es bastante menor. La mayoría de los datasets dermatoscópicos y de la literatura de evaluación se concentran en la detección de cáncer de piel —una revisión sistemática de 232 estudios circunscribe el grueso de las aplicaciones de IA en dermatología al melanoma y al carcinoma queratinocítico [37]—, y la extensión a tareas multiclase sobre el conjunto amplio de dermatosis es más reciente y está mucho menos consolidada. La propia tarea de segmentación de la lesión se ha formulado también sobre datasets dermatoscópicos de cáncer [11], lo que ilustra hasta qué punto la modalidad gravita en torno al problema oncológico.

La fotografía clínica o macroscópica —la obtenida con una cámara convencional o un teléfono, sin lente de contacto ni aumento— está mucho menos explorada. El trabajo de Esteva et al. [31] mostró que una red entrenada sobre imágenes clínicas podía clasificar cáncer de piel a nivel de dermatólogo, y sistemas posteriores como el de Liu et al. [34] ampliaron el alcance a las 26 dermatosis más frecuentes en atención primaria a partir de casos de teledermatología. Aun así, estos esfuerzos son escasos frente al volumen del trabajo dermatoscópico, se concentran en un número reducido de sistemas y siguen condicionados por problemas de generalización: el rendimiento cae sobre los fototipos cutáneos más oscuros y sobre los diagnósticos menos frecuentes [13, 15, 36].

Esta asimetría delimita el terreno menos trabajado. La dermatoscopia para melanoma está relativamente resuelta, pero el resto del espectro de patologías —y, en especial, la fotografía clínica— sigue siendo poco explorado, y casi todo el material disponible está en inglés. Incluso los recursos más recientes que enriquecen imágenes con descripciones clínicas, como SkinCAP [17], se construyen sobre datasets clínicos en inglés ya existentes. La parte menos explorada de este panorama es, por tanto, la fotografía clínica en lenguas distintas del inglés y con texto narrativo de caso real.

2.3 Modelos fundacionales: arquitectura y objetivos

Los modelos fundacionales sustituyen el entrenamiento específico por encoders preentrenados de forma auto-supervisada o multimodal sobre datasets visuales masivos. La arquitectura predominante es el Vision Transformer [23], que procesa la imagen como una secuencia de parches y aprende dependencias globales mediante mecanismos de atención. Los objetivos de preentrenamiento más extendidos son tres: el *masked image modeling*, en el que la red reconstruye parches ocultos a partir del contexto visible; la destilación auto-supervisada entre vistas; y la alineación contrastiva imagen-texto al estilo CLIP [24]. La adaptación posterior a tareas específicas opera por linear probe sobre representaciones congeladas, fine-tuning supervisado, o transferencia directa zero-shot guiada por *prompts* en los modelos con rama lingüística.

2.4 Encoders visuales auto-supervisados

DINOv2 [18] es la referencia abierta de encoder visual auto-supervisado de propósito general, entrenado sobre ~ 142 millones de imágenes naturales sin etiquetas mediante destilación entre vistas. Sus representaciones transfieren a tareas de clasificación, recu-

peración y segmentación sobre dominios naturales y biomédicos con ajuste mínimo, y constituyen una base habitual para adaptación a dominios especializados.

En el dominio dermatológico, PanDerm [1] es un encoder visual ViT (Base ~ 86 M y Large ~ 307 M parámetros) entrenado sobre ~ 2,1 millones de imágenes dermatológicas en cuatro modalidades (fotografía corporal total, dermatoscopia, fotografía clínica e histopatología). El preentrenamiento utiliza *masked latent modeling*: la red reconstruye representaciones latentes de regiones ocultas en lugar de píxeles, con un modelo CLIP-Large congelado como *teacher*. Sus autores reportan una mejora media del +10,2 % sobre el estado del arte previo en 28 tareas dermatológicas. La disponibilidad simultánea de pesos, código y benchmarks lo convierte en el primer modelo fundacional dermatológico verificable de forma independiente.

2.5 Modelos vision-language contrastivos

CLIP [24] establece el preentrenamiento contrastivo imagen-texto sobre 400 millones de pares de la web. El objetivo InfoNCE aproxima la imagen a su descripción dentro del lote y la aleja del resto. El espacio compartido habilita dos modos operativos: clasificación zero-shot guiada por *prompts* textuales (la clase ganadora es la de mayor similitud coseno entre el vector visual y los vectores textuales de las clases candidatas) y recuperación bidireccional imagen-texto sobre datasets precomputados.

SigLIP [25] sustituye la pérdida softmax de CLIP por una pérdida sigmoide que reduce la dependencia del tamaño de batch y escala con mejor estabilidad. Su variante Large (SO400M) dispone de embedding de 1 152 dimensiones y ~ 878 M parámetros. BiomedCLIP [19] extiende el paradigma al dominio biomédico sobre PMC-15M (~ 15 millones de pares figura-leyenda de literatura científica); su cobertura dermatológica específica es limitada por el sesgo de selección del dataset.

En dermatología, Derm1M y la familia DermLIP [2] añaden la rama lingüística contrastiva al estado del arte de la disciplina. Derm1M reúne 1 029 761 pares imagen-texto sobre 403 563 imágenes únicas, organizados según una ontología jerárquica de cuatro niveles construida por dermatólogos. La familia DermLIP combina varios encoders visuales (PanDerm Base, ConvNeXt-Large) con varios encoders textuales (PubMedBERT extendido a 256 tokens, GPT-2 dermatológico con tokenizer de CLIP a 77 tokens). La configuración con mejor rendimiento reportada por los autores combina PanDerm Base como encoder visual y PubMedBERT como encoder textual, superando a BiomedCLIP en los benchmarks zero-shot evaluados.

La implementación operativa de la recuperación visual densa sobre datasets a gran escala requiere índices vectoriales optimizados para búsqueda aproximada del vecino más próximo. FAISS [28] y estructuras basadas en grafos del tipo Hierarchical Navigable Small Worlds permiten consultas en el orden de 10^2 milisegundos sobre datasets de centenares de miles a millones de *embeddings* precomputados.

2.6 Modelos integrados con zero-shot nativo

DermFM-Zero [3] integra el preentrenamiento visual auto-supervisado y la alineación contrastiva imagen-texto en un único modelo con capacidad zero-shot nativa. El entrenamiento se estructura en dos fases: *masked latent modeling* sobre tres millones de

imágenes en la primera, y *bootstrapped contrastive learning* sobre un millón de pares texto-imagen en la segunda. El encoder textual es PubMedBERT. El modelo incorpora interpretabilidad emergente mediante Sparse Autoencoders [21], redes auxiliares que descomponen la representación interna en un diccionario disperso de direcciones asociables a conceptos clínicamente identificables. Sus autores reportan validación en tres *reader studies* con más de mil cien clínicos. Sus pesos no son públicos en la fecha de cierre del presente trabajo, lo que restringe su tratamiento a la discusión conceptual.

BLIP-2 [27] introduce un patrón arquitectónico distinto: conecta un encoder visual congelado con un modelo de lenguaje preentrenado mediante un módulo intermedio ligero (*Q-Former* o *Querying Transformer*) que transforma las representaciones visuales en una secuencia reducida de tokens interpretables por el modelo de lenguaje. Sólo el Q-Former se entrena. No existe, en la fecha de cierre, una adaptación pública específica de BLIP-2 al dominio dermatológico.

2.7 Segmentación promptable

SAM [26] establece el paradigma de segmentación promptable: produce máscaras a partir de *prompts* visuales (puntos, cajas, máscaras parciales) sobre imagen natural. Su preentrenamiento utiliza ~ 11 millones de imágenes con más de mil millones de máscaras generadas mediante un proceso semi-automatizado. SAM2 [20] amplía el enfoque al dominio del vídeo y mejora el rendimiento sobre imágenes estáticas.

La transferencia a dominios médicos requiere adaptación supervisada sobre conjuntos con máscaras binarias. La estrategia habitual combina un modelo SAM/SAM2 preentrenado con fine-tuning sobre ISIC2018 [11] y adaptadores de bajo rango (*Low-Rank Adaptation*, LoRA) [38], que incorporan un número reducido de parámetros entrenables manteniendo congelado el peso original del encoder visual. Esta estrategia reduce los requisitos de memoria y cómputo y permite la adaptación sobre hardware modesto.

2.8 Modelos de lenguaje multimodales generalistas

Los modelos de lenguaje multimodales preentrenados sobre datasets web masivos constituyen una referencia de comparación pertinente: GPT-4o (OpenAI), Gemini 2.5 Pro (Google DeepMind) y la familia MedGemma (versiones 4B Vision y 27B Text, Google). Su número de parámetros supera al de los encoders fundacionales específicos en uno o dos órdenes de magnitud. Su modo de uso característico es la inferencia guiada por *prompts* sin fine-tuning específico por tarea. Trabajos recientes documentan su uso conversacional para soporte al razonamiento clínico [6, 8]. Los modelos de acceso restringido (GPT-4o, Gemini) sólo se evalúan mediante API; MedGemma libera pesos y se evalúa en local.

2.9 Problemas metodológicos y guías de reporte

La aplicación de modelos fundacionales a imagen médica plantea tres problemas metodológicos directamente relevantes para el presente trabajo. El primero es la fuga de

información entre conjuntos de evaluación y dataset de preentrenamiento. La construcción de Derm1M sobre fuentes web abiertas implica que datasets como Dermnet, HIBA o MSKCC pueden solaparse con su dataset de entrenamiento, lo que sesga al alza las métricas zero-shot reportadas. El segundo es la heterogeneidad taxonómica entre datasets, que impide comparaciones directas sin un paso explícito de armonización. El tercero es la disparidad de rendimiento por fototipo cutáneo, documentada en Fitzpatrick17k [15] y atendida específicamente por SkinCon [16] mediante anotación basada en 48 conceptos clínicos visuales.

Las guías de reporte recientes para inteligencia artificial en imagen médica —CLAIM [41] y la actualización TRIPOD+AI [42]— establecen la transparencia metodológica como condición de defensibilidad: cohorte, particiones, métricas, incertidumbre y limitaciones deben constar explícitamente en el informe completo. El reporte de pruebas estadísticas (intervalos de confianza por *bootstrap*, comparaciones múltiples, contrastes pareados de AUROC mediante el test de DeLong [39], y tamaños muestrales por subgrupo) constituye un requisito creciente en publicaciones de la disciplina.

2.10 Resumen del estado del arte

El recorrido anterior puede resumirse en una idea. El aprendizaje profundo alcanzó un rendimiento comparable al del especialista en la detección de melanoma [31], pero al precio de una arquitectura por tarea, una fuerte dependencia de anotación experta y una caída notable de rendimiento fuera del dominio de entrenamiento, especialmente sobre los fototipos cutáneos más oscuros [15, 13]. Los *modelos fundacionales* cambiaron esa lógica: un mismo encoder, preentrenado a gran escala, se reutiliza en muchas tareas mediante adaptación ligera. En dermatología, las referencias abiertas son PanDerm —un encoder visual entrenado sobre las cuatro modalidades de la especialidad [1]— y la familia DermLIP, que añade una rama de texto y la clasificación *zero-shot* [2]; el modelo más reciente con *zero-shot* nativo, DermFM-Zero, no libera sus pesos [3]. Alrededor de ellos conviven encoders generalistas (DINOv2), modelos contrastivos imagen-texto (CLIP, SigLIP, BiomedCLIP), la segmentación *promptable* de la familia SAM [20] y los grandes modelos de lenguaje multimodales como comparadores de contexto.

Tres problemas atraviesan toda esta literatura y condicionan cualquier lectura de sus resultados: la fuga de información entre los datasets de evaluación y los de preentrenamiento, que infla las cifras; la incompatibilidad entre las taxonomías de cada dataset, que impide compararlos directamente; y la desigualdad de rendimiento entre fototipos cutáneos. A ello se suma una exigencia creciente de transparencia metodológica —cohorte, particiones, incertidumbre y contrastes estadísticos— recogida en guías como TRIPOD+AI [42].

De todo lo anterior se desprenden las carencias que motivan el trabajo. Cada modelo se publica evaluado por sus propios autores, sobre sus propios *benchmarks* y con protocolos distintos: falta una comparación independiente, bajo un mismo protocolo y sobre datasets externos comunes, realizada por un equipo ajeno a quien creó los modelos. Casi todo el material y los encoders de texto están en inglés y centrados en dermatoscopia; la fotografía clínica en español, con texto narrativo de caso real, es prácticamente inexistente —los recursos recientes de *captions* clínicas ricas, como Skin-

CAP [17], enriquecen datasets en inglés ya existentes, pero no cubren esa carencia—. Y entre la evaluación sobre *benchmarks* y el despliegue real en un hospital media una distancia operativa que los trabajos publicados no abordan.

De este panorama se desprende el plan de este trabajo. El primer paso es reproducir y validar PanDerm —el modelo fundacional dermatológico abierto más completo— sobre un conjunto común de datasets externos, comprobando que su comportamiento se corresponde con el publicado y comparándolo de forma homogénea con los demás modelos disponibles; ello exige armonizar las taxonomías heterogéneas de los datasets y auditar su posible solapamiento con los datos de preentrenamiento. Sobre esta base se quiere explorar un conjunto de ideas que el propio estado del arte —y en particular DermFM-Zero— apunta como prometedoras: el trabajo en el espacio latente y el alineamiento contrastivo imagen-texto al estilo CLIP, la interpretabilidad mediante *sparse autoencoders* —adaptada al español para explicar las imágenes— y la clasificación *zero-shot* guiada por lenguaje. El horizonte de todo ello es el reconocimiento sobre fotografía clínica —en clasificación y en segmentación—, la modalidad menos trabajada y de mayor interés asistencial.

METODOLOGÍA

En este capítulo se explica cómo se han realizado todos los experimentos del trabajo. Se describen los datasets, los modelos comparados, la infraestructura utilizada, las métricas de evaluación y las pruebas estadísticas empleadas, con el objetivo de que los resultados del capítulo 4 puedan reproducirse e interpretarse correctamente.

3.1 Datasets

La selección de datasets persigue medir la capacidad de generalización de los modelos entre modalidades de imagen, dominios clínicos y tareas. Por ello se emplean doce datasets externos públicos que cubren dermatoscopia, fotografía clínica, histopatología, análisis de equidad y aprendizaje basado en conceptos, agrupados por modalidad y finalidad. La tabla 3.1 resume sus características.

Los datasets cubren las tres modalidades del diagnóstico dermatológico. La dermatoscopia (HAM10000, BCN20000, Derm7pt dermo, HIBA, MSKCC, ISIC2018) aporta imagen polarizada adquirida con dermatoscopio. La fotografía clínica (PAD-UFES-20, DDI, Dermnet, Derm7pt clínico) reproduce las condiciones de captura en consulta y atención primaria. La histopatología la aporta WSI patches, con 12 354 *parches* en 16 categorías. Dos datasets cumplen un papel específico: Fitzpatrick17k habilita el análisis de equidad, al anotar conjuntamente patología (114 categorías) y fototipo cutáneo (escala Fitzpatrick I-VI), y SkinCon aporta anotación densa de 48 conceptos clínicos visuales para los Concept Bottleneck Models. En todos los experimentos se utilizaron las particiones oficiales de entrenamiento, validación y prueba *train/val/test* proporcionadas por cada dataset, sin modificar ni reasignar imágenes entre ellas.

3.1.1 Independencia frente al preentrenamiento: solapamiento con Derm1M

La validez de toda comparación de transferencia y *zero-shot* del trabajo depende de que los conjuntos de test no se solapen con el dataset de preentrenamiento, por lo que

3. METODOLOGÍA

Cuadro 3.1: Datasets externos empleados en la evaluación. N_{test} : tamaño nominal del *split* de evaluación canónico; “Clases”: número de categorías diagnósticas o conceptos en la convención propia del dataset. El asterisco (*) marca Dermnet, el único dataset con solapamiento exacto frente al dataset de preentrenamiento Derm1M (auditoría en sección 3.1.1). Las dos variantes de Derm7pt (clínica y dermatoscópica) comparten origen (Seven-Point Checklist) y se reportan como un único dataset en el conteo agregado de doce datasets externos.

Dataset	N_{test}	Clases	Modalidad	Uso
HAM10000 [9]	1 232	7	Dermoscopia	LP, FT, ZS, LLMs
BCN20000 [29]	1 242	9	Dermoscopia	LP
PAD-UFES-20 [12]	461	6	Clínica móvil	LP, FT
DDI [13]	137	2	Clínica	LP, FT, equidad
Dermnet [14]	4 002	23	Clínica	LP*
Derm7pt clínico [10]	168	2	Clínica	LP
Derm7pt dermo [10]	225	2	Dermoscopia	LP
HIBA	334	2	Dermoscopia	LP
MSKCC	1 664	2	Dermoscopia	LP, FT
WSI patches	12 354	16	Histopatología	LP
ISIC2018 [11]	2 594	binaria	Dermoscopia	Segmentación
Fitzpatrick17k [15]	16 577	114 + FP	Clínica	Equidad
SkinCon [16]	3 230	48 conc.	Clínica	CBM

conviene comprobarlo antes de emplearlos. La auditoría reduce cada imagen a su hash MD5 (biblioteca estándar de Python) e intersecta los hashes de los doce datasets externos —salvo SkinCon, no evaluado sobre clases diagnósticas— con los 415 451 hashes únicos de la fracción accesible de Derm1M, principal dataset de preentrenamiento de la familia PanDerm y DermLIP. El cruce identifica un único dataset con solapamiento exacto: **Dermnet**, cuyas 18 302 imágenes están todas contenidas en Derm1M (100%). Los once datasets restantes no arrojan ninguna coincidencia. En particular, HIBA y MSKCC —cuyo origen en el ISIC archive motivaba una sospecha de procedencia— presentan 0 coincidencias MD5, por lo que esa sospecha no se traduce en solapamiento exacto. El resultado completo por dataset figura en el repositorio reproducible (A, sección A.13).

El solapamiento de Dermnet no invalida las cifras que se reportan en la sección 4.1 para PanDerm, DINOv2, ConvNeXt-Large, EfficientNetV2-Large y SigLIP-Large, cuyo preentrenamiento no incluye Derm1M. Sí condiciona, en cambio, la interpretación de las cifras zero-shot de la familia DermLIP sobre Dermnet (sección 4.6), ya que DermLIP se entrenó sobre Derm1M y vio durante el preentrenamiento la totalidad de ese conjunto.

El alcance de la auditoría se declara con precisión. El hash MD5 detecta coincidencias *exactas* a nivel de bytes —duplicados idénticos—, pero no *near-duplicates* —recortes, reescalados, recompresiones o alteraciones leves de una misma imagen—. La auditoría sostiene, en consecuencia, la ausencia de *solapamiento exacto*, no la ausencia completa de contaminación visual. Esta elección prioriza la trazabilidad y el bajo coste del hash exacto frente a la cobertura perceptual; el *perceptual hashing* o la comparación por *embeddings* visuales constituyen su extensión natural, y las implicaciones de este alcance acotado se retoman en la sección 7.2.3.

3.2 Ontología jerárquica L1/L2/L3

Comparar modelos entre datasets exige resolver un problema previo: cada conjunto usa su propia taxonomía, y esas taxonomías no son compatibles entre sí. Dos diagnósticos equivalentes pueden aparecer bajo denominaciones distintas o con niveles de granularidad diferentes. Para unificarlas se diseñó, en colaboración con la Dra. R. Taberner, una ontología jerárquica de tres niveles que actúa como vocabulario común a todos los protocolos del trabajo.

El nivel L1 (etiológico) reparte los diagnósticos en cuatro familias: patología inflamatoria, tumoral, infecciosa y genodermatosis. El nivel L2 (subcategoría clínica) contiene 43 entradas; cinco de ellas no se desagregan en L3 por considerarse ya suficientemente específicas (*Esclerosis tuberosa*, *Neurofibromatosis tipo 1*, *Incontinentia pigmenti*, *Queratodermia palmoplantar hereditaria* y *Pseudoxantoma elástico*). El nivel L3 (diagnóstico) contiene 367 entradas individuales, cada una con sus códigos SNOMED CT y CIE-10 para garantizar interoperabilidad con sistemas clínicos.

Once de los doce datasets se mapean a la ontología; SkinCon queda fuera por estar anotado con conceptos, no con diagnósticos. El conjunto armonizado resultante reúne 72654 imágenes etiquetadas sobre vocabulario común.

3.3 Dataset DermapixelAI 1.0

DermapixelAI 1.0 es un dataset dermatológico en español construido en este trabajo a partir del archivo del blog Dermapixel de la Dra. R. Taberner; su construcción materializa el objetivo O2 (sección 1.2). A diferencia de los datasets públicos utilizados en la evaluación, DermapixelAI 1.0 incorpora texto narrativo clínico en español asociado a cada caso, lo que permite estudiar escenarios multimodales y de transferencia lingüística no cubiertos por los conjuntos de referencia internacionales. La elaboración comprende la extracción del material del archivo, la depuración, la estructuración que vincula para cada caso imagen y modalidad, metadatos clínicos y texto narrativo, y el etiquetado contra la ontología jerárquica L1/L2/L3; el pipeline completo se documenta en el repositorio reproducible (A, sección A.8). La versión utilizada reúne 1089 imágenes vinculadas a 669 casos clínicos, cada uno con su texto narrativo asociado (mediana de 223 palabras). Predomina la fotografía clínica (1036 imágenes), con un subconjunto dermatoscópico reducido (49).

Las imágenes se etiquetan según la ontología L1/L2/L3 y se particionan bajo regla *case-aware* (891/157/41 imágenes; 538/100/31 casos), de modo que todas las imágenes de un mismo caso caen en el mismo *split* y no hay fuga entre conjuntos. Dos campos cuantifican la calidad del etiquetado: el 97,89% del dataset está mapeado a la ontología con revisión experta del vocabulario (`label_source = ontology`) y el 84,39% ha pasado además revisión visual caso-a-caso por la Dra. R. Taberner (`rosa_verified`). Ambas cifras no son intercambiables y se detallan, junto a un tercer campo de validación textual, en el repositorio reproducible (A, sección A.8).

El dataset se distribuye bajo licencia CC-BY-NC-SA 4.0. Su pipeline de construcción, caracterización completa y datasheet figuran en el repositorio reproducible (A, sección A.8), y el documento formal de entrega, en su sección A.4. La validación experimental sobre DermapixelAI 1.0 forma parte de los resultados de este trabajo: las

secciones 5.1 y 5.2 del capítulo 4 evalúan sobre este dataset el sondeo lineal supervisado y la clasificación zero-shot multimodal en los tres niveles ontológicos.

3.4 Modelos evaluados

Los modelos incluidos en el estudio se seleccionan con el objetivo de representar los principales paradigmas actualmente utilizados en visión artificial y aprendizaje multimodal aplicado a dermatología. La comparación combina modelos específicamente entrenados para dermatología, modelos visuales generalistas de referencia, arquitecturas vision-language biomédicas y modelos multimodales de propósito general. Esta diversidad permite evaluar hasta qué punto la especialización dermatológica aporta ventajas medibles frente a modelos más generales y situar el rendimiento de los modelos fundacionales dermatológicos dentro del ecosistema actual de inteligencia artificial médica.

La tabla 3.2 resume los dieciséis sistemas evaluados: catorce modelos fundacionales —encoders visuales de dominio (PanDerm) y generales (DINOv2), modelos vision-language (la familia DermLIP, BiomedCLIP y SigLIP), el segmentador promptable SAM2.1 y los modelos de lenguaje multimodales (GPT-4o, Gemini 2.5 Pro, MedGemma y BLIP-2)— y dos líneas de base de redes convolucionales supervisadas (ConvNeXt-Large y EfficientNetV2-Large), incluidas como referencia no fundacional frente a la que medir el valor del preentrenamiento.

Cuadro 3.2: Modelos evaluados.

Modelo	Familia	Parámetros	Referencia
PanDerm Base	Encoder visual derm.	~ 86 M	[1]
PanDerm Large	Encoder visual derm.	~ 307 M	[1]
DINOv2 ViT-L/14	Encoder visual general	~ 300 M	[18]
ConvNeXt-Large	ConvNet supervisada	~ 198 M	—
EfficientNetV2-Large	ConvNet supervisada	~ 118 M	—
DermLIP v1 (PubMedBERT)	Vision-language derm.	—	[2]
DermLIP v2 (PubMedBERT)	Vision-language derm.	—	[2]
DermLIP original (GPT-2)	Vision-language derm.	—	[2]
BiomedCLIP	Vision-language biomédico	—	[19]
SigLIP-Large SO400M	Vision-language general	~ 878 M	[25]
SAM2.1-Large (decoder FT)	Segmentación	~ 227 M	[20]
GPT-4o	LLM multimodal	no público	—
Gemini 2.5 Pro	LLM multimodal	no público	—
MedGemma 4B Vision	LLM multimodal biomédico	~ 4 B	—
MedGemma 27B Text+LoRA	LLM multimodal biomédico	~ 27 B	—
BLIP-2 (Q-Former)	Vision-language general	—	[27]

Los encoders difieren en la dimensión de sus *embeddings*: 768 en PanDerm Base; 1 024 en PanDerm Large y DINOv2 ViT-L/14; 1 152 en SigLIP-Large SO400M. La cifra de ~ 307 M parámetros de PanDerm Large es el valor nominal del ViT-L/16 publicado por sus autores. Al cargarlo como extractor de características y sustituir la head original por la identidad quedan 303,3 M parámetros efectivos. Esta diferencia no afecta al rendimiento, porque la head descartada no interviene en la inferencia. La familia DermLIP usa ViT-B/16 como encoder visual y dos encoders textuales alternativos: PubMedBERT extendido a 256 tokens (variantes v1 y v2) y GPT-2 con tokenizer de CLIP

a 77 tokens (variante original). DermFM-Zero [3] se incluye en la discusión pero no en la evaluación empírica, ya que sus pesos no estaban disponibles a la fecha de cierre.

3.5 Infraestructura experimental

Todos los experimentos corren sobre una NVIDIA DGX Spark con chip Grace Hopper GB10, 128 GB de memoria unificada compartida entre CPU y GPU, Linux ARM aarch64 y CUDA 13.0. La precisión nativa es BF16 (*brain floating-point* de 16 bits) en inferencia y entrenamiento, con FP32 en optimizador y pérdida durante el ajuste fino (precisión mixta canónica). La memoria unificada es clave para este trabajo: permite mantener cargados modelos del orden de 55 GB en BF16 sin *offloading* ni cuantización, de modo que incluso MedGemma 27B opera localmente y sin comprimir. El software queda fijado en Python 3.12.3, PyTorch 2.11.0, timm 0.9.16, scikit-learn, transformers, open_clip, sam2, peft y FAISS [28].

Los tiempos de cálculo característicos sobre este equipo orientan sobre el coste de cada protocolo: un linear probe completo de un encoder sobre un dataset estándar tarda 1–3 minutos; el fine-tuning de PanDerm Large sobre HAM10000 (50 épocas con TTA), unas 15 horas; el fine-tuning del decoder de SAM2.1-Large sobre ISIC2018 (50 épocas), unas 24 horas; la validación cruzada de cinco pliegues del modelo de segmentación, con la ablación de rango *LoRA* asociada, unas 18 horas; y el entrenamiento de un Sparse Autoencoder Large (16384 características), unas 4 horas.

3.6 Métricas

Ninguna métrica individual captura por sí sola el rendimiento sobre problemas dermatológicos, caracterizados por clases desbalanceadas, distintos niveles de granularidad diagnóstica y requisitos clínicos diversos. El trabajo reporta, por tanto, un conjunto de métricas complementarias para clasificación, segmentación, equidad y rendimiento computacional.

Clasificación. La métrica principal es la *Balanced Accuracy* (BAcc, promedio del *recall* por clase): se adopta porque asigna el mismo peso a todas las clases con independencia de su frecuencia, lo que evita que las categorías mayoritarias dominen la evaluación en los datasets desbalanceados de este trabajo. La *accuracy* acompaña como referencia comparativa entre modelos sobre la misma distribución. Se reportan además la F1 ponderada (media armónica de precisión y *recall*, pesada por frecuencia de clase), la AUROC *one-vs-rest* (`multi_class='ovr'` en `scikit-learn`, promediada sobre clases) y el coeficiente kappa de Cohen, que corrige la concordancia por azar. *Recall@k* —presencia de la etiqueta verdadera entre las k primeras posiciones del ranking— se reporta específicamente para melanoma sobre HAM10000.

Segmentación. La calidad de las máscaras predichas se evalúa mediante el coeficiente Dice (DSC) y la intersección sobre unión (IoU), dos métricas estándar que cuantifican el grado de solapamiento entre la segmentación automática y la máscara de referencia: $DSC = 2|P \cap G|/(|P| + |G|)$ e $IoU = |P \cap G|/|P \cup G|$, con P la máscara predicha y G la de referencia.

Equidad. BAcc por subgrupo Fitzpatrick (I-VI) sobre la formulación de tres clases de malignidad, y *gap* $\text{Gap}_{I \rightarrow VI} = \text{BAcc}_I - \text{BAcc}_{VI}$. Un valor próximo a cero indica rendimiento comparable entre fototipos extremos; su interpretación conjunta con la BAcc global se discute en la sección 3.9.7.

Operativas. Además del rendimiento predictivo, se evalúa el coste computacional asociado a cada modelo, que permite valorar la viabilidad de un despliegue en entornos clínicos con recursos limitados: latencia por consulta en milisegundos (inferencia más posproceso) y huella de memoria (VRAM en gigabytes, BF16), medidas sobre la infraestructura de sección 3.5.

Agregación entre datasets. Algunas vistas panorámicas del capítulo 4 reportan la media de una métrica sobre varios datasets externos. Esta media debe interpretarse únicamente como un resumen descriptivo de tendencias generales entre conjuntos con taxonomías, modalidades y prevalencias diferentes. No pretende establecer un ranking absoluto entre modelos, ya que datasets como HAM10000, DDI, PAD-UFES-20 o Dermnet no son estrictamente comparables entre sí. Por ello, todas las conclusiones se fundamentan en el análisis desglosado por dataset y por nivel ontológico, utilizando las métricas agregadas únicamente como apoyo descriptivo.

3.7 Pruebas estadísticas

Que un modelo obtenga una cifra mejor que otro no basta para afirmar que sea mejor: la diferencia podría deberse al azar de qué imágenes concretas cayeron en el conjunto de evaluación. Este riesgo es mayor en dermatología, donde los conjuntos de test son moderados, las clases están desbalanceadas y los casos son clínicamente heterogéneos. Para no confundir una diferencia real con una casualidad, el trabajo adopta un protocolo estadístico explícito, alineado con las guías de reporte para inteligencia artificial en imagen médica (CLAIM [41] y TRIPOD+AI [42]). Lo componen tres herramientas: los intervalos de confianza por *bootstrap*, que miden cuánto puede oscilar cada cifra; el test de DeLong, que compara dos modelos de forma justa; y la corrección de Holm, que evita dar por buenas diferencias surgidas de hacer muchas comparaciones.

El *bootstrap* responde a la pregunta “¿cuánto cambiaría esta cifra si el test hubiera estado formado por otras imágenes?”. El procedimiento es sencillo: se generan 1 000 conjuntos de test “alternativos” tomando imágenes del test real al azar y con reemplazo—conservando la proporción de clases—, y se recalcula la métrica en cada uno. La dispersión de esas 1 000 cifras describe su incertidumbre, y el rango que descarta el 2,5 % de valores más altos y el 2,5 % más bajos define el intervalo de confianza al 95 %: el margen dentro del cual cabe esperar el valor verdadero. Este método no exige suponer que los datos sigan ninguna distribución concreta, lo que lo hace apropiado para los conjuntos reducidos y desbalanceados de este trabajo, donde las fórmulas estadísticas clásicas no son fiables. Los intervalos al 95 % ($B = 1\,000$, remuestreo estratificado por clase, percentil 2,5/97,5) de las métricas *headline* que no los incluyen en el cuerpo figuran en el repositorio reproducible (A, sección A.6).

Para decidir si la diferencia de AUROC entre dos modelos es real, y no fruto del azar, se emplea el test de DeLong [39]. La razón de elegirlo es importante: como ambos

modelos se evalúan sobre exactamente las mismas imágenes, sus aciertos y errores están ligados; tratar sus dos AUROC como si procedieran de muestras independientes haría parecer las diferencias más significativas de lo que son. El test de DeLong tiene en cuenta esa relación y produce una comparación pareada correcta. Se aplica a los contrastes entre encoders sobre tres tareas binarias de detección de malignidad —Fitzpatrick17k, HAM10000 y DermapixelAI 1.0— (sección 4.8.1; tabla detallada en el repositorio reproducible, A.5).

Por último, cuando se hacen muchas comparaciones aumenta la probabilidad de que alguna parezca significativa solo por azar. Para controlarlo, los p -valores se reportan de dos maneras: el valor nominal (sin corregir) y el valor corregido por el método de Holm dentro de cada tarea. Mostrar ambos es deliberado: la corrección reduce los falsos positivos, pero también la capacidad de detectar diferencias reales, y ofrecer las dos cifras permite al lector juzgar por sí mismo la solidez de cada comparación. En la práctica, las diferencias observadas son tan grandes (con p varios órdenes de magnitud por debajo de 0,05) que las conclusiones principales se mantienen con cualquier corrección estándar. Los tamaños de muestra por subgrupo —por fototipo cutáneo y por nivel de la ontología— se recogen en las tablas 3.3 y 3.4, que ayudan a ver qué análisis tienen más respaldo: en particular, el escaso número de casos del fototipo VI ($n = 73$ en test) y la larga cola de diagnósticos poco frecuentes de L3 limitan la fiabilidad de las conclusiones en esos subgrupos. El detalle por subgrupo acompaña además a sus cifras en el capítulo 4.

Cuadro 3.3: Tamaño muestral por fototipo cutáneo (Fitzpatrick17k), cohorte de los análisis de equidad y del test de DeLong de malignidad. La evaluación del *gap* I-VI usa los 1597 casos de test con fototipo asignado; el *endpoint* binario de malignidad emplea los 1658 del test (226 malignos). El reducido tamaño del fototipo VI ($n = 73$ en test) acota la potencia estadística en ese subgrupo.

Fototipo (FST)	N corpus	N test
I	2947	299
II	4808	470
III	3308	325
IV	2781	261
V	1533	169
VI	635	73
Sin asignar	565	61
Total	16577	1658

Cuadro 3.4: Tamaño muestral por nivel ontológico sobre DermapixelAI 1.0 (1089 imágenes, 669 casos). El vocabulario común declara 4 categorías etiológicas L1, 43 subcategorías clínicas L2 y 367 diagnósticos L3; el dataset armonizado de los doce externos aporta 72654 imágenes mapeadas a ese vocabulario. La long tail L3 concentra 64 clases con una sola imagen, 129 con dos a cinco, 39 con seis a diez, 11 con once a veinte y 7 con veintiuna o más.

Nivel	Declarado	Representado
L1	4	4
L2	43	38
L3	367	250

Conviene aclarar que este aparato estadístico no se aplica por igual en todo el trabajo. El test de DeLong y la corrección por comparaciones múltiples se usan allí donde comparar modelos es el objetivo central —el ranking de encoders en detección de malignidad (sección 4.8.1)—, y los intervalos por *bootstrap* acompañan a las métricas principales sobre DermapixelAI 1.0 y a la validación cruzada de segmentación. Otros bloques —el linear probe sobre los datasets externos, la eficiencia en etiquetas y la equidad por fototipo— se presentan como una sola estimación, sin repetirla con varias semillas (sección 7.3.1). Por eso las afirmaciones se gradúan según el respaldo estadístico disponible: se presentan como patrones sólidos cuando la diferencia supera con holgura la variabilidad esperable, y con la cautela correspondiente cuando no se dispone de un contraste formal.

3.8 Trazabilidad y reproducibilidad

La reproducibilidad es una condición necesaria para la validación independiente de los resultados. El trabajo se diseña, por tanto, para que cualquier número del capítulo 4 se reconstruya a partir de artefactos persistentes y no de la memoria de una ejecución concreta. Tres mecanismos articulan esta garantía.

El primero es el determinismo de la ejecución. Las semillas aleatorias se fijan a 0 para `torch`, `numpy` y `random` en fine-tuning y segmentación, y a 42 en `random_state` para los protocolos basados en `scikit-learn` (linear probe, eficiencia en etiquetas, equidad). El entorno queda fijado a las versiones de sección 3.5, y cualquier desviación se documenta en el experimento afectado. Por último, se deshabilita la telemetría externa y se fija explícitamente el dispositivo de ejecución para evitar variaciones no controladas del entorno experimental.

El segundo mecanismo es la persistencia de las salidas. Los resultados numéricos se vuelcan a ficheros CSV o JSON con esquema estable, lo que permite reconstruir cualquier tabla o figura del capítulo 4 sin reejecutar nada, y los mapeos de etiquetas nativas a la ontología L1/L2/L3 se mantienen fijos entre experimentos. El tercero es la integridad de la cadena de cómputo: cuando un experimento toma como entrada la salida de otro —por ejemplo, los *embeddings* del linear probe alimentan la rama visual del zero-shot—, la identidad de esa entrada se preserva mediante hash MD5 del fichero. El encadenamiento por hash convierte el conjunto de experimentos en un grafo de dependencias verificable: cualquier alteración silenciosa de una entrada intermedia invalidaría el hash y sería detectable, lo que protege la cadena de evidencia frente a la deriva de datos entre etapas dependientes. El listado completo de tareas reproducibles, con sus comandos, ficheros de salida y *checkpoints*, figura en el repositorio reproducible (A, sección A.13).

3.9 Experimentos

Los experimentos se organizan en cuatro bloques. El primero mide la calidad y la adaptabilidad de las representaciones visuales: el linear probe evalúa lo que capturan los encoders congelados, el fine-tuning su rendimiento máximo tras adaptación supervisada, y la eficiencia en etiquetas cuántos datos anotados hacen falta para alcanzarlo. El segundo aborda la localización espacial de la lesión mediante segmentación. El tercero

examina la capacidad multimodal: la clasificación *zero-shot* guiada por texto y la comparación con los grandes modelos de lenguaje generalistas. El cuarto comprueba la equidad del rendimiento entre fototipos cutáneos; la independencia entre evaluación y preentrenamiento ya quedó verificada al describir los datos (sección 3.1.1). La tabla 3.5 resume cada experimento, la pregunta que responde y su alcance. Todos comparten la infraestructura (sección 3.5) y las semillas declaradas (sección 3.8), de modo que sus cifras son comparables entre sí.

Cuadro 3.5: Resumen de los experimentos: la pregunta que responde cada uno y su alcance en modelos y datasets. DermapixelAI 1.0 se evalúa además en linear probe y *zero-shot* (secciones 5.1 y 5.2).

Experimento	Pregunta	Modelos	Datasets
Linear probe (3.9.1)	Calidad de las representaciones congeladas	8 encoders visuales	10 externos de clasificación
Fine-tuning (3.9.2)	Rendimiento máximo tras adaptación supervisada	PanDerm Base/Large	HAM10000, PAD-UFES-20, DDI, MSKCC
Eficiencia en etiquetas (3.9.3)	Datos anotados necesarios	PanDerm Large	HAM10000, PAD-UFES-20
Segmentación (3.9.4)	Localización de la lesión; arquitectura, dominio y tamaño	5 modelos SAM/SAM2 y controles	ISIC2018 (transferencia a ISIC2017, PH2)
Zero-shot multimodal (3.9.5)	Transferencia guiada por texto sin entrenamiento	DermLIP, BiomedCLIP, SigLIP	HAM10000, HIBA, MSKCC, DDI, Derm7pt clínico
Modelos generalistas (3.9.6)	¿Compiten con los encoders especializados?	GPT-4o, Gemini 2.5 Pro, MedGemma 4B/27B	HAM10000
Equidad por fototipo (3.9.7)	Estabilidad del rendimiento entre fototipos	5 encoders	Fitzpatrick17k

3.9.1 Linear probe (LP)

El linear probe mide el valor de las representaciones de un encoder sin modificarlo: se congela el encoder y se entrena un clasificador lineal sobre los *embeddings* que extrae. La extracción aplica la normalización canónica de cada modelo —parámetros ImageNet para PanDerm y DINOv2, parámetros OpenAI CLIP para DermLIP, BiomedCLIP y SigLIP— y los vectores se persisten en disco para no recomputarlos entre experimentos. El clasificador es una regresión logística multinomial entrenada sobre las particiones canónicas de la tabla 3.1; su configuración exacta y los parámetros de normalización por modelo figuran en el repositorio reproducible (A, sección A.13). El protocolo se aplica a PanDerm Base y Large, DINOv2, ConvNeXt-Large, EfficientNetV2-Large y la rama visual de DermLIP v2, BiomedCLIP y SigLIP-Large.

3.9.2 Fine-tuning supervisado (FT)

A diferencia del linear probe, el fine-tuning sí modifica el encoder: entrena de forma conjunta el encoder visual y una head de clasificación. La receta reproduce la del paper original de PanDerm [1], para que la comparación sea directa: optimizador AdamW con *cosine annealing* y *warmup* lineal, regularización combinada (*layer decay*, *drop-path*,

label smoothing, Mixup y CutMix) y un *weighted random sampler* con pesos inversos a la frecuencia de clase, sobre 50 épocas en precisión mixta canónica con semillas fijadas a 0. El listado completo de hiperparámetros figura en el repositorio reproducible (A, sección A.13). En la evaluación final sobre HAM10000 se añade *test-time augmentation* (TTA): se promedian los logits de 5 aumentaciones deterministas por imagen. El protocolo se aplica a PanDerm Base y Large sobre HAM10000, PAD-UFES-20, DDI y MSKCC.

3.9.3 Eficiencia en etiquetas

Este protocolo responde a una pregunta práctica: cuántas etiquetas hacen falta. Manteniendo el encoder congelado, se entrenan clasificadores lineales (misma configuración que el linear probe, sección 3.9.1) sobre submuestreos estratificados del conjunto de entrenamiento de HAM10000 y PAD-UFES-20 al 1 %, 5 %, 10 %, 20 %, 50 % y 100 %. La estratificación preserva la proporción de clases en cada subconjunto y los submuestreos se generan con `random_state = 42`. PanDerm Large es el encoder principal; PanDerm Base se usa como referencia adicional sobre HAM10000.

3.9.4 Segmentación binaria de lesión

La segmentación evalúa la capacidad de localizar la lesión, y permite separar la contribución de la arquitectura, del preentrenamiento médico y del tamaño del *backbone* en la familia *Segment Anything*. La evaluación se organiza en dos protocolos complementarios y varios análisis de robustez.

Adaptación de SAM2.1-Large al dominio dermatológico. El primer protocolo adapta SAM2.1-Large mediante fine-tuning denso de su decoder: se ajustan el decoder de máscaras y el *promptable encoder*, mientras que el *image encoder* (Hiera-Large preentrenado) permanece congelado, de modo que solo $\sim 4,2$ M parámetros resultan entrenables (~ 17 MB de *checkpoint*). La optimización (AdamW, pérdida combinada *cross-entropy*+*Dice*, normalización uniforme según la convención de SAM2) se detalla en el repositorio reproducible (A, sección A.13). El entrenamiento es sobre ISIC2018 [11] y la transferencia fuera de dominio se evalúa sobre ISIC2017 y PH2 sin reentrenamiento. Como referencias no adaptadas se incluyen SAM2 *zero-shot* sin fine-tuning y un *Convolutional AutoEncoder* (CAE-seg) entrenado desde cero con idéntica pérdida y optimización.

Comparación controlada entre arquitecturas de segmentación. El segundo protocolo separa los tres factores que determinan el rendimiento —generación de arquitectura, preentrenamiento de dominio y tamaño de *backbone*— mediante una comparativa pareada de cinco arquitecturas de segmentación *promptable*: MedSAM2-tiny [44], SAM2.1-tiny y SAM2.1-Large (familia SAM2 [20]), y SAM-Med2D [45] y MedSAM v1 [43] (familia SAM [26]). Todas se entrenan bajo un régimen común (fine-tuning denso del decoder y el *promptable encoder*, encoder visual congelado, *prompt* de *bounding box* derivada de la máscara de referencia) sobre un dataset dermatoscópico ampliado y deduplicado por hash MD5 de píxel (14 201 imágenes únicas de ISIC2018, ISIC2017, HAM10000-seg y PH2), y se evalúan sobre el mismo test canónico de ISIC2018 ($N = 1\,000$, blindado

frente al entrenamiento). La significación de las diferencias de Dice se contrasta con el test de Wilcoxon pareado [40].

Análisis complementarios. Para interpretar las diferencias observadas entre arquitecturas se realizan cuatro análisis complementarios. Un control automático sin caja —una U-Net con encoder ResNet-101 preentrenado en ImageNet— se evalúa sin recibir *bounding box* para aislar la contribución del *prompt*. La estabilidad de la mejor configuración se estima por validación cruzada de cinco pliegues estratificados por dataset de origen, junto a una ablación del rango de adaptación de bajo rango (*LoRA*, $r \in \{4, 8, 16, 32\}$); su robustez frente a la calidad del *prompt* se mide bajo perturbaciones controladas de la *bounding box*, y la confianza de las máscaras se calibra *a posteriori* mediante *temperature scaling*. Por último, el techo de la métrica se contextualiza frente al acuerdo inter-anotador del propio dataset.

3.9.5 Clasificación zero-shot multimodal

La clasificación zero-shot mide qué pueden clasificar los modelos vision-language sin entrenamiento específico sobre las clases objetivo, aprovechando su espacio compartido imagen-texto. Cada clase candidata se formula como una o varias frases de plantilla, que el encoder textual codifica y —cuando hay varias por clase— promedia en un único vector; la imagen se codifica con el encoder visual y gana la clase de mayor similitud coseno. Sobre HAM10000 se comparan tres formulaciones de *prompt*: (i) genéricos en inglés, una plantilla por clase (p. ej. “*a dermoscopic image of a melanoma*”); (ii) el conjunto A3 del paper de Derm1M [2], que sustituye el nombre simple de cada enfermedad por varias descripciones clínicas y visuales más informativas; y (iii) una versión enriquecida de A3 con descriptores clínicos (modalidad, localización, criterios visuales). Para caracterizar la sensibilidad al tokenizer, el protocolo se ejecuta con los dos tokenizers de la familia DermLIP: PubMedBERT a 256 tokens (v1/v2) y GPT-2 con tokenizer de CLIP a 77 tokens (original). Sobre HIBA, MSKCC, DDI y Derm7pt clínico se corre la versión binaria melanoma/no-melanoma con *prompts* genéricos y A3. De este modo, el protocolo permite aislar el efecto de tres componentes fundamentales del rendimiento zero-shot: el modelo multimodal utilizado, la formulación textual de las clases y el tokenizer empleado por la rama lingüística.

3.9.6 Comparación con modelos de lenguaje multimodales

Este protocolo evalúa si los grandes modelos multimodales de propósito general, capaces de procesar simultáneamente imagen y texto, compiten con los encoders especializados de las secciones anteriores bajo un escenario común de clasificación diagnóstica. La comparación contrapone dos paradigmas —la especialización dermatológica explícita frente a la escala de los modelos generalistas—, con los modelos biomédicos generales (MedGemma) en posición intermedia, lo que permite contrastar la contribución relativa de la especialización de dominio frente a la escala del preentrenamiento.

Para situar a los encoders frente a los grandes modelos generalistas, el protocolo evalúa GPT-4o (API OpenAI), Gemini 2.5 Pro (API Google), MedGemma 4B Vision (local) y MedGemma 27B Text (local en BF16) sobre el mismo *split* de test de HAM10000 (1 232 imágenes) usado en linear probe y fine-tuning. El *prompt* clínico estandarizado (unas

300 palabras) plantea la tarea como apoyo al diagnóstico —no sustitución del juicio clínico—, presenta las siete categorías de HAM10000 con una descripción breve y pide el diagnóstico más probable con razonamiento estructurado. La etiqueta se extrae por *parsing* determinista que mapea el nombre del diagnóstico al código de HAM10000; las respuestas no mapeables (menos del 1 % en todos los modelos) cuentan como incorrectas. El modo principal es *zero-shot*; para MedGemma 27B se evalúa además una variante ajustada con LoRA ($r = 8$) sobre el entrenamiento de HAM10000.

3.9.7 Evaluación de equidad por fototipo

Diversos estudios han señalado que muchos conjuntos de entrenamiento presentan una representación desigual de los fototipos cutáneos, lo que puede traducirse en diferencias de rendimiento entre grupos poblacionales [13]. Por ello, además de la precisión global, este protocolo mide si el rendimiento se mantiene estable a lo largo del espectro de fototipos de la escala de Fitzpatrick. Cinco encoders (PanDerm Large, PanDerm Base, la rama visual de DermLIP v2, DINOv2 ViT-L/14 y BiomedCLIP) se evalúan sobre Fitzpatrick17k completo (16577 imágenes, 114 patologías, 6 fototipos I-VI) por linear probe (configuración de sección 3.9.1, con la normalización canónica de cada modelo). Se reportan dos formulaciones: clasificación a 114 patologías (grano fino) y a 3 clases de malignidad (benigno / no neoplásico / maligno), esta última habitual en estudios de equidad sobre Fitzpatrick17k. Las métricas se calculan por subgrupo sobre los seis fototipos, y la equidad se resume con la brecha entre los extremos $\text{Gap}_{I \rightarrow VI} = \text{BAcc}_I - \text{BAcc}_{VI}$. La brecha entre fototipos extremos resume de forma sencilla la estabilidad del rendimiento entre grupos; su interpretación, no obstante, debe realizarse conjuntamente con la exactitud global, ya que una diferencia reducida puede reflejar tanto un comportamiento equitativo como un rendimiento uniformemente bajo en todos los subgrupos. El experimento se verifica re-ejecutando el sondeo sobre PanDerm Large y comprobando coincidencia hasta cuatro decimales con el resultado original.

RESULTADOS

Este capítulo presenta los resultados de la evaluación de modelos fundacionales dermatológicos y de las contribuciones originales del trabajo, que concretan sus objetivos formales (sección 1.2). La secuencia es acumulativa: establecida en la metodología la independencia entre los conjuntos de evaluación y el preentrenamiento (sección 3.1.1), se estudia la transferencia supervisada (linear probe, fine-tuning, eficiencia en etiquetas), las tareas de segmentación, clasificación *zero-shot* y razonamiento multimodal, y los aspectos de equidad y seguridad diagnóstica; y, finalmente, las contribuciones propias sobre DermapixelAI 1.0 y Dermapixel R0, la interpretabilidad mediante *Sparse Autoencoders* y una síntesis comparativa. En conjunto, los experimentos permiten analizar el impacto del preentrenamiento específico de dominio, las distintas estrategias de adaptación y el papel de los datos en la transferencia de modelos fundacionales a un entorno clínico dermatológico en castellano.

4.1 Evaluación de PanDerm

El trabajo arranca evaluando PanDerm, el modelo fundacional dermatológico que se toma como referencia: se mide si sus representaciones, sin reajustar el encoder, clasifican lesiones en datasets externos no vistos. El encoder de mayor capacidad (PanDerm Large) transfiere de forma robusta entre datasets, con ventaja creciente en los escenarios de mayor heterogeneidad de adquisición y complejidad taxonómica, como cuantifican los diez datasets externos a continuación.

La tabla 4.1 aplica este protocolo a PanDerm Base y Large sobre los diez datasets externos contrastados, conforme a sección 3.9.1. Se reportan cinco métricas: *accuracy* (Acc), *balanced accuracy* (BAcc), AUROC *one-vs-rest*, F1 ponderada (W-F1) y coeficiente kappa de Cohen.

Sobre los diez datasets evaluados (estimación de semilla única, sección 3.7), PanDerm Large supera a PanDerm Base en cuatro de las cinco métricas, con mejoras medias de +4,1 pp en *accuracy*, +9,0 pp en *balanced accuracy* y +3,6 pp en AUROC; la

4. RESULTADOS

Cuadro 4.1: Linear probe con PanDerm Base y Large sobre diez datasets externos. El asterisco (*) marca Dermnet, el único dataset con solapamiento exacto frente a Derm1M (100 % por hash MD5; sección 3.1.1). Mejores valores por dataset y métrica en negrita.

Dataset	Modelo	Acc	BAcc	AUROC	W-F1	Kappa
HAM10000	Base	0,853	0,381	0,892	0,829	0,709
HAM10000	Large	0,888	0,575	0,954	0,880	0,814
BCN20000	Base	0,659	0,292	0,855	0,615	0,447
BCN20000	Large	0,702	0,382	0,903	0,676	0,527
PAD-UFES-20	Base	0,725	0,510	0,913	0,692	0,369
PAD-UFES-20	Large	0,772	0,642	0,949	0,760	0,527
Dermnet*	Base	0,450	0,381	0,888	0,432	0,437
Dermnet*	Large	0,550	0,495	0,931	0,540	0,555
WSI patches	Base	0,781	0,640	0,976	0,774	0,842
WSI patches	Large	0,868	0,792	0,991	0,871	0,896
DDI	Base	0,847	0,714	0,827	0,836	0,482
DDI	Large	0,847	0,764	0,860	0,846	0,535
Derm7pt clín.	Base	0,762	0,675	0,808	0,736	0,397
Derm7pt clín.	Large	0,798	0,732	0,869	0,784	0,506
Derm7pt dermo	Base	0,818	0,749	0,841	0,811	0,528
Derm7pt dermo	Large	0,836	0,766	0,858	0,829	0,570
HIBA	Base	0,883	0,595	0,894	0,853	0,275
HIBA	Large	0,904	0,701	0,942	0,892	0,494
MSKCC	Base	0,721	0,654	0,746	0,720	0,309
MSKCC	Large	0,746	0,644	0,751	0,732	0,316
<i>Media</i>	Base	0,750	0,559	0,865	0,730	—
<i>Media</i>	Large	0,791	0,649	0,901	0,781	—

única excepción es la BAcc de MSKCC (−1,0 pp; figura 4.1).




Figura 4.1: Linear probe con PanDerm Base y Large sobre los diez datasets externos contrastados. Diferencia absoluta en BAcc (+9,0 pp de promedio) y AUROC (+3,6 pp de promedio) a favor de PanDerm Large.

Las mayores ganancias aparecen en Dermnet, WSI patches y PAD-UFES-20 —los escenarios más heterogéneos del benchmark—, lo que sugiere que el aumento de capacidad del encoder beneficia especialmente la generalización compleja. Dermnet, no obstante, está íntegramente contenido en Derm1M (100 % por hash MD5; sección 3.1.1) y su cifra debe leerse con ese *caveat*.

En conjunto, las representaciones de la familia PanDerm transfieren de forma consistente a múltiples cohortes externas y a las tres modalidades evaluadas —clínica, dermatoscópica e histopatológica—, más allá del dataset de origen. Las medias por columna agregan datasets de taxonomía, modalidad y prevalencia heterogéneas, por lo que se interpretan como tendencia descriptiva y no como marcador absoluto del mejor modelo (sección 3.6).

4.2 Comparación con otras familias de modelos

Para distinguir si la ventaja de PanDerm Large refleja el preentrenamiento dermatológico o una mera comparación favorable frente a su versión Base, se sitúa frente a familias con filosofías de aprendizaje distintas: arquitecturas convolucionales supervisadas, modelos auto-supervisados generalistas y sistemas vision-language a gran escala. La tabla 4.2 compara cinco modelos representativos sobre HAM10000, PAD-UFES-20 y DDI bajo el mismo protocolo de linear probe.

Cuadro 4.2: Benchmark comparativo bajo linear probe sobre HAM10000, PAD-UFES-20 y DDI. Mejor valor por columna en negrita. La AUROC del DDI de las líneas base convolucionales se calcula sobre $N = 220$ (fusión de validación y test en el *script* de extracción CNN), frente a $N = 137$ (solo test) en PanDerm Large y SigLIP; la convención de promediado de la AUROC multiclase tampoco es homogénea entre filas (OvR-macro en las CNN, OvR-ponderada en SigLIP, OvO-macro en PanDerm). Ambas particularidades —y el mismo desajuste de N en las filas Gemini de la tabla 4.7— se documentan celda a celda en el repositorio reproducible (A, sección A.6).

Modelo	Tipo	Params	HAM Acc	HAM AUROC	PAD Acc	PAD AUROC	DDI AUROC
ConvNeXt-Large	ConvNet sup.	197 M	0,883	0,967	0,668	0,894	0,774
EfficientNetV2-Large	ConvNet sup.	118 M	0,860	0,950	0,690	0,895	0,766
DINOv2 ViT-L/14	SSL general	307 M	0,744	0,847	—	—	—
PanDerm Large	SSL derm.	307 M	0,888	0,954	0,772	0,949	0,860
SigLIP-Large SO400M	Vis-leng. gen.	400 M	0,900	0,971	0,718	0,903	0,793

PanDerm Large supera en accuracy a la mejor CNN supervisada (la mejor de ConvNeXt-L y EfficientNetV2-L por métrica) sobre los tres datasets, con ventaja no uniforme: +0,5 pp en HAM10000 (dermatoscopia estandarizada) frente a +8,2 pp en PAD-UFES-20 (fotografía móvil) y +2,9 pp en DDI (+8,6 pp AUROC; desglose en el repositorio reproducible, A, sección A.5). HAM10000 constituye una excepción parcial: SigLIP-Large SO400M obtiene la mejor accuracy y AUROC, y ConvNeXt-Large supera ligeramente a PanDerm Large en AUROC (−1,3 pp). Este comportamiento sugiere que los beneficios del preentrenamiento de dominio son menores en entornos dermatoscópicos altamente estandarizados; en cambio, PanDerm Large encabeza en PAD-UFES-20 y DDI, los datasets clínicos más alejados del dominio web.

No existe, por tanto, una jerarquía universal entre familias: los sistemas vision-language generalistas igualan o superan a los especializados en escenarios dermatoscópicos muy estandarizados, mientras que los modelos dermatológicos mantienen ventaja cuando aumenta la variabilidad clínica. El preentrenamiento de dominio ofrece una ventaja *creciente* con la heterogeneidad, no una superioridad absoluta, lo que anticipa la tesis de especialización por tarea (sección 6.1.1). Como modelo dermatológico de referencia —abierto y el más sólido sobre los datasets clínicos más exigentes—,

PanDerm se adopta como base de los protocolos que siguen, en los que se estudia hasta dónde puede llevarse su rendimiento.

4.3 Fine-tuning supervisado

Esta sección delimita cuándo el fine-tuning del encoder mejora sobre la representación congelada y cuándo es contraproducente, decisión central para los datasets clínicos pequeños. El fine-tuning mejora con una cantidad moderada o elevada de datos de entrenamiento y puede degradar el rendimiento bajo baja disponibilidad de muestras. La tabla 4.3 lo concreta comparando el linear probe con el fine-tuning supervisado de PanDerm Base sobre cuatro datasets de tamaño dispar, con la configuración descrita en sección 3.9.2. Sobre HAM10000 se añade además *test-time augmentation* con cinco aumentaciones deterministas.

Cuadro 4.3: Linear probe (LP) frente a fine-tuning (FT) con PanDerm Base. Δ Bacc en puntos porcentuales respecto al LP.

Dataset	Modo	Acc	BAcc	AUROC	W-F1	Δ Bacc
HAM10000	LP	0,853	0,381	0,892	0,829	—
HAM10000	FT	0,920	0,852	0,978	0,923	+47,1
PAD-UFES-20	LP	0,725	0,510	0,913	0,692	—
PAD-UFES-20	FT	0,755	0,704	0,935	0,757	+19,4
DDI	LP	0,847	0,714	0,827	0,836	—
DDI	FT	0,774	0,693	0,682	0,780	-2,1
MSKCC	LP	0,721	0,654	0,746	0,720	—
MSKCC	FT	0,731	0,684	0,719	0,735	+3,0

El fine-tuning mejora sustancialmente el rendimiento en HAM10000 (+47,1 pp Bacc) y PAD-UFES-20 (+19,4 pp), especialmente sobre las clases minoritarias responsables de la baja *balanced accuracy* del linear probe. El beneficio desaparece, en cambio, cuando disminuye la disponibilidad de datos: DDI muestra degradación global compatible con sobreajuste y MSKCC sólo mejoras marginales. En la práctica, esto deja una regla sencilla: con un *dataset* clínico grande conviene hacer fine-tuning, pero con pocos datos es más seguro quedarse con el encoder congelado, porque el fine-tuning tiende a sobreajustar. Este resultado justifica la exploración posterior de adaptación eficiente de parámetros (PEFT, sección 5.3) y motiva cuantificar cuántas etiquetas son realmente necesarias, objeto de la sección siguiente.

4.4 Eficiencia en etiquetas

Se mide el rendimiento de PanDerm Large bajo submuestreos estratificados crecientes del conjunto de entrenamiento, dado que el etiquetado experto es el principal cuello de botella en dermatología. Una fracción mínima del conjunto basta para casi saturar el rendimiento. La tabla 4.4 lo cuantifica con submuestreos al 1 %, 5 %, 10 %, 20 %, 50 % y 100 % sobre HAM10000 y PAD-UFES-20.

La AUROC satura tempranamente en ambos datasets: el 1 % de HAM10000 (82 imágenes) ya recupera AUROC 0,918 y el 5 % (410) el 97,7 % del máximo; sobre PAD-UFES-20, 14 imágenes recuperan el 95,5 % de la AUROC final. La *balanced accuracy*, en cambio, sigue mejorando con el volumen, reflejando mayor sensibilidad a las clases

Cuadro 4.4: Eficiencia en etiquetas (linear probe con PanDerm Large). N_{train} : tamaño efectivo del subconjunto de entrenamiento. Mejor valor por columna en negrita.

% entrenam.	N_{train}	Acc	BAcc	AUROC	W-F1
<i>HAM10000</i>					
1 %	82	0,850	0,406	0,918	0,828
5 %	410	0,870	0,481	0,932	0,855
10 %	820	0,875	0,480	0,939	0,863
20 %	1 641	0,882	0,547	0,951	0,873
50 %	4 103	0,894	0,589	0,952	0,887
100 %	8 207	0,888	0,575	0,954	0,880
<i>PAD-UFES-20</i>					
1 %	14	0,740	0,599	0,907	0,727
5 %	74	0,751	0,632	0,919	0,742
10 %	149	0,738	0,593	0,923	0,724
20 %	298	0,748	0,587	0,931	0,728
50 %	746	0,757	0,611	0,941	0,742
100 %	1 493	0,772	0,642	0,949	0,760

minoritarias. La conclusión práctica es llamativa: con muy pocas imágenes etiquetadas —del orden de unas decenas— ya se alcanza casi todo el rendimiento, porque el encoder preentrenado aporta la mayor parte de la capacidad de discriminar y las etiquetas solo afinan la frontera de decisión. Esto reduce mucho la dependencia de grandes volúmenes de anotación experta, el principal cuello de botella en dermatología. Las cifras proceden de una única partición y semilla por nivel de submuestreo, por lo que delimitan una tendencia y no un margen con cierre estadístico.

4.5 Segmentación binaria de lesión

Este bloque evalúa si un modelo fundacional de segmentación adaptado al dominio dermatológico alcanza una delimitación de lesión de calidad clínica y qué factores la determinan. La tabla 4.5 compara SAM2.1-Large adaptado al dominio mediante fine-tuning del decoder frente a SAM2 sin adaptar (*zero-shot*), un autoencoder convolucional sobre PanDerm Large (CAE-seg) y la referencia publicada por Yan et al. [1], analizando además su generalización fuera de dominio sobre ISIC2017 y PH2; las subsecciones posteriores aíslan el efecto de la arquitectura, del *prompt* y de la variabilidad inter-anotador.

Cuadro 4.5: Segmentación binaria de lesión: Dice de test sobre tres datasets dermatoscópicos. Modelos entrenados sobre ISIC2018 y evaluados sin reentrenamiento sobre ISIC2017 y PH2.

Configuración	ISIC2018 Dice	ISIC2017 Dice	PH2 Dice
SAM2 <i>zero-shot</i> (bbox de GT)	—	0,797	0,886
CAE-seg (PanDerm-L) FT ISIC2018	0,894	0,879	0,924
PanDerm [1] (ref.)	0,921	—	—
SAM2.1-L (decoder FT) ISIC2018	0,947	0,945	0,960

El detalle con la desviación estándar y el IoU sobre los datasets de transferencia (ISIC2017 y PH2) figura en el repositorio reproducible (A, sección A.5).

SAM2.1-L con fine-tuning del decoder alcanza Dice 0,947 sobre ISIC2018, +2,6 pp sobre la cifra publicada por Yan et al. [1] y +5,3 pp sobre el CAE-seg: supera, por tanto,

la referencia previa. Su generalización fuera de dominio es prácticamente nula (Dice 0,945 en ISIC2017 y 0,960 en PH2, este último superior por su mayor limpieza visual). Y, sobre todo, la adaptación del decoder aporta +14,8 pp en ISIC2017 (0,797 $\rightarrow$ 0,945) y +7,4 pp en PH2 (0,886 $\rightarrow$ 0,960) frente a SAM2 sin adaptar: es la adaptación al dominio, y no el tamaño bruto del modelo, lo que explica la mayor parte de la mejora.

Desde una perspectiva aplicada, este resultado anticipa una lectura que las subsecciones siguientes confirman: una vez disponible una caja que *localice* la lesión, la calidad del contorno depende poco del segmentador concreto (sección 4.5.2), de modo que localizar la lesión puede importar más que la precisión absoluta de la máscara.

4.5.1 Comparativa de arquitecturas promptables

La cifra anterior mezcla generación de arquitectura, preentrenamiento de dominio y tamaño de *backbone*. Para separarlos, se evalúan de forma pareada cinco arquitecturas *promptables* sobre un dataset dermatoscópico ampliado y deduplicado por hash MD5 (14 201 imágenes únicas de ISIC2018, ISIC2017, HAM10000-seg y PH2), bajo régimen común (fine-tuning denso del decoder y el *promptable encoder*, encoder visual congelado, *prompt* de *bounding box* de referencia; detalle de optimización en Cap. 3) y sobre el mismo test canónico de ISIC2018 ($N = 1\,000$, blindado) que la cifra de referencia 0,947 de la tabla 4.5. La tabla 4.6 reporta el Dice resultante.

Cuadro 4.6: Comparativa de cinco arquitecturas promptables sobre el test canónico de ISIC2018 ($N = 1\,000$). Régimen común de fine-tuning del decoder con *prompt* de *bounding box*. Las diferencias de Dice son modestas en valor absoluto pero significativas al test de Wilcoxon pareado [40] ($p < 10^{-6}$ en todos los contrastes).

Modelo	Arquitectura	Preentr.	Params	Dice	Latencia
MedSAM2-tiny [44]	SAM2 [20]	médico	39 M	0,9556	26 ms
SAM2.1-tiny	SAM2 [20]	general	39 M	0,9517	26 ms
SAM2.1-Large	SAM2 [20]	general	224 M	0,9503	96 ms
SAM-Med2D [45]	SAM [26]	médico	271 M	0,9465	20 ms
MedSAM v1 [43]	SAM [26]	médico	94 M	0,9458	74 ms

Tres conclusiones emergen de la comparación, con todos los contrastes pareados significativos (tabla 4.6). *Primero*, la generación SAM2 aporta más que el preentrenamiento médico: los tres modelos SAM2 superan a los basados en SAM v1, incluso a los de preentrenamiento médico. *Segundo*, el preentrenamiento médico ofrece una mejora adicional, pero solo dentro de la misma generación y de menor magnitud. *Tercero*, el tamaño del *backbone* aporta poco en régimen *box-prompted*: SAM2.1-tiny iguala o supera a SAM2.1-Large con 5,7 veces menos parámetros y menor latencia. La mejor configuración es MedSAM2-tiny (0,9556, 26 ms), que combina generación SAM2 y preentrenamiento médico en el *backbone* más compacto. Que la arquitectura pese más que el preentrenamiento médico matiza la hipótesis central del trabajo: en este régimen, el diseño del segmentador domina sobre la especialización dermatológica. Las tres subsecciones siguientes acotan cuánto del resultado depende del *prompt*, su estabilidad y su techo real.

4.5.2 Valor del prompt: control automático sin caja

Toda la comparativa anterior opera en régimen *box-prompted*: cada predicción parte de una *bounding box* derivada de la máscara de referencia. Para aislar la contribución de ese *prompt* se entrena un control automático que no recibe caja alguna —una U-Net con encoder ResNet-101 preentrenado en ImageNet, fine-tuning denso de 51,5 M de parámetros sobre el mismo dataset *v1c*— y se evalúa sobre el test canónico de ISIC2018, contrastando su Dice con el del mejor modelo *promptable* (desglose completo con IoU, precisión y recall en el repositorio reproducible, A, sección A.5).

El control automático alcanza Dice 0,8811, 7,5 pp por debajo del mejor modelo *box-prompted* (0,9556). La comparación de magnitudes es reveladora: la arquitectura mueve $\sim 1,0$ pp de Dice (tabla 4.6) y el preentrenamiento médico $\sim 0,4$ pp, pero retirar la caja cuesta 7,5 pp —entre seis y siete veces más que cualquiera de los otros dos factores—. El factor dominante de la segmentación dermatoscópica no es, por tanto, ni la arquitectura ni el preentrenamiento, sino la disponibilidad de una localización razonable de la lesión. El perfil de error del modo automático lo confirma —recall alto (0,942) pero precisión desplomada (0,856) y Hausdorff 95 entre 2,5 y 3 veces peor (desv. 0,121), señal de fallos catastróficos puntuales que la caja elimina—. El control valida además que la comparativa fue justa: todos los modelos compartían el mismo *prompt*, de modo que sus diferencias reflejan el segmentador y no la información de localización.

4.5.3 Robustez del resultado: validación cruzada, prompt y calibración

La cifra de 0,9556 procede de una única partición. Una validación cruzada de cinco pliegues sobre MedSAM2-tiny confirma su robustez: Dice $0,9554 \pm 0,0010$ (IC95 % [0,9543, 0,9564]), con la cifra principal dentro del intervalo y una desviación interpliegue (8×10^{-4}) que descarta dependencia de una partición afortunada.

La estabilidad frente a la calidad del *prompt* es crítica en despliegue, donde la caja procede de un anotador o detector y no de la máscara de referencia. Bajo perturbaciones controladas, el *jitter* de esquinas (± 20 px) apenas resta 0,86 pp, pero la escala es crítica y asimétrica: apretar la caja es catastrófico ($-6,8$ pp al -10% , $-15,4$ pp al -20% , por recortar lesión real) mientras que aflojarla degrada poco ($-2,8$ pp al $+10\%$; figura 4.2). La lectura operativa se desarrolla en sección 6.1.10.

El resto de comprobaciones confirman un modelo bien comportado y no alteran la conclusión: el ajuste de bajo rango (LoRA $r \in \{4, 8, 16, 32\}$) iguala al ajuste denso del decoder; la calibración a nivel de píxel es buena (ECE 0,0082); la equidad por fototipo (ITA) muestra una brecha de solo 1,1 pp entre fototipos extremos; y el aumento en test y el *ensemble* de pliegues aportan mejoras marginales ($+0,13/+0,14$ pp) que no compensan su coste, por lo que se recomienda un único modelo.

4.5.4 El techo de la métrica: acuerdo inter-anotador

El hallazgo más relevante de este bloque no es la cifra absoluta de Dice, sino su relación con el límite humano. El Dice se mide contra una máscara de referencia trazada por una persona, y el contorno de una lesión es intrínsecamente ambiguo: sobre el subconjunto de IMA++ con anotación múltiple (312 imágenes con dos o más máscaras independientes, reservado y nunca usado en entrenamiento), el acuerdo *inter-anotador* es de solo




Figura 4.2: Robustez de MedSAM2-tiny a la calidad de la caja-*prompt* sobre el test canónico de ISIC2018 ($N = 1000$). El *jitter* de esquinas es prácticamente inocuo ($-0,86$ pp), pero la escala es crítica y asimétrica: apretar la caja degrada mucho más que aflojarla.

0,728, mientras que el modelo concuerda con el consenso en 0,915 —es decir, coincide con el consenso mejor de lo que los propios humanos coinciden entre sí— y cae dentro de la envolvente de las máscaras humanas el 97,8 % de las veces.

La lectura, en términos sencillos, es que el modelo segmenta tan bien como un experto humano, o mejor: coincide con el consenso de varios médicos (0,915) más de lo que esos médicos coinciden entre sí (0,728). Por eso las diferencias de ~ 1 pp entre arquitecturas (tabla 4.6) dejan de ser relevantes —son más pequeñas que el desacuerdo natural entre dos personas que dibujan el mismo contorno—: se ha alcanzado el techo de precisión que la propia tarea permite medir. Conviene acotar esta conclusión: vale para la segmentación de una sola lesión dermatoscópica con *prompt* de caja sobre el test blindado de ISIC2018, y no se extiende a imágenes con varias lesiones ni al uso sin caja. A partir de aquí, la idea de guiar el modelo con lenguaje —en lugar de con una caja— abre el bloque siguiente, sobre clasificación *zero-shot* multimodal.

4.6 Clasificación zero-shot multimodal

La clasificación *zero-shot* permite asignar una imagen a un diagnóstico descrito solo con palabras, sin haber entrenado el modelo con ejemplos etiquetados de esas categorías. Su interés práctico es claro: permitiría poner en marcha un sistema sin reunir antes un *dataset* etiquetado, y añadir diagnósticos nuevos con solo describirlos. Esta sección estudia de qué depende que ese régimen funcione, y la respuesta es menos intuitiva de lo esperable: lo decisivo no es la imagen, sino que el texto y la imagen “hablen el mismo idioma”, es decir, que el tokenizer del texto encaje con el espacio del encoder visual. Se cuantifica sobre HAM10000 (7 clases, $N_{\text{test}} = 1232$) con tres formas de redactar los *prompts* y dos tokenizers distintos (cifras completas en el repositorio reproducible, A, sección A.10).

El rendimiento depende drásticamente de cómo se construye el texto. Pasar de

4.7. Comparación con modelos generativos generalistas

prompts genéricos en inglés con tokenizer PubMedBERT al conjunto A3 de Derm1M con tokenizer GPT-2/CLIP eleva la AUROC de 0,366 a 0,854 (+48,8 pp). Los *prompts* genéricos con PubMedBERT quedan en AUROC < 0,5, señal de que proyectan en un espacio no alineado con el encoder visual de la variante v1/v2. Cambiar solo el conjunto A3, sin tocar el tokenizer, sube la AUROC a 0,516; cambiar solo el tokenizer, manteniendo A3, la lleva a 0,854. El principal cuello de botella del régimen *zero-shot* no reside, por tanto, en la representación visual —idéntica en todas las configuraciones—, sino en la alineación entre el espacio textual y el espacio visual.

Esta diferencia de casi 50 pp de AUROC, obtenida sin modificar el encoder visual ni las imágenes, tiene una implicación metodológica directa: evaluar un modelo *zero-shot* con una única configuración de *prompts* o tokenizers puede falsear sus capacidades reales, y una comparación entre modelos puede incluso invertirse según el *prompt* elegido.

La generalización de este comportamiento a escenarios clínicos externos se evalúa sobre la tarea binaria melanoma/no-melanoma en cuatro datasets independientes (DDI, MSKCC, HIBA y Derm7pt clínico) con la configuración PubMedBERT de DermLIP v1/v2 (cifras por dataset en el repositorio reproducible, A, sección A.5).

La sensibilidad observada en HAM10000 se reproduce en los cuatro datasets externos: bajo la configuración PubMedBERT con *prompts* genéricos, DermLIP opera cerca del azar (BAcc $\approx$ 0,5 sobre DDI, MSKCC, HIBA y Derm7pt clínico), lo que confirma que el rendimiento *zero-shot* depende críticamente de la alineación texto-imagen y limita la robustez del paradigma zero-shot puro (análisis extendido en el repositorio reproducible, A, sección A.10).

4.7 Comparación con modelos generativos generalistas

Esta sección contrasta si los grandes modelos de lenguaje multimodales, entrenados sobre datasets mucho mayores, cierran la brecha frente a los especialistas. La tabla 4.7 evalúa seis modelos de lenguaje multimodales sobre HAM10000, PAD-UFES-20 y DDI, junto a los modelos de referencia de las secciones 4.1 y 4.3.

Cuadro 4.7: Comparación de paradigmas sobre HAM10000, PAD-UFES-20 y DDI ($N_{\text{test}} = 1\,232/461/137$). FT: fine-tuning, LP: linear probe, ZS: zero-shot.

Modelo	Modo	HAM Acc	HAM BAcc	PAD Acc	PAD BAcc	DDI Acc	DDI BAcc
PanDerm Base (TTA HAM)	FT	0,920	0,852	0,755	0,704	0,774	0,693
PanDerm Large	LP	0,888	0,575	0,772	0,642	0,847	0,764
SigLIP-Large	LP	0,900	—	0,718	—	0,789	—
MedGemma 27B + LoRA	FT	0,802	0,270	0,430	0,347	0,657	0,618
MedGemma 27B	ZS	0,665	0,243	0,447	0,342	0,474	0,566
GPT-4o	ZS	0,485	0,465	0,553	0,523	0,723	0,648
GPT-4o-mini	ZS	0,256	0,319	0,390	0,435	0,737	0,556
Gemini 2.5 Pro	ZS	0,403	—	0,477	—	0,441	—
Gemini 2.5 Flash	ZS	0,380	—	0,486	—	0,555	—
DermLIP	ZS	0,239	0,581	0,601	—	0,329	—
BLIP-2 (Flan-T5-XL)	ZS	0,015	0,145	0,017	0,167	0,796	0,542
InstructBLIP (Flan-T5-XL)	ZS	0,024	0,123	0,171	0,224	0,788	0,500

Los resultados separan claramente especialistas y generalistas. El mejor sistema dermatológico (PanDerm Base ajustado con TTA) alcanza accuracy 0,920 sobre HAM10000,

4. RESULTADOS

frente a 0,485 del mejor generalista *zero-shot* (GPT-4o) —una diferencia de 43,5 pp (figura 4.3) que se mantiene en PAD-UFES-20 y DDI—; en el extremo inferior, BLIP-2 e InstructBLIP caen a accuracy $\sim 0,02$ sobre HAM10000. La lectura no es que un modelo generalista sea deficiente, sino que, cuando el problema es extremadamente visual y especializado, el conocimiento dermatológico adquirido durante el preentrenamiento domina sobre la mayor capacidad lingüística de los modelos multimodales generalistas.¹




Figura 4.3: Comparativa de paradigmas sobre HAM10000. Gradiente de 43,5 pp accuracy entre el mejor especialista ajustado (PanDerm Base FT con TTA, 0,920) y el mejor LLM multimodal generalista *zero-shot* (GPT-4o, 0,485). BLIP-2 e InstructBLIP descienden hasta accuracy $\sim 0,02$.

4.7.1 Ajuste supervisado de un LLM multimodal: MedGemma con LoRA

MedGemma es el único LLM multimodal que se acerca, y lo hace gracias a la adaptación al dominio: el ajuste con LoRA sobre MedGemma 27B mejora +13,7 pp de accuracy sobre HAM10000 respecto a su variante *zero-shot* (0,665 $\rightarrow$ 0,802) —un salto que vuelve a señalar que es la adaptación, y no la escala bruta, lo que cierra la brecha—. Aun así, incluso adaptado queda 11,8 pp por debajo del mejor especialista y la mejora no transfiere de forma sistemática (sin ganancia sobre PAD-UFES-20). El desglose por dataset, los patrones de error de GPT-4o y los costes de inferencia figuran en el repositorio reproducible (A, sección A.10).

¹Las cifras de los modelos accesibles por API comercial corresponden al *prompt* y a la versión del proveedor disponibles en la fecha de evaluación, no reproducible ante actualizaciones silenciosas (sección 7.1.1); documentan un punto de comparación reproducible en su formulación, no el techo intrínseco de cada sistema.

4.8 Equidad por fototipo cutáneo

Esta sección analiza si los modelos rinden de forma equitativa entre fototipos cutáneos y cómo distinguir una equidad real de una métrica engañosa: un *gap* pequeño puede esconder un modelo uniformemente peor, de modo que la métrica aislada no decide, como establecen la comparación de cinco encoders y el test de DeLong. El rendimiento global de los cinco encoders sobre Fitzpatrick17k completo ($N = 16577$), en las dos formulaciones consideradas —114 patologías y 3 clases de malignidad—, figura en el repositorio reproducible (A, sección A.5); el análisis de equidad se centra en la formulación de 3 clases. La tabla 4.8 reporta la BAcc por fototipo Fitzpatrick sobre esa formulación.

Cuadro 4.8: BAcc por subgrupo Fitzpatrick (3 clases de malignidad) y *gap* entre fototipos extremos. Tamaños muestrales por subgrupo: 299/470/325/261/169/73 para FST I a VI.

Modelo	FST I	FST II	FST III	FST IV	FST V	FST VI	Gap I-VI
PanDerm Large	0,723	0,708	0,743	0,669	0,568	0,506	+0,217
PanDerm Base	0,653	0,693	0,669	0,630	0,585	0,384	+0,269
DermLIP v2 (visual)	0,716	0,730	0,765	0,710	0,693	0,434	+0,281
DINOv2 ViT-L/14	0,673	0,671	0,679	0,654	0,553	0,368	+0,306
BiomedCLIP	0,569	0,602	0,606	0,566	0,590	0,445	+0,124

Los cinco modelos tienen *gap* I-VI positivo (figura 4.4): todos rinden peor sobre los fototipos elevados. Pero el ranking de equidad no coincide con el de rendimiento. DermLIP v2 logra la mejor BAcc global (0,721 sobre 3 clases) y la mejor AUROC (0,909), pero con un *gap* I-VI (+0,281) mayor que el de PanDerm Large (+0,217); y BiomedCLIP exhibe el *gap* menor (+0,124) pero la peor BAcc global (0,590).




Figura 4.4: Equidad por fototipo Fitzpatrick (formulación de tres clases de malignidad) sobre los cinco encoders evaluados. Los cinco presentan *gap* I-VI positivo (entre +0,124 y +0,306 pp BAcc). Paradoja BiomedCLIP: *gap* mínimo asociado a peor BAcc global, lo que demuestra el carácter no decisional de la métrica aislada.

Este contraste encierra la principal aportación metodológica de la sección: **el *gap***

aislado no constituye una métrica suficiente de equidad. Un modelo uniformemente peor entre subgrupos puede presentar una brecha reducida simplemente porque falla en todos ellos —ser equitativamente malo no es ser equitativo en sentido sustantivo—. La interpretación debe además acotarse por el reducido tamaño muestral del fototipo VI ($N = 73$, frente a 299 en FST I; sección 7.2.4), que ensancha los intervalos del *gap* sobre los fototipos oscuros (tabla 4.9). El contraste con cierre estadístico se reserva al test de DeLong (sección 4.8.1).

Cuadro 4.9: *Gap* de equidad I-VI (BAcc FST I – BAcc FST VI) con intervalo de confianza al 95 % por *bootstrap* ($B = 1\,000$, estratificado). El reducido tamaño de FST VI ($N = 73$) ensancha los intervalos; el de BiomedCLIP incluye el cero, de modo que su *gap* mínimo no es estadísticamente distinguible de la ausencia de disparidad. Intervalos por subgrupo en el repositorio reproducible (A, sección A.6).

Modelo	<i>Gap</i> I-VI [IC95 %]
PanDerm Large	0,217 [0,015, 0,387]
PanDerm Base	0,269 [0,116, 0,389]
DermLIP v2	0,281 [0,109, 0,430]
DINOv2 ViT-L/14	0,306 [0,136, 0,426]
BiomedCLIP	0,124 [-0,052, 0,280]

Un experimento cruzado *Light* $\leftrightarrow$ *Dark* (*Light* agrupa FST I-III; *Dark*, FST IV-VI; matriz completa en el repositorio reproducible, A, sección A.5) añade una segunda lectura, más fuerte que el simple *gap*. Entrenar solo con fototipos claros y evaluar sobre oscuros (L $\rightarrow$ D frente a L $\rightarrow$ L) penaliza el rendimiento. La caída es mayor en DINOv2 ($\Delta = -0,132$ pp BAcc) y menor en BiomedCLIP ($\Delta = -0,063$ pp). DermLIP v2 muestra la menor caída Dark $\rightarrow$ Light frente a Dark $\rightarrow$ Dark ($\Delta = +0,016$ pp), lo que apunta a representaciones más invariantes al fototipo cutáneo.

La proximidad entre algunos resultados —especialmente entre PanDerm Large y DermLIP v2— plantea si las diferencias reflejan una ventaja real o son compatibles con la variabilidad muestral, lo que motiva un contraste formal mediante el test de DeLong.

4.8.1 Validación estadística del ranking de encoders: test de DeLong

El contraste estadístico formal mediante el test de DeLong [39] —que controla la correlación de evaluar varios modelos sobre las mismas imágenes— se aplica a tres *endpoints* binarios centrales de detección de lesión maligna: malignidad sobre Fitzpatrick17k, melanoma sobre HAM10000 y malignidad sobre DermapixelAI 1.0. En cada uno, la comparación entre modelos parte de una regresión logística binaria sobre sus *features* congeladas (sección 3.9.1) y los *p*-valores pareados se corrigen por el método de Holm dentro del *endpoint*. Las comparaciones se interpretan como contrastes centrales del estudio.

Endpoint 1: malignidad sobre Fitzpatrick17k. Sobre el test de Fitzpatrick17k ($N = 1\,658$, 226 malignos), la tabla 4.10 reporta la AUROC binaria con IC95 % por la varianza de DeLong; la matriz completa de *p*-valores pareados (dos colas) figura en el repositorio reproducible (A, sección A.5).

El test de DeLong confirma que PanDerm Large y DermLIP v2 presentan un rendimiento estadísticamente indistinguible ($\Delta\text{AUROC} = 0,0036$, $p = 0,55$): ningún dato

Cuadro 4.10: AUROC binaria de detección de malignidad (*maligno* frente al resto) sobre el test de Fitzpatrick17k ($N = 1\,658$, 226 malignos), con intervalo de confianza al 95 % por la varianza de DeLong. Mejor valor en negrita.

Modelo	AUROC	IC95 % (DeLong)
PanDerm Large	0,9488	[0,9350, 0,9626]
DermLIP v2	0,9452	[0,9307, 0,9598]
PanDerm Base	0,9296	[0,9130, 0,9463]
DINOv2 ViT-L/14	0,9150	[0,8932, 0,9367]
BiomedCLIP	0,8915	[0,8672, 0,9158]

sostiene una jerarquía entre ambos sobre este *endpoint*. Los dos superan, en cambio, de forma significativa a los encoders generalistas (DINOv2 y BiomedCLIP) y a PanDerm Base ($p \leq 7,3 \times 10^{-3}$ en los seis contrastes), lo que respalda cuantitativamente la ventaja del preentrenamiento específico de dominio. Tras la corrección de Holm, siete de los diez contrastes se mantienen significativos, mientras que algunas comparaciones entre generalistas (DINOv2–BiomedCLIP, DINOv2–PanDerm Base) dejan de ser concluyentes, delimitando qué distinciones del *ranking* son señal y cuáles ruido muestral.

Endpoint 2: melanoma sobre HAM10000. El mismo contraste se aplica al *endpoint* binario melanoma frente al resto sobre el test de HAM10000 ($N = 1\,232$, 70 melanomas), incorporando SigLIP-Large al conjunto de encoders con AUROC publicada sobre este dataset. La tabla 4.11 reporta las cifras.

Cuadro 4.11: AUROC binaria de detección de melanoma (*melanoma* frente al resto) sobre el test de HAM10000 ($N = 1\,232$, 70 melanomas), con intervalo de confianza al 95 % por la varianza de DeLong. Ningún contraste pareado resulta significativo tras la corrección de Holm ($p_{\text{Holm}} = 1,0$ en los tres). Mejor valor en negrita.

Modelo	AUROC	IC95 % (DeLong)
PanDerm Large	0,9523	[0,9314, 0,9733]
SigLIP-Large	0,9495	[0,9245, 0,9745]
DermLIP v2	0,9463	[0,9246, 0,9681]

Los tres encoders alcanzan AUROC en torno a 0,95 con diferencias inferiores a 0,006, y ningún contraste pareado resulta significativo tras la corrección de Holm (todos con $p_{\text{Holm}} = 1,0$): sobre este *endpoint*, PanDerm Large, SigLIP-Large y DermLIP v2 son estadísticamente indistinguibles. Con sólo 70 positivos, la potencia es insuficiente para separar modelos cuyas AUROC se solapan ampliamente.

Sobre este mismo *endpoint*, la discriminación es fuerte (AUROC $\sim 0,95$) y la calibración de las probabilidades resulta razonable: reutilizando las mismas predicciones por muestra del contraste de DeLong (head de regresión logística *train*→*test*, sin reentrenamiento), el error de calibración esperado (ECE, 15 *bins* de igual anchura sobre la probabilidad de la clase positiva) y el *Brier score* son de ECE = 0,017 y *Brier* = 0,029 para PanDerm Large, ECE = 0,017 y *Brier* = 0,030 para SigLIP-Large, y ECE = 0,018 y *Brier* = 0,031 para DermLIP v2 (curvas de fiabilidad por *bin* en el repositorio reproducible, A, sección A.7). El análisis sistemático de calibración entre tareas queda fuera del alcance de este trabajo (capítulo 7, sección de elementos no abordados).

Endpoint 3: malignidad sobre DermapixelAI 1.0 (protocolo distinto). El tercer *endpoint* —malignidad frente al resto sobre DermapixelAI 1.0— requiere una salvedad de protocolo. El *split* de test canónico (sección 5.1) es de tamaño limitado para inferencia binaria ($N = 36$, sólo 3 positivos), por lo que el contraste de DeLong se estima en su lugar mediante una validación cruzada de cinco pliegues *out-of-fold* sobre el dataset completo ($N = 1\,062$, 58 malignos; tabla 4.12), con DeLong pareado sobre las predicciones agrupadas y corrección de Holm. Este protocolo difiere del de los dos *endpoints* anteriores (train→test) y se emplea por el tamaño limitado del *split* fijo.

Cuadro 4.12: AUROC binaria de detección de malignidad sobre DermapixelAI 1.0 estimada por validación cruzada *out-of-fold* de cinco pliegues ($N = 1\,062$, 58 malignos), con intervalo de confianza al 95 % por la varianza de DeLong. Protocolo distinto del de los *endpoints* train→test por el tamaño limitado del *split* fijo. Ningún contraste pareado alcanza significación tras la corrección de Holm. Mejor valor en negrita.

Modelo	AUROC (OOF)	IC95% (DeLong)
DermLIP v2	0,8946	[0,8472, 0,9421]
PanDerm Large	0,8632	[0,8075, 0,9189]
PanDerm Base	0,8630	[0,8097, 0,9163]
CLIP-L	0,8536	[0,7926, 0,9146]
DINOv2	0,8469	[0,7980, 0,8958]

DermLIP v2 obtiene el mejor valor puntual (AUROC = 0,8946), por delante de PanDerm Large (0,8632) y del resto (0,85–0,86), pero ningún par de contrastes alcanza significación tras la corrección de Holm: con 58 positivos el *endpoint* no tiene potencia para ordenar los modelos. Dermapixel R0 queda fuera de este contraste, cuyo alcance se circunscribe a los encoders congelados.

En conjunto, el cierre estadístico se concentra en Fitzpatrick17k —el único *endpoint* con potencia suficiente (226 positivos)—, donde la jerarquía «específico de dominio > generalista» es significativa sin sostener una ordenación fina entre los dos líderes específicos. Los *endpoints* de HAM10000 (70 melanomas) y DermapixelAI 1.0 (58 malignos) corroboran de forma descriptiva ese patrón —AUROC elevadas y solapadas— sin alcanzar significación, un resultado compatible con la falta de potencia y no con la ausencia de efecto. La lectura que habilita el contraste es, por tanto, más sólida que coronar a un único modelo: los resultados no identifican un encoder dermatológico claramente superior, sino una *familia* de encoders dermatológicos que supera de forma consistente a los modelos generalistas, conclusión que se retoma en la discusión (sección 6.1.1).

4.9 Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos

Esta sección analiza si las representaciones internas del modelo se corresponden con los conceptos que usa un dermatólogo, base de la interpretabilidad clínica. Las *features* del autoencoder disperso se alinean con los criterios dermatoscópicos clásicos, aunque forzar un cuello de botella conceptual cuesta exactitud, como muestran los experimentos sobre Derm7pt.

4.9. Interpretabilidad del SAE: alineamiento con conceptos dermatoscópicos clásicos

La línea de interpretabilidad mediante Sparse Autoencoders (SAE), documentada en el repositorio reproducible (A, sección A.9), introduce un SAE Large de 16384 *features* entrenado sobre las activaciones de PanDerm Large y validado sobre los 48 conceptos visuales de SkinCon [16]. Esta sección extiende la validación a Derm7pt [10] (1011 lesiones dermatoscópicas, *splits* oficiales 413/203/395, 24,5 % melanomas) y explota las anotaciones del *Seven-Point Checklist*. Se realizan cuatro experimentos complementarios para evaluar si las representaciones del SAE codifican conceptos dermatoscópicos clínicamente relevantes (E1 alineamiento *single-feature*; E3 cruce con el Grupo A de la Dra. R. Taberner) y si dichos conceptos pueden sostener modelos interpretables sin penalizar el rendimiento (E2 *Concept Bottleneck Model*; E4 fine-tuning multitarea). Todos sobre DGX Spark GB10.

E1 evalúa, para cada uno de los siete criterios binarizados, la AUROC efectiva $\max(\text{AUROC}, 1 - \text{AUROC})$ de cada una de las 16384 *features* como predictor binario, sobre Derm7pt completo ($N = 1011$). Las mejores *features* alcanzan AUROC efectivo entre 0,681 y 0,823 según el criterio evaluado (máximo sobre *vascular structures*; desglose por criterio en el repositorio reproducible, A, sección A.9). La estabilidad entre el AUROC de la mejor *feature* (*top-1*) y el promedio de las diez mejores (*top-10*; diferencia $\leq 0,043$) indica que el alineamiento no se concentra en una *feature* aislada: el SAE codifica los conceptos mediante un pequeño subconjunto coherente de activaciones.

E2 construye un CBM jerárquico de dos etapas: una head logística sobre las 16384 activaciones estima la probabilidad de los siete criterios, y un meta-clasificador logístico predice melanoma/no-melanoma a partir de esas siete estimaciones. Las cifras de E2 se reportan junto al fine-tuning multitarea en la tabla 4.13.

La pérdida de 5,8 pp de AUROC ($0,890 \rightarrow 0,832$) cuantifica el coste de obligar al modelo a razonar exclusivamente mediante conceptos explícitos. Los pesos del meta-clasificador identifican *blue whitish veil* y *regression structures* como conceptos dominantes para la decisión melanoma, jerarquía coherente con el peso que el *Seven-Point Checklist* [10] asigna a ambos (criterios mayores de 2 puntos); el desglose completo figura en el repositorio reproducible (A, sección A.9).

E3 cruza los 16 conceptos del Grupo A propuestos a la Dra. R. Taberner (sección 3.3) con el *Seven-Point Checklist*: 11 admiten *mapping* operativo y 7 quedan cubiertos por al menos una *feature* SAE con AUROC efectivo $\geq 0,70$ (incluido un concepto con sólo 15 positivos, lo que sugiere que el SAE captura conceptos poco frecuentes sin contaminación por la clase mayoritaria). Los 5 sin *mapping* corresponden a estructuras no contempladas en la escala original y definen el contenido de la anotación clínica colaborativa (detalle completo en el repositorio reproducible, A, sección A.9).

Fine-tuning multitarea: heads conceptuales y melanoma

E4 replica el protocolo multitarea de Kawahara et al. [10] sustituyendo la red convolucional por PanDerm Large, con LoRA ($r = 16$) sobre los dos últimos bloques (*blocks.22-23*), idéntico al protocolo de Dermapixel R0 (sección 5.3). Sobre la representación adaptada se conectan ocho heads paralelas (una por criterio del *Seven-Point Checklist* más una binaria de melanoma), optimizadas con la suma equiponderada de entropías cruzadas $\mathcal{L} = \sum_{i=1}^7 \text{CE}(\hat{c}_i, c_i) + \text{CE}(\hat{m}, m)$ y *class weight* balanceado (0,56 M parámetros entrenables, 0,18 % del encoder). La tabla 4.13 compara E4 con el linear probe directo (E2

4. RESULTADOS

Direct LP) y el CBM jerárquico (E2 CBM) sobre el test Derm7pt ($N_{\text{test}} = 395$, $n_{\text{mel}} \approx 98$), con IC95% por *bootstrap*.

Cuadro 4.13: Comparativa sobre la tarea binaria melanoma/no-melanoma entre linear probe directo sobre las 16384 *features* del SAE Large (E2 Direct LP), CBM jerárquico de siete conceptos (E2 CBM) y fine-tuning multitarea LoRA con ocho heads paralelas (E4). Conjunto de test Derm7pt ($N_{\text{test}} = 395$, $n_{\text{mel}} \approx 98$), mismo *split* oficial. AUROC en negrita.

Método	Params entr.	Acc@1	BAcc	AUROC	W-F1	Kappa
E2 Direct LP (SAE $\rightarrow$ melanoma)	16 K	0,841	0,735	0,890	0,829	0,527
E2 CBM (SAE $\rightarrow$ 7 conceptos $\rightarrow$ mel)	~ 120	0,825	0,681	0,832	0,801	0,440
E4 FT multitarea LoRA	0,56 M	0,841	0,804	0,891	0,843	0,590

La head melanoma del fine-tuning multitarea alcanza AUROC test = 0,891 (IC95% [0,856, 0,927]), que iguala al linear probe directo (0,890) y mejora el CBM jerárquico en +5,9 pp. **A diferencia del CBM jerárquico, el aprendizaje multitarea conserva la capacidad discriminativa del modelo mientras mantiene salidas conceptuales explícitas**, ofreciendo predicción de melanoma e inferencia sobre los siete criterios en una sola pasada sin coste apreciable, cuando los conceptos auxiliares son taxonómicamente coherentes con la tarea principal —como ocurre con el *Seven-Point Checklist* [10]—. En síntesis, el SAE Large codifica conceptos dermatoscópicos clásicos sin supervisión explícita (E1), el CBM cuantifica el compromiso interpretabilidad–precisión (−5,8 pp AUROC, E2) y el multitarea LoRA iguala al linear probe preservando inferencia concepto-a-concepto (E4), lo que refuerza la viabilidad del módulo de interpretabilidad del prototipo (repositorio reproducible, A, sección A.11).

DERMAPIXEL

Hasta aquí los modelos se han evaluado sobre datasets públicos, casi todos en inglés y centrados en dermatoscopia. Este capítulo da el paso que motiva todo el trabajo: llevar esos modelos al material clínico real con el que se quiere ayudar —en castellano, mayoritariamente fotografía clínica y, sobre todo, acompañado de texto—.

El origen es el blog *Dermapixel*, que la Dra. R. Taberner mantiene desde 2010 y que reúne más de 700 casos comentados: cada uno con su imagen clínica y dermatoscópica, una historia breve, el diagnóstico y el razonamiento diferencial. Ese archivo tiene algo poco habitual: no son solo imágenes etiquetadas, sino casos con texto clínico rico en castellano. Y precisamente el papel de ese texto como contexto para el diagnóstico —la segunda vía que este trabajo defiende como poco explorada (sección 1.2)— es lo que hace a Dermapixel especialmente valioso: ya tiene lo que casi ningún dataset público ofrece.

De ahí la decisión de continuar con Dermapixel. A partir de ese archivo se construyó DermapixelAI 1.0 (sección 3.3) —un dataset clínico en castellano con texto narrativo por caso— y se liberó para la comunidad. Este capítulo lo pone a prueba: primero evalúa si los modelos fundacionales transfieren a este material (de forma congelada y en *zero-shot*), y después presenta la contribución propia, **Dermapixel R0**, una adaptación ligera de PanDerm al castellano —con una head supervisada y una rama contrastiva imagen-texto— cerrando con una síntesis comparativa de todos los métodos.

5.1 Evaluación de los modelos fundacionales sobre DermapixelAI

El capítulo empieza por la pregunta más básica: ¿transfieren los modelos fundacionales a este material clínico en castellano? Esta sección los evalúa sobre DermapixelAI 1.0 en los tres niveles de la ontología (L1, L2 y L3): primero con sus representaciones congeladas —usando lo que ya aprendieron, sin reentrenarlos— y luego con una adaptación

supervisada moderada. Aparece ya un hallazgo que se repetirá a lo largo del capítulo: no hay un método óptimo único; la mejor opción depende del nivel de detalle diagnóstico.

Una propiedad importante de DermapixelAI 1.0 es que es completamente independiente del preentrenamiento de PanDerm y DermLIP. A diferencia de Dermnet (sección 3.1.1), la auditoría por hash MD5 sobre 507 657 imágenes catalogadas (Derm1M más los once datasets externos del capítulo anterior) no encuentra ninguna coincidencia (0 sobre las 1 062 imágenes evaluables). Esta evaluación está, por tanto, libre de fuga de información (documento de entrega del dataset en el repositorio reproducible, A, sección A.4).

5.1.1 Transferencia congelada: linear probe y validación cruzada

Linear probe sobre el *split* fijo. Se aplica el protocolo de linear probe (sección 3.9.1) sobre las 1 062 imágenes con `label_source=ontology` (train $N = 874$, validación $N = 152$, test $N = 36$), con PanDerm Base (768-D) y Large (1 024-D) como extractores congelados y head *LogisticRegression*. La evaluación L2 usa las 38 subcategorías efectivas tras consolidar las dos variantes ortográficas de *Trastornos de la queratinización* (repositorio reproducible, A, sección A.8).

Cuadro 5.1: Linear probe con PanDerm Base y Large sobre DermapixelAI 1.0 en los tres niveles de la ontología jerárquica ($N_{\text{train}} = 874$, $N_{\text{test}} = 36$ en L1/L2 y $N_{\text{test}} = 28$ en L3 tras filtrar clases ausentes en train). Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos). Mejor valor por columna y nivel en negrita.

Nivel	Modelo	Acc	BAcc	AUROC	W-F1	Kappa
L1 (4 clases)	Base	0,639 [0,472–0,778]	0,570 [0,371–0,751]	0,697 [0,527–0,841]	0,624 [0,457–0,760]	0,296
L1 (4 clases)	Large	0,750 [0,639–0,861]	0,735 [0,637–0,835]	0,796 [0,656–0,930]	0,722 [0,596–0,845]	0,520
L2 (38 clases)	Base	0,222 [0,139–0,333]	0,221 [0,147–0,294]	0,707 [0,666–0,747]	0,212 [0,092–0,302]	0,170
L2 (38 clases)	Large	0,250 [0,167–0,333]	0,265 [0,206–0,338]	0,793 [0,749–0,837]	0,223 [0,139–0,291]	0,199
L3 (224 clases)	Base	0,143 [0,107–0,179]	0,132 [0,105–0,158]	0,735 [0,693–0,779]	0,107 [0,064–0,141]	0,112
L3 (224 clases)	Large	0,179 [0,143–0,214]	0,184 [0,158–0,211]	0,813 [0,769–0,856]	0,143 [0,100–0,184]	0,154

De aquí salen dos lecturas claras. La primera: PanDerm Large vuelve a ser mejor que Base en las cinco métricas y los tres niveles, igual que sobre los datasets externos. La segunda: cuanto más fino es el diagnóstico, más cuesta —la BAcc de Large baja de 0,735 (L1, cuatro grandes familias) a 0,265 (L2) y 0,184 (L3, 224 diagnósticos)—, aunque incluso en L3 el modelo acierta casi 41 veces más que el azar ($2,9\times$ en L1, $10,2\times$ en L2, $40,9\times$ en L3). El rendimiento en L1 (BAcc 0,735, IC95 % [0,637–0,835]) cae dentro del rango de los diez datasets externos (tabla 4.1): DermapixelAI 1.0 es, por tanto, un *benchmark* exigente en castellano y sin las marcas estandarizadas de la dermatoscopia.

Validación cruzada agrupada por caso. Dado que el test fijo $N = 36$ es un único *split*, se estima el rendimiento esperado mediante validación cruzada de cinco *folds* agrupada por `case_id` (*StratifiedGroupKFold* por L1 sobre las 1 062 imágenes), sin que ninguna imagen del mismo caso caiga a la vez en *train* y *test*. La tabla 5.2 reporta media y desviación sobre los cinco *folds*.

Con un test de solo 36 imágenes conviene no fiarse de una única partición. Por eso la validación cruzada agrupada por caso —que reparte los casos en cinco grupos sin que dos imágenes del mismo paciente caigan a la vez en *train* y *test*— es la estimación más honesta del rendimiento esperable. Comparado con ella, el test fijo resulta optimista en

Cuadro 5.2: Validación cruzada agrupada por caso (cinco *folds*, estratificado por L1 sobre *case_id*) con PanDerm Large sobre DermapixelAI 1.0. Cifras: media $\pm$ desviación estándar sobre los cinco *folds*. La cardinalidad L3 reportada aquí (250 clases) corresponde a las clases efectivas en el dataset completo; las restantes tablas del split fijo (tabla 5.1, tabla 5.3 y las del repositorio reproducible, A.8) usan 224 clases L3, las únicas representadas en el split *train*.

Nivel	Acc@1	Acc@3	BAcc	AUROC	W-F1	Kappa
L1 (4 cls)	0,574 $\pm$ 0,029	0,994 $\pm$ 0,004	0,440 $\pm$ 0,058	0,753 $\pm$ 0,054	0,569 $\pm$ 0,025	0,314 $\pm$ 0,035
L2 (38 cls)	0,227 $\pm$ 0,015	0,418 $\pm$ 0,037	0,168 $\pm$ 0,020	0,749 $\pm$ 0,019	0,221 $\pm$ 0,022	0,186 $\pm$ 0,015
L3 (250 cls)	0,124 $\pm$ 0,007	0,232 $\pm$ 0,028	0,108 $\pm$ 0,014	0,800 $\pm$ 0,018	0,124 $\pm$ 0,005	0,110 $\pm$ 0,005

BAcc (+29,5 pp en L1, +9,7 pp en L2, +7,6 pp en L3) porque le tocó un reparto favorable; la AUROC, en cambio, apenas cambia con la partición (menos de 5 pp). Las cifras del test fijo (tabla 5.1) se conservan como punto operativo y como base de comparación con el experimento *zero-shot* (sección 5.2), que usa el mismo test.

5.1.2 Validación del procedimiento de etiquetado

Dado que parte de las etiquetas etiológicas procede de la ontología y no de revisión individual, se compara el linear probe sobre el subconjunto verificado (*rosa_verified*) frente al dataset completo. Las diferencias son pequeñas, inconsistentes en dirección y compatibles con la variabilidad muestral: la imputación etiológica no degrada apreciablemente el rendimiento (resultados completos en el repositorio reproducible, A, sección A.8). Diversas ablaciones adicionales sobre los mismos *embeddings* (heads *k*-NN/MLP, función de pérdida, *Test-Time Augmentation*) tampoco modifican las conclusiones y se documentan en el mismo repositorio.

5.1.3 Estrategias de adaptación más allá del linear probe

Más allá de la representación congelada, dos estrategias buscan mejorar el rendimiento sobre DermapixelAI 1.0: combinar encoders complementarios y ajustar finamente el encoder.

Combinación de encoders. Para evaluar si las representaciones de distintos encoders son complementarias, se entrena una head logística por encoder (PanDerm Base, Large y DermLIP v2; protocolo de sección 3.9.1) sobre los *embeddings* congelados y se contrastan frente a cinco estrategias de combinación (promedio de las tres, promedio Large+DermLIP, máximo por clase y apilado con meta-head). La tabla 5.3 reporta los tres niveles en el mismo test fijo.

Ningún encoder lidera simultáneamente L1, L2 y L3. En L1 lidera la combinación avg Large+DermLIP en AUROC (0,796 $\rightarrow$ 0,817); en L2, DermLIP v2 individual en todas las métricas (+6,7 pp AUROC sobre PanDerm Large, 0,793 $\rightarrow$ 0,860), sin que ningún *ensemble* lo supere, en coherencia con el experimento *zero-shot* (sección 5.2); en L3 lidera PanDerm Large individual, donde la long tail limita la señal complementaria.

Fine-tuning parcial del encoder. Este protocolo replica sobre DermapixelAI 1.0 el fine-tuning supervisado (FT) de la sección 4.3. El encoder es PanDerm Large con las

Cuadro 5.3: Combinación de encoders sobre DermapixelAI 1.0. LP individual sobre PanDerm Base, PanDerm Large y DermLIP v2; tres estrategias de combinación: promedio Large+DermLIP, máximo por clase entre los tres, y apilado con meta-head. Mejor valor por columna y nivel en negrita.

Nivel	Estrategia	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	LP PanDerm Base	0,639	—	0,570	0,697
L1 (4 cls)	LP PanDerm Large	0,750	1,000	0,735	0,796
L1 (4 cls)	LP DermLIP v2	0,694	1,000	0,680	0,789
L1 (4 cls)	Avg L+D	0,750	1,000	0,702	0,817
L1 (4 cls)	Avg 3	0,722	1,000	0,694	0,811
L1 (4 cls)	Máx 3	0,694	1,000	0,652	0,805
L1 (4 cls)	Stack 3	0,694	1,000	0,703	0,790
L2 (38 cls)	LP PanDerm Base	0,222	—	0,221	0,707
L2 (38 cls)	LP PanDerm Large	0,250	0,500	0,265	0,793
L2 (38 cls)	LP DermLIP v2	0,333	0,528	0,279	0,860
L2 (38 cls)	Avg L+D	0,278	0,556	0,279	0,832
L2 (38 cls)	Avg 3	0,278	0,528	0,268	0,821
L2 (38 cls)	Máx 3	0,222	0,528	0,235	0,797
L2 (38 cls)	Stack 3	0,250	0,528	0,258	0,804
L3 (224 cls)	LP PanDerm Base	0,143	—	0,132	0,735
L3 (224 cls)	LP PanDerm Large	0,179	0,286	0,184	0,813
L3 (224 cls)	LP DermLIP v2	0,107	0,214	0,079	0,809
L3 (224 cls)	Avg L+D	0,179	0,250	0,184	0,802
L3 (224 cls)	Avg 3	0,143	0,250	0,152	0,795
L3 (224 cls)	Máx 3	0,143	0,250	0,132	0,780
L3 (224 cls)	Stack 3	0,143	0,250	0,158	0,791

dos últimas capas descongeladas (25,2 M parámetros entrenables, 8,3 % del encoder) y head *fully-connected*, con entropía cruzada reponderada por el desbalance de *Genodermatosis* (receta en el repositorio reproducible, A, sección A.13).

Sobre el nivel L1, el fine-tuning parcial alcanza BAcc 0,622 (IC95 % [0,510–0,735]) y AUROC 0,715, lo que mejora en +18,2 pp la cifra de validación cruzada agrupada por caso del linear probe congelado (BAcc $0,440 \pm 0,058$, tabla 5.2), con intervalos no solapados: el fine-tuning aporta valor real más allá del ruido de partición. No obstante, no supera a la combinación lineal de encoders congelados *avg_large_dermlip* (sección 5.1.3; BAcc 0,702, AUROC 0,817). La replicación sobre L2 y L3 mantiene el mismo protocolo, variando únicamente la head supervisada. La tabla 5.4 compara las métricas sobre los tres niveles.

Cuadro 5.4: Fine-tuning parcial del encoder (PanDerm Large, dos últimas capas descongeladas) sobre los tres niveles ontológicos de DermapixelAI 1.0. Test fijo $N_{\text{test}} = 36$ en L1/L2 y $N_{\text{test}} = 28$ en L3. La head L2 de este protocolo dimensiona $1\,024 \rightarrow 37$: son las 37 clases L2 efectivas en el *train* del fine-tuning, de las 38 del dataset tras fusionar las dos variantes ortográficas de “queratinización” (39 en bruto); las 38 clases son la cardinalidad nominal del nivel L2. Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos). Mejor valor por columna en negrita.

Nivel	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	0,583 [0,444–0,722]	0,972 [0,917–1,000]	0,622 [0,510–0,735]	0,715 [0,603–0,830]
L2 (37 cls)	0,250 [0,167–0,333]	0,500 [0,389–0,611]	0,324 [0,265–0,397]	0,852 [0,814–0,888]
L3 (224 cls)	0,179 [0,143–0,214]	0,286 [0,214–0,357]	0,184 [0,158–0,211]	0,804 [0,773–0,835]

El fine-tuning denso parcial mejora al linear probe en L1 y L2, pero no es la forma de adaptación más eficiente: la adaptación de bajo rango (LoRA) de Dermapixel R0 (sección 5.3) rinde mejor entrenando muchos menos parámetros. En conjunto, ni la combinación de encoders ni el fine-tuning identifican una opción óptima universal: **el rendimiento depende simultáneamente del nivel ontológico, de la estrategia de adaptación y del criterio de evaluación**, de modo que la búsqueda de un único *ganador* resulta una simplificación excesiva del problema (lectura de diseño en sección 6.1.1).

5.1.4 Limitaciones del fine-tuning en la long tail

Sobre el nivel L3, el fine-tuning denso parcial no supera al sondeo lineal congelado (BAcc 0,184 en ambos): la long tail severa del nivel (77 % de las clases con ≤ 5 ejemplos) anula el beneficio del fine-tuning, lo que reserva L3 al ranking por prototipos coseno de Dermapixel R0 (repositorio reproducible, A, sección A.8) o a la ampliación del dataset vía banco hospitalario del HUSLL.

Tres *caveats* acotan estas cifras: el test reducido ($N = 36$ en L1/L2, $N = 28$ en L3) ensancha los IC95%; la ausencia de *Genodermatosis* en el test de L1 (0/36) reduce ese nivel a una clasificación efectiva de tres clases; y la long tail de L3 limita el rendimiento alcanzable bajo cualquier ajuste denso sobre el dataset actual.

5.2 Validación *zero-shot* multimodal sobre DermapixelAI 1.0

Esta sección pregunta lo contrario que la anterior: ¿hasta dónde llega un modelo fundacional sobre el material en castellano *sin entrenar nada*, solo describiendo cada diagnóstico con palabras? La distancia entre este régimen *zero-shot* y el supervisado depende mucho del nivel de detalle: es grande en L1 y L3, pero casi desaparece en L2 —el resultado más llamativo de la sección—, donde DermLIP v2 en *zero-shot* alcanza una AUROC (0,794) indistinguible de la del linear probe supervisado de PanDerm Large (0,793).

El experimento usa el mismo test que la sección 5.1 ($N_{\text{test}} = 36$ en L1/L2, 28 en L3), sin entrenar ningún clasificador y con no solapamiento garantizado (0/507657 coincidencias MD5). Se comparan tres modelos contrastivos —DermLIP v2 (Derm1M), SigLIP-SO400M (WebLI) y BiomedCLIP (PubMed-15M)— eligiendo para cada imagen la clase de mayor similitud coseno con un *ensemble* de tres plantillas de texto por nivel, y se contrasta el *prompt* en castellano frente al inglés; L3 se evalúa solo en castellano por falta de una traducción inglesa validada de sus 224 clases (tabla 5.5).

La evaluación *zero-shot* sobre DermapixelAI 1.0 arroja tres hallazgos principales. *Primero*, DermLIP v2 obtiene el mejor o equivalente rendimiento en las cinco métricas sobre los tres niveles (salvo Acc@3 L1, liderada por BiomedCLIP), coherente con su preentrenamiento sobre Derm1M, el único dataset específicamente dermatológico de los tres [2].

Segundo, traducir el *prompt* del inglés al castellano reduce la Acc@1 en L1 entre 11 y 14 puntos porcentuales en los modelos anglófonos (DermLIP v2 –13,9 pp, de 0,500 a 0,361; SigLIP-SO400M –11,1 pp), mientras que BiomedCLIP mantiene su cifra en ambos idiomas. La penalización es consistente con el predominio del inglés en el preentrenamiento —aunque el diseño no permite atribuirle causalmente a ese único factor—

Cuadro 5.5: Clasificación *zero-shot* multimodal sobre el conjunto de test de DermapixelAI 1.0 ($N_{\text{test}} = 36$ en L1/L2, $N_{\text{test}} = 28$ en L3). Entre corchetes, IC95 % por *bootstrap* estratificado (1 000 remuestreos) para las dos métricas primarias (Acc@1 y AUROC). Las métricas BAcc y Acc@3 se reportan como valor puntual por concisión; los IC95 % correspondientes están disponibles en el material reproducible. L3 se evalúa únicamente en castellano. Mejor valor por columna, nivel e idioma en negrita.

Nivel	Modelo	Lang	Acc@1	Acc@3	BAcc	AUROC
L1 (4 cls)	BiomedCLIP	es	0,389 [0,250–0,528]	0,944	0,375	0,679 [0,562–0,781]
L1 (4 cls)	BiomedCLIP	en	0,389 [0,250–0,528]	0,972	0,324	0,639 [0,524–0,738]
L1 (4 cls)	SigLIP-SO400M	es	0,222 [0,111–0,361]	0,917	0,178	0,650 [0,571–0,735]
L1 (4 cls)	SigLIP-SO400M	en	0,333 [0,194–0,472]	0,889	0,292	0,663 [0,595–0,719]
L1 (4 cls)	DermLIP v2	es	0,361 [0,222–0,500]	0,861	0,379	0,699 [0,600–0,794]
L1 (4 cls)	DermLIP v2	en	0,500 [0,333–0,667]	0,917	0,441	0,709 [0,565–0,841]
L2 (38 cls)	BiomedCLIP	es	0,111 [0,111–0,111]	0,278	0,118	0,647 [0,604–0,688]
L2 (38 cls)	BiomedCLIP	en	0,083 [0,056–0,111]	0,250	0,088	0,655 [0,601–0,713]
L2 (38 cls)	SigLIP-SO400M	es	0,139 [0,139–0,139]	0,250	0,235	0,636 [0,589–0,680]
L2 (38 cls)	SigLIP-SO400M	en	0,194 [0,111–0,278]	0,278	0,221	0,697 [0,640–0,747]
L2 (38 cls)	DermLIP v2	es	0,222 [0,167–0,278]	0,333	0,265	0,762 [0,721–0,805]
L2 (38 cls)	DermLIP v2	en	0,250 [0,194–0,306]	0,417	0,294	0,794 [0,747–0,837]
L3 (224 cls)	BiomedCLIP	es	0,107 [0,036–0,179]	0,214	0,079	0,703 [0,673–0,732]
L3 (224 cls)	SigLIP-SO400M	es	0,071 [0,000–0,143]	0,214	0,053	0,696 [0,667–0,723]
L3 (224 cls)	DermLIP v2	es	0,107 [0,071–0,143]	0,214	0,079	0,740 [0,719–0,763]

y motiva directamente la rama textual castellana de Dermapixel R0: sin penalización lingüística, una rama en castellano no estaría justificada.

Tercero, la comparación con el linear probe supervisado (tabla 5.1) cuantifica la brecha entre un sistema entrenado y uno *zero-shot*: +29,4 pp BAcc en L1 y +10,5 pp en L3 a favor del LP. El comportamiento se invierte, en cambio, en L2, y aquí aparece el resultado más llamativo de la sección: DermLIP v2 *zero-shot* en inglés (AUROC 0,794) iguala al mejor linear probe supervisado (PanDerm Large, 0,793) dentro de los intervalos de confianza. Esto sugiere que, a nivel de subcategorías dermatológicas, una parte sustancial del conocimiento discriminativo ya está codificada en el espacio multimodal preentrenado y puede recuperarse mediante texto, sin entrenamiento adicional; el grano grueso L1 y la long tail L3 sí requieren, en cambio, clasificador supervisado. La síntesis tabular de estas brechas —penalización por idioma y distancia al linear probe supervisado— figura en el repositorio reproducible (A, sección A.8).

Las cautelas sobre el tamaño del test ($N = 36$ en L1/L2, $N = 28$ en L3) y la ausencia de solapamiento frente a Derm1M (sección 5.1) aplican también aquí. Dos *caveats* son específicos del régimen *zero-shot*: el *ensemble* de tres plantillas por nivel es una formulación mínima de *prompt engineering* —la literatura emplea entre diez y ochenta plantillas asistidas por LLMs—, por lo que las cifras son cota inferior; y la evaluación L3 únicamente en castellano, por falta de traducción inglesa validada de sus 224 clases, impide cuantificar la penalización por idioma sobre la long tail.

5.3 Dermapixel R0: adaptación supervisada con LoRA (nivel L2)

5.3.1 Diseño de Dermapixel R0

Frente a los experimentos anteriores, que evalúan modelos existentes, esta subsección aborda la contribución propia: **Dermapixel R0**, una adaptación mediante LoRA [38] de PanDerm Large sobre DermapixelAI 1.0 —una adaptación de un modelo fundacional preexistente, no un preentrenamiento a escala; la denominación R0 designa una versión base sobre un dataset reducido—. Entrena únicamente 524 K parámetros (0,17 % del modelo) y se orienta al nivel L2 (38 clases efectivas), donde la disponibilidad de muestras permite entrenamiento supervisado; el nivel L3 se evalúa mediante ranking por prototipos coseno por la extrema escasez de ejemplos por clase. La configuración completa (LoRA $r = 16$, optimización, semillas) figura en el repositorio reproducible (A, sección A.13).

5.3.2 Resultados principales L2

La tabla 5.6 compara Dermapixel R0 con las referencias internas sobre el nivel L2 ($N_{\text{test}} = 36$): el linear probe congelado bajo validación cruzada agrupada por caso (tabla 5.2), el linear probe sobre el *split* fijo (tabla 5.1) y DermLIP v2 individual (sección 5.1.3).

Cuadro 5.6: Comparativa sobre el nivel L2 de DermapixelAI 1.0 (38 clases con queratinización consolidada, $N_{\text{test}} = 36$) entre Dermapixel R0 y las referencias internas del trabajo. La fila LP CV se considera la cifra honesta del linear probe congelado por su independencia del *split* fijo y por su anclaje en validación cruzada agrupada por caso (sección 5.1). Mejor valor por columna en negrita.

Método	Encoder	Params entren.	BAcc L2	AUROC L2
LP test fijo (tabla 5.1)	PanDerm Large 1 024 (cong.)	39 K	0,265	0,793
LP 5-fold CV (tabla 5.2)	PanDerm Large 1 024 (cong.)	39 K	$0,168 \pm 0,020$	$0,749 \pm 0,019$
DermLIP v2 individual (sección 5.1.3)	DermLIP 512 (cong.)	19,5 K	0,279	0,860
Dermapixel R0 (este trabajo)	PanDerm Large 1 024 + LoRA	524 K	$0,363 \pm 0,007$	$0,855 \pm 0,006$

Dermapixel R0 alcanza la mejor BAcc L2 documentada sobre el dataset ($0,363 \pm 0,007$, media $\pm$ desviación sobre tres semillas), superando tanto al linear probe congelado como a DermLIP v2; la ventaja se mantiene frente a la estimación más conservadora por validación cruzada agrupada por caso (+19,5 pp BAcc). En AUROC, R0 ($0,855 \pm 0,006$) empata con DermLIP v2 (0,860), lo que sugiere que la adaptación ligera de PanDerm Large recupera prácticamente todo el techo discriminativo del modelo contrastivo especializado, con ventaja en las clases minoritarias.

5.3.3 Adaptación eficiente frente a ajuste denso

La adaptación de bajo rango de Dermapixel R0 entrena 524 K parámetros frente a los 25,2 M del fine-tuning parcial denso (sección 5.1.3) y obtiene mejor BAcc L2: **Dermapixel R0 rinde mejor entrenando 48 veces menos parámetros**. La adaptación eficiente de parámetros (PEFT) supera, por tanto, al fine-tuning parcial denso en este régimen de datos.

5.3.4 Limitaciones en L3

El rendimiento cae notablemente en L3 (ranking por prototipos coseno, $\text{Acc}@1 = 0,167, \times 42$ sobre el azar), donde 178 de las 250 clases disponen de cinco o menos imágenes de *train*: la principal limitación deja de ser el modelo y pasa a ser la disponibilidad de datos. Las cifras completas figuran en el repositorio reproducible (A, sección A.8); la head L3 directa queda condicionada al banco hospitalario del HUSLL (≥ 30 imágenes/clase, sección 8.5.2).

5.4 Dermapixel R0: rama contrastiva en castellano

La segunda rama de Dermapixel R0 cambia de objetivo. En lugar de clasificar en una lista fija de diagnósticos, aprende a relacionar texto clínico libre en castellano con las imágenes, al estilo CLIP: se puede consultar el archivo con una frase —“placa eritematosa descamativa en el codo”— y recuperar los casos parecidos, sin vocabulario cerrado. Es la pieza pensada para la búsqueda documental sobre el archivo de Dermapixel.

Se entrenaron cinco versiones (v1→v5) sobre una adaptación de PanDerm Large —no un preentrenamiento desde cero— y la conclusión es clara: lo que más mejora el rendimiento es ampliar la capacidad del encoder visual, no añadir más datos externos. De hecho, una de las versiones añade datos genéricos a propósito y empeora: un resultado informativo, no un fallo. El alcance en el nivel más fino (L3) queda limitado por el número de pares imagen-texto disponibles y por la long tail de diagnósticos raros.

5.4.1 Diseño experimental

La rama contrastiva es un sistema dual-encoder estilo CLIP [24] (encoder visual PanDerm Large + encoder textual multilingüe adaptado al castellano clínico). Se entrenan cinco iteraciones diseñadas para aislar tres factores: adaptación textual, adaptación visual y aumento de escala mediante datos externos genéricos; el objetivo, fijado a priori, es L3 $\text{accuracy}@1 \geq 0,25$ en *zero-shot*. La arquitectura, los hiperparámetros, las particiones *case-aware*, la justificación frente a un *wrapper* inglés con traducción ES→EN y la generación de *captions* figuran en el repositorio reproducible (A, secciones A.13 y A.8).

5.4.2 Evolución v1→v5

La tabla 5.7 reporta la $\text{accuracy}@1$ sobre las 101 imágenes de test bajo régimen híbrido *H6* (logits visuales y textuales con pesos $w_v = 0,3$, $w_t = 0,7$ calibrados sobre validación), uniforme a las cinco iteraciones para la comparativa cross-checkpoint. Los niveles L1 y L2 *zero-shot* sólo se reportan para v4 y v5.

Las tres primeras iteraciones quedan empatadas en [0,1782, 0,1980]. La cuarta alcanza 0,2475, a una imagen de test del objetivo predefinido (0,25). La quinta, ablación deliberada de escala bajo idéntica LoRA que v4, reduce el rendimiento a 0,2079 (−4,0 pp). El barrido de épocas y la síntesis tabular completa figuran en el repositorio reproducible (A, sección A.8).

Cuadro 5.7: Clasificación *zero-shot* de la rama contrastiva de Dermapixel R0 sobre el conjunto de test de 101 imágenes (per-case estratificado por L1) bajo régimen híbrido *H6* homogéneo ($w_v = 0,3$, $w_t = 0,7$) aplicado a las cinco iteraciones. La columna *Objetivo* corresponde al umbral fijado en el diseño experimental antes de observar resultados. Mejor cifra por fila excluyendo la columna *Objetivo* en negrita. La trayectoria completa con configuración LoRA por iteración, lift de recuperación y techo *Linear Probing* figura en el repositorio reproducible (sección A.8). Provenance: commit d0190c3 del repositorio spanderm-clip.

Tarea	Random	v1	v2	v3	v4	v5	Objetivo
L1 acc@1 (4 cls)	0,250	—	—	—	0,4257	0,4554	—
L2 acc@1 (23 cls)	0,043	—	—	—	0,1837	0,2041	—
L3 acc@1 (54 cls)	0,019	0,1782	0,1980	0,1980	0,2475	0,2079	$\geq 0,25$

5.4.3 Hallazgos científicos

El experimento arroja tres conclusiones diferenciadas.

(1) La adaptación textual aporta mejoras limitadas. Las iteraciones $v1 \rightarrow v3$, que actúan sobre el encoder textual y las *captions* ricas, quedan empatadas ($0,178 \rightarrow 0,198$, ruido experimental): ninguna intervención textual extrae información que las *features* visuales no contengan ya (el diagnóstico de techo *Linear Probing* figura en el repositorio reproducible, A, sección A.8).

(2) La adaptación visual es la principal fuente de mejora. El salto $+4,95$ pp entre $v3$ y $v4$ ($0,198 \rightarrow 0,248$, idéntico régimen *H6*) se atribuye a la ampliación de capacidad del encoder visual (LoRA $r = 32$ sobre doce bloques frente a $r = 16$ sobre cuatro). El cuello de botella era visual, no textual: es la palanca de mayor efecto del experimento.

(3) Ampliar con datos externos genéricos no mejora la alineación castellana. La quinta iteración, ablación deliberada de escala, añade 15 128 imágenes externas (PAD-UFES-20 [12], DermNet [14]) con *captions* sintéticas y reduce la *accuracy@1* L3 a 0,2079 ($-4,0$ pp): el resultado informa que la escala genérica no sustituye a la cobertura *in-domain*. Aunque el encoder visual mejora aislado (*H1* $0,168 \rightarrow 0,238$), las *captions* externas no preservan el registro del archivo y erosionan la alineación castellana sobre la que se calibra *H6*. La long tail tampoco se rellena (327 clases L3 con ≤ 5 imágenes; sólo ocho ganan cobertura): superar el *zero-shot* L3 $\sim 0,25$ exige anotación experta *in-domain*, no escala genérica (sección 8.5.1). Convergente con la sensibilidad de DermLIP al tokenizer (sección 4.6), el hallazgo confirma que **la alineación cross-modal de un dominio clínico de alta especificidad lingüística es un recurso frágil**.

Una ablación con el modelo inglés DermLIP v2 ($\approx 403\,000$ pares Derm1M [2]) refuerza el diagnóstico: alcanza *accuracy@1* L3 = 0,287 ($+3,96$ pp sobre $v4$), de modo que la palanca limitante es la *escala* de la alineación cross-modal y no la formulación textual. La ventaja de la rama contrastiva no es la exactitud —inferior a la head supervisada cerrada— sino aceptar consultas textuales libres en castellano sin vocabulario fijo, propiedad explotada en el módulo de recuperación del prototipo (repositorio reproducible, A, sección A.11).

5.4.4 Recuperación multimodal

El segundo eje es la recuperación cross-modal per-imagen sobre los 107 pares (imagen, caption rica) de validación, con script idéntico entre versiones, en régimen *rich-caption* (l1m_case_summary, el más representativo del lenguaje clínico real de la Dra. R. Taberner). La trayectoria por iteración con el *lift* sobre el azar figura en el repositorio reproducible (A, sección A.8).

La recuperación cross-modal alcanza su pico en v2: i2t R@5 = 0,654, un *lift* de **14,0×** sobre el azar, y desciende en las iteraciones posteriores (v4 12,4×, v5 10,8×). El dato relevante es la tensión que revela: v4 es la mejor versión *clasificando* (0,2475 en L3) pero v2 es la mejor *recuperando*. Optimizar la clasificación y optimizar la búsqueda semántica no son, por tanto, el mismo problema: la LoRA visual (v4) y las *captions* externas (v5) reesculpen el espacio embebido a favor de la primera y en contra de la segunda.

La calibración de los logits *zero-shot* de la rama contrastiva por *temperature scaling* reduce el *Expected Calibration Error* (ECE) L3 un $\sim 97\%$ sobre v4 (0,7262 $\rightarrow$ 0,0213, $\tau = 0,4165$); el procedimiento, el diagrama de fiabilidad y la limitación de convergencia sobre v5 figuran en el repositorio reproducible (A, sección A.8). El sistema v4 es candidato a módulo de búsqueda textual castellano del prototipo DermApIxel (sección A.11), con la calibración escalar $\tau = 0,4165$ como capa final.

5.5 Síntesis comparativa de métodos sobre DermapixelAI 1.0

Las secciones 5.1–5.4 evalúan encoders de dominio (PanDerm Base/Large, DermLIP v2), vision-language médicos (BiomedCLIP, SigLIP-SO400M) y las dos ramas de Dermapixel R0 sobre DermapixelAI 1.0. El repositorio reproducible (A, sección A.8) añade dos ablaciones complementarias —encoders generalistas no médicos (DINOv2, CLIP-L) bajo linear probe y dos arquitecturas de inferencia (*retrieval k*-NN con FAISS y *zero-shot* jerárquico en cascada)—, integradas en la síntesis. La tabla 5.8 consolida BAcc y AUROC por nivel ontológico para el conjunto completo de métodos.

Cuadro 5.8: Síntesis de encoders y arquitecturas evaluados sobre DermapixelAI 1.0 (test fijo: $N = 36$ en L1/L2, $N = 28$ en L3). La columna *Ref.* remite a la sección de origen de las cifras completas con sus intervalos de confianza. Mejor valor por columna y nivel en negrita.

Método	Ref.	L1		L2		L3	
		BAcc	AUROC	BAcc	AUROC	BAcc	AUROC
PanDerm Base LP	5.1	0,570	0,697	0,221	0,707	0,132	0,735
PanDerm Large LP	5.1	0,735	0,796	0,265	0,793	0,184	0,813
DermLIP v2 LP	5.1	—	—	—	0,860	—	—
DINOv2 ViT-L LP	Rep. A.8	0,537	0,650	0,250	0,718	0,211	0,794
CLIP-L-336 LP	Rep. A.8	0,556	0,658	0,279	0,826	0,184	0,827
Dermapixel R0 LoRA	5.3	—	—	0,363	0,855	—	—
FT parcial denso L1+L2+L3	5.1	0,622	0,715	0,324	0,852	0,184	0,804
<i>k</i> -NN FAISS PanDerm Large	Rep. A.8	0,686	0,748	0,265	0,700	0,210	0,719

No existe un método universalmente superior sobre DermapixelAI 1.0: el liderazgo cambia de método con cada nivel ontológico (L1–L3) y cada criterio de evaluación (clasificación equilibrada, discriminación probabilística o recuperación basada en

similitud), como muestra la alternancia de valores en negrita de la tabla 5.8. Las cifras se reportan sobre el test fijo ($N = 36$ en L1/L2, $N = 28$ en L3), por lo que las jerarquías en L2 y L3 deben leerse como indicio y remitirse a la validación cruzada agrupada por caso (tabla 5.2) como estimación defendible del linear probe congelado. La elección de arquitectura óptima queda así condicionada por el nivel ontológico objetivo y por el uso previsto del sistema (clasificación, recuperación o soporte explicativo), en línea con la lectura interpretativa de la sección 6.1.1.

Como exploración aplicada orientada a seguridad clínica, se evaluó un *ensemble* entre modelos dermatológicos y generalistas para maximizar la sensibilidad en melanoma; al tratarse de una característica del prototipo y no de un resultado central sobre modelos fundacionales, los detalles completos (configuración, tabla comparativa y análisis de complementariedad) se presentan en el repositorio reproducible (A, sección A.11).

DISCUSIÓN

6.1 Significado de los resultados

La lectura agregada de los experimentos no apunta a un único modelo vencedor, sino a que el rendimiento dermatológico está condicionado por cuatro dimensiones principales: el nivel ontológico al que se evalúa, el régimen de datos etiquetados disponible, la modalidad de entrada y la estrategia de adaptación empleada. Los resultados sugieren que, una vez alcanzado cierto nivel de capacidad representacional en los encoders visuales modernos, las diferencias de rendimiento dependen cada vez más de factores ligados a los datos, la formulación de la tarea y la integración multimodal —taxonomía de las clases, volumen y calidad de las etiquetas, alineamiento texto-imagen, formulación de los *prompts*, equidad entre subgrupos y estrategia de despliegue—. Las subsecciones siguientes interpretan estos factores a partir de la evidencia del capítulo 4, mientras que la sección 6.3 deriva sus implicaciones operativas.

Conviene subrayar que la amplitud de esta evaluación no se obtiene a costa de la comparabilidad: cada eje se contrastó bajo un protocolo controlado y homogéneo —linear probe con idéntica configuración sobre los mismos datasets, equidad evaluada entre los mismos cinco encoders sobre una partición común, y test de DeLong pareado sobre predicciones compartidas—, de modo que las comparaciones entre familias de modelos son directas y no quedan confundidas por diferencias de montaje experimental.

6.1.1 Ausencia de un método óptimo único: especialización por tarea

La síntesis transversal de los experimentos sobre DermapixelAI 1.0 (tabla 5.8) muestra que no existe un método universalmente superior para todas las tareas evaluadas. Los distintos modelos alcanzan su mejor rendimiento en escenarios diferentes según el nivel ontológico, la modalidad de entrada y el criterio de evaluación considerado. Así, los encoders especializados destacan en transferencia visual y clasificación supervisada, las arquitecturas contrastivas muestran ventajas en recuperación multimodal y búsqueda

semántica, los métodos basados en recuperación resultan competitivos en escenarios de long tail diagnóstica y los *ensembles* aportan sensibilidad adicional en tareas de seguridad clínica como el cribado de melanoma.

Esta diversidad de resultados sugiere que el problema no puede formularse en términos de un único modelo vencedor. La elección óptima depende del objetivo perseguido: clasificación general, subcategorización clínica, recuperación de casos similares, segmentación, razonamiento multimodal o maximización de sensibilidad diagnóstica. En consecuencia, la pregunta relevante deja de ser *qué modelo es el mejor* en términos absolutos y pasa a ser *qué combinación de encoder, estrategia de adaptación y mecanismo de inferencia resulta más adecuada para una tarea concreta*.

Este hallazgo conecta con una idea recurrente a lo largo del capítulo 4: a medida que los modelos fundacionales alcanzan niveles elevados de capacidad representacional, las diferencias de rendimiento dependen cada vez más de cómo se formula el problema, de la estructura de los datos y del objetivo clínico perseguido que de la arquitectura aislada del modelo. Las subsecciones siguientes desarrollan esta conclusión desde tres perspectivas complementarias: el nivel ontológico de clasificación, la estrategia de adaptación y el paradigma de inferencia empleado.

6.1.1.1 Especialización por nivel ontológico

El peso del preentrenamiento de dominio queda establecido por el linear probe (sección 4.1, sección 4.2): PanDerm Large supera a PanDerm Base con una mejora media de +9,0 pp en BAcc sobre los diez datasets externos contrastados (tabla 4.1). El detalle por dataset matiza el origen del beneficio: es modesto sobre dermatoscopia estandarizada —donde una arquitectura convolucional supervisada sobre ImageNet-21K llega a empatar la AUROC— y crece sobre fotografía clínica con dispositivos heterogéneos. Los resultados sugieren que la ventaja del preentrenamiento de dominio aumenta con la distancia entre el dataset y los datasets web generalistas, lo que la hace especialmente relevante en condiciones clínicas no estandarizadas, como la atención primaria o la teledermatología. SigLIP-Large SO400M confirma esta lectura desde el extremo opuesto: lidera sobre HAM10000 (tabla 4.2) por la sobrerepresentación de dermatoscopia estandarizada en su preentrenamiento web, pero esa superioridad se desvanece sobre el material clínico heterogéneo.

Esta ventaja, sin embargo, no es uniforme entre niveles ontológicos. Sobre la cardinalidad clínica intermedia L2, DermLIP v2 se sitúa como la mejor head individual, con una ventaja de +6,7 pp de AUROC sobre PanDerm Large (sección 5.1.3), y lidera también la AUROC L2 en régimen *zero-shot* sin entrenar head alguna (sección 5.2). Ambos resultados sugieren que el preentrenamiento contrastivo texto-imagen de Derm1M [2] captura la granularidad de subcategoría clínica con mayor fidelidad que el preentrenamiento auto-supervisado puro de la familia PanDerm. La jerarquía PanDerm Large > DermLIP v2, válida en la mayoría de datasets, se invierte por tanto en L2: el encoder óptimo depende del nivel ontológico objetivo.

6.1.1.2 Adaptación eficiente frente a ajuste denso

El fine-tuning parcial sobre DermapixelAI 1.0 (sección 5.1.3), con un volumen de entrenamiento reducido ($N_{\text{train}} = 874$), mejora sustancialmente la BAcc sobre el linear probe

congelado, pero no supera al *ensemble* lineal de encoders congelados, que lo aventaja en BAcc y AUROC (tabla 5.3). El patrón es coherente con la literatura sobre régimen de bajo N : combinar linealmente encoders fundacionales congelados aprovecha la diversidad de sus representaciones sin añadir los parámetros que el ajuste denso debe estimar sobre un dataset reducido.

La head supervisada L2 de Dermapixel R0 (sección 5.3) confirma esta lectura y aporta la cifra-ancla del argumento: la adaptación LoRA sobre los dos últimos bloques de PanDerm Large —524 K parámetros entrenables, una razón aproximada de 48× frente a los 25,2 M del ajuste denso parcial— alcanza la mejor BAcc L2 documentada sobre el dataset, y su AUROC L2 empatía estadísticamente con la de DermLIP v2 nativo (tabla 5.4). El ajuste denso, pese a su mayor parametrización, no supera a la adaptación de bajo rango sobre el mismo encoder; sobre L3, además, ningún protocolo de ajuste denso rebasa el techo que impone la long tail estructural. La implicación de diseño es directa y motiva la arquitectura de Dermapixel R0 (sección 8.5.2): en régimen de bajo N , la adaptación de bajo rango y la combinación de encoders con heads ligeras son preferibles al fine-tuning denso clásico.

Más allá de sus métricas concretas, Dermapixel R0 demuestra que la especialización de un modelo fundacional al castellano mediante técnicas PEFT, sin reproducir la escala de datos ni de cómputo del preentrenamiento original, resulta técnicamente factible con recursos modestos: una adaptación al alcance de instituciones sanitarias y grupos académicos, no sólo de grandes consorcios de investigación.

6.1.1.3 Retrieval frente a clasificación paramétrica

Una tercera fuente de especialización emerge sobre la long tail, en el paradigma de clasificación. Dos observaciones la sostienen. Primero, CLIP-L-336, un encoder generalista sin material biomédico en su preentrenamiento, encabeza la AUROC bajo linear probe sobre L2 y L3 (repositorio reproducible, A, sección A.8), lo que matiza la hipótesis de especialización de dominio cuando la métrica es el ranking probabilístico. Este resultado no contradice la ventaja global del preentrenamiento dermatológico, sino que pone de manifiesto que la AUROC y la BAcc capturan propiedades distintas del espacio de representación: la primera mide la ordenación probabilística y la segunda el acierto equilibrado por clase. Segundo, sustituir el clasificador paramétrico por *retrieval* k -NN con índice FAISS sobre los mismos *embeddings* de PanDerm Large (repositorio reproducible, A, sección A.8) supera al linear probe en el régimen de long tail severa L3, donde el escaso número de muestras por clase penaliza a los clasificadores paramétricos. La recuperación por vecindad, además, es operativamente atractiva: no exige reentrenar una head al incorporar clases nuevas y permite mostrar los casos similares que sustentan la predicción. Ambas observaciones cierran la lectura: la elección óptima debe condicionarse al nivel ontológico y al criterio operativo predominante, no a un encoder o clasificador presupuesto como universal. Esta lectura sobre L3 debe entenderse, no obstante, como indicio y no como ordenación cerrada: la long tail extrema y el tamaño reducido del conjunto de test en ese nivel (sección 7.4) limitan la fuerza de cualquier ranking sobre L3.

6.1.2 DermapixelAI 1.0 como contribución metodológica

Buena parte de la lectura anterior se apoya en DermapixelAI 1.0, cuyo papel en este trabajo conviene precisar: no es un dataset auxiliar de validación, sino una contribución metodológica en sí misma. Se trata de un dataset clínico construido en castellano, independiente del dataset de preentrenamiento Derm1M y auditado por hash MD5 frente a él (sección 3.1.1), lo que permite evaluar transferencia, *zero-shot*, adaptación LoRA y *retrieval* sin la incertidumbre de solapamiento que afecta a otros conjuntos. Su organización conforme a la ontología jerárquica L1/L2/L3 habilita la comparación de modelos a varios niveles de granularidad sobre un mismo material, y su disponibilidad documentada lo sitúa como punto de partida para evaluar modelos fundacionales sobre dermatología clínica en español.

A diferencia de los grandes repositorios internacionales, concebidos principalmente para clasificación supervisada, DermapixelAI 1.0 habilita preguntas experimentales adicionales: la estructura jerárquica L1/L2/L3 permite estudiar la granularidad diagnóstica; la disponibilidad simultánea de imagen y texto clínico en castellano permite evaluar recuperación multimodal y alineamiento *cross-modal*; y la auditoría frente a Derm1M garantiza un escenario libre de contaminación conocida. Sobre este material se generan los resultados de las secciones 5.1–5.5.

La interpretación se acota a una primera versión de tamaño limitado y long tail marcada a nivel L3, por lo que las cifras derivadas se respaldan en la estimación robusta discutida en sección 6.1.10 y no se extrapolan directamente a la práctica asistencial.

6.1.3 Eficiencia en etiquetas y régimen de saturación

Si el preentrenamiento de dominio es tan determinante, cabe preguntarse cuántas etiquetas son realmente necesarias para explotarlo. La curva de eficiencia en etiquetas (sección 4.4, tabla 4.4) muestra un comportamiento característico de los modelos fundacionales: la AUROC satura tempranamente —el 1 % de HAM10000 (82 imágenes) recupera ya el 96,2 % de la AUROC final y 14 imágenes el 95,5 % sobre PAD-UFES-20—, mientras que la *balanced accuracy* sigue mejorando con el volumen porque las clases minoritarias aún se benefician de más ejemplos. Gran parte del conocimiento visual relevante está, por tanto, internalizado en el encoder, y el clasificador supervisado sólo lo calibra.

Este comportamiento tiene una consecuencia práctica importante. En los modelos supervisados clásicos, la obtención de nuevas etiquetas suele constituir la principal vía para mejorar el rendimiento; en cambio, en los modelos fundacionales dermatológicos la rentabilidad marginal de cada nueva etiqueta disminuye rápidamente una vez superado un umbral relativamente bajo de ejemplos. A partir de ese punto, la calidad del preentrenamiento y la adecuación del dominio pueden resultar más determinantes que el simple aumento del tamaño del conjunto etiquetado.

Desde una perspectiva clínica, el resultado es especialmente relevante para enfermedades raras, centros con bajo volumen asistencial o subgrupos infrarrepresentados, donde la obtención de miles de anotaciones expertas es poco realista. Los datos sugieren que una estrategia basada en encoders fundacionales especializados y heads ligeras puede ofrecer rendimientos cercanos al máximo alcanzable incluso en escenarios de escasez de datos. Esta observación refuerza una de las ideas centrales del trabajo: en

dermatología, el cuello de botella deja de ser necesariamente la disponibilidad de etiquetas y pasa a ser, en muchos escenarios, la calidad del preentrenamiento del que se parte.

6.1.4 Linear probe frente a fine-tuning

La elección entre congelar el encoder o reentrenarlo no tiene una respuesta única, y esta subsección discute de qué depende. La comparación directa entre linear probe y fine-tuning sobre cuatro datasets (sección 4.3, tabla 4.3) revela un patrón asimétrico con implicaciones para el diseño de sistemas clínicos. Sobre HAM10000 y PAD-UFES-20, datasets de tamaño intermedio o alto ($N \in [1\,493, 8\,207]$), el fine-tuning mejora la BAcc en +47,1 pp y +19,4 pp respectivamente. Esto confirma la utilidad de la receta original de PanDerm —*weighted random sampler*, Mixup, CutMix y *layer decay*— para aprender las clases minoritarias bajo desbalance acusado.

El comportamiento se invierte cuando el dataset es pequeño. Sobre DDI ($N_{\text{train}} = 427$), el linear probe supera al ajuste fino en las cuatro métricas, con un descenso de AUROC especialmente diagnóstico ($0,827 \rightarrow 0,682$): el encoder ajustado pierde capacidad de *ranking* sobre el *test*, compatible con sobreajuste pese a las aumentaciones. Sobre MSKCC la mejora es marginal. La asimetría admite una explicación común: el fine-tuning sólo rentabiliza su mayor capacidad cuando el conjunto basta para estimar los nuevos pesos sin memorizar la distribución; por debajo de ese umbral, congelar el encoder actúa como regularización implícita y preserva la capacidad de *ranking* heredada del preentrenamiento.

Estos tres casos delimitan un régimen operativo cuantificable. Para datasets con $N_{\text{train}} \lesssim 500$ imágenes, el sondeo lineal sobre PanDerm Large es la opción de referencia. Para $N_{\text{train}} \gtrsim 5000$, el fine-tuning con la receta original es preferible, siempre que existan clases minoritarias clínicamente relevantes que el linear probe no logre discriminar. Entre ambos regímenes, la decisión depende del desbalance de clases y del coste computacional asumible.

La oposición no se reduce, sin embargo, a congelar frente a ajustar el encoder completo: la adaptación de bajo rango (LoRA) sobre L2 de DermapixelAI 1.0 (sección 5.1.3) mejora la BAcc frente al ajuste denso parcial con 48 veces menos parámetros, una tercera vía intermedia que materializa la arquitectura de Dermapixel R0 (sección 5.3). La evidencia ordena así las tres estrategias en una regla escalonada por volumen de datos: sondeo lineal con $N_{\text{train}} \lesssim 500$; LoRA en el régimen intermedio, preferible al ajuste denso por su menor exposición al sobreajuste; y fine-tuning denso con la receta original sólo con $N_{\text{train}} \gtrsim 5000$ y clases minoritarias clínicamente relevantes. La capacidad del modelo a desplegar se escala, por tanto, con los datos disponibles.

6.1.5 Segmentación promptable y adaptación de bajo coste

La segmentación aporta el hallazgo de mayor magnitud absoluta del trabajo, y conviene discutir tanto su alcance como su origen. Sobre ISIC2018 (sección 4.5, tabla 4.5), SAM2.1-Large con fine-tuning de su decoder alcanza Dice 0,947 en el conjunto de test. Supera en +2,6 pp la cifra publicada por Yan et al. [1] (0,921) y en +5,3 pp al baseline CAE-seg con backbone PanDerm Large entrenado desde cero (0,894). El ajuste mantiene congelado el *image_encoder* y entrena sólo el decoder de máscaras y el *promptable*

encoder. Por eso los pesos actualizados se limitan a $\sim 4,2$ M sobre los ~ 227 M de SAM2.1-Large (menos del 2%), con un coste computacional bajo.

La transferencia fuera de dominio es prácticamente nula: el Dice apenas varía sobre ISIC2017 y PH2 respecto a ISIC2018. Este patrón sugiere que las representaciones del encoder visual congelado (Hiera-Large) codifican primitivas geométricas y de contorno suficientemente generales, de modo que el ajuste del decoder de máscaras y del *promptable encoder* captura los matices del dominio dermatoscópico sin sobreajustar a una fuente de adquisición concreta. La magnitud del efecto de la adaptación de dominio, cuantificada en sección 4.5 frente a SAM2 *zero-shot*, confirma que el coste de adaptación se concentra en el decoder y no en el encoder.

La comparativa pareada de arquitecturas promptables (sección 4.5.1, tabla 4.6) matiza, no obstante, dónde reside ese valor. La generación de la arquitectura pesa más que el preentrenamiento médico: SAM2.1-tiny generalista supera a MedSAM v1 con preentrenamiento médico, y el tamaño de *backbone* no aporta en el régimen *box-prompted*. La especialización dermatológica del segmentador parece, por tanto, un factor secundario frente al diseño del modelo. Esta asimetría contrasta con el peso decisivo del preentrenamiento de dominio en clasificación (sección 6.1.1): reconocer *qué* lesión aparece sigue dependiendo del conocimiento dermatológico del preentrenamiento, mientras que delimitar *dónde* termina parece depender de mecanismos geométricos más generales, lo que invita a tratar por separado ambas familias de tareas.

El control automático sin caja (sección 4.5.2) reordena, sin embargo, esta jerarquía de factores. Si las cinco arquitecturas *promptables* caben en ~ 1 pp pero retirar el *prompt* cuesta 7,5 pp, el determinante real del rendimiento no es el segmentador sino la caja: la información de localización pesa entre seis y siete veces más que la elección de modelo. La consecuencia de diseño es directa: el esfuerzo de ingeniería rinde más en el detector que produce la caja que en sustituir un segmentador por otro. Desde una perspectiva metodológica, este hallazgo obliga además a reinterpretar las comparaciones habituales entre segmentadores: cuando la diferencia entre arquitecturas es del orden de un punto porcentual y la calidad del *prompt* modifica el rendimiento en más de siete, una parte sustancial de la literatura comparativa puede estar midiendo indirectamente diferencias en localización más que diferencias reales entre segmentadores. Para este último, el análisis de robustez (sección 4.5.3) deja una especificación poco habitual pero accionable: dado que apretar la caja degrada el Dice mucho más que aflojarla, el detector debe sesgarse hacia cajas ligeramente holgadas. La validación cruzada de cinco pliegues sitúa además el *headline* en $0,9554 \pm 0,0010$, lo que eleva la cifra de segmentación de estimación puntual a estimación con intervalo, a diferencia del resto de protocolos del trabajo.

Conviene, por último, no sobreinterpretar la magnitud absoluta. El análisis sobre anotación múltiple (sección 4.5.4) muestra que el acuerdo entre dermatólogos sobre el mismo contorno es de apenas 0,728 de Dice, mientras que el modelo concuerda con el consenso en 0,915. El 0,9556 se sitúa, por tanto, cerca del techo que impone la propia ambigüedad del borde lesional, con las diferencias de ~ 1 pp entre arquitecturas por debajo del desacuerdo inter-anotador. El valor de Dice debe leerse, en consecuencia, como aproximación al consenso humano y no como medida absoluta de verdad geométrica —con la salvedad de una ligera sobreconfianza en los bordes dudosos—: alcanzado el entorno de 0,95 frente a una referencia única, el margen de mejora técnica queda condicionado por la incertidumbre de la anotación clínica.

6.1.6 Sensibilidad al tokenizer en zero-shot multimodal

El rendimiento zero-shot no depende sólo del modelo, sino de cómo se le interroga. La evaluación sobre HAM10000 (sección 4.6) revela una sensibilidad acusada al tokenizer y a la formulación de los *prompts*. La AUROC oscila entre 0,366 (DermLIP v1/v2 con tokenizer PubMedBERT y *prompts* genéricos) y 0,854 (DermLIP original con tokenizer GPT-2/CLIP y *prompts* A3 de Derm1M). Es un rango de 48,8 pp para variaciones que no tocan los pesos visuales, sino sólo la rama lingüística y la formulación textual de las clases.

A diferencia de los clasificadores supervisados convencionales, donde la etiqueta final se obtiene a partir de una head entrenada explícitamente para la tarea, los sistemas *vision-lenguaje zero-shot* realizan una comparación geométrica entre *embeddings* visuales y textuales. En consecuencia, la calidad de la predicción depende simultáneamente de ambos espacios y, sobre todo, de su alineamiento mutuo: un encoder visual excelente puede producir resultados mediocres si las representaciones textuales no ocupan la región adecuada del espacio compartido.

El valor AUROC < 0,5 de la configuración inicial es diagnóstico de un desalineamiento entre el espacio textual proyectado por PubMedBERT y el espacio visual del encoder de DermLIP v1/v2, hasta el punto de invertir la correlación respecto a la tarea de clasificación. El experimento de modificaciones aisladas (sección 4.6) permite atribuir la recuperación del rendimiento a la combinación de dos factores —el cambio de tokenizer y el cambio al conjunto de *prompts* A3—, sin que la evidencia disponible permita aislar una causa única de forma concluyente, puesto que ambos operan sobre la misma rama textual. La lectura no debe, por tanto, formularse como causalidad absoluta de un único componente, sino como el efecto conjunto del tokenizer, los *prompts* y el alineamiento texto-imagen resultante. Los resultados sugieren que, en régimen *zero-shot*, la rama textual deja de ser un mecanismo de entrada y pasa a formar parte efectiva del modelo de decisión: desde esta perspectiva, el tokenizer, los *prompts* y el encoder textual no son hiperparámetros externos, sino componentes funcionales del clasificador. De aquí se sigue una implicación práctica directa: todo despliegue *zero-shot* debe validar empíricamente, sobre un conjunto del dominio, no sólo el modelo sino también su tokenizer y la formulación de los *prompts*, porque la transferencia desde la configuración publicada por los autores no está garantizada. El experimento cuestiona, además, una práctica habitual en la literatura multimodal: reportar resultados *zero-shot* utilizando una única configuración de *prompts*. Sobre los datos de este trabajo, la variabilidad inducida por la formulación textual supera ampliamente la diferencia entre algunas arquitecturas visuales, lo que sugiere que las comparaciones entre modelos sin controlar el espacio de *prompts* pueden resultar difíciles de interpretar.

La evaluación adicional sobre DermapixelAI 1.0 (sección 5.2, tabla 5.5) extiende esta lectura al idioma. DermLIP v2 con *prompts* en inglés alcanza Acc@1 = 0,500 sobre la categoría etiológica L1, frente a 0,361 con *prompts* equivalentes en castellano (−13,9 pp); SigLIP-SO400M cae −11,1 pp en la misma comparación. BiomedCLIP, en cambio, mantiene Acc@1 = 0,389 en ambos idiomas. Esto sitúa la penalización por castellano como dependiente del dataset textual de preentrenamiento. La magnitud de la caída motiva, como línea futura inmediata, construir modelos *vision-language* contrastivos con rama textual entrenada sobre material clínico en castellano. Esta

penalización proporciona, además, una posible explicación mecanística para parte de los resultados obtenidos posteriormente con Dermapixel R0 (sección 6.1.1): si una simple traducción del vocabulario diagnóstico reduce el rendimiento entre 11 y 14 pp, resulta razonable esperar que una adaptación explícita de la rama textual al lenguaje clínico castellano aporte beneficios incluso cuando la representación visual permanece inalterada.

6.1.7 Brecha entre modelos específicos y LLMs multimodales

La sensibilidad de la rama contrastiva al texto invitaba a comprobar si los grandes modelos de lenguaje multimodales, con dataset de preentrenamiento mucho mayores, cierran la distancia con los especialistas. La comparación de paradigmas sobre HAM10000 (sección 4.7) muestra lo contrario y fija un orden de magnitud entre familias relevante para elegir arquitectura en escenarios clínicos. El gradiente de accuracy entre el mejor especialista ajustado (PanDerm Base con fine-tuning y *test-time augmentation*) y el mejor LLM multimodal *zero-shot* (GPT-4o) supera los 43 pp; el desglose de la escala completa de configuraciones intermedias figura en el repositorio reproducible (A, sección A.10). La magnitud de la diferencia observada sugiere que, al menos en dermatología visual, el conocimiento específico del dominio continúa siendo más determinante que la escala general del modelo: la disponibilidad de miles de millones de parámetros y de grandes capacidades lingüísticas no compensa la ausencia de una representación dermatológica especializada.

Tres observaciones cualitativas, detalladas en sección 4.7, matizan esta brecha sin reducirla. Primero, la adaptación con LoRA sobre MedGemma 27B mejora la accuracy sobre los datasets vistos en entrenamiento pero no transfiere de forma sistemática al resto, lo que aconseja reportar su rendimiento por dataset y no agregado. Segundo, GPT-4o y GPT-4o-mini exhiben un sesgo de error hacia clases minoritarias del *prompt* —con sobreproducción de predicciones de dermatofibroma y melanoma muy por encima de su prevalencia real—, lo que sugiere que responden al espacio léxico de la consigna tanto como a la evidencia visual. Este patrón es compatible con un razonamiento guiado parcialmente por asociaciones semánticas aprendidas durante el preentrenamiento generalista y no exclusivamente por evidencia visual, por lo que la interpretación de las respuestas de los LLM multimodales requiere cautela cuando se aplican a taxonomías clínicas especializadas. Tercero, BLIP-2 e InstructBLIP con *Q-Former* preentrenado producen una accuracy incompatible con cualquier uso clínico, atribuible a la falta de adaptación al vocabulario dermatológico. Las tres observaciones convergen en que la distancia entre especialistas y LLMs multimodales generalistas no se explica por capacidad bruta del modelo, sino por su grado de adaptación al dominio. La conclusión queda acotada, en todo caso, a los *prompts* estandarizados y a la versión de los modelos cerrados disponible en la fecha de evaluación (sección 7.1.1): no afirma el techo teórico de estos modelos, sino su rendimiento en el régimen de uso evaluado.

De forma consistente con el resto del trabajo, la escala del modelo no emerge como variable dominante: el determinante fue el *prompt* espacial en segmentación (sección 6.1.5), la alineación texto-imagen en *zero-shot* (sección 6.1.6) y el preentrenamiento de dominio en clasificación (sección 6.1.1). La brecha tiene además una vertiente de coste: bajo las condiciones evaluadas, los modelos fundacionales dermatológicos ofrecen simultáneamente mejor rendimiento y menor coste operativo

—ejecución local en BF16 sobre la DGX Spark con latencia media de 1,49 s por imagen— que las alternativas multimodales cerradas de propósito general.

6.1.8 Equidad por fototipo cutáneo

La generalización entre fototipos es una condición de seguridad clínica, y los resultados la cuantifican sin ambigüedad. La evaluación sobre Fitzpatrick17k completo (sección 4.8, tabla 4.8; matriz cruzada en el repositorio reproducible, A.5) reproduce un patrón conocido en la literatura: los cinco encoders contrastados presentan *gap* I-VI positivo en la formulación de tres clases de malignidad, con valores entre +0,124 y +0,306 pp de BAcc (tabla 4.8). Ese *gap* no se interpreta en aislamiento, sino junto a la BAcc global de cada modelo: DermLIP v2, con la mejor BAcc y AUROC globales, exhibe sin embargo un *gap* (+0,281 pp) mayor que el de PanDerm Large (+0,217 pp), y BiomedCLIP combina el *gap* mínimo (+0,124 pp) con la peor BAcc global (0,590).

Esta última asimetría —*gap* mínimo con BAcc global inferior— ilustra que la métrica de equidad aislada no es decisional. **Un modelo uniformemente malo entre subgrupos puede mostrar baja desigualdad aritmética sin ser equitativo en sentido sustantivo**, porque su rendimiento es bajo en todos los fototipos por igual: la equidad no puede medirse al margen del rendimiento que reparte. Por eso BAcc global y *gap* deben leerse de forma conjunta. Bajo esa lectura, PanDerm Large presenta el equilibrio más favorable entre ambas dimensiones, seguido de DermLIP v2. La consecuencia asistencial es que un modelo validado únicamente mediante métricas globales puede ocultar pérdidas de sensibilidad en fototipos menos representados, por lo que la validación estratificada por fototipo se interpreta como requisito de seguridad y no como evaluación complementaria.

El experimento cruzado *Light* ↔ *Dark* (detallado en el repositorio reproducible, A, sección A.5) añade una lectura causal. La caída al entrenar sólo con fototipos claros y evaluar sobre oscuros (L→D vs L→L) es máxima en DINOv2 ($\Delta = -0,132$ pp BAcc) y mínima en BiomedCLIP ($\Delta = -0,063$ pp); DermLIP v2 mantiene la menor caída Dark→Light vs Dark→Dark ($\Delta = +0,016$ pp), coherente con mayor invariancia de sus representaciones al fototipo. La caída sistemática confirma que el sesgo no se reduce a diferencias de prevalencia, sino que emerge incluso al excluir parte de la variabilidad fenotípica del entrenamiento. Que ninguno de los cinco encoders elimine la degradación apunta a un problema de representación de fototipos oscuros en los datos disponibles, lo que justifica incorporar diversidad fenotípica en futuras versiones de DermapixelAI mediante la expansión del repositorio clínico del HUSLL (sección 6.1.2).

6.1.9 El cuello de botella ya no es sólo el modelo

La evidencia acumulada a lo largo del trabajo sugiere que el rendimiento dermatológico no está limitado principalmente por la arquitectura del modelo. En varios experimentos, modificaciones en el diseño del sistema —tokenización, *prompts*, estrategia de adaptación, estructura ontológica, equilibrio de clases, recuperación por similitud o validación por subgrupos— producen variaciones comparables o superiores a las obtenidas al sustituir el encoder visual. Estas decisiones, más que la elección aislada de un encoder, determinan el rendimiento alcanzable, y la lectura desplaza parcialmente el foco desde el diseño del modelo hacia el diseño del sistema completo.

Esta evolución es coherente con la madurez progresiva de los modelos fundacionales: a medida que las representaciones visuales alcanzan calidad elevada, el margen de mejora se desplaza desde la arquitectura hacia los datos, las ontologías, el alineamiento multimodal, la calibración, la equidad y la integración operativa. Optimizar exclusivamente el modelo produce así retornos decrecientes si no se acompaña de mejoras equivalentes en esos componentes, lo que constituye el objeto de las implicaciones operativas de la sección 6.3.

6.1.10 Estimación robusta del rendimiento sobre datasets de tamaño moderado

La fiabilidad de las cifras sobre un dataset pequeño depende del método de estimación. La validación cruzada de cinco *folds* agrupada por caso sobre DermapixelAI 1.0 (sección 5.1, tabla 5.2) ilustra un punto metodológico relevante: la diferencia entre la cifra puntual del *split* fijo y la media de los *folds* es sustancial sobre las métricas dependientes de umbral (BAcc) y casi nula sobre la AUROC *one-vs-rest*. La cifra puntual no es, por tanto, el rendimiento, sino una observación de una distribución. De aquí se siguen dos lecturas operativas. *Primero*, la cifra del *split* publicado conserva validez como punto operativo de referencia —y como base de la comparación con la evaluación *zero-shot* sobre el mismo *test* (sección 5.2)—, pero requiere la estimación cruzada para defender el rendimiento esperado. *Segundo*, sobre datasets de tamaño moderado la AUROC es la métrica primaria recomendable para comparar *transfer learning* congelado —por evaluar la ordenación del modelo con independencia de la frontera de decisión—, mientras que la BAcc y la *accuracy* deben acompañarse de su intervalo de confianza o de su estimación por *folds*.

En consecuencia, los *rankings* entre modelos sobre DermapixelAI 1.0 se interpretan como estimaciones sujetas a incertidumbre muestral y no como jerarquías absolutas, en especial sobre los niveles L2 y L3 —los de *test* más reducido—, donde la validación cruzada agrupada por caso protege la lectura frente a diferencias dentro del margen de error.

Esta cautela enmarca también la lectura de los tres *endpoints* de malignidad contrastados con el test de DeLong (sección 4.8.1). Su titular sostenible es la jerarquía «específico de dominio > generalista», con cierre estadístico únicamente en Fitzpatrick17k —el único con potencia suficiente— y corroboración descriptiva, sin significación, en HAM10000 y DermapixelAI 1.0, cuyos contrastes no superan la corrección de Holm por falta de potencia y no por ausencia de efecto; el cierre no respalda una ordenación fina entre los dos líderes específicos. Reportar los tres *endpoints* con su corrección por comparaciones múltiples —y declarar cuál tiene potencia y cuál no— es la práctica que las guías de reporte para inteligencia artificial en imagen médica (TRIPOD+AI) prescriben, y que distingue una superioridad estadísticamente sostenida de una mera diferencia puntual.

6.2 Comparación con la literatura

Esta sección contrasta los hallazgos con los principales trabajos de referencia en modelos fundacionales dermatológicos, segmentación médica, aprendizaje multimodal,

equidad por fototipo e interpretabilidad, delimitando qué observaciones confirman la literatura existente, cuáles la matizan y cuáles aportan evidencia nueva.

6.2.1 Reproducción del benchmark de PanDerm

Yan et al. [1] reportan para PanDerm Large una mejora media del +10,2% sobre el estado del arte previo a través de los 28 *downstream tasks* de su benchmark interno. Las cifras de linear probe de este trabajo sobre los datasets compartidos (HAM10000, PAD-UFES-20 y Derm7pt; tabla 4.1) se sitúan dentro de ese rango y reproducen las relaciones de rendimiento entre PanDerm Base y Large, pese a ejecutarse sobre una plataforma distinta de la original —arquitectura aarch64, CUDA 13.0 y BF16 sobre NVIDIA Grace Hopper GB10 frente a x86_64—, lo que documenta la portabilidad del *pipeline* hacia arquitecturas de nueva generación.

La magnitud de la mejora es consistente con la literatura: sobre los diez datasets externos, PanDerm Large supera a PanDerm Base en +9,0 pp de *balanced accuracy*, valor próximo al +10,2% reportado por Yan et al. sobre su benchmark interno pese a que los datasets empleados aquí son externos al desarrollo original. Esta convergencia sobre cohortes independientes aporta evidencia externa de generalización: la ventaja del modelo no depende de los conjuntos utilizados durante su desarrollo.

6.2.2 Segmentación binaria de lesión

En segmentación, SAM2.1-Large con fine-tuning del decoder sobre ISIC2018 alcanza Dice = 0,947, +2,6 pp sobre el resultado de Yan et al. [1] (0,921). La diferencia es atribuible a la señal espacial explícita de la *bounding box*, al encoder Hiera-Large preentrenado a gran escala y a la adaptación restringida al decoder, que concentra la capacidad de ajuste y reduce el sobreajuste. La comparación pareada entre arquitecturas (sección 4.5.1) y el control sin caja (sección 4.5.2) refuerzan que el determinante del rendimiento no es el segmentador concreto —diferencias de ≈ 1 pp— sino la localización de la lesión, cuya retirada cuesta 7,5 pp.

Frente a la lectura habitual que atribuye la mejora a arquitecturas mayores o preentrenamientos más especializados, los resultados sugieren que, alcanzada cierta calidad representacional, el beneficio del tamaño es reducido frente a la información espacial y la adaptación de bajo coste. El análisis inter-anotador lo confirma: el acuerdo entre dermatólogos (0,728 Dice) es muy inferior al acuerdo del modelo con el consenso (0,915), de modo que la tarea se aproxima a un régimen de saturación práctica sobre ISIC2018.

6.2.3 Comportamiento zero-shot

El comportamiento zero-shot es consistente con la literatura previa sobre modelos contrastivos dermatológicos pero la matiza: DermLIP alcanza AUROC comparable a la reportada en Derm1M [2] (máxima 0,854 sobre HAM10000) cuando se emplea una configuración textual alineada con su desarrollo, mientras que la sensibilidad al tokenizer y a la formulación de los *prompts* (sección 6.1.6) —hasta 48,8 pp de AUROC sobre el mismo encoder visual— muestra que la alineación texto-imagen es un componente crítico. Dado que la mayoría de trabajos reportan una única configuración textual, su cuantificación sistemática sobre la familia DermLIP constituye una aportación empírica de este trabajo.

Estos hallazgos son coherentes con la hipótesis de que, alcanzada cierta calidad en las representaciones visuales, las limitaciones del paradigma zero-shot se desplazan hacia la rama textual; la penalización por castellano sobre DermapixelAI 1.0 (sección 6.1.6) refuerza que la disponibilidad de recursos lingüísticos específicos del dominio puede ser tan importante como la de imágenes. Metodológicamente, recomiendan cautela al comparar modelos multimodales sólo por métricas zero-shot, pues diferencias atribuidas a la arquitectura pueden reflejar la formulación textual de la evaluación.

6.2.4 Disparidad por fototipo

La disparidad observada por fototipo es coherente con los resultados previamente descritos en Fitzpatrick17k [15] y con la motivación que impulsó la creación del dataset DDI [13]. Al igual que en esos trabajos, los modelos evaluados muestran un descenso sistemático del rendimiento sobre los fototipos más oscuros, lo que confirma que el sesgo asociado a la representación desigual de tonos de piel continúa siendo un problema abierto incluso en los modelos fundacionales dermatológicos más recientes.

La aportación de este trabajo reside en comparar esa disparidad de forma homogénea entre cinco familias de encoders bajo un mismo protocolo, lo que revela que la relación entre rendimiento global y equidad no es directa: la paradoja de BiomedCLIP —menor *gap* con peor rendimiento global— muestra que un modelo uniformemente mediocre puede parecer más equitativo que otro superior. Los resultados respaldan, en línea con las discusiones recientes sobre evaluación responsable de IA, reportar simultáneamente rendimiento global, rendimiento por subgrupo y magnitud de las diferencias.

La evaluación cruzada *Light* $\leftrightarrow$ *Dark* (repositorio reproducible, A, sección A.5) añade que los modelos preentrenados sobre dermatología son más robustos a cambios en la distribución de fototipos que los encoders generalistas, lo que sugiere que el preentrenamiento de dominio contribuye a una representación más estable frente a variaciones demográficas. La mejora del rendimiento global no garantiza, en todo caso, una mejora equivalente en equidad —tensión que se retoma entre las limitaciones (capítulo 7)—.

6.3 Implicaciones operativas

Los resultados no sólo permiten comparar modelos, sino extraer consecuencias prácticas para el diseño de sistemas dermatológicos asistidos por inteligencia artificial. Frente a la literatura inicial sobre modelos fundacionales, centrada en identificar un único modelo capaz de superar al estado del arte en múltiples tareas, la evidencia acumulada apunta a una conclusión diferente: distintos problemas dermatológicos —clasificación jerárquica, segmentación, recuperación de casos similares, búsqueda multimodal, interpretación conceptual o cribado de seguridad— favorecen arquitecturas distintas, y ninguna las optimiza simultáneamente. La estrategia más defendible para un entorno clínico consiste, por tanto, en combinar componentes especializados dentro de una arquitectura modular, seleccionando cada uno según la tarea. Las subsecciones siguientes traducen los hallazgos del capítulo 4 en decisiones de diseño aplicables a sistemas reales de apoyo al diagnóstico.

6.3.1 Arquitectura defendible para sistemas de apoyo al diagnóstico

Los cuatro bloques de evidencia anteriores convergen en una arquitectura técnicamente defendible para sistemas de apoyo al diagnóstico dermatológico contruidos sobre los modelos fundacionales disponibles. La estructura recomendable es la siguiente. El encoder es PanDerm Large preentrenado, congelado por defecto y ajustado sólo bajo demanda. La head es una regresión logística multi-clase (L-BFGS, $C = 1,0$, $\text{max_iter} = 5000$) cuando el dataset de entrenamiento es reducido ($N_{\text{train}} \lesssim 500$), o una head ajustada con la receta de PanDerm Large (Mixup, CutMix, *weighted random sampler*, 50 épocas) cuando $N_{\text{train}} \gtrsim 5000$ y existe desbalance acusado. La segmentación se resuelve con SAM2.1-Large adaptado mediante fine-tuning del decoder cuando la tarea requiera localizar la lesión.

Las ramas textuales se incorporan con cautela. La rama lingüística contrastiva (DermLIP) sólo entra con prompts validados y tokenizer compatible, verificado sobre un conjunto de validación del dominio. La rama LLM multimodal generalista (GPT-4o, Gemini, MedGemma) no se usa como clasificador principal, dado el orden de magnitud de rendimiento inferior cuantificado en sección 6.1.7. Su rol natural es complementario: generar razonamiento textual o explicaciones para casos ya clasificados por el encoder especializado.

La consecuencia de diseño que se desprende del conjunto de hallazgos (sección 6.4) es que la arquitectura defendible es modular, no un modelo único: PanDerm Large para la transferencia visual general, adaptación LoRA para la subcategoría clínica bajo N reducido, *retrieval* FAISS para la long tail, SAM2.1 para la segmentación y un *ensemble* acotado para el cribado de melanoma, seleccionando el componente según la tarea y el nivel ontológico. Sobre esta estructura, dos validaciones son condición necesaria antes del despliegue: la de los *prompts* y el tokenizer de cualquier rama contrastiva sobre un conjunto del dominio, dada la sensibilidad documentada en sección 6.1.6, y la validación por fototipo cutáneo (sección 6.1.8).

Esta arquitectura modular hereda, por último, una decisión taxonómica: la comparación inter-dataset es defendible a nivel L1 y L2 sobre el dataset armonizado, mientras que el nivel L3 conserva la long tail propia de cada dataset y no admite contrastes directos sin agregación (sección 3.2). La implicación para producción es presentar al usuario clínico la predicción L3 junto a su agregación L2 y L1, lo que da robustez frente a la incertidumbre de la long tail sin sacrificar especificidad cuando ésta es fiable. Y, dado el *gap* por fototipo (sección 6.1.8), desplegar sobre poblaciones con representación significativa de fototipos elevados exige validación específica por subgrupos y revisión humana cuando el modelo opere en su régimen de menor confianza.

6.3.2 Ensemble de seguridad para detección de melanoma

La detección de melanoma admite un esquema orientado a la seguridad, y conviene discutir tanto su valor como sus costes. El protocolo auxiliar de ensemble (repositorio reproducible, A, sección A.11) muestra que la combinación OR *top-3* de PanDerm Large *fine-tuned* sobre HAM10000 (M1) y SigLIP-Large SO400M con linear probe alcanza *recall* de melanoma del 100% (70 de 70) sobre el *split* de test de HAM10000. El análisis de errores explica por qué: los dos melanomas que M1 no captura en *top-3* sí los captura SigLIP, lo que confirma la complementariedad de los *backbones* y justifica la elección

del par. M7 (clasificador unificado sobre el dataset armonizado de 43 clases) no añade melanomas adicionales sobre HAM, pero mantiene valor en escenarios multidataset por su mayor cobertura ontológica.

Tres caveats acompañan la lectura operativa de este resultado. (i) El *recall* del 100 % es *top-3*, no *top-1*, por lo que exige una interfaz que presente al clínico las tres clases más probables. (ii) El tamaño muestral de melanomas es $N = 70$, lo que produce intervalos de confianza al 95 % amplios y obliga a validación prospectiva sobre una cohorte mayor. (iii) El coste en falsos positivos del esquema OR *top-3* es elevado (885 FP sobre 1 162 no-melanomas): asumible en un cribado oportunista, pero suficiente para descartar su uso aislado como clasificación primaria. La lectura operativa, coherente con la arquitectura modular de sección 6.3.1, es que este *ensemble* debe integrarse como mecanismo de apoyo orientado a la sensibilidad —priorizar la detección de melanoma asumiendo falsos positivos— y nunca como decisión diagnóstica autónoma.

Más allá del caso del melanoma, el conjunto de resultados apunta a una conclusión arquitectónica general: ninguno de los modelos evaluados domina simultáneamente la clasificación jerárquica, la segmentación, la recuperación multimodal, la interpretabilidad conceptual y el cribado de seguridad, sino que cada tarea presenta un candidato óptimo diferente. Esta observación favorece la composición de módulos especializados sobre una representación dermatológica y una ontología comunes, antes que la búsqueda de un único modelo universal, como vía más realista de integración de la inteligencia artificial en la práctica dermatológica (prototipo descrito en el repositorio reproducible, A, sección A.11).

6.4 Hallazgos no anticipados

Cinco observaciones del trabajo no se anticipaban desde la literatura y, a diferencia de las conclusiones robustas que se sintetizan en el capítulo 7, contradicen una expectativa previa razonable. Por ese motivo merecen atención específica como aportaciones empíricas con entidad propia.

Sensibilidad extrema al tokenizer y al *prompt*. La AUROC *zero-shot* de la familia DermLIP sobre HAM10000 varía en un rango comparable al de cambiar de paradigma completo, sin modificar los pesos del encoder visual, en función del tokenizer y de la formulación de los *prompts* (sección 6.1.6). Esta sensibilidad no está cuantificada de forma sistemática en la literatura previa sobre DermLIP y desplaza parte de la atención metodológica del modelo hacia su configuración operativa.

Retrieval competitivo en la long tail L3. La sustitución del clasificador lineal por *retrieval k*-NN con índice FAISS sobre los mismos *embeddings* PanDerm Large supera al linear probe en el régimen de long tail severa L3 de DermapixelAI 1.0 (repositorio reproducible, A, sección A.8). El hallazgo indica que, cuando el número de muestras por clase es muy bajo, un esquema no paramétrico basado en vecindad puede ser preferible al ajuste de una frontera de decisión paramétrica.

Linear probe supera al fine-tuning en DDI. Sobre DDI ($N_{\text{train}} = 427$), el linear probe sobre PanDerm Large supera al fine-tuning en accuracy, AUROC, BAcc y F1 ponderada

(sección 6.1.4). El comportamiento, atribuible a sobreajuste bajo N reducido, no se documenta de forma explícita en la literatura sobre PanDerm y ofrece una heurística operativa para datasets pequeños.

Más datos externos no siempre mejoran el modelo. La transición v4→v5 de Dermapixel R0 constituye un resultado negativo de interés: añadir 15 128 imágenes externas genéricas (PAD-UFES-20, DermNet) con *captions* sintéticas *reduce* la *accuracy@1 zero-shot* L3 ($0,2475 \rightarrow 0,2079$, sección 5.4.3). El resultado contradice la hipótesis razonable de que aumentar el volumen de datos mejora el rendimiento y sugiere que, en un dominio clínico de alta especificidad lingüística, la alineación entre dominio y lenguaje puede ser más determinante que la escala bruta de imágenes.

Interpretabilidad emergente del SAE Large sobre Derm7pt. La validación del SAE Large (16384 *features*) sobre Derm7pt (sección 4.9) identifica *features* individuales con AUROC efectivo hasta 0,823, pese a que las anotaciones *Seven-Point Checklist* no se usaron en ningún preentrenamiento: la base *sparse* aprendida sobre Derm1M ya captura representaciones alineadas con la taxonomía dermatoscópica clásica. El SAE no es, por tanto, sólo un mecanismo de reducción dimensional, sino que admite interpretación concepto-a-concepto, lo que refuerza la viabilidad del módulo de interpretabilidad del prototipo (repositorio reproducible, A, sección A.9) sin reentrenar el SAE.

6.5 Limitaciones interpretativas

Conviene cerrar la discusión acotando hasta dónde llegan estas conclusiones. Seis elementos condicionan su interpretación y el capítulo 7 los desarrolla en detalle: el solapamiento exacto de Dermnet con Derm1M (100 % por hash MD5), que acota la lectura de la familia DermLIP sobre ese dataset sin afectar al resto de encoders (sección 7.2.3); el tamaño muestral reducido de los fototipos Fitzpatrick V y VI, que ensancha los intervalos del *gap*; la condicionalidad de las cifras *zero-shot* y de LLMs multimodales a una formulación concreta de *prompt*; la evaluación sobre fotografías de archivos de investigación, no sobre adquisición prospectiva en flujo asistencial; la denominación de Dermapixel R0 como primera adaptación en español, afirmación de prioridad acotada a su categoría (sección 8.5.2); y el tamaño moderado de DermapixelAI 1.0, cuya long tail L3 obliga a leer ese nivel como evidencia exploratoria (sección 7.4). Estas limitaciones acotan el dominio de validez de las cifras, pero no invalidan los patrones cualitativos identificados: la ventaja del preentrenamiento de dominio, la saturación temprana del linear probe, el umbral $N_{\text{train}} \lesssim 500$ de preferencia del LP, la brecha frente a los LLMs multimodales generalistas y el *gap* por fototipo sistemático entre encoders.

LIMITACIONES

El estudio presenta limitaciones de cinco órdenes que conviene declarar explícitamente. La presente sección las desarrolla por familia, cuantifica su magnitud cuando es posible y acota su impacto sobre la interpretación de los resultados del capítulo 4 y de la discusión del capítulo 6.

7.1 Limitaciones de disponibilidad

7.1.1 Modelos sin pesos públicos

Los pesos de DermFM-Zero [3] no son públicos en la fecha de cierre del presente trabajo. Esta restricción impide su evaluación empírica directa sobre los doce datasets externos contrastados y restringe su tratamiento al marco conceptual del capítulo 2. La comparación entre PanDerm Large y DermFM-Zero, que la publicación original reporta a favor del segundo, no puede verificarse de forma independiente con los mismos protocolos. La disponibilidad eventual de los pesos permitiría esa comparación directa con los hallazgos cuantitativos del trabajo (tabla 4.1, tabla 4.8).

Los modelos cerrados accedidos vía API (GPT-4o, GPT-4o-mini, Gemini 2.5 Pro, Gemini 2.5 Flash) presentan una limitación estructural: no permiten controlar la versión exacta del modelo en el momento de la inferencia ni el posprocesado interno aplicado por el proveedor. Las cifras de la tabla 4.7 son condicionales a la versión disponible en la fecha del experimento (marzo de 2026) y no son estrictamente reproducibles ante actualizaciones silenciosas del proveedor. El coste agregado de la evaluación (\$4,07 aproximadamente entre GPT-4o y GPT-4o-mini, sin desglose público de tarifa por token de entrada y salida) introduce una segunda dependencia que limita la replicación por terceros.

7.1.2 Conjuntos de preentrenamiento no liberados

Los conjuntos de preentrenamiento internos del grupo de la Universidad Monash empleados en PanDerm [1] no son accesibles para terceros, lo que impide reproducir la fase de preentrenamiento y limita la verificación a los pesos liberados. En consecuencia, cualquier afirmación sobre la composición del dataset de preentrenamiento (las cuatro modalidades dermatológicas, ~ 2,1 millones de imágenes) descansa sobre la declaración de los autores y no sobre auditoría independiente. La misma restricción aplica al dataset Derm1M de la familia DermLIP, distribuido con *embeddings* agregados pero sin acceso íntegro al material de imagen original.

7.1.3 Dependencia de modelos fundacionales externos

El trabajo evalúa principalmente estrategias de adaptación, transferencia e integración sobre modelos fundacionales desarrollados por terceros (PanDerm, DermLIP, SAM2.1, SigLIP, BiomedCLIP). Por tanto, parte de las conclusiones depende de las decisiones de diseño y de los sesgos heredados de dichos modelos. Aunque esta situación refleja el escenario real de adopción clínica actual —en el que una institución sanitaria parte de pesos preentrenados disponibles y no de un preentrenamiento propio a gran escala—, limita la capacidad de atribuir causalmente determinados comportamientos a componentes específicos del entrenamiento original.

7.2 Limitaciones de los datos

7.2.1 Sesgo geográfico y lingüístico

Los doce datasets externos contrastados provienen mayoritariamente de instituciones de Estados Unidos (DDI), Australia (HAM10000 parcial), Europa central (BCN20000 sobre Hospital Clínic de Barcelona; HAM10000 parcial; ISIC2018; Dermnet) y Brasil (PAD-UFES-20). HIBA procede del Hospital Italiano de Buenos Aires y MSKCC del Memorial Sloan Kettering Cancer Center. La población hispanohablante europea, con la distribución epidemiológica documentada en DIADERM [5], no está representada de forma específica en los conjuntos de evaluación. La consecuencia es que las cifras agregadas de la tabla 4.1 no son directamente extrapolables al espectro diagnóstico atendido en el Hospital Universitario Son Llàtzer (HUSLL) [4] sin validación adicional.

La rama lingüística de los modelos vision-language contrastivos (DermLIP, BiomedCLIP) está preentrenada sobre dataset en inglés. La sensibilidad documentada al tokenizer (sección 6.1.6, 48,8 pp AUROC entre la peor y la mejor configuración) se limita a las variantes evaluadas en inglés y no caracteriza el rendimiento sobre *prompts* en español, idioma sobre el que no se han evaluado por la ausencia de validación de los tokenizers con vocabulario clínico hispanohablante. El dataset DermapixelAI 1.0 publicado como contribución del trabajo (sección 3.3) aborda esta brecha para la fase posterior al periodo cubierto por este documento.

7.2.2 Heterogeneidad taxonómica entre datasets

Las taxonomías diagnósticas nativas de los doce datasets son incompatibles entre sí. La formulación binaria melanoma/no-melanoma de Derm7pt clínico, Derm7pt dermo,

HIBA y MSKCC contrasta con la multiclase de HAM10000 (7 clases), PAD-UFES-20 (6), DDI (2), Dermnet (23), BCN20000 (9), WSI patches (16) y Fitzpatrick17k (114 patologías). SkinCon emplea anotación basada en 48 conceptos clínicos visuales, taxonomía incompatible con la diagnóstica de los demás datasets.

La ontología jerárquica L1/L2/L3 introducida en sección 3.2 mitiga esta limitación al armonizar el dataset agregado sobre vocabulario común (72 654 imágenes etiquetadas, 4 categorías L1, 43 subcategorías L2 con cinco entradas sin desagregación a L3, y 367 diagnósticos L3 con codificación SNOMED CT y CIE-10), pero no la elimina por completo. Las comparaciones inter-dataset son defendibles a nivel L1 (cuatro familias etiológicas) y L2 (43 entradas), pero a nivel L3 cada dataset conserva su cola larga propia y los contrastes directos requieren agregación adicional. Once de los doce datasets se mapean a la ontología; SkinCon queda fuera por el desajuste de granularidad ya mencionado.

La consecuencia operativa para los hallazgos del capítulo 4 es que el reporte por dataset de la tabla 4.1 mantiene fidelidad a la taxonomía nativa, y las cifras agregadas (filas *Media* de la misma tabla) deben interpretarse como promedios sobre tareas heterogéneas no estrictamente comparables entre sí.

7.2.3 Solapamiento con el dataset de preentrenamiento Derm1M

La auditoría descrita en sección 3.1.1 identifica un único dataset evaluado, **Dermnet**, con solapamiento exacto frente al dataset de preentrenamiento Derm1M empleado por la familia DermLIP: sus 18 302 imágenes están íntegramente contenidas en Derm1M (100 % por hash MD5). HIBA y MSKCC, pese a su origen en el ISIC archive, no presentan ninguna coincidencia MD5 con Derm1M, por lo que la sospecha de procedencia no se confirma como solapamiento exacto (tabla 3.1).

Las métricas obtenidas sobre Dermnet con modelos cuya rama visual deriva de Derm1M (DermLIP v1, v2 y original) deben interpretarse con *caveat* y no son directamente comparables con las obtenidas sobre los datasets sin solapamiento. La sensibilidad de la métrica AUROC a la presencia de imágenes ya vistas en preentrenamiento puede inflar al alza las cifras zero-shot de DermLIP sobre Dermnet.

Las cifras de PanDerm Base y Large, DINOv2 ViT-L/14, ConvNeXt-Large, EfficientNetV2-Large y SigLIP-Large SO400M no se ven afectadas por este solapamiento, dado que su preentrenamiento no incluye Derm1M. Por consiguiente, los hallazgos cuantitativos sobre la ventaja del preentrenamiento de dominio (sección 6.1.1), la eficiencia en etiquetas (sección 6.1.3) y la comparación con CNNs (sección 4.2) permanecen defendibles incluso bajo el peor escenario de la auditoría.

La auditoría acota, no obstante, su propio alcance epistemológico. El hash MD5 detecta coincidencias *exactas* a nivel de bytes, pero no identifica *near-duplicates*: recortes, reescalados, recompresiones o alteraciones leves de una misma imagen. Lo que la auditoría sostiene es, por tanto, la ausencia de duplicación *exacta* entre los datasets de evaluación y Derm1M, no la ausencia completa de contaminación visual. Las cifras declaradas libres de solapamiento deben leerse en sentido estricto como libres de *solapamiento exacto*; la extensión natural —*perceptual hashing* o comparación por *embeddings* visuales— se identifica como refinamiento metodológico de la auditoría.

7.2.4 Tamaños muestrales por subgrupo en el experimento de equidad

Los tamaños muestrales del experimento de equidad sobre Fitzpatrick17k son asimétricos entre fototipos cutáneos: 299 imágenes para FST I, 470 para FST II, 325 para FST III, 261 para FST IV, 169 para FST V y 73 para FST VI en el conjunto de test (N total = 1597 con fototipo asignado). El subgrupo FST VI dispone de aproximadamente la cuarta parte de los ejemplos del subgrupo FST I y supone el 4,6% del conjunto de test.

La consecuencia estadística es que los intervalos de confianza al 95% por *bootstrap* sobre las cifras de BAcc por subgrupo de la tabla 4.8 son más amplios para FST V-VI que para FST I-IV, lo que limita la precisión cuantitativa del *gap* I-VI reportado. La interpretación cualitativa —rendimiento inferior sobre fototipos elevados— es robusta frente a esta asimetría muestral; la cuantificación exacta del *gap*, en cambio, queda condicionada por la menor masa muestral de los fototipos oscuros, y su acompañamiento con intervalos de confianza al 95% por *bootstrap* —incluido el *gap* I-VI de cada encoder— se reporta en el repositorio reproducible (A, sección A.6).

7.3 Limitaciones del diseño experimental

7.3.1 Variabilidad inter-semilla

Los protocolos de linear probe, eficiencia en etiquetas y evaluación de equidad por fototipo operan con una única semilla (`random_state = 42`); el protocolo de fine-tuning emplea también una única configuración de semillas (`torch`, `numpy`, `random` fijadas a 0). La variabilidad inter-semilla no se reporta de forma sistemática en estos protocolos, lo que limita la cuantificación de la incertidumbre estadística asociada a la inicialización aleatoria del clasificador lineal y al orden de muestreo durante el entrenamiento. La segmentación constituye la excepción: el cifra principal de Dice se acompaña de una validación cruzada de cinco pliegues con su intervalo de confianza (sección 4.5.3), por lo que en esa tarea la incertidumbre de partición sí queda acotada.

La consecuencia es que las cifras de las tablas 4.1, 4.3, 4.4 y 4.8 son estimaciones puntuales sobre una trayectoria de optimización concreta y no incluyen su variabilidad esperable bajo distintas inicializaciones. Las heurísticas operativas extraídas en sección 6.1.4 (régimen $N_{\text{train}} \lesssim 500$ para preferencia de linear probe) son cualitativas y robustas, pero los umbrales exactos pueden desplazarse bajo otras semillas.

Esta limitación se acota por dos consideraciones. La semilla fija respondió al objetivo de comparar arquitecturas bajo un protocolo constante, aislando el efecto del modelo del de la inicialización. Y la magnitud de los efectos cualitativos sobre los que se sostienen las conclusiones —del orden de +9,0 pp en la ventaja del preentrenamiento de dominio o de 43,5 pp en la brecha entre encoders especializados y LLMs generalistas— excede ampliamente la variabilidad inter-semilla esperable para un clasificador lineal sobre estos tamaños muestrales, por lo que no se anticipan cambios cualitativos en las conclusiones. El reporte sistemático de media y desviación estándar sobre múltiples semillas constituye, en todo caso, la extensión natural de este protocolo.

7.3.2 Pruebas estadísticas y comparaciones múltiples

El test de DeLong [39] se ha aplicado a los contrastes pareados entre encoders sobre tres *endpoints* binarios centrales de detección de lesión maligna —Fitzpatrick17k (malignidad), HAM10000 (melanoma) y DermapixelAI 1.0 (malignidad)—, con corrección de Holm dentro de cada *endpoint* (sección 4.8.1; tabla detallada en el repositorio reproducible, A.5). El cierre estadístico se concentra, no obstante, en Fitzpatrick17k, el único con potencia muestral suficiente (226 positivos); en HAM10000 (70) y DermapixelAI 1.0 (58 en validación cruzada) ningún contraste alcanza significación, un patrón compatible con la falta de potencia y no con la ausencia de efecto. El acompañamiento de cada cifra principal con su intervalo de confianza al 95 % por *bootstrap* se reporta en el repositorio reproducible (sección A.6); la extensión del contraste pareado de DeLong al resto de tablas multiclase del capítulo queda como continuación natural del trabajo.

La consecuencia operativa es que la superioridad de los encoders de dominio sobre los generalistas queda establecida estadísticamente sobre el *endpoint* con potencia (Fitzpatrick17k), mientras que el resto de hallazgos numéricos del capítulo 4 —y la ordenación fina entre los dos líderes específicos— deben interpretarse en términos descriptivos y de magnitud del efecto: las afirmaciones de *superioridad estadísticamente significativa* en los demás *endpoints* requieren mayor tamaño muestral. Los patrones cualitativos identificados en la discusión son, no obstante, robustos frente a esta limitación por la magnitud absoluta de los efectos cuantificados.

7.3.3 Sensibilidad al *prompt* en zero-shot y LLMs

La evaluación zero-shot multimodal y la comparación con LLMs multimodales operan sobre formulaciones concretas de *prompts* que condicionan los resultados reportados. La diferencia de 48,8 pp AUROC entre la peor y la mejor configuración de DermLIP sobre HAM10000 (sección 4.6) cuantifica la magnitud de esta dependencia para la rama contrastiva. La generalización a otras formulaciones requiere validación específica.

Para los LLMs multimodales, el *prompt* clínico de aproximadamente 300 palabras descrito en sección 3.9.6 introduce una formulación fija que no se ha auditado mediante barrido sistemático de longitud, orden de las clases candidatas o inclusión de descriptores anatómicos. El sesgo léxico documentado en sección 6.1.7 (GPT-4o emite 284 predicciones de dermatofibroma frente a 8 muestras reales) sugiere que el modelo responde al espacio léxico del *prompt*, lo que amplifica el efecto de la formulación. Las cifras de la tabla 4.7 son condicionales a este *prompt* y no caracterizan el rendimiento de los modelos bajo formulaciones alternativas. Una caracterización sistemática de la sensibilidad al *prompt* en LLMs queda fuera del alcance del trabajo y se documenta como línea futura en el repositorio reproducible (A, sección A.10).

7.4 Limitaciones del dataset DermapixelAI 1.0

El dataset DermapixelAI 1.0 entregado como contribución del trabajo presenta cuatro limitaciones específicas declaradas explícitamente en el repositorio reproducible (A, sección A.8) y en el documento formal de entrega (sección A.4).

Desbalance estructural por modalidad. La distribución por modalidad es 1 036 imágenes de fotografía clínica frente a 49 imágenes dermatoscópicas, lo que limita el uso del dataset para entrenamiento o evaluación de tareas dermatoscópicas. El predominio clínico refleja la finalidad docente original del archivo Dermapixel, no una decisión de diseño del trabajo, pero condiciona la utilidad del dataset para benchmarks comparativos con HAM10000, BCN20000, ISIC2018 u otros conjuntos dermatoscópicos.

Cobertura ontológica parcial. El dataset contiene anotación L3 sobre 250 diagnósticos distintos, sobre las 367 entradas declaradas en la ontología, lo que corresponde a una cobertura efectiva del 68,1 % del vocabulario L3 con al menos una imagen. El diagnóstico L3 más frecuente concentra aproximadamente el 32 % del dataset, lo que reproduce la long tail típica del material clínico. Esta cobertura parcial limita el uso del dataset para evaluación granular sobre L3 sin agregación a L2.

Tres cifras de validación no intercambiables. La distinción entre los tres campos de validación documentados en el repositorio reproducible (A, sección A.8) es relevante para la interpretación correcta de las cifras de calidad. El 97,89 % del dataset con `label_source = ontology` indica mapeo ontológico validado del vocabulario, no verificación visual caso-a-caso. El 84,39 % con `rosa_verified` corresponde a la revisión visual explícita por la Dra. R. Taberner. La cifra de validación textual `diagnosis_source = expert_v3` (98,38 %) se refiere a la coherencia del razonamiento textual con el diagnóstico asignado, sin verificación visual de la imagen asociada. Las tres cifras deben declararse con precisión en cualquier comunicación derivada y no son intercambiables.

Splits y tamaños reducidos. La partición *case-aware* del dataset (891/157/41 imágenes en *train/val/test*) es metodológicamente correcta para evitar fuga de información entre imágenes del mismo caso clínico, pero produce un conjunto de test reducido (41 imágenes en el *split* de producción; los contrastes por nivel ontológico se evalúan sobre el subconjunto filtrado, $N = 36$ en L1/L2 y $N = 28$ en L3) que limita la potencia estadística de los contrastes realizados sobre él. La explotación experimental sistemática sobre DermapixelAI 1.0 se ha pospuesto al periodo posterior al cierre de este documento por esta razón. En consecuencia, las conclusiones comparativas sobre el dataset —en particular la jerarquía entre métodos en L2 y L3 y la narrativa de Dermapixel R0— se anclan en la validación cruzada agrupada por caso (sección 6.1.10, tabla 5.2) y no en la cifra puntual del *split* fijo, que sobrestima la BAcc sobre este *test* reducido.

7.5 Limitaciones de generalización clínica

7.5.1 Material de archivo frente a flujo asistencial real

El estudio mide rendimiento sobre fotografías procedentes de archivos de investigación curados (HAM10000, BCN20000, ISIC2018) o de archivos clínicos con verificación posterior (HIBA, MSKCC, DDI, Fitzpatrick17k). El rendimiento sobre material adquirido en el flujo real de teledermatología, sobre fotografías de atención primaria con dispositivos heterogéneos (variabilidad de iluminación, distancia focal, encuadre, calibración

cromática) o sobre material adquirido en consulta presencial sin estandarización no se aborda en este trabajo. La extrapolación de las cifras de la tabla 4.1 a estos escenarios requiere validación adicional sobre cohorte representativa del entorno de despliegue previsto, particularmente en el contexto del proyecto institucional de teledermatología con IB-Salut descrito en sección 1.1.

7.5.2 Sesgo de modalidad de los componentes evaluados

Varios de los protocolos evaluados se apoyan en dataset predominantemente dermatoscópicos: la clasificación adaptada sobre HAM10000, la segmentación promptable adaptada sobre ISIC2018 (sección 4.5) y la lista de comprobación de siete puntos, cuyos criterios son intrínsecamente dermatoscópicos. Dado que la entrada mayoritaria en un escenario de teledermatología real es la fotografía clínica —como refleja la propia composición del dataset DermapixelAI 1.0, con 1 036 imágenes clínicas frente a 49 dermatoscópicas (sección 7.4)—, la transferencia de estos componentes a fotografía clínica no estandarizada queda como limitación operativa conocida. Su mitigación —clasificación previa de la modalidad de imagen y encaminamiento diferenciado por tipo— se identifica como línea de continuación y no se aborda en este trabajo.

7.5.3 Ausencia de validación prospectiva

El trabajo no aborda la validación clínica prospectiva sobre cohorte hospitalaria real con protocolo aprobado por Comité Ético de Investigación Clínica (CEIC). Esta limitación es estructural y se asume explícitamente como decisión de alcance en sección 7.5.4. La validación prospectiva del prototipo DermApIxel descrito en el repositorio reproducible (A, sección A.11) sobre cohorte del HUSLL requiere prerequisites administrativos y temporales (aprobación CEIC, definición de *endpoints* clínicos primarios y secundarios, cálculo muestral, contratación de revisores independientes) que exceden el alcance del Trabajo de Fin de Grado y se identifican como línea de continuación inmediata en la sección 8.5 del capítulo 8.

7.5.4 Elementos no abordados por decisión de alcance

Tres restricciones explícitas condicionan, además, el diseño experimental y la interpretación de los resultados. En cuanto al **hardware**, todas las ejecuciones se realizan sobre la NVIDIA DGX Spark descrita en la sección 3.5, cuya arquitectura aarch64 no coincide con el hardware x86_64 dominante en la literatura. En cuanto al **acceso a datos**, los conjuntos internos del grupo de la Universidad Monash empleados en el preentrenamiento de PanDerm no son accesibles para terceros (sección 7.1.2), lo que limita el trabajo a los pesos liberados y a la evaluación sobre datasets externos públicos. En cuanto al **acceso a modelos**, los pesos de DermFM-Zero no son públicos en la fecha de cierre (sección 7.1.1), lo que impide su evaluación empírica directa y restringe su tratamiento a la discusión conceptual.

Cinco elementos quedan, por decisión de alcance, fuera del trabajo, y deben reconocerse como limitaciones del documento aunque sean por decisión deliberada: (i) el preentrenamiento desde cero de un modelo fundacional propio, que requeriría acceso al material de las cuatro modalidades dermatológicas en volumen comparable al de

PanDerm (~ 2,1 millones de imágenes); (ii) la integración operativa con el sistema PACS y el visor radiológico del HUSLL, que excede el alcance técnico del trabajo experimental; (iii) el reentrenamiento multilingüe de la rama lingüística sobre dataset en español de gran escala, condicionado a la disponibilidad futura de material en cantidad suficiente; (iv) la certificación CE como producto sanitario (*Software as a Medical Device*), que requiere un proceso regulatorio y de auditoría independiente no contemplado; y (v) el análisis sistemático de calibración (*Brier score* y ECE en todas las tareas) y la evaluación de utilidad clínica mediante análisis de curva de decisión (*decision curve analysis* y *net benefit*), cuyo objeto —fijar umbrales operativos y cuantificar el beneficio neto de una decisión asistida— excede el de este trabajo, centrado en la capacidad discriminativa y la adaptación de los modelos; la calibración se reporta de forma puntual donde resulta directamente relevante (ECE en segmentación, en *zero-shot* L3 y en el *endpoint* de melanoma de HAM10000), y su tratamiento sistemático queda como continuación natural hacia una eventual evaluación de despliegue.

7.6 Síntesis: dominio de validez de los resultados

El conjunto de limitaciones declarado en este capítulo acota el dominio de validez de las cifras reportadas en el capítulo 4 pero no invalida los patrones cualitativos identificados en la discusión. Cinco afirmaciones resisten al peor escenario combinado de muestreo, semilla, sensibilidad al *prompt* y restricciones de modelos cerrados, y constituyen la evidencia empírica defendible del trabajo en relación con el planteamiento descrito en sección 1.2:

1. La **ventaja del preentrenamiento sobre el dominio clínico** frente a encoders generalistas.
2. La **saturación temprana del linear probe**, que alcanza el grueso de su rendimiento con 1–5 % de los datos etiquetados.
3. La **brecha entre encoders específicos y LLMs multimodales generalistas**, a favor de los primeros.
4. El **gap sistemático por fototipo cutáneo**, con sentido peor-en-fototipos-elevados y consistente entre encoders.
5. La **ausencia de un método óptimo único y la consiguiente especialización por tarea** (sección 6.1.1), lectura transversal que sintetiza las cuatro anteriores.

Las cuatro primeras son afirmaciones directas; la quinta es una lectura de orden superior que emerge de leerlas en conjunto. Su cuantificación y su lectura como conclusiones se desarrollan en el capítulo 8 (sección 8.1). La quinta está, además, acotada por el tamaño moderado del dataset DermapixelAI 1.0 (sección 7.4), su long tail en el nivel L3 y el carácter exploratorio de varios de los contrastes por nivel ontológico: el patrón cualitativo es robusto, pero no constituye una ordenación cuantitativa cerrada entre métodos, cuya validación requeriría los tamaños muestrales y la cohorte prospectiva descritos en el capítulo 8.

CONCLUSIONES

8.1 Síntesis de la evaluación

El planteamiento descrito en sección 1.2 se desarrolló mediante la evaluación empírica de catorce modelos fundacionales sobre doce datasets externos públicos armonizados a una ontología jerárquica L1/L2/L3, bajo cuatro protocolos principales (linear probe, fine-tuning supervisado, segmentación binaria promptable y clasificación zero-shot multimodal) y tres protocolos complementarios (equidad por fototipo cutáneo, comparación con modelos de lenguaje multimodales generalistas, auditoría de solapamiento con el dataset de preentrenamiento Derm1M). La evidencia disponible sostiene cuatro afirmaciones cualitativas, en las que se resumen los hallazgos defendibles del trabajo.

Primera. Ventaja del preentrenamiento sobre el dominio clínico. PanDerm Large es, entre los encoders contrastados con pesos públicos, el de mejor rendimiento agregado sobre los diez datasets externos, con una mejora media respecto a PanDerm Base de +9,0 pp en BAcc y +3,6 pp en AUROC bajo linear probe, máxima sobre los datasets más heterogéneos. El fine-tuning con la receta original aumenta la BAcc en +47,1 pp sobre HAM10000 y +19,4 pp sobre PAD-UFES-20. Frente a las arquitecturas convolucionales supervisadas, la ventaja crece con la dificultad del dataset (+0,5 pp accuracy sobre HAM10000, +8,2 pp sobre PAD-UFES-20).

Segunda. Saturación temprana del linear probe. El linear probe sobre encoders preentrenados específicos de dominio alcanza saturación con un volumen de datos etiquetados muy reducido: con 1 % del conjunto de entrenamiento de HAM10000 (82 imágenes), PanDerm Large recupera 95,7 % de la accuracy y 96,2 % del AUROC del modelo entrenado con el conjunto completo; con 5 % (410 imágenes), AUROC alcanza 97,7 % del valor máximo. Sobre PAD-UFES-20, 14 imágenes de entrenamiento (1 %) bastan para alcanzar 0,907 AUROC, equivalente al 95,5 % del rendimiento con el conjunto completo. Esta eficiencia es relevante para contextos clínicos con disponibilidad limita-

da de etiquetas: enfermedades raras, centros de bajo volumen asistencial, subgrupos poco representados y extensión a especialidades dermatológicas no cubiertas por los benchmarks habituales.

Tercera. Brecha entre modelos específicos y LLMs multimodales generalistas. La comparación de paradigmas sobre HAM10000 cuantifica un gradiente de rendimiento de 43,5 pp de accuracy entre el mejor especialista ajustado (PanDerm Base FT con TTA, 0,920) y el mejor modelo de lenguaje multimodal generalista *zero-shot* (GPT-4o, 0,485). La adaptación con LoRA sobre MedGemma 27B reduce parcialmente esta brecha (+13,7 pp Acc HAM, +18,3 pp Acc DDI), pero no sistemáticamente entre datasets (−1,7 pp sobre PAD-UFES-20). La consecuencia operativa para sistemas de apoyo al diagnóstico es que los LLMs multimodales generalistas no constituyen sustitutos defendibles de los encoders fundacionales específicos del dominio en el régimen clínico evaluado, sin perjuicio de su papel complementario como generadores de razonamiento textual o explicaciones.

Cuarta. Gap sistemático por fototipo cutáneo. Los cinco encoders contrastados sobre Fitzpatrick17k completo presentan *gap* I-VI positivo sobre la formulación de tres clases de malignidad, con valores en BAcc entre +0,124 (BiomedCLIP) y +0,306 (DINOv2 ViT-L/14). La paradoja BiomedCLIP, con *gap* mínimo asociado a la peor BAcc global (0,590), ilustra que la métrica de equidad aislada no constituye un criterio decisonal: un modelo uniformemente inferior puede presentar baja desigualdad sin ser equitativo en sentido sustantivo. El modelo con mejor compromiso entre rendimiento global y equidad es PanDerm Large (BAcc 0,699, *gap* +0,217); DermLIP v2 ofrece la mejor BAcc global (0,721) con *gap* superior (+0,281).

Síntesis. No hay modelo universalmente superior, sino especialización por tarea. Leídas en conjunto, las cuatro afirmaciones no convergen en un modelo vencedor único, sino en que el rendimiento dermatológico es función conjunta del nivel ontológico, del régimen de datos, de la modalidad de entrada y de la estrategia de adaptación: clasificación general, subcategoría L2, long tail L3, ranking probabilístico, segmentación y cribado de melanoma no se resuelven con el mismo método óptimo (sección 6.1.1). El modelo y el protocolo adecuados se seleccionan en función del objetivo clínico y de las restricciones de cómputo, datos y supervisión, no en abstracto.

Corolario: la palanca de mejora son los datos. El corolario transversal es que la palanca dominante de mejora son los datos: la ventaja de PanDerm y DermLIP procede de la escala y el dominio de su preentrenamiento, la adaptación de Dermapixel R0 sólo es viable porque dispone de datos clínicos en castellano, y el nivel L3 queda limitado por la long tail. El siguiente salto en rendimiento clínico no se espera de sustituir el encoder, sino de ampliar y mejorar los datos —en cobertura diagnóstica, representación de fototipos y registro lingüístico— sobre los que se adapta y evalúa. Esta lectura concuerda con la evidencia reciente en IA clínica conversacional, donde la ventaja que aporta el andamiaje agéntico sobre el modelo base se estrecha conforme este madura [7]: alcanzada cierta madurez del componente central, el margen de mejora se desplaza desde la complejidad añadida hacia el sustrato.

8.2 Contribuciones reproducibles

Las contribuciones del trabajo se enumeran en orden decreciente de centralidad respecto a los objetivos del trabajo.

8.2.1 Contribuciones en el cuerpo del documento

1. **Reproducción experimental de PanDerm sobre arquitectura aarch64.** El pipeline de PanDerm Base y Large se ha verificado sobre NVIDIA DGX Spark con chip Grace Hopper GB10, 128 GB de memoria unificada, CUDA 13.0 y precisión BF16, con reproducción de los rangos numéricos reportados por Yan et al. [1] sobre los datasets compartidos. La portabilidad al chip Grace Hopper queda documentada como base operativa para grupos de investigación con hardware no estándar.
2. **Benchmark homogéneo de catorce modelos fundacionales sobre doce datasets.** El estudio comparativo aplica cuatro protocolos principales bajo configuración estándar (sección 3.9) sobre PanDerm Base y Large, DINOv2, tres variantes de DermLIP, BiomedCLIP, SigLIP-Large, SAM2.1-Large, GPT-4o, Gemini 2.5 Pro, Med-Gemma 4B Vision y 27B Text, y BLIP-2, más dos líneas de base de redes convolucionales supervisadas (ConvNeXt-Large y EfficientNetV2-Large) como referencia no fundacional. Las cifras se reportan con desglose por dataset y métrica (tabla 4.1, tabla 4.2), y la comparación de paradigmas frente a modelos de lenguaje multimodales se sintetiza en la sección 4.7 (tabla 4.7).
3. **Ontología jerárquica L1/L2/L3.** Cuatro categorías etiológicas, 43 subcategorías clínicas y 367 diagnósticos individuales codificados en SNOMED CT y CIE-10, validados por revisión experta de la Dra. R. Taberner. La ontología se aplica a la armonización de once de los doce datasets externos contrastados, agregando 72 654 imágenes sobre vocabulario común y habilitando comparaciones inter-dataset defendibles a nivel L1 y L2.
4. **Dataset DermapixelAI 1.0.** Primer dataset dermatológico verificado en español con imagen, metadatos y texto narrativo asociado (1 089 imágenes, 669 casos clínicos, mediana de 223 palabras por caso). Particionado bajo regla *case-aware* (891/157/41) y distribuido bajo licencia CC-BY-NC-SA 4.0 con datasheet formal y documento de entrega (repositorio reproducible, A, secciones A.8 y A.4).
5. **Auditoría sistemática de solapamiento con Derm1M.** Procedimiento por hash MD5 exhaustivo sobre los doce datasets externos contrastados, con identificación de Dermnet como único conjunto con solapamiento exacto (100 % contenido en Derm1M) y declaración de *caveat* explícito sobre las cifras zero-shot de la familia DermLIP en ese dataset.
6. **Marco metodológico reproducible de evaluación.** La articulación de las contribuciones anteriores bajo un protocolo común constituye en sí misma un marco de evaluación reproducible y transferible a futuros modelos fundacionales dermatológicos, con código, *splits* canónicos y *outputs* documentados en el repositorio reproducible (A, sección A.13).

8.2.2 Contribuciones complementarias

6. **Análisis empírico de equidad por fototipo.** Evaluación de cinco encoders sobre Fitzpatrick17k completo (16577 imágenes, 6 fototipos cutáneos) con cuantificación del *gap* I-VI por modelo (tabla 4.8) y análisis cruzado *Light* ↔ *Dark* (detallado en el repositorio reproducible, A, sección A.5).
7. **Caracterización de la sensibilidad al tokenizer en DermLIP.** Identificación del tokenizer y la formulación del *prompt* como factores críticos del rendimiento zero-shot, con diferencia de 48,8 pp AUROC entre la peor y la mejor configuración sobre HAM10000.
8. **Adaptación de SAM2.1 al dominio dermatoscópico mediante fine-tuning del decoder.** Ajuste denso del *mask_decoder* y el *promptable encoder* (~ 4,2 M pesos entrenables), congelando el *image_encoder* Hiera-Large preentrenado. Resultado de Dice 0,947 sobre ISIC2018 (+2,6 pp sobre la cifra publicada por Yan et al. [1]), con transferencia fuera de dominio prácticamente nula sobre ISIC2017 (0,945) y PH2 (0,960).
9. **Ensemble de seguridad para detección de melanoma.** Combinación OR *top-3* de PanDerm Large ajustado sobre HAM10000 (M1) y SigLIP-Large SO400M con linear probe, que alcanza *recall* de melanoma del 100 % (70 de 70, *top-3*) sobre el conjunto de test de HAM10000.
10. **Modelo de cuello de botella conceptual SAE × SkinCon.** Replicación del mecanismo de interpretabilidad por Sparse Autoencoders sobre PanDerm Large (SAE Large, 1024 → 16384 *features*, entrenado sobre 50454 imágenes) y su validación frente al diccionario clínico SkinCon [16] mediante un *Concept Bottleneck Model*, con AUROC media de 0,880 sobre los 22 conceptos con cobertura suficiente y 11 conceptos con AUROC del mejor predictor superior a 0,80. Los experimentos E1–E4 de validación conceptual sobre Derm7pt se detallan en el repositorio reproducible (A, sección A.9).
11. **Dermapixel R0: adaptación dermatológica multimodal en español.** Modelo inicializado desde PanDerm Large y adaptado sobre DermapixelAI 1.0, articulado en una rama supervisada (head L2 con LoRA $r = 16$, BAcc $0,363 \pm 0,007$, sección 5.3) y una rama contrastiva multimodal en castellano (sección 5.4). Es una de las primeras adaptaciones dermatológicas multimodales con texto clínico narrativo en español sobre un modelo fundacional abierto; su contribución reside en la metodología reproducible que establece, y su escalado con el banco hospitalario del HUSLL queda como continuación (sección 8.5.2).

8.3 Hallazgos metodológicos transferibles

Los hallazgos metodológicos del trabajo son transferibles a escenarios clínicos análogos y constituyen aportaciones operativas más allá del benchmark concreto evaluado. El primero es de orden estructural —la inexistencia de un método óptimo único— y enmarca a los restantes, que precisan las condiciones bajo las que cada estrategia resulta preferible.

Ausencia de un método óptimo único. El hallazgo transversal del trabajo es que ningún encoder ni estrategia de adaptación domina todos los escenarios: la configuración preferible depende del nivel ontológico, del régimen de datos, de la modalidad de entrada y del objetivo clínico (clasificación general, subcategoría clínica L2, long tail L3, ranking probabilístico, segmentación o cribado de seguridad). Esta especialización por tarea, sostenida en sección 6.1.1, implica que el diseño de un sistema de apoyo dermatológico debe formularse como selección condicional de modelo y protocolo, y no como adopción de un único encoder de referencia.

Régimen de aplicabilidad del linear probe. La comparación cuantitativa sobre cuatro datasets (sección 6.1.4) delimita un régimen operativo: para datasets con $N_{\text{train}} \lesssim 500$ imágenes, el sondeo lineal sobre PanDerm Large supera al fine-tuning completo en las cuatro métricas. El umbral se identifica sobre DDI ($N_{\text{train}} = 427$), donde el linear probe mantiene AUROC 0,827 frente a 0,682 del fine-tuning, descenso diagnóstico de sobreajuste pese a las aumentaciones de la receta canónica. La heurística derivada es monitorizar la AUROC sobre validación independiente y descartar el fine-tuning si el ranking de probabilidades degrada.

Compatibilidad tokenizer-encoder en zero-shot. La AUROC en clasificación zero-shot con modelos vision-language contrastivos depende críticamente de la compatibilidad entre el tokenizer empleado para los *prompts* y el espacio de *embeddings* del encoder textual del modelo. La verificación empírica de esta compatibilidad sobre un conjunto de validación del dominio es prerequisite de cualquier despliegue zero-shot defendible.

Ajuste del decoder sobre encoders promptables preentrenados a gran escala. El fine-tuning del decoder de SAM2.1-Large con encoder visual congelado ($\sim 4,2$ M parámetros, $< 2\%$ del total) supera al fine-tuning completo de *baselines* dermatológicos: las primitivas geométricas del encoder transfieren entre fuentes de adquisición sin reentrenamiento.

Limitación operativa del *gap* aislado como métrica de equidad. La paradoja Bio-medCLIP —*gap* I-VI mínimo (+0,124) con peor BAcc global (0,590)— demuestra que el *gap* aislado puede inducir conclusiones erróneas; el reporte conjunto de BAcc global, AUROC global y *gap* debería adoptarse como práctica estándar.

Recuperación k -NN como alternativa competitiva en la long tail. Sobre el nivel L3, dominado por una long tail estricta, la recuperación k -NN con FAISS sobre *embeddings* congelados resulta competitiva frente a las heads paramétricas, que carecen de muestras suficientes por clase (sección 6.1.1): cuando la cardinalidad excede la disponibilidad de etiquetas, la recuperación no paramétrica es preferible a la clasificación supervisada directa.

Interpretabilidad conceptual emergente vía Sparse Autoencoders. La descomposición de PanDerm Large mediante Sparse Autoencoders revela *features* alineadas con conceptos dermatológicos sin supervisión conceptual, validadas frente a SkinCon [16]

y al *Seven-Point Checklist* de Derm7pt, lo que habilita modelos de cuello de botella conceptual y una vía de trazabilidad clínica transferible a otros encoders del dominio.

8.4 Aportaciones a la práctica clínica

El trabajo aporta cuatro elementos directamente aplicables al diseño de sistemas de apoyo al diagnóstico dermatológico en el contexto del Servicio de Dermatología del HUSLL y, por extensión, al circuito de teledermatología institucional descrito en sección 1.1.

Arquitectura técnica defendible. Encoder PanDerm Large preentrenado y congelado por defecto, con head lineal multi-clase mediante regresión logística L-BFGS ($C = 1,0$, $\text{max_iter} = 5000$) en datasets con $N_{\text{train}} \lesssim 500$, o head ajustada con la receta de PanDerm Large en datasets con $N_{\text{train}} \gtrsim 5000$ y desbalance acusado. Segmentación con SAM2.1-Large adaptado mediante fine-tuning del decoder cuando la tarea requiera localización de lesión. Ensemble OR *top*-3 de M1 (PanDerm Large *fine-tuned*) y SigLIP-Large con sondeo lineal cuando la tarea sea cribado oportunista de melanoma con prioridad de *recall*.

Ontología armonizada como columna vertebral. La ontología L1/L2/L3 con codificación SNOMED CT y CIE-10 proporciona una columna vertebral semántica reutilizable para sistemas de información hospitalarios y compatible con la nomenclatura clínica del entorno. La presentación jerárquica al usuario clínico (predicción L3 acompañada de su agregación L2 y L1) aporta robustez frente a la incertidumbre en la long tail sin sacrificar especificidad cuando ésta sea fiable.

Dataset DermapixelAI 1.0 como recurso público en español. Habilita la reutilización del archivo Dermapixel en proyectos académicos posteriores, la adaptación de modelos vision-language a texto clínico en castellano y la validación de sistemas de apoyo sobre material de referencia docente reconocida en el ámbito hispanohablante.

Caveats explícitos sobre fuga de información. La auditoría de solapamiento entre datasets de evaluación y preentrenamiento aporta una práctica de reporte transferible a otros benchmarks dermatológicos. La declaración explícita de *caveats* de leakage en las tablas (tabla 3.1) y la consistencia entre la cifra reportada y su *caveat* asociado debería adoptarse como condición de defensibilidad en publicaciones del campo.

8.5 Trabajo futuro

Las líneas abiertas se enuncian como continuación natural del trabajo, sobre las contribuciones reproducibles de la sección 8.2: el escalado con el banco HUSLL, la validación clínica prospectiva, el aprendizaje activo *in-domain*, la IA agéntica y el reentrenamiento multilingüe de la rama lingüística, condicionados a recursos o aprobaciones específicas.

8.5.1 Escalado del dataset con el banco hospitalario HUSLL

El siguiente paso de mayor impacto será extender DermapixelAI 1.0 con el banco hospitalario del HUSLL (~ 22 000 estudios en archivo, con imagen clínica y dermatoscópica, diagnóstico final, edad y sexo), previa aprobación del Comité Ético de Investigación Clínica de las Illes Balears y anonimización conforme a la normativa de protección de datos. Su incorporación habilita la head L3 directa de Dermapixel R0 (sección 8.5.2), la validación clínica prospectiva (sección 8.5.3) y un análisis de equidad por fototipo más representativo de la población atendida que el disponible en Fitzpatrick17k.

Aprendizaje activo *in-domain* sobre la long tail L3. El resultado negativo de escala de la rama contrastiva (sección 5.4.3) informa que la palanca para la long tail L3 no es más datos genéricos, sino aprendizaje activo dirigido *in-domain*: identificar las clases peor cubiertas e invertir en ellas anotación experta bajo revisión de la Dra. R. Taberner. Queda como continuación natural una vez disponible el banco hospitalario.

Auditoría sistemática de *leakage* extensible. La auditoría por hash MD5 desarrollada para Derm1M (sección 3.1.1) es directamente extensible a los demás datasets de preentrenamiento dermatológicos: el siguiente paso será aplicar el mismo procedimiento sobre sus *splits* de evaluación canónicos para recalibrar las cifras *zero-shot* publicadas.

8.5.2 Dermapixel R0: adaptación dermatológica multimodal en español

Dermapixel R0 constituye, a juicio de este trabajo, su aportación más original: la adaptación de un modelo fundacional preexistente (PanDerm Large) al registro clínico en castellano, no un preentrenamiento a gran escala. Por diseño es una versión base (R0) sobre un dataset reducido; su relevancia no reside en una métrica de máximo rendimiento, sino en demostrar que un modelo dermatológico especializado en castellano puede construirse sobre un modelo fundacional liberado mediante adaptación eficiente, con un presupuesto de cómputo y datos al alcance de una institución hospitalaria. Articulado en una rama supervisada (head L2 con LoRA, BAcc $0,363 \pm 0,007$) y una rama contrastiva multimodal en castellano (sección 5.4), traslada al dominio una conclusión más amplia: la frontera de la especialización ya no la marca el acceso a grandes infraestructuras de preentrenamiento, sino la disponibilidad de datos clínicos bien curados, replicable por otras instituciones con archivos clínicos en su propia lengua. El siguiente paso será su escalado con el banco hospitalario del HUSLL, que habilita la head L3 directa (251 diagnósticos), hoy limitada por la long tail de DermapixelAI 1.0.

Cobertura experimental sobre DermapixelAI 1.0. Las técnicas de *transfer learning* sobre el dataset —fine-tuning denso, adaptación LoRA de Dermapixel R0, *Test-Time Augmentation*, ensemble multi-encoder y pérdida focal— quedan ejecutadas y reportadas en el capítulo 4. La línea CBM sobre conceptos SkinCon (condicionada a anotación) y la extensión vía banco HUSLL quedan como continuación, con el estado detallado de cada técnica y su coste en el repositorio reproducible (A, sección A.8).

Derm7pt + Sparse Autoencoders como ground-truth conceptual. Las anotaciones *Seven-Point Checklist* de Derm7pt (siete criterios por imagen) son ground-truth con-

ceptual no explotada por la literatura previa sobre Sparse Autoencoders. Los cuatro experimentos de este eje (correlación SAE-Derm7pt, *Concept Bottleneck Model*, cruce con el Grupo A y fine-tuning multitarea) están *ejecutados* (sección 4.9; repositorio reproducible, A.9): la base *sparse* aprendida sobre Derm1M alinea *features* con la taxonomía dermatoscópica sin entrenamiento específico (AUROC efectivo hasta 0,926) y el fine-tuning multitarea produce inferencia simultánea de melanoma y los siete criterios en una pasada (AUROC 0,891). La línea genuinamente abierta es extender el diccionario conceptual a los 15 conceptos adicionales propuestos por la Dra. R. Taberner (repositorio reproducible, A.9), condicionada a la anotación de ~ 200 imágenes por concepto.

8.5.3 Validación clínica prospectiva

La validación clínica prospectiva del prototipo DermApIxel (repositorio reproducible, A, sección A.11) sobre cohorte hospitalaria real del HUSLL queda como continuación bajo protocolo aprobado por CEIC-IB. El *recall* del 100% sobre melanoma reportado en el repositorio es prueba de concepto sobre material de archivo, no resultado clínico validado: su extrapolación al flujo asistencial real exige esta validación, requisito de cualquier despliegue operativo.

Recuperación visual densa como sistema de apoyo. La recuperación visual densa basada en FAISS sobre los *embeddings* de Derm1M ya opera en el prototipo (repositorio reproducible, A, sección A.11) con latencia inferior a 150 ms. El siguiente paso será evaluar su valor clínico sobre cohorte HUSLL e integrarla en la historia clínica electrónica.

Selección de arquitectura para segmentación promptable. La comparativa pareada de arquitecturas promptables (sección 4.5.1) delimita una pauta de selección reproducible (generación SAM2 sobre SAM v1, caja-*prompt* como factor determinante, MedSAM2-tiny como candidata para cómputo restringido). Queda como continuación un detector de lesión extremo a extremo que sustituya la caja manual y la validación sobre adquisición clínica no dermatoscópica.

8.5.4 IA agéntica y modelos multimodales en español

A medio plazo, la combinación de los componentes desarrollados (encoder PanDerm, ontología L1/L2/L3, dataset DermapixelAI, recuperación visual densa y LLM multimodal en local) habilita un agente clínico orquestado bajo control del facultativo, que incorpore evidencia estructurada externa y auditable. Frente al uso directo de un LLM multimodal generalista (sección 6.1.7), este esquema reduciría el sesgo léxico documentado y facilitaría la justificación clínica de la salida; su desarrollo es condicional a pesos abiertos con capacidad de razonamiento estructurado y se detalla en el repositorio reproducible (A, sección A.11). En otro dominio clínico, los agentes conversacionales que fundamentan sus recomendaciones en guías mediante razonamiento de contexto largo ya han demostrado un rendimiento no inferior al de médicos de atención primaria en tareas de razonamiento de manejo dentro de estudios simulados [7], lo que sitúa esta línea como una continuación realista y no meramente especulativa.

Reentrenamiento multilingüe de la rama lingüística. La sensibilidad documentada al tokenizer (sección 6.1.6) sugiere que reentrenar el encoder textual de DermLIP sobre texto clínico en español aportaría mejoras apreciables sobre el rendimiento *zero-shot* hispanohablante. La estrategia mínima viable aplica *continued pretraining* del encoder textual sobre los 669 casos clínicos de DermapixelAI 1.0 con su razonamiento narrativo, manteniendo congelado el encoder visual; la ampliada requiere un dataset de pares imagen-texto en español de mayor escala, condicional al escalado con el banco HUSLL (sección 8.5.1).

8.6 Cierre

El trabajo ha caracterizado empíricamente el rendimiento y la capacidad de generalización de catorce modelos fundacionales para imagen dermatológica, bajo cuatro protocolos principales y tres complementarios, sobre doce datasets externos armonizados a una ontología jerárquica de tres niveles validada por revisión experta. La lectura de conjunto no es la designación de un encoder vencedor, sino una tesis matizada: el rendimiento dermatológico depende del nivel ontológico, del régimen de datos, de la modalidad de entrada y de la estrategia de adaptación, de modo que la elección de modelo y protocolo se resuelve en función del objetivo clínico (sección 6.1.1), lo que desplaza la palanca de mejora desde el encoder hacia la taxonomía, la cobertura de etiquetas, el alineamiento texto-imagen, los *prompts*, la equidad por fototipo y la estrategia de despliegue. Las líneas abiertas (sección 8.5) quedan formuladas como continuación natural de este recorrido, cuya primera etapa cierra el presente documento.

La aportación intelectual del trabajo se sitúa en la conjunción de tres elementos. El primero es una contribución empírica: la evaluación rigurosa y multi-eje del estado del arte, que cuantifica la dependencia del rendimiento respecto al nivel ontológico, el régimen de datos, la modalidad y la estrategia de adaptación. El segundo es una contribución de recurso: el dataset DermapixelAI 1.0 y la semilla Dermapixel R0 (contribuciones 8.2.1 y 8.2.2), primeros de su clase para texto clínico dermatológico en español. El tercero es la formulación explícita de líneas de continuación con base técnica y clínica verificable. De esta evidencia se desprende que el avance del campo no pasa por un único encoder de referencia, sino por una arquitectura modular que combine encoders, niveles ontológicos y estrategias de adaptación según la tarea, junto con decisiones de despliegue que contemplen cobertura de etiquetas, equidad y trazabilidad. El siguiente paso natural es la primera publicación derivada del trabajo, centrada en la comparativa de modelos fundacionales bajo la ontología armonizada, seguida del escalado de Dermapixel R0 como modelo fundacional dermatológico para texto clínico en español a partir del dataset DermapixelAI 1.0 extendido con el banco hospitalario del HUSLL.

BIBLIOGRAFÍA

- [1] Yan, S. *et al.* (2025). A multimodal vision foundation model for clinical dermatology. *Nature Medicine*, 31, 2691–2702. DOI: 10.1038/s41591-025-03747-y. Versión arXiv: 2410.15038v3. 2.4, 2.10, 3.2, 3.9.2, 4.5, 4.5, 6.1.5, 6.2.1, 6.2.2, 7.1.2, 1, 8
- [2] Yan, S., Hu, M., Jiang, Y., Li, X., Fei, H., Tschandl, P., Kittler, H., Ge, Z. (2025). Derm1M: A million-scale vision-language dataset aligned with clinical ontology knowledge for dermatology. arXiv:2503.14911v2. 2.5, 2.10, 3.2, 3.9.5, 5.2, 5.4.3, 6.1.1.1, 6.2.3
- [3] Yan, S., Li, X. *et al.* (2026). DermFM-Zero: A vision-language foundation model for zero-shot clinical collaboration and automated concept discovery in dermatology. arXiv:2602.10624v1. 2.6, 2.10, 3.4, 7.1.1
- [4] Taberner, R., Nadal, C., Llambrich, A., Vila, I.T.A. (2010). Dermatology service utilization and reasons for consultation by Spanish and immigrant patients in the region served by Hospital Son Llàtzer, Palma de Majorca, Spain. *Actas Dermo-Sifiliográficas* 101(4):323–329. 1.1, 7.2.1
- [5] Buendía-Eisman, A., Arias-Santiago, S., Molina-Leyva, A., Gilaberte, Y., Fernández-Crehuet, P., Husein-ElAhmed, H., Viera-Ramírez, A., Fernández-Peñas, P., Taberner, R., Descalzo, M.Á., García-Doval, I. (2018). Análisis de los diagnósticos realizados en la actividad ambulatoria dermatológica en España: muestreo aleatorio nacional DIADERM. *Actas Dermo-Sifiliográficas* 109(5):416–423. DOI: 10.1016/j.ad.2018.02.003. 1.1, 7.2.1
- [6] Tu, T., Palepu, A., Schaekermann, M., Saab, K., Freyberg, J., Tanno, R., Wang, A., Li, B., Amin, M., Tomasev, N., Azizi, S., Singhal, K., Cheng, Y., Hou, L., Webson, A., Kulkarni, K., Mahdavi, S.S., Semturs, C., Gottweis, J., Barral, J., Chou, K., Corrado, G.S., Matias, Y., Karthikesalingam, A., Natarajan, V. (2024). Towards conversational diagnostic AI. arXiv:2401.05654. 2.8
- [7] Liévin, V., Palepu, A., Weng, W.-H., Saab, K., Stutz, D., Cheng, Y., Kulkarni, K., Mahdavi, S.S., Barral, J., Webster, D.R., Chou, K., Hassidim, A., Matias, Y., Manyika, J., Tanno, R., Natarajan, V., Rodman, A., Tu, T., Karthikesalingam, A., Schaekermann, M. (2026). Towards Conversational AI for Disease Management. *Nature*. DOI: 10.1038/s41586-026-10764-5. 8.1, 8.5.4
- [8] Google DeepMind (2024). Advancing AMIE: a research AI agent for clinical reasoning, conversation and diagnosis (AI co-clinician). Disponible en <https://deepmind.google/blog/ai-co-clinician/>. Consultado en abril de 2026. 2.8

-
- [9] Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. 2.1, 2.2, 3.1
- [10] Kawahara, J., Daneshvar, S., Argenziano, G., Hamarneh, G. (2019). Seven-point checklist and skin lesion classification using multitask multimodal neural nets. *IEEE Journal of Biomedical and Health Informatics*, 23(2), 538–546. 2.1, 3.1, 4.9, 4.9, 4.9
- [11] Codella, N. *et al.* (2019). Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the International Skin Imaging Collaboration (ISIC). arXiv:1902.03368. 2.1, 2.2, 2.7, 3.1, 3.9.4
- [12] Pacheco, A.G.C. *et al.* (2020). PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones. *Data in Brief*, 32, 106221. 3.1, 5.4.3
- [13] Daneshjou, R. *et al.* (2022). Disparities in dermatology AI performance on a diverse, curated clinical image set. *Science Advances*, 8(31), eabq6147. 2.1, 2.2, 2.10, 3.1, 3.9.7, 6.2.4
- [14] DermNet New Zealand Trust. DermNet NZ: The dermatology resource. <https://dermnetnz.org> 3.1, 5.4.3
- [15] Groh, M. *et al.* (2021). Evaluating deep neural networks trained on clinical images in dermatology with the Fitzpatrick 17k dataset. *CVPR Workshops*. 2.1, 2.2, 2.9, 2.10, 3.1, 6.2.4
- [16] Daneshjou, R. *et al.* (2022). SkinCon: A skin disease dataset densely annotated by domain experts for fine-grained debugging and analysis. *NeurIPS Datasets and Benchmarks*. 2.9, 3.1, 4.9, 10, 8.3
- [17] Shen, Y. *et al.* (2024). SkinCAP: A multi-modal dermatology dataset annotated with rich medical captions. *arXiv preprint arXiv:2405.18004*. 2.2, 2.10
- [18] Oquab, M. *et al.* (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. 2.4, 3.2
- [19] Zhang, S. *et al.* (2024). BiomedCLIP: A multimodal biomedical foundation model pretrained from fifteen million scientific image-text pairs. *NEJM AI*, 1(7). 2.5, 3.2
- [20] Ravi, N. *et al.* (2024). SAM 2: Segment Anything in Images and Videos. arXiv:2408.00714. 2.7, 2.10, 3.2, 3.9.4, 4.6
- [21] Templeton, A. *et al.* (2024). Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet. Anthropic Research Blog. 2.6
- [22] Gershenwald, J.E., Scolyer, R.A., Hess, K.R., Sondak, V.K., Long, G.V., Ross, M.I., Lazar, A.J., Faries, M.B., Kirkwood, J.M., McArthur, G.A., Haydu, L.E., Eggermont, A.M.M., Flaherty, K.T., Balch, C.M., Thompson, J.F. (2017). Melanoma staging:

- Evidence-based changes in the American Joint Committee on Cancer eighth edition cancer staging manual. *CA: A Cancer Journal for Clinicians*, 67(6), 472–492. DOI: 10.3322/caac.21409. 1.1
- [23] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR 2021)*. 2.3
- [24] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askeell, A., Mishkin, P., Clark, J., Krueger, G., Sutskever, I. (2021). Learning transferable visual models from natural language supervision. *Proceedings of the 38th International Conference on Machine Learning (ICML 2021)*, 8748–8763. 2.3, 2.5, 5.4.1
- [25] Zhai, X., Mustafa, B., Kolesnikov, A., Beyer, L. (2023). Sigmoid loss for language image pre-training. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, 11975–11986. 2.5, 3.2
- [26] Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A.C., Lo, W.-Y., Dollár, P., Girshick, R. (2023). Segment anything. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2023)*, 4015–4026. 2.7, 3.9.4, 4.6
- [27] Li, J., Li, D., Savarese, S., Hoi, S.C.H. (2023). BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. *Proceedings of the 40th International Conference on Machine Learning (ICML 2023)*, 19730–19742. 2.6, 3.2
- [28] Johnson, J., Douze, M., Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535–547. DOI: 10.1109/TBDATA.2019.2921572. 2.5, 3.5
- [29] Combalia, M., Codella, N.C.F., Rotemberg, V., Helba, B., Vilaplana, V., Reiter, O., Carrera, C., Barreiro, A., Halpern, A.C., Puig, S., Malvehy, J. (2019). BCN20000: Dermoscopic lesions in the wild. arXiv:1908.02288. 3.1
- [30] Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J.W., Wallach, H., Daumé III, H., Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92. DOI: 10.1145/3458723. Versión original arXiv:1803.09010 (2018).
- [31] Esteva, A., Kuprel, B., Novoa, R.A., Ko, J., Swetter, S.M., Blau, H.M., Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118. DOI: 10.1038/nature21056. 2.1, 2.2, 2.10
- [32] Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. DOI: 10.1038/sdata.2018.161. 2.1
- [33] Salinas, M.P., Sepúlveda, J., Hidalgo, L., Peirano, D., Morel, M., Uribe, P., Rotemberg, V., Briones, J., Mery, D., Navarrete-Dechent, C. (2024). A systematic review and

- meta-analysis of artificial intelligence versus clinicians for skin cancer diagnosis. *npj Digital Medicine*, 7, 125. DOI: 10.1038/s41746-024-01103-x. 2.2
- [34] Liu, Y., Jain, A., Eng, C., Way, D.H., Lee, K., Bui, P., et al. (2020). A deep learning system for differential diagnosis of skin diseases. *Nature Medicine*, 26, 900–908. DOI: 10.1038/s41591-020-0842-3. 2.2
- [35] International Skin Imaging Collaboration (ISIC). ISIC Challenge. Disponible en <https://challenge.isic-archive.com/>. Consultado en junio de 2026. 2.2
- [36] Tjiu, J.-W., Lu, C.-F. (2025). Equity and generalizability of artificial intelligence for skin-lesion diagnosis using clinical, dermoscopic, and smartphone images: a systematic review and meta-analysis. *Medicina*, 61(12), 2186. DOI: 10.3390/medicina61122186. 2.2
- [37] Jairath, N., Pahalyants, V., Shah, R., Weed, J., Carucci, J.A., Criscito, M.C. (2024). Artificial Intelligence in Dermatology: A Systematic Review of Its Applications in Melanoma and Keratinocyte Carcinoma Diagnosis. *Dermatologic Surgery*, 50(9), 791–798. DOI: 10.1097/DSS.0000000000004223. 2.2
- [38] Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., Chen, W. (2022). LoRA: Low-Rank Adaptation of large language models. *International Conference on Learning Representations (ICLR 2022)*. arXiv:2106.09685. 2.7, 5.3.1
- [39] DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3), 837–845. 2.9, 3.7, 4.8.1, 7.3.2
- [40] Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83. DOI: 10.2307/3001968. 3.9.4, 4.6
- [41] Tejani, A.S., Klontzas, M.E., Gatti, A.A., Mongan, J.T., Moy, L., Park, S.H., Kahn Jr., C.E. (2024). Checklist for Artificial Intelligence in Medical Imaging (CLAIM): 2024 update. *Radiology: Artificial Intelligence*, 6(4), e240300. DOI: 10.1148/ryai.240300. 2.9, 3.7
- [42] Collins, G.S., Moons, K.G.M., Dhiman, P., Riley, R.D., Beam, A.L., Van Calster, B., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378. DOI: 10.1136/bmj-2023-078378. 2.9, 2.10, 3.7
- [43] Ma, J., He, Y., Li, F., Han, L., You, C., Wang, B. (2024). Segment anything in medical images. *Nature Communications*, 15, 654. DOI: 10.1038/s41467-024-44824-z. 3.9.4, 4.6
- [44] Ma, J., Yang, Z., Kim, S., Chen, B., Baharoon, M., Fallahpour, A., Asakereh, R., Lyu, H., Wang, B. (2024). MedSAM2: Segment anything in medical images and videos. arXiv:2408.03322. [Datos de venue aproximados.] 3.9.4, 4.6
- [45] Cheng, J., Ye, J., Deng, Z., Chen, J., Li, T., Wang, H., Su, Y., Huang, Z., Chen, J., Jiang, L., Sun, H., He, J., Zhang, S., Zhu, M., Qiao, Y. (2023). SAM-Med2D. arXiv:2308.16184. 3.9.4, 4.6



MATERIAL COMPLEMENTARIO Y REPOSITORIO REPRODUCIBLE

El cuerpo de esta memoria se circunscribe a la pregunta de investigación central: el rendimiento agregado y la capacidad de generalización de los modelos fundacionales para imagen dermatológica. El material instrumental, las tablas extendidas de resultados, los análisis complementarios y los artefactos de software derivados del trabajo se publican de forma estructurada en un repositorio reproducible público, con el fin de no fragmentar la argumentación del documento principal y de habilitar la verificación independiente de las cifras reportadas en el capítulo 4.

A.1 Repositorio público

El conjunto del material complementario se distribuye en el repositorio `dermapixel-tfg-EPS0270`, accesible a través de la página de documentación

`https://tcontesti.github.io/dermapixel-tfg-EPS0270/`

que actúa como portada e índice navegable del contenido. El repositorio contiene el código de los experimentos, el *datasheet* del dataset DermapixelAI 1.0, las tablas detalladas de resultados, la descripción del prototipo, las ablaciones complementarias, el material de interpretabilidad y la declaración de uso de herramientas de inteligencia artificial. Todas las cifras publicadas en el repositorio coinciden de forma exacta con las reportadas en el cuerpo de la memoria; no se introduce ningún resultado adicional que altere las conclusiones del documento principal.

A.2 Estructura de carpetas

El repositorio se organiza en directorios de responsabilidad disjunta. La tabla A.1 sintetiza su contenido.

Cuadro A.1: Estructura de directorios del repositorio reproducible.

Directorio	Contenido
code/	Pipelines de <i>linear probing</i> , <i>fine-tuning</i> , segmentación con LoRA y evaluación <i>zero-shot</i> .
datasheet/	<i>Datasheet</i> y documento de entrega del dataset DermapixelAI 1.0.
tables/	Tablas detalladas de resultados por dataset (equidad, evaluación cruzada, segmentación).
ablations/	Ablaciones complementarias sobre DermapixelAI 1.0 y rama contrastiva SpanDerm.
sae/	Diccionario de conceptos y modelos de interpretabilidad (<i>Sparse Autoencoders</i> , CBM).
llm/	Comparación extendida de modelos de lenguaje multimodales.
prototype/	Descripción del prototipo DermApIxel y de sus componentes.
repro/	Mapa de tareas experimentales, recetas de entrenamiento, semillas y <i>checkpoints</i> .
ai-statement/	Declaración sobre el uso de herramientas de inteligencia artificial.

A.3 Índice de correspondencia

La tabla A.2 establece la correspondencia entre el material complementario y su ubicación en el repositorio. Cada entrada puede consultarse a través de la página de documentación indicada en la sección A.1.

Cuadro A.2: Índice de correspondencia entre el material complementario y el repositorio.

Material complementario	Ubicación en el repositorio	Sección
Mapa de tareas y reproducibilidad	repro/	A.13
Tablas detalladas de resultados	tables/	A.5
Intervalos de confianza <i>bootstrap</i>	tables/	A.6
Calibración <i>endpoint</i> melanoma HAM10000	tables/	A.7
Pipeline y caracterización del dataset	datasheet/, ablations/	A.8
Declaración de uso de IA	ai-statement/	A.12
Documento de entrega del dataset	datasheet/	A.4
<i>Sparse Autoencoders</i> y conceptos	sae/	A.9
Modelos de lenguaje multimodales	llm/	A.10
Prototipo DermApIxel	prototype/	A.11
Ablaciones complementarias	ablations/	A.8

A.4 Datasheet del dataset DermapixelAI 1.0

El repositorio incluye el *datasheet* completo del dataset DermapixelAI 1.0 y el documento formal de entrega, con la identidad, la procedencia, la licencia CC-BY-NC-SA 4.0, las condiciones de disponibilidad, la composición, las recomendaciones de uso responsable y el plan de mantenimiento del recurso. La caracterización resumida del dataset figura en el capítulo 3.

A.5 Tablas detalladas de resultados

El repositorio recoge las tablas extendidas de resultados que desagregan, por dataset y por modelo, las cifras sintetizadas en el capítulo 4: el desglose de equidad por fototipo, la matriz de evaluación cruzada entre conjuntos, los resultados de segmentación por arquitectura y las tareas de transferencia adicionales.

A.6 Intervalos de confianza por *bootstrap*

El repositorio publica los intervalos de confianza al 95% por *bootstrap* ($B = 1000$, remuestreo estratificado por clase, percentil 2,5/97,5, semilla 42), celda a celda, de las métricas *headline* que en el cuerpo se reportan como estimaciones puntuales: el sondeo lineal de PanDerm sobre los conjuntos externos, la comparativa de paradigmas de razonamiento clínico, el desglose de equidad por fototipo y el *benchmark* frente a líneas base convolucionales. El material documenta el mecanismo de cómputo —reajuste determinista de un clasificador lineal sobre los *embeddings* congelados, o remuestreo directo sobre las predicciones guardadas, según el caso— y declara abiertamente las celdas no cubiertas y las convenciones de cálculo empleadas por fila.

A.7 Calibración en el *endpoint* de melanoma de HAM10000

El repositorio publica el detalle de la calibración de los tres codificadores en el *endpoint* binario melanoma frente al resto sobre el test de HAM10000 (sección 4.8.1, tabla 4.11): el error de calibración esperado (ECE, 15 *bins* de igual anchura sobre la probabilidad de la clase positiva) y el *Brier score*, junto con las curvas de fiabilidad por *bin* que los sustentan. Las probabilidades por muestra son exactamente las del test de DeLong de ese *endpoint* —reajuste determinista de la misma cabeza lineal sobre los *embeddings* congelados, sin reentrenamiento—; el cómputo verifica previamente, celda a celda, que la AUROC recomputada reproduce el valor publicado antes de admitir cualquier cifra de calibración.

A.8 Ablaciones complementarias

El repositorio documenta las ablaciones complementarias sobre el dataset Dermapix-IAI 1.0, el pipeline de construcción y caracterización del dataset, la ablación del modelo fundacional inglés con traducción ES-EN y las iteraciones de la rama contrastiva en castellano, incluyendo configuración de entrenamiento, barridos de épocas, techos de sondeo lineal y calibración.

A.9 Sparse Autoencoders y diccionario de conceptos

El repositorio contiene el material de interpretabilidad: la configuración de los *Sparse Autoencoders* sobre el modelo fundacional, el diccionario de conceptos clínicos, los modelos de cuello de botella conceptual (*Concept Bottleneck Models*) y los coeficientes derivados de las anotaciones *Seven-Point Checklist*.

A.10 Modelos de lenguaje multimodales

El repositorio presenta la comparación extendida de modelos de lenguaje multimodales evaluados como sistemas de razonamiento clínico, con el detalle de los *prompts*, los proveedores y las métricas que sintetiza el capítulo 4.

A.11 Prototipo DermApIxel

El repositorio describe el prototipo DermApIxel, que integra los componentes derivados del trabajo en un entorno operativo. Su evaluación operativa queda fuera del alcance del presente documento; el repositorio recoge la descripción de sus módulos, los resultados de *ensemble* y los análisis de recuperación visual y codificadores adicionales.

A.12 Declaración de uso de inteligencia artificial

El repositorio incluye la declaración sobre el uso de herramientas de inteligencia artificial durante la elaboración del trabajo, con el alcance, las herramientas empleadas y las responsabilidades del autor.

A.13 Reproducibilidad

El repositorio documenta el mapa de tareas experimentales, las recetas de entrenamiento, las semillas, las normalizaciones y los *checkpoints* necesarios para reproducir de forma independiente las cifras del capítulo 4 a partir del código publicado.